SÍLABO DEL CURSO

# IA Causal en Producción

*De la identificación al despliegue: estimar **efectos**, no solo predicciones, y poner políticas causales en producción en Hugging Face*

**Audiencia:** Profesionales (data / ML / product / analytics / risk / ops)
**Modalidad:** Online, asíncrona con checkpoints síncronos
**Duración:** 16 semanas (4 meses) · 32 sesiones de 1 h 30 · **48 horas cronológicas**
**Balance:** 50% teoría causal · 50% práctica (casos + HF)
**Curso:** ECO-490 / ECON-540 — Edición 2026

**Promesa del curso.** Deja de priorizar con scores que confunden correlación con impacto. Aprende a **estimar efectos**, documentar supuestos y desplegar políticas causales en **Hugging Face** — con monitoreo de cuándo dejan de ser válidas.

Monografía del curso (32 caps., Typst/PDF) · *Designing Machine Learning Systems* (Huyen) · *Causal Artificial Intelligence* (Bareinboim) · Monorepo: labs L01–L28 · Serie A/B · datos de benchmark

# 1. Presentación y fundamentación

Este curso está diseñado para **profesionales** que ya usan datos o machine learning y deben **decidir o priorizar intervenciones** —no para formar investigadores básicos en econometría teórica—. Combina tres fuentes: (1) el marco de IA causal de Elias Bareinboim (*Causal Artificial Intelligence*); (2) la monografía del curso *IA Causal en Producción* (32 capítulos, Typst/PDF en `02_monografia/`); (3) la filosofía de ingeniería de *Designing Machine Learning Systems* (Chip Huyen), aplicada a **sistemas cuyo objetivo es un efecto causal**, no solo un score predictivo.

**Disrupción que se enseña.** Un modelo predictivo responde «¿quién tiene peor outcome?» Un sistema causal responde «¿a quién **cambia** el outcome si actuamos?». Esa diferencia reordena presupuestos, targeting, go/no-go de programas y riesgo de políticas injustas. Cada bloque del curso cierra con la pregunta: **si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?**

**Balance 50/50.** La teoría (identificación y estimación) se ancla en monografía + Bareinboim. La práctica sigue el ciclo DMLS (datos, features, evaluación, despliegue, monitoreo) y se materializa en el **monorepo del curso**: labs de sesión (L01–L28), notebooks de caso (Serie A) y producción en Hugging Face (Serie B). Ningún módulo termina en un análisis de notebook aislado: termina en un **artefacto operable** (estimación auditada, API, model card, Space o dashboard).

**Navegación del libro.** La monografía tiene **32 capítulos**. En este sílabo, la columna **Lectura** usa la **numeración actual del PDF** (no la de ediciones cortas anteriores). Ante duda: `PLAN_INTEGRACION_MONOGRAFIA.md` (tabla maestra S ↔ Cap ↔ Lab ↔ A/B).

# 2. Filosofía pedagógica: DMLS + efecto causal

**Cuadro sinóptico del capítulo**

- **Decisiones de diseño, no tutoriales de una receta.** Online vs batch, reentrenar vs alertar, biblioteca vs servicio — aplicados a **validez del efecto**.
- **Proceso iterativo.** Identificar → estimar → servir en HF → monitorear supuestos → actualizar.
- **Cuatro requisitos en producción (versión causal):** confiabilidad del efecto, escalabilidad del pipeline, mantenibilidad de la identificación, adaptabilidad ante drift de supuestos.
- **Lado humano.** Comunicar ATE/CATE a no técnicos; model cards honestas; equidad y límites de validez externa.

# 3. Objetivos de aprendizaje

## 3.1 Objetivo general

Capacitar a profesionales para **formular, estimar y desplegar** sistemas de IA causal en producción —con énfasis en **casos de estudio** y **Hugging Face**— de modo que puedan sustituir (o auditar) priorizaciones puramente predictivas por decisiones basadas en **efectos** documentados y monitoreables.

## 3.2 Objetivos específicos

- Distinguir asociación, intervención y contrafactual (PCH) y reconocer cuándo **no** estimar.
- Diseñar pipelines de datos con roles tratamiento / outcome / covariables sin fuga causal.
- Estimar ATE y CATE (DML, meta-learners, bosques causales) con inferencia válida y evaluación offline (Qini, placebo).
- Convertir CATE en **política** bajo presupuesto y compararla con baselines no causales.
- Empaquetar en HF: FastAPI/Docker, Hub, model card causal, CI/CD, Space, dashboard de drift.

- Comunicar resultados a audiencias de negocio con supuestos y límites explícitos.

## 4. Perfil de ingreso

Dirigido a **profesionales** (y posgrado aplicado) en datos, ML, producto, analítica, riesgo u operaciones.

- ☐ Python intermedio (pandas, scikit-learn); Git básico.
  - ☐ Estadística/econometría introductoria (regresión; deseable IV o evaluación de impacto).
  - ☐ Experiencia deseable con APIs o despliegue ligero (se cubre en el curso).
  - ☐ No se exige perfil de investigación ni demostraciones teóricas avanzadas (caps. electivos del libro son opcionales).

## 5. Unidades temáticas

Siete módulos · 16 semanas. Cada semana combina lectura de monografía (Cap. N del PDF) + lab de sesión (L##) y, en hitos, entrega Serie A o B.

- **Módulo 0** — Causalidad elemental y arranque (Semana 1)
- **Módulo 1** — Fundamentos y datos para sistemas causales (Semanas 2–4) → **A1**
- **Módulo 2** — Estimación con ML y primer despliegue HF (Semanas 5–7) → **A2, B1**
- **Checkpoint 1** — Integración (Semana 8) → **A3**
- **Módulo 3** — Hub, model cards y CI/CD (Semana 9) → **B2**
- **Módulo 4** — Explicación, decisión, policy y uplift (Semanas 10–12) → **A4, B3**
- **Módulo 5** — Monitoreo, discovery y frontera (Semanas 13–14) → **B4**
- **Módulo 6** — Proyecto final en HF (Semanas 15–16)

**Capítulos electivos del PDF (no bloquean el camino profesional):** Cap. 16 (PDS extendido), 17 (panel/DML-IV), 18 (mapa metodológico), 27 (deep causal), 28 (SCM/matrix completion). Ver plan de integración.

## 6. Metodología y materiales del monorepo

Curso online asíncrono; dos sesiones semanales de 1 h 30. Formato orientativo: 20 min concepto · 50–60 min práctica (lab) · 10–20 min cierre. Los pipelines completos son entregas quincenales, no actividades de una sola sesión.

**Carga horaria total: 48 horas cronológicas** (32 sesiones × 1 h 30), distribuidas en 16 semanas. Sobre ese total, el formato orientativo reserva ≈ 1/3 a concepto y ≈ 2/3 a práctica guiada y cierre.

| Componente | Ubicación en monorepo | Rol |
|---|---|---|
| Monografía PDF | `02_monografia/…/monografia.pdf` | Lectura Cap. 1–32 |
| Labs L01–L28 | `05_labs_sesion/` | Práctica formativa por sesión (sin L16) |
| Serie A (casos) | `03_notebooks_caso_estudio/` | 4 entregas: identificación, DML, CATE, policy |
| Serie B (HF) | `04_notebooks_produccion_hf/` | 4 entregas: API, Hub/CI, Space, monitor |
| Datos | `data_benchmark_causal/…/datasets/` | Jobs, IHDP, etc. (benchmark documentado) |
| Diapositivas | `07_diapositivas/capitulos/` | Mazo Touying por sesión ★; plan y novedades de la última edición en `07_diapositivas/PLAN_SPRINT_DIAPOSITI` |

| Componente | Ubicación en monorepo | Rol |
|---|---|---|
| Proyecto | `06_proyecto_final/` | Sistema causal en HF (40%) |
| Planes | `PLAN_CURSO_COMPLETO.md` y `PLAN_INTEGRACION_MONOGRAFIA.md` | Práctica + integración libro↔repo |
| Cronograma semanal | `CHRONOGRAMA_SEMANAL.md` | Uso de materiales por rol (profesor / estudiante) |

**Serie A** se evalúa por corrección metodológica; **Serie B** por humo de producción (endpoint/Space responde, artefactos auditables) más buenas prácticas. El proyecto exige **comparar ranking predictivo vs política causal** y pasar humo en HF o equivalente local documentado.

# 7. Planificación clase a clase

**Convención. Lectura** = capítulo de la monografía (numeración del PDF 2026). **Lab** = carpeta `05_labs_sesion/` (prefijo L). **Entrega** = A1–A4 o B1–B4. **Diapositiva** = mazo Touying en `07_diapositivas/capitulos/` (un archivo `capNN` por capítulo del PDF); hay un mazo por cada capítulo del camino ★, con callout de monorepo en los capítulos de despliegue/producción (4, 9, 15, 19, 20, 30).

**Actualización editorial vigente.** La monografía recibió una segunda pasada de mejoras (Etapa 2, C1–C11: score ortogonal canónico, eficiencia semiparamétrica, soporte común, tests de heterogeneidad, intervalos conformes, RATE, sensibilidad en tres niveles, EIF del **policy value**, **model card** machine-readable, inferencia robusta a instrumentos débiles) que afecta a 11 capítulos — varios de ellos en el bloque de Hugging Face. Las tablas de esta sección ya incorporan las novedades relevantes para la sesión en vivo; el detalle completo capítulo por capítulo está en `07_diapositivas/PLAN_SPRINT_DIAPOSITIVAS.md` §5 y en `02_monografia/monografia-ml-causal-typst/CHANGELOG_MEJORA.md`.

## Módulo 0 — Causalidad elemental y arranque (Semana 1)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S1 | Correlación ≠ causación; problema fundamental; escalera de Pearl (adelanto) | Cap. **1** Causalidad elemental | L01 | Casos espurios + Simpson; pregunta: ¿asociación o efecto? |
| S2 | Anatomía de un sistema ML en producción; requisitos de un sistema **causal** | Cap. **2** Anatomía del sistema | L02 | Lab 0: entorno Python, Git, HF, monorepo · **Cierre HF (10 min):** crear la cuenta y el token de Hugging Face no es un trámite: es la llave de todo el hilo de producción del curso. Con `huggingface_hub` (`notebook_login()`) se deja el entorno listo para subir datasets (S5, S8), modelos (S13) y Spaces (S23) sin volver a |

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| | | | | configurar. Herramienta: `huggingface_hub` + token de acceso. |

## Módulo 1 — Fundamentos y datos (Semanas 2–4)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S3 | SCM y Jerarquía Causal de Pearl (ver / hacer / imaginar) | Cap. **3** SCM y PCH | L03 | Clasificar 10 preguntas en la PCH |
| S4 | Ingeniería de datos: tratamiento, outcome, covariables, trazabilidad | Cap. **4** Ingeniería de datos | L04 | **Arranca A1** — roles T/Y/X (Jobs) |
| S5 | Regularización y post-selección (PDS); Cap. 16 del PDF es profundización ◇ | Cap. **6** Regularización (+ Cap. **16** PDS ◇) | L05 | PDS vs OLS vs diff-in-means · **Cierre HF (10 min):** subir el dataset de A1 (Jobs) al Hub como dataset versionado, para que el primer caso del curso quede disponible y trazable. Se usa `HfApi().create_repo(… repo_type=«dataset»)` + `upload_folder()` sobre la carpeta limpia de `data/`. Objetivo: que el estudiante vea que «datos listos» ya es un artefacto de producción, no solo un archivo local. |
| S6 | Datos de entrenamiento, muestreo, etiquetas naturales | Cap. **7** Datos de entrenamiento | L06 | **Entrega A1** — identificación + PDS |
| S7 | Operador do, puertas traseras, contrafactuales | Cap. **8** Intervención y contrafactual | L07 | Backdoor vs confusor latente (abstenerse) |
| S8 | Features sin fuga causal | Cap. **9** Features sin fuga | L08 | **Arranca A2** — cazar leakage · **Cierre HF (10 min):** subir el dataset limpio de A2 (IHDP) al Hub, ya sin columnas de fuga causal, como dataset versionado. Se usa `HfApi().upload_folde` |

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| | | | | `repo_type=«dataset»)` sobre la carpeta auditada por `auditar_features()`. Objetivo: el dataset «listo» (sin leakage) queda publicado y reutilizable, cerrando la sesión con un artefacto concreto. |

## Módulo 2 — Estimación causal y primer despliegue HF (Semanas 5–7)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S9 | Ortogonalidad de Neyman, cross-fitting y el **score ortogonal canónico** (PLR/IRM/DR/R/PLIV/policy value, una misma inferencia) | Cap. **10** Ortogonalidad | L09 | Residuales OOF; partialling-out; ubicar cada estimando futuro en la tabla del score canónico |
| S10 | DML: PLR e IRM, eficiencia semiparamétrica y diagnóstico cuantitativo de soporte común (ESS/trimming) | Cap. **11** DML | L10 | PLR mínimo; ATE con IC; reportar ESS/n y trimming ($\alpha^* \approx 0.057$, Crump et al. 2009) |
| S11 | Evaluación offline: baselines (+ RATE), Qini, placebo, sensibilidad en tres niveles (E-value / $R^2$ / Manski) | Cap. **14** Validación | L11 | **Entrega A2** — DML serializado → B1; profundización opcional: BLP/BEST/CLAN, intervalos conformes |
| S12 | Despliegue como servicio (FastAPI + Docker); `/metadata` ahora machine-readable | Cap. **15** Despliegue servicio | L12 | **Arranca B1** — stub `/health` `/predict` `/metadata` (valida contra JSON Schema, Ap. G.4) |
| S13 | Meta-learners S/T/X/R/DR (el DR-learner como instancia del score canónico del Cap. 10) | Cap. **12** Meta-learners | L13 | **Arranca A3** — T-learner / CATE · **Cierre HF (10 min):** subir el modelo DML de A2 (`.joblib` + `feature_list.json`) al Hub como artefacto versionado, para que el estimador «vi- |

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| | | | | va» en el Hub antes de la model card formal (S17). Se usa `HfApi().upload_file()` sobre `artifacts/A2/dml_estimator.` Objetivo: el modelo ya está publicado; en S17 solo falta documentarlo con la card. |
| S14 | Árboles y bosques causales | Cap. **13** Bosques causales | L14 | **Entrega B1** + avance A3 |

## Checkpoint 1 (Semana 8)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S15 | Integración: identificación + estimación + primer servicio | Repaso Caps. 1–15 | L15 | **Entrega A3** — checklist de sistema |
| S16 | Examen parcial y defensa de avance | — | — | Evaluación parcial (camino profesional ⋆) |

## Módulo 3 — Publicación y CI/CD en Hugging Face (Semana 9)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S17 | HF Hub y model cards **causales** (supuestos, no solo accuracy); ahora con **JSON Schema** machine-readable (Ap. G.4) | Cap. **19** Hub y model cards · Ap. G (incl. G.4) | L17 | **Arranca B2** — completar card y validarla contra el schema |
| S18 | CI/CD: Actions, tests de humo, **validación de schema** antes de publicar | Cap. **20** CI/CD | L18 | **Entrega B2** |

## Módulo 4 — Explicación, decisión, policy y uplift (Semanas 10–12)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S19 | Explicación causal vs asociativa; equidad | Cap. **23** Explicación y equidad | L19 | Casos: SHAP $\neq$ efecto |
| S20 | Interpretabilidad y fairness sobre estimadores causales | Cap. **24** Ética e interpretabilidad | L20 | Auditoría de importancia (asociativa) con advertencia |
| S21 | Decisiones estructurales bajo incertidumbre | Cap. **25** Decisiones estructurales | L21 | Formalizar la decisión de negocio |

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S22 | Policy learning y presupuesto; inferencia formal del **policy value** (EIF) para comparar dos políticas, no solo el punto | Cap. **21** Policy learning | L22 | **Arranca A4** — top-k B=20%; reportar IC de la comparación contra baseline |
| S23 | Uplift y targeting; Space de política | Cap. **22** Uplift | L23 | **Entrega A4** · **Arranca B3** (Gradio/Space) |
| S24 | Transportabilidad entre dominios | Cap. **26** Generalización | L24 | ¿El efecto vale en **mi** mercado? |

## Módulo 5 — Monitoreo y frontera (Semanas 13–14)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S25 | Drift de covariables y estabilidad del efecto en producción; si el sistema usa PLIV, monitorear también la fuerza del instrumento (doble umbral F y test de Anderson-Rubin, Cap. 17) | Cap. **30** Monitoreo (+ Cap. **17** PLIV ◇) | L25 | **Arranca B4** — métricas KS + chequeo de fuerza de instrumento si aplica |
| S26 | Descubrimiento de estructura (PC/NOTEARS; lab con esqueleto) | Cap. **29** Discovery | L26 | **Entrega B3** · avanza B4 |
| S27 | Continual learning; panorama RL causal | Cap. **31** Aprendizaje continuo | L27 | Reentrenar vs alertar |
| S28 | Lado humano: comunicación y responsabilidad | Cap. **32** Lado humano | L28 | **Entrega B4** — comunicar ATE |

## Módulo 6 — Proyecto final (Semanas 15–16)

| S | Tema | Lectura monografía | Lab | Actividad / entrega |
|---|---|---|---|---|
| S29 | Trabajo autónomo + mentoría | Ap. E, G (incl. G.4), H · guía `06_proyecto_final/` | P1 | Repo + identificación + baseline |
| S30 | Peer review estructurado | Rúbrica del curso | P2 | Evaluar 2–3 proyectos (10%) |
| S31 | Defensa del sistema causal en HF | — | P3 | **Entrega final 40%** + humo |
| S32 | Cierre y frontera (CRL, RL causal — panorama) | Caps. electivos 27–28 si aplica | P4 | Encuesta; límites y trabajo futuro |

### 7.1 Foco Hugging Face: qué construimos y qué cambió (Etapa 2)

La Serie B entrega cuatro piezas de producción sobre Hugging Face (Hub, Spaces, Actions), cada una construida sobre la anterior. La segunda pasada de mejoras de la monografía (Etapa 2) tocó

específicamente lo que se documenta y valida en el Hub — no la arquitectura del despliegue, que no cambió.

**Hugging Face como hilo conductor.** A lo largo del curso hay **10 puntos de contacto** con Hugging Face: **4 de refuerzo corto** (cierre de 10 minutos) en las sesiones **2** (setup de cuenta/token), **5** (subir dataset de A1 al Hub), **8** (subir dataset limpio de A2 sin fuga al Hub) y **13** (subir el modelo DML de A2 al Hub como artefacto); y **6 de contenido central** en las sesiones **12** (despliegue del endpoint, B1), **17** (Hub y model cards, B2), **18** (CI/CD, B2), **23** (Space de política, B3), **25** (monitoreo, B4) y **31** (aprendizaje continuo / RL). Los refuerzos cortos repiten el mismo patrón — subir un artefacto con `huggingface_hub`— para que el estudiante llegue a la model card formal de S17 con el flujo ya familiar.

| Entrega | Sesiones | Qué se construye | Lectura / diapositiva |
|---|---|---|---|
| **B1** — API | Arranca S12 · Entrega S14 | FastAPI + Docker; endpoints `/health`, `/predict` y `/metadata` — este último ahora **machine-readable** y validado contra el JSON Schema de la model card. | Cap. 15 |
| **B2** — Hub / CI | Arranca S17 · Entrega S18 | Model card causal (supuestos, población, IC — no solo accuracy) serializada según el nuevo **JSON Schema** `causal-model-card-v1.schema.json` (Ap. G.4); GitHub Actions corre el smoke test **y** valida el schema antes de permitir publicar. | Cap. 19, Cap. 20 |
| **B3** — Space | Arranca S23 · Entrega S26 | Gradio Space que expone la **política** (top-k con presupuesto), no solo una predicción puntual — el decisor interactúa con el resultado de A4. | Cap. 22 |
| **B4** — Monitor | Arranca S25 · Entrega S28 | Dashboard de drift de covariables (KS) y estabilidad del efecto en producción; si el sistema usa PLIV, agrega el **doble umbral** (F de primera etapa + Anderson-Rubin, Cap. 17) para no reportar un efecto sobre un instrumento débil. | Cap. 30 (+ Cap. 17 ◇) |
| Proyecto final | S29–S32 | Integra B1–B4 en un sistema único; obligatorio comparar ranking predictivo vs. política causal y pasar la prueba de humo con la model card ya validada por schema. | Síntesis Caps. 15/19/20/22/30 |

**Qué cambió en Etapa 2 (y por qué importa para B2 en particular):** antes, la model card causal era una convención de prosa (qué campos incluir, sin forma verificable). Ahora es un JSON Schema publicado (Ap. G.4) que el pipeline de CI puede validar automáticamente — la diferencia entre «recordarle al estudiante que documente los supuestos» y «el CI rechaza el **merge** si la card no los documenta en el campo correcto». Detalle capítulo por capítulo de las 11 áreas afectadas por Etapa 2: `07_diapositivas/PLAN_SPRINT_DIAPOSITIVAS.md` §5.

# 8. Evaluación

| Componente | Peso | Descripción |
|---|---|---|
| Proyecto final | 40% | Sistema causal en Hugging Face (identificación + estimación + model card + servicio/Space + monitoreo ligero). **Obligatorio:** comparación predictivo vs causal y prueba de humo. Ver `06_proyecto_final/`. |
| Serie A — casos de estudio | 20% | A1 Jobs · A2 DML · A3 CATE · A4 policy. Metodología + autograder. |
| Serie B — producción HF | 15% | B1 API · B2 Hub/CI · B3 Space · B4 monitor. Humo + prácticas de despliegue. |
| Revisión por pares | 10% | 2–3 proyectos con rúbrica. |
| Quizzes | 10% | 7 quizzes cortos (camino profesional ⋆). |
| Contribución al Hub | 5% | Dataset o model card reutilizable por la cohorte. |

El proyecto **no se aprueba** si el sistema no pasa la prueba de humo (endpoint o Space responde; estimaciones en rango documentado).

**Labs Lxx:** formativos (badge/consistencia); no sustituyen el peso de A/B salvo política del instructor.

# 9. Herramientas y stack

- Python 3.10+, pandas, NumPy, scikit-learn; monorepo `lib/` del curso.
- EconML / DoubleML (recomendados; hay fallback sklearn en el monorepo).
- Hugging Face Hub, Spaces, Gradio; FastAPI + Docker; GitHub Actions.
- `jsonschema` (Python) para validar la model card contra `causal-model-card-v1.schema.json` (Ap. G.4) en B2 y en CI.
- Datos: solo `data_benchmark_causal/causal_benchmark_synthetic/datasets/` en entregas del curso.
- Auditoría local: `bash scripts/audit_repo.sh`.

# 10. Bibliografía y referencias

## 10.1 Fuentes principales


- Curso ECO-490/ECON-540 (2026). *IA Causal en Producción* — monografía Typst, **32 capítulos**. `02_monografia/monografia_IA_Causal_en_Produccion.pdf`.
- Huyen, C. (2022). *Designing Machine Learning Systems*. O'Reilly. Filosofía pedagógica y ciclo de vida.
- Bareinboim, E. (2025). *Causal Artificial Intelligence* (v0.27). Columbia CausalAI Lab.
- Planes del monorepo: `PLAN_CURSO_COMPLETO.md`, `PLAN_INTEGRACION_MONOGRAFIA.md`.


## 10.2 Metodología (selección)


- Chernozhukov et al. (2018). Double/debiased machine learning. *The Econometrics Journal*.
- Wager & Athey (2018). Estimation of heterogeneous treatment effects with random forests. *JASA*.
- Künzel et al. (2019). Metalearners for heterogeneous treatment effects. *PNAS*.
- Pearl, J. (2009). *Causality* (2.ª ed.). Cambridge University Press.


## 10.3 Producción y documentación


- EconML, DoWhy, Hugging Face Hub docs.

- Kästner et al., *Machine Learning in Production* (CMU), Cap. 10.
- Mitchell et al. (2019). Model Cards for Model Reporting. *FAT**.

# 11. Mapa rápido del hilo de producto (CDS)

| Paso | Artefacto | Sesiones | Pregunta de valor |
|---|---|---|---|
| 1 | A1 Identificación (Jobs) | S4–S6 | ¿Es estimable el efecto del programa? |
| 2 | A2 DML (IHDP-medium) | S8–S11 | ¿Cuánto mueve en promedio (ATE + IC)? |
| 3 | B1 API + B2 Hub/CI | S12–S18 | ¿Se puede consultar, documentar con supuestos validables por schema, y no publicar roto? |
| 4 | A3 CATE + A4 policy | S13–S15, S22–S23 | ¿A quién priorizar con 20% de capacidad? |
| 5 | B3 Space + B4 monitor | S23–S28 | ¿Un decisor lo usa? ¿Sigue valiendo el efecto? |
| 6 | Proyecto final HF | S29–S32 | ¿Tu caso de negocio en producción? |

# 12. Cronograma semana a semana (profesor y estudiante)

Cómo **usar** los materiales del monorepo cada semana. Detalle ampliado (checklists, rutas de apertura): `CHRONOGRAMA_SEMANAL.md` en la raíz del monorepo. La planificación sesión a sesión (S1–S32) está en la §7; aquí el **cómo** por rol.

## 12.1 Rutina semanal tipo

| Quién | Antes | Durante (1 h 30) | Después |
|---|---|---|---|
| **Profesor** | Revisar Cap. PDF + lab; 1 pregunta de valor de negocio | 20′ concepto · 50–60′ lab guiado · 10–20′ cierre (disrupción) | Dudas del hilo CDS; no retrasar entregas A/B |
| **Estudiante** | Leer Cap. del PDF (núm. índice 32) | Lab en vivo o asíncrono | Completar lab + avanzar A/B del bloque |

**Cierre obligatorio (cada semana):** si solo predijéramos el outcome, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

## 12.2 Uso de materiales por semana

| Sem | Ses. | Cap. / Lab | Entrega | Profesor usa | Estudiante usa |
|---|---|---|---|---|---|
| 1 | S1–S2 | 1–2 / L01–L02 | — | Sílabo + monorepo; verificar L02 entorno | PDF Caps. 1–2; labs L01–L02; cuenta HF |
| 2 | S3–S4 | 3–4 / L03–L04 | A1 arranca | PCH (L03); Jobs como caso; abrir A1 + `CausalSchema` | L03–L04; A1 EDA/DAG; `real/jobs` |
| 3 | S5–S6 | 6(+16◇)–7 / L05–L06 | **A1** | Rúbrica A1; Cap. 16 solo si hay tiempo | L05–L06; **entregar A1** (solo observed) |
| 4 | S7–S8 | 8–9 / L07–L08 | A2 arranca | Abstenerse si no hay ID; demo leakage; abrir A2 | L07–L08; A2 sin fugas; `ihdp_medium` |

| Sem | Ses. | Cap. / Lab | Entrega | Profesor usa | Estudiante usa |
|---|---|---|---|---|---|
| 5 | S9–S10 | 10–11 / L09–L10 | A2 curso | Cross-fitting + score ortogonal canónico; ESS/ trimming (Crump) → ATE→go/no-go | L09–L10; A2 PLR + K-fold; reportar ESS/n |
| 6 | S11–S12 | 14–15 / L11–L12 | **A2** · B1 | Cerrar A2 (joblib); sensibilidad (E-value/$R^2$/ Manski); demo B1 / health /predict /metadata | **A2** + sync; L11–L12; carpeta B1 |
| 7 | S13–S14 | 12–13 / L13–L14 | A3 · **B1** | CATE ≠ riesgo predicho; autograder B1 | A3 T-learner; **B1**; L13–L14 |
| 8 | S15–S16 | Repaso / — · L15 | **A3** · parcial | Checklist A1–A3+B1; parcial solo ⋆ | **A3**; L15; estudiar ⋆ (no deep) |
| 9 | S17–S18 | 19–20 / L17–L18 | **B2** | Model card = supuestos, ahora con JSON Schema; CI que falla humo y schema | L17–L18; **B2** card+Actions |
| 10 | S19–S20 | 23–24 / L19–L20 | — | SHAP de $\hat{Y}$ ≠ efecto; preparar policy | L19–L20; releer card B2 |
| 11 | S21–S22 | 25+21 / L21–L22 | A4 arranca | Decisión de negocio antes de λ; B=20% | L21–L22; A4 con scores A3 |
| 12 | S23–S24 | 22+26 / L23–L24 | **A4** · B3 | A4: causal vs random vs outcome; demo Space | **A4**; L23–L24; B3 Gradio |
| 13 | S25–S26 | 30+29 / L25–L26 | B4 · **B3** | 200 OK ≠ efecto válido; doble umbral F/AR si hay PLIV; cerrar B3 | **B3**; L25–L26; B4 |
| 14 | S27–S28 | 31–32 / L27–L28 | **B4** | Ops L27; comunicación 3 capas; brief proyecto | L27–L28; **B4**; elegir caso P |
| 15 | S29–S30 | Ap. E/G/H · guía proyecto | P1 · P2 | Mentoría ID+humo+disrupción; pares peer | P1 repo; P2 rúbrica; HF |
| 16 | S31–S32 | — / elect. ◇ | **P3** · P4 | Humo + sección disrupción irrenunciables | **P3** sistema HF + video; encuesta |

## 12.3 Calendario de entregas (vista rápida)

| Semana | Entrega | Notas |
|---|---|---|
| 3 | **A1** | Identificación Jobs (Serie A 20%) |
| 6 | **A2** | DML → artefacto B1 |
| 7 | **B1** | API + Docker (Serie B 15%) |
| 8 | **A3** · parcial | CATE → A4; parcial camino ⋆ |
| 9 | **B2** | Model card + CI HF (valida contra JSON Schema, Ap. G.4) |

| Semana | Entrega | Notas |
|---|---|---|
| 12 | **A4** | Policy B=20% → B3 |
| 13 | **B3** | Space Gradio |
| 14 | **B4** | Monitor drift/supuestos; doble umbral F/Anderson-Rubin si el sistema usa PLIV |
| 15 | P1 · P2 | Baseline + peer review 10% |
| 16 | **P3** (+ P4) | Proyecto final 40% + humo |

## 12.4 Checklist semanal (plantilla)

**Estudiante:** (1) Cap. N del PDF; (2) lab.ipynb / checks en verde; (3) avance A/B del bloque; (4) tres líneas predictivo vs efecto; (5) no usar columnas de verdad (`truth\_*`) fuera de evaluación.

**Profesor:** (1) Cap. + lab + ejemplo de negocio de la cohorte; (2) numeración PDF (no Typst antiguo); (3) cierre con disrupción; (4) office hours si bloqueo A/B; (5) electivos ◇ no entran al parcial ★.

## 12.5 Primera apertura por rol

**Estudiante:** `01_silabo/silabo.pdf` → `CHRONOGRAMA_SEMANAL.md` (semana actual) → Cap. monografía → `05_labs_sesion/Lxx/lab.ipynb` → notebook A o carpeta B si hay entrega.

**Profesor:** `docs/NOTA_INSTRUCTORS.md` → sílabo + cronograma → `bash scripts/audit_repo.sh` → demo 10′ (L01 + promesa del curso).