SÍLABO DEL CURSO

IA Causal en Producción

*De la identificación al despliegue: estimar **efectos**, no solo predicciones, y poner políticas causales en producción en Hugging Face*

Audiencia: Profesionales (data / ML / product / analytics / risk / ops)
Modalidad: Online, asíncrona con checkpoints síncronos
Duración: 16 semanas (4 meses) · 32 sesiones de 1 h 30
Balance: 50% teoría causal · 50% práctica (casos + HF)
Curso: ECO-490 / ECON-540 — Edición 2026

Promesa del curso. Deja de priorizar con scores que confunden correlación con impacto. Aprende a **estimar efectos**, documentar supuestos y desplegar políticas causales en **Hugging Face** — con monitoreo de cuándo dejan de ser válidas.

Monografía del curso (32 caps., Typst/PDF) · *Designing Machine Learning Systems* (Huyen) · *Causal Artificial Intelligence* (Bareinboim) · Monorepo: labs L01–L28 · Serie A/B · datos de benchmark

1. Presentación y fundamentación

Este curso está diseñado para **profesionales** que ya usan datos o machine learning y deben **decidir o priorizar intervenciones** —no para formar investigadores básicos en econometría teórica—. Combina tres fuentes: (1) el marco de IA causal de Elias Bareinboim (*Causal Artificial Intelligence*); (2) la monografía del curso *IA Causal en Producción* (32 capítulos, Typst/PDF en `02_monografia/`); (3) la filosofía de ingeniería de *Designing Machine Learning Systems* (Chip Huyen), aplicada a **sistemas cuyo objetivo es un efecto causal**, no solo un score predictivo.

Disrupción que se enseña. Un modelo predictivo responde «¿quién tiene peor outcome?» Un sistema causal responde «¿a quién **cambia** el outcome si actuamos?». Esa diferencia reordena presupuestos, targeting, go/no-go de programas y riesgo de políticas injustas. Cada bloque del curso cierra con la pregunta: **si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?**

Balance 50/50. La teoría (identificación y estimación) se ancla en monografía + Bareinboim. La práctica sigue el ciclo DMLS (datos, features, evaluación, despliegue, monitoreo) y se materializa en el **monorepo del curso**: labs de sesión (L01–L28), notebooks de caso (Serie A) y producción en Hugging Face (Serie B). Ningún módulo termina en un análisis de notebook aislado: termina en un **artefacto operable** (estimación auditada, API, model card, Space o dashboard).

Navegación del libro. La monografía tiene **32 capítulos**. En este sílabo, la columna **Lectura** usa la **numeración actual del PDF** (no la de ediciones cortas anteriores). Ante duda: `PLAN_INTEGRACION_MONOGRAFIA.md` (tabla maestra S ↔ Cap ↔ Lab ↔ A/B).

2. Filosofía pedagógica: DMLS + efecto causal

Cuadro sinóptico del capítulo

- **Decisiones de diseño, no tutoriales de una receta.** Online vs batch, reentrenar vs alertar, biblioteca vs servicio — aplicados a **validez del efecto**.
- **Proceso iterativo.** Identificar → estimar → servir en HF → monitorear supuestos → actualizar.
- **Cuatro requisitos en producción (versión causal):** confiabilidad del efecto, escalabilidad del pipeline, mantenibilidad de la identificación, adaptabilidad ante drift de supuestos.
- **Lado humano.** Comunicar ATE/CATE a no técnicos; model cards honestas; equidad y límites de validez externa.

3. Objetivos de aprendizaje

3.1 Objetivo general

Capacitar a profesionales para **formular, estimar y desplegar** sistemas de IA causal en producción —con énfasis en **casos de estudio** y **Hugging Face**— de modo que puedan sustituir (o auditar) priorizaciones puramente predictivas por decisiones basadas en **efectos** documentados y monitoreables.

3.2 Objetivos específicos

- Distinguir asociación, intervención y contrafactual (PCH) y reconocer cuándo **no** estimar.
- Diseñar pipelines de datos con roles tratamiento / outcome / covariables sin fuga causal.
- Estimar ATE y CATE (DML, meta-learners, bosques causales) con inferencia válida y evaluación offline (Qini, placebo).
- Convertir CATE en **política** bajo presupuesto y compararla con baselines no causales.
- Empaquetar en HF: FastAPI/Docker, Hub, model card causal, CI/CD, Space, dashboard de drift.

- Comunicar resultados a audiencias de negocio con supuestos y límites explícitos.

4. Perfil de ingreso

Dirigido a **profesionales** (y posgrado aplicado) en datos, ML, producto, analítica, riesgo u operaciones.

- ☐ Python intermedio (pandas, scikit-learn); Git básico.
  ☐ Estadística/econometría introductoria (regresión; deseable IV o evaluación de impacto).
  ☐ Experiencia deseable con APIs o despliegue ligero (se cubre en el curso).
  ☐ No se exige perfil de investigación ni demostraciones teóricas avanzadas (caps. electivos del libro son opcionales).

5. Unidades temáticas

Siete módulos · 16 semanas. Cada semana combina lectura de monografía (Cap. N del PDF) + lab de sesión (L##) y, en hitos, entrega Serie A o B.

- **Módulo 0** — Causalidad elemental y arranque (Semana 1)
- **Módulo 1** — Fundamentos y datos para sistemas causales (Semanas 2–4) → **A1**
- **Módulo 2** — Estimación con ML y primer despliegue HF (Semanas 5–7) → **A2, B1**
- **Checkpoint 1** — Integración (Semana 8) → **A3**
- **Módulo 3** — Hub, model cards y CI/CD (Semana 9) → **B2**
- **Módulo 4** — Explicación, decisión, policy y uplift (Semanas 10–12) → **A4, B3**
- **Módulo 5** — Monitoreo, discovery y frontera (Semanas 13–14) → **B4**
- **Módulo 6** — Proyecto final en HF (Semanas 15–16)

Capítulos electivos del PDF (no bloquean el camino profesional): Cap. 16 (PDS extendido), 17 (panel/DML-IV), 18 (mapa metodológico), 27 (deep causal), 28 (SCM/matrix completion). Ver plan de integración.

6. Metodología y materiales del monorepo

Curso online asíncrono; dos sesiones semanales de 1 h 30. Formato orientativo: 20 min concepto · 50–60 min práctica (lab) · 10–20 min cierre. Los pipelines completos son entregas quincenales, no actividades de una sola sesión.

Componente	Ubicación en monorepo	Rol
Monografía PDF	`02_monografia/…/monografia.pdf`	Lectura Cap. 1–32
Labs L01–L28	`05_labs_sesion/`	Práctica formativa por sesión (sin L16)
Serie A (casos)	`03_notebooks_caso_estudio/`	4 entregas: identificación, DML, CATE, policy
Serie B (HF)	`04_notebooks_produccion_hf/`	4 entregas: API, Hub/CI, Space, monitor
Datos	`data_benchmark_causal/…/datasets/`	Jobs, IHDP, etc. (benchmark documentado)
Proyecto	`06_proyecto_final/`	Sistema causal en HF (40%)
Planes	`PLAN_CURSO_COMPLETO.md` y `PLAN_INTEGRACION_MONOGRAFIA.md`	Práctica + integración libro↔repo

Componente	Ubicación en monorepo	Rol
Cronograma semanal	`CHRONOGRAMA_SEMANAL.md`	Uso de materiales por rol (profesor / estudiante)

Serie A se evalúa por corrección metodológica; **Serie B** por humo de producción (endpoint/Space responde, artefactos auditables) más buenas prácticas. El proyecto exige **comparar ranking predictivo vs política causal** y pasar humo en HF o equivalente local documentado.

7. Planificación clase a clase

Convención. Lectura = capítulo de la monografía (numeración del PDF 2026). **Lab** = carpeta `05_labs_sesion/` (prefijo L). **Entrega** = A1–A4 o B1–B4.

Módulo 0 — Causalidad elemental y arranque (Semana 1)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S1	Correlación $\neq$ causación; problema fundamental; escalera de Pearl (adelanto)	Cap. **1** Causalidad elemental	L01	Casos espurios + Simpson; pregunta: ¿asociación o efecto?
S2	Anatomía de un sistema ML en producción; requisitos de un sistema **causal**	Cap. **2** Anatomía del sistema	L02	Lab 0: entorno Python, Git, HF, monorepo

Módulo 1 — Fundamentos y datos (Semanas 2–4)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S3	SCM y Jerarquía Causal de Pearl (ver / hacer / imaginar)	Cap. **3** SCM y PCH	L03	Clasificar 10 preguntas en la PCH
S4	Ingeniería de datos: tratamiento, outcome, covariables, trazabilidad	Cap. **4** Ingeniería de datos	L04	**Arranca A1** — roles T/Y/X (Jobs)
S5	Regularización y post-selección (PDS); Cap. 16 del PDF es profundización ◇	Cap. **6** Regularización (+ Cap. **16** PDS ◇)	L05	PDS vs OLS vs diff-in-means
S6	Datos de entrenamiento, muestreo, etiquetas naturales	Cap. **7** Datos de entrenamiento	L06	**Entrega A1** — identificación + PDS
S7	Operador do, puertas traseras, contrafactuales	Cap. **8** Intervención y contrafactual	L07	Backdoor vs confusor latente (abstenerse)
S8	Features sin fuga causal	Cap. **9** Features sin fuga	L08	**Arranca A2** — cazar leakage

Módulo 2 — Estimación causal y primer despliegue HF (Semanas 5–7)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S9	Ortogonalidad de Neyman y cross-fitting	Cap. **10** Ortogonalidad	L09	Residuales OOF; partialling-out
S10	Double Machine Learning: PLR e IRM	Cap. **11** DML	L10	PLR mínimo; ATE con IC
S11	Evaluación offline: baselines, Qini, placebo	Cap. **14** Validación	L11	**Entrega A2** — DML serializado → B1
S12	Despliegue del estimador como servicio (FastAPI + Docker)	Cap. **15** Despliegue servicio	L12	**Arranca B1** — stub / predict
S13	Meta-learners S/T/X/R	Cap. **12** Meta-learners	L13	**Arranca A3** — T-learner / CATE
S14	Árboles y bosques causales	Cap. **13** Bosques causales	L14	**Entrega B1** + avance A3

Checkpoint 1 (Semana 8)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S15	Integración: identificación + estimación + primer servicio	Repaso Caps. 1–15	L15	**Entrega A3** — checklist de sistema
S16	Examen parcial y defensa de avance	—	—	Evaluación parcial (camino profesional ⋆)

Módulo 3 — Publicación y CI/CD en Hugging Face (Semana 9)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S17	HF Hub y model cards **causales** (supuestos, no solo accuracy)	Cap. **19** Hub y model cards · Ap. G	L17	**Arranca B2**
S18	CI/CD: Actions, tests de humo, publicación condicionada	Cap. **20** CI/CD	L18	**Entrega B2**

Módulo 4 — Explicación, decisión, policy y uplift (Semanas 10–12)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S19	Explicación causal vs asociativa; equidad	Cap. **23** Explicación y equidad	L19	Casos: SHAP $\neq$ efecto
S20	Interpretabilidad y fairness sobre estimadores causales	Cap. **24** Ética e interpretabilidad	L20	Auditoría de importancia (asociativa) con advertencia

S	Tema	Lectura monografía	Lab	Actividad / entrega
S21	Decisiones estructurales bajo incertidumbre	Cap. **25** Decisiones estructurales	L21	Formalizar la decisión de negocio
S22	Policy learning y presupuesto	Cap. **21** Policy learning	L22	**Arranca A4** — top-k B=20%
S23	Uplift y targeting; Space de política	Cap. **22** Uplift	L23	**Entrega A4** · **Arranca B3** (Gradio/Space)
S24	Transportabilidad entre dominios	Cap. **26** Generalización	L24	¿El efecto vale en **mi** mercado?

Módulo 5 — Monitoreo y frontera (Semanas 13–14)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S25	Drift de covariables y estabilidad del efecto en producción	Cap. **30** Monitoreo	L25	**Arranca B4** — métricas KS
S26	Descubrimiento de estructura (PC/NOTEARS; lab con esqueleto)	Cap. **29** Discovery	L26	**Entrega B3** · avanza B4
S27	Continual learning; panorama RL causal	Cap. **31** Aprendizaje continuo	L27	Reentrenar vs alertar
S28	Lado humano: comunicación y responsabilidad	Cap. **32** Lado humano	L28	**Entrega B4** — comunicar ATE

Módulo 6 — Proyecto final (Semanas 15–16)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S29	Trabajo autónomo + mentoría	Ap. E, G, H · guía `06_proyecto_final/`	P1	Repo + identificación + baseline
S30	Peer review estructurado	Rúbrica del curso	P2	Evaluar 2–3 proyectos (10%)
S31	Defensa del sistema causal en HF	—	P3	**Entrega final 40%** + humo
S32	Cierre y frontera (CRL, RL causal — panorama)	Caps. electivos 27–28 si aplica	P4	Encuesta; límites y trabajo futuro

8. Evaluación

Componente	Peso	Descripción
Proyecto final	40%	Sistema causal en Hugging Face (identificación + estimación + model card + servicio/Space + monitoreo ligero). **Obligatorio:** comparación predictivo vs causal y prueba de humo. Ver `06_proyecto_final/`.

Componente	Peso	Descripción
Serie A — casos de estudio	20%	A1 Jobs · A2 DML · A3 CATE · A4 policy. Metodología + autograder.
Serie B — producción HF	15%	B1 API · B2 Hub/CI · B3 Space · B4 monitor. Humo + prácticas de despliegue.
Revisión por pares	10%	2–3 proyectos con rúbrica.
Quizzes	10%	7 quizzes cortos (camino profesional ⋆).
Contribución al Hub	5%	Dataset o model card reutilizable por la cohorte.

El proyecto **no se aprueba** si el sistema no pasa la prueba de humo (endpoint o Space responde; estimaciones en rango documentado).

Labs Lxx: formativos (badge/consistencia); no sustituyen el peso de A/B salvo política del instructor.

9. Herramientas y stack

- ? Python 3.10+, pandas, NumPy, scikit-learn; monorepo `lib/` del curso.
  ? EconML / DoubleML (recomendados; hay fallback sklearn en el monorepo).
  ? Hugging Face Hub, Spaces, Gradio; FastAPI + Docker; GitHub Actions.
  ? Datos: solo `data_benchmark_causal/causal_benchmark_synthetic/datasets/` en entregas del curso.
  ? Auditoría local: `bash scripts/audit_repo.sh`.

10. Bibliografía y referencias

10.1 Fuentes principales

- Curso ECO-490/ECON-540 (2026). *IA Causal en Producción* — monografía Typst, **32 capítulos**. `02_monografia/monografia_IA_Causal_en_Produccion.pdf`.
- Huyen, C. (2022). *Designing Machine Learning Systems*. O'Reilly. Filosofía pedagógica y ciclo de vida.
- Bareinboim, E. (2025). *Causal Artificial Intelligence* (v0.27). Columbia CausalAI Lab.
- Planes del monorepo: `PLAN_CURSO_COMPLETO.md`, `PLAN_INTEGRACION_MONOGRAFIA.md`.

10.2 Metodología (selección)

- Chernozhukov et al. (2018). Double/debiased machine learning. *The Econometrics Journal*.
- Wager & Athey (2018). Estimation of heterogeneous treatment effects with random forests. *JASA*.
- Künzel et al. (2019). Metalearners for heterogeneous treatment effects. *PNAS*.
- Pearl, J. (2009). *Causality* (2.ª ed.). Cambridge University Press.

10.3 Producción y documentación

- EconML, DoWhy, Hugging Face Hub docs.
- Kästner et al., *Machine Learning in Production* (CMU), Cap. 10.
- Mitchell et al. (2019). Model Cards for Model Reporting. *FAT**.

11. Mapa rápido del hilo de producto (CDS)

Paso	Artefacto	Sesiones	Pregunta de valor
1	A1 Identificación (Jobs)	S4–S6	¿Es estimable el efecto del programa?

Paso	Artefacto	Sesiones	Pregunta de valor
2	A2 DML (IHDP-medium)	S8–S11	¿Cuánto mueve en promedio (ATE + IC)?
3	B1 API + B2 Hub/CI	S12–S18	¿Se puede consultar, documentar y no publicar roto?
4	A3 CATE + A4 policy	S13–S15, S22–S23	¿A quién priorizar con 20% de capacidad?
5	B3 Space + B4 monitor	S23–S28	¿Un decisor lo usa? ¿Sigue valiendo el efecto?
6	Proyecto final HF	S29–S32	¿Tu caso de negocio en producción?

12. Cronograma semana a semana (profesor y estudiante)

Cómo **usar** los materiales del monorepo cada semana. Detalle ampliado (checklists, rutas de apertura): `CHRONOGRAMA_SEMANAL.md` en la raíz del monorepo. La planificación sesión a sesión (S1–S32) está en la §7; aquí el **cómo** por rol.

12.1 Rutina semanal tipo

Quién	Antes	Durante (1 h 30)	Después
Profesor	Revisar Cap. PDF + lab; 1 pregunta de valor de negocio	20′ concepto · 50–60′ lab guiado · 10–20′ cierre (disrupción)	Dudas del hilo CDS; no retrasar entregas A/B
Estudiante	Leer Cap. del PDF (núm. índice 32)	Lab en vivo o asíncrono	Completar lab + avanzar A/B del bloque

Cierre obligatorio (cada semana): si solo predijéramos el outcome, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

12.2 Uso de materiales por semana

Sem	Ses.	Cap. / Lab	Entrega	Profesor usa	Estudiante usa
1	S1–S2	1–2 / L01–L02	—	Sílabo + monorepo; verificar L02 entorno	PDF Caps. 1–2; labs L01–L02; cuenta HF
2	S3–S4	3–4 / L03–L04	A1 arranca	PCH (L03); Jobs como caso; abrir A1 + `CausalSchema`	L03–L04; A1 EDA/DAG; `real/jobs`
3	S5–S6	6(+16◇)–7 / L05–L06	**A1**	Rúbrica A1; Cap. 16 solo si hay tiempo	L05–L06; **entregar A1** (solo observed)
4	S7–S8	8–9 / L07–L08	A2 arranca	Abstenerse si no hay ID; demo leakage; abrir A2	L07–L08; A2 sin fugas; `ihdp_medium`
5	S9–S10	10–11 / L09–L10	A2 curso	Cross-fitting + ortogonalidad; ATE→go/no-go	L09–L10; A2 PLR + K-fold
6	S11–S12	14–15 / L11–L12	**A2** · B1	Cerrar A2 (joblib); demo B1 /health /predict	**A2** + sync; L11–L12; carpeta B1
7	S13–S14	12–13 / L13–L14	A3 · **B1**	CATE ≠ riesgo predicho; autograder B1	A3 T-learner; **B1**; L13–L14

Sem	Ses.	Cap. / Lab	Entrega	Profesor usa	Estudiante usa
8	S15–S16	Repaso / — · L15	**A3** · parcial	Checklist A1–A3+B1; parcial solo ⋆	**A3**; L15; estudiar ⋆ (no deep)
9	S17–S18	19–20 / L17–L18	**B2**	Model card = supuestos; CI que falla humo	L17–L18; **B2** card+Actions
10	S19–S20	23–24 / L19–L20	—	SHAP de $\hat{Y} \neq$ efecto; preparar policy	L19–L20; releer card B2
11	S21–S22	25+21 / L21–L22	A4 arranca	Decisión de negocio antes de λ; B=20%	L21–L22; A4 con scores A3
12	S23–S24	22+26 / L23–L24	**A4** · B3	A4: causal vs random vs outcome; demo Space	**A4**; L23–L24; B3 Gradio
13	S25–S26	30+29 / L25–L26	B4 · **B3**	200 OK $\neq$ efecto válido; cerrar B3	**B3**; L25–L26; B4
14	S27–S28	31–32 / L27–L28	**B4**	Ops L27; comunicación 3 capas; brief proyecto	L27–L28; **B4**; elegir caso P
15	S29–S30	Ap. E/G/H · guía proyecto	P1 · P2	Mentoría ID+humo+disrupción; pares peer	P1 repo; P2 rúbrica; HF
16	S31–S32	— / elect. ◇	**P3** · P4	Humo + sección disrupción irrenunciables	**P3** sistema HF + video; encuesta

12.3 Calendario de entregas (vista rápida)

Semana	Entrega	Notas
3	**A1**	Identificación Jobs (Serie A 20%)
6	**A2**	DML → artefacto B1
7	**B1**	API + Docker (Serie B 15%)
8	**A3** · parcial	CATE → A4; parcial camino ⋆
9	**B2**	Model card + CI HF
12	**A4**	Policy B=20% → B3
13	**B3**	Space Gradio
14	**B4**	Monitor drift/supuestos
15	P1 · P2	Baseline + peer review 10%
16	**P3** (+ P4)	Proyecto final 40% + humo

12.4 Checklist semanal (plantilla)

Estudiante: (1) Cap. N del PDF; (2) lab.ipynb / checks en verde; (3) avance A/B del bloque; (4) tres líneas predictivo vs efecto; (5) no usar columnas de verdad (`truth\_*`) fuera de evaluación.

Profesor: (1) Cap. + lab + ejemplo de negocio de la cohorte; (2) numeración PDF (no Typst antiguo); (3) cierre con disrupción; (4) office hours si bloqueo A/B; (5) electivos ◇ no entran al parcial ⋆.

12.5 Primera apertura por rol

Estudiante: `01_silabo/silabo.pdf` → `CHRONOGRAMA_SEMANAL.md` (semana actual) → Cap. monografía → `05_labs_sesion/Lxx/lab.ipynb` → notebook A o carpeta B si hay entrega.

Profesor: `docs/NOTA_INSTRUCTORS.md` → sílabo + cronograma → `bash scripts/audit_repo.sh` → demo 10′ (L01 + promesa del curso).