SÍLABO DEL CURSO

Sistema de Inteligencia Causal

*De la identificación al despliegue: estimar **efectos**, no solo predicciones, y poner políticas causales en producción en Hugging Face*

Audiencia: Profesionales (data / ML / product / analytics / risk / ops)
Modalidad: Online, asíncrona con checkpoints síncronos
Duración: 16 semanas (4 meses) · 32 sesiones de 1 h 30 · **48 horas cronológicas**
Balance: 50% teoría causal · 50% práctica (casos + HF)
Curso: ECO-490 / ECON-540 — Edición 2026

Promesa del curso. Deja de priorizar con scores que confunden correlación con impacto. Aprende a **estimar efectos**, documentar supuestos y desplegar políticas causales en **Hugging Face** — con monitoreo de cuándo dejan de ser válidas.

Monografía del curso (32 caps., Typst/PDF) · *Designing Machine Learning Systems* (Huyen) · *Causal Artificial Intelligence* (Bareinboim) · Monorepo: labs L01–L28 · Serie A/B · datos de benchmark

1. Presentación y fundamentación

Este curso está diseñado para **profesionales** que ya usan datos o machine learning y deben **decidir o priorizar intervenciones** —no para formar investigadores básicos en econometría teórica—. Combina tres fuentes: (1) el marco de IA causal de Elias Bareinboim (*Causal Artificial Intelligence*); (2) la monografía del curso *Sistema de Inteligencia Causal* (32 capítulos, Typst/PDF en `02_monografia/`); (3) la filosofía de ingeniería de *Designing Machine Learning Systems* (Chip Huyen), aplicada a **sistemas cuyo objetivo es un efecto causal**, no solo un score predictivo.

Disrupción que se enseña. Un modelo predictivo responde «¿quién tiene peor outcome?» Un sistema causal responde «¿a quién **cambia** el outcome si actuamos?». Esa diferencia reordena presupuestos, targeting, go/no-go de programas y riesgo de políticas injustas. Cada bloque del curso cierra con la pregunta: **si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?**

Balance 50/50. La teoría (identificación y estimación) se ancla en monografía + Bareinboim. La práctica sigue el ciclo DMLS (datos, features, evaluación, despliegue, monitoreo) y se materializa en el **monorepo del curso**: labs de sesión (L01–L28), notebooks de caso (Serie A) y producción en Hugging Face (Serie B). Ningún módulo termina en un análisis de notebook aislado: termina en un **artefacto operable** (estimación auditada, API, model card, Space o dashboard).

Navegación del libro. La monografía tiene **32 capítulos**. En este sílabo, la columna **Lectura** usa la **numeración actual del PDF** (no la de ediciones cortas anteriores). Ante duda: `PLAN_INTEGRACION_MONOGRAFIA.md` (tabla maestra S ↔ Cap ↔ Lab ↔ A/B).

2. Filosofía pedagógica: DMLS + efecto causal

Cuadro sinóptico del capítulo

- **Decisiones de diseño, no tutoriales de una receta.** Online vs batch, reentrenar vs alertar, biblioteca vs servicio — aplicados a **validez del efecto**.
- **Proceso iterativo.** Identificar → estimar → servir en HF → monitorear supuestos → actualizar.
- **Cuatro requisitos en producción (versión causal):** confiabilidad del efecto, escalabilidad del pipeline, mantenibilidad de la identificación, adaptabilidad ante drift de supuestos.
- **Lado humano.** Comunicar ATE/CATE a no técnicos; model cards honestas; equidad y límites de validez externa.

3. Objetivos de aprendizaje

3.1 Objetivo general

Capacitar a profesionales para **formular, estimar y desplegar** sistemas de IA causal en producción —con énfasis en **casos de estudio** y **Hugging Face**— de modo que puedan sustituir (o auditar) priorizaciones puramente predictivas por decisiones basadas en **efectos** documentados y monitoreables.

3.2 Objetivos específicos

- Distinguir asociación, intervención y contrafactual (PCH) y reconocer cuándo **no** estimar.
- Diseñar pipelines de datos con roles tratamiento / outcome / covariables sin fuga causal.
- Estimar ATE y CATE (DML, meta-learners, bosques causales) con inferencia válida y evaluación offline (Qini, placebo).
- Convertir CATE en **política** bajo presupuesto y compararla con baselines no causales.
- Empaquetar en HF: FastAPI/Docker, Hub, model card causal, CI/CD, Space, dashboard de drift.

- Comunicar resultados a audiencias de negocio con supuestos y límites explícitos.

4. Perfil de ingreso

Dirigido a **profesionales** (y posgrado aplicado) en datos, ML, producto, analítica, riesgo u operaciones.

- ☐ Python intermedio (pandas, scikit-learn); Git básico.
  - ☐ Estadística/econometría introductoria (regresión; deseable IV o evaluación de impacto).
  - ☐ Experiencia deseable con APIs o despliegue ligero (se cubre en el curso).
  - ☐ No se exige perfil de investigación ni demostraciones teóricas avanzadas (caps. electivos del libro son opcionales).

5. Unidades temáticas

Siete módulos · 16 semanas. Cada semana combina lectura de monografía (Cap. N del PDF) + lab de sesión (L##) y, en hitos, entrega Serie A o B.

- **Módulo 0** — Causalidad elemental y arranque (Semana 1)
- **Módulo 1** — Fundamentos y datos para sistemas causales (Semanas 2–4) → **A1**
- **Módulo 2** — Estimación con ML y primer despliegue HF (Semanas 5–7) → **A2, B1**
- **Checkpoint 1** — Integración (Semana 8) → **A3**
- **Módulo 3** — Hub, model cards y CI/CD (Semana 9) → **B2**
- **Módulo 4** — Explicación, decisión, policy y uplift (Semanas 10–12) → **A4, B3**
- **Módulo 5** — Monitoreo, discovery y frontera (Semanas 13–14) → **B4**
- **Módulo 6** — Proyecto final en HF (Semanas 15–16)

Capítulos electivos del PDF (no bloquean el camino profesional): Cap. 5 (predicción vs. causalidad — solapa con el Cap. 1, que se prioriza en vivo en S1; lectura de refuerzo), 16 (PDS extendido), 17 (panel/DML-IV), 18 (mapa metodológico), 27 (deep causal), 28 (SCM/matrix completion). Ver plan de integración.

6. Metodología y materiales del monorepo

Curso online asíncrono; dos sesiones semanales de 1 h 30. Formato orientativo: 20 min concepto · 50–60 min práctica (lab) · 10–20 min cierre. Los pipelines completos son entregas quincenales, no actividades de una sola sesión.

Carga horaria total: 48 horas cronológicas (32 sesiones × 1 h 30), distribuidas en 16 semanas. Sobre ese total, el formato orientativo reserva ≈ 1/3 a concepto y ≈ 2/3 a práctica guiada y cierre.

Componente	Ubicación en monorepo	Rol
Monografía PDF	`02_monografia/…/monografia.pdf`	Lectura Cap. 1–32
Labs L01–L28	`05_labs_sesion/`	Práctica formativa por sesión (sin L16)
Serie A (casos)	`03_notebooks_caso_estudio/`	4 entregas: identificación, DML, CATE, policy
Serie B (HF)	`04_notebooks_produccion_hf/`	4 entregas: API, Hub/CI, Space, monitor
Datos	`data_benchmark_causal/…/datasets/`	Jobs, IHDP, etc. (benchmark documentado)

Componente	Ubicación en monorepo	Rol
Diapositivas	07_diapositivas/capitulos/	Mazo Touying por sesión ★; plan y novedades de la última edición en 07_diapositivas/PLAN_SPRINT_DIAPOSITI
Proyecto	06_proyecto_final/	Sistema causal en HF (40%)
Planes	PLAN_CURSO_COMPLETO.md y PLAN_INTEGRACION_MONOGRAFIA.md	Práctica + integración libro↔repo
Cronograma semanal	CHRONOGRAMA_SEMANAL.md	Uso de materiales por rol (profesor / estudiante)

Serie A se evalúa por corrección metodológica; **Serie B** por humo de producción (endpoint/Space responde, artefactos auditables) más buenas prácticas. El proyecto exige **comparar ranking predictivo vs política causal** y pasar humo en HF o equivalente local documentado.

7. Planificación clase a clase

Convención. Lectura = capítulo de la monografía (numeración del PDF 2026). **Lab** = carpeta `05_labs_sesion/` (prefijo L). **Entrega** = A1–A4 o B1–B4. **Diapositiva** = mazo Touying en `07_diapositivas/capitulos/` (un archivo `capNN` por capítulo del PDF); hay un mazo por cada capítulo del camino ★, con callout de monorepo en los capítulos de despliegue/producción (4, 9, 15, 19, 20, 30).

Actualización editorial vigente. La monografía recibió una segunda pasada de mejoras (Etapa 2, C1–C11: score ortogonal canónico, eficiencia semiparamétrica, soporte común, tests de heterogeneidad, intervalos conformes, RATE, sensibilidad en tres niveles, EIF del **policy value**, **model card** machine-readable, inferencia robusta a instrumentos débiles) que afecta a 11 capítulos — varios de ellos en el bloque de Hugging Face. Las tablas de esta sección ya incorporan las novedades relevantes para la sesión en vivo; el detalle completo capítulo por capítulo está en `07_diapositivas/PLAN_SPRINT_DIAPOSITIVAS.md` §5 y en `02_monografia/CHANGELOG_MEJORA.md`.

Módulo 0 — Causalidad elemental y arranque (Semana 1)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S1	Correlación ≠ causación; problema fundamental; escalera de Pearl (adelanto)	Cap. **1** Causalidad elemental	L01	Casos espurios + Simpson; pregunta: ¿asociación o efecto?
S2	Anatomía de un sistema ML en producción; requisitos de un sistema **causal**	Cap. **2** Anatomía del sistema	L02	Lab 0: entorno Python, Git, HF, monorepo · **Cierre HF (10 min):** crear la cuenta y el token de Hugging Face no es un trámite: es la llave de todo el hilo de producción del curso. Con `huggingface_hub` (`notebook_login()`) se deja el entorno listo para subir datasets (S5, S8), mode-

S	Tema	Lectura monografía	Lab	Actividad / entrega
				los (S13) y Spaces (S23) sin volver a configurar. Herramienta: `huggingface_hub` + token de acceso.

Módulo 1 — Fundamentos y datos (Semanas 2–4)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S3	SCM y Jerarquía Causal de Pearl (ver / hacer / imaginar)	Cap. **3** SCM y PCH	L03	Clasificar 10 preguntas en la PCH
S4	Ingeniería de datos: tratamiento, outcome, covariables, trazabilidad	Cap. **4** Ingeniería de datos	L04	**Arranca A1** — roles T/Y/X (Jobs)
S5	Regularización y post-selección (PDS); Cap. 16 del PDF es profundización ◇	Cap. **6** Regularización (+ Cap. **16** PDS ◇)	L05	PDS vs OLS vs diff-in-means · **Cierre HF (10 min):** subir el dataset de A1 (Jobs) al Hub como dataset versionado, para que el primer caso del curso quede disponible y trazable. Se usa `HfApi().create_repo(… repo_type=«dataset»)` + `upload_folder()` sobre la carpeta limpia de `data/`. Objetivo: que el estudiante vea que «datos listos» ya es un artefacto de producción, no solo un archivo local.
S6	Datos de entrenamiento, muestreo, etiquetas naturales	Cap. **7** Datos de entrenamiento	L06	**Entrega A1** — identificación + PDS
S7	Operador do, puertas traseras, contrafactuales	Cap. **8** Intervención y contrafactual	L07	Backdoor vs confusor latente (abstenerse)
S8	Features sin fuga causal	Cap. **9** Features sin fuga	L08	**Arranca A2** — cazar leakage · **Cierre HF (10 min):** subir el dataset limpio de A2 (IHDP) al Hub, ya sin columnas de fuga cau-

S	Tema	Lectura monografía	Lab	Actividad / entrega
				sal, como dataset versionado. Se usa `HfApi().upload_folde` `repo_type=«dataset»)` sobre la carpeta auditada por `auditar_features()`. Objetivo: el dataset «listo» (sin leakage) queda publicado y reutilizable, cerrando la sesión con un artefacto concreto.

Módulo 2 — Estimación causal y primer despliegue HF (Semanas 5–7)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S9	Ortogonalidad de Neyman, cross-fitting y el **score ortogonal canónico** (PLR/IRM/DR/R/PLIV/policy value, una misma inferencia)	Cap. **10** Ortogonalidad	L09	Residuales OOF; partialling-out; ubicar cada estimando futuro en la tabla del score canónico
S10	DML: PLR e IRM, eficiencia semiparamétrica y diagnóstico cuantitativo de soporte común (ESS/trimming)	Cap. **11** DML	L10	PLR mínimo; ATE con IC; reportar ESS/n y trimming ($\alpha \approx 0.1$, Crump et al. 2009)
S11	Evaluación offline: baselines (+ RATE), Qini, placebo, sensibilidad en tres niveles (E-value / R^2 / Manski)	Cap. **14** Validación	L11	**Entrega A2** — DML serializado → B1; profundización opcional: BLP/BEST/CLAN, intervalos conformes
S12	Despliegue como servicio (FastAPI + Docker); `/metadata` ahora machine-readable	Cap. **15** Despliegue servicio	L12	**Arranca B1** — stub `/health` `/predict` `/metadata` (valida contra JSON Schema, Ap. G.4)
S13	Meta-learners S/T/X/R/DR (el DR-learner como instancia del score canónico del Cap. 10)	Cap. **12** Meta-learners	L13	**Arranca A3** — T-learner / CATE · **Cierre HF (10 min):** subir el modelo DML de A2 (`.joblib` + `feature_list.json`) al Hub como arte-

S	Tema	Lectura monografía	Lab	Actividad / entrega
				facto versionado, para que el estimador «viva» en el Hub antes de la model card formal (S17). Se usa `HfApi().upload_file()` sobre `artifacts/A2/dml_estimator.` Objetivo: el modelo ya está publicado; en S17 solo falta documentarlo con la card.
S14	Árboles y bosques causales	Cap. **13** Bosques causales	L14	**Entrega B1** + avance A3

Checkpoint 1 (Semana 8)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S15	Integración: identificación + estimación + primer servicio	Repaso Caps. 1–15	L15	**Entrega A3** — checklist de sistema
S16	Examen parcial y defensa de avance	—	—	Evaluación parcial (camino profesional ⋆)

Módulo 3 — Publicación y CI/CD en Hugging Face (Semana 9)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S17	HF Hub y model cards **causales** (supuestos, no solo accuracy); ahora con **JSON Schema** machine-readable (Ap. G.4)	Cap. **19** Hub y model cards · Ap. G (incl. G.4)	L17	**Arranca B2** — completar card y validarla contra el schema
S18	CI/CD: Actions, tests de humo, **validación de schema** antes de publicar	Cap. **20** CI/CD	L18	**Entrega B2**

Módulo 4 — Explicación, decisión, policy y uplift (Semanas 10–12)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S19	Explicación causal vs asociativa; equidad	Cap. **23** Explicación y equidad	L19	Casos: SHAP $\neq$ efecto
S20	Interpretabilidad y fairness sobre estimadores causales	Cap. **24** Ética e interpretabilidad	L20	Auditoría de importancia (asociativa) con advertencia

S	Tema	Lectura monografía	Lab	Actividad / entrega
S21	Decisiones estructurales bajo incertidumbre	Cap. **25** Decisiones estructurales	L21	Formalizar la decisión de negocio
S22	Policy learning y presupuesto; inferencia formal del **policy value** (EIF) para comparar dos políticas, no solo el punto	Cap. **21** Policy learning	L22	**Arranca A4** — top-k B=20%; reportar IC de la comparación contra baseline
S23	Uplift y targeting; Space de política	Cap. **22** Uplift	L23	**Entrega A4** · **Arranca B3** (Gradio/Space)
S24	Transportabilidad entre dominios	Cap. **26** Generalización	L24	¿El efecto vale en **mi** mercado?

Módulo 5 — Monitoreo y frontera (Semanas 13–14)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S25	Drift de covariables y estabilidad del efecto en producción; si el sistema usa PLIV, monitorear también la fuerza del instrumento (doble umbral F y test de Anderson-Rubin, Cap. 17)	Cap. **30** Monitoreo (+ Cap. **17** PLIV ◇)	L25	**Arranca B4** — métricas KS + chequeo de fuerza de instrumento si aplica
S26	Descubrimiento de estructura (PC/NOTEARS; lab con esqueleto)	Cap. **29** Discovery	L26	**Entrega B3** · avanza B4
S27	Continual learning; panorama RL causal	Cap. **31** Aprendizaje continuo	L27	Reentrenar vs alertar
S28	Lado humano: comunicación y responsabilidad	Cap. **32** Lado humano	L28	**Entrega B4** — comunicar ATE

Módulo 6 — Proyecto final (Semanas 15–16)

S	Tema	Lectura monografía	Lab	Actividad / entrega
S29	Trabajo autónomo + mentoría	Ap. E, G (incl. G.4), H · guía `06_proyecto_final/`	P1	Repo + identificación + baseline
S30	Peer review estructurado	Rúbrica del curso	P2	Evaluar 2–3 proyectos (10%)
S31	Defensa del sistema causal en HF	—	P3	**Entrega final 40%** + humo
S32	Cierre y frontera (CRL, RL causal — panorama)	Caps. electivos 27–28 si aplica	P4	Encuesta; límites y trabajo futuro

7.1 Foco Hugging Face: qué construimos y qué cambió (Etapa 2)

La Serie B entrega cuatro piezas de producción sobre Hugging Face (Hub, Spaces, Actions), cada una construida sobre la anterior. La segunda pasada de mejoras de la monografía (Etapa 2) tocó específicamente lo que se documenta y valida en el Hub — no la arquitectura del despliegue, que no cambió.

Hugging Face como hilo conductor. A lo largo del curso hay **10 puntos de contacto** con Hugging Face: **4 de refuerzo corto** (cierre de 10 minutos) en las sesiones **2** (setup de cuenta/token), **5** (subir dataset de A1 al Hub), **8** (subir dataset limpio de A2 sin fuga al Hub) y **13** (subir el modelo DML de A2 al Hub como artefacto); y **6 de contenido central** en las sesiones **12** (despliegue del endpoint, B1), **17** (Hub y model cards, B2), **18** (CI/CD, B2), **23** (Space de política, B3), **25** (monitoreo, B4) y **31** (aprendizaje continuo / RL). Los refuerzos cortos repiten el mismo patrón — subir un artefacto con `huggingface_hub`— para que el estudiante llegue a la model card formal de S17 con el flujo ya familiar.

Entrega	Sesiones	Qué se construye	Lectura / diapositiva
B1 — API	Arranca S12 · Entrega S14	FastAPI + Docker; endpoints `/health`, `/predict` y `/metadata` — este último ahora **machine-readable** y validado contra el JSON Schema de la model card.	Cap. 15
B2 — Hub / CI	Arranca S17 · Entrega S18	Model card causal (supuestos, población, IC — no solo accuracy) serializada según el nuevo **JSON Schema** `causal-model-card-v1.schema.json` (Ap. G.4); GitHub Actions corre el smoke test **y** valida el schema antes de permitir publicar.	Cap. 19, Cap. 20
B3 — Space	Arranca S23 · Entrega S26	Gradio Space que expone la **política** (top-k con presupuesto), no solo una predicción puntual — el decisor interactúa con el resultado de A4.	Cap. 22
B4 — Monitor	Arranca S25 · Entrega S28	Dashboard de drift de covariables (KS) y estabilidad del efecto en producción; si el sistema usa PLIV, agrega el **doble umbral** (F de primera etapa + Anderson-Rubin, Cap. 17) para no reportar un efecto sobre un instrumento débil.	Cap. 30 (+ Cap. 17 ◇)
Proyecto final	S29–S32	Integra B1–B4 en un sistema único; obligatorio comparar ranking predictivo vs. política causal y pasar la prueba de humo con la model card ya validada por schema.	Síntesis Caps. 15/19/20/22/30

Qué cambió en Etapa 2 (y por qué importa para B2 en particular): antes, la model card causal era una convención de prosa (qué campos incluir, sin forma verificable). Ahora es un JSON Schema publicado (Ap. G.4) que el pipeline de CI puede validar automáticamente — la diferencia entre «recordarle al estudiante que documente los supuestos» y «el CI rechaza el **merge** si la card

no los documenta en el campo correcto». Detalle capítulo por capítulo de las 11 áreas afectadas por Etapa 2: `07_diapositivas/PLAN_SPRINT_DIAPOSITIVAS.md` §5.

8. Evaluación

Componente	Peso	Descripción
Proyecto final	40%	Sistema causal en Hugging Face (identificación + estimación + model card + servicio/Space + monitoreo ligero). **Obligatorio:** comparación predictivo vs causal y prueba de humo. Ver `06_proyecto_final/`.
Serie A — casos de estudio	20%	A1 Jobs · A2 DML · A3 CATE · A4 policy. Metodología + autograder.
Serie B — producción HF	15%	B1 API · B2 Hub/CI · B3 Space · B4 monitor. Humo + prácticas de despliegue.
Revisión por pares	10%	2–3 proyectos con rúbrica.
Quizzes	10%	7 quizzes cortos (camino profesional ★).
Contribución al Hub	5%	Dataset o model card reutilizable por la cohorte.

El proyecto **no se aprueba** si el sistema no pasa la prueba de humo (endpoint o Space responde; estimaciones en rango documentado).

Labs Lxx: formativos (badge/consistencia); no sustituyen el peso de A/B salvo política del instructor.

9. Herramientas y stack

- Python 3.10+, pandas, NumPy, scikit-learn; monorepo `lib/` del curso.
- EconML / DoubleML (recomendados; hay fallback sklearn en el monorepo).
- Hugging Face Hub, Spaces, Gradio; FastAPI + Docker; GitHub Actions.
- `jsonschema` (Python) para validar la model card contra `causal-model-card-v1.schema.json` (Ap. G.4) en B2 y en CI.
- Datos: solo `data_benchmark_causal/causal_benchmark_synthetic/datasets/` en entregas del curso.
- Auditoría local: `bash scripts/audit_repo.sh`.

10. Bibliografía y referencias

10.1 Fuentes principales

- Curso ECO-490/ECON-540 (2026). *Sistema de Inteligencia Causal* — monografía Typst, **32 capítulos**. `02_monografia/monografia_Sistema_de_Inteligencia_Causal.pdf`.
- Huyen, C. (2022). *Designing Machine Learning Systems*. O'Reilly. Filosofía pedagógica y ciclo de vida.
- Bareinboim, E. (2025). *Causal Artificial Intelligence* (v0.27). Columbia CausalAI Lab.
- Planes del monorepo: `PLAN_CURSO_COMPLETO.md`, `PLAN_INTEGRACION_MONOGRAFIA.md`.

10.2 Metodología (selección)

- Chernozhukov et al. (2018). Double/debiased machine learning. *The Econometrics Journal*.
- Wager & Athey (2018). Estimation of heterogeneous treatment effects with random forests. *JASA*.
- Künzel et al. (2019). Metalearners for heterogeneous treatment effects. *PNAS*.
- Pearl, J. (2009). *Causality* (2.ª ed.). Cambridge University Press.

10.3 Producción y documentación

- EconML, DoWhy, Hugging Face Hub docs.
- Kästner et al., *Machine Learning in Production* (CMU), Cap. 10.
- Mitchell et al. (2019). Model Cards for Model Reporting. *FAT**.

11. Mapa rápido del hilo de producto (CDS)

Paso	Artefacto	Sesiones	Pregunta de valor
1	A1 Identificación (Jobs)	S4–S6	¿Es estimable el efecto del programa?
2	A2 DML (IHDP-medium)	S8–S11	¿Cuánto mueve en promedio (ATE + IC)?
3	B1 API + B2 Hub/CI	S12–S18	¿Se puede consultar, documentar con supuestos validables por schema, y no publicar roto?
4	A3 CATE + A4 policy	S13–S15, S22–S23	¿A quién priorizar con 20% de capacidad?
5	B3 Space + B4 monitor	S23–S28	¿Un decisor lo usa? ¿Sigue valiendo el efecto?
6	Proyecto final HF	S29–S32	¿Tu caso de negocio en producción?

12. Cronograma semana a semana (profesor y estudiante)

Cómo **usar** los materiales del monorepo cada semana. Detalle ampliado (checklists, rutas de apertura): `CHRONOGRAMA_SEMANAL.md` en la raíz del monorepo. La planificación sesión a sesión (S1–S32) está en la §7; aquí el **cómo** por rol.

12.1 Rutina semanal tipo

Quién	Antes	Durante (1 h 30)	Después
Profesor	Revisar Cap. PDF + lab; 1 pregunta de valor de negocio	20′ concepto · 50–60′ lab guiado · 10–20′ cierre (disrupción)	Dudas del hilo CDS; no retrasar entregas A/B
Estudiante	Leer Cap. del PDF (núm. índice 32)	Lab en vivo o asíncrono	Completar lab + avanzar A/B del bloque

Cierre obligatorio (cada semana): si solo predijéramos el outcome, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

12.2 Uso de materiales por semana

Sem	Ses.	Cap. / Lab	Entrega	Profesor usa	Estudiante usa
1	S1–S2	1–2 / L01–L02	—	Sílabo + monorepo; verificar L02 entorno	PDF Caps. 1–2; labs L01–L02; cuenta HF
2	S3–S4	3–4 / L03–L04	A1 arranca	PCH (L03); Jobs como caso; abrir A1 + `CausalSchema`	L03–L04; A1 EDA/DAG; `real/jobs`
3	S5–S6	6(+16◇)–7 / L05–L06	**A1**	Rúbrica A1; Cap. 16 solo si hay tiempo	L05–L06; **entregar A1** (solo observed)

Sem	Ses.	Cap. / Lab	Entrega	Profesor usa	Estudiante usa
4	S7–S8	8–9 / L07–L08	A2 arranca	Abstenerse si no hay ID; demo leakage; abrir A2	L07–L08; A2 sin fugas; `ihdp_medium`
5	S9–S10	10–11 / L09–L10	A2 curso	Cross-fitting + score ortogonal canónico; ESS/ trimming (Crump) → ATE→go/no-go	L09–L10; A2 PLR + K-fold; reportar ESS/n
6	S11–S12	14–15 / L11–L12	**A2** · B1	Cerrar A2 (joblib); sensibilidad (E-value/R^2/ Manski); demo B1 / health /predict /metadata	**A2** + sync; L11–L12; carpeta B1
7	S13–S14	12–13 / L13–L14	A3 · **B1**	CATE ≠ riesgo predicho; autograder B1	A3 T-learner; **B1**; L13–L14
8	S15–S16	Repaso / — · L15	**A3** · parcial	Checklist A1–A3+B1; parcial solo ★	**A3**; L15; estudiar ★ (no deep)
9	S17–S18	19–20 / L17–L18	**B2**	Model card = supuestos, ahora con JSON Schema; CI que falla humo y schema	L17–L18; **B2** card+Actions
10	S19–S20	23–24 / L19–L20	—	SHAP de $\hat{Y}$ ≠ efecto; preparar policy	L19–L20; releer card B2
11	S21–S22	25+21 / L21–L22	A4 arranca	Decisión de negocio antes de λ; B=20%	L21–L22; A4 con scores A3
12	S23–S24	22+26 / L23–L24	**A4** · B3	A4: causal vs random vs outcome; demo Space	**A4**; L23–L24; B3 Gradio
13	S25–S26	30+29 / L25–L26	B4 · **B3**	200 OK ≠ efecto válido; doble umbral F/AR si hay PLIV; cerrar B3	**B3**; L25–L26; B4
14	S27–S28	31–32 / L27–L28	**B4**	Ops L27; comunicación 3 capas; brief proyecto	L27–L28; **B4**; elegir caso P
15	S29–S30	Ap. E/G/H · guía proyecto	P1 · P2	Mentoría ID+humo+disrupción; pares peer	P1 repo; P2 rúbrica; HF
16	S31–S32	— / elect. ◇	**P3** · P4	Humo + sección disrupción irrenunciables	**P3** sistema HF + video; encuesta

12.3 Calendario de entregas (vista rápida)

Semana	Entrega	Notas
3	**A1**	Identificación Jobs (Serie A 20%)
6	**A2**	DML → artefacto B1
7	**B1**	API + Docker (Serie B 15%)
8	**A3** · parcial	CATE → A4; parcial camino ★

Semana	Entrega	Notas
9	**B2**	Model card + CI HF (valida contra JSON Schema, Ap. G.4)
12	**A4**	Policy B=20% → B3
13	**B3**	Space Gradio
14	**B4**	Monitor drift/supuestos; doble umbral F/Anderson-Rubin si el sistema usa PLIV
15	P1 · P2	Baseline + peer review 10%
16	**P3** (+ P4)	Proyecto final 40% + humo

12.4 Checklist semanal (plantilla)

Estudiante: (1) Cap. N del PDF; (2) lab.ipynb / checks en verde; (3) avance A/B del bloque; (4) tres líneas predictivo vs efecto; (5) no usar columnas de verdad (`truth\_*`) fuera de evaluación.

Profesor: (1) Cap. + lab + ejemplo de negocio de la cohorte; (2) numeración PDF (no Typst antiguo); (3) cierre con disrupción; (4) office hours si bloqueo A/B; (5) electivos ◇ no entran al parcial ★.

12.5 Primera apertura por rol

Estudiante: `01_silabo/silabo.pdf` → `CHRONOGRAMA_SEMANAL.md` (semana actual) → Cap. monografía → `05_labs_sesion/Lxx/lab.ipynb` → notebook A o carpeta B si hay entrega.

Profesor: `docs/NOTA_INSTRUCTORS.md` → sílabo + cronograma → `bash scripts/audit_repo.sh` → demo 10′ (L01 + promesa del curso).