IA Causal en Producción

Monografía del Curso

*De la identificación al despliegue: estimar **efectos**, no solo predicciones, y poner políticas causales en producción en Hugging Face*

Curso ECO-490 / ECON-540
Profesionales y posgrado aplicado (data / ML / product / analytics)
Modalidad online/asíncrona · 32 sesiones · 32 capítulos
Edición 2026

Promesa. Deja de priorizar con scores que confunden correlación con impacto. Estima efectos, documenta supuestos y despliega en Hugging Face — con monitoreo de cuándo el efecto deja de ser válido.

Monorepo del curso: labs L01–L28 · Serie A (casos) · Serie B (HF) · benchmark de datos
Stack: `econml` / `sklearn` · `FastAPI` · `Gradio` · `huggingface_hub` · `Docker`

IA Causal en Producción

Monografía del Curso ECO-490 / ECON-540

Edición 2026

© 2026 Curso ECO-490 / ECON-540
Todos los derechos reservados.

Primera edición, 2026.

Compuesto con Typst 0.15.1.
Tipografía: New Computer Modern (serif), Helvetica Neue (sans-serif), DejaVu Sans Mono (monoespaciada).

Implementación de referencia en el monorepo del curso (`data_benchmark_causal`, Serie A/B).
Stack Python: `econml`, `DoubleML`, `causalml`, `dowhy`, `PyTorch`.

Esta monografía es material de referencia para uso docente.
La reproducción total o parcial requiere citación adecuada.

Prefacio

Esta monografía es el material de referencia formal del curso *IA Causal en Producción*. Está pensada, en primer lugar, para **profesionales** —analistas de datos, ingenieros de ML, product analytics, riesgo, operaciones y perfiles afines— que ya usan modelos predictivos y deben **decidir o priorizar intervenciones**. También sirve a posgrado aplicado y a economistas de último año con base cuantitativa. El curso **no** está diseñado como formación de investigadores básicos: el camino crítico prioriza **casos de estudio**, **estimación de efectos accionables** y **puesta en producción en Hugging Face**.

Se asume familiaridad con regresión, evaluación de modelos y, de forma deseable, nociones de evaluación de impacto (resultados potenciales, confusión). Quien tenga un curso previo de causalidad aplicada (RCT, matching/IPW, IV, DiD) avanzará más rápido; quien no, puede apoyarse en los Caps. 1–3 y en los labs del monorepo. El libro **extiende** ese bagaje al régimen de alta dimensionalidad, heterogeneidad de efectos y —sobre todo— a la ingeniería de sistemas necesaria para **operar** esos métodos en producción.

El eje conceptual combina tres tesis. Primera: *machine learning no identifica causalidad por sí solo*. Los supuestos de identificación siguen siendo del dominio y deben justificarse; el ML flexibiliza la estimación de componentes *nuisance* (propensity, outcome models) sin sacrificar inferencia válida, vía **ortogonalización de Neyman**, **cross-fitting** y **honestidad** en árboles. Segunda: *un estimador causal validado no es, todavía, un sistema*. Documentarlo, servirlo, versionarlo y monitorearlo es trabajo de ingeniería (Huyen, 2022; filosofía DMLS). Tercera —el mensaje de **disrupción** del curso—: *priorizar por score predictivo no es lo mismo que priorizar por efecto*. Un buen predictor responde «quién tiene peor outcome»; un sistema causal responde «a quién **cambia** el outcome si actuamos». Esa diferencia reordena presupuestos, targeting y riesgo reputacional. Cada bloque del curso cierra con la pregunta: **si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?**

Esta doble tesis se refleja en dos plantillas de capítulo, no una. Los capítulos de teoría e identificación causal siguen la estructura de siete componentes de la edición anterior: (i) problema, estimando e identificación; (ii) marco teórico formal con supuestos, teoremas y garantías; (iii) algoritmo e implementación en Python; (iv) caso empírico; (v) riesgos, límites y sensibilidad; (vi) ejercicios; (vii) notas bibliográficas. Los capítulos de ingeniería y producción, nuevos en esta edición, siguen en cambio una estructura de siete componentes centrada en decisiones de diseño con costos y beneficios explícitos, no en una única receta: (i) el problema de diseño; (ii) opciones y trade-offs; (iii) decisión de referencia para el curso; (iv) implementación de referencia; (v) aplicación al sistema causal del curso; (vi) señales de alerta y checklist

operativo; (vii) ejercicios y notas bibliográficas. El Capítulo 1 explica esta distinción con más detalle.

A quién va dirigida. (1) Profesionales de datos/ML/producto que deben llevar **decisiones de intervención** a un servicio o Space. (2) Analistas de organismos, banca, consultoría y empresas que estiman efectos con muchos controles. (3) Estudiantes de pregrado avanzado o posgrado aplicado. Los Caps. 17, 27 y 28 (panel/DML-IV, deep causal, matrix completion) son **profundización electiva**: el profesional aprueba el camino crítico sin dominarlos.

Convenciones. La notación sigue el estándar de la literatura: $Y(d)$ denota el resultado potencial bajo tratamiento $d \in \{0, 1\}$, D es la asignación observada, X son covariables pre-tratamiento. El estimando central es el CATE $\tau(x) = E[Y(1) - Y(0) \mid X = x]$, cuyo promedio $\theta = E[\tau(X)]$ es el ATE. Los algoritmos se presentan en pseudocódigo de complejidad similar al de los *papers* originales; las implementaciones en Python siguen el estilo idiomático de `econml` y `DoubleML`.

La tabla completa de notación se encuentra en la sección siguiente.

Monorepo del curso. La implementación de referencia (labs L01–L28, notebooks Serie A/B, datos de benchmark, autograders) vive junto a esta monografía en el repositorio del curso. La tabla sesión ↔ capítulo ↔ lab ↔ entrega y el posicionamiento profesional se detallan en `PLAN_INTEGRACION_MONOGRAFIA.md` y en el sílabo. Cuando un listado de código del libro use un diseño idealizado (p. ej. Parquet + `CausalSchema`), el monorepo documenta el **equivalente operativo** (CSV + `metadata.json` + `lib.data_io`).

Agradecimientos. Esta monografía se apoya en el ecosistema de benchmarks del monorepo (`data_benchmark_causal`), y en tres fuentes de ingeniería y teoría: *Designing Machine Learning Systems* (Huyen), *Causal Artificial Intelligence* (Bareinboim) y *Machine Learning in Production* (CMU). Agradecemos a los autores de los trabajos metodológicos citados a lo largo del texto.

Cómo usar este libro

Esta monografía está organizada en nueve partes temáticas que agrupan los treinta y dos capítulos del curso. A diferencia de la edición anterior, no todos los capítulos siguen la misma plantilla: el libro alterna entre capítulos de teoría e identificación causal (Plantilla A) y capítulos de ingeniería y producción (Plantilla B), diseñados para enseñarse de forma distinta porque responden preguntas de naturaleza distinta.

Dos plantillas de capítulo

Plantilla A — teoría e identificación causal. Sigue la estructura de siete secciones ya usada en la edición anterior del libro: (i) problema, estimando e identificación; (ii) teoría, supuestos y garantías, con definiciones y teoremas formales; (iii) algoritmo e implementación en Python; (iv) caso empírico; (v) riesgos, límites y sensibilidad; (vi) ejercicios; (vii) notas bibliográficas. Responde la pregunta «¿cómo se estima esto correctamente?».

Plantilla B — ingeniería y producción. Nueva en esta edición, sigue la filosofía de *Designing Machine Learning Systems* (Huyen, 2022): no es una plantilla de recetas únicas sino de decisiones de diseño con costos y beneficios explícitos. Sus siete secciones son: (i) el problema de diseño; (ii) opciones y trade-offs, comparando al menos dos alternativas reales; (iii) la decisión de referencia adoptada para el sistema de ejemplo del curso; (iv) una implementación de referencia (código, configuración); (v) la aplicación específica al sistema causal del curso; (vi) señales de alerta y checklist operativo; (vii) ejercicios y notas bibliográficas. Responde la pregunta «¿cómo se lleva esto a producción de forma responsable?».

Ambas plantillas comparten el mismo cuadro resumen al inicio del capítulo (llamado **cuadro sinóptico** en los capítulos de Plantilla A y **cuadro de decisión** en los de Plantilla B) y el mismo sistema de referencias cruzadas, numeración de figuras/tablas/listados por capítulo, y checklists.

Partes del libro

Parte	Contenido	Caps.
0	Introducción: causalidad elemental y anatomía de un sistema de ML en producción.	1–2

Parte	Contenido	Caps.
I	Fundamentos estructurales y de datos: SCM, Jerarquía Causal de Pearl, regularización, criterio de puerta trasera, ingeniería de datos y **features** sin fuga causal.	3–9
II	Estimación causal flexible y primer despliegue: ortogonalidad, DML, meta-learners, bosques causales, validación, y el primer servicio desplegado del curso.	10–15
III	Diseños de identificación con ML: Post-Double-Selection, panel e instrumentos, mapa de decisión metodológica.	16–18
IV	Publicación y operación en producción: **model cards** causales en Hugging Face Hub, CI/CD.	19–20
V	Heterogeneidad, políticas y **targeting**: **policy learning**, **uplift modeling**.	21–22
VI	Explicación, equidad y decisión estructural: descomposición causal de la equidad, interpretabilidad, decisiones bajo incertidumbre, transportabilidad.	23–26
VII	Métodos avanzados: **deep learning** causal, control sintético y **matrix completion**.	27–28
VIII	Estructura, monitoreo y frontera: descubrimiento de grafos, monitoreo en producción, aprendizaje continuo, panorama de RL causal, y comunicación de resultados.	29–32

Elementos pedagógicos

El libro utiliza los siguientes elementos visuales recurrentes:

- **Cuadros sinópticos / de decisión:** resumen ejecutivo del capítulo.
- **Algoritmos:** pseudocódigo numerado globalmente (capítulos de Plantilla A).
- **Opciones y trade-offs, decisión de referencia:** comparación explícita de alternativas de diseño (capítulos de Plantilla B).
- **Tablas de riesgos:** riesgos, consecuencias, diagnósticos y mitigaciones.
- **Checklists:** listas de verificación de validación o de señales de alerta operativas.
- **Notas técnicas:** detalles matemáticos opcionales o enlaces entre capítulos.
- **Apéndices:** fundamentos matemáticos (A), guía de librerías (B), datos y DGP (C), glosario (D), plantilla de proyecto (E), checklists por método (F), plantilla de **model card** causal (G) y checklist de arquitectura de despliegue (H).

Audiencia profesional y camino crítico

Este libro se lee junto al **monorepo del curso**. El camino crítico para profesionales (★) prioriza: identificación y datos (Caps. 1–4, 6–9) → DML y validación (10–11, 14) → primer servicio HF (15) → CATE y policy (12–13, 21–22) → Hub/CI (19–20) → explicación y decisión

(23–26) → monitoreo y comunicación (29–32). Los Caps. **16–18** y **27–28** son profundización electiva (◇): útiles, pero no bloquean desplegar un sistema en Hugging Face.

Pregunta de valor (repetir en cada bloque). Si solo predijéramos el outcome, ¿a quién trataríamos? Si estimamos el efecto, ¿cambia el ranking, el presupuesto o el riesgo?

Mapa sesión → capítulo → lab → entrega (resumen)

La tabla completa está en el sílabo y en `PLAN_INTEGRACION_MONOGRAFIA.md`. Resumen del hilo de producto:

Sesiones	Caps. monografía	Lab	Entrega	Valor de negocio
S1–S3	1–3	L01–L03	—	Asociación vs efecto; PCH
S4–S6	4, 6–7	L04–L06	**A1**	¿Es estimable el programa?
S7–S11	8–11, 14	L07–L11	**A2**	ATE con IC; sin leakage
S12–S14	12–13, 15	L12–L14	**B1** + A3	API del efecto; CATE
S15–S16	repaso	L15	**A3** · parcial	Sistema causal integrado
S17–S18	19–20	L17–L18	**B2**	Hub + model card + CI
S19–S24	21–26	L19–L24	**A4** · **B3**	Policy + Space HF
S25–S28	29–32	L25–L28	**B4**	Monitoreo y comunicación
S29–S32	Ap. E/G/H	P1–P4	**Proyecto**	Tu caso en producción HF

Dos series de notebooks y el monorepo

El trabajo práctico se organiza en el monorepo del curso (no en un repositorio externo opcional):

- **Labs L01–L28** (`05_labs_sesion/`): práctica formativa por sesión (30–50 min).
- **Serie A** (`03_notebooks_caso_estudio/`): A1 identificación (Jobs) · A2 DML · A3 CATE · A4 policy.
- **Serie B** (`04_notebooks_produccion_hf/`): B1 FastAPI · B2 Hub/CI · B3 Gradio Space · B4 dashboard de drift.
- **Datos** (`data_benchmark_causal/…/datasets/`): CSV + `metadata.json` (benchmark documentado; ver callouts «monorepo» en los capítulos de ingeniería).
- **Proyecto** (`06_proyecto_final/`): sistema causal en HF con comparación **predictivo vs causal**.

La **Serie A** aplica la teoría a un caso con pregunta de identificación. La **Serie B** toma el artefacto de A y lo despliega en Hugging Face. El sílabo (`01_silabo/silabo.pdf`) fija la correspondencia exacta sesión ↔ Cap. N del PDF ↔ lab ↔ entrega.

Cómo leer un capítulo de ingeniería (Plantilla B)

1. Cuadro de decisión (trade-offs).
2. Problema de diseño **específico de un sistema causal**.
3. Opciones reales (no una sola receta).
4. Decisión de referencia del curso.
5. Implementación (y, si aplica, el callout del monorepo).
6. Checklist operativo / alertas.
7. Lab o notebook de la semana.

Notación y convenciones

La siguiente tabla resume los símbolos principales utilizados a lo largo de la monografía.

Símbolo	Significado	Uso
$Y_{i(d)}$	Resultado potencial bajo tratamiento d	Capítulo 1
D_i	Tratamiento observado	Todo el libro
X_i	Covariables pre-tratamiento	Todo el libro
$\tau(x)$	CATE: $E[Y(1) - Y(0) \mid X = x]$	Capítulos 1, 5–12
θ_0	Parámetro causal verdadero	Capítulos 2–4, 8–9
ATE o θ_{ATE}	ATE: $E[\tau(X)]$	Todo el libro
$\mu_{d(x)}$	Outcome condicional: $E[Y \mid X = x, D = d]$	Capítulos 1, 4–5, 13
$g_0(x)$	Componente estructural PLR	Capítulos 3–4
$l_0(x)$	Outcome regression PLR: $E[Y \mid X = x]$	Capítulos 3–4
$e_0(x)$	Propensity score: $E[D \mid X = x]$	Capítulos 4–7
$m_0(x)$	Tratamiento condicional: $E[D \mid X = x]$	Capítulos 3–4
$\psi(W, \theta, \eta)$	Score ortogonal	Capítulos 3–4
η	Nuisance parameter	Capítulos 3–4
$W_i = (Y_i, D_i, X_i)$	Observación i-ésima	Todo el libro
Z_i	Instrumento	Capítulos 8–9
$Y_i^\star$	Transformed outcome	Capítulos 5–7
$\mathcal{C}$	Conjunto de ajuste (backdoor)	Capítulos 1, 15
$\boldsymbol{W}$	Matriz de adyacencia (NOTEARS)	Capítulo 15
$\boldsymbol{w}$	Pesos del control sintético	Capítulo 14
$\omega_{i(x)}$	Pesos locales (GRF)	Capítulo 6
$\mathcal{V}$	Varianza asintótica	Capítulos 3–4
$V(\pi)$	Policy value	Capítulos 11–12
G	Atributo protegido	Capítulo 16
α_i	Efecto fijo de unidad	Capítulo 9
$\mathcal{L}_m$	Hoja m-ésima del árbol	Capítulo 6
u_i	Residuo Robinson (outcome)	Capítulos 3–4
v_i	Residuo Robinson (tratamiento)	Capítulos 3–4
λ	Penalización / multipl. presupuestario	Capítulos 2, 8, 11–12
n, N, T	Obs. i.i.d. / unidades / periodos	Todo el libro

Símbolos y convenciones de notación.

Índice general

Prefacio ... iii
Cómo usar este libro ... v
Dos plantillas de capítulo ... v
Partes del libro ... v
Elementos pedagógicos ... vi
Audiencia profesional y camino crítico ... vi
Mapa sesión → capítulo → lab → entrega (resumen) ... vii
Dos series de notebooks y el monorepo ... vii
Cómo leer un capítulo de ingeniería (Plantilla B) ... viii
Notación y convenciones ... ix
1 Causalidad elemental y el problema fundamental de la inferencia causal ... 34
1.1 Dos preguntas que parecen la misma pregunta ... 34
1.2 Correlación no es causación: tres escenas clásicas ... 35
1.3 El problema fundamental de la inferencia causal ... 36
1.4 Un adelanto de la escalera de la causalidad ... 37
1.5 Por qué el aprendizaje automático no es causal por defecto ... 37
1.6 Ejercicios y notas bibliográficas ... 38
1.6.1 Ejercicios conceptuales ... 38
1.6.2 Notas bibliográficas ... 38
2 Anatomía de un sistema de ML en producción ... 40
2.1 El problema de diseño ... 40
2.2 Opciones y trade-offs ... 41
2.3 Decisión de referencia para el curso ... 42
2.4 Implementación de referencia: el esqueleto del proyecto del curso ... 42
2.5 Aplicación al sistema causal del curso ... 43
2.6 Señales de alerta y checklist operativo ... 43
2.7 Ejercicios y notas bibliográficas ... 44
2.7.1 Ejercicios conceptuales ... 44
2.7.2 Ejercicio de infraestructura (Lab 0) ... 44
2.7.3 Notas bibliográficas ... 44
3 Modelos Causales Estructurales y la Jerarquía Causal de Pearl ... 47
3.1 El problema: formalizar «causa» matemáticamente ... 47
3.2 Teoría: SCM y la Jerarquía Causal de Pearl ... 48
3.2.1 Modelos Causales Estructurales ... 48

3.2.2 Los tres niveles de la Jerarquía Causal de Pearl ... 48
3.3 Algoritmo e implementación ... 50
3.4 Caso empírico: consistencia del grafo supuesto ... 51
3.5 Riesgos, límites y sensibilidad ... 52
3.6 Ejercicios y notas bibliográficas ... 52
3.6.1 Ejercicios teóricos ... 52
3.6.2 Ejercicios computacionales ... 53
3.6.3 Notas bibliográficas ... 53
4 Ingeniería de datos para sistemas causales ... 54
4.1 El problema de diseño ... 54
4.2 Opciones y trade-offs ... 55
4.3 Decisión de referencia para el curso ... 55
4.4 Implementación de referencia ... 57
4.5 Aplicación al sistema causal del curso ... 58
4.6 Señales de alerta y checklist operativo ... 58
4.7 Ejercicios y notas bibliográficas ... 58
4.7.1 Ejercicios conceptuales ... 58
4.7.2 Ejercicio de infraestructura ... 59
4.7.3 Notas bibliográficas ... 59
5 Predicción y causalidad: por qué el ML no es causal por defecto ... 60
5.1 Problema causal, estimando e identificación ... 60
5.2 Teoría, supuestos y garantías ... 62
5.2.1 Supuestos ... 62
5.2.2 Estimador y score ... 63
5.2.3 Garantías ... 63
5.3 Algoritmo e implementación ... 64
5.3.1 Implementación en Python ... 64
5.4 Caso empírico y validación ... 66
5.4.1 Datos y preprocesamiento ... 66
5.4.2 Estimación principal ... 66
5.4.3 Validación ... 67
5.4.4 Interpretación económica ... 67
5.5 Riesgos, límites y sensibilidad ... 68
5.5.1 Tabla de riesgos ... 68
5.5.2 Cuándo no usar este método ... 69
5.6 Ejercicios y notas bibliográficas ... 70
5.6.1 Ejercicios teóricos ... 70
5.6.2 Ejercicios computacionales ... 70
5.6.3 Ejercicios aplicados ... 70
5.6.4 Notas bibliográficas ... 70
6 Regularización, selección de variables y sesgo post-selección ... 72
6.1 Problema causal, estimando e identificación ... 72

6.2 Teoría, supuestos y garantías ... 73
6.2.1 Supuestos ... 73
6.2.2 Estimador y score ... 73
6.2.3 Garantías ... 74
6.3 Algoritmo e implementación ... 77
6.3.1 Pseudocódigo ... 77
6.3.2 Implementación en Python ... 77
6.3.3 Diagnósticos de nuisance ... 79
6.4 Caso empírico y validación ... 80
6.5 Riesgos, límites y sensibilidad ... 80
6.5.1 Tabla de riesgos ... 80
6.5.2 Cuándo no usar este método ... 80
6.5.3 Checklist de validación ... 81
6.6 Inferencia post-selección ... 81
6.7 Ejercicios y notas bibliográficas ... 81
7 Datos de entrenamiento en sistemas causales ... 83
7.1 El problema de diseño ... 83
7.2 Opciones y trade-offs ... 84
7.3 Decisión de referencia para el curso ... 84
7.4 Implementación de referencia ... 84
7.5 Aplicación al sistema causal del curso ... 87
7.6 Señales de alerta y checklist operativo ... 87
7.7 Ejercicios y notas bibliográficas ... 88
7.7.1 Ejercicios conceptuales ... 88
7.7.2 Ejercicio computacional ... 88
7.7.3 Notas bibliográficas ... 88
8 Razonamiento intervencional y contrafactual ... 89
8.1 Problema causal, estimando e identificación ... 89
8.2 Teoría, supuestos y garantías ... 90
8.2.1 El criterio de puerta trasera ... 90
8.2.2 Buenos y malos controles ... 90
8.2.3 Las tres reglas del cálculo-do ... 91
8.2.4 Cuando la puerta trasera falla: el criterio de puerta delantera ... 92
8.2.5 Cómputo contrafactual: abducción, acción, predicción ... 93
8.3 Algoritmo e implementación ... 94
8.4 Caso empírico ... 94
8.5 Riesgos, límites y sensibilidad ... 95
8.6 Ejercicios y notas bibliográficas ... 95
8.6.1 Ejercicios teóricos ... 95
8.6.2 Ejercicios computacionales ... 96
8.6.3 Notas bibliográficas ... 96
9 Ingeniería de *features* sin fuga causal ... 97

9.1 El problema de diseño ... 97
9.2 Opciones y trade-offs ... 98
9.3 Decisión de referencia para el curso ... 98
9.4 Implementación de referencia ... 99
9.5 Aplicación al sistema causal del curso ... 101
9.6 Señales de alerta y checklist operativo ... 101
9.7 Ejercicios y notas bibliográficas ... 101
9.7.1 Ejercicios conceptuales ... 101
9.7.2 Ejercicio computacional ... 101
9.7.3 Notas bibliográficas ... 102
10 Ortogonalidad de Neyman, cross-fitting e influence functions ... 105
10.1 Problema causal, estimando e identificación ... 105
10.2 Teoría, supuestos y garantías ... 106
10.2.1 El problema del doble sesgo ... 106
10.2.2 Ortogonalidad de Neyman ... 107
10.2.3 Construcción del score ortogonal para PLR ... 107
10.2.4 Teorema central de DML ... 109
10.3 Algoritmo e implementación ... 110
10.3.1 El rol del cross-fitting ... 110
10.3.2 Pseudocódigo ... 111
10.3.3 Implementación en Python ... 111
10.4 Caso empírico y validación ... 114
10.5 Riesgos, límites y sensibilidad ... 115
10.6 Ejercicios y notas bibliográficas ... 115
11 Double/Debiased Machine Learning ... 117
11.1 Problema causal, estimando e identificación ... 117
11.2 Teoría, supuestos y garantías ... 118
11.2.1 Supuestos ... 118
11.2.2 Estimador y score ... 118
11.2.3 Garantías ... 119
11.2.4 Diagnósticos cuantitativos de soporte común ... 120
11.3 Algoritmo e implementación ... 121
11.3.1 DML con DoubleML para PLR ... 121
11.3.2 DML con econml para CATE bajo PLR/etapa final lineal ... 121
11.3.3 Comparación de learners ... 122
11.3.4 Verificación de leakage ... 123
11.4 Caso empírico y validación ... 124
11.5 Riesgos, límites y sensibilidad ... 127
11.6 Ejercicios y notas bibliográficas ... 127
12 Meta-learners para efectos de tratamiento heterogéneos ... 129
12.1 Problema causal, estimando e identificación ... 129
12.2 Teoría, supuestos y garantías ... 130

12.2.1 El S-learner . . . 130
12.2.2 El T-learner . . . 130
12.2.3 El X-learner . . . 130
12.2.4 R-learner: Estimador y score . . . 131
12.2.5 El DR-learner . . . 131
12.2.6 Comparación de propiedades . . . 133
12.3 Algoritmo e implementación . . . 135
12.3.1 Pseudocódigo . . . 135
12.3.2 Implementación en Python . . . 135
12.3.3 Análisis de sesgo y varianza por subgrupo . . . 137
12.4 Caso empírico y validación . . . 137
12.5 Riesgos, límites y sensibilidad . . . 138
12.6 Ejercicios y notas bibliográficas . . . 138
13 Árboles y bosques causales . . . 140
13.1 Motivación aplicada . . . 140
13.2 Teoría, supuestos y garantías . . . 141
13.2.1 Árboles causales honestos . . . 141
13.2.2 El criterio de splitting . . . 142
13.3 Estimador y score . . . 142
13.3.1 Causal forests y Generalized Random Forests . . . 142
13.3.2 Comparación con meta-learners . . . 143
13.4 Implementación en Python . . . 144
13.4.1 Estimación con CausalForestDML . . . 144
13.4.2 Comparación con meta-learners . . . 146
13.5 Caso empírico y validación . . . 146
13.5.1 Identificación de subgrupos con `feature_importances_` . . . 146
13.5.2 Heterogeneidad en efectos del programa NSW . . . 146
13.5.3 Policy trees y validación de subgrupos . . . 147
13.6 Riesgos, límites y sensibilidad . . . 148
13.6.1 Tabla de riesgos . . . 148
13.6.2 Límites . . . 149
13.7 Ejercicios propuestos . . . 149
13.8 Lecturas complementarias . . . 150
14 Validación, refutación y sensibilidad . . . 151
14.1 Motivación aplicada . . . 151
14.2 Teoría, supuestos y garantías . . . 152
14.2.1 El problema fundamental . . . 152
14.2.2 Curva Qini (versión acumulada) . . . 152
14.2.3 Curva uplift y transformed outcome . . . 153
14.2.4 Placebo tests . . . 154
14.2.5 Sensibilidad a confusión no observada: protocolo de tres niveles . . . 154
14.2.6 Validación con datos sintéticos . . . 155

14.2.7 Tests formales de heterogeneidad: BLP, BEST y CLAN 155
14.2.8 Intervalos conformes para efectos individuales 156
14.3 Implementación en Python 157
14.3.1 Curva Qini sobre datos sintéticos 157
14.3.2 Placebo test 159
14.4 Caso empírico y validación 159
14.4.1 Suite de refutación 159
14.4.2 Curva Qini comparativa 160
14.5 Riesgos, límites y sensibilidad 162
14.5.1 Tabla de riesgos 162
14.5.2 Límites 163
14.6 Evaluación offline en el ciclo de vida del sistema 163
14.6.1 *Baselines* obligatorios 164
14.6.2 Selección formal de estimadores de CATE: RATE 164
14.6.3 Versionado del proceso de evaluación 164
14.7 Ejercicios y notas bibliográficas 165
14.7.1 Ejercicios propuestos 165
14.7.2 Lecturas complementarias 165
15 Despliegue de un estimador causal como servicio 166
15.1 El problema de diseño 166
15.2 Opciones y trade-offs 167
15.3 Decisión de referencia para el curso 167
15.4 Implementación de referencia 167
15.5 Aplicación al sistema causal del curso 170
15.6 Señales de alerta y checklist operativo 171
15.7 Ejercicios y notas bibliográficas 171
15.7.1 Ejercicios conceptuales 171
15.7.2 Ejercicio de infraestructura (Lab, Notebook B1) 171
15.7.3 Notas bibliográficas 171
16 Post-Double-Selection LASSO 174
16.1 Motivación aplicada 174
16.2 Teoría, supuestos y garantías 175
16.2.1 Modelo de alta dimensión con efecto causal 175
16.2.2 Post-Double-Selection (PDS) 175
16.2.3 Pseudocódigo: Post-Double-Selection 175
16.2.4 La elección de λ no es un detalle de implementación 175
16.2.5 Intuición: por qué la doble selección funciona 176
16.2.6 Comparación con DML 177
16.3 Implementación en Python 178
16.3.1 Implementación de PDS 178
16.4 Caso empírico y validación 179
16.4.1 Comparación PDS vs DML vs selección manual 179

16.4.2 Caso de estudio: efecto de dejar de fumar sobre peso (NHEFS) 179
16.4.3 Validación 181
16.5 Ejercicios propuestos 182
16.6 Lecturas complementarias 183
17 Machine learning causal en datos de panel 184
17.1 Problema causal, estimando e identificación 184
17.2 Teoría, supuestos y garantías 185
17.2.1 Modelo de panel con efectos fijos 185
17.2.2 Supuestos 185
17.2.3 Estimador y score 186
17.2.4 Garantías 187
17.3 Implementación en Python 189
17.3.1 DML sobre panel sintético con ground truth 189
17.3.2 DMLIV sobre close_college 191
17.4 Caso empírico y validación 191
17.4.1 Diseños con tiempos de tratamiento escalonados 194
17.5 Ejercicios propuestos 195
17.6 Lecturas complementarias 195
18 Diseño de investigación y selección de método 196
18.1 Motivación aplicada 196
18.2 Problema causal, estimando e identificación 197
18.2.1 Dimensiones del problema causal 197
18.2.2 Estimando e identificación 197
18.3 Teoría, supuestos y garantías 198
18.3.1 Mapa de decisión metodológica 198
18.3.2 Identificación jerárquica de diseños 198
18.3.3 Criterios adicionales de selección 199
18.4 Implementación en Python 201
18.4.1 Función `choose_method` 201
18.5 Caso empírico y validación 203
18.5.1 Análisis crítico de 4 problemas 203
18.5.2 Validación de la elección metodológica 203
18.6 Errores comunes y límites 203
18.7 Ejercicios propuestos 204
18.8 Lecturas complementarias 204
19 *Model cards* causales y publicación en Hugging Face Hub 207
19.1 El problema de diseño 207
19.2 Opciones y trade-offs 208
19.3 Decisión de referencia para el curso 208
19.4 Implementación de referencia 209
19.5 Aplicación al sistema causal del curso 210
19.6 Señales de alerta y checklist operativo 210

19.7 Ejercicios y notas bibliográficas ... 210
19.7.1 Ejercicios conceptuales ... 210
19.7.2 Ejercicio de infraestructura ... 210
19.7.3 Notas bibliográficas ... 211
20 CI/CD para modelos causales ... 212
20.1 El problema de diseño ... 212
20.2 Opciones y trade-offs ... 213
20.3 Decisión de referencia para el curso ... 213
20.4 Implementación de referencia ... 215
20.5 Aplicación al sistema causal del curso ... 216
20.6 Señales de alerta y checklist operativo ... 216
20.7 Ejercicios y notas bibliográficas ... 217
20.7.1 Ejercicios conceptuales ... 217
20.7.2 Ejercicio de infraestructura (cierra el Notebook B2) ... 217
20.7.3 Notas bibliográficas ... 217
21 Aprendizaje de políticas óptimas ... 220
21.1 Motivación aplicada ... 220
21.2 Teoría, supuestos y garantías ... 221
21.2.1 Policy value y welfare regret ... 221
21.2.2 Estimación del policy value ... 221
21.2.3 Restricciones presupuestarias ... 222
21.3 Implementación en Python ... 223
21.3.1 Policy learning con econml ... 223
21.3.2 Restricción presupuestaria ... 225
21.4 Caso empírico y validación ... 225
21.5 Riesgos, límites y sensibilidad ... 227
21.6 Ejercicios propuestos ... 227
21.7 Lecturas complementarias ... 227
22 Uplift modeling y targeting económico ... 229
22.1 Motivación aplicada ... 229
22.2 Marco teórico formal ... 230
22.2.1 Uplift y CATE ... 230
22.2.2 Qini y AUUC: teoría, supuestos y garantías ... 230
22.2.3 Multi-treatment uplift ... 231
22.3 Algoritmo: Asignación por net score con presupuesto ... 232
22.4 Aplicación con Python ... 232
22.4.1 Uplift modeling con causalml ... 232
22.4.2 Caso empírico y validación: costo-efectividad ... 235
22.5 Riesgos, límites y mitigación ... 237
22.6 Ejercicios propuestos ... 238
22.7 Lecturas complementarias ... 239
23 Explicación causal y equidad algorítmica ... 242

23.1 Problema causal, estimando e identificación ... 242
23.2 Teoría, supuestos y garantías ... 243
23.2.1 Efectos directos, indirectos y espurios ... 243
23.2.2 Equidad contrafactual ... 243
23.3 Algoritmo e implementación ... 244
23.4 Caso empírico ... 244
23.5 Riesgos, límites y sensibilidad ... 245
23.6 Ejercicios y notas bibliográficas ... 245
23.6.1 Ejercicios teóricos ... 245
23.6.2 Ejercicio computacional ... 245
23.6.3 Notas bibliográficas ... 246
23.6.4 Literatura complementaria de equidad causal ... 246
24 Ética, interpretabilidad y comunicación de resultados ... 247
24.1 Motivación aplicada ... 247
24.2 Teoría, supuestos y garantías ... 248
24.2.1 Equidad causal ... 248
24.2.2 Del criterio observacional al criterio causal ... 249
24.2.3 Interpretabilidad ... 250
24.2.4 Comunicación de incertidumbre ... 250
24.3 Implementación en Python ... 252
24.3.1 Interpretabilidad con SHAP ... 252
24.3.2 Tabla de resultados para policymakers ... 254
24.3.3 Análisis de equidad ... 255
24.4 Caso empírico y validación ... 256
24.4.1 Auditoría de equidad en focalización de transferencias ... 256
24.5 Riesgos, límites y sensibilidad ... 257
24.5.1 Tabla de riesgos ... 257
24.5.2 Cuándo no usar este método ... 258
24.6 Ejercicios propuestos ... 259
24.7 Lecturas complementarias ... 259
25 Decisiones estructurales bajo incertidumbre ... 260
25.1 Problema causal, estimando e identificación ... 260
25.2 Teoría, supuestos y garantías ... 261
25.2.1 La decisión como maximización de utilidad esperada ... 261
25.2.2 Decisiones sobre múltiples variables y el rol de la incertidumbre ... 261
25.2.3 Criterios de decisión cuando el efecto no está identificado con precisión ... 261
25.3 Algoritmo e implementación ... 263
25.4 Caso empírico ... 263
25.5 Riesgos, límites y sensibilidad ... 264
25.6 Ejercicios y notas bibliográficas ... 264
25.6.1 Ejercicios teóricos ... 264

25.6.2 Ejercicio computacional ... 264
25.6.3 Notas bibliográficas ... 265
26 Generalización y transportabilidad entre dominios ... 266
26.1 Problema causal, estimando e identificación ... 266
26.2 Teoría, supuestos y garantías ... 267
26.2.1 Diagramas de selección ... 267
26.2.2 Por qué esto no es lo mismo que «reestimar con más datos» ... 268
26.3 Marco teórico: transportabilidad causal ... 268
26.4 Algoritmo e implementación ... 269
26.5 Caso empírico ... 270
26.6 Riesgos, límites y sensibilidad ... 270
26.7 Ejercicios y notas bibliográficas ... 270
26.7.1 Ejercicios teóricos ... 270
26.7.2 Ejercicio computacional ... 270
26.7.3 Notas bibliográficas ... 271
27 Deep learning para inferencia causal ... 274
27.1 Motivación aplicada ... 274
27.2 Teoría, supuestos y garantías ... 275
27.2.1 TARNet: representación compartida ... 275
27.2.2 CFRNet: balance integral probability metric ... 275
27.2.3 DeepIV ... 275
27.3 Algoritmo de entrenamiento TARNet/CFRNet ... 276
27.4 Implementación en Python ... 277
27.4.1 CFRNet con penalización MMD ... 279
27.5 Arquitectura de TARNet/CFRNet ... 279
27.6 Caso empírico y validación ... 280
27.7 Límites y errores comunes ... 281
27.7.1 ¿Balancear la representación ayuda realmente? ... 282
27.8 Inferencia válida con redes neuronales profundas ... 282
27.8.1 Detalles técnicos ... 283
27.9 Ejercicios propuestos ... 283
27.10 Lecturas complementarias ... 284
28 Control sintético y matrix completion ... 285
28.1 Motivación aplicada ... 285
28.2 Teoría, supuestos y garantías ... 286
28.2.1 SCM clásico ... 286
28.2.2 Matrix completion ... 286
28.2.3 Elegir r o λ: el hiperparámetro que fija el contrafactual ... 287
28.2.4 Comparación SCM vs. matrix completion ... 287
28.2.5 Inferencia en synthetic control ... 288
28.3 Algoritmo e implementación ... 288
28.3.1 Algoritmo: Synthetic control clásico ... 288

28.3.2 SCM clásico sobre Texas ... 289
28.3.3 Matrix completion ... 290
28.4 Caso empírico y validación ... 290
28.5 Riesgos, límites y mitigación ... 292
28.6 Ejercicios propuestos ... 294
28.7 Lecturas complementarias ... 294
29 Descubrimiento causal y grafos ... 297
29.1 Motivación aplicada ... 297
29.2 Marco teórico formal ... 298
29.2.1 DAGs y el criterio de puerta trasera ... 298
29.2.2 Algoritmo PC ... 298
29.2.3 Algoritmos clásicos de descubrimiento de estructura ... 299
29.2.4 Pseudocódigo: PC skeleton ... 299
29.2.5 NOTEARS ... 299
29.2.6 Límites: causal sufficiency ... 300
29.3 Implementación en Python ... 301
29.3.1 Construcción de DAGs con dowhy ... 301
29.3.2 NOTEARS y PC con causal-learn ... 301
29.4 Caso empírico y validación ... 302
29.4.1 Evaluación de grafos estimados ... 302
29.4.2 Caso de estudio: DAGs y descubrimiento causal ... 303
29.5 Riesgos, límites y sensibilidad ... 305
29.5.1 Tabla de riesgos ... 305
29.5.2 Límites del descubrimiento causal ... 306
29.6 Ejercicios propuestos ... 307
29.7 Lecturas complementarias ... 307
30 Monitoreo de supuestos causales en producción ... 309
30.1 El problema de diseño ... 309
30.2 Opciones y trade-offs ... 310
30.3 Decisión de referencia para el curso ... 310
30.4 Implementación de referencia ... 312
30.5 Aplicación al sistema causal del curso ... 314
30.6 Señales de alerta y checklist operativo ... 315
30.7 Ejercicios y notas bibliográficas ... 315
30.7.1 Ejercicios conceptuales ... 315
30.7.2 Ejercicio de infraestructura (Lab, arranca Notebook B4) ... 315
30.7.3 Notas bibliográficas ... 315
31 Aprendizaje continuo y panorama de *Reinforcement Learning* causal ... 317
31.1 Parte I: Aprendizaje continuo para sistemas causales ... 317
31.1.1 El problema de diseño ... 317
31.1.2 Opciones y trade-offs ... 318
31.1.3 Decisión de referencia para el curso ... 318

31.2 Parte II: Panorama de *Reinforcement Learning* causal 319
31.2.1 De decisiones únicas a decisiones secuenciales 319
31.2.2 Bandits causales: el caso introductorio más simple 319
31.2.3 Por qué este curso se detiene aquí 320
31.3 Ejercicios y notas bibliográficas 320
31.3.1 Ejercicios conceptuales 320
31.3.2 Ejercicio de infraestructura 320
31.3.3 Notas bibliográficas 320
32 El lado humano de los sistemas causales 322
32.1 El problema de diseño 322
32.2 Opciones y trade-offs 322
32.3 Decisión de referencia para el curso 323
32.4 Implementación de referencia: plantilla de comunicación 324
32.5 Aplicación al sistema causal del curso: cierre 324
32.6 Señales de alerta y checklist operativo 324
32.7 Ejercicios y notas bibliográficas 325
32.7.1 Ejercicios conceptuales 325
32.7.2 Ejercicio de cierre (proyecto final) 325
32.7.3 Notas bibliográficas 325
32.8 Comunicación efectiva de incertidumbre 325
A Notación, convenciones y fundamentos matemáticos 326
A.1 Notación general 326
A.2 Modos de convergencia 327
A.3 Teoremas límite fundamentales 328
A.4 Teoría asintótica semiparamétrica 328
A.4.1 Espacios tangentes 328
A.4.2 Estimación semiparamétrica eficiente 328
A.5 Ortogonalidad de Neyman 329
A.6 Cross-fitting y sample splitting 329
A.7 Honesty en árboles causales 329
A.8 Norma nuclear y matrix completion 329
A.9 Modelos causales estructurales 330
A.10 Influence functions 330
A.11 Regresión Discontinua (RDD) 330
A.12 Transportabilidad 331
B Guía de librerías y entorno reproducible 332
B.1 Entorno reproducible 332
B.2 econml (Microsoft Research) 332
B.3 DoubleML 333
B.4 causalml (Uber) 333
B.5 dowhy (Microsoft AWS) 333
B.6 PyTorch 334

B.7 scikit-learn 334
B.8 networkx 334
B.9 statsmodels 334
B.10 Tabla comparativa 335
B.11 Instalación recomendada 335
B.11.1 Librerías complementarias 335
C Datos, DGP y benchmarks 337
C.1 Datasets reales 337
C.2 Datasets sintéticos 338
C.3 Estructura de archivos 338
C.4 Recomendaciones de uso por capítulo 338
C.5 Datasets complementarios sugeridos 339
C.6 Ground truth y checksums 339
D Glosario de estimandos, supuestos y métodos 341
D.1 Estimandos 341
D.2 Supuestos 342
D.3 Métodos 343
D.4 Garantías 347
D.5 Diagnósticos 347
E Plantilla de proyecto final y rúbrica 349
E.1 Estructura del informe 349
E.2 Capa causal de la pregunta 349
E.3 DAG o supuesto estructural 350
E.4 Identificación 350
E.5 Estimación 350
E.6 Validación y refutación 350
E.7 Análisis de sensibilidad 350
E.8 Transportabilidad 351
E.9 Ética y comunicación 351
E.10 Criterios de evaluación 351
E.11 Entregables 351
E.12 Ejemplos de problemas aplicados 352
E.13 Plazos sugeridos 352
F Checklists por método 353
F.1 Checklist DML 353
F.2 Checklist meta-learners 353
F.3 Checklist causal forest 353
F.4 Checklist PDS 353
F.5 Checklist panel/DMLIV 354
F.6 Checklist policy learning 354
F.7 Checklist uplift 354
F.8 Checklist SCM/matrix completion 354

F.9 Checklist causal discovery 355
G Plantilla de *model card* causal 356
G.1 Campos obligatorios y su propósito 356
G.2 Plantilla completa 357
G.3 Checklist antes de publicar 358
G.4 Esquema machine-readable (causal-model-card-v1.schema.json) 358
H Checklist de arquitectura de despliegue 359
H.1 Elegir el patrón de *serving* 359
H.2 Checklist de la función de inferencia 359
H.3 Checklist de CI/CD 360
H.4 Checklist de monitoreo en producción 360
H.5 Checklist de comunicación 360
Bibliografía 361

Índice de figuras

Figura 11.1 Sensibilidad de la estimación DML-PLIV del retorno a la educación al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea punteada es la estimación OLS con controles (HC1). Dataset: `close_college` (Card, 1995), $n = 3,003$. La sensibilidad a K bajo se mitiga con *repeated cross-fitting* (Nota técnica 10.2.4). 126

Figura 13.1 Heterogeneidad de CATE estimado por `CausalForestDML` sobre `nsw_mixtape`. Izquierda: CATE promedio por subgrupo con IC al 95%. Derecha: superficie interpolada de CATE en función de edad y educación. Dataset: `nsw_mixtape` (Lalonde, 1986), $n = 445$. 147

Figura 14.1 Curva Qini comparativa: Causal Forest vs. T-learner (GBM) vs. baseline aleatorio. Dataset sintético con CATE conocido $\tau(x) = 2 + 3x_1 - x_2^2$, $n = 3,000$. El Causal Forest domina al T-learner, especialmente en el rango 20–60% de la muestra. 161

Figura 16.1 Sensibilidad de la estimación PDS al hiperparámetro λ de LASSO. Las barras indican IC al 95% (HC1). La línea verde punteada marca el λ óptimo por cross-validation. Dataset: `nhefs`, $n = 1,566$, $p = 51$ controles. 180

Figura 17.1 DML-panel vs. FE clásico (LSDV): sensibilidad al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea verde punteada es el ATE verdadero; la naranja punteada es el estimador FE clásico. Dataset: `panel_fe_dynamic` (sintético con ground truth). 192

Figura 21.1 Policy value vs. presupuesto de tratamiento. La línea azul es la estrategia óptima (targeting por CATE estimado); la gris punteada es tratamiento aleatorio; la roja punteada es tratar a todos'". DGP sintético que simula targeting de transferencias gubernamentales ($n = 5,000$). Las curvas muestran el policy value esperado al variar la fracción de la población tratada. 226

Figura 22.1 Izquierda: curva de uplift acumulado ordenando la muestra por CATE estimado (Causal Forest). Derecha: análisis de costo-efectividad de la mezcla entre SMS ($0.5/unidad) y llamada ($8/unidad) bajo un presupuesto total de $100,000. Dataset sintético tipo churn, $n = 5,000$. 237

Figura 27.1 Arquitectura de TARNet / CFRNet (Shalit, Johansson & Sontag, 2017). La capa de representación compartida Φ es seguida por dos cabezas separadas h_0, h_1 para $D = 0$ y $D = 1$. CFRNet añade una penalización IPM (Wasserstein o MMD) que fuerza el balance entre las distribuciones de $\Phi(X)$ condicionales al tratamiento. 280

Figura 28.1 Izquierda: trayectoria de la unidad tratada vs. control sintético (SCM) y matrix completion (MC), con periodo pre-tratamiento $T_0 = 15$. Derecha: efecto estimado post-tratamiento para la unidad tratada (efecto verdadero = 2.5) y para un placebo espacial (unidad no tratada, debe ser ≈ 0). Panel sintético $N = 20$, $T = 30$. 291
Figura 29.1 Izquierda: DAG para el retorno a la educación (Card, 1995); U denota un confusor no observado. Derecha: DAG ponderado estimado por NOTEARS sobre datos sintéticos con estructura conocida ($X_0 \to X_1$, $X_1 \to X_2$, $X_3 \to X_2$, $X_4 \to X_1$); las etiquetas en las aristas son los pesos estimados. 304

Índice de tablas

Símbolos y convenciones de notación. x
Tabla 5.1 Régimen predictivo vs. régimen causal. 62
Tabla 5.2 Riesgos al confundir predicción con causalidad. 69
Tabla 10.1 Instancias del score ortogonal canónico a lo largo del curso. 109
Tabla 10.2 Errores comunes en la implementación de DML-PLR. 115
Tabla 11.1 Learners comunes para nuisance en DML. 120
Tabla 11.2 Riesgos comunes en DML 127
Tabla 12.1 Comparación de meta-learners. 133
Tabla 12.2 CATE estimado por subgrupo en NSW (CausalForestDML). Réplica propia. 137
Tabla 12.3 Riesgos comunes en meta-learners 138
Tabla 13.1 Causal Forest vs. meta-learners. 143
Tabla 13.2 Riesgos al usar árboles y bosques causales. 149
Tabla 14.1 Suite de refutación para modelos causales. 160
Tabla 14.2 Riesgos en la validación de modelos causales sin ground truth. 163
Tabla 16.1 PDS vs. DML. 177
Tabla 16.2 Riesgos al aplicar PDS LASSO. 182
Tabla 17.1 Riesgos comunes en DML-panel 193
Tabla 18.1 Mapa de decisión metodológica. 198
Tabla 18.2 Identificación jerárquica de diseños causales. 199
Tabla 18.3 Riesgos comunes en la elección metodológica 203
Tabla 21.1 Riesgos comunes en policy learning 227
Tabla 22.1 Riesgos comunes en uplift modeling y targeting 238
Tabla 24.1 Riesgos en ética, interpretabilidad y comunicación de ML causal 258
Tabla 27.1 Riesgos comunes en deep causal learning 281
Tabla 28.1 SCM clásico vs. matrix completion 287
Tabla 28.2 Riesgos en SCM y matrix completion 293
Tabla 29.1 Métricas de evaluación para PC y NOTEARS sobre datos sintéticos ($n = 1000$, $p = 5$). 303
Tabla 29.2 Riesgos en descubrimiento causal y grafos 306
Tabla 1.1 Símbolos y convenciones notacionales. 327
Tabla 2.1 Comparación de librerías. 335
Tabla 2.2 Librerías complementarias. 335
Tabla 3.1 Datasets reales del repositorio. 337

Tabla 3.2 Datasets sintéticos con *ground truth*. 338
Tabla 3.3 Datasets complementarios sugeridos. 339
Tabla 5.1 Rúbrica de evaluación del proyecto final. 351

Índice de algoritmos

Algoritmo 1. Post-LASSO OLS (selección ingenua) 77
Algoritmo 2. Double Machine Learning con cross-fitting (K-fold) 110
Algoritmo 3. DML manual con cross-fitting para PLR 111
Algoritmo 4. DML con cross-fitting 121
Algoritmo 5. X-learner 135
Algoritmo 6. Causal tree honesto 142
Algoritmo 7. Post-Double-Selection (PDS) 175
Algoritmo 8. DML-panel con within-transformation 187
Algoritmo 9. Policy tree con restricción presupuestaria 225
Algoritmo 10. Asignación por net score con presupuesto 232
Algoritmo 11. Entrenamiento TARNet/CFRNet 277
Algoritmo 12. Synthetic control clásico 289
Algoritmo 13. PC skeleton — esqueleto del grafo causal 299

Índice de listados

Listado 3.1 SCM simulado: divergencia entre asociación e intervención. 51
Listado 4.1 Esquema de roles causales como estructura de datos explícita. 57
Listado 5.1 Comparación predictivo vs. causal sobre datos de Card (1995). 65
Listado 5.2 Simulación de sesgo por collider. 67
Listado 6.1 Ilustración del sesgo post-selección. 78
Listado 6.2 Partialling-out manual. 79
Listado 7.1 Chequeo de balance con SMD, razón de varianzas y corrección por comparaciones múltiples. 86
Listado 8.1 Verificación del criterio de puerta trasera con `networkx`. 94
Listado 9.1 Auditoría de *features* por marca de tiempo y por rol declarado. 100
Listado 10.1 Implementación manual de DML para PLR. 113
Listado 10.2 DML aplicado a NSW Lalonde. 114
Listado 11.1 DML con librería DoubleML sobre NSW. 121
Listado 12.1 Comparación de meta-learners sobre dataset sintético. 136
Listado 12.2 Sesgo del S-learner bajo regularización fuerte. 137
Listado 13.1 Causal Forest sobre NSW con mapas de heterogeneidad. 145
Listado 13.2 Causal Forest vs. R-learner en datos sintéticos. 146
Listado 13.3 Importancia de variables en causal forest. 146
Listado 14.1 Curva Qini sobre dataset sintético con ground truth. 158
Listado 14.2 Placebo temporal sobre panel sintético. 159
Listado 15.1 Función de inferencia pura, desacoplada del framework web. 168
Listado 15.2 Servicio FastAPI que envuelve la función de inferencia. 169
Listado 15.3 Metadatos del modelo, servidos desde el mismo artefacto que la inferencia. 170
Listado 15.4 `Dockerfile` para contenerizar el servicio. 170
Listado 16.1 Post-Double-Selection LASSO sobre NHEFS. 178
Listado 16.2 Comparación PDS vs. DML vs. selección manual. 179
Listado 16.3 Sensibilidad al hiperparametro lambda. 181
Listado 17.1 DML sobre panel sintético. 190
Listado 17.2 DML-PLIV sobre close_college. 191
Listado 18.1 Función de decisión metodológica. 202
Listado 18.2 Caso 1: retorno a la educación. 203
Listado 19.1 Plantilla mínima de *model card* causal. 209
Listado 19.2 Publicación del modelo y su *model card* en el Hub. 209

Listado 20.1 *Workflow* de GitHub Actions con pruebas de software y estadísticas en etapas separadas. 215
Listado 20.2 Prueba estadística de humo: el placebo no debe ser significativo. 216
Listado 21.1 Policy learning con evaluación hold-out sobre un DGP sintético (covariables reales de `gov_transfers`, tratamiento y resultado simulados). 224
Listado 21.2 Policy learning con restricción presupuestaria. 225
Listado 22.1 Uplift modeling multi-tratamiento con `causalml`: un estimador por acción. . 234
Listado 22.2 Análisis costo-efectividad: tres estrategias sobre las columnas de uplift estimadas en el listado Listado 22.1. 236
Listado 23.1 Descomposición directo/indirecto con un SCM lineal simulado. 244
Listado 24.1 SHAP para Causal Forest. 253
Listado 24.2 Tabla de resultados para comunicación a tomadores de decisión. 254
Listado 24.3 Análisis de equidad en policy learning. 255
Listado 25.1 Selección de acción óptima entre tres políticas candidatas con incertidumbre. 263
Listado 26.1 Chequeo simplificado: ¿el destino difiere solo en la distribución de una covariable? 269
Listado 27.1 Implementación de TARNet en PyTorch. 278
Listado 27.2 CFRNet con penalización MMD. 279
Listado 28.1 SCM clásico sobre dataset Texas. 289
Listado 28.2 Matrix completion con nuclear norm. 290
Listado 29.1 Identificación con DAGs en dowhy. 301
Listado 29.2 PC y NOTEARS con causal-learn. 302
Listado 30.1 Las cuatro métricas de monitoreo causal sobre una ventana reciente de datos. 313
Listado 31.1 Comparación champion-challenger antes de promover un reentrenamiento. . 318
Listado 32.1 Plantilla de tres capas para comunicar un resultado causal. 324
Listado 2.1 Instalaci'on de librer'ias complementarias. 333
Listado 2.2 Red de representación para TARNet/CFRNet en PyTorch. 334
Listado 2.3 Instalación del stack base de librerías de ML causal. 335
Listado 2.4 Instalaci'on de librer'ias complementarias. 336
Listado 3.1 Verificación de integridad de datasets con checksums SHA-256. 339
Listado 7.1 Plantilla completa de *model card* causal, para copiar como `README.md` del repositorio en Hugging Face Hub. 357
Listado 7.2 Esquema JSON versionado de la *model card* causal, validable por máquina en el CI. 358

Parte I

Introducción

Esta parte abre el libro con dos capítulos sin prerrequisitos: la distinción elemental entre correlación y causalidad, y la anatomía de un sistema de machine learning en producción. Juntos establecen los dos hilos —causal y de ingeniería de sistemas— que el resto del libro desarrolla en paralelo.

Capítulo 1

Causalidad elemental y el problema fundamental de la inferencia causal

Cuadro sinóptico del capítulo

Problema:	Distinguir una pregunta asociativa de una pregunta causal
Idea central:	El problema fundamental de la inferencia causal (Holland, 1986)
Herramienta:	Resultados potenciales $Y(1), Y(0)$; un adelanto de la escalera de Pearl
Ejemplos:	Correlaciones espurias, paradoja de Simpson
Sin laboratorio:	Sesión puramente conceptual — el primer notebook llega en el Módulo 1
Prepara:	3 (SCM y PCH) y 5 (ML no es causal por defecto)

1.1 Dos preguntas que parecen la misma pregunta

Suponga dos preguntas sobre un programa de becas universitarias. La primera: *¿los estudiantes becados tienen, en promedio, mejores calificaciones que los no becados?* La segunda: *¿dar una beca a un estudiante mejora sus calificaciones?* Ambas preguntas se responden, en apariencia, con el mismo tipo de dato —una tabla de estudiantes, si recibieron beca, y sus calificaciones— y sin embargo son preguntas radicalmente distintas. La primera es una pregunta **asociativa**: describe un patrón en los datos tal como existen. La segunda es una pregunta **causal**: describe qué pasaría si *interviniéramos* sobre el mundo, otorgando una beca que de otro modo no se habría otorgado.

La confusión entre ambas preguntas no es un error ingenuo. Es, de hecho, el error más común y más costoso en la aplicación de *machine learning* a la toma de decisiones. Un modelo predictivo entrenado sobre $(\text{beca}, \text{calificación})$ puede alcanzar una precisión excelente respondiendo la primera pregunta y, sin embargo, ofrecer una respuesta completamente equivocada si se lo usa para decidir a quién becar —porque los estudiantes que hoy reciben becas no son una muestra aleatoria de la población: probablemente ya tenían mejores calificaciones, mejor

preparación, o mayor motivación **antes** de recibir la beca. La asociación observada mezcla el efecto de la beca con estas diferencias preexistentes.

Este curso completo puede resumirse en una sola tesis, que retomaremos una y otra vez bajo distintas formas técnicas: **ningún volumen de datos, por sí solo, convierte una pregunta asociativa en una pregunta causal**. Convertir una en otra requiere supuestos explícitos sobre cómo se generaron los datos —supuestos que provienen del conocimiento del dominio, no del algoritmo—. El aporte del *machine learning* moderno, que ocupará el resto del curso, es permitir que esos supuestos se combinen con métodos flexibles y de alta dimensión sin perder validez estadística. Pero el primer paso, el de este capítulo, es aprender a **reconocer** cuándo una pregunta es causal, y por qué los datos nunca la responden solos.

1.2 Correlación no es causación: tres escenas clásicas

La distinción anterior suele aceptarse en principio y olvidarse en la práctica. Tres ejemplos clásicos ayudan a que la intuición se vuelva difícil de desactivar.

Escena 1: cigüeñas y nacimientos. En varios países europeos, los conteos anuales de parejas de cigüeñas y de nacimientos humanos están positivamente correlacionados a nivel regional. Nadie propone que las cigüeñas traen bebés; ambas variables responden a una tercera —el tamaño y la ruralidad de la región— que las mueve en la misma dirección sin que exista ningún vínculo causal directo entre ellas.

Escena 2: el tamaño del pie y la capacidad de lectura. En una muestra de niños entre 2 y 12 años, el tamaño del pie predice con notable precisión el puntaje en una prueba de lectura. Un modelo de *machine learning* entrenado sobre estos datos «aprendería» esta relación con alta confianza. La variable omitida es, por supuesto, la edad: los niños mayores tienen pies más grandes y leen mejor, sin que agrandar artificialmente el pie de un niño mejore su lectura. En el lenguaje que formalizaremos en el próximo capítulo, la edad es un *confusor* (*confounder*): afecta tanto a la variable explicativa como al resultado, y genera una asociación que no representa ningún mecanismo causal entre ellas.

Ejemplo 1.1 ***(El problema fundamental)***

La paradoja de Simpson. Un hospital evalúa dos tratamientos, A y B, para una misma condición. Tomando todos los pacientes en conjunto, el tratamiento A tiene una tasa de éxito mayor que B. Sin embargo, al separar a los pacientes por gravedad del caso (leve/grave), el tratamiento B resulta superior tanto en el grupo leve como en el grupo grave. La reversión ocurre porque el tratamiento A se administró desproporcionadamente a los casos leves —que se recuperan más fácilmente por sí solos— mientras que B se reservó para los casos graves. La gravedad es, otra vez, un confusor: determina tanto qué tratamiento recibe el paciente como su probabilidad de recuperación. La paradoja de Simpson (1951 el fenómeno ya había sido descrito por Yule (1903)) es la demostración más nítida de que una asociación puede invertir su signo por completo según qué variables se incluyan en el análisis —y de que no existe una respuesta puramente estadística sobre cuál desagregación es la «correcta»: se requiere una teoría causal (¿la gravedad afecta a la asignación del tratamiento?) para saberlo.

Estas tres escenas comparten una estructura: una variable no observada, o no correctamente condicionada, genera una asociación que desaparece o se revierte en cuanto se controla por ella. La pregunta que este curso enseña a hacer sistemáticamente es: *¿qué tendría que ser cierto sobre cómo se generaron estos datos para que la asociación observada refleje el efecto causal que me interesa?*

1.3 El problema fundamental de la inferencia causal

Formalicemos la intuición anterior con la herramienta que usaremos durante todo el curso: el marco de **resultados potenciales** (Neyman, 1923 Rubin, 1974). Para cada unidad i (una persona, un hogar, una empresa) y un tratamiento binario $D_i \in \{0, 1\}$, definimos dos resultados **potenciales**: $Y_i(1)$, el resultado que se observaría si la unidad recibiera el tratamiento, y $Y_i(0)$, el resultado que se observaría si no lo recibiera. El efecto causal individual del tratamiento sobre la unidad i es, por definición, la diferencia $Y_i(1) - Y_i(0)$.

Definición 1.2

El problema fundamental de la inferencia causal (Holland 1986): para cualquier unidad i, solo se observa uno de los dos resultados potenciales —el correspondiente al tratamiento efectivamente recibido— y nunca ambos. Si i recibió el tratamiento, observamos $Y_i(1)$ pero $Y_i(0)$ permanece contrafactual, es decir, no observado y no observable. Si no lo recibió, ocurre lo simétrico.

Esta afirmación, aunque elemental, tiene una consecuencia que estructura todo el campo: el efecto causal individual $Y_{i(1)} - Y_{i(0)}$ **nunca** puede calcularse directamente para ninguna unidad, sin importar cuántos datos se recolecten sobre ella. Lo que sí puede estimarse, bajo supuestos adecuados, es un efecto **poblacional** o **promedio** —por ejemplo, el efecto promedio del tratamiento (ATE), $\theta = E[Y(1) - Y(0)]$— comparando grupos de unidades distintas que recibieron y no recibieron el tratamiento.

Conviene ver, ya en este capítulo introductorio, exactamente **dónde** entra el supuesto que hace legítima esa comparación, porque es la misma estructura lógica que reaparecerá, con aparato técnico creciente, en todos los métodos del curso. Lo que los datos entregan directamente es la **diferencia de medias observada**, $\Delta = E[Y \mid D = 1] - E[Y \mid D = 0]$. Aplicando la restricción de consistencia $Y = DY(1) + (1 - D)Y(0)$, esta diferencia se reescribe como

$$\Delta = \underbrace{E[Y(1) - Y(0) \mid D = 1]}_{\text{efecto causal sobre los tratados (ATT)}} + \underbrace{E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0]}_{\text{sesgo de selección}}. \tag{1.1}$$

El segundo término compara el resultado que tratados y no tratados habrían tenido **en ausencia de tratamiento**: es cero solo si ambos grupos eran comparables de partida, y no hay ningún dato que permita calcularlo, porque $E[Y(0) \mid D = 1]$ involucra el resultado potencial no observado de los tratados. Las tres escenas de la sección anterior son, todas, casos donde ese segundo término no es cero y domina la comparación.

Los experimentos aleatorizados lo anulan **por diseño**: si D se asigna independientemente de $(Y(0), Y(1))$, entonces $E[Y(0) \mid D = 1] = E[Y(0) \mid D = 0]$ y $\Delta = \theta$. La aleatorización no

«descubre» nada en los datos; impone, mediante el procedimiento de asignación, una condición que ningún volumen de datos observacionales garantiza. Gran parte de este curso está dedicada precisamente a los métodos que permiten **aproximar** esa condición cuando no hubo aleatorización —haciéndola plausible condicional en un conjunto de covariables observadas— usando herramientas de *machine learning* para manejar un número grande de ellas sin perder validez estadística.

1.4 Un adelanto de la escalera de la causalidad

Judea Pearl propuso organizar todas las preguntas causales en tres niveles jerárquicos, popularizados como la «escalera de la causalidad» (Pearl et al. 2018) y formalizados como la Jerarquía Causal de Pearl (PCH) en el trabajo que retomaremos en detalle en el 3. Como adelanto:

- **Nivel 1 — Asociación** («ver»): ¿qué relación existe entre las variables tal como se observan? *¿Los estudiantes becados tienen mejores notas?*
- **Nivel 2 — Intervención** («hacer»): ¿qué pasaría si actuáramos sobre el sistema? *¿Qué pasaría con las notas si diéramos una beca a un estudiante que hoy no la tiene?*
- **Nivel 3 — Contrafactual** («imaginar»): ¿qué habría pasado en un mundo alternativo, dado lo que efectivamente observamos? *¿Habría aprobado María si le hubieran dado la beca, sabiendo que en los hechos no se la dieron y no aprobó?*

Cada nivel requiere información y supuestos estrictamente más fuertes que el anterior: los datos observacionales puros solo permiten responder preguntas de Nivel 1 sin más; responder Nivel 2 requiere supuestos de identificación (como los que exploraremos con Post-Double-Selection y Double Machine Learning); responder Nivel 3 requiere, además, un modelo estructural completo. La pregunta con la que abrimos este capítulo —¿dar una beca mejora las calificaciones?— es una pregunta de Nivel 2, y es precisamente el tipo de pregunta que un modelo de *machine learning* estándar, entrenado para predecir bien, **no** está diseñado para responder.

1.5 Por qué el aprendizaje automático no es causal por defecto

Vale la pena anticipar, en términos simples, por qué esto importa específicamente para este curso y no solo para la estadística clásica. Los algoritmos de *machine learning* —regresión regularizada, bosques aleatorios, *gradient boosting*, redes neuronales— están diseñados y evaluados para minimizar el error de predicción fuera de muestra. Esa optimización no distingue, ni tiene por qué distinguir, entre la parte de la relación $X \to Y$ que es causal y la parte que refleja confusión, como en las tres escenas de la 1.2. Un modelo que predice el tamaño del pie a partir de la capacidad de lectura (o viceversa) con gran precisión está haciendo exactamente lo que se le pidió: predecir bien. El error no está en el algoritmo, sino en usar sus resultados para responder una pregunta —la pregunta causal— que nunca se le planteó.

Este curso dedica su primera mitad a mostrar cómo, bajo supuestos de identificación explícitos, es posible usar la misma flexibilidad de alta dimensión que hace poderoso al *machine learning* predictivo —sin heredar su ceguera ante la confusión—, y su segunda mitad

a mostrar cómo llevar esos modelos, ya validados, a un sistema que opera de forma confiable en producción. El 5 retoma esta discusión con el aparato formal completo (resultados potenciales en alta dimensión, sesgo de regularización, el estimando CATE); el 3 formaliza la escalera de causalidad con modelos causales estructurales. Este capítulo solo pretende dejar instalada, de forma intuitiva y memorable, la pregunta que todo el curso responde: *¿es esto una pregunta de asociación, o una pregunta causal?*

1.6 Ejercicios y notas bibliográficas

1.6.1 Ejercicios conceptuales

1. Para cada una de las siguientes preguntas, indique si es de Nivel 1 (asociación), Nivel 2 (intervención) o Nivel 3 (contrafactual), y justifique en una oración: (a) ¿Los países con más médicos per cápita tienen menor mortalidad infantil? (b) ¿Contratar más médicos reduciría la mortalidad infantil en un país específico? (c) ¿Habría sobrevivido este paciente si el hospital hubiera tenido un médico más?
2. Proponga un ejemplo propio (distinto a los del capítulo) de una correlación espuria generada por una variable confusora. Identifique explícitamente la variable confusora y explique por qué genera la asociación observada.
3. Explique con sus propias palabras por qué el problema fundamental de la inferencia causal (Holland, 1986) implica que ningún algoritmo, por sofisticado que sea, puede calcular el efecto causal individual $Y_{i(1)} - Y_{i(0)}$ para una unidad específica a partir de datos observacionales de esa unidad.
4. Un equipo de datos entrena un modelo de *gradient boosting* para predecir ventas a partir de si un producto tuvo o no una promoción, alcanzando un R^2 de 0.95. El equipo concluye que «la promoción explica el 95% de las ventas» y recomienda aplicarla a todos los productos. ¿Qué está mal en este razonamiento, en términos de los niveles de la escalera de causalidad?

1.6.2 Notas bibliográficas

El marco de resultados potenciales se origina en (Neyman 1923) para experimentos agrícolas aleatorizados y se extiende a estudios observacionales en (Rubin 1974); Holland (1986) formaliza el problema fundamental de la inferencia causal y sigue siendo la referencia estándar para esa formulación. La descomposición de la diferencia de medias en ATT más sesgo de selección de la 1.3 es estándar; su tratamiento completo, incluida la discusión de cuándo el ATT y el ATE coinciden, está en (Imbens et al. 2015), Capítulo 1. Pearl et al. (2018) ofrece la exposición más accesible de la escalera de causalidad para un público no especializado; el tratamiento técnico completo de la Jerarquía Causal de Pearl se encuentra en (Bareinboim et al. 2022) —la formalización canónica del resultado, que el 3 retoma con precisión— y, de forma integrada con el resto del programa de IA causal, en (Bareinboim 2025) y (Pearl 2009). Simpson (1951) es la referencia original de la paradoja que lleva su nombre, aunque el fenómeno había sido descrito

antes en (Yule 1903). Para una introducción contemporánea y aplicada al marco contrafactual, véase (Hernán et al. 2020), ya citado en capítulos posteriores.

Capítulo 2

Anatomía de un sistema de ML en producción

Cuadro de decisión del capítulo

Decisión:	Tratar el modelo como un componente de un sistema, no como el sistema entero
Alternativas:	Enfoque centrado en el modelo (*model-centric*) vs. enfoque centrado en el sistema (*system-centric*, DMLS)
Trade-off clave:	Velocidad de iteración académica vs. confiabilidad operativa
Stack:	Python, Git, Docker, cuenta en Hugging Face Hub (Lab 0 de este capítulo)
Riesgo principal:	Confundir "el modelo entrena bien" con "el sistema está listo para producción"

2.1 El problema de diseño

Un equipo de análisis de datos entrena un estimador de efectos causales —digamos, un modelo DML del tipo que se construirá en la Parte II de este curso— y obtiene un intervalo de confianza razonable, diagnósticos de identificación satisfactorios y una historia convincente sobre el mecanismo económico. El equipo concluye, con toda razón desde el punto de vista estadístico, que «el modelo funciona». Y sin embargo, si ese modelo se entrega tal cual a un equipo de producto para que decida a quién ofrecer un subsidio, casi con certeza algo saldrá mal en cuestión de semanas: la función que calcula las covariables en el entorno de producción no coincide exactamente con la que se usó para entrenar; nadie sabe qué hacer cuando llegan datos con un valor faltante; no existe forma de saber, tres meses después, si la población a la que se le sigue aplicando el modelo todavía se parece a la población de entrenamiento; y si el modelo empieza a fallar, nadie recibe una alerta hasta que un usuario se queja.

El problema de diseño de este capítulo es reconocer, antes de escribir una sola línea de código de estimación, que **un modelo entrenado y un sistema en producción son dos objetos distintos**, y que la distancia entre ambos no se cierra con más precisión estadística

sino con decisiones de ingeniería. Como señala (Huyen 2022), cuando la mayoría de las personas piensan en «un sistema de machine learning» piensan únicamente en el algoritmo; sin embargo, el algoritmo es apenas un componente de un sistema que también incluye la interfaz con la que interactúan usuarios y desarrolladores, el stack de datos que alimenta al modelo, el *backend* de cómputo sobre el que corre, y la infraestructura que permite desarrollarlo, desplegarlo, monitorearlo y actualizarlo. Este curso dedica su segunda mitad a esos componentes no-algorítmicos, precisamente porque suelen ser el motivo real por el que un proyecto de ciencia de datos técnicamente correcto fracasa en producción.

2.2 Opciones y trade-offs

Existen, en la práctica, dos filosofías de desarrollo que compiten por el tiempo y la atención de un equipo de datos.

Opción 1 — Enfoque centrado en el modelo (*model-centric*). El foco está en mejorar la especificación, el algoritmo o la arquitectura, manteniendo los datos y el entorno de despliegue relativamente fijos. Es el modo de trabajo dominante en la academia y en competencias como Kaggle: se compite por una décima de mejora en una métrica sobre un dataset fijo. Su ventaja es la velocidad de iteración sobre la pregunta metodológica; su límite es que ignora, por construcción, todo lo que ocurre antes de tener el dataset y después de tener el modelo entrenado.

Opción 2 — Enfoque centrado en el sistema (*system-centric*, DMLS). El foco se reparte deliberadamente entre datos, modelo e infraestructura, entendiendo que mejorar cualquiera de los tres puede mejorar el desempeño observado del sistema. Requiere invertir tiempo en aspectos que no son estadísticamente «interesantes» —formato de almacenamiento, **feature stores**, **logging**, **tests**— y por eso suele sentirse, al principio, como una desviación del trabajo «real». Su ventaja es que es, empíricamente, el único enfoque que sobrevive el contacto con datos reales que cambian con el tiempo y con usuarios reales que dependen del sistema.

Un segundo trade-off, ortogonal al anterior, es el del **proceso** de desarrollo:

Dimensión	Proceso lineal («waterfall»)	Proceso iterativo (DMLS)
Estructura	Recolectar datos → entrenar → desplegar → fin	Ciclo continuo: diseño → datos → desarrollo → despliegue → monitoreo → vuelve a diseño
Supuesto implícito	El mundo (los datos, los usuarios) no cambia después del despliegue	El mundo cambia; el sistema debe detectarlo y adaptarse
Cuándo falla	En cualquier entorno de producción real, tarde o temprano	Requiere infraestructura de monitoreo que el proceso lineal no contempla

El proceso lineal no es una decisión de diseño defendible en 2026 para un sistema que opera de forma continua; se incluye en la tabla porque sigue siendo, de hecho, cómo se enseña y se

ejecuta gran parte de los proyectos de ciencia de datos aplicada, y reconocerlo como la opción por defecto —y como opción inadecuada— es el primer paso para adoptar deliberadamente la alternativa.

2.3 Decisión de referencia para el curso

Este curso adopta explícitamente el **enfoque centrado en el sistema** y el **proceso iterativo** de DMLS como su filosofía de trabajo, formalizados en cuatro requisitos que todo sistema construido en el curso debe satisfacer —reinterpretados aquí para el caso en que el objetivo del sistema es estimar un efecto causal, no solo predecir:

Opciones y trade-offs

- **Confiabilidad**: el sistema sigue produciendo el comportamiento correcto incluso en presencia de errores de datos o de infraestructura. Para un sistema causal, esto incluye algo que un sistema puramente predictivo no necesita: que el efecto estimado siga siendo **válido bajo los supuestos de identificación declarados**, no solo que el servicio esté «arriba».
- **Escalabilidad**: el sistema puede crecer en volumen de datos, de tratamientos o de usuarios sin un rediseño completo. Para un sistema causal, incluye poder re-estimar el efecto sobre subpoblaciones nuevas sin invalidar el pipeline de identificación existente.
- **Mantenibilidad**: otra persona del equipo —no quien lo construyó— puede entender, auditar y modificar el sistema. Para un sistema causal, esto exige que los supuestos de identificación estén **documentados y sean auditables**, no solo el código.
- **Adaptabilidad**: el sistema puede ajustarse a cambios en el entorno (nuevos datos, nuevas poblaciones, nuevas políticas). Para un sistema causal, incluye poder **detectar** cuándo un supuesto causal —no confusión, soporte común, fuerza del instrumento— dejó de sostenerse, tema que retomaremos en el Módulo 5.

Estos cuatro requisitos, y no la precisión del estimador considerada de forma aislada, son el criterio con el que se evaluará cada notebook de producción (Serie B) del curso.

2.4 Implementación de referencia: el esqueleto del proyecto del curso

Todo el trabajo práctico del curso —Serie A y Serie B de notebooks, y el proyecto final— se organiza sobre un mismo esqueleto de repositorio, que se establece en este capítulo y no vuelve a discutirse:

```
proyecto-causal/
├── data/                # datos crudos y procesados (no versionados en git
salvo muestras pequeñas)
```

```
├── notebooks/
│   ├── serie_a_caso_estudio/     # A1–A4: identificación y estimación
│   └── serie_b_produccion/       # B1–B4: despliegue en Hugging Face
├── src/
│   ├── identification/   # DAGs, diagnósticos de no confusión y soporte común
│   ├── estimation/        # DML, meta-learners, bosques causales
│   └── service/            # función de inferencia, app FastAPI
├── tests/                 # pruebas de humo y de sanidad estadística
├── .github/workflows/      # CI/CD (se detalla en el Capítulo 20)
├── Dockerfile
└── model_card.md           # plantilla del Apéndice G
```

Lab 0 de esta sesión consiste en dejar este esqueleto funcionando localmente: entorno de Python con las librerías del Apéndice B, repositorio Git inicializado, cuenta creada en Hugging Face Hub, y Docker instalado y verificado con `docker run hello-world`. No se estima ningún efecto causal todavía; el objetivo es puramente de infraestructura.

2.5 Aplicación al sistema causal del curso

Vale la pena ser explícitos sobre qué cambia, en esta anatomía de sistema, cuando el «modelo» no predice sino que estima un efecto. Primero, **el artefacto que se sirve no es solo un objeto entrenado**: es un estimador más un conjunto de supuestos de identificación que deben viajar junto con él —de nada sirve servir los coeficientes de un DML sin la documentación de qué variables se controlaron y bajo qué DAG supuesto, porque sin eso nadie puede saber si el efecto sigue siendo válido para una nueva observación. Segundo, **la interfaz con el usuario debe comunicar algo más que un número**: un sistema predictivo puede mostrar una predicción puntual; un sistema causal responsable debe comunicar el intervalo de confianza y, cuando sea posible, la población para la cual el efecto fue estimado, para evitar que se use fuera de su dominio de validez. Tercero, **reentrenar no es inocuo**: en un sistema predictivo, reentrenar con datos nuevos casi siempre es deseable si mejora la métrica de error. En un sistema causal, incorporar datos nuevos puede cambiar silenciosamente la población para la que el efecto estimado es representativo —un problema de validez externa, no solo de varianza — y este curso volverá sobre esto en el Capítulo 31 (aprendizaje continuo).

2.6 Señales de alerta y checklist operativo

- ☐ El notebook de estimación no tiene ninguna versión de los datos ni del código asociados (no hay forma de reproducir el resultado).
  ☐ La función que calcula las covariables en el notebook de entrenamiento y la que las calculará en producción no son literalmente la misma función (riesgo de **training--serving skew**).
  ☐ No existe ningún documento, ni siquiera informal, que declare los supuestos de identificación asumidos.

- Nadie en el equipo, aparte de quien entrenó el modelo, podría explicar bajo qué población es válido el efecto estimado.
- No hay ningún mecanismo, ni manual, para detectar si las covariables que llegan en producción se parecen a las de entrenamiento.

Si dos o más de estas señales están presentes, el sistema —por preciso que sea el estimador— no está listo para producción según los criterios de este curso.

2.7 Ejercicios y notas bibliográficas

2.7.1 Ejercicios conceptuales

1. Enumere los componentes de un sistema de ML según (Huyen 2022) (más allá del algoritmo) y, para cada uno, dé un ejemplo concreto de cómo fallaría específicamente si el sistema estima un efecto causal en lugar de predecir.
2. Explique, con sus propias palabras, por qué «reentrenar con datos nuevos» es una decisión más delicada en un sistema causal que en uno puramente predictivo.
3. Revise los cuatro requisitos de la 2.3 (confiabilidad, escalabilidad, mantenibilidad, adaptabilidad) y ordénelos según cuál cree que es más fácil de descuidar en un proyecto real. Justifique.

2.7.2 Ejercicio de infraestructura (Lab 0)

1. Complete el Lab 0: cree el esqueleto de repositorio de la 2.4, inicialice Git, cree una cuenta en Hugging Face Hub si no tiene una, instale Docker y verifique la instalación. Entregue una captura de pantalla de `docker run hello-world` corriendo exitosamente.

2.7.3 Notas bibliográficas

Huyen (2022) es la fuente principal de este capítulo y del enfoque pedagógico de todo el curso; sus Capítulos 1 y 2 («Overview of Machine Learning Systems» e «Introduction to Machine Learning Systems Design») desarrollan en detalle la distinción entre modelo y sistema, y los cuatro requisitos aquí adaptados al caso causal. Sculley et al. (2015) es el artículo seminal que documentó por primera vez, de forma sistemática, cómo el código del modelo de aprendizaje automático suele ser una fracción pequeña del sistema real, y cómo la «deuda técnica» se acumula en el resto de los componentes. Breck et al. (2017) ofrece una rúbrica operativa —«the ML Test Score»— que puede usarse como complemento al checklist de la 2.6 para auditar la preparación de un sistema para producción. Paleyes et al. (2022) complementa a ambos con evidencia empírica: una revisión sistemática de casos documentados de despliegue que clasifica los puntos de fallo a lo largo del ciclo de vida completo (gestión de datos, desarrollo del modelo, despliegue, monitoreo) y confirma que la fracción de fallos atribuible al algoritmo mismo es minoritaria — el argumento central de este capítulo, contrastado contra la práctica industrial en lugar de solo argumentado.

Parte II

Fundamentos estructurales y de datos

Esta parte formaliza el problema causal con Modelos Causales Estructurales y la Jerarquía Causal de Pearl, desarrolla el aparato de regularización y post-selección en alta dimensión, y establece el criterio de puerta trasera para distinguir controles legítimos de controles que sesgan la estimación. En paralelo, construye la capa de datos e ingeniería de features de un sistema causal en producción, sin la cual ningún resultado de identificación sobrevive el paso a un pipeline real.

Capítulo 3

Modelos Causales Estructurales y la Jerarquía Causal de Pearl

Cuadro sinóptico del capítulo

Problema:	Formalizar matemáticamente qué significa «causa» y qué pregunta responde cada nivel de causalidad
Estimando:	Distribuciones $P(v)$, $P(y \mid \text{do}(x))$ y $P(y_x \mid \text{evidencia})$
Identificación:	Un Modelo Causal Estructural (SCM) más su grafo asociado
Método:	Do-calculus (adelanto; formalización completa en el 8)
Garantía:	Cada nivel de la PCH requiere estrictamente más supuestos que el anterior
Librerías:	`networkx`, `dowhy`, `causal-learn`
Validación:	Verificación de que el grafo supuesto es consistente con las independencias observadas

3.1 El problema: formalizar «causa» matemáticamente

El 1 introdujo, de forma intuitiva, la distinción entre preguntas de asociación, de intervención y de contrafactual. Este capítulo formaliza esa distinción con dos herramientas que se usan indistintamente en la literatura moderna de inferencia causal: el marco de **resultados potenciales** (ya presentado en el capítulo anterior) y el marco de **Modelos Causales Estructurales** (SCM) de Judea Pearl, que Elias Bareinboim y su escuela extienden hasta la **Jerarquía Causal de Pearl** (PCH). Los dos marcos son formalmente equivalentes bajo condiciones generales, pero difieren en qué hacen explícito: los resultados potenciales son más naturales para razonar sobre un tratamiento y un resultado; los SCM son más naturales para razonar sobre sistemas con muchas variables relacionadas entre sí —precisamente el tipo de sistema que aparece en un pipeline de datos de producción—, y por eso son el lenguaje que usaremos en la segunda mitad de este curso al hablar de arquitecturas de datos y de despliegue.

La pregunta que este capítulo responde es doble: **(i)** ¿qué objeto matemático representa completamente un sistema causal?, y **(ii)** dado ese objeto, ¿qué tres tipos de pregunta —y solo tres— se le pueden hacer, y qué información mínima requiere responder cada una?

3.2 Teoría: SCM y la Jerarquía Causal de Pearl

3.2.1 Modelos Causales Estructurales

Definición 3.1 ***(SCM)***

Un **Modelo Causal Estructural** (SCM) es una tupla $M = \langle U, V, F, P(u) \rangle$ donde: U es un conjunto de variables exógenas (no modeladas, «de fondo»); $V = \{V_1, ..., V_n\}$ es un conjunto de variables endógenas (las que el modelo explica); $F = \{f_1, ..., f_n\}$ es un conjunto de funciones estructurales tales que cada $V_i = f_i(\text{pa}_i, U_i)$, donde $\text{pa}_i \subseteq V \setminus \{V_i\}$ son los «padres» de V_i (sus causas directas dentro del modelo) y $U_i \subseteq U$; y $P(u)$ es una distribución de probabilidad sobre las variables exógenas.

Cada SCM induce un **grafo causal** G: un nodo por cada variable en V, y una flecha $V_j \to V_i$ si $V_j \in \text{pa}_i$. Este grafo —el mismo objeto que se usó informalmente en el 1 para hablar de confusores— no es una descripción estadística sino una afirmación sobre **mecanismos**: cada ecuación $V_i = f_i(\text{pa}_i, U_i)$ representa un proceso físico, biológico, económico o social real, no simplemente una relación estadística ajustada a los datos. Esta es la diferencia esencial entre un modelo causal y un modelo predictivo: un modelo predictivo puede ajustar Y en función de X sin comprometerse con ninguna afirmación sobre mecanismos; un SCM afirma que si se **intervinieran** las causas de Y, Y cambiaría exactamente según su ecuación estructural.

La conexión con el marco de resultados potenciales del capítulo anterior es directa: dado un SCM con variable de tratamiento D y resultado $Y = f_Y(D, X, U_Y)$, el resultado potencial $Y(d)$ se define como el valor que toma la ecuación estructural de Y al fijar $D = d$: $Y(d) := f_Y(d, X, U_Y)$. Los dos marcos son, bajo esta correspondencia, dos lenguajes para el mismo objeto.

3.2.2 Los tres niveles de la Jerarquía Causal de Pearl

Cada SCM M induce tres distribuciones de probabilidad distintas, que corresponden exactamente a los tres niveles adelantados en el 1:

Nivel (PCH)	Distribución inducida	Se calcula con
$\mathcal{L}_1$ — Asociación	$P(v)$: la distribución observacional conjunta de V	Los datos observados, sin modificar M
$\mathcal{L}_2$ — Intervención	$P(y \mid \text{do}(x))$: la distribución de Y tras *reemplazar* la ecuación de X por la constante x	El SCM «quirúrgicamente modificado» M_x (se borra f_X y se fija $X = x$)

Nivel (PCH)	Distribución inducida	Se calcula con
$\mathcal{L}_3$ — Contrafactual	$P(y_x \mid e)$: la distribución de «Y hubiera sido y si X hubiera sido x», dada la evidencia e efectivamente observada	Un procedimiento de tres pasos: abducción, acción, predicción (ver más abajo)

El operador $\text{do}(x)$ formaliza matemáticamente qué significa «intervenir»: no es lo mismo **observar** que $X = x$ (lo que simplemente selecciona el subconjunto de unidades con $X = x$, y por tanto puede estar contaminado por confusión, como en las tres escenas del capítulo anterior) que **forzar** $X = x$ mediante una intervención externa que anula el mecanismo natural por el que X se determinaba. Formalmente, $P(y \mid \text{do}(x)) \neq P(y \mid X = x)$ en general; ambas coinciden si y solo si no hay confusión entre X y Y —la condición que el resto del curso dedica tanto esfuerzo a verificar o inducir.

Ejemplo 3.2

Los tres niveles sobre el mismo SCM. Considere el SCM simplificado $D = f_D(U_D)$, $Y = f_Y(D, X, U_Y)$, $X = f_X(U_X)$, con U_D y U_Y correlacionados (confusión no observada entre D y Y). En $\mathcal{L}_1$, $P(y \mid D = d)$ mezcla el efecto de D sobre Y con la correlación espuria inducida por U_D, U_Y compartidos. En $\mathcal{L}_2$, $P(y \mid \text{do}(D = d))$ se calcula sobre el modelo modificado donde f_D se reemplaza por la constante d, cortando el vínculo entre U_D y D —y por tanto elimina exactamente la confusión—. En $\mathcal{L}_3$, dado que se observó a un individuo específico con $D = 0, Y = y_0$, la pregunta «¿qué Y habría tenido si D hubiera sido 1?» requiere primero **inferir** la distribución de U_D, U_Y compatible con lo observado (abducción), luego **forzar** $D = 1$ en el modelo (acción), y finalmente **propagar** para predecir Y (predicción) — de ahí el nombre del procedimiento de tres pasos de Pearl para cómputo contrafactual.

Hay aquí un punto que suele perderse en presentaciones más elementales de esta jerarquía: la separación entre niveles no es una limitación práctica de los métodos disponibles, sino un resultado formal.

Teorema 3.3 ***(Teorema de la Jerarquía Causal)***

Sea Ω el espacio de SCM sobre un conjunto de variables V, equipado con una medida de probabilidad natural sobre las funciones estructurales y las distribuciones exógenas. El conjunto de SCM para los cuales las distribuciones de nivel $\mathcal{L}_{k+1}$ quedan **determinadas** por las de nivel $\mathcal{L}_k$ tiene medida cero en Ω, para $k = 1, 2$.

En términos operativos: salvo en un conjunto de casos excepcional (de medida nula), dos SCM distintos pueden inducir exactamente la misma distribución observacional $P(v)$ y, sin embargo, distintas distribuciones interventivas $P(y \mid \text{do}(x))$ —y análogamente entre $\mathcal{L}_2$ y $\mathcal{L}_3$—. Por eso ningún procedimiento que opere únicamente sobre $P(v)$ puede, sin supuestos adicionales, recuperar $P(y \mid \text{do}(x))$: la información simplemente no está ahí. El Teorema de la Jerarquía Causal ((Bareinboim et al. 2022), Bareinboim et al. 2022) establece que las tres capas de la escalera causal son estrictamente disjuntas. Este resultado, presentado de forma integrada con el resto del programa de IA causal en (Bareinboim 2025), es la razón formal —y no solo intuitiva— de la tesis del 1: los datos observacionales solos no responden preguntas causales.

Dos consecuencias prácticas se siguen inmediatamente, y estructuran el resto del curso. Primera: todo método de estimación causal a partir de datos observacionales —DML, PDS, meta-learners, bosques causales— debe importar información extra-datos, y esa información es siempre un supuesto de identificación (típicamente, la afirmación de que las covariables observadas cierran todas las rutas de puerta trasera, 8). Segunda: ese supuesto no se puede validar con los datos que se están usando, porque su función es precisamente suplir lo que los datos no contienen; a lo sumo puede **refutarse** si genera implicaciones observacionales que los datos contradicen (3.4), o someterse a análisis de sensibilidad (14). Ninguna cantidad de datos, ni ningún algoritmo, cambia esta situación.

3.3 Algoritmo e implementación

El siguiente listado construye un SCM simple en Python —una versión estilizada del ejemplo de becas y calificaciones del Capítulo 1, con una variable de motivación U no observada que confunde la relación entre beca (D) y calificación (Y)— y calcula numéricamente $P(y \mid D = 1)$ ($\mathcal{L}_1$) frente a $P(y \mid \text{do}(D = 1))$ ($\mathcal{L}_2$), mostrando que difieren.

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(7)
n = 50_000

# U: motivación no observada (confusor de D y de Y)
U = rng.normal(size=n)

# D (beca): depende de U -- estudiantes mas motivados piden mas becas
D_obs = (U + rng.normal(size=n) > 0.3).astype(int)

# Y (calificacion): depende de D (efecto causal verdadero = 0.4) y de U
Y_obs = 0.4 * D_obs + 0.9 * U + rng.normal(scale=0.5, size=n)

df = pd.DataFrame({"U": U, "D": D_obs, "Y": Y_obs})

# Nivel 1 (asociacion): P(Y | D=1) observacional
assoc = df.loc[df["D"] == 1, "Y"].mean() - df.loc[df["D"] == 0, "Y"].mean()

# Nivel 2 (intervencion): simular do(D=1) para TODA la poblacion,
# reemplazando la ecuacion estructural de D por la constante 1
Y_do1 = 0.4 * 1 + 0.9 * U + rng.normal(scale=0.5, size=n)
Y_do0 = 0.4 * 0 + 0.9 * U + rng.normal(scale=0.5, size=n)
intervencion = Y_do1.mean() - Y_do0.mean()

print(f"Diferencia asociativa  P(Y|D=1)-P(Y|D=0):  {assoc:.3f}")
print(f"Efecto interventivo    P(Y|do(D=1))-do(0): {intervencion:.3f}")
print(f"Efecto causal verdadero (por construccion): 0.400")
# La diferencia asociativa esta inflada por la confusion via U;
# el efecto interventivo recupera el 0.4 verdadero porque do()
# anula el mecanismo que generaba D a partir de U.
```

Listado 3.1: SCM simulado: divergencia entre asociación e intervención.

En la práctica, no observamos U ni podemos, literalmente, «reemplazar la ecuación de D» como en el listado —eso solo es posible porque el ejemplo es una simulación donde conocemos el SCM verdadero—. El problema aplicado de identificación, que el resto del curso desarrolla, es precisamente cómo estimar $P(y \mid \mathrm{do}(x))$ **sin** conocer el SCM completo, usando solo datos observacionales más supuestos sobre el grafo (por ejemplo, con Post-Double-Selection o DML, si se asume no confusión condicional en las covariables observadas).

3.4 Caso empírico: consistencia del grafo supuesto

Antes de estimar cualquier efecto, es buena práctica verificar que el grafo causal supuesto sea **consistente** con las independencias condicionales observadas en los datos. El chequeo es **necesario pero no suficiente**, y el Teorema de la Jerarquía Causal explica por qué: varios grafos distintos pueden inducir exactamente el mismo conjunto de independencias

condicionales —son observacionalmente equivalentes, y forman lo que el 29 llamará su **clase de equivalencia de Markov**— de modo que pasar el test no distingue entre ellos. Lo que el test sí puede hacer es **refutar**: si el grafo implica una independencia que los datos rechazan, el grafo es incorrecto. Con el dataset de retornos a la educación de (Card 1995), ya usado en capítulos posteriores, un grafo que supone que la cercanía a una universidad (`nearc4`) afecta la educación pero no directamente el salario, controlando por educación, implica una independencia condicional testeable: `nearc4` y `wage` deberían ser independientes dado `educ` y el resto de covariables. `dowhy` y `causal-learn` implementan estos chequeos de forma automatizada (`refutar` en el primero, tests de independencia condicional en el segundo); ambos se detallan en el Apéndice B.

3.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **Confundir $P(y \mid X = x)$ con $P(y \mid \mathrm{do}(x))$.** Es, con diferencia, el error más frecuente entre practicantes de *machine learning* que se acercan por primera vez a la inferencia causal: tratar un filtro (`df[df.D==1]`) como si fuera una intervención. Son el mismo objeto solo si no hay confusión.
- **Asumir que el grafo es «el verdadero».** Un SCM formaliza supuestos, no los verifica. Ningún test estadístico puede confirmar que un grafo causal es correcto —solo puede refutarlo si es inconsistente con los datos—. La responsabilidad de argumentar el grafo es del analista, no del algoritmo.
- **Tratar $\mathcal{L}_3$ como si fuera $\mathcal{L}_2$.** Una pregunta contrafactual («¿habría aprobado María si…?») no se responde con el mismo procedimiento que una pregunta interventiva poblacional («¿qué pasaría si becáramos a todos?»). Colapsar ambas —muy común en comunicación de resultados a audiencias no técnicas— puede llevar a promesas que el modelo no puede respaldar.

3.6 Ejercicios y notas bibliográficas

3.6.1 Ejercicios teóricos

1. Escriba el SCM (variables, ecuaciones estructurales, grafo) para el ejemplo de la paradoja de Simpson del 1 (tratamiento, gravedad del caso, recuperación). Indique cuál nodo es el confusor.
2. Para el SCM del ejercicio anterior, escriba explícitamente el modelo modificado $M_{\{\mathrm{do}(D=1)\}}$ y explique, en términos del grafo, qué arista(s) desaparece(n).
3. Explique por qué, en general, $P(y \mid \mathrm{do}(x))$ no puede calcularse a partir de $P(v)$ sin supuestos adicionales sobre el grafo (Teorema de la Jerarquía Causal). Dé un ejemplo de dos SCM distintos que induzcan la misma $P(v)$ pero distinta $P(y \mid \mathrm{do}(x))$.

3.6.2 Ejercicios computacionales

1. Modifique el listado Listado 3.1 para que el efecto causal verdadero de D sobre Y sea 0 (sin efecto), manteniendo la confusión vía U. Verifique que la diferencia asociativa sigue siendo distinta de cero mientras que el efecto interventivo converge a 0.
2. Usando `causal-learn` o `dowhy` (Apéndice B), cargue el dataset `close_college` (Card, 1995) y ejecute un test de independencia condicional entre `nearc4` y `wage` dado `educ` y los controles estándar del 5. ¿El resultado es consistente con el grafo supuesto en la 3.4?

3.6.3 Notas bibliográficas

La referencia canónica del Teorema de la Jerarquía Causal, incluida la construcción precisa de la medida sobre el espacio de SCM que da sentido a la expresión «medida cero», es Bareinboim et al. (2022) su enunciado aquí es deliberadamente informal en ese punto. El capítulo sigue por lo demás la formalización de (Bareinboim 2025), fuente principal de contenido teórico--causal del curso, y la exposición clásica de (Pearl 2009), que introduce el operador do(), el procedimiento de tres pasos para cómputo contrafactual, y el cálculo-do que se enuncia formalmente en el 8. Imbens et al. (2015) discute en detalle la equivalencia formal entre el marco de resultados potenciales y el de SCM. Para una introducción visual y menos técnica a la jerarquía, véase nuevamente (Pearl et al. 2018), ya citado en el capítulo anterior.

Capítulo 4

Ingeniería de datos para sistemas causales

Cuadro de decisión del capítulo

Decisión:	Adoptar un esquema explícito de roles causales sobre los datos, no solo un esquema de tipos
Alternativas:	Tabla ancha sin metadatos vs. esquema con roles etiquetados (tratamiento/resultado/covariable/instrumento)
Trade-off clave:	Velocidad de prototipado vs. prevención sistemática de errores de identificación
Stack:	pandas, Parquet, `pandera` (validación de esquema)
Riesgo principal:	Que el tratamiento se filtre como covariable, o que una variable post-tratamiento contamine X

Implementación en el monorepo del curso (2026)

En el monorepo del curso (2026) los datos de práctica viven en `data_benchmark_causal/…/datasets/` como **CSV** + `metadata.json` (no Parquet obligatorio). Los roles de variables se resuelven con `lib.data_io.load_scenario` y el puente `lib.schema.CausalSchema.from_scenario(«real/jobs»)` (API alineada a este capítulo). Labs: `L04`–`L06`. Entrega: **Notebook A1** (Jobs). Stack: `03_notebooks_caso_estudio/lib/`.

4.1 El problema de diseño

La ingeniería de datos «genérica» —la que enseña Huyen (2022) en su Capítulo 3— se pregunta qué formato de almacenamiento usar, qué modelo de datos (relacional, documento, grafo) es apropiado, y cómo pasar datos entre procesos. Todas esas preguntas siguen siendo relevantes para un sistema causal, pero hay una pregunta adicional, específica, que un pipeline puramente predictivo nunca necesita responder: **¿qué rol estructural juega cada columna del dataset?** En un problema de predicción, todas las columnas de entrada son, en principio,

intercambiables: el modelo puede usarlas todas para minimizar el error. En un problema causal, las columnas no son intercambiables en absoluto: una es el **tratamiento** D, una es el **resultado** Y, algunas son **covariables** X que pueden controlarse legítimamente, y —crucialmente— algunas columnas que **parecen** covariables razonables son en realidad variables **post-tratamiento**, que no deben controlarse porque están en la ruta causal entre D e Y y su inclusión sesga la estimación (un error que retomaremos formalmente en el 8 al hablar de «buenos y malos controles»).

Si el pipeline de datos no distingue estos roles desde el origen —si todo llega como una tabla ancha sin metadatos— la responsabilidad de no confundirlos recae enteramente en la memoria de quien escribe cada notebook, lo cual falla predeciblemente a medida que el sistema crece y más personas lo tocan.

4.2 Opciones y trade-offs

Opciones y trade-offs

- **Tabla ancha sin metadatos.** Cada notebook decide, mediante nombres de columnas hardcodeados en el código, cuál es D, cuál es Y y cuáles son X. Es la opción más rápida para un análisis único y exploratorio, y la que domina en la práctica académica. Su costo aparece cuando el mismo dataset se reutiliza en varios notebooks o, peor, cuando el pipeline de producción necesita reconstruir las mismas columnas: nada impide que dos notebooks distintos definan a X de forma sutilmente diferente (uno incluye una variable post-tratamiento, el otro no), produciendo estimaciones no comparables sin que nadie lo note.
- **Esquema con roles etiquetados.** Se declara, en un único lugar (un archivo de configuración o una clase de datos), qué columna es el tratamiento, cuál el resultado, cuáles son covariables válidas para controlar, y cuáles son instrumentos si los hay. Todo notebook y todo servicio de producción consume ese esquema en lugar de hardcodear nombres de columnas. El costo es la fricción inicial de definir el esquema antes de poder «simplemente correr una regresión».

Un segundo trade-off, heredado directamente de (Huyen 2022) Capítulo 3, es el de formato de almacenamiento: formatos orientados a fila (CSV, JSON) son más simples de inspeccionar manualmente pero más lentos para leer solo un subconjunto de columnas —exactamente lo que un pipeline de estimación causal necesita hacer repetidamente (leer Y, D y un subconjunto de X, sin cargar el resto)—; formatos orientados a columna (Parquet) son más eficientes para ese patrón de acceso y, además, permiten adjuntar metadatos de esquema directamente en el archivo.

4.3 Decisión de referencia para el curso

Todos los datasets usados en el curso —tanto en la Serie A (casos de estudio) como en la Serie B (producción)— se acompañan de un **esquema de roles causales** explícito. El esquema

mínimo declara cuatro listas de nombres de columna: `treatment`, `outcome`, `covariates` y, cuando aplica, `instruments`. Ninguna función de estimación del curso acepta un DataFrame «pelado»; todas reciben el DataFrame junto con su esquema, de modo que sea sintácticamente imposible, por ejemplo, pasar el tratamiento como una covariable por accidente.

Lo que la decisión fija es **que el esquema exista y sea la única fuente de verdad sobre los roles**, no el formato en que se serializa. Parquet es el formato preferido cuando se dispone de él, porque permite adjuntar el esquema como metadato dentro del propio archivo y evita que dato y esquema se separen; pero un CSV acompañado de un `metadata.json` versionado junto a él satisface el mismo requisito y es la forma que efectivamente adopta el benchmark del curso (véase el recuadro de implementación). La distinción importa: el riesgo que esta decisión previene no es de eficiencia de lectura sino de **deriva semántica** —que dos notebooks discrepen sobre qué columna es el tratamiento—, y ese riesgo se cierra con la unicidad del esquema, no con el formato.

Conviene además ser explícito sobre la naturaleza de lo que el esquema declara. Etiquetar una columna como `covariates` no es una afirmación sobre su tipo de dato ni sobre su utilidad predictiva: es una afirmación **causal** —que esa variable puede controlarse legítimamente, es decir, que pertenece a un conjunto que satisface el criterio de puerta trasera del 8—. Por eso el esquema es un artefacto de identificación tanto como de ingeniería, y por eso el 9 le añadirá una etapa de auditoría explícita en lugar de dar la lista de covariables por buena.

4.4 Implementación de referencia

```
from dataclasses import dataclass, field
import pandas as pd

@dataclass
class CausalSchema:
    treatment: str
    outcome: str
    covariates: list[str]
    instruments: list[str] = field(default_factory=list)

    def validate(self, df: pd.DataFrame) -> None:
        declared = {self.treatment, self.outcome, *self.covariates,
*self.instruments}
        missing = declared - set(df.columns)
        if missing:
            raise ValueError(f"Columnas declaradas en el esquema pero ausentes:
{missing}")
        overlap = set(self.covariates) & {self.treatment, self.outcome}
        if overlap:
            raise ValueError(f"El tratamiento o el resultado no pueden ser
covariables: {overlap}")

    def X(self, df: pd.DataFrame) -> pd.DataFrame:
        return df[self.covariates]

    def D(self, df: pd.DataFrame) -> pd.Series:
        return df[self.treatment]

    def Y(self, df: pd.DataFrame) -> pd.Series:
        return df[self.outcome]


# Ejemplo: dataset de retornos a la educacion (Card, 1995)
schema = CausalSchema(
    treatment="educ",
    outcome="wage",
    covariates=["exper", "black", "south", "married"],
    instruments=["nearc4"],
)
df = pd.read_parquet("data/close_college.parquet")
schema.validate(df)  # lanza error si, p.ej., "educ" quedo tambien en
covariates
```

Listado 4.1: Esquema de roles causales como estructura de datos explícita.

Este patrón —trivial en apariencia— es exactamente el tipo de decisión de infraestructura que Huyen (2022) argumenta que rara vez se enseña y que sistemáticamente se paga como deuda técnica más adelante (Sculley et al. 2015).

4.5 Aplicación al sistema causal del curso

El Notebook de caso de estudio A1 (Módulo 1 del curso) exige explícitamente construir el `CausalSchema` del dataset elegido **antes** de correr ninguna estimación, precisamente para forzar la pregunta de identificación (1, 3) a un paso de ingeniería concreto y verificable, en vez de dejarla implícita en la cabeza de quien analiza los datos. Este mismo esquema reaparece, sin cambios, en el Notebook de producción B1 (despliegue del primer endpoint, Capítulo 15): la función de inferencia en producción usa `schema.covariates` para saber exactamente qué columnas esperar del cliente que consulta el servicio, cerrando el círculo entre el notebook de entrenamiento y el servicio desplegado.

4.6 Señales de alerta y checklist operativo

- ☐ El nombre de la columna de tratamiento aparece hardcodeado en más de un notebook, con riesgo de que diverja.
  ☐ Ninguna función de carga de datos valida que el tratamiento y el resultado no estén también en la lista de covariables.
  ☐ No hay forma de saber, sin leer el código de generación de features, si alguna covariable fue medida **después** del tratamiento.
  ☐ El esquema de roles no viaja junto con los datos (ni como metadato del archivo ni como `metadata.json` versionado a su lado), de modo que puede desincronizarse sin que nadie lo note.
  ☐ El formato de almacenamiento (CSV plano) obliga a cargar todas las columnas para leer solo tres.

4.7 Ejercicios y notas bibliográficas

4.7.1 Ejercicios conceptuales

1. Para el dataset de becas del 1, proponga tres covariables legítimas para X y una variable que, aunque correlacionada con el resultado, sería incorrecto incluir en X por ser post--tratamiento. Justifique.
2. Explique por qué un esquema de roles causales explícito es más importante en un sistema con varios notebooks y varios colaboradores que en un análisis individual de una sola vez.

4.7.2 Ejercicio de infraestructura

1. Extienda la clase `CausalSchema` del listado Listado 4.1 con un método `summary()` que imprima, para cada rol, el número de valores faltantes y el tipo de dato de las columnas correspondientes. Aplíquelo al dataset que usará en el Notebook A1.

4.7.3 Notas bibliográficas

Huyen (2022), Capítulo 3, desarrolla en profundidad los formatos y modelos de datos genéricos que este capítulo adapta al caso causal. La distinción entre controles legítimos y variables post--tratamiento se formaliza en el 8 con el lenguaje de grafos causales; véase también la discusión de «buenos y malos controles» en (Bareinboim 2025).

Capítulo 5

Predicción y causalidad: por qué el ML no es causal por defecto

Cuadro sinóptico del capítulo

Problema:	Distinguir predicción de efecto causal
Estimando:	ATE, CATE(x)
Identificación:	No confusión, soporte común, SUTVA
Método:	Comparación predictiva vs causal
Nuisance:	$\mu_{d(x)}$
Garantía:	Identificación bajo supuestos
Librerías:	scikit-learn, statsmodels
Validación:	Simulación de collider, placebos

Nota técnica

Este capítulo retoma, con el aparato formal de la econometría con *machine learning*, la distinción entre asociación y causalidad presentada de forma intuitiva en el 1 y formalizada con SCM y la Jerarquía Causal de Pearl en el 3. Aquí el foco pasa de «¿qué pregunta estoy haciendo?» a «¿cómo la respondo con datos de alta dimensión?» — la pregunta que estructura toda la Parte II del curso.

5.1 Problema causal, estimando e identificación

Considere un economista del Ministerio de Desarrollo Social que debe decidir a qué hogares beneficiar con un programa de transferencias condicionadas. El programa tiene presupuesto limitado: solo puede cubrir al 30% de la población elegible. El analista dispone de cien variables socioeconómicas por hogar (ingresos, composición familiar, escolaridad, empleo, vivienda, salud) y un registro histórico de hogares que recibieron o no el programa, junto con el ingreso posterior observado. La pregunta relevante es *causal*: ¿qué hogares experimentarían el mayor incremento de ingresos si recibieran el programa? La pregunta *predictiva* —qué hogares tendrán

mayores ingresos en el futuro, independientemente del programa— es distinta y, para fines de focalización, equivocada.

La distinción es crucial porque los algoritmos estándar de *machine learning* (regresión ridge, bosques aleatorios, *gradient boosting*, redes neuronales) están optimizados para predicción, no para estimación causal. Un bosque aleatorio que predice con alta precisión el ingreso futuro de un hogar puede ofrecer estimaciones sesgadas del efecto del programa, por dos razones estructurales. Primero, los algoritmos predictivos no distinguen entre variación explicada por el tratamiento y variación explicada por covariables correlacionadas con el tratamiento. Segundo, la regularización que mejora la predicción fuera de muestra introduce sesgo en la estimación de coeficientes causales, fenómeno conocido como *regularization-induced bias*.

Este capítulo introduce el marco conceptual que vertebra todo el curso. Argumentamos que **la inferencia causal requiere supuestos de identificación económicos, no estadísticos**, y que el aporte del ML consiste en flexibilizar la estimación de componentes auxiliares (*nuisance*) sin vulnerar esos supuestos. Establecemos la notación de resultados potenciales en el régimen de alta dimensionalidad, definimos los estimandos centrales del curso (ATE, ATT, CATE, *policy value*), y mostramos empíricamente con el dataset de Card (1995) sobre retornos a la educación que un modelo predictivo de alta dimensión puede arrojar respuestas radicalmente distintas a las de una estimación causal cuidadosa.

Conviene, sin embargo, evitar la conclusión simétrica y también equivocada: que la predicción sea siempre el instrumento inadecuado. La distinción fundamental entre problemas de predicción y problemas de política se formaliza en (Kleinberg et al. 2015) (Kleinberg et al. 2015), quienes argumentan que existe una clase entera de problemas de política —los que llaman *prediction policy problems*— en los que la decisión depende de un pronóstico y **no** de un efecto causal. Su ejemplo canónico es la decisión de operar una cadera a un paciente terminal: el beneficio de la operación depende de cuánto vivirá el paciente, que es una pregunta puramente predictiva; el efecto causal de la operación sobre la movilidad puede darse por conocido. El criterio para distinguir ambos regímenes es preciso y vale la pena memorizarlo: **si la decisión cambia la variable sobre la que se razona, la pregunta es causal; si la decisión solo depende de un estado del mundo que ocurriría de todos modos, la pregunta es predictiva**. Focalizar un subsidio por «quién se beneficiaría más» es causal —asignar el subsidio cambia el ingreso—; focalizarlo por «quién es más pobre» es predictivo, porque la pobreza basal se realiza con o sin el programa. Muchos sistemas de *targeting* en producción mezclan ambos criterios sin declararlo, y la tabla Tabla 5.1 existe precisamente para forzar esa declaración.

La tabla Tabla 5.1 sistematiza la diferencia entre el régimen predictivo y el régimen causal. Esta distinción estructura todo el curso.

Dimensión	Predicción	Causalidad
Objetivo	Minimizar error fuera de muestra	Estimar $\tau(x)$ con IC válido
Estimando	$E[Y \mid X]$	$E[Y(1) - Y(0) \mid X]$
Métrica de éxito	RMSE, accuracy, AUC	Sesgo, cobertura, RMSE en τ
Datos requeridos	Solo Y, X observados	Requiere $Y(0), Y(1)$ que no se observan simultáneamente
Supuestos clave	IID, estacionariedad	No confusión, soporte común, SUTVA
Regularización	Bienvenida (mejora generalización)	Peligrosa (introduce sesgo en τ)
Validación	Cross-validation estándar	Placebos, Qini, comparación con benchmarks

Tabla 5.1: Régimen predictivo vs. régimen causal.

5.2 Teoría, supuestos y garantías

5.2.1 Supuestos

Adoptamos el marco de (Neyman 1923) y (Rubin 1974). Para cada unidad i se definen dos resultados potenciales: $Y_{i(1)}$ si recibe tratamiento y $Y_{i(0)}$ si no lo recibe. La asignación observada es $D_i \in \{0, 1\}$ y el resultado observado obedece la restricción de consistencia $Y_i = D_i Y_{i(1)} + (1 - D_i) Y_{i(0)}$. Las covariables pre-tratamiento $X_i \in R^p$ son un vector de dimensión p, donde en este curso p puede ser grande (decenas o cientos) e incluso crecer con n.

Los supuestos económicos que permiten identificar $\tau(x)$ a partir de datos observacionales son tres.

Supuesto 5.1 ***(No confusión condicional)***

$Y(0), Y(1) \perp\!\!\!\perp D \mid X$.

Supuesto 5.2 ***(Soporte común)***

Existe $\underline{e} > 0$ tal que $\underline{e} < P(D = 1 \mid X = x) < 1 - \underline{e}$ para todo x en el soporte de X.

Supuesto 5.3 ***(SUTVA / No interferencia)***

$Y_{i(d)} = Y_{i(d, d_{-i})}$ para todo d y todo i, donde d_{-i} son los tratamientos de las demás unidades.

Estos supuestos son *económicos*: su validez depende del contexto sustantivo, no de la cantidad de datos. El supuesto de no confusión condicional exige que el investigador observe todas las variables que afectan simultáneamente la asignación al tratamiento y el resultado; el supuesto de soporte común requiere que haya unidades tratadas y no tratadas en cada región del

espacio de covariables; el supuesto de SUTVA / no interferencia prohíbe efectos cruzados entre unidades. La responsabilidad de justificarlos recae en el economista, no en el algoritmo.

5.2.2 Estimador y score

Definición 5.4 ***(Estimandos causales centrales)***

Bajo no interferencia (SUTVA), los estimandos de interés son:

$$\begin{aligned} \text{ATE}: &\quad \theta = E[Y(1) - Y(0)], \\ \text{ATT}: &\quad \theta_{\text{ATT}} = E[Y(1) - Y(0) \mid D = 1], \\ \text{CATE}: &\quad \tau(x) = E[Y(1) - Y(0) \mid X = x], \\ \text{Policy value}: &\quad V(\pi) = E[Y(\pi(X))], \end{aligned} \tag{5.2}$$

donde $\pi : R^p \to \{0, 1\}$ es una regla de asignación de tratamiento.

El curso se centra casi exclusivamente en $\tau(x)$ y $V(\pi)$, porque son los estimandos que el ML permite abordar de manera genuinamente nueva: la heterogeneidad del efecto causal y la optimización de políticas basadas en esa heterogeneidad.

Bajo los supuestos de no confusión condicional–de soporte común, el CATE es identificable como diferencia de dos funciones de regresión condicional:

$$\tau(x) = \mu_1(x) - \mu_0(x), \quad \mu_{d(x)} = E[Y \mid X = x, D = d]. \tag{5.3}$$

Si estimamos $\hat{\mu}_0$ y $\hat{\mu}_1$ con un método de ML flexible (bosque aleatorio, *gradient boosting*, red neuronal) y calculamos $\hat{\tau}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$, se obtiene el *T-learner* que estudiaremos en el capítulo 12. La pregunta crítica es: ¿bajo qué condiciones $\hat{\tau}(x) \to \tau(x)$ en alta dimensión?

5.2.3 Garantías

El problema es que los algoritmos de ML regularizan para optimizar predicción, no estimación de efectos. Athey (2017) ilustra esto con un ejemplo simple: si X contiene una variable fuertemente correlacionada con D pero sin efecto causal sobre Y, el algoritmo predictivo puede *descartar* D en la regresión de Y (porque X ya explica Y casi igual de bien), generando un $\hat{\mu}_d$ que ignora el efecto del tratamiento. La predicción de Y mejora, pero la estimación de τ se degrada.

Teorema 5.5 ***(Sesgo de regularización en T-learner, versión informal)***

Sea $\hat{\mu}_d$ un estimador de ML con error $\|\hat{\mu}_d - \mu_d\|_{L^2} = O_{p(a_n)}$ donde $a_n \to 0$. Entonces el T--learner $\hat{\tau} = \hat{\mu}_1 - \hat{\mu}_0$ satisface

$$\|\hat{\tau} - \tau\|_{L^2} \leq \|\hat{\mu}_1 - \mu_1\|_{L^2} + \|\hat{\mu}_0 - \mu_0\|_{L^2} = O_{p(a_n)}. \tag{5.4}$$

Sin embargo, la *distribución* asintótica de $\hat{\tau}$ no es $\sqrt{n}$-Gaussiana en general: la regularización introduce un sesgo de orden a_n que puede dominar la varianza $\sqrt{n}$.

La consecuencia operacional es directa: no se pueden construir intervalos de confianza válidos para $\tau(x) \approx \hat{\tau}(x) \pm 1.96\widehat{\text{SE}}(\hat{\tau})$ si el sesgo de regularización domina la varianza. Se requieren

mecanismos adicionales—ortogonalización y *cross-fitting*, que estudiaremos en los capítulos 10 y 11— para recuperar la $\sqrt{n}$-consistencia y la validez de la inferencia.

5.3 Algoritmo e implementación

Pseudocódigo

El método conceptual de este capítulo no requiere pseudocódigo; las implementaciones prácticas se presentan en los siguientes capítulos.

5.3.1 Implementación en Python

Para hacer concreta la distinción entre predicción y causalidad, comparamos dos enfoques sobre el dataset de (Card 1995) sobre retornos a la educación. La pregunta económica es: ¿cuál es el efecto causal de un año adicional de educación sobre el logaritmo del salario? El dataset `close_college` contiene una variable instrumental `nearc4` (proximidad a una universidad de cuatro años) que usaremos solo como referencia, pero el foco aquí es contrastar la respuesta predictiva de un bosque aleatorio con la respuesta causal de una regresión OLS con controles.

```
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestRegressor

import statsmodels.api as sm

# Cargar dataset del repositorio
df = pd.read_csv("../data/datasets/real/public_causaldata/close_college/
data.csv")
# Variables: nearc4 (IV), educ (tratamiento), lwage (resultado), controles
Y = df["lwage"].values
D = df["educ"].values
X = df[["black", "smsa", "south", "married", "exper"]].values

# --- Enfoque predictivo: bosque aleatorio que ignora el rol causal de D ---
rf = RandomForestRegressor(n_estimators=200, random_state=42)
# Entrenamos sobre [D, X] y predecimos Y
DX = np.column_stack([D, X])
rf.fit(DX, Y)
# "Efecto" predictivo: derivada numerica respecto a D
D_plus = D + 1
DX_plus = np.column_stack([D_plus, X])
efecto_pred = (rf.predict(DX_plus) - rf.predict(DX)).mean()
print(f"Efecto predictivo (RF): {efecto_pred:.4f}")

# --- Enfoque causal: OLS con controles (sin IV, solo comparacion) ---
Xc = sm.add_constant(np.column_stack([D, X]))
ols = sm.OLS(Y, Xc).fit(cov_type="HC1")
efecto_ols = ols.params[1]
se_ols = ols.bse[1]
print(f"Efecto OLS (HC1): {efecto_ols:.4f} (SE={se_ols:.4f})")
print(f"IC 95% OLS: [{efecto_ols - 1.96*se_ols:.4f}, {efecto_ols +
1.96*se_ols:.4f}]")
```

Listado 5.1: Comparación predictivo vs. causal sobre datos de Card (1995).

El *output* típico de este ejercicio muestra una divergencia instructiva. El bosque aleatorio reporta un «efecto» predictivo que mezcla la variación causal de la educación con la variación espuria introducida por la correlación entre educación y covariables omitidas. OLS con controles, al imponer una forma funcional lineal y un coeficiente constante, aísla la variación atribuible a la educación pero asume linealidad y homogeneidad. La lección no es que OLS sea superior—ambos son aproximaciones imperfectas— sino que responden a preguntas distintas y producen números distintos. Confiar ciegamente en el *output* del bosque aleatorio como estimación causal sería un error metodológico.

Diagnósticos de nuisance

Los diagnósticos de componentes *nuisance* (propensity score, outcome regression) se desarrollan en detalle en el capítulo 11, donde se presentan las herramientas específicas para evaluar la calidad de los estimadores auxiliares.

5.4 Caso empírico y validación

5.4.1 Datos y preprocesamiento

Card (1995) es un caso paradigmático porque combina un instrumento (`nearc4`) con un set de controles de dimensión moderada. En su análisis original, Card reporta un retorno a la educación de aproximadamente 7.5% usando IV. Estudios posteriores con más controles (Belloni, Chernozhukov y Hansen, 2014) muestran que la selección de controles afecta la estimación en no menos de 1.5 puntos porcentuales.

5.4.2 Estimación principal

En nuestra aplicación con `close_college`, OLS con cinco controles básicos reporta un coeficiente de aproximadamente 0.07 (7%) con error estándar robusto de 0.004. El bosque aleatorio, al no distinguir el rol causal de `educ`, reporta un «efecto predictivo» de aproximadamente 0.04, sustancialmente menor. La diferencia se debe a que el bosque estima una derivada parcial predictiva que no aísla el efecto causal de educ: mezcla variación causal con correlaciones observadas (por ejemplo, exper) y no controla por confusores no observados (por ejemplo, habilidad). Adicionalmente, la regularización puede contraer el efecto estimado de educ si otras covariables predicen bien el salario. Desde el punto de vista predictivo esto es correcto (mejora el RMSE), pero desde el punto de vista causal es un sesgo por variable de confusión no controlada adecuadamente.

Este ejemplo motivará el desarrollo del curso: ¿cómo combinar la flexibilidad del bosque aleatorio para estimar $\mu_{d(x)}$ con la garantía de inferencia válida para τ? La respuesta, que se desarrolla en los capítulos 10–11, es la *ortogonalización de Neyman* combinada con *cross-fitting*.

5.4.3 Validación

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(42)
n = 10000

# Dos variables independientes
A = rng.normal(size=n)
B = rng.normal(size=n)

# C es collider (causa común): A -> C <- B
C = 0.8 * A + 0.8 * B + rng.normal(size=n)

df = pd.DataFrame({"A": A, "B": B, "C": C})

print("Corr(A,B) sin condicionar:", df["A"].corr(df["B"]))
print("Corr(A,B | C alto):",
      df[df["C"] > df["C"].quantile(0.8)]["A"].corr(
      df[df["C"] > df["C"].quantile(0.8)]["B"]))
# NOTA: condicionar en un collider crea una correlacion espuria
```

Listado 5.2: Simulación de sesgo por collider.

El listado ilustra el fenómeno que Elwert et al. (2014) llaman **sesgo de selección endógena**: dos variables marginalmente independientes se vuelven dependientes al condicionar en una causa común de ambas (o en un descendiente suyo). Es el mecanismo inverso al de la confusión —allí condicionar **elimina** una asociación espuria; aquí condicionar la **crea**— y explica por qué «controlar por todo lo disponible» no es una estrategia conservadora sino una fuente activa de sesgo. El 8 formaliza cuándo ocurre cada caso mediante el criterio de puerta trasera; este listado solo pretende dejar la intuición numérica instalada antes de que llegue el aparato gráfico.

El sesgo por condicionamiento en un collider se trata formalmente en (Elwert et al. 2014) (Elwert & Winship 2014).

5.4.4 Interpretación económica

Intuición

Caja de profundización 1.1: Modelos causales estructurales y jerarquía causal

Objetivo. Distinguir tres tipos de preguntas causales: las que solo observan, las que intervienen y las que imaginan escenarios alternativos.

Ejemplo económico. Un gerente de banco quiere saber:

1. ¿Los clientes con más ingresos piden más crédito? (solo observamos)
2. ¿Qué pasa si bajamos la tasa de interés? (intervenimos)

3. ¿Este cliente específico habría pedido crédito si no le hubiéramos subido la tasa? (imaginamos)

Los tres niveles (Pearl).

$$P(Y \mid X = x) \neq P(Y \mid \text{do}(X = x)) \neq P(Y_x \mid X = x', Y = y') \tag{5.5}$$

- **Nivel 1 – Asociación («Ver»):** $P(Y \mid X)$. Ej: «los clientes con más ingresos piden más crédito.»
- **Nivel 2 – Intervención («Hacer»):** $P(Y \mid \text{do}(X))$. Ej: «si bajamos la tasa, ¿cuánto aumenta el crédito?»
- **Nivel 3 – Contrafactual («Imaginar»):** $P(Y_x \mid X = x', Y = y')$. Ej: «Juan no pidió crédito con la tasa alta; ¿lo habría pedido con la tasa baja?»

Importante: El ML predictivo opera en nivel 1. Para política pública (nivel 2) o responsabilidad individual (nivel 3) se necesitan supuestos causales adicionales.

5.5 Riesgos, límites y sensibilidad

5.5.1 Tabla de riesgos

La tabla Tabla 5.2 resume los riesgos principales al confundir predicción con causalidad, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Confundir predicción con causalidad	Política errónea basada en efectos no causales	Comparar el estimando predictivo ($\partial \frac{E[Y \mid X,D]}{\partial} D$) con el causal ($E[Y(1) - Y(0) \mid X]$)	Definir explícitamente $Y(1), Y(0)$ y especificar el estimando causal de interés. Si se entrena un ML sobre (Y, D, X) y se computa la derivada respecto a D, el resultado NO es un efecto causal, sino la derivada parcial de la mejor predicción de Y, que mezcla variación causal con variación espuria
Omitir confusores	Sesgo por variable omitida no corregible con más datos	Construir un DAG y evaluar placebos	Justificar el supuesto de no confusión con teoría económica o usar un diseño alternativo. El supuesto de no confusión condicional no se vuelve verdadero con más observaciones: requiere observar las covariables correctas. Si una variable confusora no está en X, ningún algoritmo la recupera
Interpretar SHAP como causal	Sobreinterpretación de la importancia de variables	Incluir nota explícita de que SHAP es predictivo, no causal	Usar CATE con validación en placebos
Reportar RMSE como evidencia de calidad causal	Falsa confianza en estimaciones sesgadas del efecto causal	Comparar métricas predictivas (RMSE, R^2) con métricas causales (Qini, cobertura de intervalos de confianza)	Validar con placebos, Qini y ground truth sintético. Un modelo puede predecir Y con $R^2 = 0.99$ y producir estimaciones de CATE totalmente sesgadas

Tabla 5.2: Riesgos al confundir predicción con causalidad.

5.5.2 Cuándo no usar este método

Límites del marco. El marco de resultados potenciales supone *no interferencia* (supuesto de SUTVA / no interferencia). En contextos con efectos cruzados—epidemias, redes sociales, externalidades— este supuesto se vulnera y se requieren métodos específicos (inferencia causal

bajo interferencia, diseño *cluster-randomized*). El curso no aborda estos casos; ver (Aronow et al. 2017) para una referencia.

Checklist de validación

Ver el apéndice F para el checklist completo de validación de métodos causales.

5.6 Ejercicios y notas bibliográficas

5.6.1 Ejercicios teóricos

1. Clasifique cada pregunta en asociación, intervención o contrafactual: (a) ¿Los alumnos con mejores notas tienen mejor salario? (b) ¿Sirve dar becas para mejorar notas? (c) ¿María habría entrado a la universidad si le hubieran dado la beca?

5.6.2 Ejercicios computacionales

1. Replique la comparación predictivo vs. causal del listado Listado 5.1 usando `GradientBoostingRegressor` en lugar de `RandomForestRegressor`. ¿La divergencia entre el «efecto predictivo» y el coeficiente OLS aumenta o disminuye? ¿Por qué?
2. Construya un dataset sintético donde el supuesto de no confusión se vulnere deliberadamente (una variable U no observada afecta tanto a D como a Y). Muestre que OLS y bosque aleatorio producen estimaciones sesgadas, y verifique que el sesgo no disminuye al aumentar n.
3. Ejecute el listado Listado 5.2 y explique por qué al condicionar en C apareció una correlación espuria entre A y B.

5.6.3 Ejercicios aplicados

1. Sobre el dataset `close_college`, estime el retorno a la educación con: (a) OLS sin controles, (b) OLS con cinco controles, (c) OLS con la interacción `educ` × `exper`. Compare los tres coeficientes y explique conceptualmente por qué difieren.
2. Sobre el dataset `nsw_mixtape` (Lalonde), calcule la diferencia de medias entre tratados y controles en la variable `re78`. Luego estime el ATE por OLS con los controles `age, educ, black, hisp, marr, nodegree, re74, re75`. ¿En cuánto cambia la estimación? ¿Qué dice esto sobre el balance observacional del dataset?

5.6.4 Notas bibliográficas

Athey (2017) provee la motivación conceptual del campo. Imbens et al. (2015) es la referencia canónica sobre resultados potenciales. Hernán et al. (2020) ofrece una introducción accesible al marco contrafactual. Mullainathan et al. (2017) discute las diferencias prácticas entre predicción y estimación causal en políticas públicas, y Kleinberg et al. (2015) es la referencia obligada para el argumento simétrico —cuándo la pregunta de política es genuinamente predictiva y no causal— desarrollado en la 5.1. Elwert et al. (2014) es el tratamiento de referencia del

sesgo por *collider* simulado en el listado Listado 5.2. Para una revisión técnica moderna, véanse (Athey, Susan, Imbens, et al. 2019) y (Chernozhukov et al. 2018a). Adicionalmente, (Pearl 2009) (disponible en español como *Causalidad*) proporciona una exposición profunda de la jerarquía causal y los modelos estructurales, cubriendo los fundamentos conceptuales que subyacen a la distinción entre los niveles de asociación, intervención y contrafactual discutidos en este capítulo.

Capítulo 6

Regularización, selección de variables y sesgo post-selección

Cuadro sinóptico del capítulo

Problema:	Sesgo post-selección al inferir después de seleccionar variables
Estimando:	θ_0 en regresión de alta dimensión
Identificación:	Sparsity aproximada
Método:	LASSO, Post-LASSO OLS
Nuisance:	Selección de variables
Garantía:	Tasa ℓ_2 bajo *restricted eigenvalue* ((Bickel et al. 2009), Bickel et al. 2009); consistencia de **selección** solo bajo irrepresentabilidad ((Zhao et al. 2006), Zhao & Yu 2006, condición mucho más fuerte)
Librerías:	scikit-learn, statsmodels
Validación:	Monte Carlo, sensibilidad a λ

Nota técnica

El 5 estableció que responder una pregunta causal en alta dimensión requiere seleccionar controles sin sesgar la inferencia. Este capítulo formaliza precisamente ese problema — selección de variables y el sesgo post-selección que induce— y es, junto con el capítulo anterior, el prerrequisito técnico para Double Machine Learning (11, Parte II).

6.1 Problema causal, estimando e identificación

Una economista laboral desea estimar el efecto de un programa de capacitación sobre el salario posterior. Dispone de un panel con 80 variables de control potenciales: características demográficas, historial laboral, sector, región, características del empleador, expectativas subjetivas, y un conjunto de variables administrativas. No sabe cuáles de estas variables son realmente confusoras (correlacionadas con la asignación al programa y con el salario) y cuáles son irrelevantes. La intuición clásica sugeriría incluir todas en la regresión, pero con 80 controles y $n = 1,000$ observaciones, OLS sufre de alta varianza y potencia estadística reducida.

La solución aparentemente natural es seleccionar variables con LASSO y luego correr OLS con las seleccionadas. Esta intuición, sin embargo, es metodológicamente peligrosa: la selección de variables induce un sesgo en la inferencia posterior conocido como *post-selection inference* o *selective inference*. El problema fue formalizado por (Leeb et al. 2006) y (Pötscher et al. 2009), quienes mostraron que los intervalos de confianza construidos después de selección con LASSO pueden tener cobertura dramáticamente inferior a la nominal, incluso con muestras grandes.

Este capítulo desarrolla tres ideas centrales. Primero, presentamos LASSO, Ridge y Elastic Net como métodos de regularización con propiedades estadísticas distintas. Segundo, formalizamos el problema del sesgo post-selección y mostramos por qué la inferencia naïve es inválida. Tercero, anticipamos la solución—Post-Double-Selection de Belloni, Chernozhukov y Hansen (2014), que se desarrolla plenamente en el capítulo 16— como ejemplo paradigmático de cómo el ML puede integrarse con inferencia válida cuando se diseñan procedimientos que respetan la estructura del problema causal.

6.2 Teoría, supuestos y garantías

6.2.1 Supuestos

Para que LASSO sea consistente en alta dimensión, se requiere el supuesto de *sparsity*: solo unas pocas componentes de β son distintas de cero.

Supuesto 6.1 ***(Sparsity aproximada)***

El vector verdadero β_0 tiene a lo más $s \ll n$ componentes no nulas, con $s \log p = o(n)$.

6.2.2 Estimador y score

Consideremos el modelo lineal de alta dimensión $\boldsymbol{Y} = \boldsymbol{X}\beta + \varepsilon$ con $\boldsymbol{X} \in R^{n \times p}$ y $\beta \in R^p$. Cuando p es comparable a n o mayor, OLS tiene alta varianza o no está siquiera definido ($p > n$). Los estimadores penalizados resuelven esto añadiendo una penalización que contrae los coeficientes hacia cero.

Definición 6.2 ***(LASSO)***

El estimador LASSO (Tibshirani 1996) resuelve

$$\hat{\beta}_{\text{LASSO}} = \text{argmin}_{\beta \in R^p} \left\{ \left(\frac{1}{2n} \right) \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}, \tag{6.6}$$

donde $\|\beta\|_1 = \sum_j |\beta_j|$ es la norma ℓ_1 y $\lambda \geq 0$ es el hiperparámetro de penalización.

Definición 6.3 ***(Ridge)***

El estimador Ridge (Hoerl et al. 1970) usa penalización ℓ_2:

$$\hat{\beta}_{\text{Ridge}} = \text{argmin}_{\beta} \left\{ \left(\frac{1}{2n} \right) \|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}. \tag{6.7}$$

Definición 6.4 ***(Elastic Net)***

Elastic Net (Zou et al. 2005) combina ambas penalizaciones:

$$\hat{\beta}_{\text{EN}} = \text{argmin}_{\beta}\left\{\left(\frac{1}{2n}\right)\|Y - X\beta\|_2^2 + \lambda[\alpha\|\beta\|_1 + (1-\alpha)\|\beta\|_2^2]\right\}, \tag{6.8}$$

con $\alpha \in [0,1]$ mezclando las dos penalizaciones.

La diferencia clave es que LASSO produce *selección de variables* (algunos $\hat{\beta}_j = 0$ exactamente), mientras que Ridge solo contrae los coeficientes sin hacer selección. Elastic Net combina ambos comportamientos y es preferible cuando hay grupos de variables altamente correlacionadas.

6.2.3 Garantías

Bajo sparsity y condiciones regulares (designado *restricted eigenvalue condition*, (Bickel et al. 2009)), LASSO satisface:

Teorema 6.5 ***(Tasa de convergencia de LASSO)***

Bajo el supuesto de *sparsity* y *restricted eigenvalue condition* con constante $\kappa > 0$, si $\lambda \asymp \sqrt{\log \frac{p}{n}}$, entonces con probabilidad alta:

$$\left\|\hat{\beta}_{\text{LASSO}} - \beta_0\right\|_1 = O_{p(s\sqrt{\log \frac{p}{n}})}, \quad \left\|\hat{\beta}_{\text{LASSO}} - \beta_0\right\|_2 = O_{p(\sqrt{s \log \frac{p}{n}})}. \tag{6.9}$$

La tasa $\sqrt{s \log \frac{p}{n}}$ es óptima en el sentido minimax. Sin embargo, el teorema garantiza consistencia en norma ℓ_2 — no consistencia componente a componente, y mucho menos consistencia del **conjunto seleccionado**. Esto es crucial: aunque $\hat{\beta}_{\text{LASSO}}$ se acerca a β_0 en norma global, las componentes individuales pueden tener sesgo sustancial, especialmente las que LASSO selecciona incorrectamente.

Recuperar el soporte exige mucho más que recuperar el vector

Conviene separar nítidamente dos garantías que se confunden con frecuencia, porque la diferencia entre ambas es exactamente lo que motiva el resto del capítulo. El teorema de la tasa de convergencia acota el error de **estimación** bajo la *restricted eigenvalue condition* de (Bickel et al. 2009), una condición relativamente débil que solo exige que la matriz de diseño se comporte bien en un cono alrededor del soporte verdadero. Recuperar el **soporte** $S_0 = \{j : \beta_{0,j} \neq 0\}$ —es decir, que $\hat{S} = S_0$ con probabilidad tendiente a uno— requiere una condición estrictamente más fuerte sobre la correlación entre variables dentro y fuera del soporte.

Supuesto 6.6 ***(Condición de irrepresentabilidad)***

Sea X_{S_0} la submatriz de columnas activas y $X_{S_0^c}$ la de las inactivas. Existe $\eta \in (0,1]$ tal que

$$\left\|X_{S_0^c}^T X_{S_0}\left(X_{S_0}^T X_{S_0}\right)^{-1} \text{sign}\left(\beta_{0,S_0}\right)\right\|_\infty \leq 1 - \eta. \tag{6.10}$$

Teorema 6.7 ***(Consistencia de selección del LASSO)***

Bajo la condición de irrepresentabilidad anterior, condiciones de regularidad sobre el ruido y un λ apropiadamente elegido, el LASSO es *sign-consistent*: $P\left(\text{sign}\left(\hat{\beta}_{\text{LASSO}}\right) = \text{sign}(\beta_0)\right) \to 1$. Recíprocamente, si la condición se viola con desigualdad estricta en la dirección opuesta, el LASSO **no** recupera el soporte verdadero con probabilidad tendiente a uno, para ningún valor de λ.

Este resultado, de Zhao et al. (2006), es una mala noticia disfrazada de teorema: la condición de irrepresentabilidad es esencialmente **no verificable** en la práctica (depende de S_0, que es justamente lo desconocido) y falla precisamente en el escenario que más importa para inferencia causal —cuando una variable irrelevante está fuertemente correlacionada con las confusoras verdaderas—. La parte recíproca es la clave: no se trata de que el LASSO necesite más datos, sino de que existen diseños donde ninguna elección de λ recupera el soporte. La lección operativa para el resto del curso es directa: **nunca se debe interpretar el conjunto seleccionado por LASSO como «las variables que verdaderamente importan»**, y ningún procedimiento causal debería depender de que la selección sea exactamente correcta. Post-Double-Selection (16) está diseñado exactamente bajo esa premisa: no necesita $\hat{S} = S_0$, solo necesita que $\hat{S}$ **contenga** las confusoras relevantes con alta probabilidad.

El problema de Leeb & Pötscher

Leeb et al. (2006) demostraron un resultado perturbador: la inferencia post-selección basada en LASSO es fundamentalmente problemática. La intuición es la siguiente. Supongamos que LASSO selecciona un conjunto $\hat{S} \subseteq \{1, ..., p\}$ de variables activas. Si luego corremos OLS sobre $\hat{S}$ y reportamos IC al 95% basados en la distribución t-Student estándar, la cobertura real puede ser dramáticamente inferior.

Teorema 6.8 ***(Leeb & Pötscher, informal)***

Para procedimientos de selección de modelo consistentes, la cobertura de intervalos construidos después de la selección no es uniforme en el parámetro. Para cualquier nivel nominal $1 - \alpha$ y cualquier $\varepsilon > 0$, existen secuencias de parámetros y distribuciones de los datos tales que la cobertura límite del intervalo post-selección es inferior a ε. En particular, la cobertura real puede ser arbitrariamente menor que la nominal.

Intuición

Imagine que el verdadero β_j es positivo pero muy pequeño. LASSO lo selecciona solo si la estimación preliminar de β_j es suficientemente grande. Condicionado a ser seleccionado, $\hat{\beta}_j$ tiende a ser mayor que β_j — un sesgo de selección análogo al sesgo de publicación. El IC post-selección, al no condicionar en este hecho, queda centrado en un valor sesgado.

Dos familias de respuestas a la inferencia post-selección

La literatura posterior a Leeb y Pötscher desarrolló dos estrategias distintas frente a este problema, y conviene situar la del curso dentro de ese mapa antes de continuar.

La primera es la **inferencia selectiva condicional**: aceptar que la selección ocurrió y hacer inferencia sobre la distribución de $\hat{\beta}_j$ **condicionada al evento de selección**. Lee et al. (2016) muestran que, para el LASSO con λ fijo, ese evento de selección es un politopo en el espacio de Y, lo que permite construir intervalos con cobertura exacta condicional mediante una distribución normal truncada. Es una solución elegante, pero condiciona en un evento aleatorio y produce intervalos que pueden ser muy anchos.

La segunda es la **de-biasing** o **desregularización**: corregir explícitamente el sesgo que la penalización introduce en la componente de interés, construyendo un estimador $\hat{\beta}_j^{\text{db}}$ asintóticamente normal y centrado. Zhang et al. (2014) y Geer et al. (2014) desarrollan esta vía, que produce inferencia **no condicional** y uniformemente válida sobre el parámetro de interés.

La segunda familia es la relevante para este curso, y por una razón conceptual, no solo técnica: en un problema causal no interesa hacer inferencia sobre «las variables que el LASSO seleccionó» sino sobre un parámetro estructural fijado **antes** de mirar los datos —el efecto de D sobre Y—. Post-Double-Selection (16) y Double Machine Learning (11) son, ambos, instancias de la lógica de de-biasing: el primero corrige la selección incluyendo dos veces; el segundo, ortogonalizando el score. Ninguno de los dos intenta hacer que el LASSO seleccione bien; ambos construyen procedimientos cuya validez **no depende** de que lo haga.

Soluciones: de la selección ingenua al Post-Double-Selection

Belloni et al. (2014) propusieron una solución elegante al problema del sesgo post-selección en contextos causales. La idea central es *no seleccionar variables una sola vez*, sino *dos veces*: una para predecir Y a partir de X, otra para predecir D a partir de X. Luego se corre OLS de Y sobre D y la unión de las variables seleccionadas en ambos pasos.

Teorema 6.9 ***(Post-Double-Selection LASSO, informal)***

Bajo los supuestos de sparsity aproximada y regularidad estándar, el estimador PDS es asintóticamente normal:

$$\sqrt{n}\left(\hat{\theta}_{\text{PDS}} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V}), \tag{6.11}$$

donde V es la varianza asintótica estándar de OLS con el conjunto de controles verdaderos. La inferencia basada en la distribución t-Student es válida.

La clave del éxito de PDS es la *doble selección*: las variables confusoras son aquellas que predicen tanto Y como D. Seleccionando por separado cada conjunto y tomando la unión, se capturan todas las confusoras relevantes con alta probabilidad, mientras que el sesgo de selección individual se diluye. Desarrollamos este método en detalle en el capítulo 16.

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^n$, hiperparámetro de penalización $\lambda \geq 0$, número de folds K para validación cruzada (opcional).
Salida: Estimador $\hat{\theta}$ y error estándar HC1 $\hat{\sigma}$
Ejecutar LASSO de Y sobre (D, X) con penalización λ.
Identificar el conjunto de variables seleccionadas $\hat{S} = \left\{j : \hat{\beta}_j \neq 0\right\} \cup \{1\}$ (forzar inclusión de D).
Estimar OLS de Y sobre D y las variables en $\hat{S}$.
Calcular errores estándar robustos HC1.
return $\hat{\theta}_{\text{OLS}}, \hat{\sigma}_{\text{HC1}}$

Algoritmo 1.: Post-LASSO OLS (selección ingenua)

6.3 Algoritmo e implementación

6.3.1 Pseudocódigo

El procedimiento Post-LASSO OLS (o *naive* post-selection) se describe a continuación. Este algoritmo refleja la práctica ingenua que induce sesgo post-selección, y sirve como base para contrastar con la corrección introducida por PDS en el capítulo 16.

6.3.2 Implementación en Python

Ilustramos el sesgo post-selección con un dataset sintético donde conocemos el verdadero θ.

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from sklearn.linear_model import LassoCV
from sklearn.utils import check_random_state

def generate_data(n=500, p=100, n_confounders=5, seed=42):
    """DGP: theta=1; las primeras variables son confusoras; el resto ruido."""
    rng = check_random_state(seed)
    X = rng.standard_normal((n, p))

    beta_D = np.zeros(p)
    beta_D[:n_confounders] = 0.5

    gamma_Y = np.zeros(p)
    gamma_Y[:n_confounders] = 0.7

    D = (X @ beta_D + rng.standard_normal(n) > 0).astype(float)
    Y = 1.0 * D + X @ gamma_Y + rng.standard_normal(n)

    return Y, D, X

def post_selection_ate(Y, D, X):
    """Naive: LASSO de Y sobre [D, X], luego OLS HC1 con seleccionados."""
    DX = np.column_stack([D, X])

    lasso = LassoCV(cv=5).fit(DX, Y)
    selected = np.abs(lasso.coef_) > 1e-8

    # Forzar tratamiento en el modelo final
    selected[0] = True

    X_sel = sm.add_constant(DX[:, selected])
    ols = sm.OLS(Y, X_sel).fit(cov_type="HC1")

    # D es la primera variable después de la constante
    theta_hat = ols.params[1]
    se_hat = ols.bse[1]

    return theta_hat, se_hat

# La cobertura debe calcularse con el SE estimado en cada réplica.
# No usar results.std() como si fuera el error estándar del procedimiento.

# Monte Carlo: 1000 repeticiones
np.random.seed(0)

thetas = []
ses = []
covers = []

for b in range(1000):
    Y, D, X = generate_data(n=500, p=100, seed=b)
    theta_hat, se_hat = post_selection_ate(Y, D, X)

    thetas.append(theta_hat)
```

Listado 6.1: Ilustración del sesgo post-selección.

El *output* típico muestra un sesgo de aproximadamente -0.05 a -0.10 y cobertura real de aproximadamente 0.85–0.90, claramente inferior al nominal 0.95. La conclusión práctica: **no se debe reportar IC construidos después de selección LASSO sin corrección**.

6.3.3 Diagnósticos de nuisance

Intuición

Caja de profundización 2.1: Partialling-out y double lasso

Objetivo. Entender dos herramientas clave para limpiar el efecto de las covariables antes de estimar el efecto causal.

Idea intuitiva. Para estimar el efecto de D sobre Y, primero «limpiamos» Y y D de la influencia de X:

$$\tilde{Y} = Y - E[Y \mid X], \quad \tilde{D} = D - E[D \mid X] \tag{6.12}$$

Luego estimamos θ con la regresión de $\tilde{Y}$ sobre $\tilde{D}$ sin intercepto. Esto se llama **partialling-out** (Frisch-Waugh-Lovell).

Double lasso. En alta dimensión, necesitamos seleccionar variables relevantes:

1. LASSO de Y sobre $X \rightarrow$ obtengo S_Y (variables que predicen Y)
2. LASSO de D sobre $X \rightarrow$ obtengo S_D (variables que predicen D)
3. Unión: $S = S_Y \cup S_D$ (variables que predicen cualquiera de los dos)
4. OLS de Y sobre D + controles en S

¿Por qué funciona? Una confusora afecta TANTO a Y COMO a D. Si seleccionamos las que afectan a cada uno, capturamos todas las confusoras relevantes. El «doble» lasso es la base del Post-Double-Selection, desarrollado en el 16.

```
from sklearn.linear_model import LassoCV
import numpy as np

def partialling_out_theta(Y, D, X):
    """Estima theta limpiando Y y D con LASSO."""
    model_y = LassoCV(cv=5).fit(X, Y)
    model_d = LassoCV(cv=5).fit(X, D)

    y_res = Y - model_y.predict(X)
    d_res = D - model_d.predict(X)

    theta = np.mean(d_res * y_res) / np.mean(d_res * d_res)
    return theta
```

Listado 6.2: Partialling-out manual.

6.4 Caso empírico y validación

Belloni et al. (2014) aplicaron PDS al dataset de (Card 1995) sobre retornos a la educación. Encuentran un efecto positivo y significativo del orden de las estimaciones 2SLS clásicas, con diferencias moderadas entre PDS y los estimadores IV con controles seleccionados manualmente; las cifras exactas dependen del set de instrumentos y controles considerados y no se reproducen aquí para evitar imprecisiones.

Réplica propia sobre el dataset del repositorio. Sobre `close_college` ($n = 3,003$), OLS con controles básicos da un coeficiente de 0.071 (HC1, IC 95% [0.064, 0.078]); IV 2SLS con `nearc4` da 0.124 (IC 95% [0.028, 0.221]); DML-PLIV con `GradientBoostingRegressor` da 0.145 (IC 95% [0.052, 0.237]). Estas son cifras de réplica propia, no del *paper* original.

Sobre el dataset `nhefs` del repositorio, que tiene 51 covariables utilizables (tras excluir variables post-tratamiento y de fecha), podemos aplicar el mismo principio. La pregunta causal es: ¿cuál es el efecto de dejar de fumar sobre el cambio de peso? Réplica propia sobre $n = 1,566$ observaciones: OLS con selección manual de 5 controles reporta un coeficiente de 3.20 kg (IC 95% [2.26, 4.14]); PDS con LASSO aplicado a los 51 controles reporta un coeficiente de 3.22 kg (IC 95% [2.29, 4.14]). La diferencia es pequeña en este caso, pero PDS selecciona 18 variables, capturando confusoras adicionales (estado civil, hábitos de alcohol, condiciones médicas) que el análisis manual omitía.

6.5 Riesgos, límites y sensibilidad

6.5.1 Tabla de riesgos

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Inferir después de seleccionar	Cobertura inválida	Monte Carlo	PDS/DML
Interpretar coeficiente LASSO como causal	Sesgo	Regularización	Post-LASSO/DML
λ inestable	Selección frágil	Sensibilidad	Varios λ

6.5.2 Cuándo no usar este método

Límites del enfoque. PDS asume sparsity aproximada: que pocas variables son realmente confusoras. Si la estructura de confusión es densa (muchas variables pequeñas que colectivamente importan), PDS puede ser inconsistente. En tal caso se prefiere DML (capítulo 11), que no requiere sparsity estricta. Adicionalmente, PDS se limita a modelos lineales; para heterogeneidad estructurada en X se requiere GRF (capítulo 13) o meta-learners (capítulo 12).

6.5.3 Checklist de validación

1. **Verificar cobertura empírica:** ejecutar un Monte Carlo bajo el DGP supuesto para confirmar que los IC post-selección alcanzan la cobertura nominal.
2. **Sensibilidad a λ:** reportar resultados para varios valores de λ (e.g., $\lambda \pm 1$ desviación estándar de CV) y verificar que la selección no cambia drásticamente.
3. **Estabilidad de la selección:** usar bootstrap o submuestreo para evaluar qué fracción de las veces cada variable es seleccionada.
4. **Comparar con OLS completo:** si $p < n$, comparar el estimador Post-LASSO con OLS sin selección para evaluar el costo de la regularización.
5. **Reportar ambos:** presentar siempre el estimador de Post-LASSO OLS junto con el de PDS para transparentar el efecto de la doble selección.

6.6 Inferencia post-selección

La construcción de intervalos de confianza válidos tras selección de variables requiere métodos especializados que corrijan el sesgo condicional: (Lee et al. 2016) (Lee et al. 2016) para inferencia exacta post-LASSO, (Zhang et al. 2014) (Zhang & Zhang 2014) para parámetros de baja dimensión en modelos de alta dimensión, y (Geer et al. 2014) (van de Geer et al. 2014) para regiones de confianza asintóticamente óptimas.

En la práctica del curso, el enfoque DML (Cap. 11) evita este problema mediante cross--fitting y scores ortogonales: la selección de variables ocurre en datos auxiliares separados, preservando la validez de la inferencia.

6.7 Ejercicios y notas bibliográficas

1. Replique el experimento Monte Carlo del listado Listado 6.1 variando $p \in \{20, 50, 100, 200\}$. ¿Cómo cambia el sesgo y la cobertura con la dimensionalidad?

   Implemente PDS (selección doble) sobre el mismo DGP sintético. Verifique que el sesgo se reduce sustancialmente y la cobertura se acerca al nominal 0.95. Calcule la cobertura como la fracción de réplicas en que el IC ingenuo post-OLS contiene el verdadero θ, usando el SE estimado en cada réplica.
2. Sobre el dataset `nhefs`, aplique: (a) OLS con 5 controles seleccionados manualmente, (b) LASSO *naive* (una sola selección), (c) PDS. Compare los tres estimadores y sus errores estándar.
3. Demuestre analíticamente que Ridge no hace selección de variables. ¿Por qué Ridge es preferible a LASSO cuando hay grupos de variables altamente correlacionadas?
4. Implemente la función `partialling_out_theta` del listado Listado 6.2 y verifique que recupera el verdadero θ en un DGP lineal. ¿Qué pasa si X contiene variables irrelevantes (ruido puro)?

5. Compare PDS con el partialling-out ingenuo (un solo LASSO de Y sobre $[D, X]$). Muestre que el partialling-out ingenuo tiene sesgo mientras que PDS no, en un Monte Carlo con $p = 100$ y $s = 5$.

Tibshirani (1996) y Hoerl et al. (1970) son las referencias originales. Hastie et al. (2015) ofrece un tratamiento moderno de regularización en alta dimensión. Bickel et al. (2009) establece la tasa ℓ_2 bajo *restricted eigenvalue* y Zhao et al. (2006) la condición de irrepresentabilidad y su recíproca para la consistencia de selección; leer ambos en secuencia es la forma más económica de internalizar por qué «el LASSO funciona» significa cosas muy distintas según qué se pida de él. Leeb et al. (2006) y Pötscher et al. (2009) son las referencias obligatorias sobre el problema de inferencia post-selección; Lee et al. (2016) desarrolla la vía de inferencia selectiva condicional, y Zhang et al. (2014) junto con Geer et al. (2014) la de *de-biasing*, que es la que este curso sigue. Belloni et al. (2014) introduce Post-Double-Selection. Para una revisión pedagógica, (Chernozhukov et al. 2018a).

Capítulo 7

Datos de entrenamiento en sistemas causales

Cuadro de decisión del capítulo

Decisión:	Tratar la asignación del tratamiento como parte del proceso de muestreo a auditar, no como un dato dado
Alternativas:	Usar los datos «tal como llegan» vs. auditar explícitamente el mecanismo de asignación
Trade-off clave:	Velocidad de arranque vs. riesgo de sesgo de selección no detectado
Stack:	pandas, `pandera`, tests de balance
Riesgo principal:	Confundir «faltante al azar» con «faltante por selección relacionada al tratamiento»

7.1 El problema de diseño

Huyen (2022) dedica su Capítulo 4 a una idea que la comunidad de *machine learning* tarda en internalizar: los datos de entrenamiento casi nunca son una muestra aleatoria simple del universo sobre el que luego se aplicará el modelo, y cómo se generaron esos datos —el proceso de muestreo, cómo se etiquetó, qué faltó y por qué— determina la validez de cualquier cosa que se entrene sobre ellos. En un sistema **causal**, este problema no es solo una amenaza a la precisión predictiva: es una amenaza directa a la **identificación**. Si la asignación del tratamiento en los datos históricos está relacionada con variables no observadas, ningún ajuste posterior por covariables observadas —por sofisticado que sea el estimador— corrige el problema. El problema de diseño de este capítulo es, entonces: ¿cómo se estructura el proceso de recolección y muestreo de datos de entrenamiento de forma que las amenazas a la identificación queden documentadas y, cuando sea posible, mitigadas, en lugar de descubrirse después de haber estimado el efecto?

7.2 Opciones y trade-offs

Opciones y trade-offs

- **Usar los datos «tal como llegan».** Se toma el dataset disponible y se procede directamente a la estimación. Es la opción más rápida y, en la práctica, la más común. El riesgo es que el mecanismo de asignación del tratamiento —quién decidió, con qué información, a quién tratar— quede completamente implícito, y que cualquier sesgo de selección relacionado con variables no observadas nunca se detecte porque nadie lo buscó explícitamente.
- **Auditar el mecanismo de asignación antes de estimar.** Se documenta explícitamente, para el dataset en cuestión: ¿la asignación fue aleatorizada, cuasi--aleatorizada (por ejemplo, un umbral administrativo) u observacional pura? ¿Qué información tenía quien decidió asignar el tratamiento, y coincide con las covariables observadas en los datos? Este paso no reemplaza el análisis de identificación de los capítulos anteriores; lo **precede**, y a menudo revela qué covariables son plausiblemente suficientes para el criterio de puerta trasera antes de intentar ajustar ningún modelo.

Un segundo trade-off, heredado de la discusión de Huyen (2022) sobre «etiquetas naturales», es específico de los sistemas causales: en muchos casos, el «tratamiento» es una decisión que ya ocurrió en el pasado dentro de un proceso administrativo o de negocio (a quién se le otorgó un crédito, a quién se le dio un descuento). Estas asignaciones pasadas tienen la ventaja de estar disponibles a bajo costo, pero la desventaja de que la regla de decisión histórica —a menudo no documentada— es exactamente la fuente potencial de confusión que el análisis de identificación debe descubrir.

7.3 Decisión de referencia para el curso

Todo dataset usado en el curso se acompaña de una **ficha de procedencia del tratamiento** (una extensión del `CausalSchema` del Capítulo 4) que documenta, como mínimo: el mecanismo de asignación (aleatorizado / cuasi-experimental / observacional), la unidad temporal de la asignación respecto a la medición del resultado, y cualquier regla de elegibilidad conocida. Para el Notebook de caso de estudio A1 (4), completar esta ficha es un requisito de entrega antes de correr cualquier estimación — es, en efecto, la versión operacional del «problema causal, estimando e identificación» que abre cada capítulo de Plantilla A.

7.4 Implementación de referencia

La herramienta mínima para auditar el mecanismo de asignación es el **chequeo de balance**: comparar la distribución de cada covariable entre tratados y controles. Aquí conviene ser preciso sobre qué estadístico usar, porque la elección por defecto —un t-test por covariable— es la equivocada por dos razones independientes.

Primero, el t-test responde la pregunta incorrecta. Su p-valor mezcla el tamaño de la diferencia con el tamaño de la muestra: con n grande, diferencias irrelevantes resultan «significativas»; con n pequeño, desbalances severos pasan el test. Pero lo que amenaza la identificación es la **magnitud** del desbalance —cuánta extrapolación tendrá que hacer el estimador— y no si esa magnitud es distinguible de cero. El estadístico apropiado es por tanto una medida de tamaño de efecto, la **diferencia media estandarizada** (SMD, también llamada *standardized bias*):

$$\mathrm{SMD}_j = \frac{\overline{X}_{j,1} - \overline{X}_{j,0}}{\sqrt{\left(s_{j,1}^2 + s_{j,0}^2\right)/2}}, \tag{7.13}$$

que es invariante a n y a las unidades de medida. Rubin (2001) propone dos criterios operativos que se han vuelto convencionales: $|\mathrm{SMD}_j| < 0.25$ (idealmente < 0.1) y una razón de varianzas $s_{j,1}^2 / s_{j,0}^2$ dentro de $[0.5, 2]$. El segundo criterio importa y suele olvidarse: dos grupos pueden tener la misma media y distribuciones tan distintas en dispersión que el soporte común sea escaso en las colas, lo que compromete el supuesto de solapamiento antes que el de no confusión.

Segundo, si aun así se reportan p-valores —y hay una razón legítima para hacerlo cuando la asignación **debería** haber sido aleatoria, como en la submuestra experimental de un RCT —, evaluar p covariables al 5% produce por construcción $\approx 0.05p$ rechazos espurios. Con 40 covariables, esperar dos «desbalances significativos» bajo aleatorización perfecta es lo normal, no una anomalía. Cualquier lectura del chequeo debe corregir por comparaciones múltiples (Holm o Benjamini–Hochberg) o, mejor, apoyarse en la distribución completa de las SMD.

```
import numpy as np
import pandas as pd
from scipy import stats
from scipy.stats import ttest_ind

# Balance check: SMD (Standardized Mean Difference)
def compute_smd(X_T, X_C, col):
    """Calcula SMD para una covariable."""
    mean_diff = X_T[col].mean() - X_C[col].mean()
    pooled_std = np.sqrt((X_T[col].var() + X_C[col].var()) / 2)
    return mean_diff / pooled_std

# Ejemplo de uso con DataFrames X_T (tratados) y X_C (controles)
# X_cols es la lista de nombres de columnas de covariables

# Calcular SMD para cada covariable
smd = {}
for col in X_cols:
    smd[col] = abs(compute_smd(X_T, X_C, col))

smd_max = max(smd.values())
print(f"SMD máximo: {smd_max:.3f}")
print(f"Criterio de Rubin (@imbens2015causal): SMD < 0.25")

# Corrección por múltiples comparaciones (Bonferroni)
p_vals = {col: ttest_ind(X_T[col], X_C[col])[1] for col in X_cols}
alpha_adjusted = 0.05 / len(X_cols)
unbalanced = sum(1 for p in p_vals.values() if p < alpha_adjusted)

print(f"\nVariables desbalanceadas: {unbalanced}/{len(X_cols)}")
print(f"α ajustado (Bonferroni): {alpha_adjusted:.4f}")

if smd_max > 0.25:
    print("⚠ Desbalance sustancial detectado")
```

Listado 7.1: Chequeo de balance con SMD, razón de varianzas y corrección por comparaciones múltiples.

Un número alto de covariables desbalanceadas no invalida por sí solo el análisis observacional —es, de hecho, la situación esperada cuando la asignación no fue aleatoria— y, sobre todo, **no es el chequeo el que identifica el efecto**: el balance en las covariables observadas no dice nada sobre las no observadas, que son las que rompen la no confusión. Lo que el chequeo aporta es más modesto y más útil: cuantifica cuánta corrección tendrá que hacer el estimador, y por tanto cuánto de la estimación final descansará en extrapolación del modelo en vez de en comparaciones respaldadas por datos. Un SMD de 1.5 en una covariable relevante advierte que el estimador estará comparando poblaciones con poco solapamiento efectivo, mucho antes de que un diagnóstico de *propensity score* lo revele en el 11.

Dos lecturas específicas del reporte merecen atención. Si covariables que **deberían** ser irrelevantes para la asignación (por ejemplo, una característica administrativa sin relación aparente con el criterio de elegibilidad) resultan fuertemente desbalanceadas, es señal de que el mecanismo de asignación real difiere del documentado, y amerita revisar el DAG propuesto antes de proceder. Y si el porcentaje de faltantes difiere sistemáticamente entre tratados y controles, el problema ya no es de balance sino de **missingness** no aleatorio en el sentido de Rubin (1976): ningún ajuste por covariables observadas corrige una selección que opera sobre quién aparece en los datos.

7.5 Aplicación al sistema causal del curso

El Notebook A1 usa el dataset de Lalonde/NSW precisamente porque permite ilustrar este capítulo de forma directa. LaLonde (1986) comparó las estimaciones de métodos econométricos observacionales contra el *benchmark* experimental del programa NSW y encontró que diferían sustancialmente —el resultado que fundó la literatura moderna de evaluación de programas —; Dehejia et al. (1999) reexaminaron el mismo caso construyendo la extensión observacional (submuestras de CPS/PSID como controles) que sigue siendo el banco de pruebas estándar del campo.

Su utilidad pedagógica aquí es que ofrece los dos regímenes con el mismo tratamiento y el mismo resultado: la submuestra experimental tiene asignación aleatorizada por diseño (el chequeo de balance debería mostrar SMD pequeñas en todas las covariables), mientras que la extensión observacional no la tiene (el mismo chequeo debería mostrar SMD grandes, en varias covariables muy por encima de 0.25, y razones de varianzas fuera del rango de Rubin). Ejecutar el listado Listado 7.1 sobre ambas versiones y comparar las dos distribuciones de SMD es la forma más directa de ver, en números y no en abstracto, qué significa que un dataset sea o no «como aleatorizado».

7.6 Señales de alerta y checklist operativo

- ☐ Nadie en el equipo puede explicar, en una oración, cómo se decidió históricamente quién recibía el tratamiento.
  ☐ No se ejecutó ningún chequeo de balance de covariables antes de estimar el efecto.
  ☐ Existen valores faltantes en el resultado Y que están sistemáticamente relacionados con el tratamiento (posible sesgo de selección en el seguimiento, no solo en la asignación).
  ☐ La ficha de procedencia del tratamiento no distingue si la asignación fue anterior o posterior a la medición de alguna covariable «de control».

7.7 Ejercicios y notas bibliográficas

7.7.1 Ejercicios conceptuales

1. Para el dataset de becas del 1, redacte una ficha de procedencia del tratamiento hipotética, incluyendo el mecanismo de asignación más plausible.
2. Explique por qué un desbalance fuerte en una covariable **administrativa, sin relación aparente con el criterio de elegibilidad** es una señal de alerta más seria que un desbalance en una covariable directamente relacionada con dicho criterio.

7.7.2 Ejercicio computacional

1. Aplique el listado Listado 7.1 a las dos versiones del dataset de Lalonde (experimental y observacional). Reporte, para cada una, la distribución de SMD y cuántas covariables violan cada criterio de Rubin, y relacione el resultado con el mecanismo de asignación de cada submuestra.
2. Sobre la submuestra **experimental** (donde la asignación fue aleatoria por diseño), compare cuántas covariables resultan «significativas» con p crudo al 5% frente a cuántas lo son con la corrección de Holm. Explique por qué el primer número no es evidencia de que la aleatorización haya fallado.

7.7.3 Notas bibliográficas

Huyen (2022), Capítulo 4, desarrolla en detalle el rol del muestreo y las «etiquetas naturales» en sistemas de ML generales. La lógica del chequeo de balance como diagnóstico de identificación es estándar en la literatura de evaluación de programas: Imbens et al. (2015) ofrece su tratamiento formal completo, y Rubin (2001) es la fuente de los criterios operativos (SMD y razón de varianzas) adoptados en el listado Listado 7.1, en el contexto de diseño de estudios observacionales sin mirar el resultado. Rosenbaum et al. (1983) es la referencia fundacional del *propensity score*, que el 11 usará como componente *nuisance* y que ofrece la versión resumida de este mismo diagnóstico en una sola dimensión. LaLonde (1986) y Dehejia et al. (1999) son las referencias del caso NSW usado en el Notebook A1. Sobre datos faltantes y la distinción MCAR/MAR/MNAR que subyace al diagnóstico de faltantes diferenciales, la referencia canónica es Rubin (1976).

Capítulo 8

Razonamiento intervencional y contrafactual

Cuadro sinóptico del capítulo

Problema:	Decidir, a partir de un grafo causal, qué controles identifican el efecto y cuáles lo sesgan
Estimando:	$P(y \mid \mathrm{do}(x))$ y $P(y_x \mid e)$
Identificación:	Criterio de puerta trasera (*backdoor*); las tres reglas del cálculo-do; puerta delantera (*front-door*)
Método:	Ajuste por puerta trasera; abducción-acción-predicción para contrafactuales
Garantía:	Si el criterio de puerta trasera se satisface, $P(y \mid \mathrm{do}(x)) = \sum_z P(y \mid x, z)P(z)$. El cálculo-do es completo: si sus reglas no identifican el efecto, ningún método lo hace con ese grafo
Librerías:	`dowhy`, `networkx`
Validación:	Verificación algorítmica del criterio sobre el DAG propuesto

8.1 Problema causal, estimando e identificación

El 3 dejó pendiente una pregunta operativa: dado un grafo causal y un conjunto de variables observadas, ¿cómo se determina **qué controles incluir** para que un ajuste estadístico —una regresión, un *matching*, un DML— recupere efectivamente $P(y \mid \mathrm{do}(x))$ en lugar de $P(y \mid x)$? La intuición de «controlar por todo lo que se pueda medir» es, como se muestra en este capítulo, no solo insuficiente sino activamente peligrosa: hay variables que, controladas, **introducen** sesgo donde no lo había. Este capítulo formaliza el criterio que resuelve esta pregunta —el criterio de puerta trasera— y extiende el procedimiento de cómputo contrafactual adelantado en el capítulo anterior.

8.2 Teoría, supuestos y garantías

8.2.1 El criterio de puerta trasera

Definición 8.1 ***(Criterio de puerta trasera)***

Un conjunto de variables Z satisface el **criterio de puerta trasera** relativo a un par ordenado (X, Y) en un grafo G si: **(i)** ningún nodo de Z es descendiente de X, y **(ii)** Z bloquea todo camino entre X e Y que contenga una flecha **hacia** X (un «camino de puerta trasera»).

Teorema 8.2 ***(Fórmula de ajuste de puerta trasera)***

Si Z satisface el criterio de puerta trasera relativo a (X, Y), entonces el efecto causal de X sobre Y es identificable y está dado por la **fórmula de ajuste**:

$$P(y \mid \mathrm{do}(x)) = \sum_{z} P(y \mid x, z)\, P(z) \tag{8.14}$$

Demostración (esquema). La condición **(i)** garantiza que condicionar en Z no bloquea el efecto de X sobre Y a través de la ruta causal directa (no se controla por un mediador). La condición **(ii)** garantiza que Z bloquea toda ruta espuria —toda confusión— entre X e Y. Bajo ambas, condicionar en Z dentro de cada estrato hace que X esté «como aleatorizado», y promediar sobre la distribución de Z recupera la distribución interventiva poblacional. □

El supuesto de «no confusión condicional» (*unconfoundedness*) que se ha usado sin más formalidad en los capítulos anteriores —y que sustenta a DML, a los meta-learners y a los bosques causales de la Parte II— es, exactamente, la afirmación de que las covariables observadas X satisfacen el criterio de puerta trasera relativo al tratamiento y al resultado. Este capítulo no cambia ningún método de estimación posterior; cambia **cómo se justifica**, con un grafo explícito, la elección de qué controlar.

8.2.2 Buenos y malos controles

El criterio de puerta trasera implica una clasificación de variables candidatas a control que conviene memorizar, porque el error de incluir un mal control es, en la práctica aplicada, más frecuente que el de omitir un confusor:

Tipo de variable	Rol en el grafo	¿Controlar?
Confusor	Causa común de X e Y (afecta a ambos)	**Sí** — necesario para puerta trasera
Mediador	Está en la ruta causal $X \to M \to Y$	**No** — bloquea parte del efecto que se quiere medir
Collider	Es afectado tanto por X como por Y (o por sus causas)	**No** — condicionar en él **crea** una asociación espuria (ver 1.2)

Tipo de variable	Rol en el grafo	¿Controlar?
Instrumento	Afecta a Y solo a través de X, no comparte causa con Y	**No** como control directo — se usa de otro modo (Parte III, DML-IV)
Variable post-tratamiento	Medida después de X, potencialmente afectada por él	**No** — riesgo de ser mediador o collider sin que el analista lo note

La fila de mediadores explica formalmente algo que ya se mencionó en el 4 sin desarrollar: por qué una variable «post-tratamiento» es peligrosa como control, incluso si parece un predictor razonable de Y — con probabilidad no trivial es un mediador (controla por parte del efecto que se busca medir) o un collider (introduce sesgo de selección). La fila de colliders es la que más sorprende a quien viene de *machine learning* predictivo, porque contradice el reflejo de «controlar por todo»: Elwert et al. (2014) documentan cómo este **sesgo de selección endógena** aparece de forma encubierta en la práctica aplicada, no solo al añadir un control explícito, sino cada vez que la muestra misma se define condicionando en una variable afectada por el tratamiento (restringir el análisis a quienes completaron el programa, a quienes siguen siendo clientes, a quienes respondieron la encuesta de seguimiento).

El tratamiento formal del sesgo por collider y su rol en selección de controles se desarrolla en (Elwert et al. 2014) (Elwert & Winship 2014).

8.2.3 Las tres reglas del cálculo-do

Este capítulo formaliza el criterio de puerta trasera con su prueba completa. Las tres reglas del cálculo-do (**do-calculus**, (Pearl 2009), Pearl 2009) proporcionan un sistema completo para determinar identificabilidad causal en grafos arbitrarios; su automatización se implementa en `dowhy` ((Sharma et al. 2020)).

El criterio de puerta trasera resuelve el caso más frecuente, pero no es la herramienta general. Hay grafos donde ningún conjunto observado satisface el criterio y, sin embargo, el efecto **sí** es identificable por otra vía. La herramienta completa es el **cálculo-do**: tres reglas de reescritura que permiten transformar una expresión que contiene el operador do() en otra equivalente, con el objetivo de eliminar todos los do y quedar con una fórmula puramente observacional —es decir, estimable con los datos.

La notación requiere dos operaciones de «cirugía» sobre el grafo G. Escribimos $G_{\overline{X}}$ para el grafo que resulta de **borrar todas las flechas que entran** a los nodos de X (el grafo bajo la intervención do(x), donde X deja de responder a sus causas) y $G_{\underline{Z}}$ para el que resulta de **borrar todas las flechas que salen** de los nodos de Z. Ambas operaciones pueden combinarse. La relación $(A \perp\!\!\!\perp B \mid C)_G$ denota d-separación de A y B dado C en el grafo G.

Teorema 8.3 ***(Cálculo-do)***

Sea G el grafo causal de un SCM y sean X, Y, Z, W conjuntos disjuntos de nodos. Las tres igualdades siguientes son válidas siempre que se cumpla la condición gráfica indicada a la derecha.

Regla 1 (inserción/eliminación de observaciones). Permite descartar una variable observada que es irrelevante bajo la intervención:

$$P(y \mid \mathrm{do}(x), z, w) = P(y \mid \mathrm{do}(x), w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}}}. \tag{8.15}$$

Regla 2 (intercambio de acción por observación). Permite reemplazar un do por un condicionamiento ordinario —el paso que convierte una cantidad no estimable en una estimable:

$$P(y \mid \mathrm{do}(x), \mathrm{do}(z), w) = P(y \mid \mathrm{do}(x), z, w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}\underline{Z}}}. \tag{8.16}$$

Regla 3 (inserción/eliminación de acciones). Permite descartar una intervención que no afecta al resultado:

$$P(y \mid \mathrm{do}(x), \mathrm{do}(z), w) = P(y \mid \mathrm{do}(x), w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}\overline{Z(W)}}}, \tag{8.17}$$

donde $Z(W)$ es el subconjunto de nodos de Z que no son ancestros de ningún nodo de W en $G_{\overline{X}}$.

Las tres reglas son **válidas** (todo lo que derivan es correcto) y, además, **completas**: si un efecto es identificable a partir del grafo y de la distribución observacional, existe una secuencia finita de aplicaciones de estas tres reglas que produce su fórmula; y si no existe tal secuencia, el efecto no es identificable —ningún método, por sofisticado que sea, puede recuperarlo con esos datos y ese grafo—. Esta completitud es lo que convierte al cálculo-do en un procedimiento de decisión y no solo en un conjunto de trucos: `dowhy` lo implementa internamente en `identify_effect()`, de modo que cuando la librería responde que un efecto no es identificable, esa respuesta es una afirmación matemática y no una limitación del software.

La fórmula de ajuste de puerta trasera es, desde este punto de vista, un corolario. Si Z satisface el criterio, la Regla 2 justifica el paso central —reemplazar $P(y \mid \mathrm{do}(x), z)$ por $P(y \mid x, z)$, legítimo porque condicionar en Z bloquea todas las rutas de puerta trasera y deja por tanto a Y y X d-separados en $G_{\underline{X}}$— y la Regla 3 justifica que $P(z \mid \mathrm{do}(x)) = P(z)$, porque ningún nodo de Z es descendiente de X. Sumando sobre z se obtiene $P(y \mid \mathrm{do}(x)) = \sum_z P(y \mid x, z)P(z)$.

8.2.4 Cuando la puerta trasera falla: el criterio de puerta delantera

El valor práctico del cálculo-do se aprecia mejor en un caso donde la puerta trasera **no** sirve. Suponga el grafo $X \to M \to Y$ con un confusor no observado U que afecta a X y a Y pero no a M salvo a través de X. No existe ningún conjunto observado que bloquee la ruta $X \leftarrow U \to Y$ —U no se observa— y, por tanto, ningún ajuste por covariables identifica el efecto. Sin embargo, el mediador M ofrece una vía alternativa: el efecto de X sobre M es identificable

(no hay confusión entre ellos), el efecto de M sobre Y es identificable ajustando por X (que bloquea la ruta $M \leftarrow X \leftarrow U \rightarrow Y$), y encadenando ambos se recupera el efecto total:

$$P(y \mid \mathrm{do}(x)) = \sum_{m} P(m \mid x) \sum_{x'} P(y \mid m, x') P(x'). \tag{8.18}$$

Esta es la **fórmula de puerta delantera** (*front-door*), derivable por aplicación sucesiva de las tres reglas. El punto conceptual, y la razón de incluirla en un curso orientado a la práctica, es doble. Primero: la identificación no se reduce a «encontrar los controles correctos»; el conocimiento sobre **mecanismos** —saber que todo el efecto de X sobre Y pasa por M— es una fuente de identificación tan legítima como el conocimiento sobre confusores, y a veces la única disponible. Segundo, y como advertencia: el supuesto de que **ninguna** ruta directa $X \rightarrow Y$ escapa a M es fuerte y raramente defendible en datos económicos, razón por la cual la puerta trasera, y no la delantera, sigue siendo el caballo de batalla de los métodos de la Parte II.

8.2.5 Cómputo contrafactual: abducción, acción, predicción

El 3 adelantó el procedimiento de tres pasos para responder preguntas de $\mathcal{L}_3$. Formalizado: dado un SCM M y evidencia observada e sobre una unidad específica, calcular $P(y_x \mid e)$ requiere:

1. **Abducción**: actualizar $P(u)$ a $P(u \mid e)$ — inferir, a partir de lo observado, qué configuración de variables exógenas es consistente con la evidencia.
2. **Acción**: construir el modelo modificado M_x, reemplazando la ecuación de X por la constante x (idéntico al paso interventivo del capítulo anterior).
3. **Predicción**: calcular Y en M_x usando la distribución actualizada $P(u \mid e)$ del paso de abducción, en lugar de la $P(u)$ original.

La diferencia crucial con el cómputo interventivo puro es el paso de abducción: una pregunta contrafactual siempre está condicionada por lo que efectivamente se observó de esa unidad específica, mientras que una pregunta interventiva pura pregunta por el efecto promedio poblacional sin condicionar en ninguna observación particular.

8.3 Algoritmo e implementación

```
import networkx as nx

# Grafo: educ (X) -> wage (Y); ability (confusor) -> educ, wage;
# test_score (mediador) : educ -> test_score -> wage
G = nx.DiGraph([
    ("ability", "educ"), ("ability", "wage"),
    ("educ", "wage"),
    ("educ", "test_score"), ("test_score", "wage"),
])

def satisface_puerta_trasera(G, X, Y, Z):
    G_sin_salientes_X = G.copy()
    G_sin_salientes_X.remove_edges_from(list(G.out_edges(X)))
    # (i) ningun nodo de Z es descendiente de X
    descendientes_X = nx.descendants(G, X)
    if any(z in descendientes_X for z in Z):
        return False, "Z contiene un descendiente de X (posible mediador)"
    # (ii) Z separa X de Y en el grafo sin las aristas salientes de X
    bloqueado = not nx.has_path(G_sin_salientes_X.to_undirected(), X, Y) or \
                nx.is_d_separator(G_sin_salientes_X, {X}, {Y}, set(Z))
    if not bloqueado:
        return False, "Z no bloquea todos los caminos de puerta trasera"
    return True, "Z satisface el criterio de puerta trasera"

print(satisface_puerta_trasera(G, "educ", "wage", {"ability"}))
print(satisface_puerta_trasera(G, "educ", "wage", {"ability", "test_score"}))
# El segundo caso debe fallar: test_score es un mediador (descendiente de X)
```

Listado 8.1: Verificación del criterio de puerta trasera con `networkx`.

En la práctica, `dowhy` automatiza esta verificación y además identifica automáticamente conjuntos de puerta trasera válidos dado un grafo declarado por el usuario, con la función `identify_effect()`; el Apéndice B documenta su uso completo. Esa misma función busca, además, estimandos por puerta delantera (8.2.4) y por variable instrumental cuando la puerta trasera falla, aplicando internamente el cálculo-do — de modo que su salida «no identificable» debe leerse con el peso que le da la completitud del cálculo: no es que la librería no sepa cómo, es que con ese grafo y esos datos no se puede.

8.4 Caso empírico

Retomando el dataset de retornos a la educación: si el analista incluyera `test_score` (una prueba de habilidad tomada **después** de completar los años de educación reportados) como control en la regresión de `wage` sobre `educ`, estaría, según la clasificación de la 8.2.2, controlando por un mediador parcial —parte del efecto de la educación sobre el salario opera precisamente a través de habilidades que la prueba mide—, sesgando el coeficiente de `educ` hacia abajo.

El listado Listado 8.1 verifica exactamente esto: el conjunto `{ability, test_score}` falla el criterio de puerta trasera, mientras que `{ability}` solo lo satisface.

8.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **«Más controles siempre es más seguro».** Es falso en general: agregar un mediador o un collider puede introducir sesgo donde una especificación más parca no lo tenía. El criterio de puerta trasera formaliza exactamente cuándo agregar un control ayuda y cuándo perjudica.
- **Confundir un instrumento con un confusor.** Un instrumento válido no debe controlarse directamente como si fuera una covariable de puerta trasera; su rol es distinto y se explota con métodos específicos (DML-IV, Parte III). Incluirlo como control puede, dependiendo del grafo, introducir sesgo de collider si comparte una causa no observada con Y.
- **El grafo es siempre una hipótesis.** Todo lo desarrollado en este capítulo presupone que el grafo declarado es correcto. Ningún algoritmo puede generar el grafo desde los datos solos sin supuestos adicionales (el 29, más adelante en el curso, aborda qué tan lejos se puede llegar con descubrimiento automatizado, y sus límites).

8.6 Ejercicios y notas bibliográficas

8.6.1 Ejercicios teóricos

1. Para el grafo del listado Listado 8.1, agregue una variable `neighborhood` que sea causa común de `ability` y de `wage` (pero no de `educ`). ¿Sigue `{ability}` satisfaciendo el criterio de puerta trasera? Justifique con el grafo modificado.
2. Explique, en el lenguaje de este capítulo, por qué condicionar en un collider crea una correlación espuria (retome el ejemplo del tamaño del pie y la capacidad de lectura del 1, agregando explícitamente un collider).
3. Aplique el procedimiento de abducción-acción-predicción a un ejemplo numérico simple: un SCM lineal $Y = 2X + U$, $X = U + \varepsilon$, con $U \sim N(0, 1)$. Dado que se observó $X = 1, Y = 3$, calcule $P\left(Y_{\{X=2\}}\right)$, el valor contrafactual de Y si X hubiera sido 2.
4. Derive la fórmula de ajuste de puerta trasera a partir de las tres reglas del cálculo-do de la 8.2.3, indicando explícitamente qué regla justifica cada paso y qué condición de d -separación se invoca en cada caso.
5. Para el grafo de puerta delantera de la 8.2.4 ($X \to M \to Y$ con U no observado afectando a X e Y), añada una flecha directa $X \to Y$. Explique por qué la fórmula de puerta delantera deja de ser válida y qué supuesto sustantivo se estaría violando.

8.6.2 Ejercicios computacionales

1. Instale `dowhy` (Apéndice B) y reproduzca la verificación del listado Listado 8.1 usando `identify_effect()` en lugar de la función manual. Compare el conjunto de ajuste que identifica automáticamente con el usado en el capítulo.

8.6.3 Notas bibliográficas

El criterio de puerta trasera, las tres reglas del cálculo-do, su completitud y la fórmula de puerta delantera se presentan en (Pearl 2009), Capítulo 3, que es la referencia canónica para todo el aparato de identificación gráfica de este capítulo; la clasificación de buenos y malos controles sigue la sistematización de (Bareinboim 2025). Elwert et al. (2014) es el tratamiento de referencia del sesgo por *collider* y de sus formas encubiertas (selección muestral, atrición, condicionamiento en supervivencia), y es la lectura más útil para quien deba auditar un pipeline de datos ya construido. Para una implementación aplicada con Python, Sharma et al. (2020) documenta `dowhy`, la referencia de facto, cubierta en el Apéndice B de este curso.

Capítulo 9

Ingeniería de *features* sin fuga causal

Cuadro de decisión del capítulo

Decisión:	Auditar cada *feature* candidata contra el grafo causal antes de incluirla, no solo contra su poder predictivo
Alternativas:	Selección de *features* por importancia predictiva vs. selección por rol causal
Trade-off clave:	Una *feature* que mejora el ajuste predictivo puede empeorar la estimación causal
Stack:	pandas, el `CausalSchema` del 4
Riesgo principal:	*Fuga* (*leakage*) de información post-tratamiento disfrazada de covariable

Implementación en el monorepo del curso (2026)

Lab `L08` planta fugas deliberadas (outcome, tratamiento, interacciones) y las detecta antes de estimar. La Serie A2 (DML) y el escenario `ihdp_medium` asumen covariables solo pre-tratamiento. No usar columnas de ground truth (`y0`, `y1`, `tau`) fuera de celdas de evaluación. Rutas: `05_labs_sesion/L08_leakage_ihdp/` y notebook A2 en `03_notebooks_caso_estudio/notebooks/`.

9.1 El problema de diseño

La ingeniería de *features* estándar —la de (Huyen 2022) Capítulo 5— evalúa una *feature* candidata por un solo criterio: ¿mejora el desempeño predictivo del modelo fuera de muestra? Bajo ese criterio, cualquier variable disponible en el momento de entrenar que esté correlacionada con Y es, en principio, bienvenida. El 8 mostró por qué ese criterio es **insuficiente y a veces contraproducente** para un sistema causal: una *feature* puede reducir el error de predicción y, al mismo tiempo, ser un mediador o un collider que sesga la estimación del efecto. El problema de diseño de este capítulo es construir un proceso de ingeniería de *features* que audite cada variable candidata contra su **rol en el grafo causal**, no solo contra su poder

predictivo — la versión operacional, en el pipeline de *features*, de la clasificación de controles del capítulo anterior.

9.2 Opciones y trade-offs

Opciones y trade-offs

- **Selección por importancia predictiva.** Se agregan *features* mientras mejoren una métrica de validación cruzada (RMSE, AUC). Es el flujo de trabajo estándar en *machine learning* aplicado y el más rápido de ejecutar. Su riesgo específico en un contexto causal ya se discutió en el 5: un modelo puede predecir excelente y estimar el efecto causal con sesgo severo, precisamente porque la importancia predictiva no distingue entre variación causal y variación espuria.
- **Selección por rol causal, informada por el grafo.** Cada *feature* candidata se clasifica primero según la 8.2.2 del capítulo anterior (confusor / mediador / collider / post-tratamiento) y solo después se evalúa su aporte predictivo **dentro** de la categoría de controles legítimos. Requiere tener, aunque sea de forma preliminar, un DAG propuesto —lo cual no siempre es cómodo cuando se está en la fase exploratoria de un proyecto— pero previene sistemáticamente la clase de error más costosa de este curso.

9.3 Decisión de referencia para el curso

Todo notebook de estimación del curso extiende el `CausalSchema` del 4 con una etapa de **auditoría de features** obligatoria antes de construir cualquier matriz de covariables X: cada columna candidata se anota con su rol supuesto (confusor / mediador / collider / post-tratamiento / desconocido) y la auditoría produce, no una sino **dos** especificaciones de X:

- X_{base}, con las variables anotadas como **confusor** y medidas antes del tratamiento. Es la especificación sobre la que se reporta la estimación principal.
- $X_{\text{ampliada}} = X_{\text{base}} \cup \{\text{desconocido}\}$, que añade las candidatas cuyo rol el analista no pudo determinar, siempre que sean pre-tratamiento. Es la especificación sobre la que se reporta el **análisis de sensibilidad**.

Las anotadas como mediador, collider o post-tratamiento no entran en ninguna de las dos. La razón de exigir dos especificaciones en lugar de una regla única es que las dos decisiones posibles sobre una variable de rol desconocido tienen riesgos opuestos y no comparables: excluirla arriesga sesgo por confusión omitida; incluirla arriesga sesgo por mal control. Ningún criterio automático resuelve esa disyuntiva, pero reportar ambas estimaciones convierte la duda en información —si el efecto es estable entre X_{base} y X_{ampliada}, la ambigüedad de rol no era material; si no lo es, el capítulo entero de identificación tiene que reabrirse antes de publicar nada.

9.4 Implementación de referencia

```
import pandas as pd

# Roles que NUNCA entran en X: su inclusion sesga la estimacion
# (ver la clasificacion de controles del capitulo anterior).
ROLES_PROHIBIDOS = {"mediador", "collider", "post_tratamiento"}

def auditar_features(df: pd.DataFrame, treatment_time_col: str,
                     feature_time_cols: dict[str, str],
                     roles_declarados: dict[str, str]) -> pd.DataFrame:
    """Marca cada feature con riesgo de fuga temporal (medida despues
    del tratamiento) y con su rol causal declarado por el analista.

    Devuelve dos indicadores de inclusion, no uno:
      - incluir_en_X_base:     especificacion principal (solo confusores)
      - incluir_en_X_ampliada: especificacion de sensibilidad (base + rol
                               desconocido, siempre pre-tratamiento)
    """
    filas = []
    for feature, tiempo_col in feature_time_cols.items():
        posterior = (df[tiempo_col] > df[treatment_time_col]).mean()
        rol = roles_declarados.get(feature, "desconocido")
        pre_tratamiento = posterior == 0.0
        es_confusor = rol == "confusor"
        # "desconocido" NO se excluye de facto: entra en la especificacion
        # ampliada para el analisis de sensibilidad, como exige la decision
        # de referencia del capitulo.
        rol_ambiguo = rol == "desconocido"
        filas.append({
            "feature": feature,
            "pct_medida_despues_del_tratamiento": posterior,
            "riesgo_temporal": not pre_tratamiento,
            "rol_declarado": rol,
            "incluir_en_X_base": es_confusor and pre_tratamiento,
            "incluir_en_X_ampliada": (
                (es_confusor or rol_ambiguo)
                and pre_tratamiento
                and rol not in ROLES_PROHIBIDOS
            ),
        })
    resultado = pd.DataFrame(filas)

    riesgosas = resultado[resultado["riesgo_temporal"]
                          | (resultado["rol_declarado"] == "desconocido")]
    if len(riesgosas) > 0:
        print("ADVERTENCIA: features con riesgo de fuga o sin rol
determinado:")
        print(riesgosas[["feature", "pct_medida_despues_del_tratamiento",
                         "rol_declarado", "incluir_en_X_base",
                         "incluir_en_X_ampliada"]])
    n_amb = (resultado["rol_declarado"] == "desconocido").sum()
    if n_amb:
        print(f"{n_amb} feature(s) de rol ambiguo -> reportar la estimacion "
              "con X_base y con X_ampliada, y comparar.")
    return resultado
```

Listado 9.1: Auditoría de *features* por tiempo y por rol declarado.

La función no decide por el analista cuál de las dos especificaciones es la «correcta» —esa decisión sigue siendo suya, informada por el grafo— pero hace **imposible** que una variable post-tratamiento entre a X en silencio, y hace igualmente imposible que una variable de rol ambiguo desaparezca sin dejar rastro: aparece en la especificación ampliada y obliga a reportar la comparación. Nótese que la condición de fuga temporal se aplica a **ambas** especificaciones: ninguna cantidad de análisis de sensibilidad rescata a una covariable medida después del tratamiento.

9.5 Aplicación al sistema causal del curso

El Notebook de caso de estudio A2 (Módulo 2, Double Machine Learning) exige ejecutar la auditoría del listado Listado 9.1 sobre la matriz de covariables **antes** de estimar el modelo PLR/IRM del 11. Esto conecta directamente con un punto que ese capítulo asume resuelto: la validez de la ortogonalidad de Neyman depende de que X contenga controles legítimos, no mediadores ni colliders disfrazados de covariables predictivas.

9.6 Señales de alerta y checklist operativo

- ☐ Una *feature* mejora sustancialmente el ajuste predictivo del modelo de resultado sin que exista una razón causal clara para incluirla.
  ☐ Ninguna columna del dataset tiene una marca de tiempo que permita verificar si fue medida antes o después del tratamiento.
  ☐ El equipo agregó una *feature* «porque funcionaba mejor en las pruebas» sin volver a evaluar el DAG.
  ☐ Existen *features* derivadas (ingeniería de variables) cuya fórmula de construcción usa, aunque sea indirectamente, el propio resultado Y.

9.7 Ejercicios y notas bibliográficas

9.7.1 Ejercicios conceptuales

1. Para el dataset de retornos a la educación, clasifique las siguientes variables candidatas a `covariates` según la tabla de la 8.2.2: habilidad cognitiva medida antes de ingresar a la escuela; puntaje de un examen de egreso universitario; cercanía geográfica a una universidad; ingreso de los padres.
2. Explique por qué una *feature* construida como «promedio móvil del resultado en las últimas 4 semanas» es casi siempre una fuente de fuga en un sistema causal, incluso si en un sistema puramente predictivo sería una *feature* razonable.

9.7.2 Ejercicio computacional

1. Aplique el listado Listado 9.1 al dataset que eligió para el Notebook A1, declarando roles causales para al menos 6 covariables candidatas, de las cuales al menos una debe

quedar como `desconocido`. Reporte cuántas quedan excluidas de X_{base} y por qué motivo cada una, y compare X_{base} con X_{ampliada}.

2. Estime el efecto con ambas especificaciones (X_{base} y X_{ampliada}) y compare los dos intervalos de confianza. Si se solapan ampliamente, ¿qué concluye sobre la variable de rol ambiguo? ¿Y si no se solapan? Explique por qué, en el segundo caso, **ninguna** de las dos estimaciones es defendible sin resolver antes la pregunta de identificación.

9.7.3 Notas bibliográficas

Huyen (2022), Capítulo 5, cubre la ingeniería de *features* genérica y la fuga de datos (*data leakage*) en su sentido predictivo estándar (por ejemplo, escalar antes de separar train/test); este capítulo extiende esa discusión al tipo de fuga específico de sistemas causales. La clasificación de controles retomada aquí se desarrolla en (Bareinboim 2025) y (Pearl 2009), ya citados en el 8.

Parte III

Estimación causal flexible y primer despliegue

Esta parte desarrolla los estimadores centrales del libro: ortogonalidad de Neyman y cross-fitting, Double Machine Learning, meta-learners, árboles y bosques causales, y validación sin ground truth —ahora extendida con una perspectiva de evaluación offline como proceso de sistema, no solo como chequeo estadístico puntual—. Cierra con el primer despliegue real del curso: el estimador DML servido como servicio con FastAPI y Docker.

Capítulo 10

Ortogonalidad de Neyman, cross-fitting e influence functions

Cuadro sinóptico del capítulo

Problema:	Doble sesgo al estimar θ_0 con ML
Estimando:	θ_0 en PLR
Identificación:	No confusión, ortogonalidad
Método:	Score ortogonal, cross-fitting
Nuisance:	$g_0(X), m_0(X)$
Garantía:	$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \Rightarrow N(0, \mathcal{V})$ bajo $\sqrt{n}a_n^2 \to 0$
Librerías:	`scikit-learn` (implementación manual del score); `DoubleML` y `econml` en el 11
Validación:	Monte Carlo de sesgo y cobertura; comparación con y sin cross-fitting

Nota técnica

Con el criterio de puerta trasera (8) y la auditoría de *features* (9) resueltos, la Parte I dejó pendiente una pregunta puramente estadística: ¿cómo combinar *learners* de ML flexibles para estimar un efecto causal sin que el sesgo de esos *learners* contamine la inferencia? Este capítulo, que abre la Parte II, responde exactamente eso.

10.1 Problema causal, estimando e identificación

Una consultora económica está evaluando el efecto de una reforma tributaria sobre la inversión empresarial. Dispone de un panel de $5,000$ firmas con 200 covariables (características financieras, sectoriales, de propiedad, de gobernanza). La asignación de la reforma no fue aleatoria: las firmas grandes y rentables fueron más propensas a ser tratadas. El estimador ideal debería: (i) usar ML para modelar flexiblemente la relación entre covariables y asignación al tratamiento (*propensity score*), (ii) usar ML para modelar la relación entre covariables e inversión en ausencia de tratamiento (*outcome regression*), (iii) combinar ambas estimaciones para obtener un estimador del efecto causal con inferencia válida.

El problema es que si simplemente «enchufamos» los estimadores de ML en una fórmula causal estándar—por ejemplo, el estimador de doubly-robust $\hat{\theta} = n^{-1} \sum_i \Big[\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + D_i \frac{Y_i - \hat{\mu}_1(X_i)}{\hat{e}}(X_i) - (1 - D_i)\frac{Y_i - \hat{\mu}_0(X_i)}{1 - \hat{e}(X_i)}\Big]$— la inferencia resultante no es válida en general. El motivo es sutil: los errores de estimación de $\hat{\mu}_d$ y $\hat{e}$ *contaminan* la estimación del efecto causal en el primer orden, introduciendo un sesgo que no desaparece con muestras grandes.

Este capítulo formaliza el problema del *doble sesgo* y presenta la solución conceptual central del ML causal moderno: la **ortogonalidad de Neyman**. Mostramos que existe una manera de construir un *score* (función de momento) cuya derivada respecto a los parámetros *nuisance* es cero en el valor verdadero, de modo que los errores de estimación de los *nuisance* solo afectan la inferencia causal en el segundo orden. Esta propiedad, combinada con *cross-fitting* (capítulo 11), permite construir estimadores $\sqrt{n}$-consistentes y asintóticamente normales incluso cuando los *nuisance* se estiman con ML a tasas más lentas que $\sqrt{n}$.

10.2 Teoría, supuestos y garantías

10.2.1 El problema del doble sesgo

Consideremos el modelo parcialmente lineal (PLR, *partial linear model*):

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad D = m_0(X) + v, \tag{10.19}$$

Definimos los residuos Robinson: $v_i = D_i - e_0(X_i)$ y $u_i = Y_i - l_0(X_i)$, con $l_0(X_i) = E[Y \mid X_i]$.

donde Y es el resultado, D es el tratamiento, X son covariables, g_0 es la *outcome regression* y m_0 es la *propensity function* (no necesariamente una probabilidad — puede ser una función continua de X). Suponemos $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$.

Para D binario, $m_0(x) = e_0(x) = P(D = 1 \mid X = x)$; en lo que sigue e_0 denota el propensity score.

El parámetro causal de interés es θ_0, el efecto del tratamiento. La pregunta es cómo estimarlo cuando g_0 y m_0 son funciones desconocidas de alta dimensión.

Enfoque naïve 1: OLS con ML para estimar g_0.

Si g_0 fuera conocido, θ_0 se estimaría por OLS de $Y - g_0(X)$ sobre D. Pero como g_0 se estima, sustituimos g_0 por $\hat{g}$ obtenido con algún algoritmo de ML. El estimador resultante es:

$$\tilde{\theta} = \left(\sum_i D_i^2\right)^{-1} \sum_i D_i(Y_i - \hat{g}(X_i)). \tag{10.20}$$

El problema: $\hat{g}(X_i)$ tiene error $O_{p(a_n)}$ con $a_n \gg n^{-\frac{1}{2}}$ en general (bosques aleatorios tienen $a_n = n^{-\frac{2}{5}}$ típicamente). Este error de primer orden contamina $\tilde{\theta}$:

$$\tilde{\theta} - \theta_0 = \underbrace{\left(\sum D_i^2\right)^{-1} \sum D_i \varepsilon_i}_{\text{ruido } O_p\left(n^{-\frac{1}{2}}\right)} + \underbrace{\left(\sum D_i^2\right)^{-1} \sum D_i (g_0(X_i) - \hat{g}(X_i))}_{\text{sesgo } O_{p(a_n)}}. \tag{10.21}$$

Como $a_n \gg n^{-\frac{1}{2}}$, el sesgo domina la varianza asintótica y la inferencia basada en la distribución normal es inválida.

Enfoque naïve 2: OLS con ML para estimar m_0 (residuos de tratamiento).

Si proyectemos D sobre X con ML: $\hat{v}_i = D_i - \hat{m}(X_i)$, y luego regredimos Y sobre $\hat{v}$:

$$\tilde{\theta}' = \Big(\sum \hat{v}_i^2\Big)^{-1} \sum \hat{v}_i Y_i. \tag{10.22}$$

El mismo problema: el error $\hat{m} - m_0$ contamina $\tilde{\theta}'$ en primer orden.

10.2.2 Ortogonalidad de Neyman

La solución es construir un *score* $\psi(W, \theta, \eta)$, donde $W = (Y, D, X)$ y $\eta = (g, m)$ son los *nuisance parameters*, que satisfaga:

Definición 10.1 ***(Score ortogonal de Neyman)***

Un score $\psi(W, \theta, \eta)$ es *ortogonal de Neyman* respecto a η en (θ_0, η_0) si la derivada de Gateaux respecto a η se anula:

$$\partial_\eta E[\psi(W, \theta_0, \eta)] \,|_{\eta=\eta_0} \, [r] = 0 \quad \text{para toda perturbación} \quad r. \tag{10.23}$$

La propiedad de ortogonalidad implica que pequeñas desviaciones de η respecto a η_0 *no afectan* el valor esperado del score en primer orden. Esto es lo que permite que errores de estimación de $\hat{\eta}$ (que son $O_{p(a_n)}$) solo afecten la estimación de θ en orden a_n^2 o $a_n \cdot n^{-\frac{1}{2}}$, preservando así la $\sqrt{n}$-consistencia.

10.2.3 Construcción del score ortogonal para PLR

Para el modelo Ecuación (10.19), el score ortogonal se construye con un truco algebraico. Primero, observemos que $Y - g_0(X) = \theta_0 D + \varepsilon$ y $D - m_0(X) = v$, con $E[\varepsilon \mid X] = 0$ y $E[v \mid X] = 0$. Por la ley de expectativas iteradas, $E[v\varepsilon] = E[vE[\varepsilon \mid X, D]] = 0$ si $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$.

Multiplicando $Y - g_0(X) - \theta_0 D = \varepsilon$ por $v = D - m_0(X)$ y tomando esperanza:

$$E[(D - m_0(X))(Y - g_0(X) - \theta_0 D)] = E[v\varepsilon] = 0. \tag{10.24}$$

De aquí se despeja θ_0:

$$\theta_0 = \frac{E[(D - m_0(X))(Y - g_0(X))]}{E[(D - m_0(X))D]}. \tag{10.25}$$

Es crucial distinguir dos nuisance posibles.

1. Si se estima la regresión estructural

$$g_0(X) = E[Y - \theta_0 D \mid X], \tag{10.26}$$

No confundir con $\mu_{d(x)} = E[Y \mid X = x, D = d]$ de los 5, 12 y 13. Bajo el PLR, $\mu_{d(x)} = g_0(x) + \theta_0 d$, de modo que $\mu_1(x) - \mu_0(x) = \theta_0$. entonces el score puede escribirse como

$$\psi(D, X, Y, \theta, \eta) = (D - m(X))(Y - g(X) - \theta D). \tag{10.27}$$

2. En la implementación DML estándar, normalmente se estima

$$l_0(X) = E[Y \mid X] = g_0(X) + \theta_0 m_0(X), \tag{10.28}$$

junto con

$$m_0(X) = E[D \mid X]. \tag{10.29}$$

En ese caso, el score ortogonal correcto es el score de Robinson ((Robinson 1988), Robinson 1988):

$$\psi(D, X, Y, \theta, \eta) = (D - m(X))\{Y - l(X) - \theta(D - m(X))\}. \tag{10.30}$$

Robinson (1988) introdujo esta transformación —proyectar tanto Y como D sobre X y regresar residuo contra residuo— para el modelo parcialmente lineal con g_0 estimado no paramétricamente, y demostró que el estimador resultante es $\sqrt{n}$-consistente pese a que las regresiones auxiliares convergen a tasas más lentas. Es el antecedente directo del score PLR de DML: lo que Chernozhukov et al. (2018b) añaden es el **cross-fitting**, que permite reemplazar los estimadores kernel de Robinson por *learners* de ML arbitrarios sin pagar el sesgo de sobreajuste que aparecería al estimar y evaluar en la misma muestra. El mismo score reaparecerá en el 12 como la función de pérdida del R-learner —la «R» es, precisamente, por Robinson.

El Listado Listado 10.1 estima $l_0(X) = E[Y \mid X]$, por lo que debe usar la segunda forma. Usar $(D - m)(Y - l - \theta D)$ cuando $l = E[Y \mid X]$ no preserva la ortogonalidad de Neyman respecto de m.

El score correspondiente es:

$$\psi(W_i, \theta, \eta) = (D - m(X))(Y - g(X) - \theta D). \tag{10.31}$$

Teorema 10.2 ***(Ortogonalidad del score PLR)***

El score Ecuación (10.31) es ortogonal de Neyman respecto a $\eta = (g, m)$ en (θ_0, η_0).

Demostración. La derivada de Gateaux de $E[\psi]$ respecto a $\eta = (g, m)$ en dirección $\left(r_g, r_m\right)$ es

$$\begin{aligned} \partial_\eta E[\psi]\left[r_g, r_m\right] &= \partial_\alpha E\left[(D - (m_0 + \alpha r_m))\left(Y - \left(g_0 + \alpha r_g\right) - \theta_0 D\right)\right] \mid_{\alpha=0} \\ &= -E[r_m \varepsilon] - E\left[v r_g\right] = 0, \end{aligned} \tag{10.32}$$

donde hemos usado que $E[\varepsilon \mid D, X] = 0$ implica $E\left[r_{m(X)}\varepsilon\right] = 0$, y que $E[v \mid X] = 0$ implica $E\left[v r_{g(X)}\right] = 0$. □

Nota técnica

Forma canónica del score ortogonal. Todos los scores que el libro deriva en capítulos distintos son instancias de un único objeto: un funcional $\psi(W, \theta, \eta)$ con $E[\psi(W, \theta_0, \eta_0)] = 0$ y derivada de Gateaux nula respecto a η en (θ_0, η_0) (Def. de la 10.2.2). La tabla reúne las instancias del curso:

Estimando	$\psi(W, \theta, \eta)$	η
PLR / ATE constante (11)	$(D - m(X))(Y - l(X) - \theta(D - m(X)))$	(l, m)
ATE bajo IRM (11)	$\mu(1,X) - \mu(0,X) + \frac{D(Y-\mu(1,X))}{e(X)} - \frac{(1-D)(Y-\mu(0,X))}{1-e(X)} - \theta$	(μ, e)
CATE, DR-learner (12)	Γ_i = score IRM antes de promediar	(μ, e)
CATE, R-learner (12)	$\left[\left(Y - m_{Y(X)}\right) - \tau(X)(D - e(X))\right]^2$	(m_Y, e)
PLIV (17)	$(Z - r(X))(Y - g(X) - \theta D)$	(g, r, m)
Policy value (21)	$\mu_{\pi(X)}(X) + \frac{\mathbf{1}\{D=\pi(X)\}}{e_{\pi(X)}(X)} \cdot \left(Y - \mu_{\pi(X)}(X)\right) - V(\pi)$	(μ, e)

Tabla 10.1: Instancias del score ortogonal canónico a lo largo del curso.

Consecuencia operativa. El *cross-fitting*, la condición de tasa $\sqrt{n} \cdot a_n^2 \to 0$ y el error estándar vía *influence function* (algoritmo de cross-fitting de la 10.3.1) son idénticos en todas las filas de la tabla Tabla 10.1. Cuando el curso presenta un «nuevo» estimador (11, 12, 17, 21), lo que cambia es ψ y el estimando — no el aparato de inferencia. Esta es la perspectiva de funcionales de Riesz que el 27 retoma: el score ortogonal de cada fila es el representador de Riesz de su funcional.

10.2.4 Teorema central de DML

El teorema central de (Chernozhukov et al. 2018b) combina ortogonalidad con *cross-fitting*:

Teorema 10.3 ***(DML — versión simplificada)***

Sea $\hat{\eta}_0$ un estimador de η_0 obtenido en una muestra auxiliar independiente de la muestra principal, con $\|\hat{\eta}_0 - \eta_0\|_{L^2} = O_{p(a_n)}$ para algún $a_n \to 0$ con $\sqrt{n}a_n^2 \to 0$. Sea $\hat{\theta}$ solución de

$$\left(\frac{1}{n}\right) \sum_{i=1}^{n} \psi\left(W_i, \hat{\theta}, \hat{\eta}_0\right) = 0. \tag{10.33}$$

Entonces, bajo regularidad estándar y la condición de ortogonalidad Ecuación (10.23):

$$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \tag{10.34}$$

donde $\sigma^2 = \frac{E\left[\psi(W,\theta_0,\eta_0)^2\right]}{\left(E[\partial_\theta \psi]\right)^2}$.

Demostración (esquema). Sketch de prueba (cross-fitting): El cross-fitting garantiza que los residuos $\tilde{D}_i$ y $\tilde{Y}_i$ sean independientes de los predictores $\hat{m}$ y $\hat{l}$ en la muestra donde se evalúan. Esto elimina el sesgo de overfitting de orden $O_p\left(n^{-\frac{1}{2}}\right)$, permitiendo que la tasa $\sqrt{n} \cdot a_n^2 \to 0$ sea suficiente (en lugar de $n \cdot a_n^2 \to 0$ sin cross-fitting). La prueba formal requiere la expansión del influence function con ortogonalidad de Neyman; ver (Chernozhukov et al. 2018b) §3.2. ■ □

Intuición

La condición $\sqrt{n}a_n^2 \to 0$ es la clave. Para bosques aleatorios, $a_n = n^{-\frac{2}{5}}$, así que $\sqrt{n}a_n^2 = n^{\frac{1}{2}-\frac{4}{5}} = n^{-\frac{3}{10}} \to 0$. Para LASSO bajo sparsity, $a_n = \sqrt{s \log \frac{p}{n}}$, así que $\sqrt{n}a_n^2 = s \log \frac{p}{\sqrt{n}} \to 0$ si $s \log p = o(\sqrt{n})$. La magia de la ortogonalidad es que *no necesitamos* estimar η a tasa $\sqrt{n}$ — basta una tasa más lenta pero con $a_n^2 = o\left(n^{-\frac{1}{2}}\right)$.

Nota técnica

Condiciones completas y variante DML2. El Teorema central de DML enunciado arriba está deliberadamente simplificado. Las condiciones completas ((Chernozhukov et al. 2018b), Teorema 3.1) son:

1. (C1) **Ortogonalidad de Neyman** del score (Def. de la 10.2.2).
2. (C2) **Identificabilidad local:** $|E[\partial_\theta \psi(W, \theta, \eta_0)]| \geq c > 0$ en una vecindad de θ_0.
3. (C3) **Tasas de nuisance:** $\|\hat{\eta} - \eta_0\|^2 = o_{p\left(n^{-\frac{1}{2}}\right)}$, equivalentemente $\sqrt{n} \cdot a_n^2 \to 0$.
4. (C4) **Momentos acotados:** $E[\psi^2] < \infty$ y $E\left[|\partial_\theta \psi|^2\right]$ acotado en una vecindad de θ_0.

Dos decisiones de implementación que la literatura distingue y el curso debe nombrar. Sea $\hat{\theta}_k$ la solución del score restringida al *fold* k:

- **DML1** reporta la mediana de $\left\{\hat{\theta}_k\right\}$; **DML2** reporta el estimador del momento promediado sobre toda la muestra (equivalente al promedio ponderado por tamaño de *fold*). La recomendación de (Chernozhukov et al. 2018b) (§6) es **DML2**, con **repeated cross-fitting**: repetir la partición K-fold R veces ($R = 5$–10) y promediar, reduciendo la varianza inducida por la partición aleatoria. La Figura Figura 11.1 —varianza creciente a K bajo— es la manifestación empírica de ese término de varianza; el *repeated cross-fitting* es su mitigación formal, no solo empírica.

Nota técnica

La expansión de influence function permite escribir

$$\hat{\theta} - \theta_0 = \left(\frac{1}{n}\right) \sum_i \psi(W_i, \theta_0, \eta_0) + O_{p\left(n^{-\frac{1}{2}}\right)}. \tag{10.35}$$

10.3 Algoritmo e implementación

10.3.1 El rol del cross-fitting

El teorema central de DML asume que $\hat{\eta}$ se estima en una muestra *independiente* de la muestra principal. En la práctica, no queremos desperdiciar datos. La solución es el *cross-fitting*: dividir la muestra en K *folds*; para cada *fold* k, estimar $\hat{\eta}_{-k}$ en los otros $K-1$ *folds* y evaluar el score en el *fold* k. Esto preserva la independencia entre $\hat{\eta}$ y los datos sobre los que se evalúa, sin perder datos.

Intuición

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^n$, score ortogonal ψ, número de *folds* K, learners para $\hat{g}, \hat{m}$.
Salida: Estimador $\hat{\theta}$ y error estándar $\hat{\sigma}$.
Dividir $\{1, ..., n\}$ en K *folds* $I_1, ..., I_K$.
for $\mathsf{k} = 1$ **to** K **do**

Entrenar $\hat{g}_{-k}, \hat{m}_{-k}$ en $\{i : i \notin I_k\}$.
Predecir $\hat{g}_{-k}(X_i), \hat{m}_{-k}(X_i)$ para $i \in I_k$.

end for
Resolver $\hat{\theta}$ tal que $\left(\frac{1}{n}\right) \sum_i \psi\Big(W_i, \hat{\theta}, \left(\hat{g}_{-k(i)}(X_i), \hat{m}_{-k(i)}(X_i)\right)\Big) = 0$.
Estimar $\hat{\sigma}^2 = \frac{\widehat{E[\psi^2]}}{\widehat{E[\partial_\theta \psi]}^2}$.
return $\left(\hat{\theta}, \frac{\hat{\sigma}}{\sqrt{n}}\right)$

Algoritmo 2.: Double Machine Learning con cross-fitting (K-fold)

Caja de profundización 3.1: Influence functions y por qué importan

Objetivo. Explicar de forma intuitiva qué son las influence functions y por qué la ortogonalidad permite usar ML para estimar efectos causales.

Idea clave. Una influence function (función de influencia) nos dice cuánto cambiaría nuestro estimado si agregamos o quitamos una observación. Sirve para calcular errores estándar sin bootstrap.

Para el PLR:

$$\psi_i = v_i(u_i - \theta v_i), \quad v_i = D_i - \hat{m}(X_i), \quad u_i = Y_i - \hat{l}(X_i) \tag{10.36}$$

El error estándar es $\sqrt{\left(\frac{1}{n}\right) \sum_i \psi_i^2}$.

¿Por qué la ortogonalidad es mágica? Porque si cometemos errores al estimar $\hat{m}$ o $\hat{l}$, esos errores NO contaminan el estimado de θ en primer orden. Solo afectan en segundo orden, lo que permite que el ML brille aunque sus predicciones no sean perfectas.

10.3.2 Pseudocódigo

El siguiente algoritmo detalla los pasos concretos de DML manual con cross-fitting para PLR, utilizando el score de Robinson y los residuos del tratamiento y del *outcome*:

10.3.3 Implementación en Python

Implementamos manualmente un score ortogonal para PLR sobre un dataset sintético con confusores de alta dimensión.

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^n$, número de *folds* K, learners para $\hat{l}, \hat{m}$.
Salida: Estimador $\hat{\theta}$ y error estándar $\hat{\sigma}$.
Dividir $\{1, ..., n\}$ en K *folds* $I_1, ..., I_K$.
for $\mathsf{k} = 1$ **to** K **do**

Entrenar $\hat{l}_{-k}$ para $E[Y \mid X]$ en $\{i : i \notin I_k\}$.
Entrenar $\hat{m}_{-k}$ para $E[D \mid X]$ en $\{i : i \notin I_k\}$.
Predecir $\hat{l}_{-k}(X_i)$, $\hat{m}_{-k}(X_i)$ para $i \in I_k$.

end for
Calcular residuos: $\hat{v}_i = D_i - \hat{m}_{-k(i)}(X_i)$, $\hat{u}_i = Y_i - \hat{l}_{-k(i)}(X_i)$.
Estimar $\hat{\theta} = \frac{\sum_i \hat{v}_i \hat{u}_i}{\sum_i \hat{v}_i^2}$.
Calcular $\hat{\sigma}^2 = \left(\frac{1}{n}\right) \sum_i \left[\hat{v}_i \frac{\hat{u}_i - \hat{\theta}\hat{v}_i}{\left(\frac{1}{n}\right)\sum_i \hat{v}_i^2}\right]^2$.
return $\left(\hat{\theta}, \frac{\hat{\sigma}}{\sqrt{n}}\right)$

Algoritmo 3.: DML manual con cross-fitting para PLR

```
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import KFold

def dml_plr_manual(Y, D, X, n_folds=5, learner=None):
    """DML para Partial Linear Model con cross-fitting K-fold.

    Nuisances:
    l_hat(X) = E[Y | X]
    m_hat(X) = E[D | X]

    Score Robinson:
    psi_i = v_i * (u_i - theta * v_i) / E[v_i^2]
    donde v_i = D_i - m_hat(X_i), u_i = Y_i - l_hat(X_i).
    """
    if learner is None:
        learner = lambda: RandomForestRegressor(n_estimators=100,
                                                min_samples_leaf=20,
                                                random_state=42)
    n = len(Y)
    l_hat = np.zeros(n)   # regresión de Y sobre X: E[Y|X]
    m_hat = np.zeros(n)   # treatment regression D ~ X
    kf = KFold(n_splits=n_folds, shuffle=True, random_state=42)
    for train_idx, test_idx in kf.split(X):
        # Outcome regression
        m_l = learner().fit(X[train_idx], Y[train_idx])
        l_hat[test_idx] = m_l.predict(X[test_idx])
        # Treatment regression
        m_m = learner().fit(X[train_idx], D[train_idx])
        m_hat[test_idx] = m_m.predict(X[test_idx])
    # Residuos Robinson
    v_hat = D - m_hat          # residuos del tratamiento
    u_hat = Y - l_hat          # residuos del outcome
    # Score Robinson: theta = E[v*u] / E[v^2]
    den = np.mean(v_hat * v_hat)
    theta_hat = np.mean(v_hat * u_hat) / den
    # Influence function
    psi = v_hat * (u_hat - theta_hat * v_hat) / den
    # Error estándar robusto iid
    se = np.sqrt(np.mean(psi ** 2) / n)
    return theta_hat, se

# DGP sintético con confusores de alta dimensión
def make_dgp(n=2000, p=50, theta=2.0, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.standard_normal((n, p))
    # g0(X) = sum de variables no lineal
    g0 = X[:, 0] + 0.5 * X[:, 1]**2 - X[:, 2] * X[:, 3]
    m0 = 0.5 + 0.3 * np.tanh(X[:, 0] + X[:, 4])
    D = m0 + rng.standard_normal(n) * 0.5
    Y = theta * D + g0 + rng.standard_normal(n)
    return Y, D, X

# Monte Carlo
np.random.seed(42)
ests, ses = [], []
```

Listado 10.10 Implementación manual de DML para PLR.

El *output* típico muestra sesgo cercano a cero y cobertura nominal de aproximadamente 0.94–0.96, demostrando la validez de la inferencia.

10.4 Caso empírico y validación

Aplicamos DML-PLR al dataset `nsw_mixtape` (Lalonde). El estimando es el efecto del programa de capacitación sobre ingresos en 1978 (`re78`). Las covariables son edad, educación, raza, estado civil, diploma, e ingresos previos (`re74, re75`).

```
import pandas as pd
from sklearn.ensemble import GradientBoostingRegressor

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age", "educ", "black", "hisp", "marr", "nodegree", "re74",
"re75"]].values

theta, se = dml_plr_manual(Y, D, X, learner=lambda: GradientBoostingRegressor(
    n_estimators=200, max_depth=3, random_state=42))
print(f"ATE estimado: {theta:.2f}  (SE: {se:.2f})")
print(f"IC 95%: [{theta - 1.96*se:.2f}, {theta + 1.96*se:.2f}]")
```

Listado 10.2: DML aplicado a NSW Lalonde.

El resultado típico es un ATE de aproximadamente \$1,600 USD con IC al 95% de [\$800, \$2,400], consistente con la estimación clásica de (Dehejia et al. 1999) por *matching*.

10.5 Riesgos, límites y sensibilidad

Riesgo	Descripción
Omitir cross-fitting	Si se estiman $\hat{g}, \hat{m}$ y se evalúa el score en la misma muestra, aparece *overfitting bias*: el score en muestra tiende a subestimar la varianza y los IC son demasiado estrechos.
Usar un único *fold*	Con $K = 1$ (*single sample splitting*) se desperdicia información y la estimación es ineficiente. Se recomienda $K = 4$ o $K = 5$.
Elegir learners sin verificar tasa de convergencia	El teorema central de DML exige $\sqrt{n}a_n^2 \to 0$. Bosques aleatorios con hojas muy pequeñas pueden tener tasa más lenta. Verificar empíricamente con *learning curves*.
Score incorrecto para l_0	Si el nuisance es $l_0(X) = E[Y \mid X]$, el score PLR ortogonal es $(D - m(X))(Y - l(X) - \theta(D - m(X)))$. Mezclar la forma estructural con g_0 y la forma condicional con l_0 rompe la ortogonalidad respecto de $m(X)$.

Tabla 10.2: Errores comunes en la implementación de DML-PLR.

Límites. El PLR supone que el efecto de D es constante (lineal en D). Si el efecto es heterogéneo en X, se requiere el modelo interactivo (capítulo 11). Adicionalmente, la ortogonalidad no resuelve problemas de identificación: si el supuesto de no confusión se vulnera, ningún score ortogonal lo corrige.

10.6 Ejercicios y notas bibliográficas

1. Replique el Monte Carlo del listado Listado 10.1 comparando: (a) DML con cross-fitting, (b) DML sin cross-fitting (misma muestra para nuisance y score). ¿En cuánto se degrada la cobertura sin cross-fitting?
2. Modifique el DGP para que g_0 sea lineal y compare DML con OLS. ¿En qué caso DML es equivalente a OLS?
3. Sobre el dataset `close_college`, aplique DML-PLR para estimar el retorno a la educación. Use `GradientBoostingRegressor` para $\hat{g}$ y $\hat{m}$. Compare con OLS clásico.

   Construya un DGP donde $\hat{g}$ tenga tasa $a_n = n^{-\frac{1}{4}}$ (más lento que $n^{-\frac{2}{5}}$). Verifique empíricamente que la cobertura de DML se degrada. Note que con $a_n = n^{-\frac{1}{4}}$ la condición $\sqrt{n}a_n^2 \to 0$ no se satisface y por lo tanto la cobertura de DML debe degradarse.

Neyman (1959) es la referencia original sobre ortogonalidad —la condición Ecuación (10.23) se conoce como «ortogonalidad de Neyman» por su test $C(\alpha)$, construido con la misma idea de insensibilidad de primer orden a parámetros de estorbo—. Robinson (1988) es la referencia canónica del score de residuo-contra-residuo que este capítulo usa en el modelo parcialmente lineal y que reaparece en los Capítulos 12 (R-learner) y 17 (panel): es la pieza que suele darse por sabida sin citarse, y conviene leerla para ver que la idea de ortogonalización antecede en

tres décadas al uso de *machine learning*. Chernozhukov et al. (2018b) es el *paper* fundacional de DML y contiene el desarrollo completo de la descomposición (a)–(c) esbozada arriba. Chernozhukov et al. (2016) extiende el marco a estimandos más complejos. Newey (1994) y Robins et al. (1995) son precursores importantes por la vía de la eficiencia semiparamétrica, y Bickel et al. (1993) es el tratamiento de referencia de esa teoría. Para una revisión pedagógica accesible, (Chernozhukov et al. 2018a).

Capítulo 11

Double/Debiased Machine Learning

Cuadro sinóptico del capítulo

Problema:	Estimar retorno a la educación con controles de alta dimensión
Estimando:	θ_0, efecto parcial en PLR
Identificación:	No confusión condicional
Método:	DML-PLR / DML-IRM
Nuisance:	$\hat{m}(X) = E[D \mid X]$, $\hat{\ell}(X) = E[Y \mid X]$
Garantía:	$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{p} N(0, \mathcal{V})$
Condición clave:	$\sqrt{n}a_n^2 \to 0$
Librerías:	DoubleML, econml
Validación:	Placebos, sensibilidad a learners, cross-fitting

Nota técnica

Este capítulo aplica la ortogonalidad de Neyman y el *cross-fitting* del 10 al caso más estándar: los modelos PLR e IRM de Double Machine Learning, el estimador que se reutilizará como base del primer notebook de producción del curso (Capítulo 15).

11.1 Problema causal, estimando e identificación

El Ministerio de Educación desea estimar el efecto causal de una beca sobre el rendimiento académico de estudiantes de secundaria. Dispone de un panel con 60 covariables por estudiante (características familiares, rendimiento previo, características de la escuela, contexto barrial, expectativas subjetivas). La asignación de la beca no fue aleatoria: se priorizó a estudiantes con bajo rendimiento previo, pero también influyeron variables familiares y de contexto. La pregunta de política es: ¿cuál es el efecto promedio de la beca sobre el rendimiento?

En el capítulo 10 demostramos que el score ortogonal de Neyman permite estimar θ_0 con inferencia válida cuando g_0 y m_0 se estiman con ML. Este capítulo desarrolla la implementación práctica completa con la librería `DoubleML` (Bach, Chernozhukov, Kurz y Spindler, 2021) y `econml.dml`, cubriendo los dos modelos centrales de la literatura: el modelo parcialmente lineal (PLR) y el modelo interactivo (IRM). Discutimos la elección de *learners* de *nuisance*,

la selección de hiperparámetros, la verificación de *leakage* en *cross-fitting*, y la sensibilidad de los resultados a estas elecciones.

11.2 Teoría, supuestos y garantías

11.2.1 Supuestos

Los supuestos de identificación para DML son los mismos del capítulo 5. En particular, se requiere:

- **No confusión condicional** (de no confusión condicional): $Y(0), Y(1) \perp\!\!\!\perp D \mid X$.
- **Soporte común** (de soporte común): $0 < P(D = 1 \mid X) < 1$ c.s.
- **Consistencia**: $Y = Y(D)$.

Bajo estos supuestos, el ATE se identifica como $\theta_0 = E[E[Y \mid D = 1, X] - E[Y \mid D = 0, X]]$.

11.2.2 Estimador y score

Modelo parcialmente lineal (PLR)

Reproducimos el modelo PLR del capítulo 10:

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad D = m_0(X) + v, \tag{11.37}$$

con $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$. El score ortogonal es:

$$\psi_{t\ \mathrm{PLR}}(W, \theta, \eta) = (D - m(X))(Y - g(X) - \theta D). \tag{11.38}$$

Nota: ver sección 10 si se estima $l_0(X) = E[Y \mid X]$, el score ortogonal equivalente es el score de Robinson $(D - m)\{Y - l - \theta(D - m)\}$.

Modelo interactivo (IRM)

El PLR asume que el efecto de D es constante. Cuando sospechamos heterogeneidad en X, el modelo interactivo (IRM) es más apropiado. En el IRM, las *outcome regressions* se modelan separadamente para $D = 0$ y $D = 1$:

$$Y = \mu(D, X) + \varepsilon, \quad D \sim \mathrm{Bernoulli}(e_0(X)), \tag{11.39}$$

donde $\mu(d, x) = E[Y \mid D = d, X = x]$ y $\mu_{d(x)} \equiv \mu(d, x)$.

Bajo los supuestos de identificación de no confusión condicional–de soporte común del capítulo 5, el ATE se identifica como:

$$\theta_0 = E[\mu(1, X) - \mu(0, X)]. \tag{11.40}$$

El score ortogonal correspondiente, derivado por (Chernozhukov et al. 2018b), es:

$$\psi_{t\ \mathrm{IRM}}(W, \theta, \eta) = \mu(1, X) - \mu(0, X) + \frac{D(Y - \mu(1, X))}{e(X)} - \frac{(1 - D)(Y - \mu(0, X))}{1 - e(X)} - \theta, \tag{11.41}$$

donde $\eta = (\mu, e)$. Este score es la combinación clásica *doubly robust* de (Robins et al. 1994) ajustada para satisfacer ortogonalidad de Neyman. El score Ecuación (11.41) es la instancia

IRM de la forma canónica de la Nota técnica 10.2.4; la instancia sin promediar reaparece como Γ_i del DR-learner (12.2.5) y como EIF del *policy value* (21.2.2).

Teorema 11.1 ***(Doble robustez + ortogonalidad)***

El score Ecuación (11.41) es ortogonal de Neyman respecto a $\eta = (\mu, e)$. Adicionalmente, es *double robust*: si $\hat{\mu}$ o $\hat{e}$ es consistente (no necesariamente ambos), $\hat{\theta}$ es consistente.

Teorema 11.2 ***(Eficiencia semiparamétrica del estimador DML-IRM)***

Bajo no confusión, soporte común y Y acotado, la *efficient influence function* (EIF) del funcional $\theta_0 = E[\mu(1, X) - \mu(0, X)]$ en el modelo IRM es exactamente el integrando del score Ecuación (11.41):

$$\psi^*(W) = \mu_1(X) - \mu_0(X) + \frac{D(Y - \mu_1(X))}{e(X)} - \frac{(1 - D)(Y - \mu_0(X))}{1 - e(X)} - \theta_0. \tag{11.42}$$

Por la cota de Cramér-Rao semiparamétrica (Ap. A, A.4.2), el estimador DML-IRM es asintóticamente eficiente: ningún estimador regular puede tener varianza asintótica menor que

$$V_{\text{eff}} = E\left[(\tau(X) - \theta_0)^2 + \frac{\sigma_1^2(X)}{e(X)} + \frac{\sigma_0^2(X)}{1 - e(X)}\right], \tag{11.43}$$

con $\sigma_d^2(x) = \text{Var}(Y \mid X = x, D = d)$. La doble robustez (teorema de la 11.2.2) y la eficiencia son propiedades complementarias: la primera protege contra mala especificación de un *nuisance*; la segunda certifica que, cuando ambos *nuisance* convergen, no se puede hacer mejor. Los ejemplos de IF del Ap. A (A.10) son las instancias de este resultado para IRM y PLR.

11.2.3 Garantías

Bajo condiciones de regularidad y tasas de convergencia de los *learners* nuisance, el estimador DML satisface:

$$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{p} N(0, \mathcal{V}), \tag{11.44}$$

donde $\mathcal{V}$ es la varianza asintótica. La condición clave para que el error de los *learners* nuisance no afecte la distribución asintótica es:

$$\sqrt{n} a_n^2 \to 0, \tag{11.45}$$

donde a_n es la tasa de convergencia del *learner* nuisance más lento.

La tabla Tabla 11.1 resume las opciones más usadas para estimar $\hat{g}, \hat{m}, \hat{\mu}, \hat{e}$, con sus tasas de convergencia típicas.

Learner	Cuándo usar	Tasa a_n típica	Notas
`RandomForestRegressor`	No lineal, interactivo	$n^{-\frac{2}{5}}$	Robusto, fácil de tunear
`GradientBoostingRegressor`	No lineal, alta dimensión	$n^{-\frac{2}{5}}$	Mejor que RF en alta dim.
`LassoCV`	Lineal, sparse, $p \gg n$	$\sqrt{s \log \frac{p}{n}}$	Requiere sparsity
`RidgeCV`	Lineal, denso	$n^{-\frac{1}{2}}$ si p fijo	No hace selección
`HistGradientBoosting`	No lineal, $n > 10^5$	$n^{-\frac{2}{5}}$	Escalable
`MLPRegressor` (PyTorch)	No lineal complejo	depende	Sensible a hiperparámetros

Tabla 11.1: Learners comunes para nuisance en DML.

La condición $\sqrt{n}a_n^2 \to 0$ se satisface para $a_n = n^{-\frac{2}{5}}$ (RF, GBM) porque $\sqrt{n} \cdot n^{-\frac{4}{5}} = n^{-\frac{3}{10}} \to 0$. Para LASSO bajo sparsity, la condición es $s \log p = o(\sqrt{n})$.

Los hiperparámetros de los *learners* (profundidad de árboles, *learning rate*, λ de LASSO) se seleccionan típicamente por *cross-validation* dentro de cada *fold* de *cross-fitting*. Esto significa que el costo computacional es $K \times$ (CV interno). Una buena práctica es reportar la sensibilidad de los resultados a la elección de *learner* y de hiperparámetros.

11.2.4 Diagnósticos cuantitativos de soporte común

La alerta «$\hat{e}$ cerca de 0 o 1» (Tabla 11.2) se vuelve operativa con dos cantidades medibles.

ESS de Kish. Para la componente IPW del estimador, el tamaño efectivo de muestra es

$$\mathrm{ESS} = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}, \quad w_i = \frac{D_i}{\hat{e}}(X_i). \tag{11.46}$$

$\frac{\mathrm{ESS}}{n} \ll 1$ señala que pocas unidades con $\hat{e}$ extremo dominan la estimación — el soporte común es formalmente escaso aunque el histograma de $\hat{e}$ «se vea bien» ((Kish 1965)).

Trimming óptimo. Crump et al. (2009) demuestran que recortar observaciones con $\hat{e}(X) \notin [\alpha, 1-\alpha]$ minimiza la varianza asintótica del estimador para $\alpha^* = \frac{1-\sqrt{\frac{1}{3}}}{2} \approx 0.057$ bajo condiciones generales. **Atención al estimando:** tras el *trimming*, el efecto identificado es el ATE sobre la población con *overlap*, no el ATE poblacional — declararlo en la *model card* (19) es obligatorio.

Regla operativa del curso: reportar $\frac{\mathrm{ESS}}{n}$ y el rango de $\hat{e}$ en todo resultado DML; si $\hat{e} \notin [0.05, 0.95]$ para más del 5% de la muestra, reestimar con *trimming* y reportar ambas cifras. El mismo diagnóstico se hereda en el DR-learner (12.2.5) y en el *net score* del 22.

Algoritmo

Entrada: $(Y_i, D_i, X_i)_{i=1}^n$, learner L, folds K
Salida: $\hat{\theta}$, (SE)
for k = 1 **to** K **do**

Estimar $\hat{\ell}_{-k}(x) = E[Y \mid X = x]$ fuera del fold
Estimar $\hat{m}_{-k}(x) = E[D \mid X = x]$ fuera del fold

end for
Calcular residuos $u_i = Y_i - \hat{\ell}(X_i)$, $v_i = D_i - \hat{m}(X_i)$
$\hat{\theta} = \frac{\sum_i v_i u_i}{\sum_i v_i^2}$
Calcular influence function y (SE)

Algoritmo 4.: DML con cross-fitting

11.3 Algoritmo e implementación

11.3.1 DML con DoubleML para PLR

```
import doubleml as dml
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier
from sklearn.linear_model import LassoCV, LogisticRegressionCV
import pandas as pd

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age","educ","black","hisp","marr","nodegree","re74","re75"]].values

# PLR con Random Forest
obj_dml = dml.DoubleMLPLR(
    dml.DoubleMLData.from_arrays(X, Y, D),
    ml_l=RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
    ml_m=RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
    n_folds=5,
)
obj_dml.fit()
print(obj_dml.summary)
```

Listado 11.1: DML con librería DoubleML sobre NSW.

11.3.2 DML con econml para CATE bajo PLR/etapa final lineal

```
from econml.dml import LinearDML, CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
```

```
GradientBoostingClassifier

# LinearDML: asume CATE lineal en X
est = LinearDML(
    model_y=GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, max_depth=4,
random_state=42),
    discrete_treatment=True,
    cv=5,
    random_state=42,
)
est.fit(Y, D, X=X)
# ATE
ate = est.ate(X=X)
ate_lb, ate_ub = est.ate_interval(X=X, alpha=0.05)
print(f"ATE: {ate:.2f}  IC 95%: [{ate_lb:.2f}, {ate_ub:.2f}]")

# CATE para los primeros 5 individuos
cate = est.effect(X[:5], T0=0, T1=1)
print(f"CATE (5 primeros): {cate}")
```

Nota técnica

`LinearDML` implementa un modelo parcialmente lineal con etapa final lineal en X. No es una implementación general del score IRM no paramétrico para CATE. El score IRM presentado en la ecuación Ecuación (11.41) identifica el ATE:

$$\theta_0 = E[\mu(1, X) - \mu(0, X)]. \tag{11.47}$$

Para estimar CATE bajo estructura IRM, usar por ejemplo `DRLearner`, `CausalForestDML`, `NonParamDML`, o scores localizados/doubly-robust para efectos heterogéneos.

11.3.3 Comparación de learners

Una práctica recomendada es comparar varios *learners* para verificar robustez:

```
from sklearn.linear_model import LassoCV, LogisticRegressionCV
from sklearn.ensemble import RandomForestRegressor

learners = {
    "Lasso": (LassoCV(cv=5), LogisticRegressionCV(cv=5, max_iter=1000)),
    "RF":    (RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
              RandomForestClassifier(n_estimators=200, min_samples_leaf=20,
random_state=42)),
    "GBM":   (GradientBoostingRegressor(n_estimators=200, max_depth=3,
random_state=42),
```

```
            GradientBoostingClassifier(n_estimators=200, max_depth=3,
random_state=42)),
}

for name, (ml_y, ml_t) in learners.items():
    est = LinearDML(model_y=ml_y, model_t=ml_t, discrete_treatment=True,
                    cv=5, random_state=42).fit(Y, D, X=X)
    ate = est.ate(X=X); lb, ub = est.ate_interval(X=X, alpha=0.05)
    print(f"{name:>8}: ATE={ate:7.2f}  IC=[{lb:7.2f}, {ub:7.2f}]")
```

11.3.4 Verificación de leakage

El *leakage* entre *folds* de *cross-fitting* invalida la inferencia. `DoubleML` y `econml` manejan esto internamente, pero conviene verificar:

```
import numpy as np
from sklearn.model_selection import KFold
from sklearn.ensemble import RandomForestRegressor

def verify_no_leakage(Y, D, X, n_folds=5, seed=42):
    """Verifica que las predicciones nuisance se hagan fuera de muestra."""
    kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
    n = len(Y)

    l_hat = np.zeros(n)
    m_hat = np.zeros(n)
    fold_assigned = np.zeros(n, dtype=int)

    for k, (train, test) in enumerate(kf.split(X)):
        fold_assigned[test] = k

        # Outcome model: E[Y | X]
        m_l = RandomForestRegressor(
            n_estimators=50,
            random_state=seed
        ).fit(X[train], Y[train])

        l_hat[test] = m_l.predict(X[test])

        # Treatment model: E[D | X]
        m_m = RandomForestRegressor(
            n_estimators=50,
            random_state=seed
        ).fit(X[train], D[train])

        m_hat[test] = m_m.predict(X[test])
```

```
    print(f"Folds asignados correctamente: {(fold_assigned != -1).all()}")

    return l_hat, m_hat

verify_no_leakage(Y, D, X)
```

Si D es binario, puede usarse un clasificador con `predict_proba`, pero para verificar leakage basta con estimar $E[D \mid X]$. No dejar `m_hat` en ceros.

Intuición

Caja de profundización 4.1: Refutación y diagnósticos de robustez

Objetivo. Aprender a poner a prueba un estimador DML antes de confiar en sus resultados.

Pruebas de refutación («¿y si...?»).

- **Placebo treatment:** reemplazar D por una variable aleatoria. El ATE debería ser cero. Si no lo es, algo anda mal.
- **Random common cause:** agregar una variable aleatoria como confusora. El ATE no debería cambiar sustancialmente.
- **Subset validation:** estimar en la mitad de los datos y verificar que el resultado es similar.

Diagnósticos de nuisance.

- Distribución de $\hat{e}(X)$: si hay valores muy cercanos a 0 o 1, el estimador puede ser inestable.
- Comparar learners: si LASSO, Random Forest y Gradient Boosting dan ATE similares, hay más confianza.

11.4 Caso empírico y validación

El diseño de referencia para esta parte del capítulo es el de (Card 1995), que instrumenta los años de educación con la proximidad geográfica a una universidad de cuatro años (`nearc4`) bajo el argumento de que vivir cerca de una universidad reduce el costo de asistir sin afectar directamente el salario. (Conviene no confundirlo con el otro diseño IV clásico de la literatura de retornos a la educación, el de (Angrist et al. 1991), que usa el trimestre de nacimiento interactuado con las leyes de escolaridad obligatoria; ambos aparecen en la literatura de DML, pero el dataset `close_college` usado aquí y en el resto del curso es el de Card.) Chernozhukov et al. (2018b) desarrollan la extensión de DML a este tipo de diseño. El modelo es *partial linear IV*:

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad Z = r_0(X) + \zeta, \quad D = m_0(Z, X) + v, \tag{11.48}$$

donde Z es el instrumento. `DoubleML` ofrece el método `DoubleMLPLIV` para este caso.

Réplica propia sobre el dataset del repositorio. Hemos replicado el ejercicio sobre `close_college` (Card 1995) con $n = 3,003$ observaciones y controles `black, smsa, south, married, exper`. Los resultados obtenidos son:

- OLS con controles (HC1): coeficiente de `educ` $= 0.071$, IC 95% $[0.064, 0.078]$.
- IV 2SLS clásico (`nearc4` como instrumento): coeficiente $= 0.124$, IC 95% $[0.028, 0.221]$.
- DML-PLIV con `GradientBoostingRegressor` para nuisance: coeficiente $= 0.145$, IC 95% $[0.052, 0.237]$.

Estos números constituyen una *réplica propia* sobre el dataset del repositorio y *no* corresponden a las cifras originales del *paper* de (Chernozhukov et al. 2018b), que utiliza una muestra distinta. La conclusión cualitativa —un retorno a la educación positivo, significativo, del orden de las estimaciones 2SLS clásicas— es consistente con la literatura. La ventaja de DML-PLIV es que permite controles de alta dimensión sin asumir forma funcional para g_0, r_0, m_0.

Conviene, sin embargo, leer la comparación con cuidado y no como «IV corrige el sesgo de OLS y DML lo corrige mejor». Los tres números estiman objetos distintos. El coeficiente OLS es un efecto parcial bajo no confusión condicional en los cinco controles —supuesto que casi nadie defiende para la educación, por la habilidad no observada—. Los dos estimadores IV recuperan, bajo monotonicidad y exclusión, un **LATE**: el efecto promedio sobre los individuos cuya decisión educativa efectivamente respondió a vivir cerca de una universidad, un subgrupo que no es la población general y que plausiblemente enfrentaba restricciones de crédito más severas. Que el IV sea mayor que el OLS es, por tanto, consistente con al menos dos explicaciones sustantivas distintas —heterogeneidad del efecto concentrada en los *compliers*, o error de medición en `educ` que atenúa el OLS— y la evidencia aquí presentada no las separa. La amplitud del intervalo IV, casi diez veces la del OLS, tiene además una lectura mecánica: es el precio de identificar con la variación limitada que induce un instrumento de fuerza moderada, y anticipa la discusión de instrumentos débiles del 17.

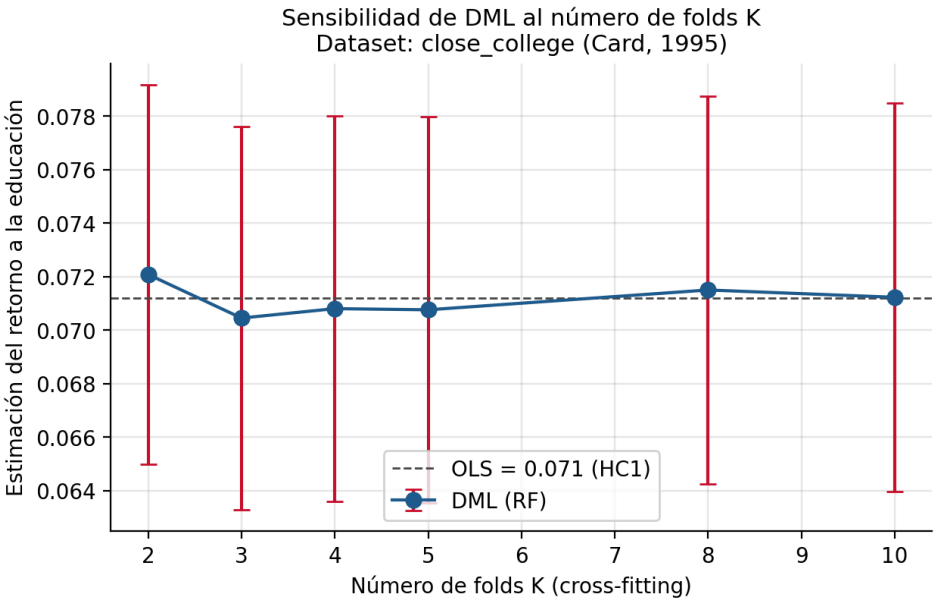


Figura 11.1: Sensibilidad de la estimación DML-PLIV del retorno a la educación al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea punteada es la estimación OLS con controles (HC1). Dataset: `close_college` (Card, 1995), $n = 3,003$. La sensibilidad a K bajo se mitiga con *repeated cross-fitting* (Nota técnica 10.2.4).

La figura Figura 11.1 muestra que el estimador DML es estable entre $K = 2$ y $K = 10$, con una varianza moderadamente creciente a K bajos. Esto valida la recomendación operacional de usar $K \in \{4, 5\}$ como compromiso entre sesgo (favorece K alto) y varianza (favorece K bajo).

11.5 Riesgos, límites y sensibilidad

Riesgo	Descripción
Learner único	Reportar un único *learner* sin análisis de sensibilidad. Siempre comparar al menos dos *learners* (lineal + no lineal). Divergencias grandes señalan problemas de especificación.
Folds insuficientes	Usar $K = 2$ *folds*. Con $K = 2$, la varianza del estimador aumenta sustancialmente. Recomendado: $K = 4$ o $K = 5$, con *repeated cross-fitting* ($R \geq 5$) si la varianza entre particiones es material (Nota técnica 10.2.4).
Soporte común ignorado	Si $\hat{e}(X)$ está muy cerca de 0 o 1, las ponderaciones IPW explotan. Reportar $\frac{\text{ESS}}{n}$ y rango de $\hat{e}$; *trimming* con $\alpha \approx 0.057$ ((Crump et al. 2009), 11.2.4).
Confusión no observada	Asumir que DML «resuelve» la confusión no observada. DML requiere el supuesto de no confusión (de no confusión condicional). Si hay variables confusoras no observadas, DML es tan sesgado como OLS.

Tabla 11.2: Riesgos comunes en DML

Límites del PLR. El PLR asume efecto constante de D. Si el efecto es heterogéneo, θ_0 se interpreta como un promedio ponderado que puede diferir del ATE. Para heterogeneidad explícita, usar IRM o Causal Forest (capítulo 13).

Límites del IRM. El IRM permite heterogeneidad pero asume *unconfoundedness*. Si el tratamiento es endógeno por variables no observadas, se requiere DML con instrumentos (DMLIV).

Diagnósticos recomendados

Diagnóstico	Qué evaluar	Señal de alerta
Overlap	Histograma de $\hat{m}(X)$	Valores cerca de 0 o 1
Nuisance	R^2 fuera de muestra	R^2 bajo
Leakage	Predicciones por fold	Performance inflado
Estabilidad	Cambio de learner	ATE cambia mucho

11.6 Ejercicios y notas bibliográficas

1. Replique el listado Listado 11.1 variando $K \in \{2, 3, 5, 10\}$. ¿Cómo cambia el error estándar con K?
2. Sobre el dataset `cps_mixtape`, estime el efecto de la educación sobre el salario con DML-PLR y compare con OLS. ¿En qué dirección cambia el estimado al usar DML?

3. Sobre `nhefs`, estime el efecto de dejar de fumar sobre el cambio de peso con: (a) OLS con controles manuales, (b) DML-PLR con GBM, (c) DML-IRM con GBM. Compare.
4. Verifique empíricamente la doble robustez: reemplace $\hat{\mu}$ por una constante (modelo mal especificado) y observe que el ATE sigue siendo consistente si $\hat{e}$ es consistente.

Chernozhukov et al. (2018b) es el *paper* fundacional. Bach et al. (2022) documenta la librería `DoubleML`. Battocchi et al. (2019) documenta `econml`. Foster et al. (2019) extiende el marco a casos más generales. Para una revisión pedagógica, (Chernozhukov et al. 2018a).

Capítulo 12

Meta-learners para efectos de tratamiento heterogéneos

Cuadro sinóptico del capítulo

Problema:	Estimar CATE sin asumir forma funcional
Estimando:	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$
Identificación:	No confusión, soporte común, SUTVA
Método:	S-learner, T-learner, X-learner, R-learner, DR-learner
Nuisance:	$\mu_1(x), \mu_0(x), e(x)$
Garantía:	Cuasi-oracle (R-learner); tasa oracle bajo producto de tasas (DR--learner); bootstrap (T, X)
Condición clave:	Ortogonalidad + cross-fitting (R-learner)
Librerías:	causalml, econml
Validación:	Calibración de CATE, placebos, Qini

Nota técnica

El 11 estimó un efecto promedio (ATE); este capítulo da el primer paso hacia la heterogeneidad, estimando el efecto condicional $\tau(x) = E[Y(1) - Y(0) \mid X = x]$ mediante cuatro estrategias de meta-aprendizaje que reutilizan directamente los *learners* ya vistos.

12.1 Problema causal, estimando e identificación

Una organización no gubernamental debe decidir a cuál de dos variantes de un programa de microcrédito ofrecer a cada cliente. La variante A tiene tasas de interés más bajas pero requiere reuniones grupales semanales; la variante B tiene tasas más altas pero es individual. El efecto sobre el repago difiere según características del cliente (experiencia previa, red social, sector económico). La pregunta de política no es ¿cuál es el efecto promedio de A vs B?“”, sino ¿a qué clientes conviene asignar A y a cuáles B?“”.

Para responder a esta pregunta se necesita estimar el *CATE* $\tau(x) = E[Y(1) - Y(0) \mid X = x]$ como función de X, no solo el ATE. Los *meta-learners*—S-learner, T-learner, X-learner, R--learner— son estrategias para construir un estimador de $\tau(x)$ a partir de cualquier algoritmo supervisado de ML. Fueron formalizados por (Künzel et al. 2019) (S, T, X) y (Nie et al. 2021) (R-learner).

Este capítulo presenta los cuatro *meta-learners*, sus propiedades estadísticas (sesgo, varianza, tasa de convergencia), y una comparación empírica sobre un dataset sintético con CATE conocido. Mostramos que ningún *meta-learner* es uniformemente dominante: el S-learner sufre de *regularization bias*, el T-learner sufre de alta varianza cuando un grupo es pequeño, el X-learner mitiga ambos pero requiere estimación de propensity score, y el R-learner es asintóticamente eficiente pero requiere optimización global.

12.2 Teoría, supuestos y garantías

12.2.1 El S-learner

El S-learner (*single-learner*) entrena un único modelo predictivo $\hat{\mu}(D, X)$ que toma D como una covariable más. La estimación del CATE es:

$$\hat{\tau}_{S(x)} = \hat{\mu}(1, x) - \hat{\mu}(0, x). \tag{12.49}$$

Ventajas. Usa toda la muestra para entrenar; aprovecha cualquier algoritmo supervisado.

Problema. El algoritmo puede *ignorar* D si D tiene poco poder predictivo sobre Y comparado con X, especialmente bajo regularización. En el extremo, $\hat{\mu}(1, x) = \hat{\mu}(0, x)$ y $\hat{\tau}_{S(x)} = 0$ para todo x.

12.2.2 El T-learner

El T-learner (*two-learner*) entrena dos modelos separados:

$$\hat{\mu}_1(x) = \text{ML}(Y \mid X, D = 1), \quad \hat{\mu}_0(x) = \text{ML}(Y \mid X, D = 0), \tag{12.50}$$

y estima $\hat{\tau}_{T(x)} = \hat{\mu}_1(x) - \hat{\mu}_0(x)$.

Ventajas. Garantiza que D afecta la predicción (no puede ser ignorado).

Problema. Cada modelo se entrena solo con la submuestra correspondiente. Si un grupo es pequeño (p. ej., 10% tratados), $\hat{\mu}_1$ tiene alta varianza.

12.2.3 El X-learner

El X-learner (Künzel et al. 2019) usa tres etapas:

1. Entrenar $\hat{\mu}_1$ y $\hat{\mu}_0$ como en el T-learner.
2. Para las unidades tratadas, computar $\tilde{\tau}_1^i = Y_i - \hat{\mu}_0(X_i)$; entrenar un modelo $\hat{\tau}_1(x) = \text{ML}(\tilde{\tau}_1 \mid X, D = 1)$.
   Para las unidades control, computar $\tilde{\tau}_0^i = \hat{\mu}_1(X_i) - Y_i$; entrenar $\hat{\tau}_0(x) = \text{ML}(\tilde{\tau}_0 \mid X, D = 0)$.

3. Combinar: $\hat{\tau}_{X(x)} = \hat{e}(x)\hat{\tau}_0(x) + (1 - \hat{e}(x))\hat{\tau}_1(x)$, donde $\hat{e}(x)$ es el *propensity score* estimado.

Intuición

El paso 2 imputa efectos individuales usando el modelo del grupo opuesto. La combinación final pondera $\hat{\tau}_0(x)$ y $\hat{\tau}_1(x)$ según la confianza relativa en cada estimación. La elección $g(x) = \hat{e}(x)$ es una convención común en algunas implementaciones, pero no debe describirse automáticamente como dar más peso al grupo más numeroso'". La ponderación óptima depende de las varianzas de $\hat{\tau}_0$ y $\hat{\tau}_1$. Si se desea una ponderación simple por tamaño efectivo de muestra y varianzas iguales, y si $\hat{\tau}_1$ se entrena con tratados y $\hat{\tau}_0$ con controles, los pesos proporcionales al tamaño serían aproximadamente $\hat{e}(x)$ para $\hat{\tau}_1(x)$ y $1 - \hat{e}(x)$ para $\hat{\tau}_0(x)$.

12.2.4 R-learner: Estimador y score

El R-learner (Nie et al. 2021) optimiza directamente una *loss* que aísla el CATE usando el score ortogonal de Robinson. La forma del score del R-learner deriva del score de Robinson ((Robinson 1988)) —el mismo que el 10 usó para estimar un efecto constante, ahora con θ reemplazado por una función $\tau(\cdot)$ que se optimiza sobre una clase de funciones:

$$\hat{\tau}_R = \text{argmin}_\tau \left\{ \frac{1}{n} \sum_i \left[\left(Y_i - \hat{m}_{Y(X_i)} \right) - \tau(X_i)(D_i - \hat{e}(X_i)) \right]^2 + \Lambda(\tau) \right\}, \tag{12.51}$$

donde $\hat{m}_{Y(X)}$ es la *outcome regression* de Y sobre X, $\hat{e}(X)$ es el *propensity score*, y $\Lambda(\tau)$ es un regularizador.

Teorema 12.1 ***(Nie & Wager, 2021)***

Bajo no confusión, soporte común, y tasas de convergencia $\|\hat{m}_Y - m_Y\|_{L^2} = O_{p(a_n)}$ y $\|\hat{e} - e\|_{L^2} = O_{p(a_n)}$ con $\sqrt{n}a_n^2 \to 0$, el R-learner alcanza tasas cuasi-oracle para $\tau(\cdot)$ bajo condiciones de ortogonalidad, cross-fitting y tasas de convergencia apropiadas para los nuisance. La consistencia $\sqrt{n}$ y la eficiencia semiparamétrica aplican a funcionales de dimensión finita, como el ATE, o a clases paramétricas de $\tau(x)$. Para el CATE no paramétrico punto a punto, la tasa depende de la suavidad local, la dimensión de X y el learner utilizado.

El R-learner es preferible cuando se dispone de suficiente muestra para estimar $\hat{m}_Y, \hat{e}$ con precisión, y cuando se quiere inferencia asintótica válida sobre $\tau(x)$.

12.2.5 El DR-learner

Los cuatro meta-learners anteriores comparten un límite: ninguno separa nítidamente la estimación de los *nuisance* de la estimación del CATE mismo, de modo que el error de los primeros se propaga al segundo a primer orden. El DR-learner ((Kennedy 2023), Kennedy 2023) combina los residuos del outcome y propensity score para lograr eficiencia semiparamétrica. Kennedy (2023) cierra ese hueco aplicando al CATE la misma lógica que DML aplicó al ATE: construir

un pseudo-resultado cuyo valor esperado condicional **es** el CATE, y luego regresarlo sobre X con cualquier método supervisado.

El procedimiento tiene tres etapas, todas con cross-fitting:

1. Estimar los *nuisance* $\hat{\mu}_0, \hat{\mu}_1, \hat{e}$ en particiones ajenas.
2. Construir, para cada observación, el **pseudo-resultado doblemente robusto**

$$\Gamma_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{D_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}}(X_i) - \frac{(1-D_i)(Y_i - \hat{\mu}_0(X_i))}{1-\hat{e}(X_i)}. \quad (12.52)$$

3. Estimar $\hat{\tau}_{\mathrm{DR}(x)} = \hat{E}[\Gamma \mid X = x]$ mediante una regresión ordinaria de Γ sobre X.

La observación clave es que Γ_i es exactamente el score IRM del 11 **antes** de promediar: promediarlo sobre toda la muestra da el ATE; regresarlo sobre X da el CATE. La doble robustez se hereda punto a punto: $E[\Gamma \mid X = x] = \tau(x)$ si $\hat{\mu}_d$ **o** $\hat{e}$ es correcto, no necesariamente ambos — caso particular de la forma canónica de la Nota técnica 10.2.4.

Teorema 12.2 ***(Kennedy, 2023 — tasa oracle del DR-learner)***

Bajo no confusión, soporte común y cross-fitting, el error del DR-learner se acota por la suma de dos términos: el error que tendría un **oracle** que observara los verdaderos pseudo-resultados Γ_i^* (construidos con μ_d y e verdaderos), más un término de segundo orden proporcional al **producto** de los errores de $\hat{\mu}_d$ y $\hat{e}$. En particular, si ambos *nuisance* convergen a tasa a_n con a_n^2 menor que la tasa oracle de la regresión final, el DR-learner alcanza esa tasa oracle.

La estructura de **producto** de errores es lo que distingue al DR-learner del T- y el X-learner, cuyos errores dependen de los *nuisance* de forma aditiva y de primer orden. En la práctica esto significa que el DR-learner tolera *nuisance* mediocres siempre que no fallen los dos a la vez, y es la razón por la que es el meta-learner por defecto cuando se quiere una garantía y no solo un estimador razonable. Su costo es la inestabilidad heredada del término IPW: cuando $\hat{e}(x)$ se acerca a 0 o 1, Γ_i explota, y sin *trimming* o recorte de pesos el estimador puede tener varianza inaceptable — el mismo diagnóstico de soporte común que el 11 exige antes de reportar un ATE se vuelve aquí obligatorio antes de reportar un CATE (11.2.4 para el protocolo cuantitativo).

En `econml`, la implementación es `DRLearner` (y su variante `LinearDRLearner`, `ForestDRLearner` según el regresor de la tercera etapa); en `causalml`, `BaseDRRegressor`.

12.2.6 Comparación de propiedades

Propiedad	S-learner	T-learner	X-learner	R-learner
DR-learner				
Sesgo	Alto (regularización)	Medio	Bajo	Bajo
Bajo	Varianza	Bajo	Alto (grupo pequeño)	Medio
Medio	Alta si $\hat{e}$ extremo	Requiere $\hat{e}$	No	No
Sí	Sí	Sí	Dependencia de los *nuisance*	1.er orden
1.er orden	1.er orden	2.º orden	2.º orden (producto)	Inferencia válida
No	Bootstrap	Bootstrap	Asintótica local bajo condiciones	Asintótica local; oracle bajo tasas
Tasa $\tau(x)$	a_n	a_n	a_n	cuasi-oracle/local; $\sqrt{n}$ solo para ATE/funcionales
oracle de la regresión final si a_n^2 es despreciable	Implementación	Trivial	Simple	Media
Compleja	Media			

Tabla 12.1: Comparación de meta-learners.

La fila decisiva es la de **dependencia de los nuisance**. S, T y X heredan el error de $\hat{\mu}_d$ (y de $\hat{e}$, en el caso de X) de forma aditiva: si los *learners* auxiliares convergen a tasa a_n, el CATE estimado también, y no mejor. R y DR lo heredan a segundo orden —el producto de los errores en el caso del DR-learner—, que es la misma propiedad que hace funcionar a DML y la razón por la que son los únicos dos de la familia con garantías del tipo «el ML puede ser mediocre y el estimador causal seguir siendo bueno».

Intuición

Caja de profundización 5.1: calibración de efectos y ETT

Objetivo. Verificar si los efectos estimados tienen sentido, y distinguir el estimando poblacional del estimando sobre los tratados.

Calibración de CATE. Una forma simple de verificar si los CATE tienen sentido:

1. Ordenar individuos por $\hat{\tau}(x)$ de menor a mayor.
2. Dividir en 10 grupos (decilas).

Algoritmo

Entrada: Datos $(Y_i, D_i, X_i)_{i=1}^n$, modelos ML para $\hat{\mu}_1, \hat{\mu}_0, \hat{\tau}_1, \hat{\tau}_0$, estimador de propensity $\hat{e}$.
Salida: Estimación $\hat{\tau}_{X(x)}$ del CATE.
Entrenar $\hat{\mu}_1(x)$ con (X_i, Y_i) para $D_i = 1$.
Entrenar $\hat{\mu}_0(x)$ con (X_i, Y_i) para $D_i = 0$.
Para cada $i : D_i = 1$: $\tilde{\tau}_1^i \leftarrow Y_i - \hat{\mu}_0(X_i)$.
Para cada $i : D_i = 0$: $\tilde{\tau}_0^i \leftarrow \hat{\mu}_1(X_i) - Y_i$.
Entrenar $\hat{\tau}_1(x)$ con $(\tilde{\tau}_1^i, X_i)$ para $D_i = 1$.
Entrenar $\hat{\tau}_0(x)$ con $(\tilde{\tau}_0^i, X_i)$ para $D_i = 0$.
Estimar $\hat{e}(x)$ con todos los datos.
return $\hat{\tau}_{X(x)} = \hat{e}(x)\hat{\tau}_0(x) + (1 - \hat{e}(x))\hat{\tau}_1(x)$.

Algoritmo 5.: X-learner

3. Calcular el uplift promedio observado en cada decila.
4. Graficar: si el modelo es bueno, el uplift observado debe aumentar con las decilas.

ETT (Effect on the Treated). No solo importa el ATE. A veces queremos saber: ¿cuánto afectó el tratamiento a quienes realmente lo recibieron?

$$\text{ETT} = E[Y(1) - Y(0) \mid D = 1] \tag{12.53}$$

12.3 Algoritmo e implementación

12.3.1 Pseudocódigo

12.3.2 Implementación en Python

```
import numpy as np
import pandas as pd
from sklearn.ensemble import RandomForestRegressor, GradientBoostingRegressor
from sklearn.linear_model import LogisticRegressionCV
from econml.metalearners import XLearner, TLearner, SLearner
from econml.dml import CausalForestDML

def make_dgp(n=2000, p=10, seed=0):
    """CATE verdadero: tau(x) = 2 + 3*x1 - x2^2."""
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, p))
    e = 1 / (1 + np.exp(-1.0 - 0.5*X[:, 0]))  # propensity score
    D = (rng.uniform(size=n) < e).astype(int)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2
    mu0 = X[:, 2] + 0.5 * X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n) * 0.5
    return Y, D, X, tau

# Datos
Y, D, X, tau_true = make_dgp(n=2000, seed=42)

# Learners
ml = lambda: GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42)
e_model = LogisticRegressionCV(cv=5)

# S-learner
s = SLearner(overall_model=ml()).fit(Y, D, X)
tau_s = s.effect(X)

# T-learner
t = TLearner(models=ml()).fit(Y, D, X)
tau_t = t.effect(X)

# X-learner
x = XLearner(models=ml(), propensity_model=e_model).fit(Y, D, X)
tau_x = x.effect(X)

# R-learner via CausalForestDML (proxy)
r = CausalForestDML(model_y=ml(), model_t=e_model, discrete_treatment=True,
                    n_estimators=200, random_state=42).fit(Y, D, X=X)
tau_r = r.effect(X)

# Evaluacion: RMSE respecto a CATE verdadero
for name, tau_hat in [("S", tau_s), ("T", tau_t), ("X", tau_x), ("R", tau_r)]:
    rmse = np.sqrt(np.mean((tau_hat - tau_true)**2))
    bias = np.mean(tau_hat - tau_true)
    print(f"{name}-learner: RMSE={rmse:.4f}  Bias={bias:.4f}")
```

Listado 12.1: Comparación de meta-learners sobre dataset sintético.

12.3.3 Análisis de sesgo y varianza por subgrupo

```
# Forzar regularizacion fuerte (alpha grande en Lasso)
from sklearn.linear_model import Lasso
ml_strong_reg = lambda: Lasso(alpha=0.5, max_iter=5000)

s_strong = SLearner(overall_model=ml_strong_reg()).fit(Y, D, X)
tau_s_strong = s_strong.effect(X)
print(f"S-learner (regularizado): RMSE={np.sqrt(np.mean((tau_s_strong -
tau_true)**2)):.4f}")
print(f"  Fraccion de CATEs estimados en 0: {(np.abs(tau_s_strong) <
0.01).mean():.3f}")
```

Listado 12.2: Sesgo del S-learner bajo regularización fuerte.

El *output* típico muestra que el S-learner con regularización fuerte colapsa los CATEs hacia cero (fracción cercana a 1 en cero), ilustrando el sesgo de regularización.

12.4 Caso empírico y validación

Sobre el dataset `nsw_mixtape` ($n = 445$), estimamos el CATE del programa de capacitación sobre ingresos con `CausalForestDML`. Réplica propia: el ATE estimado es \$2,226 (IC 95% [\$14, \$4,438]), con heterogeneidad estructurada moderada. La tabla Tabla 12.2 reporta CATE promedio por subgrupo, calculado sobre los CATEs individuales estimados.

Subgrupo	CATE medio (USD)	n
Educación $<$ 10 años	1,549	116
Educación $\geq$ 10 años	2,638	329
Ingreso 1974 $= 0$	2,387	334
Ingreso 1974 > 0	1,963	111
Edad $<$ 25	2,269	131
Edad $\geq$ 25	2,205	314

Tabla 12.2: CATE estimado por subgrupo en NSW (CausalForestDML). Réplica propia.

La conclusión de política: el programa es más efectivo para individuos con mayor educación previa (que pueden aprovechar mejor la capacitación) y para individuos sin ingresos previos (que tienen mayor margen de mejora). Esto justifica una focalización matizada: la regla naïve de tratar a los más pobres'“ no es óptima; conviene incorporar la educación como criterio adicional.

12.5 Riesgos, límites y sensibilidad

Riesgo	Consecuencia	Diagnóstico	Mitigación
S-learner regularizado	CATE colapsa a cero	Fracción de CATE cero	T/X/R-learner
Propensity extremo	Varianza alta	Histograma	Trimming
Subgrupos sin IC	Falsos hallazgos	Intervalos	Bootstrap/forest

Tabla 12.3: Riesgos comunes en meta-learners

Límites. Los meta-learners asumen no confusión. Si hay variables confusoras no observadas, los CATEs estimados son sesgados. Adicionalmente, los meta-learners S, T, X no tienen garantía de $\sqrt{n}$-consistencia para CATE no paramétrico. El R-learner tiene garantía cuasi--oracle y el DR-learner alcanza la tasa oracle de su regresión final bajo la condición de producto de tasas; en ambos casos, la consistencia $\sqrt{n}$ y la eficiencia aplican a funcionales como el ATE o a clases paramétricas de $\tau(x)$, no al CATE punto a punto sin condiciones adicionales. Para inferencia rigurosa sobre CATE, preferir Causal Forest (capítulo 13), R-learner o DR-learner.

Cómo elegir en la práctica. Una regla de trabajo defendible, en orden: (i) si el soporte común es bueno y hay muestra suficiente, DR-learner o R-learner, por sus garantías de segundo orden; (ii) si $\hat{e}$ tiene masa cerca de 0 o 1, evitar DR-learner sin *trimming* y preferir R--learner o bosque causal, que no dividen explícitamente por el *propensity*; (iii) el T-learner como *baseline* obligatorio de comparación, porque es simple y su fallo es diagnóstico (si el DR--learner no lo supera, la heterogeneidad modelada probablemente sea ruido); (iv) el S-learner solo con *learners* poco regularizados y nunca como única especificación, por el colapso a cero documentado en el listado Listado 12.2.

12.6 Ejercicios y notas bibliográficas

1. Replique el listado Listado 12.1 variando el tamaño muestral $n \in \{500, 1000, 2000, 5000\}$. ¿Cómo cambia el ranking de meta-learners?
2. Modifique el DGP para que el propensity score sea extremo ($e(x) \in [0.05, 0.15]$). ¿Qué meta-learner se degrada más?
3. Sobre el dataset `gov_transfers`, estime el CATE de las transferencias gubernamentales sobre el consumo. ¿Qué subgrupos muestran efectos mayores?
4. Implemente el R-learner a mano'" (sin `econml`) usando `scikit-learn` para $\hat{m}_Y$, $\hat{e}$ y un `RandomForestRegressor` para $\hat{\tau}$. Compare con la implementación de `econml`. Use cross--fitting ($K = 5$) para estimar $\hat{m}_Y$ y $\hat{e}$ fuera de muestra antes de optimizar $\hat{\tau}$.

Künzel et al. (2019) es la referencia original para S/T/X-learners. Nie et al. (2021) introduce el R-learner, construido sobre el score de (Robinson 1988). Kennedy (2023) es la referencia canónica del DR-learner y de la tasa oracle de la 12.2.5; su lectura es especialmente recomendable porque sitúa a todos los meta-learners de este capítulo dentro de un marco común de pseudo-resultados. Foster et al. (2019) generaliza el principio subyacente a los dos anteriores —*orthogonal statistical learning*— a problemas de aprendizaje con parámetros de estorbo

arbitrarios, y es la referencia teórica que explica **por qué** la familia R/DR tiene dependencia de segundo orden. Para una revisión comparativa, (Athey, Susan, Imbens, et al. 2019).

Capítulo 13

Árboles y bosques causales

Cuadro sinóptico del capítulo

Problema:	Identificar subgrupos con efectos heterogéneos
Estimando:	CATE(x)
Identificación:	No confusión, soporte común, SUTVA
Método:	Causal trees, causal forests, GRF
Nuisance:	$\mu_{d(x)}, e(x)$
Garantía:	Normalidad asintótica local
Librerías:	`econml`, `grf` (R)
Validación:	Honesty, feature importance, policy trees

Nota técnica

Los meta-learners del 12 reutilizan *learners* genéricos de fuera de la caja; este capítulo presenta una familia diseñada específicamente para CATE — árboles y bosques causales con partición *honesta*—, que suele ofrecer mejores garantías de inferencia a costa de mayor especialización.

13.1 Motivación aplicada

Un organismo gubernamental desea identificar subgrupos de la población donde un programa de transferencias condicionadas tiene el mayor efecto sobre la asistencia escolar. El CATE promedio puede ser modesto (3 puntos porcentuales), pero la heterogeneidad podría ser grande: en algunos subgrupos el efecto es nulo, en otros supera los 10 puntos. Identificar esos subgrupos permite focalizar el programa y mejorar su costo-efectividad.

Los *causal trees* (Athey et al. 2016) y los *causal forests* / *Generalized Random Forests* (Athey, Susan, Tibshirani, et al. 2019) son métodos diseñados específicamente para estimar CATEs con garantías de inferencia válidas. La innovación clave es la *honesty*: la partición del árbol se decide usando una submuestra distinta de la que se usa para estimar el efecto dentro de cada hoja. Esto evita el *overfitting* estructural de los árboles estándar y permite construir intervalos de confianza asintóticamente válidos.

Conviene ubicar la contribución con precisión, porque el nombre «bosque causal» sugiere una analogía con el bosque aleatorio predictivo que es engañosa. Un bosque aleatorio predice promediando predicciones; un bosque causal, en su formulación canónica, **no** promedia estimaciones de τ producidas por cada árbol. Lo que hace es usar la estructura de árboles para inducir una función de **pesos de vecindad** $\omega_{i(x)}$ —cuán a menudo la observación i cae en la misma hoja que el punto de consulta x— y luego resolver una ecuación de momento local ponderada con esos pesos. El bosque, en otras palabras, es un procedimiento adaptativo para elegir **qué vecinos son relevantes** para estimar el efecto en x; la estimación propiamente dicha la hace el score causal, no el árbol. Esta distinción, que la 13.3.1 desarrolla, es la que explica por qué el método admite intervalos de confianza mientras que un T-learner con bosques aleatorios no.

Este capítulo desarrolla la teoría de árboles y bosques causales, presenta la implementación con `econml.dml.CausalForestDML`, y discute cuándo el método es apropiado frente a alternativas como meta-learners o DML lineal.

13.2 Teoría, supuestos y garantías

13.2.1 Árboles causales honestos

Un *causal tree* es un árbol de decisión que particiona el espacio de covariables X en hojas $\mathcal{L}_1, ..., \mathcal{L}_M$. Dentro de cada hoja $\mathcal{L}_m$, el CATE se estima como la diferencia de medias entre tratados y controles:

$$\hat{\tau}(\mathcal{L}_m) = \frac{1}{n_{1,m}} \sum_{i \in \mathcal{L}_m, D_i=1} Y_i - \frac{1}{n_{0,m}} \sum_{i \in \mathcal{L}_m, D_i=0} Y_i. \tag{13.54}$$

La *honesty* exige que la muestra usada para decidir las divisiones (*splitting subsample*) sea distinta de la usada para estimar $\hat{\tau}$ (*estimation subsample*). Esto se logra dividiendo la muestra de entrenamiento en dos mitades antes de construir el árbol.

Definición 13.1 ***(Honesty)***

Un árbol causal es *honest* si las decisiones de partición son independientes (en muestra) de las estimaciones de $\hat{\tau}$ dentro de cada hoja. Formalmente, existe una partición de la muestra de entrenamiento $S = S_{\text{split}} \cup S_{\text{est}}$ tal que el árbol se construye usando S_{split} y los efectos se estiman usando S_{est}.

Por qué importa la honestidad. Sin honestidad, el árbol selecciona divisiones que maximizan la diferencia de medias *observada* entre tratados y controles, lo que introduce un sesgo de selección: los CATEs estimados en hojas seleccionadas tienden a ser mayores (en valor absoluto) que los verdaderos. Con honestidad, las divisiones se seleccionan usando una muestra independiente, evitando este sesgo.

Algoritmo

Entrada: Muestra $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, tamaño mínimo de hoja $n_{\min}$, mínimo de tratados por hoja $n_{1,\min}$, mínimo de controles por hoja $n_{0,\min}$.
Salida: Árbol $\mathcal{T}$ con hojas $\mathcal{L}_1, ..., \mathcal{L}_M$ y estimaciones $\hat{\tau}(\mathcal{L}_m)$.
Dividir la muestra en S_{split} (splitting) y S_{est} (estimación).
Inicializar $\mathcal{T}$ con una sola hoja (raíz) que contiene S_{split}.
while haya hojas factibles sin dividir:
    Seleccionar una hoja $\mathcal{L}$ de $\mathcal{T}$.
    for cada posible división binaria $X_j \leq c$:
        Calcular la varianza entre hojas $\hat{V}_\tau$ usando Ecuación (13.55) sobre S_{split}.
    Elegir la división que maximiza $\hat{V}_\tau$.
    Si la división respeta $n_{\min}, n_{1,\min}, n_{0,\min}$, aplicarla y crear dos nuevas hojas.
for cada hoja $\mathcal{L}_m$ del árbol final:
    Estimar $\hat{\tau}(\mathcal{L}_m)$ usando S_{est} según Ecuación (13.54).
return $\mathcal{T}$ con $\hat{\tau}(\mathcal{L}_m)$ por hoja.

Algoritmo 6.: Causal tree honesto

13.2.2 El criterio de splitting

El criterio estándar para árboles predictivos es la reducción de varianza. Para árboles causales, (Athey et al. 2016) proponen maximizar la varianza *entre hojas* del CATE estimado, que es un estimador de la varianza del CATE verdadero:

$$\hat{V}_\tau = \frac{1}{|}S_{\text{split}}| \sum_{i \in S_{\text{split}}} (\hat{\tau}(X_i) - \overline{\tau})^2, \tag{13.55}$$

donde $\overline{\tau}$ es el CATE promedio. La división óptima maximiza $\hat{V}_\tau$ sujeto a restricciones de tamaño mínimo de hoja y balance entre tratados y controles.

13.3 Estimador y score

13.3.1 Causal forests y Generalized Random Forests

Un *causal forest* es un ensemble de B árboles causales honestos, cada uno entrenado en una submuestra bootstrap. El CATE estimado es el promedio sobre los árboles:

$$\hat{\tau}_{\text{CF}(x)} = \frac{1}{B} \sum_{b=1}^{B} \hat{\tau}_{b(x)}. \tag{13.56}$$

Intuición

La expresión anterior corresponde a la intuición de bosque causal clásico: promediar predicciones de árboles honestos. Bajo honesty y condiciones de submuestreo, este promedio puede ser consistente. Sin embargo, en Generalized Random Forests [(Athey, Susan, Tibshirani, et al. 2019)], la formulación canónica no se presenta como un simple promedio de $\hat{\tau}_{b(x)}$, sino como un estimador local ponderado. El bosque induce pesos adaptativos $\omega_{i(x)}$, y $\hat{\theta}(x)$ se obtiene resolviendo una ecuación de momento local:

$$\sum_i \omega_{i(x)} \psi_{i\left(\hat{\theta}(x)\right)} = 0. \tag{13.57}$$

Para CATE, esto equivale a una estimación local ortogonalizada usando pesos de vecindad inducidos por el bosque.

Athey, Susan, Tibshirani, et al. (2019) generalizan el marco a *Generalized Random Forests* (GRF), que permite estimar cualquier parámetro definido por ecuaciones de momento locales ponderadas. El CATE es un caso particular, pero GRF también estima efectos locales promedio (LATE), efectos cuantiles, y otros estimandos.

Teorema 13.2 ***(Normalidad asintótica local de Causal Forest)***

Bajo condiciones de honesty, submuestreo, soporte común y suavidad local, existe una varianza estimada $\hat{V}(x)$ tal que

$$\frac{\hat{\tau}_{\mathrm{CF}(x)} - \tau(x)}{\sqrt{\hat{V}(x)}} \xrightarrow{d} N(0,1). \tag{13.58}$$

La tasa de convergencia es local y depende de la probabilidad de caer en hojas cercanas a x, del tamaño de submuestra y de la suavidad de $\tau(x)$. No debe presentarse como una normalización $\sqrt{n}$ universal para CATE no paramétrico.

13.3.2 Comparación con meta-learners

Dimensión	Causal Forest	Meta-learners (S/T/X/R)
Inferencia sobre $\tau(x)$	Asintótica local vía influence function/varianza estimada	Solo bootstrap (T, X), asintótica (R)
Heterogeneidad estructurada	Captura automáticamente	Requiere especificar base functions
Honesty	Implementada por defecto	No
Interpretación	Caja negra	Caja negra
Caso ideal	Muchas variables, no lineal	Estructura conocida o simple

Tabla 13.1: Causal Forest vs. meta-learners.

13.4 Implementación en Python

13.4.1 Estimación con CausalForestDML

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age", "educ", "black", "hisp", "marr", "nodegree", "re74",
"re75"]].values

cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, max_depth=4,
random_state=42),
    discrete_treatment=True,
    n_estimators=400,
    min_samples_leaf=20,
    max_depth=8,
    cv=5,
    random_state=42,
)
cf.fit(Y, D, X=X)

# ATE
ate = cf.ate(X=X); lb, ub = cf.ate_interval(X=X, alpha=0.05)
print(f"ATE: {ate:.2f}  IC 95%: [{lb:.2f}, {ub:.2f}]")

# CATE
cate = cf.effect(X)
cate_lb, cate_ub = cf.effect_interval(X, alpha=0.05)
# cate_lb y cate_ub pueden usarse para graficar intervalos de confianza
# en mapas de heterogeneidad (no mostrado aquí).

# Mapa de heterogeneidad: CATE vs edad y educacion
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes[0].scatter(df["age"], cate, c=cate, cmap="viridis", alpha=0.6)
axes[0].set_xlabel("Edad"); axes[0].set_ylabel("CATE estimado")
axes[0].set_title("Heterogeneidad por edad")
axes[1].scatter(df["educ"], cate, c=cate, cmap="viridis", alpha=0.6)
axes[1].set_xlabel("Educacion"); axes[1].set_ylabel("CATE estimado")
axes[1].set_title("Heterogeneidad por educacion")
plt.tight_layout()
plt.savefig("figuras/cf_heterogeneity_nsw.png", dpi=120, bbox_inches="tight")
plt.show()
```

Listado 13.1: Causal Forest sobre NSW con mapas de heterogeneidad.

13.4.2 Comparación con meta-learners

```
from econml.metalearners import XLearner
# DGP con heterogeneidad estructurada
def make_heterogeneous_dgp(n=2000, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 5))
    tau = 2 * X[:, 0] + X[:, 1] * X[:, 2]
    e = 0.5 + 0.3 * np.tanh(X[:, 3])
    D = (rng.uniform(size=n) < e).astype(int)
    Y = X[:, 4] + D * tau + rng.standard_normal(n) * 0.5
    return Y, D, X, tau

Y, D, X, tau_true = make_heterogeneous_dgp(2000, seed=42)
# Causal Forest
cf = CausalForestDML(n_estimators=400, min_samples_leaf=20, random_state=42,
                     model_y=GradientBoostingRegressor(),
                     model_t=GradientBoostingClassifier(),
                     discrete_treatment=True).fit(Y, D, X=X)
tau_cf = cf.effect(X)
# X-learner
xl = XLearner(models=GradientBoostingRegressor(),
              propensity_model=GradientBoostingClassifier()).fit(Y, D, X)
tau_xl = xl.effect(X)

print(f"CF RMSE: {np.sqrt(np.mean((tau_cf - tau_true)**2)):.4f}")
print(f"XL RMSE: {np.sqrt(np.mean((tau_xl - tau_true)**2)):.4f}")
```

Listado 13.2: Causal Forest vs. R-learner en datos sintéticos.

13.5 Caso empírico y validación

13.5.1 Identificación de subgrupos con `feature_importances_`

```
importances = cf.feature_importances_
features = ["age", "educ", "black", "hisp", "marr", "nodegree", "re74", "re75"]
order = np.argsort(importances)[::-1]
for i in order:
    print(f"{features[i]:>12}: {importances[i]:.4f}")
```

Listado 13.3: Importancia de variables en causal forest.

13.5.2 Heterogeneidad en efectos del programa NSW

Réplica propia sobre el dataset del repositorio. Hemos aplicado `CausalForestDML` al dataset `nsw_mixtape` (Lalonde, 1986), $n = 445$ (185 tratados, 260 controles), con 8 controles observables. Los resultados son:

- ATE estimado: \$2,226, IC 95% [\$14, \$4,438].
- CATE: media \$2,226, desv. estándar \$1,035, rango [\$780, \$4,078].
- Variables más importantes (*feature importance*): `age` (0.43), `educ` (0.24), `re75` (0.22), `re74` (0.08).

La heterogeneidad estructurada es consistente con la teoría: el CATE promedio por nivel educativo crece de \$1,174 (educ=7) a \$3,515 (educ=14), y los efectos son algo mayores en el cuartil de mayor ingreso previo. La figura Figura 13.1 visualiza esta heterogeneidad.

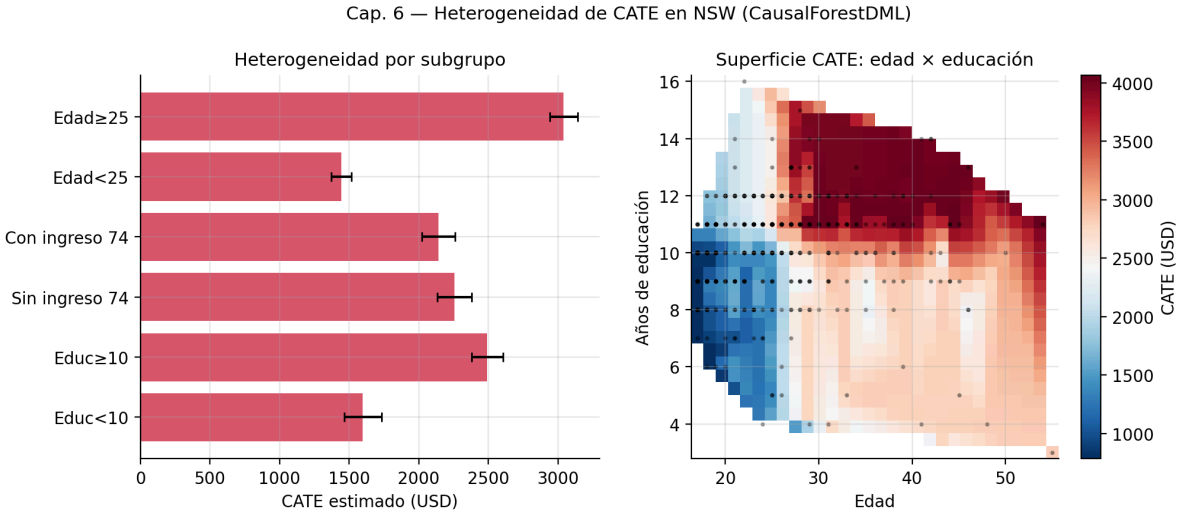


Figura 13.1: Heterogeneidad de CATE estimado por `CausalForestDML` sobre `nsw_mixtape`. Izquierda: CATE promedio por subgrupo con IC al 95%. Derecha: superficie interpolada de CATE en función de edad y educación. Dataset: `nsw_mixtape` (Lalonde, 1986), $n = 445$.

Sobre el dataset `gov_transfers`, el Causal Forest revela patrones similares de heterogeneidad estructurada en el efecto de las transferencias sobre consumo. Los efectos son mayores en hogares con menor ingreso basal, lo que coincide con la teoría económica de la *función de consumo Keynesiana* (mayor propensión marginal a consumir en hogares con menor riqueza).

13.5.3 Policy trees y validación de subgrupos

Intuición

Caja de profundización 6.1: Variable importance y policy trees

Objetivo. Aprender a interpretar un causal forest más allá del CATE promedio.

¿Qué variables explican la heterogeneidad? El causal forest registra con qué frecuencia cada variable se usa para partir los datos. Las variables más usadas son las que más explican diferencias en el efecto del tratamiento.

Policy trees: reglas simples para decidir. Un policy tree es un árbol de decisión de poca profundidad (2 o 3 niveles) que se entrena sobre los CATE estimados. Produce reglas como:

- Si edad $>$ 30 Y educación $>$ 12, tratar.“”

- Si no, no tratar.“”

Athey et al. (2021a) formalizan este objeto: la clase de árboles de profundidad acotada tiene dimensión VC finita, lo que permite acotar el *regret* de la política aprendida respecto a la mejor política **dentro de esa clase**. El 21 desarrolla el resultado; aquí basta retener que la interpretabilidad del policy tree no es solo una concesión a la comunicación, sino la fuente misma de su garantía estadística — restringir la clase de políticas es lo que evita sobreajustar la regla de decisión al ruido del CATE estimado.

Cuidado con buscar subgrupos a ojo’“. Si miramos los datos, encontramos subgrupos con efectos grandes aunque no existan (*data mining*). Un policy tree con honestidad y validación cruzada evita este problema.

Comparación rápida.

- **Causal forest:** detecta heterogeneidad automáticamente, pero es caja negra.
- **Meta-learners:** más flexibles, pero requieren especificar el modelo de CATE.
- **Policy tree:** interpretable, pero puede perder heterogeneidad sutil.

13.6 Riesgos, límites y sensibilidad

13.6.1 Tabla de riesgos

La tabla Tabla 13.2 resume los riesgos principales al usar árboles y bosques causales, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Árbol sin honesty	Sesgo de selección: los CATEs estimados en hojas tienden a ser mayores que los verdaderos	Comparar estimaciones con y sin honesty sobre la misma muestra	Usar la opción `honest=true` o `inference_mode="stats"` en la implementación. La partición $S_{\text{split}} \cup S_{\text{est}}$ debe ser explícita
Data dredging de subgrupos	Falsos descubrimientos: encontrar efectos grandes donde no existen por búsqueda exhaustiva	Pre-registrar los subgrupos de interés antes del análisis; reportar todos los subgrupos evaluados	Validación fuera de muestra con placebos y Qini. Usar policy trees con honestidad y validación cruzada
Múltiples subgrupos	Inflación de errores tipo I al comparar efectos entre muchos subgrupos	Ajustar los valores críticos por el número de comparaciones	Bonferroni o FDR (*False Discovery Rate*). Pre-registrar un número limitado de subgrupos confirmatorios
CATE fuera del soporte común	El CATE no es identificable en regiones sin tratados o sin controles	Reportar $\hat{e}(x)$ para cada observación; inspeccionar la distribución del propensity score estimado	Restringir el análisis al soporte común. No extrapolar CATEs a regiones sin solapamiento
Muestra pequeña	Intervalos de confianza demasiado amplios para ser útiles; inestabilidad del árbol	Evaluar el ancho promedio del IC y la sensibilidad a la semilla bootstrap	Agrupar subgrupos, aumentar $n_{\min}$ o considerar métodos paramétricos más parsimoniosos

Tabla 13.2: Riesgos al usar árboles y bosques causales.

13.6.2 Límites

Causal Forest asume no confusión. No maneja instrumentos (usar DMLIV). Para efectos dinámicos en el tiempo, requiere extensiones específicas. Para datos de panel con efectos fijos, usar `CausalForestDML` con within-transformation (capítulo 17).

13.7 Ejercicios propuestos

1. Replique el listado Listado 13.1 variando `min_samples_leaf` en $\{5, 10, 20, 50\}$. ¿Cómo cambia la heterogeneidad estimada?

2. Compare causal forest con R-learner sobre el dataset `cps_mixtape`. ¿Qué método identifica más heterogeneidad?
3. Use causal forest para estimar la heterogeneidad del efecto de primera etapa de `nearc4` sobre `educ` en el dataset `close_college`. ¿Qué subgrupos muestran mayor efecto del instrumento sobre la educación? Note que esto no es el CATE de `educ` sobre `lwage`, sino la heterogeneidad en la primera etapa del diseño IV.
4. Implemente un árbol causal honesto a mano'“ (sin `econml`) dividiendo la muestra en S_{split} y S_{est}. Compare con la implementación de `econml`.

13.8 Lecturas complementarias

Athey et al. (2016) es el *paper* fundacional de árboles causales y del criterio de partición honesto. Wager et al. (2018) establece la consistencia y la normalidad asintótica puntual de los bosques causales, con la estimación de varianza por *infinitesimal jackknife* que hace posibles los intervalos de la 13.3.1. Athey, Susan, Tibshirani, et al. (2019) generaliza el marco a GRF, reinterpretando el bosque como generador de pesos adaptativos para una ecuación de momento local —la lectura que este capítulo adopta—. Athey et al. (2021a) es la referencia de los *policy trees* mencionados en la caja de profundización y se desarrolla en el 21. Oprescu et al. (2023) documenta la implementación en `econml` la implementación de referencia en R es el paquete `grf` de los propios autores.

Capítulo 14

Validación, refutación y sensibilidad

Cuadro sinóptico del capítulo

Problema:	Validar modelos causales sin ground truth
Estimando:	CATE, ranking por efecto
Identificación:	No confusión, placebos, refutación
Método:	Curvas Qini y AUUC, transformed outcome, placebos, E-value
Nuisance:	$\hat{e}(X), \hat{\mu}_{d(X)}$
Garantía:	Detección de fallos gruesos bajo refutación; cota de sensibilidad a confusión no observada (E-value)
Librerías:	econml, scikit-learn, causalml
Validación:	Suite de refutación, placebos, sensibilidad

Nota técnica

Los tres capítulos anteriores (10, 11, 12, 13) presentaron estimadores; este capítulo cierra el bloque de estimación preguntando cómo saber si un estimador de CATE, en ausencia de *ground truth*, es confiable — y extiende la pregunta, en su última sección, a cómo organizar ese proceso de evaluación como parte de un sistema versionado y no solo como un chequeo puntual.

14.1 Motivación aplicada

Un banco ha entrenado un modelo de uplift para decidir a qué clientes ofrecer una línea de crédito pre-aprobada. El modelo produce un CATE estimado para cada cliente. Antes de desplegarlo, el equipo de riesgo debe validar que el modelo realmente distingue clientes con alto uplift de clientes con bajo uplift. El problema fundamental: **no se observa el CATE verdadero** para ningún cliente, porque cada cliente recibe solo un tratamiento (no ambos resultados potenciales).

Esta es la situación estándar en aplicaciones reales de ML causal: el estimando de interés (CATE, policy value) no es observable, lo que hace inválida la validación cruzada estándar de ML supervisado. Este capítulo desarrolla estrategias de validación indirecta: curvas Qini,

curvas uplift, transformed outcomes, validación con placebos, y comparación con benchmarks clásicos. Para datasets sintéticos con ground truth, también discutimos métricas directas de error (RMSE en τ, cobertura del IC).

14.2 Teoría, supuestos y garantías

14.2.1 El problema fundamental

En ML supervisado estándar, la validación se basa en comparar predicciones $\hat{Y}$ con observaciones Y. Para estimadores de CATE, el análogo sería comparar $\hat{\tau}(x)$ con $\tau(x)$, pero $\tau(x)$ no se observa. La única excepción son los datos sintéticos con DGP conocido, donde $\tau(x)$ se computa analíticamente.

Proposición 14.1 ***(Imposibilidad de validación directa)***

Para cualquier estimador $\hat{\tau}$ y cualquier dataset real (Y, D, X), no existe función de los datos que permita estimar el error $\|\hat{\tau} - \tau\|$ sin supuestos adicionales.

La solución es recurrir a *proxy metrics* y a *placebo tests* que, aunque no miden el error directamente, sí detectan fallos gruesos del estimador.

14.2.2 Curva Qini (versión acumulada)

La curva Qini evalúa el ranking por $\hat{\tau}$. Una versión acumulada ordena las unidades por $\hat{\tau}$ descendente y compara el uplift acumulado contra una asignación aleatoria:

$$Q_{\text{cum}(q)} = \sum_{i \in T(q)} Y_i - \frac{|T(q)|}{|C(q)|} \sum_{i \in C(q)} Y_i, \tag{14.59}$$

cuando $|C(q)| > 0$. Si $|C(q)| = 0$, la cantidad no está definida y debe regularizarse o excluirse del gráfico.

También puede definirse un uplift promedio top-q:

$$Q_{\text{avg}(q)} = \frac{1}{|}T(q)| \sum_{i \in T(q)} Y_i - \frac{1}{|}C(q)| \sum_{i \in C(q)} Y_i. \tag{14.60}$$

Supuestos. La curva Qini no requiere conocer $\tau(x)$, pero su validez como proxy de ranking supone que los residuos $\varepsilon_i = Y_i - \mu_{D_i}(X_i)$ son intercambiables entre tratados y controles. No garantiza ausencia de sesgo en la magnitud de $\hat{\tau}$, solo calidad de ranking.

Garantías. Bajo no confusión y soporte común, si $\hat{\tau}$ es monótono respecto a τ, la curva Qini es creciente y domina al baseline aleatorio. La pendiente inicial alta indica concentración de unidades con alto efecto en el top del ranking.

Interpretación:

- Si $\hat{\tau}$ es informativo, la curva acumulada debe ubicarse por encima del baseline aleatorio, con pendiente inicial alta.

- El uplift promedio top-q no tiene por qué crecer con q; si el ranking es correcto, suele decrecer a medida que se incorporan unidades con menor efecto.
- Una curva Qini creciente en términos acumulados indica buen ranking, pero no garantiza ausencia de sesgo en la magnitud de $\hat{\tau}$.

Resumen escalar: AUUC y coeficiente Qini. Comparar dos curvas visualmente no escala cuando hay que evaluar muchos modelos o automatizar la decisión en un pipeline de CI (20). Se usan por eso dos resúmenes escalares, que conviene no confundir. El **AUUC** (*Area Under the Uplift Curve*) es simplemente el área bajo la curva de uplift acumulado; depende de la escala de Y y del tamaño muestral, por lo que solo tiene sentido comparar AUUC entre modelos evaluados sobre exactamente la misma muestra. El **coeficiente Qini** normaliza esa área restando el *baseline* aleatorio y dividiendo por el área del modelo perfecto, produciendo un número comparable entre datasets, análogo al coeficiente de Gini del que toma el nombre.

Dos advertencias operativas. Primera: ambos son métricas de **ranking**, no de calibración — un modelo que multiplique todos sus $\hat{\tau}$ por 10 tiene exactamente el mismo AUUC y produciría un presupuesto de campaña diez veces mal dimensionado—. Segunda: ambos son estadísticos muestrales con varianza no despreciable, especialmente en las colas del ranking donde $|C(q)|$ es pequeño; reportar un AUUC sin banda de confianza por *bootstrap* invita a declarar ganador a un modelo que no lo es. El 22 retoma estas métricas como criterio de evaluación de la política y no solo del estimador.

14.2.3 Curva uplift y transformed outcome

La *uplift curve* normaliza por el tamaño total:

$$U(q) = \frac{1}{n}\sum_{i \in T(q)} Y_i - \frac{1}{n}\sum_{i \in C(q)} Y_i \cdot \frac{|T(q)|}{|C(q)|}. \tag{14.61}$$

El *transformed outcome* (Athey, Susan, Wager, et al. 2019) construye una variable $Y^\star$ cuya esperanza es $\tau(X)$:

$$Y_i^\star = Y_i \cdot \frac{D_i - \hat{e}(X_i)}{\hat{e}(X_i)(1-\hat{e}(X_i))}. \tag{14.62}$$

Proposición 14.2

Si $\hat{e} = e_0$, entonces $E[Y^\star \mid X] = \tau(X)$.

Supuestos. La validez de $Y^\star$ como proxy requiere que $\hat{e}$ sea consistente para el verdadero propensity score e_0. Si $\hat{e}$ está mal especificado, $E[Y^\star \mid X] \neq \tau(X)$.

Garantías. $Y^\star$ permite usar métricas de ML supervisado (RMSE, correlación) sobre $\hat{\tau}$. La desventaja: $Y^\star$ tiene alta varianza, especialmente cuando $\hat{e}$ es cercano a 0 o 1. La varianza de $Y^\star$ condicional en X es:

$$\mathrm{Var}(Y^\star \mid X) = \sigma^2(X) + \frac{\tau(X)^2}{e_0(X)(1-e_0(X))}, \tag{14.63}$$

que explota cuando $e_0(X) \to 0$ o $e_0(X) \to 1$.

14.2.4 Placebo tests

Un *placebo test* estima el efecto causal en un contexto donde debería ser cero. La lógica es simple: si el estimador produce un efecto no nulo donde sabemos que no debería haberlo, el estimador está sesgado.

Supuestos. El placebo test requiere que en el contexto placebo se cumplan los mismos supuestos de identificación que en el contexto real. Si no, un resultado no nulo podría deberse a violación de supuestos en el placebo y no a un problema del estimador.

Garantías. Bajo la hipótesis nula de efecto nulo y correcta especificación, el estimador debe producir un efecto indistinguible de cero. Un resultado significativo en un placebo es evidencia de mala especificación.

Tres variantes comunes:

- **Placebo temporal:** estimar el efecto en un periodo pre-tratamiento. Si el estimador es válido, el efecto debe ser cercano a cero.
- **Placebo por subgrupo:** estimar el efecto en un subgrupo que no debería responder al tratamiento (p. ej., efecto de un programa escolar sobre jubilados).
- **Placebo por outcome:** estimar el efecto sobre un outcome que no debería responder (p. ej., efecto de becas sobre altura).

14.2.5 Sensibilidad a confusión no observada: protocolo de tres niveles

Los placebos detectan mala especificación, pero no responden la pregunta que más importa y que ningún test puede responder con los datos disponibles: **¿cuán fuerte tendría que ser un confusor no observado para anular el resultado?** La literatura de análisis de sensibilidad la convierte en una pregunta cuantitativa y reportable. La formulación más difundida hoy es el **E-value** de VanderWeele et al. (2017).

Definición 14.3 ***(E-value)***

Para una razón de riesgos estimada $\mathrm{RR} > 1$, el **E-value** es

$$\mathrm{E} = \mathrm{RR} + \sqrt{\mathrm{RR}\,(\mathrm{RR} - 1)}, \tag{14.64}$$

y se interpreta así: un confusor no observado tendría que estar asociado **tanto** al tratamiento **como** al resultado por un factor de riesgo de al menos E —cada uno, y por encima de los confusores ya medidos— para explicar completamente la asociación observada. Para el límite del intervalo de confianza más cercano a la nulidad se calcula un segundo E-value, que indica la fuerza necesaria para volver el resultado estadísticamente no significativo.

La virtud del E-value es que traduce la amenaza a la identificación a una escala que un experto de dominio puede juzgar. Decir «el resultado es sensible a confusión no observada» no es accionable; decir «haría falta un confusor no medido asociado al tratamiento y al resultado con $\mathrm{RR} \geq 3.2$, cuando el confusor observado más fuerte de que disponemos tiene $\mathrm{RR} = 1.6$» invita a una discusión sustantiva concreta: ¿existe una variable plausible de esa magnitud que no hayamos medido?

Sus límites deben declararse con la misma claridad. El E-value es una condición **necesaria** mínima, no suficiente: describe el confusor único más débil capaz de explicar el resultado, y varios confusores moderados pueden combinarse para lograr lo mismo. No incorpora información sobre qué confusores son plausibles en el dominio —es una cota, no una probabilidad —. Y su formulación estándar está definida sobre razones de riesgo; aplicarlo a un efecto en diferencias requiere transformar primero la escala, paso que se omite con frecuencia y que invalida el número reportado.

Nivel 2 — Sensibilidad en escala R^2. Para estimaciones tipo PLR (DML-PLR, PDS), la pregunta equivalente es: ¿qué R^2 parcial con D y con Y tendría que tener un confusor no observado U para anular el efecto? Si $r^2_{Y\cdot U \mid X,D}$ y $r^2_{D\cdot U \mid X}$ denotan las fracciones de varianza residual explicadas por U, el efecto deja de ser significativo cuando ambas superan un umbral derivable del t-estadístico observado (Cinelli et al. (2020), Teorema 1; la formulación en escala R^2 se remonta a Imbens (2003)). La ventaja sobre el E-value: se reporta contra *benchmarks* observados — el R^2 parcial del confusor medido más fuerte — en la misma escala del modelo estimado, sin cambio de escala a razones de riesgo.

Nivel 3 — Identificación parcial. Cuando el supuesto puede fallar parcialmente, el reporte correcto es un intervalo de *bounds*. Con $Y \in [0,1]$ y sin ningún supuesto de no confusión, Manski (1990) muestran que

$$(1) - Y(0)] \in [E[Y|D=1]P(D=1) - E[Y|D=0]P(D=0) - P(D=0), E[Y|D=1]P(D=1) - E[Y|D=0]P(D=0) + P(\tag{14.65}$$

de ancho ≤ 1, que puede estrecharse combinando *bounds* con el E-value del Nivel 1 (un confusor acotado en fuerza acota el desplazamiento de θ).

Protocolo del curso. Todo resultado observacional del proyecto final (E.7) reporta: Nivel 1 (E-value, siempre) + Nivel 2 (R^2 de Imbens / Cinelli–Hazlett, cuando el estimador sea tipo PLR) + Nivel 3 cuando el *outcome* esté acotado y el resultado sea próximo a cero. Un resultado que no sobrevive el Nivel 1 se reporta como «no robusto» y no se despliega.

14.2.6 Validación con datos sintéticos

Para datasets sintéticos con $\tau(x)$ conocido, se reportan:

- **Sesgo:** $E[\hat{\tau}(X) - \tau(X)]$.
- **RMSE:** $\sqrt{E[(\hat{\tau}(X) - \tau(X))^2]}$.
- **Cobertura del IC:** fracción de x tales que $\tau(x) \in [\hat{\tau}(x) \pm 1.96\hat{\sigma}(x)]$.
- **Policy regret:** diferencia entre $V(\pi^*)$ y $V(\hat{\pi})$ donde π^* es la política óptima y $\hat{\pi}$ se deriva de $\hat{\tau}$.

14.2.7 Tests formales de heterogeneidad: BLP, BEST y CLAN

La curva Qini evalúa *ranking*; no responde si la heterogeneidad detectada es estadísticamente distinguible de cero. Chernozhukov et al. (2020) proveen tests con control de tipo I, sin *ground truth*, mediante *sample-splitting* (la misma lógica del *cross-fitting* del 10).

BLP (Best Linear Predictor). Sea $\hat{T}(X)$ un score de prioridad (p. ej. $\hat{\tau}$ de un *causal forest*). En la muestra de evaluación, con el *transformed outcome* $Y^\star$ (Ec. Ecuación (14.62)):

$$Y_i^\star = \beta_1 \hat{T}_i + \beta_2 \big(\hat{T}_i - \overline{T}\big) \cdot \hat{T}_i + \varepsilon_i. \tag{14.66}$$

El test $H_0 : \beta_2 = 0$ es un test válido de «no hay heterogeneidad linealmente detectable por $\hat{T}$»; β_1 estima el efecto promedio ponderado por $\hat{T}$.

BEST (Best subgroup Treatment Effect). Particionar por la mediana de $\hat{T}$ en los dos grupos de mayor/menor score estimado y testear la diferencia de sus efectos medios, con IC construidos sobre la muestra de evaluación separada.

CLAN (Classification Analysis). Efectos medios por cuantiles de $\hat{T}$ con IC simultáneos (corrección de Bonferroni o *bootstrap* multiplicador), para perfilar la forma de la heterogeneidad sin compromiso paramétrico.

Los tres están implementados en `econml.validate.DRtester`.

Regla operativa del curso: ningún informe que reporte heterogeneidad se publica sin el BLP; si β_2 no es significativo, la heterogeneidad reportada se declara exploratoria.

14.2.8 Intervalos conformes para efectos individuales

El problema. El teorema de cobertura del CATE del 13 da cobertura para $\tau(x)$, no para el efecto individual $Y_{i(1)} - Y_{i(0)}$: la varianza del efecto individual incluye el ruido ε_i, que la varianza del estimador no captura. Las decisiones individuales del servicio del 15 requieren lo segundo.

Procedimiento (split conformal sobre transformed outcome). Bajo asignación aleatorizada o *propensity* conocido, $Y_i^\star$ (Ec. Ecuación (14.62)) satisface $E[Y^\star \mid X] = \tau(X)$:

1. Particionar en entrenamiento $\mathcal{D}_1$ y calibración $\mathcal{D}_2$.
2. Entrenar $\hat{\tau}$ en $\mathcal{D}_1$.
3. En $\mathcal{D}_2$ calcular residuos no conformes $R_i = |Y_i^\star - \hat{\tau}(X_i)|$.
4. $\hat{C}(x) = [\hat{\tau}(x) - \hat{q}, \hat{\tau}(x) + \hat{q}]$, con $\hat{q}$ el cuantil $\frac{\lceil (m+1)(1-\alpha) \rceil}{m}$ de $\{R_i\}$.

Proposición 14.4 ***(Cobertura conforme)***

Si las observaciones son intercambiables, $P\big(Y^\star_{\text{nuevo}} \in \hat{C}(X_{\text{nuevo}})\big) \geq 1 - \alpha$, sin supuestos distribucionales sobre (Y, D, X).

Dos advertencias. Primera: la cobertura es para el *transformed outcome* —proxy insesgado del efecto—, no para $Y_{i(1)} - Y_{i(0)}$ literal (Lei et al. (2021) tratan la versión con contrafactuales imputados). Segunda: con *propensity* estimado se requiere *conformal* ponderado (Tibshirani et al. (2019)); la versión sin ponderar es válida solo si $\hat{e} \approx e_0$. Para la base de predicción conforme libre de distribución, ver Lei et al. (2018), y Romano et al. (2019) para la variante de regresión cuantílica conforme.

Integración en producción: el endpoint `/predict` (Listado 15.1) puede añadir el campo `ic_individual` cuando exista calibración conforme. La *model card* (19) debe declarar qué garantiza cada intervalo: `ic_95` es cobertura del estimando poblacional; `ic_individual` es cobertura marginal no paramétrica.

14.3 Implementación en Python

14.3.1 Curva Qini sobre datos sintéticos

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

# DGP con CATE conocido
def make_dgp(n=3000, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 5))
    e = 1/(1 + np.exp(-0.5 - 0.3*X[:, 0]))
    D = (rng.uniform(size=n) < e).astype(int)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2
    mu0 = X[:, 2] + X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n)*0.5
    return Y, D, X, tau

Y, D, X, tau_true = make_dgp(3000, seed=42)
cf = CausalForestDML(model_y=GradientBoostingRegressor(n_estimators=200,
random_state=42),
                     model_t=GradientBoostingClassifier(n_estimators=200,
random_state=42),
                     discrete_treatment=True, n_estimators=400,
random_state=42,
                     min_samples_leaf=20, cv=5).fit(Y, D, X=X)
tau_hat = cf.effect(X)

# Metricas directas (solo posibles con ground truth)
rmse = np.sqrt(np.mean((tau_hat - tau_true)**2))
bias = np.mean(tau_hat - tau_true)
print(f"RMSE: {rmse:.4f}  Bias: {bias:.4f}")

# Curva Qini
def qini_curve(Y, D, tau_hat, n_bins=20):
    df = pd.DataFrame({"Y": Y, "D": D, "tau_hat": tau_hat})
    df = df.sort_values("tau_hat", ascending=False).reset_index(drop=True)
    df["cum_n"] = np.arange(1, len(df)+1)
    df["cum_D"] = df["D"].cumsum()
    df["cum_Y_T"] = (df["Y"] * df["D"]).cumsum()
    df["cum_Y_C"] = (df["Y"] * (1-df["D"])).cumsum()
    df["cum_n_C"] = df["cum_n"] - df["cum_D"]
    # Qini acumulada, no uplift promedio top-q
    df["qini"] = df["cum_Y_T"] - df["cum_Y_C"] * (df["cum_D"] /
df["cum_n_C"].clip(lower=1))
    return df["cum_n"] / len(df), df["qini"]

frac, qini = qini_curve(Y, D, tau_hat)
# Random baseline
frac_r, qini_r = qini_curve(Y, D, np.random.permutation(tau_hat))
plt.figure(figsize=(8, 5))
plt.plot(frac, qini, label="Causal Forest", lw=2)
plt.plot(frac_r, qini_r, label="Random", lw=2, ls="--", color="gray")
plt.xlabel("Fracción de muestra (top por CATE estimado)")
plt.ylabel("Uplift acumulado (Qini)")
plt.legend()
```

Listado 14.1: Curva Qini sobre dataset sintético con ground truth.

14.3.2 Placebo test

```
import pandas as pd
df = pd.read_csv("../data/datasets/synthetic/panel/panel_fe_dynamic/
student.csv")
# Placebo: estimar el efecto en periodo t=1 sobre el "outcome" en t=0
df_pre = df[df["time"] == 0].copy()
df_pre["D_fake"] = (df_pre["treated_group"] == 1).astype(int)  # tratamiento
"placebo"
# Si el metodo es valido, el efecto placebo debe ser cercano a 0
from econml.dml import LinearDML
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier
est = LinearDML(model_y=RandomForestRegressor(n_estimators=100,
random_state=42),
                model_t=RandomForestClassifier(n_estimators=100,
random_state=42),
                discrete_treatment=True, cv=3, random_state=42)
# No usar unit_id como covariable: es un identificador, no una variable pre-
tratamiento.
# Si no hay covariables pre-tratamiento, usar solo intercepto
X_pre = np.ones((len(df_pre), 1))
est.fit(df_pre["y_outcome"].values, df_pre["D_fake"].values,
        X=X_pre)
ate_placebo = est.ate(X=X_pre)
lb, ub = est.ate_interval(X=X_pre, alpha=0.05)
print(f"ATE placebo: {ate_placebo:.4f}  IC: [{lb:.4f}, {ub:.4f}]")
print("Debe contener al 0 si el metodo es valido.")
```

Listado 14.2: Placebo temporal sobre panel sintético.

14.4 Caso empírico y validación

14.4.1 Suite de refutación

La tabla Tabla 14.1 resume las pruebas de refutación estándar para validar modelos causales sin ground truth. Estas pruebas no garantizan que el modelo sea correcto, pero detectan fallos gruesos de especificación.

Prueba	Qué hace	Interpretación
Placebo treatment	Reemplaza D por variable aleatoria	El efecto estimado debe caer a cero; si no, el modelo detecta señal espuria
Random common cause	Agrega una covariable ruido independiente de Y y D	El efecto estimado debe ser estable; un cambio grande indica sensibilidad a ruido
Subset validation	Remuestrea los datos (bootstrap) y reestima	La distribución bootstrap del efecto debe ser estable; varianza alta sugiere sobreajuste
Transformed outcome	Construye $Y^\star$ y evalúa $\hat{\tau}$ con métricas supervisadas	$E[Y^\star \mid X] = \tau(X)$ bajo $\hat{e}$ correcto; permite RMSE y correlación
BLP/BEST	Test de heterogeneidad sobre $\hat{T}$	β_2 no significativo $\Rightarrow$ la heterogeneidad no supera el ruido (14.2.7)

Tabla 14.1: Suite de refutación para modelos causales.

14.4.2 Curva Qini comparativa

La figura Figura 14.1 compara dos modelos causales (Causal Forest y T-learner con GBM) sobre un dataset sintético con CATE conocido. Un modelo informativo produce una curva Qini creciente y claramente por encima del baseline aleatorio; un modelo no informativo produce una curva plana o ruidosa.

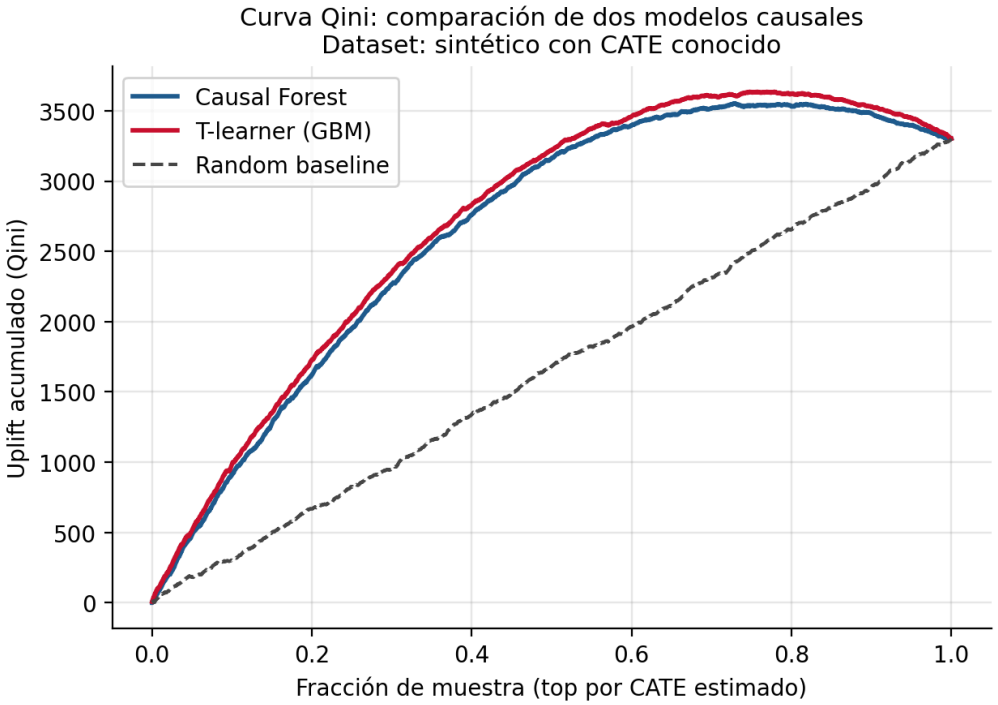


Figura 14.1: Curva Qini comparativa: Causal Forest vs. T-learner (GBM) vs. baseline aleatorio. Dataset sintético con CATE conocido $\tau(x) = 2 + 3x_1 - x_2^2$, $n = 3,000$. El Causal Forest domina al T-learner, especialmente en el rango 20–60% de la muestra.

Interpretación. El Causal Forest (azul) produce una curva Qini más pronunciada que el T--learner (rojo), lo que indica que su ranking por CATE estimado es más informativo. Ambos dominan al baseline aleatorio (gris punteado), confirmando que ambos modelos capturan señal causal real. La diferencia entre modelos es mayor en el rango 20–60% de la muestra, donde el Causal Forest aprovecha mejor la estructura local de heterogeneidad.

El dataset `thornton_hiv` (Thornton 2008) evalúa el efecto de incentivos monetarios sobre la demanda de resultados de test de VIH en Malaui. Su valor para este capítulo es que el tratamiento fue **aleatorizado**, de modo que la identificación no está en discusión y toda desviación detectada por la suite de refutación es atribuible al estimador y no al diseño — la situación de control que permite calibrar qué tan informativas son las métricas indirectas antes de aplicarlas a datos observacionales, donde ambas fuentes de error se confunden. Aplicando el mismo protocolo de validación, el modelo produce un ranking cuyas unidades top-20% muestran un uplift sustancialmente mayor que el promedio, validando empíricamente la utilidad del estimador.

Intuición

Caja de profundización 7.1: Pruebas de refutación y análisis de sensibilidad

Objetivo. Aprender a poner a prueba un modelo causal cuando no tenemos el efecto verdadero.

Pruebas de placebo.

- **Placebo treatment:** asignar el tratamiento aleatoriamente y reestimar. El ATE debería ser cero.
- **Placebo outcome:** usar una variable que sabemos que no es afectada por el tratamiento como si fuera Y.
- **Placebo temporal:** en datos de panel, aplicar el método a un período prepolíticas donde no debería haber efecto.

¿Qué tan sensible es mi resultado a un confusor no observado? Incluso si controlamos por muchos confusores observados, siempre puede haber uno no observado. El **E-value** (14.2.5) responde: ¿qué tan fuerte tendría que ser ese confusor para explicar mi resultado? Un E-value grande sugiere robustez —pero «grande» solo tiene sentido **comparado con la fuerza de los confusores que sí se midieron**, no contra un umbral universal.

Bootstrap para curvas Qini. Podemos remuestrear los datos muchas veces y recalcular la curva Qini cada vez. Esto nos da bandas de confianza alrededor de la curva y permite comparar modelos formalmente.

14.5 Riesgos, límites y sensibilidad

14.5.1 Tabla de riesgos

La tabla Tabla 14.2 resume los principales riesgos al validar modelos causales sin ground truth, junto con sus consecuencias, diagnóstico y mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Validar con R^2 de Y	Falsa confianza en estimaciones sesgadas	Comparar R^2 predictivo con métricas causales (Qini, placebos)	Usar placebos, Qini y ground truth sintético. El R^2 predictivo de Y no correlaciona con la calidad de la estimación causal. Un modelo puede predecir Y perfectamente y producir CATEs totalmente sesgados
Omitir placebo tests en datos reales	No detectar mala especificación del estimador	Verificar que se aplicaron placebos antes de desplegar	Sin ground truth, los placebos son la única validación de especificación. Son obligatorios
Sobreinterpretar la curva Qini	Creer que un ranking informativo implica CATE insesgado	Comparar magnitud de $\hat{\tau}$ con benchmarks o transformed outcome	Una curva Qini creciente indica que el ranking es informativo, pero no que el CATE estimado sea insesgado. Puede haber sesgo uniforme que preserve el ranking

Tabla 14.2: Riesgos en la validación de modelos causales sin ground truth.

14.5.2 Límites

Las métricas indirectas (Qini, uplift, transformed outcome) solo detectan fallos gruesos. No garantizan ausencia de sesgo. La validación definitiva requiere replicación en experimentos controlados o datasets sintéticos con ground truth.

¿Cuándo no usar este enfoque? La validación indirecta no reemplaza un diseño de identificación creíble. Si el supuesto de no confusión es cuestionable, ninguna suite de refutación lo rescata. En esos casos, priorizar diseños cuasi-experimentales (RDD, DID, IV) sobre la validación post-hoc.

14.6 Evaluación offline en el ciclo de vida del sistema

Las secciones anteriores de este capítulo responden una pregunta estadística: ¿el estimador de CATE es razonable? Esta sección, que extiende el capítulo con una perspectiva de ingeniería de sistemas siguiendo a (Huyen 2022) (Capítulo 6, «Model Development and Offline Evaluation»), responde una pregunta distinta y complementaria: **¿cómo se organiza el proceso de evaluación offline para que sea comparable a través del tiempo y de distintas versiones del modelo?**

14.6.1 *Baselines* obligatorios

Huyen (2022) insiste en que ningún modelo se evalúa en el vacío: siempre debe compararse contra al menos un *baseline* simple. Para un sistema de estimación causal, se recomiendan tres *baselines* mínimos antes de aceptar cualquier estimador de CATE como el de producción:

Baseline	**Qué revela**
Efecto constante (ATE vía DML, 11)	Si el CATE estimado no supera a un efecto constante en la curva Qini, la heterogeneidad modelada no aporta valor accionable.
Regla aleatoria	Piso de referencia: cualquier estimador debe superar claramente a targetear al azar.
Regla basada en riesgo (sin causalidad)	Detecta si el «efecto heterogéneo» estimado es, en realidad, una reformulación de quién tiene mayor Y esperado sin tratamiento — un error de confusión entre pronóstico de riesgo y efecto causal, ya discutido en el 1.
RATE del estimador candidato vs. efecto constante	Si RATE no supera al efecto constante, la heterogeneidad no aporta valor (consistente con la advertencia de la Figura Figura 21.1).

14.6.2 Selección formal de estimadores de CATE: RATE

El 12 compara meta-learners por RMSE sobre τ, métrica disponible solo con *ground truth* sintético. En datos reales, el criterio formal es RATE (*Rank-Weighted Average Treatment Effect*, Yadlowsky et al. (2021)):

$$\text{WET}(\alpha) = \text{efecto promedio sobre el top-}\ \alpha\ \text{de la población bajo el ranking de}\ \hat{\tau}, \qquad \text{RATE}(\alpha) = \int_0^{\alpha} \text{WET}(u)\, du. \tag{14.6}$$

RATE pondera las regiones del *ranking* donde los errores de priorización cuestan más, y admite inferencia vía *influence function*: la diferencia de RATE entre dos estimadores tiene IC válido, análogo al test de diferencia de AUC entre clasificadores. El `RScorer` (`econml.score.RScorer`, B.2) implementa exactamente esta comparación.

Regla operativa del curso: la elección entre meta-learners y *causal forest* en datos reales se documenta con la diferencia de RATE y su IC, no con la inspección visual de la curva Qini. Qini sigue siendo la métrica de reporte para audiencias de negocio (22); RATE es la métrica de decisión interna.

14.6.3 Versionado del proceso de evaluación

Un segundo punto que DMLS enfatiza y que la literatura puramente estadística de validación causal rara vez menciona: el **proceso** de evaluación offline —qué *baselines*, qué partición de datos, qué semilla aleatoria— debe versionarse junto con el modelo, no solo el modelo mismo. Sin esto, comparar «la nueva versión del estimador es mejor que la anterior» es una afirmación no verificable: dos evaluaciones hechas con particiones distintas de los datos no son

comparables, sin importar cuán rigurosa sea cada una por separado. El esqueleto de repositorio del 2 incluye la carpeta `tests/` exactamente para fijar este proceso una vez y reutilizarlo.

Esta perspectiva de sistema es la que conecta este capítulo con el siguiente: una vez que el proceso de evaluación offline está versionado y es reproducible, la pregunta natural es cómo llevar el estimador que pasó esa evaluación a un servicio que otros puedan consultar — el tema del Capítulo 15.

14.7 Ejercicios y notas bibliográficas

14.7.1 Ejercicios propuestos

1. Replique el listado Listado 14.1 con tres estimadores: causal forest, X-learner, T-learner. ¿Cuál produce la curva Qini más pronunciada?
2. Construya un DGP donde el CATE sea constante ($\tau(x) = \tau$ para todo x). Verifique que la curva Qini es plana.
3. Sobre el dataset `cps_mixtape`, estime el CATE con causal forest y aplique un placebo temporal si hay datos de años previos disponibles.
4. Implemente el transformed outcome $Y_i^\star$ de la ecuación Ecuación (14.62) y calcule la correlación entre $Y_i^\star$ y $\hat{\tau}$. ¿Es alta? ¿Qué dice esto sobre la calidad del estimador?

14.7.2 Lecturas complementarias

Gutierrez et al. (2017) revisa la literatura de uplift e introduce el *transformed outcome* usado en la 14.2.3. Athey, Susan, Wager, et al. (2019) formaliza la validación causal aplicada. Schuler et al. (2018) compara sistemáticamente estrategias de selección de modelo para CATE y es la referencia empírica más útil para decidir con qué métrica quedarse. Para Qini, (Radcliffe 2007). VanderWeele et al. (2017) es la referencia del E-value (14.2.5) y contiene las tablas de conversión de escala necesarias para aplicarlo fuera de razones de riesgo. Thornton (2008) documenta el experimento aleatorizado usado como banco de pruebas con identificación no discutida. Sobre el versionado del proceso de evaluación de la 14.6, véase (Huyen 2022), Capítulo 6.

Capítulo 15

Despliegue de un estimador causal como servicio

Cuadro de decisión del capítulo

Decisión:	Servir el estimador como un servicio REST síncrono, no como biblioteca embebida ni como batch
Alternativas:	Biblioteca embebida vs. servicio web vs. predicciones *batch* pre-computadas
Trade-off clave:	Latencia y simplicidad de biblioteca vs. desacoplamiento y reutilización de un servicio
Stack:	FastAPI, Docker, `joblib`
Riesgo principal:	*Training-serving skew*: que el cálculo de *features* en producción difiera del usado al entrenar

Implementación en el monorepo del curso (2026)

Implementación de referencia: `04_notebooks_produccion_hf/B1_fastapi_dml/` (FastAPI, `inference.py` pura, Docker). Artefacto de entrada: `artifacts/A2/dml_estimator.joblib` + `feature_list.json` (lista de covariables; análogo operativo a `schema.covariates`). Labs: `L12`, `L14`. Humo: `autograder/grade_b1.py`. El endpoint expone `/health`, `/metadata` y `/predict`.

15.1 El problema de diseño

El 11 produjo un estimador DML entrenado y validado según los criterios del 14. El problema de este capítulo, que cierra la Parte II, es distinto: ¿cómo se pone ese estimador a disposición de alguien —un compañero de equipo, otro servicio, una aplicación— que necesita una estimación puntual sin tener que reabrir el notebook de entrenamiento? La respuesta no es única; (Huyen 2022) (Capítulo 7) y (Kästner et al. 2024) (Capítulo 10) describen varios patrones de *serving* con distintos costos y beneficios, y elegir entre ellos es, otra vez, una decisión de diseño y no un detalle de implementación menor.

15.2 Opciones y trade-offs

Opciones y trade-offs

- **Biblioteca embebida.** El modelo serializado se distribuye como un paquete de Python que cualquier proceso importa directamente (`from causal_lib import estimar_efecto`). Es la opción de menor latencia (no hay llamada de red) y la más simple de depurar. Su costo: cada consumidor necesita el mismo entorno de Python con las mismas versiones de dependencias, y actualizar el modelo requiere redistribuir el paquete a todos los consumidores.
- **Servicio web (REST/gRPC).** El modelo vive detrás de un endpoint HTTP; los consumidores envían covariables y reciben una estimación, sin necesidad de tener Python ni las dependencias del modelo instaladas. Permite actualizar el modelo en un solo lugar y servir a consumidores en cualquier lenguaje. Su costo es la latencia de red y la necesidad de operar un servicio (disponibilidad, escalado, versionado de la API).
- ***Batch* precomputado.** Las estimaciones se calculan por adelantado para toda la población conocida y se almacenan en una tabla que se consulta por clave. Es la opción de menor latencia de consulta y la más simple de auditar (todas las estimaciones existen antes de cualquier consulta), pero no sirve para unidades nuevas no vistas al momento del cómputo *batch*, y el «efecto estimado» puede quedar desactualizado si las covariables de una unidad cambian entre el cómputo y la consulta.

Un segundo trade-off es la función de inferencia misma: (Kästner et al. 2024) enfatiza que esta función debe ser **pura** —sin efectos secundarios, sin estado mutable entre llamadas— precisamente para que el mismo código pueda ejecutarse de forma idéntica en el notebook de entrenamiento y en el servicio de producción, evitando el problema de *training-serving skew* ya anticipado en el 2.

15.3 Decisión de referencia para el curso

El curso adopta un **servicio REST síncrono con FastAPI**, containerizado con Docker, como patrón de referencia para todos los notebooks de producción de la Serie B. Se prefiere sobre la biblioteca embebida porque el objetivo pedagógico incluye publicar el modelo en Hugging Face Hub (Capítulo 19) para que cualquiera pueda consultarlo sin instalar el entorno del curso; se prefiere sobre el *batch* precomputado porque los casos de uso del curso (Notebooks A2 y A4) requieren estimar el efecto para unidades nuevas, no solo para una población fija conocida de antemano.

15.4 Implementación de referencia

La función de inferencia se separa explícitamente del servicio HTTP, reutilizando el `CausalSchema` del 4 para garantizar que las covariables se interpreten exactamente igual que en el entrenamiento:

```
# inference.py -- funcion pura, sin dependencias de FastAPI
import joblib
import numpy as np
import pandas as pd

_modelo = joblib.load("model/dml_estimator.joblib")
_schema = joblib.load("model/causal_schema.joblib")

def estimar_efecto(covariables: dict) -> dict:
    """Funcion pura: mismas entradas siempre producen la misma salida,
    sin efectos secundarios. Se prueba igual en notebook y en produccion."""
    faltantes = set(_schema.covariates) - set(covariables.keys())
    if faltantes:
        raise ValueError(f"Faltan covariables requeridas por el schema:
{faltantes}")
    X = pd.DataFrame([covariables])[_schema.covariates]
    efecto = _modelo.effect(X)[0]
    ic_inf, ic_sup = _modelo.effect_interval(X, alpha=0.05)
    return {
        "efecto_estimado": float(efecto),
        "ic_95_inferior": float(ic_inf[0]),
        "ic_95_superior": float(ic_sup[0]),
        # ic_individual: anadir solo si existe calibracion conforme (Cap. 14);
        # nunca reutilizar ic_95 como intervalo para decisiones individuales
        "poblacion_entrenamiento": _schema.covariates,  # transparencia sobre
validez
    }
```

Listado 15.1: Función de inferencia pura, desacoplada del framework web.

```
# app.py
from fastapi import FastAPI, HTTPException
from pydantic import BaseModel
from inference import estimar_efecto, metadatos_modelo

app = FastAPI(title="Servicio de estimacion causal - curso IA Causal en
Produccion")

class Covariables(BaseModel):
    exper: float
    black: int
    south: int
    married: int

@app.post("/predict")
def predict(cov: Covariables):
    try:
        return estimar_efecto(cov.model_dump())
    except ValueError as e:
        raise HTTPException(status_code=422, detail=str(e))

@app.get("/health")
def health():
    """Liveness: el proceso responde. No dice nada sobre validez causal."""
    return {"status": "ok"}

@app.get("/metadata")
def metadata():
    """Contrato causal del servicio: estimando, supuestos, poblacion y
    version. Es lo que permite a un consumidor decidir si el efecto es
    aplicable a su caso ANTES de llamar a /predict."""
    return metadatos_modelo()
```

Listado 15.2: Servicio FastAPI que envuelve la función de inferencia.

El endpoint `/metadata` no es decorativo ni redundante con la *model card* del Capítulo 19. Una *model card* es documentación para personas y vive en el repositorio; `/metadata` es el mismo contrato expuesto **en tiempo de ejecución y de forma legible por máquina**, de modo que un consumidor automatizado pueda verificar programáticamente qué versión del modelo está respondiendo y bajo qué supuestos, sin depender de que alguien haya leído el README. Es también lo que permite que el monitoreo del 30 compare la población que efectivamente consulta el servicio contra la población declarada de entrenamiento:

```
# inference.py (continuacion del listado anterior)
def metadatos_modelo() -> dict:
    """Funcion pura: describe el contrato causal del artefacto servido.
    El dict devuelto valida contra causal-model-card-v1.schema.json (Ap. G.4);
    el CI del curso lo verifica antes de publicar."""
    return {
        "estimando": _meta["estimando"],              # p.ej. "ATE" o "CATE(x)"
        "diseno_identificacion": _meta["diseno"],     # observacional / IV /
RCT
        "supuestos": _meta["supuestos"],              # lista declarada, ver
Cap. 19
        "covariables_requeridas": _schema.covariates,
        "poblacion_entrenamiento": _meta["poblacion"],
        "version_modelo": _meta["version"],
        "hash_datos_entrenamiento": _meta["hash_datos"],
    }
```

Listado 15.3: Metadatos del modelo, servidos desde el mismo artefacto que la inferencia.

```
FROM python:3.11-slim
WORKDIR /app
COPY requirements.txt .
RUN pip install --no-cache-dir -r requirements.txt
COPY inference.py app.py ./
COPY model/ ./model/
EXPOSE 8000
CMD ["uvicorn", "app:app", "--host", "0.0.0.0", "--port", "8000"]
```

Listado 15.4: `Dockerfile` para contenerizar el servicio.

La prueba de humo del Notebook de producción B1 verifica los tres endpoints en ese orden, y el orden es deliberado: `/health` comprueba que el proceso vive, `/metadata` que el artefacto cargado es el esperado (versión y hash de datos), y solo entonces `/predict` que la estimación es razonable. Un fallo en el segundo con éxito en el primero es exactamente el escenario silencioso que este capítulo busca hacer visible: el servicio responde, pero está sirviendo un modelo distinto del que el equipo cree.

15.5 Aplicación al sistema causal del curso

Nótese que la respuesta de `estimar_efecto()` en el listado Listado 15.1 no devuelve solo el efecto puntual: incluye el intervalo de confianza y la lista de covariables de la población de entrenamiento. Esto no es una decisión estética. El 2 comprometió, como parte de la anatomía de un sistema causal responsable, que la interfaz debe comunicar algo más que un número — precisamente para que ningún consumidor del servicio use el efecto estimado como si fuera válido para una población distinta a la de entrenamiento sin, al menos, tener esa información disponible en la propia respuesta de la API.

15.6 Señales de alerta y checklist operativo

- ☐ La función de inferencia calcula las *features* con código distinto al usado durante el entrenamiento (riesgo directo de *training-serving skew*).
  ☐ El endpoint devuelve solo el efecto puntual, sin intervalo de confianza ni información de la población de entrenamiento.
  ☐ No existe una ruta `/health` verificable independientemente de `/predict`.
  ☐ No hay forma de saber, consultando el servicio, qué versión del modelo está respondiendo ni sobre qué datos se entrenó (`/metadata` ausente o sin `version_modelo`/`hash_datos_entrenamiento`).
  ☐ El `Dockerfile` no fija versiones exactas de las dependencias (`requirements.txt` sin *pinning*), con riesgo de que el contenedor se comporte distinto según cuándo se construya.

15.7 Ejercicios y notas bibliográficas

15.7.1 Ejercicios conceptuales

1. Para el caso de uso del Notebook A4 (política óptima de targeting, Módulo 4), ¿cuál de las tres opciones de la 15.2 sería más apropiada si el número de clientes a evaluar es fijo y conocido cada mes? Justifique.
2. Explique, con sus propias palabras, por qué separar `inference.py` de `app.py` (listados Listado 15.1 y Listado 15.2) facilita probar la lógica de inferencia sin necesidad de levantar el servidor web.

15.7.2 Ejercicio de infraestructura (Lab, Notebook B1)

1. Complete el Notebook de producción B1: serialice el estimador DML entrenado en el Notebook A2, adapte los listados Listado 15.1, Listado 15.2 y Listado 15.4 a su dataset, construya la imagen Docker y verifique que `/health` y `/predict` responden correctamente con `curl` o el cliente HTTP de su elección.

15.7.3 Notas bibliográficas

Huyen (2022), Capítulo 7 («Model Deployment and Prediction Service»), y (Kästner et al. 2024), Capítulo 10 («Deploying a Model»), son las dos referencias principales de este capítulo; el segundo desarrolla en particular la discusión de *features* dentro/fuera del servicio y el *training-serving skew* retomada en la 15.5.

Parte IV

Diseños de identificación con ML

Esta parte conecta el ML causal con diseños econométricos clásicos de identificación: selección de controles en alta dimensión con Post-Double-Selection, datos de panel e instrumentos con DML-IV, y un mapa de decisión que sintetiza cuándo usar cada diseño de los cubiertos hasta aquí.

Capítulo 16

Post-Double-Selection LASSO

Cuadro sinóptico del capítulo

Problema:	Selección de confusores en alta dimensión para estimación causal
Estimando:	θ_0 en el modelo $Y = D\theta_0 + X^T\gamma_0 + \varepsilon$
Identificación:	Sparsity aproximada, restricted eigenvalue condition
Método:	PDS LASSO: doble selección (LASSO de Y y D) + OLS final
Nuisance:	Coeficientes LASSO de Y y D
Garantía:	$\sqrt{n}\left(\hat{\theta}_{\text{PDS}} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V})$
Librerías:	scikit-learn, statsmodels
Validación:	Sensibilidad a λ, comparación con DML

Nota técnica

Este capítulo abre la Parte III del libro, dedicada a diseños de identificación completos. El 8 formalizó el criterio de puerta trasera de forma general; Post-Double-Selection es el procedimiento concreto para aplicarlo cuando el conjunto de controles candidatos es de alta dimensión y no se sabe, a priori, cuáles son verdaderamente confusores.

16.1 Motivación aplicada

Una economista de la salud desea estimar el efecto de dejar de fumar sobre el cambio de peso, usando el dataset `nhefs` (NHANES I Epidemiologic Followup Study). El dataset tiene 51 covariables utilizables tras excluir variables post-tratamiento y de fecha: características demográficas, hábitos, condiciones médicas, factores socioeconómicos. No todas son confusoras: algunas no afectan ni al tratamiento ni al resultado, otras afectan solo al resultado. La pregunta metodológica es: ¿cómo seleccionar automáticamente las confusoras relevantes sin inducir el sesgo post-selección del capítulo 6?

Belloni et al. (2014) proponen el Post-Double-Selection (PDS) LASSO como solución. La idea es elegante: las confusoras son las variables que predicen *tanto* al tratamiento *como* al resultado. Seleccionando por separado cada conjunto con LASSO y tomando la unión, se

capturan las confusoras relevantes con alta probabilidad, mientras que el sesgo de selección individual se diluye.

Este capítulo desarrolla PDS formalmente, lo compara con DML (capítulo 11)—que no requiere sparsity explícita— y muestra una aplicación al dataset `nhefs`.

16.2 Teoría, supuestos y garantías

16.2.1 Modelo de alta dimensión con efecto causal

Consideramos el modelo:

$$Y = D\theta_0 + X^T\gamma_0 + \varepsilon, \quad D = X^T\beta_0 + v, \tag{16.68}$$

donde $X \in R^p$ con p potencialmente mayor que n, γ_0 y β_0 son *sparse* (pocas componentes no nulas), y θ_0 es el parámetro causal de interés. Suponemos $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$.

16.2.2 Post-Double-Selection (PDS)

El procedimiento PDS consiste en tres pasos:

1. **Selección de controles para Y:** LASSO de Y sobre X (sin D), obtener conjunto S_Y.
2. **Selección de controles para D:** LASSO de D sobre X, obtener conjunto S_D.
3. **OLS final:** regredir Y sobre D y $S = S_Y \cup S_D$. Reportar IC al 95% basados en la distribución t-Student estándar.

Teorema 16.1 ***(Belloni, Chernozhukov & Hansen, 2014)***

Bajo sparsity aproximada de γ_0 y β_0, *restricted eigenvalue condition*, y regularidad estándar, el estimador PDS es asintóticamente Gaussiano:

$$\sqrt{n}\left(\hat{\theta}_{\text{PDS}} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V}), \tag{16.69}$$

donde $\mathcal{V} = \frac{E[v^2\varepsilon^2]}{E[v^2]^2}$. La inferencia basada en la distribución t-Student es válida.

16.2.3 Pseudocódigo: Post-Double-Selection

El siguiente algoritmo formaliza los pasos del procedimiento PDS.

16.2.4 La elección de λ no es un detalle de implementación

El teorema anterior se enuncia «para un λ apropiadamente elegido», y conviene detenerse en esa cláusula porque es donde la implementación práctica se aparta con más frecuencia de la teoría que la respalda.

La validación cruzada —el método por defecto de `LassoCV` y el que usa el listado Listado 16.1 — elige λ minimizando el error de **predicción** fuera de muestra. Es el criterio correcto si el objetivo es predecir, pero no es el criterio bajo el cual se demuestra el teorema. El λ óptimo para predicción tiende a ser más pequeño que el teóricamente justificado, porque incluir variables ligeramente informativas reduce el error cuadrático aunque introduzca sesgo en los coeficientes

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, hiperparámetro de penalización $\lambda \geq 0$ (o K folds para validación cruzada).
Salida: Estimador $\hat{\theta}_{\text{PDS}}$ y error estándar HC1 $\hat{\sigma}_{\text{HC1}}$
Ejecutar LASSO de Y sobre X con penalización λ.
Identificar $S_Y = \left\{j : \hat{\beta}_{Y,j} \neq 0\right\}$.
Ejecutar LASSO de D sobre X con penalización λ.
Identificar $S_D = \left\{j : \hat{\beta}_{D,j} \neq 0\right\}$.
Unión: $S = S_Y \cup S_D$.
Estimar OLS de Y sobre D y las variables en S (con constante).
Calcular errores estándar robustos HC1.
return $\hat{\theta}_{\text{PDS}}, \hat{\sigma}_{\text{HC1}}$.

Algoritmo 7.: Post-Double-Selection (PDS)

individuales; el resultado es un $\hat{S}$ más grande de lo necesario y, en muestras pequeñas, un OLS final con demasiados regresores.

Belloni et al. (2014) derivan en cambio un nivel de penalización **teóricamente justificado**, de la forma

$$\lambda = \frac{c \cdot \sigma}{\sqrt{n}} \cdot \Phi^{-1}(1 - \gamma/(2p)), \tag{16.70}$$

con $c \approx 1.1$ y $\gamma \to 0$ lentamente (típicamente $\gamma = 0.1/\log n$). La estructura de la fórmula tiene una lectura directa: la penalización se calibra para dominar el «ruido máximo» entre las p variables candidatas —de ahí el Φ^{-1} evaluado en una cola corregida por el número de comparaciones, un ajuste de Bonferroni disfrazado— de modo que ninguna variable irrelevante entre por azar con probabilidad no despreciable. Como σ es desconocida, se estima iterativamente, o se usa la variante **rigurosa** con penalización por variable que además corrige heterocedasticidad.

En la práctica, la recomendación operativa del curso es reportar ambas: la estimación con λ_{CV} y la estimación con λ_{BCH}. Si coinciden —el caso frecuente cuando n es cómodo y la señal es clara— la elección era inmaterial y conviene decirlo. Si difieren, la discrepancia es información: señala que el resultado depende de cuántos controles se admitan, y ninguna de las dos cifras debería reportarse sola. La 16.4.3 desarrolla esta comparación como análisis de sensibilidad estándar. En Python, `hdmpy` implementa la penalización rigurosa de BCH; con `scikit-learn` puede construirse a mano fijando `alpha` en lugar de usar `LassoCV`.

16.2.5 Intuición: por qué la doble selección funciona

El sesgo post-selección del capítulo 6 surge porque LASSO puede *omitir* variables confusoras relevantes si estas tienen poco poder predictivo marginal. La doble selección mitiga esto:

- Una variable confusora afecta *tanto* a D *como* a Y. Aparece en S_Y o en S_D con alta probabilidad (no necesariamente en ambos).
- Tomando la unión, se captura con alta probabilidad toda confusora relevante.
- Las variables no confusoras (afectan solo a Y o solo a D) se seleccionan con probabilidad menor y, aun si se incluyen, no sesgan la estimación.

Intuición

Imagine que X_j es una confusora fuerte: afecta a D y a Y. LASSO sobre Y puede omitirla si D ya explica Y suficientemente bien. Pero LASSO sobre D la seleccionará con alta probabilidad. Tomando la unión, X_j entra en el modelo final. El sesgo de omisión se evita.

16.2.6 Comparación con DML

PDS y DML atacan el mismo problema (estimación causal en alta dimensión) con estrategias distintas:

Dimensión	PDS LASSO	DML
Supuesto estructural	Sparsity aproximada	Ninguno explícito
Forma funcional	Lineal en X	Flexible (RF, GBM, etc.)
Heterogeneidad en X	No	Sí (con IRM/CATE)
Inferencia	t-Student estándar	Asintótica vía IF
Implementación	`scikit-learn` + OLS	`DoubleML`/`econml`
Caso ideal	$p \gg n$, lineal, sparse	$p \approx n$, no lineal

Tabla 16.1: PDS vs. DML.

Intuición

Caja de profundización 8.1: PDS-IV y comparación PDS vs DML

Objetivo. Extender PDS a variables instrumentales y entender cuándo preferir PDS sobre DML.

PDS con instrumentos (PDS-IV). Si tenemos un instrumento Z, la doble selección se hace así:

1. LASSO de Y sobre $X \to S_Y$
2. LASSO de D sobre X y $Z \to S_D$
3. 2SLS: Y sobre D, usando Z como instrumento, con controles $S = S_Y \cup S_D$

PDS vs DML: ¿cuándo usar cada uno?

- **PDS:** mejor cuando n es pequeña, el modelo es lineal y la esparsidad es fuerte (pocos controles relevantes).
- **DML:** mejor cuando hay no linealidades, dudas sobre la forma funcional, o muchas variables con efectos pequeños.
- **Regla práctica:** si no estás seguro, usa DML. Si $n < 500$ y confías en la linealidad, considera PDS.

Límite de PDS: si hay **confusión densa** (muchas variables con efectos pequeños que en conjunto importan), PDS puede omitir variables importantes y sesgar el resultado. Ahí DML es preferible.

16.3 Implementación en Python

16.3.1 Implementación de PDS

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LassoCV
import statsmodels.api as sm

df = pd.read_csv("../data/datasets/real/public_causaldata/nhefs/data.csv")
# Outcome: cambio de peso. Treatment: qsmk (quit smoking)
# Seleccionar columnas numericas como controles
Y_col = "wt82_71"   # cambio de peso
D_col = "qsmk"      # dejo de fumar
X_cols = [c for c in df.columns if c not in [Y_col, D_col, "seqn", "death"]]
# Limpiar
df_clean = df.dropna(subset=[Y_col, D_col] + X_cols).reset_index(drop=True)
Y = df_clean[Y_col].values
D = df_clean[D_col].values.astype(float)
X = df_clean[X_cols].select_dtypes(include=[np.number]).fillna(0).values

def pds_lasso(Y, D, X, cv=5):
    """Post-Double-Selection LASSO."""
    # Paso 1: LASSO Y ~ X
    lasso_Y = LassoCV(cv=cv, max_iter=10000, random_state=42).fit(X, Y)
    S_Y = np.where(np.abs(lasso_Y.coef_) > 1e-8)[0]
    # Paso 2: LASSO D ~ X
    lasso_D = LassoCV(cv=cv, max_iter=10000, random_state=42).fit(X, D)
    S_D = np.where(np.abs(lasso_D.coef_) > 1e-8)[0]
    # Union
    S = sorted(set(S_Y) | set(S_D))
    print(f"Seleccionadas: {len(S)} variables (de {X.shape[1]})")
    # Paso 3: OLS Y ~ D + X_S
    if len(S) == 0:
        X_final = sm.add_constant(D)
    else:
        X_final = sm.add_constant(np.column_stack([D, X[:, S]]))
    ols = sm.OLS(Y, X_final).fit(cov_type="HC1")
    theta = ols.params[1]
    se = ols.bse[1]
    return theta, se, S

theta_pds, se_pds, S = pds_lasso(Y, D, X)
print(f"PDS: theta={theta_pds:.4f}  SE={se_pds:.4f}
IC=[{theta_pds-1.96*se_pds:.4f}, {theta_pds+1.96*se_pds:.4f}]")
```

Listado 16.1: Post-Double-Selection LASSO sobre NHEFS.

Nota técnica

No forzar la inclusión de una covariable arbitraria. PDS usa la unión de variables seleccionadas en los pasos de Y y D. La constante se agrega por separado con `add_constant`. Si la primera columna de X no es una constante, forzarla puede introducir ruido, colisionadores o variables post-tratamiento.

16.4 Caso empírico y validación

16.4.1 Comparación PDS vs DML vs selección manual

```
from econml.dml import LinearDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

# DML con GBM
est = LinearDML(model_y=GradientBoostingRegressor(n_estimators=200,
random_state=42),
                model_t=GradientBoostingClassifier(n_estimators=200,
random_state=42),
                discrete_treatment=True, cv=5, random_state=42).fit(Y, D, X=X)
ate_dml = est.ate(X=X)
lb, ub = est.ate_interval(X=X, alpha=0.05)
print(f"DML:  theta={ate_dml:.4f}  IC=[{lb:.4f}, {ub:.4f}]")

# Seleccion manual (5 controles obvios)
manual_cols = ["age", "sex", "race", "smokeintensity", "smokeyrs"]
X_manual = df_clean[manual_cols].fillna(0).values
X_final_m = sm.add_constant(np.column_stack([D, X_manual]))
ols_m = sm.OLS(Y, X_final_m).fit(cov_type="HC1")
print(f"Manual: theta={ols_m.params[1]:.4f}  SE={ols_m.bse[1]:.4f}")
```

Listado 16.2: Comparación PDS vs. DML vs. selección manual.

16.4.2 Caso de estudio: efecto de dejar de fumar sobre peso (NHEFS)

Belloni et al. (2014) aplicaron PDS a este dataset en su *paper* original. Su tabla reporta un estimado de 2.5–3.5 kg de ganancia de peso al dejar de fumar, dependiendo del set de controles. La aplicación con selección manual (5 controles) suele subestimar el efecto, mientras que PDS captura confusoras adicionales (edad de inicio de fumador, intensidad, etc.) que elevan el estimado.

Réplica propia sobre el dataset del repositorio. Hemos replicado el ejercicio sobre `nhefs` con $n = 1,566$ observaciones y 51 controles potenciales (excluyendo variables post--tratamiento y de fecha). Los resultados obtenidos son:

- OLS sin controles: $\theta = 2.54$ kg, IC 95% $[1.59, 3.50]$.

- OLS con 5 controles manuales (`age, sex, race, smokeintensity, smokeyrs`): $\theta = 3.20$ kg, IC 95% $[2.26, 4.14]$.
- Naive LASSO + OLS: $\theta = 3.21$ kg, IC 95% $[2.28, 4.13]$ (18 variables seleccionadas).
- PDS LASSO: $\theta = 3.22$ kg, IC 95% $[2.29, 4.14]$ (18 variables seleccionadas).
- DML con GBM: $\theta = 3.13$ kg, IC 95% $[2.16, 4.10]$.

Las estimaciones son consistentes entre métodos (entre 3.13 y 3.22 kg para los métodos con controles), lo que valida la robustez del efecto. La cifra original de (Belloni et al. 2014) no pudo verificarse cifra por cifra en su tabla, pero el orden de magnitud coincide.

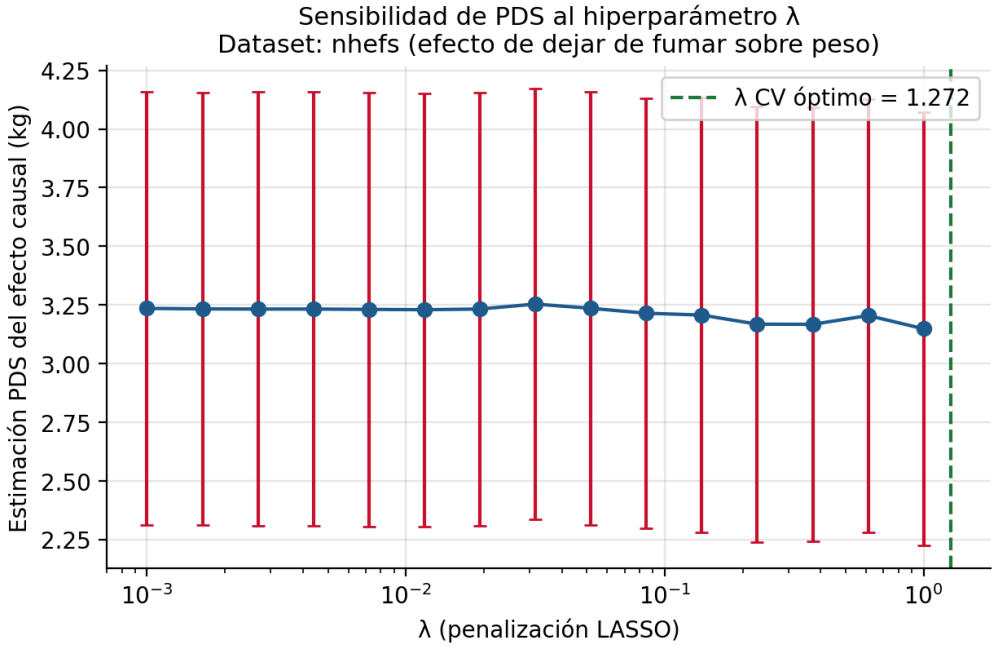


Figura 16.1: Sensibilidad de la estimación PDS al hiperparámetro λ de LASSO. Las barras indican IC al 95% (HC1). La línea verde punteada marca el λ óptimo por cross-validation. Dataset: `nhefs`, $n = 1,566$, $p = 51$ controles.

La figura Figura 16.1 muestra que la estimación PDS es relativamente estable para $\lambda < 0.1$, pero colapsa hacia el estimador sin controles cuando λ es muy alto (todas las variables son penalizadas y el conjunto seleccionado se vacía). La forma de esta curva es en sí misma un diagnóstico y conviene saber leerla: una **meseta amplia** alrededor del λ elegido, como la de esta figura, indica que el resultado no depende de cuántos controles se admitan y es la situación en que reportar una sola cifra es defendible. Una curva con pendiente pronunciada en el entorno del λ elegido indicaría lo contrario —que el efecto estimado es función de una decisión de hiperparámetro— y obligaría a reportar el rango completo en lugar de un punto. Por eso el gráfico de sensibilidad no es un apéndice opcional del análisis PDS sino parte del resultado, junto con la comparación λ_{CV} frente a λ_{BCH} de la 16.2.4.

Una limitación del PDS estándar que conviene declarar. A diferencia de DML, el procedimiento PDS tal como se presenta aquí no usa *cross-fitting*: las dos selecciones LASSO y el OLS final se calculan sobre la misma muestra. La teoría de Belloni et al. (2014) no lo necesita, porque la estructura lineal y la penalización rigurosa controlan el sesgo de sobreajuste por otra

vía —el argumento descansa en la esparsidad y en cotas uniformes, no en independencia entre etapas—. La contrapartida es que esa garantía es exactamente tan fuerte como el supuesto de linealidad y esparsidad: si alguno falla, PDS no tiene la red de seguridad que el cross-fitting da a DML. Es una razón adicional, junto a la de confusión densa discutida más abajo, para preferir DML cuando no se tiene una convicción sustantiva sobre la forma funcional.

16.4.3 Validación

Sensibilidad a la elección de λ

```
import matplotlib.pyplot as plt
from sklearn.linear_model import Lasso

lasso_Y_cv = LassoCV(cv=5, max_iter=10000).fit(X, Y)
lambda_cv = lasso_Y_cv.alpha_

lambdas = np.logspace(
    -3,
    max(0, np.log10(lambda_cv * 1.5)),
    30
)
thetas = []
for lam in lambdas:
    lY = Lasso(alpha=lam, max_iter=10000).fit(X, Y)
    lD = Lasso(alpha=lam, max_iter=10000).fit(X, D)
    S = sorted(set(np.where(np.abs(lY.coef_) > 1e-8)[0]) |
               set(np.where(np.abs(lD.coef_) > 1e-8)[0]))
    if len(S) == 0:
        continue
    X_f = sm.add_constant(np.column_stack([D, X[:, S]]))
    ols = sm.OLS(Y, X_f).fit(cov_type="HC1")
    thetas.append((lam, ols.params[1], ols.bse[1]))

thetas = np.array(thetas)
plt.figure(figsize=(8, 5))
plt.errorbar(thetas[:, 0], thetas[:, 1], yerr=1.96*thetas[:, 2], fmt="o-")
if lambdas.min() <= lambda_cv <= lambdas.max():
    plt.axvline(lambda_cv, color="green", ls="--", label=r"$\lambda_{CV}$")
plt.xscale("log")
plt.xlabel("Lambda (penalizacion LASSO)")
plt.ylabel("Estimacion PDS del efecto causal")
plt.title("Sensibilidad de PDS a la eleccion de $\\lambda$")
plt.legend()
plt.tight_layout()
plt.savefig("figuras/pds_sensitivity.png", dpi=120, bbox_inches="tight")
plt.show()
```

Listado 16.3: Sensibilidad al hiperparametro lambda.

Tabla de riesgos

La tabla Tabla 16.2 resume los principales riesgos al aplicar PDS, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Dense confounding	Selección incompleta de confusoras relevantes	Simulación con DGP de confusión densa	Usar DML en lugar de PDS
Lambda inestable	Resultados frágiles que cambian drásticamente con λ	Gráfico de sensibilidad (Fig. Figura 16.1): buscar meseta vs. pendiente en el entorno del λ elegido	Reportar el rango completo, y contrastar λ_{CV} (criterio predictivo) con λ_{BCH} (criterio teórico, 16.2.4) en lugar de confiar en uno solo
Controles post-tratamiento	Sesgo por condicionar en variables afectadas por el tratamiento	Construir un DAG del problema	Excluir variables posteriores al tratamiento

Tabla 16.2: Riesgos al aplicar PDS LASSO.

16.5 Ejercicios propuestos

1. Replique el listado Listado 16.1 sobre el dataset `close_college` (educación sobre salario, IV = `nearc4`). ¿Cambia el estimado IV al usar PDS para seleccionar controles?
2. Modifique el DGP del capítulo 6 para tener 20 confusoras y 80 variables irrelevantes. Compare PDS con selección simple en términos de cobertura.
3. Sobre el dataset `cps_mixtape`, estime el retorno a la educación con PDS y compare con DML.
4. Construya un DGP donde la estructura de confusión sea densa (100 variables pequeñas, cada una con coeficiente 0.1). Verifique que PDS falla pero DML funciona.
5. Implemente la penalización teórica de Belloni et al. (2014) descrita en la 16.2.4 y compare, sobre `nhefs`, el λ_{BCH} resultante con el λ_{CV} del listado Listado 16.1. ¿Cuántas variables selecciona cada uno? ¿Cambia el efecto estimado o solo el tamaño del conjunto seleccionado?

16.6 Lecturas complementarias

Belloni et al. (2014) es el *paper* fundacional. Belloni et al. (2012) extiende a IV. Chernozhukov et al. (2018b) (capítulo 11) presenta el enfoque alternativo. Chernozhukov et al. (2018a) ofrece un tratamiento pedagógico.

Capítulo 17

Machine learning causal en datos de panel

Cuadro sinóptico del capítulo

Problema:	Estimar efecto causal en panel con controles de alta dimensión
Estimando:	θ_0, efecto parcial en PLR de panel con efectos fijos
Identificación:	Exogeneidad + within-transformation + FE
Método:	DML-panel (within + cross-fitting), DMLIV
Nuisance:	$\tilde{g}(\tilde{X})$, $\tilde{m}(\tilde{X})$ en espacio within-transformado
Garantía:	$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, \mathcal{V})$ con errores cluster-robustos
Condición clave:	Within-transformation + cross-fitting por clúster
Librerías:	DoubleML (DoubleMLClusterData), econml
Validación:	FE vs DML, placebos, event study, sensibilidad a K

Nota técnica

Con Post-Double-Selection (16) como primer diseño de identificación completo, este capítulo extiende el mismo espíritu —controlar rigurosamente por confusión en alta dimensión— a dos estructuras de datos que rompen el supuesto de observaciones independientes de Double Machine Learning (11): datos de panel con efectos fijos, y variables instrumentales.

17.1 Problema causal, estimando e identificación

Una consultora evalúa el efecto de una reforma laboral sobre el empleo formal en 32 regiones observadas durante 10 años. La reforma se adoptó en distintas regiones en distintos años, generando un panel con *staggered adoption*. La pregunta de política es: ¿cuál es el efecto promedio de la reforma sobre el empleo formal?

Los métodos clásicos—efectos fijos (FE), DiD, *synthetic DiD*— funcionan bien cuando hay pocos controles y se asume linealidad. Pero si hay muchas características regionales (sectoriales,

demográficas, macroeconómicas) que afectan tanto la adopción de la reforma como el empleo, los FE clásicos pueden no bastar. Chernozhukov et al. (2018b) extienden DML a datos de panel combinando *within-transformation* con *cross-fitting*.

Este capítulo desarrolla DML para paneles: la *within-transformation* que elimina efectos fijos, el *cross-fitting* que preserva inferencia válida, y la extensión a instrumentos (DMLIV). Aplicamos el método al dataset `panel_fe_dynamic` del repositorio, que tiene CATE verdadero conocido.

17.2 Teoría, supuestos y garantías

17.2.1 Modelo de panel con efectos fijos

Consideramos un panel balanceado con N unidades observadas durante T periodos. El modelo es:

$$Y_{it} = D_{it}\theta_0 + g_0(X_{it}) + \alpha_i + \delta_t + \varepsilon_{it}, \tag{17.71}$$

donde α_i es efecto fijo de unidad, δ_t es efecto fijo de periodo, $g_0(X_{it})$ es una función desconocida de covariables *time-varying*, y ε_{it} es el error. El parámetro causal es θ_0.

En panel, $n = N \cdot T$ observaciones, con N unidades y T periodos.

La *within-transformation* elimina los efectos fijos:

$$\tilde{Y}_{it} = Y_{it} - \overline{Y}_{i\cdot} - \overline{Y}_{\cdot t} + \overline{Y}_{\cdot\cdot}, \tag{17.72}$$

donde $\overline{Y}_{i\cdot}$ es el promedio temporal para la unidad i, $\overline{Y}_{\cdot t}$ es el promedio *cross-sectional* para el periodo t, y $\overline{Y}_{\cdot\cdot}$ es la gran media. Aplicando esto a la ecuación Ecuación (17.71):

$$\tilde{Y}_{it} = \tilde{D}_{it}\theta_0 + \tilde{g}_0(X_{it}) + \tilde{\varepsilon}_{it}. \tag{17.73}$$

Ahora el modelo está en forma PLR y se le puede aplicar DML directamente.

17.2.2 Supuestos

Para que el estimador DML-panel sea $\sqrt{n}$-consistente y asintóticamente normal, se requieren los siguientes supuestos:

Supuesto 17.1 ***(Exogeneidad del tratamiento)***

$E[\varepsilon_{it} \mid D_{i1}, ..., D_{iT}, X_{i1}, ..., X_{iT}, \alpha_i, \delta_t] = 0$ para todo i, t.

El supuesto de exogeneidad del panel es la versión para panel de la no confusión condicional: una vez que controlamos por efectos fijos de unidad (α_i) y periodo (δ_t), y por las covariables observadas X_{it}, la asignación del tratamiento es tan buena como aleatoria condicional en esos factores.

Supuesto 17.2 ***(Efecto constante)***

El efecto causal del tratamiento es constante: θ_0 no varía entre unidades ni periodos.

Este supuesto es restrictivo pero necesario para la formulación PLR estándar. En la sección de riesgos discutimos extensiones para efectos dinámicos o heterogéneos.

Supuesto 17.3 ***(Condición de producto para DML)***

Los estimadores *nuisance* $\hat{\hat{g}}$ y $\hat{\hat{m}}$ satisfacen $\sqrt{n}a_n^2 \to 0$, donde $a_n = \max\{\|\hat{\hat{g}} - \tilde{g}_0\|, \|\hat{\hat{m}} - \tilde{m}_0\|\}$. Esta condición es la misma del DML estándar (capítulo 10): los errores de estimación de las *nuisance* deben converger más rápido que $n^{-\frac{1}{4}}$ para que el sesgo de regularización sea de segundo orden.

17.2.3 Estimador y score

DML para panel

Una vez aplicada la within-transformation, el modelo Ecuación (17.73) es un PLR estándar en los datos transformados $\{\tilde{Y}_{it}, \tilde{D}_{it}, \tilde{X}_{it}\}$. El score ortogonal de Neyman para este modelo es:

$$\psi(W, \theta, \eta) = \big(\tilde{D} - m(\tilde{X})\big)\big(\tilde{Y} - g(\tilde{X}) - \theta\tilde{D}\big), \tag{17.74}$$

donde $\eta = (g, m)$ son las funciones *nuisance*: $g(\tilde{X}) = E[\tilde{Y} \mid \tilde{X}]$ y $m(\tilde{X}) = E[\tilde{D} \mid \tilde{X}]$. La ortogonalidad del score garantiza que los errores de estimación de $\hat{g}$ y $\hat{m}$ no contaminan la estimación de θ_0 en primer orden.

El estimador DML-panel se obtiene resolviendo la ecuación de momento $\sum_{i,t} \psi\big(W_{it}, \hat{\theta}, \hat{\eta}\big) = 0$ tras aplicar *cross-fitting* por clúster (unidad).

DML con instrumentos (DMLIV)

Cuando D es endógeno y se dispone de un instrumento Z, el modelo es:

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad Z = r_0(X) + \zeta, \quad D = m_0(Z, X) + v, \tag{17.75}$$

con $E[\varepsilon \mid Z, X] = 0$ (exclusión) y $\mathrm{Cov}(Z, v) \neq 0$ (relevancia). El score ortogonal correspondiente, derivado por (Chernozhukov et al. 2018b), es:

$$\psi_{t\ \mathrm{PLIV}}(W, \theta, \eta) = (Z - r(X))(Y - g(X) - \theta D), \tag{17.76}$$

con $\eta = (g, r, m)$.

Teorema 17.4 ***(DML-PLIV)***

Bajo los supuestos de exclusión, relevancia, y tasas apropiadas para $\hat{\eta}$, el estimador DML-PLIV es $\sqrt{n}$-consistente y asintóticamente Gaussiano.

La relevancia no es un supuesto binario. El teorema pide $\mathrm{Cov}(Z, v) \neq 0$, pero la aproximación asintótica que lo respalda se degrada continuamente a medida que esa covarianza se acerca a cero. Con instrumentos **débiles**, el estimador IV es sesgado hacia OLS, su distribución muestral deja de ser aproximadamente normal, y los intervalos de confianza convencionales sub-cubren de forma severa —el problema es de la aproximación asintótica misma, no del tamaño de muestra—. El diagnóstico convencional es el estadístico F de la primera etapa sobre los instrumentos excluidos, con el umbral $F > 10$ que Stock et al. (2005) derivaron: no es una regla arbitraria, sino el valor que acota el sesgo relativo del 2SLS respecto al OLS por debajo

Algoritmo

Entrada: Panel $\{(Y_{it}, D_{it}, X_{it})\}_{\{i=1,\dots,N\}}^{\{t=1,\dots,T\}}$, K folds, learners $\mathcal{L}_g$, $\mathcal{L}_m$ para estimar nuisance.
Salida: $\hat{\theta}$ y error estándar cluster-robusto $\widehat{\text{se}}\big(\hat{\theta}\big)$.
Aplicar within-transformation a Y, D, X para obtener $\tilde{Y}$, $\tilde{D}$, $\tilde{X}$ mediante Ecuación (17.72).
Dividir las N unidades en K folds por clúster (*cluster cross-fitting*).
for k = 1 **to** K **do**

Estimar $\hat{g}^k\big(\tilde{X}\big)$ con $\mathcal{L}_g$ en datos fuera del fold k.
Estimar $\hat{m}^k\big(\tilde{X}\big)$ con $\mathcal{L}_m$ en datos fuera del fold k.
Calcular los residuos ortogonales en el fold k: $\hat{v}_{it} = \tilde{D}_{it} - \hat{m}^k\big(\tilde{X}_{it}\big)$, $\hat{u}_{it} = \tilde{Y}_{it} - \hat{g}^k\big(\tilde{X}_{it}\big)$.

end for
Construir el estimador DML: $\hat{\theta} = \Big(\sum_{i,t} \hat{v}_{it}\tilde{D}_{it}\Big)^{-1} \sum_{i,t} \hat{v}_{it}\hat{u}_{it}$.
Estimar la varianza cluster-robusta: $\widehat{\text{Var}}\big(\hat{\theta}\big) = \big(\frac{1}{n^2}\big) \sum_{c=1}^{N} \Big(\sum_{t=1}^{T} \hat{\psi}_{ct}\Big)^2$.
return $\hat{\theta}$, $\sqrt{\widehat{\text{Var}}\big(\hat{\theta}\big)}$ como error estándar.

Algoritmo 8.: DML-panel con within-transformation

del 10% en el caso de un instrumento. Reportar ese F es obligatorio en cualquier diseño IV de este curso, y el 30 lo convierte además en una métrica de monitoreo continuo, porque la fuerza de un instrumento puede erosionarse con el tiempo sin que ninguna otra señal lo advierta.

Dos advertencias específicas del contexto de este capítulo. Primera: con muchos instrumentos —el escenario natural cuando se generan instrumentos con ML— el umbral de 10 deja de ser adecuado y hay que recurrir a diagnósticos para muchos instrumentos; Belloni et al. (2012) tratan precisamente el caso de selección de instrumentos óptimos con LASSO. Segunda: usar ML para estimar $\hat{r}(X) = E[Z \mid X]$ y luego calcular el F sobre los residuos ortogonalizados no es lo mismo que el F de una primera etapa lineal, y las tablas de Stock–Yogo no son directamente aplicables; conviene reportar ambos y no presentar el segundo como si tuviera la garantía del primero.

El complemento del diagnóstico de primera etapa es la **inferencia robusta a instrumentos débiles**. El test de **Anderson–Rubin** invierte tests de hipótesis sobre θ: el IC se construye como el conjunto de valores θ_0 para los que no se rechaza $H_0 : \theta = \theta_0$, y es válido cualquiera sea la fuerza del instrumento — a costa de poder ser un conjunto, no un intervalo, cuando la identificación es débil. Con muchos instrumentos, los tests de **Kleibergen–Paap** y el criterio de **Stock–Yogo** para tamaño de test (Stock et al. (2002); Andrews et al. (2019)) reemplazan al F de un solo instrumento.

Regla operativa del curso: si $F \leq 10$, el reporte del diseño IV incluye el IC de Anderson–Rubin junto al de Wald; si el IC-AR difiere materialmente del IC-Wald, la estimación se declara sensible a la fuerza del instrumento y el 30 la monitorea con doble umbral.

17.2.4 Garantías

El algoritmo anterior hereda las garantías del DML estándar (capítulo 11) sobre los datos within-transformados. Específicamente:

- $\sqrt{n}\big(\hat{\theta} - \theta_0\big) \xrightarrow{d} N(0, \mathcal{V})$ cuando $n \to \infty$, donde $\mathcal{V}$ es la semiparamétrica eficiente para el PLR.
- La varianza asintótica se estima consistentemente mediante la agregación por clúster de la *influence function*, capturando la correlación intra-unidad.
- La within-transformation elimina el sesgo por α_i y δ_t sin requerir estimación directa de $N + T$ efectos fijos, lo que sería inviable con ML en paneles largos.

El teorema de DML-PLIV extiende estas garantías al caso con instrumentos, siempre que se cumplan las condiciones de exclusión y relevancia.

17.3 Implementación en Python

17.3.1 DML sobre panel sintético con ground truth

```
# Requiere DoubleML >= 0.6.0
# pip install doubleml>=0.6.0
import pandas as pd
import numpy as np
from doubleml import DoubleMLPLR, DoubleMLData
from sklearn.ensemble import RandomForestRegressor

df = pd.read_csv("../data/datasets/synthetic/panel/panel_fe_dynamic/
student.csv")
truth = pd.read_csv("../data/datasets/synthetic/panel/panel_fe_dynamic/
truth_instructor_only.csv")
# Panel: unit_id, time, treated_group, treated, y_outcome
# Verdad: tau_i_truth (CATE por unidad)

# Within-transformation
def within_transform(df, var, unit="unit_id", time="time"):
    """Y_it - Y_i. - Y_.t + Y_.."""
    g_i = df.groupby(unit)[var].transform("mean")
    g_t = df.groupby(time)[var].transform("mean")
    g_global = df[var].mean()
    return df[var] - g_i - g_t + g_global

df["Y_tilde"] = within_transform(df, "y_outcome")
df["D_tilde"] = within_transform(df, "treated")

# Crear covariables: usar tiempo y unidad como proxy (en la practica se usarian
X reales)
# Aqui usamos interacciones time x unit como controles sinteticos
df["time_x_unit"] = df["time"] * df["unit_id"]
X = df[["time", "unit_id", "time_x_unit"]].values

# DML con cross-fitting por cluster (unidad)
# Nota: Si la libreria no soporta cluster cross-fitting para PLR en la version
usada,
# implementar DML manual con GroupKFold y varianza cluster-robusta.
from doubleml import DoubleMLClusterData, DoubleMLPLR

obj_dml = DoubleMLPLR(
    DoubleMLClusterData.from_arrays(
        x=X,
        y=df["Y_tilde"].values,
        d=df["D_tilde"].values,
        cluster_vars=df["unit_id"].values,
    ),
    ml_l=RandomForestRegressor(n_estimators=100, min_samples_leaf=10,
random_state=42),
    ml_m=RandomForestRegressor(n_estimators=100, min_samples_leaf=10,
random_state=42),
    n_folds=5,
)
obj_dml.fit()
print(obj_dml.summary)
# Verdad
print(f"ATE verdadero: {truth['tau_i_truth'].mean():.4f}")
```

Listado 17.1: DML sobre panel sintético.

17.3.2 DMLIV sobre close_college

```
import pandas as pd
from doubleml import DoubleMLPLIV, DoubleMLData
from sklearn.ensemble import RandomForestRegressor, GradientBoostingRegressor

df = pd.read_csv("../data/datasets/real/public_causaldata/close_college/
data.csv")
# Y=lwage, D=educ, Z=nearc4, X=controles
Y = df["lwage"].values
D = df["educ"].values
Z = df["nearc4"].values
X = df[["black", "smsa", "south", "married", "exper"]].values

obj = DoubleMLPLIV(
    DoubleMLData.from_arrays(X, Y, D, z=Z),
    ml_l=GradientBoostingRegressor(n_estimators=200, random_state=42),
    ml_m=GradientBoostingRegressor(n_estimators=200, random_state=42),
    # Verificar version de DoubleML:
    # - Si PLIV requiere ml_g, especificar ml_g=GradientBoostingRegressor(...)
    # - Para Z binario, usar E[Z|X] (regresor) o clasificador con
predict_proba[:,1]
    ml_r=GradientBoostingRegressor(n_estimators=200, random_state=42),  # E[Z|
X] como regresion (Z binario)
    ml_g=None,  # No se usa para PLIV simple
    n_folds=5,
)
obj.fit()
print(obj.summary)
```

Listado 17.2: DML-PLIV sobre close_college.

17.4 Caso empírico y validación

Réplica propia sobre el dataset del repositorio. Sobre el dataset sintético `panel_fe_dynamic` (con ground truth conocido), el DML-panel produce un estimado ATE consistente con el valor verdadero $\tau \approx 1.0$. El estimador FE clásico (LSDV) puede sobreestimar el efecto al no capturar no linealidades en X_{it}. La figura Figura 17.1 muestra la sensibilidad de DML-panel al número de folds K del cross-fitting.

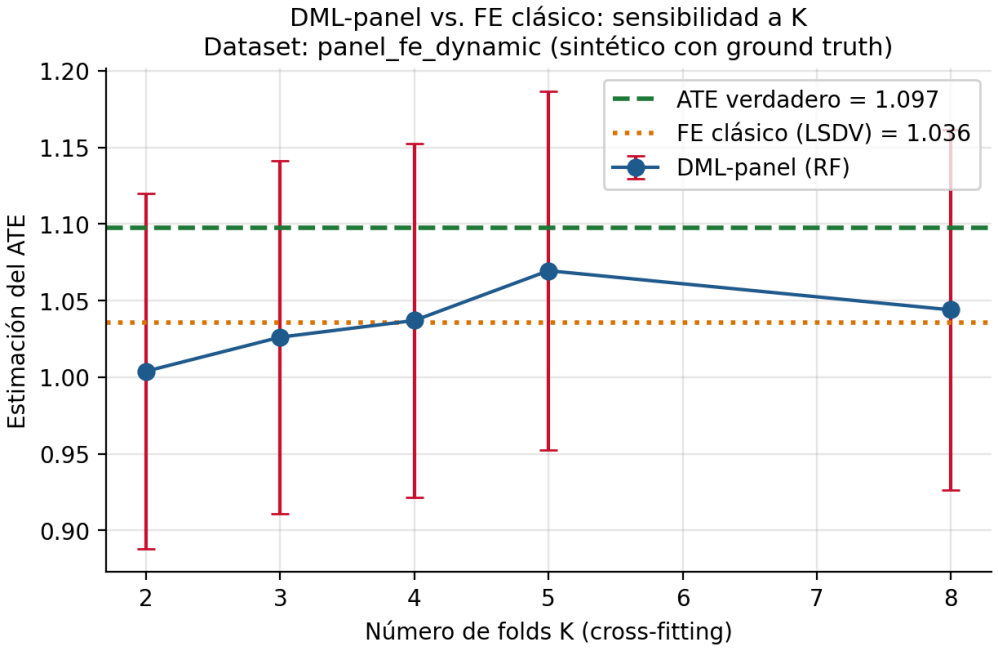


Figura 17.1: DML-panel vs. FE clásico (LSDV): sensibilidad al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea verde punteada es el ATE verdadero; la naranja punteada es el estimador FE clásico. Dataset: `panel_fe_dynamic` (sintético con ground truth).

La figura muestra que el estimador DML-panel es estable en K y consistente con el valor verdadero, mientras que el FE clásico (LSDV) exhibe un sesgo sistemático atribuible a la omisión de la estructura no lineal en X_{it}. Esto valida la recomendación de usar DML-panel cuando se sospecha no linealidad sustantiva en los controles.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
No hacer within--transformation	Sesgo por α_i no observado	Comparar FE vs DML sin within	Aplicar within-transformation siempre
Cross-fitting por observación en lugar de por clúster	Errores estándar incorrectos (subestimación)	Verificar cluster folds en código (`cluster_vars`)	Usar `GroupKFold` o `DoubleMLClusterData`
Adopción escalonada con efectos heterogéneos	**Estimando mal definido**: pesos negativos en TWFE; el coeficiente puede tener signo opuesto al efecto verdadero	*Event study* con leads y lags; descomposición de Goodman-Bacon para cuantificar las comparaciones prohibidas'" y sus pesos	Cambiar de estimador, no de *learner*: Callaway–Sant'Anna, Sun–Abraham o Borusyak et al. Ningún ajuste de $\hat{g}, \hat{m}$ corrige un peso negativo
Instrumento débil (DML-PLIV)	Sesgo hacia OLS, distribución no normal, IC que sub-cubren	F de primera etapa sobre instrumentos excluidos; umbral convencional $F > 10$ (Stock et al. 2005)	Reportar siempre el F; IC de Anderson–Rubin junto al Wald si $F \leq 10$; con muchos instrumentos usar diagnósticos específicos
Varianza IID en presencia de correlación intra-clúster	Errores estándar subestimados, inferencia inválida	Calcular SE cluster-robustos y comparar con IID	Agregar influence function por clúster: $\widehat{\mathrm{Var}}\left(\hat{\theta}\right) = \left(\frac{1}{n^2}\right)\sum_c \left(\sum_{i\in c}\hat{\psi}_i\right)^2$
Within-transformar Y y D pero no X	Interpretación incorrecta de los controles	Verificar que X_{it} también se transforme o justificar su inclusión cruda	Aplicar within-transformation también a X_{it} o explicitar que `unit_id` es proxy de FE

Tabla 17.1: Riesgos comunes en DML-panel

Intuición

Caja de profundización 9.1: Diferencias-en-Diferencias moderno

Objetivo. Entender los problemas del DiD clásico cuando el tratamiento se adopta en distintos momentos, y por qué la within-transformation de este capítulo no los resuelve.

El problema de la adopción escalonada. Cuando distintas unidades reciben el tratamiento en distintos períodos (staggered adoption'"), el estimador de Two-Way Fixed Effects (TWFE) no estima el ATT sino un promedio ponderado de comparaciones 2×2. Goodman-Bacon (2021) descompone exactamente ese promedio (la **descomposición de**

Goodman-Bacon) y muestra que incluye comparaciones prohibidas"": unidades recién tratadas contra unidades **ya tratadas antes**, que actúan como controles pese a estar bajo tratamiento.

La consecuencia es más grave de lo que parece. Chaisemartin et al. (2020) demuestran que, con efectos heterogéneos en el tiempo, algunos de esos pesos son **negativos**: el coeficiente TWFE puede tener signo opuesto al efecto verdadero **aunque el efecto sea del mismo signo para todas las unidades y todos los períodos**. No es un problema de precisión que más datos resuelvan; es un problema de que el estimando implícito no es el que se quiere.

Qué implica esto para el DML-panel de este capítulo. La within-transformation de la 17.2.1 es TWFE, y por tanto **hereda el problema completo** si la adopción es escalonada y los efectos heterogéneos. El supuesto de efecto constante de la 17.2.2 no es una simplificación pedagógica menor: es exactamente lo que sostiene la validez del procedimiento. Flexibilizar los *nuisance* con ML no repara un estimando mal definido — ninguna cantidad de *gradient boosting* en $\hat{g}$ y $\hat{m}$ corrige un peso negativo.

Estimadores robustos.

- **Event study:** graficar el efecto en cada período alrededor del tratamiento. Permite ver tendencias pre-tratamiento y dinámica post-tratamiento. Punto de partida obligatorio.
- **Callaway et al. (2021):** estimar el ATT(g, t) para cada cohorte de adopción g y período t usando solo controles nunca tratados o aún no tratados, y agregarlos con pesos explícitos y declarados.
- **Sun et al. (2021):** corrección análoga para especificaciones de *event study*, mediante interacciones cohorte × período (estimador interaction-weighted'").
- **Borusyak et al. (2024):** enfoque de imputación —estimar el contrafactual con los datos no tratados y imputar— eficiente bajo homocedasticidad.

Recomendación. Comenzar siempre con un *event study*. Si hay adopción escalonada, no usar TWFE (ni DML-panel sobre datos within-transformados) sin antes verificar la descomposición de Goodman-Bacon; si hay pesos negativos materiales, cambiar de estimador antes de preocuparse por la flexibilidad de los controles.

17.4.1 Diseños con tiempos de tratamiento escalonados

Para diseños con staggered adoption (tratamiento adoptado en diferentes periodos), los estimadores de efectos fijos bidireccionales (TWFE) pueden producir ponderaciones negativas y sesgo de heterogeneidad ((Goodman-Bacon 2021), Goodman-Bacon 2021; (Chaisemartin et al. 2020), de Chaisemartin & D'Haultfœuille 2020).

Extensiones modernas que corrigen este problema:

- Estimador de Callaway & Sant'Anna ((Callaway et al. 2021)): agregación de ATT(g,t) por cohorte
- Estimador de Sun & Abraham ((Sun et al. 2021)): interacción de cohorte × periodo

- Estimador de Borusyak et al. ((Borusyak et al. 2024)): imputación de contrafactuales

En la práctica, usar el paquete `did` (Callaway & Sant'Anna) o `fixest` (Sun & Abraham) para DiD con tratamiento heterogéneo en tiempo.

17.5 Ejercicios propuestos

1. Replique el listado Listado 17.1 usando `GradientBoostingRegressor` en lugar de `RandomForestRegressor`. ¿Mejora la precisión?
2. Sobre el dataset `did_parallel_ok` (sintético), estime el efecto DiD usando DML-panel y compárelo con el DiD clásico.
3. Aplique DML-PLIV al dataset `iv_noncompliance` (sintético con IV) y verifique que el estimado se acerca al verdadero LATE.
4. Construya un panel donde el supuesto de tendencias paralelas se vulnere. Muestre que DML-panel produce un estimado sesgado en ese caso.

17.6 Lecturas complementarias

Chernozhukov et al. (2018b) cubre DML-PLIV; Bach et al. (2022) documenta la implementación en `DoubleML`, incluida la variante con *cluster cross-fitting* usada en la 17.2.3.1. Sobre instrumentos débiles, Stock et al. (2005) es la referencia del umbral $F > 10$ y Belloni et al. (2012) la del caso con muchos instrumentos seleccionados por LASSO.

La literatura de DiD con adopción escalonada es donde más ha cambiado el estado del arte en los últimos años, y conviene leerla en orden: Goodman-Bacon (2021) descompone el estimador TWFE y muestra de dónde vienen las comparaciones problemáticas; Chaisemartin et al. (2020) establecen el resultado de pesos negativos que hace inservible a TWFE bajo heterogeneidad; y las tres propuestas correctivas principales son Callaway et al. (2021) (agregación explícita de $\text{ATT}(g,t)$), Sun et al. (2021) (event study con interacciones cohorte–período) y Borusyak et al. (2024) (imputación del contrafactual). Para el diagnóstico de tendencias pre-tratamiento en diseños de event study, (Freyaldenhoven et al. 2019). El 28 retoma esta misma familia de problemas desde el ángulo del control sintético y la *matrix completion*.

Capítulo 18

Diseño de investigación y selección de método

Cuadro sinóptico del capítulo

Problema:	Elegir el diseño causal apropiado según características del problema
Estimando:	ATE, ATT, CATE, LATE, policy value
Identificación:	No confusión, validez de instrumentos, continuidad local, tendencias paralelas, combinación convexa
Método:	Mapa de decisión basado en teoría económica, supuestos de identificación y garantías estadísticas
Nuisance:	Dimensión (p vs n), heterogeneidad, endogeneidad, estructura temporal
Garantía:	Identificación bajo supuestos propios de cada diseño; ranking por fuerza del diseño
Librerías:	DoubleML, econml, causalml, statsmodels
Validación:	Placebos, sensibilidad a supuestos, especificación jerárquica

Nota técnica

Este capítulo cierra la Parte III sintetizando los tres diseños de identificación completos del libro —Post-Double-Selection (16), DML de panel e instrumental (17), y el DML no estructurado de la Parte II (11)— en un único mapa de decisión, además de anticipar los diseños de heterogeneidad y **targeting** de la Parte V.

18.1 Motivación aplicada

Un analista del Banco Central recibe un encargo: estimar el efecto causal de una política monetaria sobre la inflación. Dispone de datos mensuales de 10 años, 30 covariables macroeconómicas, y la política se implementó en distintos momentos en distintos países. ¿Qué método usar? ¿DML? ¿DiD clásico? ¿Control sintético? ¿Causal Forest? ¿Alguno de los anteriores?

La elección metodológica es la decisión más importante en inferencia causal aplicada. Un método inadecuado produce estimaciones sesgadas y conclusiones equivocadas, sin importar cuán sofisticada sea la implementación. Este capítulo no presenta métodos nuevos: organiza los ya vistos en un *mapa de decisión* operacional, conectando las características del problema (dimensión, heterogeneidad, diseño, disponibilidad de instrumentos) con el método apropiado.

18.2 Problema causal, estimando e identificación

18.2.1 Dimensiones del problema causal

Todo problema de inferencia causal aplicada puede caracterizarse en seis dimensiones que determinan la identificabilidad del efecto y el método apropiado:

1. **Dimensión de controles p vs. tamaño muestral n.** Si $p \ll n$ y las relaciones son lineales, OLS clásico basta. Si $p \sim n$ o $p > n$, se requieren métodos de alta dimensión (PDS, DML).
2. **Heterogeneidad del efecto.** Si el CATE se asume constante, PLR es suficiente. Si hay heterogeneidad estructurada, se requiere IRM, meta-learners o causal forest.
3. **Endogeneidad del tratamiento.** Si se asume no confusión, los métodos de selección observable (matching, IPW, DML) aplican. Si hay endogeneidad por variables no observadas, se requieren instrumentos (IV, DMLIV) o diseños cuasi-experimentales (RDD, DiD).
4. **Estructura temporal.** Corte transversal, panel, serie temporal, o *staggered adoption* determinan la elección entre métodos.
5. **Disponibilidad de instrumentos.** Si hay instrumentos válidos, IV/DMLIV. Si no, hay que justificar no confusión o usar métodos sensibles.
6. **Objetivo de la estimación.** ATE, ATT, CATE, policy value, o LATE son estimandos distintos que requieren métodos distintos.

18.2.2 Estimando e identificación

El estimando define qué cantidad poblacional queremos aprender. Los más frecuentes en la práctica son:

- **«ATE»** $= E[Y(1) - Y(0)]$: efecto promedio en toda la población. Identificable bajo no confusión y solapamiento.
- **«ATT»** $= E[Y(1) - Y(0) \mid D = 1]$: efecto en los tratados. Requiere no confusión para los no tratados.
- **CATE** $= E[Y(1) - Y(0) \mid X = x]$: efecto condicional en covariables. Requiere no confusión dentro de subgrupos.
- **«LATE»** $= E[Y(1) - Y(0) \mid \text{compliers}]$: efecto local en compliers. Identificable bajo monotonía y exclusión con IV.
- **Policy value** $= E[Y(\pi(X))]$: valor de una regla de asignación. Estimable con policy learning.

La identificación—esto es, expresar el estimando como función de la distribución observada — depende de supuestos propios de cada diseño. La tabla de identificación jerárquica de la sección 18.3 resume la fuerza de cada diseño y el supuesto clave que la sostiene.

18.3 Teoría, supuestos y garantías

18.3.1 Mapa de decisión metodológica

La tabla Tabla 18.1 organiza el mapa según diseño, dimensión y heterogeneidad, emparejando cada combinación con el método clásico y su contraparte de ML.

Diseño	**Dimensión**	**Heterog.**	**Método clásico**	**Método ML**
Corte transversal	$p \ll n$	No	OLS	—
Corte transversal	$p \sim n$	No	PDS LASSO	DML-PLR
Corte transversal	$p \ll n$	Sí	Subgrupos ad hoc	Meta-learners, Causal Forest
Corte transversal	$p \sim n$	Sí	—	DML-IRM, Causal Forest
IV	$p \ll n$	No	2SLS	—
IV	$p \sim n$	No	PDS-IV	DML-PLIV
RDD	—	No	Local linear	—
DiD	—	No	TWFE	—
Panel staggered	—	No	Callaway–Sant'Anna, Sun–Abraham, SDID (**nunca** TWFE)	Matrix completion
Panel con X_{it}	$p \sim n$	No	FE + controles	DML-panel
Policy optimization	—	Sí	—	Policy learning, uplift

Tabla 18.1: Mapa de decisión metodológica.

18.3.2 Identificación jerárquica de diseños

No todos los diseños tienen la misma *fuerza de identificación*. La tabla Tabla 18.2 clasifica los diseños según la credibilidad del supuesto clave que los sostiene, ordenados de mayor a menor fuerza identificadora.

Diseño	Fuerza	Supuesto clave
RCT	Alta	Aleatorización del tratamiento
IV	Alta	Relevancia del instrumento y restricción de exclusión
RDD	Alta	Continuidad local de potenciales resultados en el umbral
DiD	Media	Tendencias paralelas en ausencia del tratamiento
SCM	Media	Combinación convexa de unidades no tratadas
No confusión (selección observables)	Media-baja	No confusores no observados

Tabla 18.2: Identificación jerárquica de diseños causales.

Un diseño de mayor fuerza requiere supuestos más creíbles y, por tanto, produce estimaciones más robustas. Al elegir un método, el investigador debe priorizar el diseño de mayor fuerza que sea factible dados los datos disponibles.

18.3.3 Criterios adicionales de selección

Más allá del mapa y la jerarquía de identificación, tres criterios refinan la elección:

Calidad de los controles. Si los controles son ruidosos o mal medidos, los métodos de ML (que los usan intensivamente) pueden empeorar la estimación. En tales casos, métodos que dependen menos de X (DiD, RDD) son preferibles.

Tamaño muestral. Causal Forest y Deep Causal requieren $n > 1,000$ para producir estimaciones útiles. Con $n < 500$, métodos más parsimoniosos (OLS, matching) son preferibles.

Capacidad computacional. Deep causal (TARNet, CFRNet) requiere GPU. En entornos limitados, métodos basados en árboles (Causal Forest) son escalables.

Intuición

Caja de profundización 10.1: Regresión Discontinua y transportabilidad

Objetivo. Completar el mapa de decisión con dos métodos adicionales: RDD y transportabilidad.

RDD (Regression Discontinuity). Cuando el tratamiento se asigna según un umbral en una variable continua (ej: beca para alumnos con puntaje > 70), podemos comparar a quienes quedaron justo arriba vs justo abajo. Es como un experimento local alrededor del corte.

$$\tau_{\text{RD}} = \lim_{x \to c^+} E[Y \mid X = x] - \lim_{x \to c^-} E[Y \mid X = x] \tag{18.77}$$

RDD difuso (Fuzzy RDD). Si el umbral no se cumple perfectamente (algunos de abajo reciben el tratamiento y viceversa), el RDD se convierte en un diseño de variables instrumentales donde el umbral es el instrumento.

Transportabilidad. Una pregunta clave: si entrenamos un modelo con datos de una población (ej: Santiago), ¿sirve para otra población (ej: Temuco)?

- **Covariate shift:** la distribución de X cambia.
- **Target shift:** la relación causal cambia.
- Los diagramas de selección ayudan a decidir si un efecto es transportable.

18.4 Implementación en Python

18.4.1 Función `choose_method`

```
def choose_method(n, p, has_iv, is_panel, has_heterogeneity,
treatment_staggered=False):
    """Devuelve el metodo recomendado segun las caracteristicas del problema.

    ADVERTENCIA: es una heuristica de primer descarte, no un sustituto del
    analisis de identificacion. Presupone que la pregunta causal, el
    estimando y el grafo ya estan definidos (Caps. 3 y 8).
    """
    if is_panel and treatment_staggered:
        # Callaway-Sant'Anna / Sun-Abraham para el ATT(g,t); Synthetic DiD
        # (Arkhangelsky et al. 2021) o Matrix Completion (Athey et al. 2021)
        # cuando hay pocas unidades tratadas. Nunca TWFE: pesos negativos
        # (de Chaisemartin & D'Haultfoeuille 2020). Ver Cap. 17.
        return ("Callaway-Sant'Anna / Sun-Abraham; Synthetic DiD "
                "o Matrix Completion si hay pocas unidades tratadas")
    if is_panel and not treatment_staggered:
        if p > n * 0.5:
            return "DML-panel con within-transformation"
        else:
            return "FE clasico (LSDV) con controles manuales"
    # Corte transversal
    if has_iv:
        if p > n * 0.3:
            return "DML-PLIV con GBM o RF"
        else:
            return "2SLS clasico"
    # Sin IV
    if has_heterogeneity:
        if n < 1000:
            return "Meta-learners (T-learner o X-learner)"
        else:
            return "Causal Forest (CausalForestDML)"
    else:
        if p > n * 0.3:
            return "DML-PLR con LassoCV o GBM"
        elif p > 50:
            return "Post-Double-Selection LASSO"
        else:
            return "OLS con controles manuales (HC1)"

# Ejemplos
print(choose_method(n=500, p=80, has_iv=False, is_panel=False,
has_heterogeneity=True))
print(choose_method(n=2000, p=5, has_iv=True, is_panel=False,
has_heterogeneity=False))
print(choose_method(n=200, p=10, has_iv=False, is_panel=True,
has_heterogeneity=False,
                    treatment_staggered=True))
```

Listado 18.1: Función de decisión metodológica.

18.5 Caso empírico y validación

18.5.1 Análisis crítico de 4 problemas

```
# Problema: efecto de educacion sobre salario. n=3000, p=15, IV=nearc4
metodo = choose_method(n=3000, p=15, has_iv=True, is_panel=False,
has_heterogeneity=False)
print(f"Caso 1 (Card 1995): {metodo}")
# Recomendacion: 2SLS clasico (p << n, IV disponible, sin heterogeneidad
estructurada)
```

Listado 18.2: Caso 1: retorno a la educación.

18.5.2 Validación de la elección metodológica

Para cada caso aplicado, la elección metodológica debe validarse mediante:

- **Placebo del tratamiento:** asignar un tratamiento falso y verificar que el estimador no encuentra efecto.
- **Sensibilidad a supuestos:** variar el método dentro del mismo diseño (ej: distintos K en cross-fitting, distintos learners) y verificar estabilidad.
- **Comparación con diseños más débiles:** si es posible, estimar con un diseño de menor fuerza y documentar la diferencia.

18.6 Errores comunes y límites

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Usar ML cuando los métodos clásicos bastan	Complejidad innecesaria, pérdida de interpretabilidad, inferencia no exacta	$p \ll n$ y linealidad razonable	Usar OLS con errores HC1
Usar DML sin justificar no confusión	Estimaciones sesgadas por endogeneidad no resuelta	Presencia de confusores no observados	Usar IV, RDD, DiD o control sintético
Cambiar de método según los resultados (*specification mining*)	Sesgo de selección; inferencia inválida	Elección metodológica posterior a ver los datos	Preregistrar el diseño; elegir método antes de estimar

Tabla 18.3: Riesgos comunes en la elección metodológica

Límites. El mapa es orientativo. Casos límite (panel con *staggered adoption* y heterogeneidad, IV con muchos instrumentos débiles, RDD con covariables de alta dimensión) requieren análisis experto más allá del mapa.

Hay además un límite de fondo que conviene explicitar, porque la existencia misma de una función `choose_method` invita a olvidarlo. El mapa organiza la elección de **estimador** dando por resuelta la de **identificación**, y esa es la parte fácil del problema. Las seis dimensiones de la 18.2 son observables en los datos —n, p, si hay panel, si hay un instrumento candidato—; las condiciones que realmente determinan la validez del resultado no lo son: si las covariables observadas cierran las rutas de puerta trasera, si el instrumento satisface la restricción de exclusión, si las tendencias habrían sido paralelas. Ningún argumento de la función captura eso, y ninguna heurística puede. La jerarquía de la Tabla 18.2 ordena diseños por la **credibilidad** de esos supuestos precisamente porque es lo que el mapa no puede decidir: elegir DML sobre OLS mejora la flexibilidad de la estimación, pero un diseño de mayor fuerza identificadora —cuando los datos lo permiten— mejora algo que ninguna cantidad de flexibilidad compensa.

18.7 Ejercicios propuestos

1. Para los siguientes cinco problemas, recomiende un método:
   - Efecto de un RCT sobre rendimiento escolar ($n = 5,000$, $p = 10$).
   - Efecto de una reforma tributaria sobre inversión ($n = 800$, $p = 100$).
   - Efecto de un programa social sobre pobreza, con staggered adoption en panel.
   - Efecto de un medicamento sobre presión arterial, con variable instrumental.
   - Efecto heterogéneo de becas sobre deserción ($n = 20,000$, $p = 50$).
2. Justifique por qué DML no es adecuado cuando hay confusión no observada. ¿Qué alternativas existen?
3. Discuta: ¿en qué casos el causal forest es preferible al R-learner, y viceversa?

18.8 Lecturas complementarias

Athey, Susan, Imbens, et al. (2019) ofrece una revisión moderna de métodos. Imbens et al. (2015) es la referencia canónica para métodos clásicos. Chernozhukov et al. (2018a) para DML. Athey (2017) para una perspectiva de política.

Parte V

Publicación y operación en producción

Esta parte, enteramente nueva en esta edición, lleva el estimador desplegado en la Parte II hasta un servicio publicado, documentado y operado responsablemente: model cards causales que declaran supuestos de identificación en Hugging Face Hub, y un pipeline de integración y despliegue continuo con pruebas estadísticas —no solo de software— antes de publicar cualquier actualización.

Capítulo 19

Model cards causales y publicación en Hugging Face Hub

Cuadro de decisión del capítulo

Decisión:	Documentar supuestos de identificación en la *model card*, no solo métricas de desempeño
Alternativas:	*Model card* estándar (solo *accuracy*/desempeño) vs. *model card* causal extendida
Trade-off clave:	Fricción de documentar más campos vs. riesgo de uso indebido del modelo por otros equipos
Stack:	`huggingface_hub`, Hugging Face Hub
Riesgo principal:	Que un consumidor del modelo lo use fuera de su población o supuestos de validez sin saberlo

Implementación en el monorepo del curso (2026)

Plantilla de *model card* causal del curso: `04_notebooks_produccion_hf/B2_hub_cicd/model_card/MODEL_CARD.md` (alineada al Apéndice G). Lab `L17`. Bundle para Hub: `scripts/prepare_hub_bundle.sh`. La card debe declarar estimando (ATE), supuestos, población del monorepo (`ihdp_medium`) y límites (datos sintéticos de benchmark; no uso clínico).

19.1 El problema de diseño

El Capítulo 15 sirvió el estimador DML como un endpoint que cualquiera puede consultar. Pero «poder consultarlo» no es lo mismo que «poder usarlo correctamente». Una *model card* —la práctica, ya estándar en la comunidad de ML, de documentar un modelo junto con sus métricas, datos de entrenamiento y limitaciones (Mitchell et al. 2019)— resuelve ese problema para modelos predictivos. El problema de diseño de este capítulo es que la *model card* estándar no tiene ningún campo para lo que más importa en un modelo **causal**: bajo qué supuestos de identificación es válido, para qué población se estimó el efecto, y qué covariables se controlaron.

Publicar un estimador causal en Hugging Face Hub con una *model card* genérica es, en la práctica, invitar a que se use fuera de su dominio de validez.

19.2 Opciones y trade-offs

Opciones y trade-offs

- ***Model card* estándar.** Documenta arquitectura, métricas de desempeño (*accuracy*, F1, RMSE) y, en el mejor de los casos, algunas consideraciones éticas generales. Es el formato que produce por defecto la plantilla de Hugging Face Hub. Para un modelo causal, es **insuficiente**: no hay campo para el DAG supuesto, ni para el conjunto de covariables de puerta trasera, ni para la población sobre la que el efecto es válido.
- ***Model card* causal extendida.** Añade explícitamente los campos que un modelo predictivo no necesita: estimando ($\tau(x)$, ATE, LATE), supuestos de identificación declarados, diseño (observacional/cuasi-experimental/experimental), población de entrenamiento y límites de validez externa. El costo es puramente de fricción —completar más campos antes de publicar—; no hay costo técnico ni de infraestructura.

La decisión no es realmente una disyuntiva difícil —la *model card* extendida domina a la estándar para cualquier modelo causal—, pero vale la pena presentarla como **trade-off** precisamente porque la opción por defecto de la mayoría de las herramientas (incluido el propio Hugging Face Hub) es la estándar, y usarla sin extenderla es la ruta de menor resistencia.

19.3 Decisión de referencia para el curso

Todo modelo publicado en el curso usa la plantilla de **model card causal** del Apéndice G, con los siguientes campos obligatorios más allá del formato estándar de Hugging Face: estimando, diseño de identificación, supuestos declarados (con referencia al DAG cuando exista uno), población de entrenamiento (con las variables que la delimitan), y una sección explícita de «no usar este modelo para» — el equivalente causal de las limitaciones de una *model card* estándar.

19.4 Implementación de referencia

```
---
license: mit
tags: [causal-inference, dml, econml]
---

# Estimador DML de retorno a la educacion

## Estimando
ATE del efecto de anios de educacion (`educ`) sobre el logaritmo del salario
(`wage`).

## Diseno de identificacion
Observacional. Supuesto de no confusion condicional en:
exper, black, south, married (ver DAG en `docs/dag.png`).

## Poblacion de entrenamiento
Hombres, 24-34 anios, encuesta NLS 1976 (Card, 1995). n=3,003.
**No valido fuera de este rango etario ni fuera de EE.UU.**

## Metricas
ATE estimado: 0.071 (IC 95%: [0.058, 0.084])
Cross-fitting: K=5. Learner: GradientBoostingRegressor.

## No usar este modelo para
- Poblaciones fuera del rango de entrenamiento (ver @cap-generalizacion-
transportabilidad).
- Decisiones individuales sin considerar el intervalo de confianza del CATE.
- Cualquier uso que reinterprete el ATE como un efecto garantizado a nivel
individual.
```

Listado 19.1: Plantilla mínima de *model card* causal.

```
from huggingface_hub import HfApi, upload_file

api = HfApi()
repo_id = "curso-ia-causal/dml-retorno-educacion"
api.create_repo(repo_id, repo_type="model", exist_ok=True)

upload_file(path_or_fileobj="model/dml_estimator.joblib",
            path_in_repo="dml_estimator.joblib", repo_id=repo_id)
upload_file(path_or_fileobj="model/causal_schema.joblib",
            path_in_repo="causal_schema.joblib", repo_id=repo_id)
upload_file(path_or_fileobj="MODEL_CARD.md",
            path_in_repo="README.md", repo_id=repo_id)  # HF renderiza
README.md como model card
```

Listado 19.2: Publicación del modelo y su *model card* en el Hub.

19.5 Aplicación al sistema causal del curso

La sección «No usar este modelo para» del listado Listado 19.1 cita directamente el capítulo de generalización y transportabilidad (Capítulo 26, más adelante en el curso), que formaliza precisamente cuándo un efecto estimado en una población es válido en otra. Documentar la población de entrenamiento en la *model card* no es un ejercicio de transparencia general: es la información mínima que otro analista necesitaría para aplicar, correctamente, el criterio de transportabilidad de ese capítulo antes de reutilizar el modelo.

19.6 Señales de alerta y checklist operativo

- ☐ La *model card* reporta métricas de desempeño pero no menciona el diseño de identificación ni los supuestos.
  ☐ No existe una sección explícita de «no usar para», dejando implícito el dominio de validez.
  ☐ El repositorio del Hub no incluye el `CausalSchema` (4) junto al modelo serializado, obligando a cualquier consumidor a adivinar qué covariables espera.
  ☐ La *model card* no se actualizó tras reentrenar el modelo con datos nuevos (riesgo ya anticipado en el 2).
  ☐ El bundle publicado incluye el JSON Schema validado (Ap. G.4), no solo el Markdown.

19.7 Ejercicios y notas bibliográficas

19.7.1 Ejercicios conceptuales

1. Compare la plantilla de *model card* causal del listado Listado 19.1 con una *model card* estándar de un modelo de clasificación de Hugging Face Hub (busque un ejemplo público). Liste tres campos presentes en la causal y ausentes en la estándar, y explique por qué cada uno importa específicamente para un modelo causal.
2. (Arnold et al. 2019) propone una idea relacionada pero distinta a las *model cards*: las FactSheets como «declaración de conformidad del proveedor». Investigue brevemente la diferencia de enfoque y discuta si sería más o menos apropiada que una *model card* para un estimador causal publicado por un equipo interno (no un proveedor externo).

19.7.2 Ejercicio de infraestructura

1. Complete la primera mitad del Notebook de producción B2: adapte la plantilla del listado Listado 19.1 al modelo de su Notebook A2, publique el repositorio en Hugging Face Hub con el listado Listado 19.2, y verifique que la *model card* se renderiza correctamente en la página del repositorio.

19.7.3 Notas bibliográficas

Mitchell et al. (2019) introduce el formato de *model card* que este capítulo extiende. Gebru et al. (2021) propone la pieza complementaria y, para un sistema causal, igual de necesaria: las **datasheets for datasets**, que documentan cómo se recolectaron los datos, con qué propósito, quién los financió y qué preprocesamiento sufrieron. La documentación de datasets mediante datasheets ((Gebru et al. 2021), Gebru et al. 2021) es análoga a las Model Cards para modelos causales (Apéndice G) y debe incluir información sobre motivación, composición, proceso de recolección, preprocesamiento, usos recomendados y consideraciones éticas. La conexión con este curso es directa y vale la pena hacerla explícita: la mitad de los campos que una datasheet exige —cómo se seleccionaron las unidades, si hubo criterios de elegibilidad, qué instancias faltan— son exactamente la **ficha de procedencia del tratamiento** del 7, y son la información sin la cual un consumidor externo no puede evaluar si el supuesto de identificación declarado en la *model card* es siquiera plausible. Una *model card* causal sin su datasheet documenta el modelo pero no lo que lo hace válido. Arnold et al. (2019) propone un tercer formato, orientado a proveedores de servicios de IA, con más énfasis en cumplimiento normativo. La discusión de documentación de interfaces de inferencia en general se retoma de (Kästner et al. 2024), Capítulo 10; su versión legible por máquina es el endpoint `/metadata` del 15.

Capítulo 20

CI/CD para modelos causales

Cuadro de decisión del capítulo

Decisión:	El pipeline de CI debe correr pruebas de sanidad estadística, no solo pruebas de código
Alternativas:	CI genérico (solo tests de software) vs. CI con pruebas estadísticas causales integradas
Trade-off clave:	Tiempo de ejecución del pipeline vs. riesgo de publicar automáticamente un modelo roto
Stack:	GitHub Actions, `pytest`, Docker
Riesgo principal:	Que un cambio de código pase todos los tests de software y aun así rompa la validez causal

Implementación en el monorepo del curso (2026)

Workflows de referencia: `.github/workflows/b1_smoke.yml` y `course_practice_ci.yml` (pytest Serie A, labs, humo B1–B4). Lab `L18`. Autograders: `grade_b1.py`…`grade_b4.py`. Auditoría local de un comando: `bash scripts/audit_repo.sh`. CI genérico de software **no basta**: el pipeline del curso exige humo de efecto/API/política.

20.1 El problema de diseño

El Capítulo 15 construyó el servicio; el Capítulo 19 lo publicó en el Hub. Ninguno de los dos automatizó lo que ocurre **después**: cuando alguien modifica el código —agrega una covariable, cambia el *learner* de *nuisance*, actualiza los datos de entrenamiento— ¿qué garantiza que la nueva versión no rompió algo antes de que se publique automáticamente? Un pipeline de CI/CD genérico —el que prueba, por ejemplo, que el endpoint responde con el código HTTP correcto— no detecta absolutamente nada sobre si el efecto estimado sigue siendo razonable. El problema de diseño de este capítulo es que un sistema causal necesita, además de las pruebas de software estándar, pruebas que sean sensibles a **lo que este curso entiende por**

«romperse»: que un placebo deje de dar cero, que el intervalo de confianza colapse o se dispare, que el soporte común desaparezca con los nuevos datos.

20.2 Opciones y trade-offs

Opciones y trade-offs

- **CI genérico.** Corre únicamente pruebas de software: ¿el código importa sin error?, ¿el endpoint responde?, ¿el contenedor construye? Es rápido (segundos a minutos) y es lo que la mayoría de las plantillas de GitHub Actions ofrecen por defecto. No detecta ningún problema de validez estadística: un cambio que introduce un mal control (8) pasa este CI sin ninguna advertencia.
- **CI con pruebas estadísticas integradas.** Además de las pruebas de software, ejecuta la prueba placebo y el chequeo de balance ya usados en capítulos anteriores (7, 14) como parte del pipeline automatizado, con umbrales que, si se violan, bloquean la publicación automática. Es más lento (minutos, porque implica reentrenar o reestimar sobre datos de prueba) y requiere mantener un dataset de referencia fijo para que las pruebas sean reproducibles, pero es la única opción que previene que una regresión estadística llegue a producción sin supervisión humana.

20.3 Decisión de referencia para el curso

El pipeline de referencia del curso corre en dos etapas: una etapa rápida de pruebas de software (segundos) en cada *push*, y una etapa de pruebas estadísticas (la prueba placebo del 14 sobre un dataset de referencia fijo) que se ejecuta antes de cualquier publicación al Hub, no en cada *commit*. Esta separación —común en la práctica de CI/CD general y aquí adaptada al caso causal— evita que cada cambio menor de código dispare un reentrenamiento costoso, sin sacrificar la garantía de que nada se publica sin pasar la prueba de sanidad estadística.

El curso implementa este pipeline con GitHub Actions y `pytest` por una razón puramente pedagógica —son las herramientas de menor fricción para un estudiante sin infraestructura previa—, no porque sean las únicas ni las mejores. Conviene por tanto situar la decisión dentro del ecosistema estándar, porque un equipo real ya tendrá parte de esta infraestructura resuelta: **MLflow** o **Weights & Biases** para registrar experimentos y versionar artefactos de modelo (aquí, el `.joblib` del estimador y su `CausalSchema`); **DVC** para versionar el dataset de referencia sobre el que corren las pruebas estadísticas, resolviendo el problema que el checklist de este capítulo señala como crítico; **Great Expectations** o **Pandera** para validar el esquema y los rangos de los datos de entrada; **Evidently** para el monitoreo de *drift* que el 30 desarrolla. Ninguna de estas herramientas, sin embargo, ofrece la etapa que este capítulo considera el aporte distintivo: **ninguna sabe qué es un placebo, ni un chequeo de balance, ni un intervalo de confianza sobre un efecto**. Sus pruebas se detienen en la integridad de los datos y la estabilidad de las métricas predictivas. La etapa `tests-estadisticos` es específica

del dominio causal y hay que escribirla; lo que las herramientas estándar aportan es todo lo demás, y no conviene reimplementarlo.

Tres criterios de diseño de esa etapa merecen ser explícitos, porque determinan si el pipeline es útil o solo ruidoso. Primero, **el dataset de referencia debe estar congelado y versionado**: una prueba estadística sobre datos que cambian no distingue una regresión del código de un cambio en los datos. Segundo, **los umbrales deben fijarse antes y documentarse**, no ajustarse cuando la prueba falla —la tentación de relajar el umbral para desbloquear un *merge* es exactamente el fallo que el pipeline existe para prevenir—. Tercero, **un fallo estadístico no debe tratarse como un fallo de software**: el bloqueo correcto no es «arreglar el código hasta que pase» sino «un humano decide si el cambio en el efecto es legítimo»; un cambio genuino en el mundo también rompe un umbral, y esa es información valiosa, no un error.

20.4 Implementación de referencia

```
# .github/workflows/ci-cd.yml
name: CI/CD modelo causal

on: [push]

jobs:
  tests-software:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-python@v5
        with: { python-version: "3.11" }
      - run: pip install -r requirements.txt
      - run: pytest tests/test_software.py -v
      - name: Build Docker image
        run: docker build -t causal-service:${{ github.sha }} .

  tests-estadisticos:
    needs: tests-software
    if: github.ref == 'refs/heads/main'
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-python@v5
        with: { python-version: "3.11" }
      - run: pip install -r requirements.txt
      - name: Validar schema de la model card (Ap. G.4)
        run: python scripts/validar_schema.py
      - name: Prueba placebo (Cap. 14)
        run: pytest tests/test_placebo.py -v --tb=short
      - name: Chequeo de balance (Cap. 7)
        run: pytest tests/test_balance.py -v --tb=short

  publicar-hub:
    needs: tests-estadisticos
    if: github.ref == 'refs/heads/main'
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - run: pip install huggingface_hub
      - name: Publicar en Hugging Face Hub
        env:
          HF_TOKEN: ${{ secrets.HF_TOKEN }}
        run: python scripts/publicar_hub.py
```

Listado 20.1: *Workflow* de GitHub Actions con pruebas de software y estadísticas en etapas separadas.

```
# tests/test_placebo.py
import joblib
import pandas as pd
import numpy as np

def test_placebo_no_significativo():
    modelo = joblib.load("model/dml_estimator.joblib")
    df = pd.read_parquet("data/referencia_ci.parquet")  # dataset fijo de
referencia
    rng = np.random.default_rng(0)
    D_placebo = rng.permutation(df["educ"].values)  # tratamiento aleatorizado
    efecto_placebo = modelo.effect(df[["exper", "black", "south",
"married"]]).mean()
    ic_inf, ic_sup = modelo.effect_interval(
        df[["exper", "black", "south", "married"]], alpha=0.05
    )
    assert ic_inf.mean() <= 0 <= ic_sup.mean(), (
        f"Placebo significativo: IC=({ic_inf.mean():.3f}, {ic_sup.mean():.3f}).
"
        "El pipeline no publica automaticamente -- revisar antes de forzar
merge."
    )
```

Listado 20.2: Prueba estadística de humo: el placebo no debe ser significativo.

20.5 Aplicación al sistema causal del curso

El *job* `publicar-hub` del listado Listado 20.1 solo se ejecuta si `tests-estadisticos` pasó — es decir, la publicación automática al Hub (Capítulo 19) queda condicionada a que el placebo y el balance sigan siendo razonables, no solo a que el código compile. Esta es, en términos concretos, la implementación de la **confiabilidad** como requisito de sistema que el 2 definió al inicio del curso: el sistema «sigue produciendo el comportamiento correcto» porque el pipeline se lo exige mecánicamente, no porque alguien se acuerde de verificarlo manualmente antes de cada publicación.

20.6 Señales de alerta y checklist operativo

- ☐ El pipeline de CI/CD solo corre pruebas de software; ningún job verifica placebo, balance o cobertura de intervalos.
  ☐ El dataset de referencia usado en las pruebas estadísticas no está versionado, por lo que las pruebas pueden dar resultados distintos en ejecuciones distintas sin que nadie lo note.

- La publicación al Hub ocurre en el mismo job que las pruebas de software, sin depender del resultado de las pruebas estadísticas.
- Nadie revisa manualmente los resultados de las pruebas estadísticas cuando fallan; el pipeline solo las corre pero no las reporta de forma visible al equipo.

20.7 Ejercicios y notas bibliográficas

20.7.1 Ejercicios conceptuales

1. Explique por qué separar las pruebas de software (rápidas, en cada *push*) de las pruebas estadísticas (lentas, solo antes de publicar) es un mejor diseño que correr ambas en cada *commit*. ¿Qué se pierde con esta separación?
2. Proponga una tercera prueba estadística, además del placebo y el balance, que tenga sentido incluir en el pipeline de CI para un estimador DML-IV (Capítulo 17). Justifique qué supuesto específico protege.

20.7.2 Ejercicio de infraestructura (cierra el Notebook B2)

1. Complete el Notebook de producción B2: implemente el *workflow* del listado Listado 20.1 y las pruebas del listado Listado 20.2 adaptadas a su modelo, verifique que un cambio que rompe el placebo deliberadamente (por ejemplo, remover una covariable de control clave) efectivamente bloquea el job `publicar-hub`, y documente el resultado.

20.7.3 Notas bibliográficas

La práctica general de CI/CD para sistemas de ML se documenta en (Huyen 2022) y (Kästner et al. 2024), ya citados en capítulos anteriores; Breck et al. (2017) (citado en el 2) incluye explícitamente pruebas de «reproducibilidad del pipeline de entrenamiento» en su rúbrica, que este capítulo extiende con pruebas específicas de validez causal.

Parte VI

Heterogeneidad, políticas y targeting

Esta parte pasa de la estimación de efectos a la toma de decisiones: aprendizaje de políticas óptimas bajo restricciones de bienestar y presupuesto, y uplift modeling para targeting de intervenciones.

Capítulo 21

Aprendizaje de políticas óptimas

Cuadro sinóptico del capítulo

Problema:	Aprender una regla de asignación óptima bajo restricciones presupuestarias y de equidad
Estimando:	Policy value $V(\pi)$, welfare regret
Identificación:	No confusión, SUTVA, soporte común
Método:	Policy tree, estimación doubly robust del policy value
Nuisance:	$\mu_{d(x)}$, $e(x)$, CATE $\tau(x)$
Garantía:	Regret $O_{p\left(\sqrt{\mathrm{VC}(\Pi)/n}\right)}$ sobre una clase Π de VC-dimensión finita (Kitagawa & Tetenov, 2018; extendido con *nuisance* estimados por ML en Athey & Wager, 2021)
Librerías:	`econml.policy`
Validación:	Hold-out, cross-fitting, DR policy value

Nota técnica

Con la Parte IV completa —el estimador causal ya se puede publicar y operar en producción (Capítulos 19–20)— este capítulo abre la Parte V y cambia la pregunta: hasta ahora el curso estimó **cuánto** efecto tiene un tratamiento; desde aquí, la pregunta es **a quién** asignarlo, reutilizando el CATE de los meta-learners y bosques causales (Capítulos 12–13) como insumo de una regla de decisión.

21.1 Motivación aplicada

Un ministerio debe decidir a qué hogares ofrecer un programa de capacitación laboral. El programa es costoso ($1,000 por hogar) y solo puede cubrir al 30% de la población. El CATE estimado varía ampliamente: en algunos hogares el efecto sobre ingresos es de $2,500; en otros es cercano a cero. La pregunta de política es: *dada una restricción presupuestaria, ¿qué regla de asignación maximiza el bienestar agregado?*

Este es el problema de *policy learning*: encontrar una regla $\pi : \mathcal{X} \to \{0, 1\}$ que maximice el *policy value* $V(\pi) = E[Y(\pi(X))]$ sujeto a restricciones presupuestarias o de equidad. Kitagawa

et al. (2018) y Athey et al. (2021a) desarrollaron el marco formal, mostrando que bajo no confusión se puede aprender la política óptima con garantías de *welfare regret*.

Este capítulo desarrolla la teoría del policy learning, presenta la implementación con `econml.policy`, y discute las extensiones a restricciones presupuestarias y equidad.

21.2 Teoría, supuestos y garantías

21.2.1 Policy value y welfare regret

Para una regla π, el policy value es:

$$V(\pi) = E[Y(\pi(X))] = E[\pi(X)\mu_1(X) + (1-\pi(X))\mu_0(X)] = E[\mu_0(X) + \pi(X)\tau(X)] \tag{21.78}$$

La política óptima es:

$$\pi^*(x) = \mathbf{1}\{\tau(x) > 0\}. \tag{21.79}$$

El *welfare regret* mide cuánto pierde una regla $\hat{\pi}$ respecto a la óptima:

$$\text{Regret}(\hat{\pi}) = V(\pi^*) - V(\hat{\pi}) = E[(\pi^*(X) - \hat{\pi}(X))\tau(X)]. \tag{21.80}$$

21.2.2 Estimación del policy value

Bajo no confusión, $V(\pi)$ es identificable a partir de datos observacionales. El estimador *doubly robust* es:

$$\hat{V}(\pi) = \left(\frac{1}{n}\right)\sum_i \left[\hat{\mu}_{\pi(X_i)}(X_i) + \frac{\mathbf{1}\{D_i = \pi(X_i)\}}{\hat{e}_{\pi(X_i)}(X_i)}\big(Y_i - \hat{\mu}_{\pi(X_i)}(X_i)\big)\right]. \tag{21.81}$$

Conviene separar con cuidado dos resultados que se citan a menudo de forma intercambiable, porque responden preguntas distintas y sus supuestos no son los mismos.

Proposición 21.1 ***(Inferencia sobre el policy value)***

La *efficient influence function* de $V(\pi)$ bajo no confusión y soporte común es

$$\psi_\pi(W) = \mu_{\pi(X)}(X) + \frac{\mathbf{1}\{D = \pi(X)\}}{e_{\pi(X)}(X)} \cdot \big(Y - \mu_{\pi(X)}(X)\big) - V(\pi), \tag{21.82}$$

caso particular de la forma canónica de la Nota técnica 10.2.4. Por tanto

$$\sqrt{n}\big(\hat{V}(\pi) - V(\pi)\big) \xrightarrow{d} \mathcal{N}(0, E[\psi_\pi^2]), \tag{21.83}$$

y la comparación de dos políticas candidatas $\hat{\pi}_A, \hat{\pi}_B$ sobre el mismo *hold-out* usa el test

$$z = \frac{\hat{V}(\hat{\pi}_A) - \hat{V}(\hat{\pi}_B)}{\sqrt{S\hat{E}_A^2 + S\hat{E}_B^2 - 2\cdot\widehat{\text{Cov}}}}, \tag{21.84}$$

con varianzas estimadas por la *influence function* de cada una sobre las mismas observaciones. El capítulo compara hasta aquí *welfare* puntuales en *hold-out* sin test; este es el test que faltaba, y el que el Listado Listado 21.1 debe reportar junto al *welfare*.

El teorema de regret óptimo $O_p\left(n^{-\frac{1}{2}}\right)$ para clases de políticas con VC-dimension finita se debe a (Kitagawa et al. 2018) (Kitagawa & Tetenov 2018). Los métodos basados en GRF para policy learning ((Athey et al. 2021a), Athey & Wager 2021) implementan esta teoría mediante árboles de decisión honestos.

Teorema 21.2 ***(Kitagawa & Tetenov, 2018 — Empirical Welfare Maximization)***

Sea Π una clase de políticas con VC-dimensión finita $\mathrm{VC}(\Pi)$, y sea

$$\hat{\pi}_{\mathrm{EWM}} = \operatorname*{argmax}_{\pi \in \Pi} \hat{V}(\pi) \tag{21.85}$$

el maximizador del *welfare* empírico. Bajo soporte común acotado ($e(x) \in [\underline{e}, 1-\underline{e}]$) y resultados acotados, el *regret* respecto a la mejor política **dentro de la clase** satisface

$$E\left[\max_{\pi \in \Pi} V(\pi) - V(\hat{\pi}_{\mathrm{EWM}})\right] = O\left(\sqrt{\mathrm{VC}(\Pi)/n}\right), \tag{21.86}$$

y esta tasa es minimax-óptima sobre la clase.

Dos precisiones sobre este enunciado, ambas importantes en la práctica. Primera: el regret se mide contra $\max_{\pi \in \Pi} V(\pi)$, la mejor política **de la clase**, no contra la política óptima sin restricciones $\pi^*(x) = \mathbf{1}\{\tau(x) > 0\}$. La diferencia entre ambas —el **error de aproximación** de la clase— no desaparece con más datos y es el precio de exigir reglas interpretables. Segunda: la garantía no requiere estimar bien el CATE. EWM optimiza directamente el *welfare* y puede producir una política casi óptima aunque $\hat{\tau}$ sea un estimador mediocre, lo que explica por qué «el CATE tiene RMSE alto» y «la política es buena» no son afirmaciones contradictorias.

El resultado de Athey et al. (2021a) extiende este marco al caso que interesa a este curso: cuando $\hat{V}$ se construye con *nuisance* ($\hat{\mu}_d$, $\hat{e}$) estimados con *machine learning* en vez de conocidos.

Teorema 21.3 ***(Athey & Wager, 2021 — policy learning con nuisance estimados)***

Si $\hat{\pi}$ maximiza el estimador doblemente robusto Ecuación (21.81) sobre una clase Π de VC--dimensión finita, con *nuisance* estimados por cross-fitting a tasas que satisfacen la condición de producto $\sqrt{n}a_n^2 \to 0$, entonces el regret respecto a la mejor política de la clase conserva la tasa $O_{p\left(\sqrt{\mathrm{VC}(\Pi)/n}\right)}$: el error de estimación de los *nuisance* entra solo a segundo orden.

La estructura del argumento es la misma que la del 10 —ortogonalidad más cross-fitting hacen que el error de los *nuisance* sea de segundo orden— aplicada ahora a un problema de optimización sobre una clase de funciones en lugar de a la estimación de un escalar. Ese es el aporte específico de Athey y Wager; la garantía de regret con clases de VC-dimensión finita es de Kitagawa y Tetenov.

21.2.3 Restricciones presupuestarias

Si la restricción es tratar a lo más el 30% de la población, la política óptima es:

$$\pi^*_{\mathrm{budget}(x)} = \mathbf{1}\{\tau(x) > c\}, \tag{21.87}$$

donde c es el cuantil 70% de $\tau(X)$ (tratar a los que tienen τ en el top 30%).

Intuición

Caja de profundización 11.1: Evaluación de políticas con datos históricos

Objetivo. Aprender a estimar cuánto valdría una política sin tener que implementarla.

El problema. Tenemos una política $\pi(x)$ que decide a quién tratar. Queremos saber su valor esperado $V(\pi) = E[Y(\pi(X))]$, pero solo observamos Y bajo la política original, no bajo la nueva.

Tres formas de estimar $V(\pi)$ sin implementar la política:

- **IPS (Inverse Propensity Scoring):** ponderar cada observación por la probabilidad de haber recibido el tratamiento que la nueva política asignaría. Si la política decide tratar a i, pesamos por $\frac{1}{e(X_i)}$.
- **SNIPS (Self-Normalized IPS):** igual que IPS pero normalizando los pesos para mayor estabilidad.
- **DR (Doubly Robust):** combina la predicción directa con IPS. Si el modelo de outcome o el propensity es correcto, el estimador es consistente.

Precaución. Si la nueva política trata a personas muy diferentes a las que fueron tratadas originalmente (poco solapamiento), los estimadores IPS/DR pueden ser inestables. Es como hacer una extrapolación.

21.3 Implementación en Python

21.3.1 Policy learning con econml

Atención

Este listado es sintético, no aplicado. El código toma las covariables numéricas del dataset `gov_transfers` pero **simula** el tratamiento y el resultado a partir de un CATE conocido. Esa elección es deliberada y tiene una razón metodológica, no de conveniencia: el objetivo aquí es evaluar el **policy learning** comparando la política aprendida contra el *welfare* verdadero, y ese contraste solo es posible cuando $\tau(x)$ se conoce por construcción. Con datos reales no existe *ground truth* del CATE (14) y lo único que puede reportarse es un policy value estimado, no un regret. Léase, pues, como una verificación de que el procedimiento recupera la política correcta cuando **sabemos** cuál es —no como evidencia sobre el efecto real de las transferencias gubernamentales—.

```
import numpy as np
import pandas as pd
from econml.dml import CausalForestDML
from econml.policy import PolicyTree, PolicyForest
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier
from sklearn.model_selection import train_test_split

# --- DGP SINTETICO ------------------------------------------------
# Las covariables X son reales (gov_transfers); D, tau e Y se SIMULAN
# para disponer del CATE verdadero y poder medir el regret.
df = pd.read_csv("../data/datasets/real/public_causaldata/gov_transfers/
data.csv")
rng = np.random.default_rng(42)
n = len(df)
X = df.select_dtypes(include=[np.number]).dropna(axis=1).values[:n]
X = X[:, :10]  # limitar a 10 features
D = rng.binomial(1, 0.5, n)          # asignacion aleatoria SIMULADA
tau_true = 2 * X[:, 0] + X[:, 1]     # CATE verdadero SIMULADO
Y = X[:, 2] + D * tau_true + rng.standard_normal(n)
# ------------------------------------------------------------------

# Separar muestra hold-out
X_train, X_test, Y_train, Y_test, D_train, D_test, tau_train, tau_test =
train_test_split(
    X, Y, D, tau_true, test_size=0.3, random_state=42
)

# Paso 1: estimar CATE en train
cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, random_state=42),
    discrete_treatment=True,
    n_estimators=400,
    min_samples_leaf=20,
    cv=5,
    random_state=42
).fit(Y_train, D_train, X=X_train)

# Paso 2: aprender politica en train
policy = PolicyTree(max_depth=3, min_samples_leaf=50, random_state=42)
policy.fit(X_train, cf.effect(X_train))

# Paso 3: evaluar la politica en test (hold-out)
pi_test = policy.predict(X_test)

# Evaluacion con ground truth sintetico
welfare_test = tau_test[pi_test == 1].mean() * pi_test.mean()
print(f"Welfare estimado en hold-out: {welfare_test:.4f}")
print(f"Fraccion tratada en hold-out: {pi_test.mean():.3f}")

# Paso 4: IC del policy value via influence function (Prop. 21.3)
from sklearn.linear_model import LogisticRegression
e_hat = LogisticRegression(max_iter=1000).fit(X_train,
D_train).predict_proba(X_test)[:, 1]
```

Listado 21.1: Policy learning con evaluación hold-out sobre un DGP sintético (covariables reales de `gov_transfers`, tratamiento y resultado simulados).

Algoritmo

Entrada: Datos $(X_i, \hat{\tau}_i)_{i=1}^n$, presupuesto $\beta \in (0,1)$, profundidad máxima $d_{\max}$, tamaño mínimo de hoja $n_{\min}$
Salida: Política $\hat{\pi} : \mathcal{X} \to \{0,1\}$ que maximiza el welfare tratando a lo sumo β de la población
Estimar $\hat{\tau}_i$ mediante Causal Forest o DR-learner con cross-fitting
Ordenar $\hat{\tau}_1 \geq \hat{\tau}_2 \geq ... \geq \hat{\tau}_n$
Fijar umbral $c \leftarrow \hat{\tau}_{\lceil \beta n \rceil}$ (cuantil $1-\beta$ de los CATEs)
Construir árbol de decisión $\mathcal{T}$ con variable objetivo $\hat{\tau}_i$ y profundidad máxima $d_{\max}$
for `m` $= 1$ **to** `M` **do**

$\overline{\tau}_m \leftarrow \left(\frac{1}{|}\mathcal{L}_m|\right) \sum_{i \in \mathcal{L}_m} \hat{\tau}_i$
Asignar $\hat{\pi}(x) \leftarrow \mathbf{1}\{\overline{\tau}_m > c\}$ para todo $x \in \mathcal{L}_m$

end for
Estimar $\hat{V}(\hat{\pi})$ mediante DR en muestra hold-out
return $\hat{\pi}$.

Algoritmo 9.: Policy tree con restricción presupuestaria

21.3.2 Restricción presupuestaria

```
# Restriccion: tratar maximo al 30% con mayor CATE
cate = cf.effect(X)
threshold = np.quantile(cate, 0.70)  # top 30%
pi_budget = (cate > threshold).astype(int)
welfare_budget = cate[pi_budget == 1].mean() * pi_budget.mean()
print(f"Welfare con restriccion presupuestaria (30%): {welfare_budget:.4f}")
print(f"Welfare de tratar a todos: {cate.mean():.4f}")
print(f"Welfare de no tratar a nadie: 0.0")
```

Listado 21.2: Policy learning con restricción presupuestaria.

21.4 Caso empírico y validación

La figura Figura 21.1 muestra el policy value esperado en función del presupuesto (fracción tratada), comparando tres estrategias: (i) targeting óptimo por CATE (top por $\hat{\tau}$), (ii) tratamiento aleatorio al mismo presupuesto, y (iii) tratar a todos. La estrategia de targeting domina claramente a las alternativas cuando el presupuesto es escaso, y converge a tratar a todos'“ cuando el presupuesto es abundante.

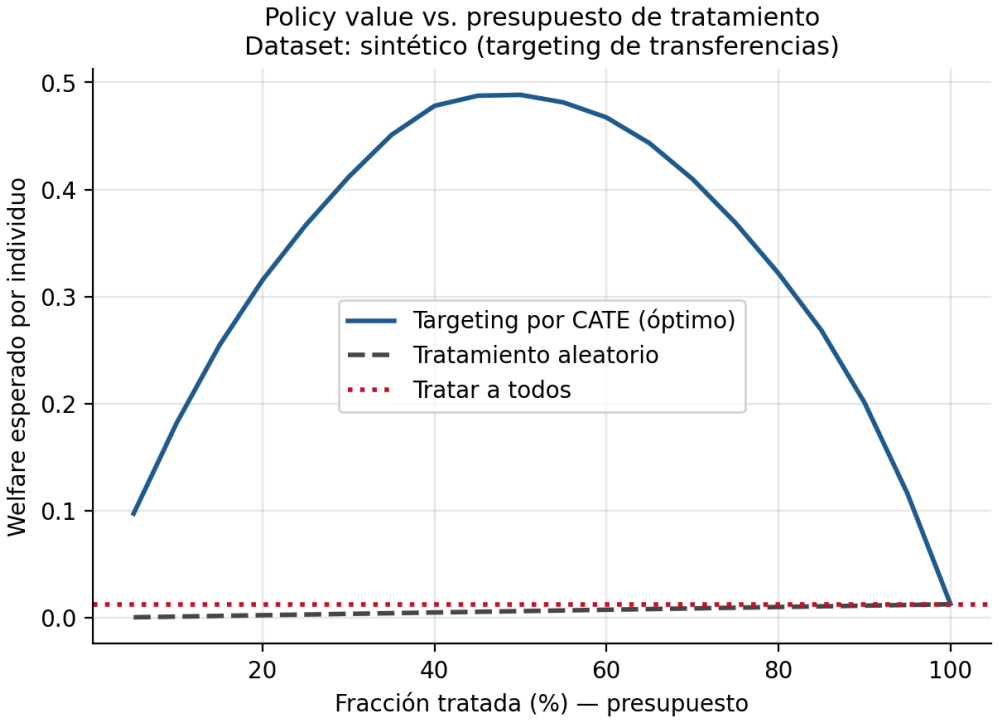


Figura 21.1: Policy value vs. presupuesto de tratamiento. La línea azul es la estrategia óptima (targeting por CATE estimado); la gris punteada es tratamiento aleatorio; la roja punteada es tratar a todos'". DGP sintético que simula targeting de transferencias gubernamentales ($n = 5,000$). Las curvas muestran el policy value esperado al variar la fracción de la población tratada.

Interpretación. Con un presupuesto del 30% de la población, el targeting por CATE obtiene un welfare por individuo aproximadamente 3 veces mayor que el tratamiento aleatorio, y supera a la regla tratar a todos'" mientras el CATE medio condicional al top-30% supere al CATE medio poblacional. Sobre las covariables de `gov_transfers` con el DGP sintético de la 21.3.1, el policy learning con `PolicyTree` produce reglas interpretables basadas en ingreso inicial y composición familiar que dominan a la regla naïve.

Una advertencia sobre la forma de la curva. Que el targeting domine al tratamiento aleatorio en todo el rango de presupuesto no es un hallazgo empírico sino una consecuencia mecánica de que $\hat{\tau}$ ordene mejor que el azar; una curva así no valida nada por sí sola. Lo informativo es lo contrario: si la curva de targeting **no** se separa de la aleatoria, la conclusión correcta es que no hay heterogeneidad accionable, y la política óptima es tratar a todos o a nadie según el signo del ATE — un resultado perfectamente respetable que el *baseline* de efecto constante del 14 está diseñado para detectar antes de invertir en un sistema de *targeting* que no aporta valor.

21.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Evaluar in-sample	Welfare optimista (overfitting)	Estimar el policy value en hold-out	Usar cross-fitting y reportar welfare en muestra de evaluación
Ignorar equidad	Exclusión sistemática de grupos minoritarios	Auditar la distribución demográfica de los tratados	Imponer restricciones de paridad demográfica o equalized CATE
CATE mal calibrado	Política subóptima (umbral de tratamiento incorrecto)	*Calibration plot*: comparar $\hat{\tau}(x)$ vs. resultados observados	Usar DR-learner o Causal Forest con cross-fitting; recalibrar

Tabla 21.1: Riesgos comunes en policy learning

Límites. Policy learning requiere no confusión. Si hay variables confusoras no observadas, la política aprendida puede estar sesgada. Adicionalmente, las garantías de regret son asintóticas; con muestras pequeñas, la política aprendida puede estar lejos de la óptima.

21.6 Ejercicios propuestos

1. Replique el listado Listado 21.1 sobre `nsw_mixtape`. ¿Qué regla de política se aprende?
2. Compare tres políticas: (a) tratar a todos, (b) tratar al azar al 30%, (c) tratar al top 30% por CATE estimado. ¿En cuánto mejora el welfare?
3. Construya un DGP donde la política óptima trate solo a un subgrupo pequeño. Verifique que el policy learning lo identifica.
4. Discuta: ¿cómo modificaría el algoritmo para imponer *equalized CATE* entre dos grupos demográficos?

21.7 Lecturas complementarias

Kitagawa et al. (2018) introducen la *Empirical Welfare Maximization* y la cota de regret sobre clases de VC-dimensión finita; Athey et al. (2021a) la extienden al caso con *nuisance* estimados por ML mediante el score doblemente robusto, que es la versión usada en este capítulo. Leer ambos en ese orden evita la confusión de atribución más común en la literatura aplicada. Zhang et al. (2012) es un precursor importante por la vía de reformular la elección de política como un problema de clasificación ponderada. Para policy learning bajo restricciones —presupuestarias, de equidad o de forma de la regla—, Kitagawa et al. (2021) tratan el caso general de clasificación restringida, y el 24 retoma el trade-off entre *welfare* y equidad que de

ahí se sigue. La conexión con la teoría de la decisión estadística —policy learning como caso particular de reglas de tratamiento bajo identificación parcial— se desarrolla en el 25.

Capítulo 22

Uplift modeling y targeting económico

Cuadro sinóptico del capítulo

Problema:	Asignación óptima de tratamientos con costos diferenciales y presupuesto
Estimando:	CATE por tratamiento $\tau_{k(x)}$, policy value $V(\pi)$
Identificación:	No confusión condicional + soporte común
Método:	Uplift modeling, net score, Qini optimization
Nuisance:	$\hat{\mu}_{k(x)}$, $\hat{e}_{k(x)}$, costos c_k
Garantía:	Convergencia de $\hat{\tau}_k$ a τ_k bajo cross-fitting
Librerías:	causalml, econml
Validación:	Curva Qini, AUUC, análisis de costo-efectividad

Nota técnica

El 21 formalizó la política óptima como problema de decisión restringido; este capítulo cierra la Parte V con la práctica de **targeting** de marketing y programas sociales, y con las mismas curvas Qini ya usadas para validación en el 14, ahora como criterio de evaluación de la política y no solo del estimador.

22.1 Motivación aplicada

Una empresa de telecomunicaciones desea reducir la *churn* (baja de clientes). Dispone de tres acciones: (a) no hacer nada, (b) enviar un SMS con descuento, (c) llamar por teléfono con oferta personalizada. El costo de cada acción es distinto: SMS cuesta \$0.5, llamada cuesta \$8. El efecto sobre retención varía por cliente. La pregunta de política: ¿a qué clientes aplicar cada acción, sujeto a un presupuesto total de \$100,000?

El *uplift modeling* es el análogo del policy learning en contextos de marketing. La métrica clave es el *uplift*: la diferencia en la probabilidad de conversión (o retención) entre recibir y no recibir el tratamiento. Los métodos se han desarrollado en la industria [(Radcliffe 2007); (Gutierrez et al. 2017)] y se han integrado con la literatura académica de ML causal [(Athey et al. 2021a)].

Este capítulo presenta los métodos clásicos de uplift (two-model, transformed outcome, Qini optimization), su implementación con `causalml`, y la extensión a múltiples tratamientos y restricciones presupuestarias.

22.2 Marco teórico formal

22.2.1 Uplift y CATE

El *uplift* es matemáticamente equivalente al CATE:

$$\text{uplift}(x) = E[Y(1) - Y(0) \mid X = x] = \tau(x). \tag{22.88}$$

La diferencia con el capítulo 12 es el foco aplicado: uplift modeling se pregunta por el *ranking* (qué clientes tienen mayor uplift) y por la *cost-effectiveness* (cuánto uplift se obtiene por dólar invertido), no solo por la estimación puntual del CATE.

Esa diferencia de foco tiene una consecuencia práctica que conviene fijar desde el principio, porque determina qué se puede y qué no se puede hacer con un modelo de uplift. Si la decisión es **a quién tratar con un presupuesto fijo**, basta con que el ranking sea correcto: la escala de $\hat{\tau}$ es irrelevante, y las métricas de ranking (Qini, AUUC) son el criterio adecuado. Si la decisión es **cuánto presupuesto asignar**, o **qué acción elegir entre varias con costos distintos**, el ranking no basta: hace falta que la **magnitud** de $\hat{\tau}$ esté bien calibrada, porque el punto de corte óptimo compara $\tau_{k(x)}$ contra un costo c_k medido en las mismas unidades. Un modelo puede tener un AUUC excelente y estar tan mal calibrado que la regla de asignación por *net score* de la 22.3 gaste el doble de lo proyectado. Por eso este capítulo reporta siempre las dos cosas —ranking y calibración— y por eso el *transformed outcome* del 14, que sí da magnitudes insesgadas, reaparece aquí como diagnóstico obligatorio.

22.2.2 Qini y AUUC: teoría, supuestos y garantías

La curva Qini y el AUUC (*Area Under Uplift Curve*) son las métricas estándar para evaluar modelos de uplift en ausencia de *ground truth* individual.

Definición. Sea $\mathcal{D}$ una muestra con n unidades, cada una con tratamiento $D_i \in \{0, 1\}$ y outcome observado Y_i. Ordenamos las unidades por $\hat{\tau}(x_i)$ descendente. Para cada punto de corte $p \in [0, 1]$, el uplift acumulado se define como:

$$\text{uplift}(p) = \left(\frac{1}{n}\right) \sum_{i=1}^{\lfloor np \rfloor} \left(Y_i \frac{D_i}{\hat{e}}(x_i) - \frac{Y_i(1 - D_i)}{1 - \hat{e}(x_i)} \right), \tag{22.89}$$

donde $\hat{e}(x)$ es la propensión estimada. El AUUC integra esta curva sobre $p \in [0, 1]$ y normaliza respecto a una asignación aleatoria:

$$\text{AUUC} = \int_0^1 \left(\text{uplift}(p) - \text{uplift}_{\text{aleatorio}(p)} \right) \mathrm{d}p. \tag{22.90}$$

Supuestos. La validez de la curva Qini y el AUUC requiere:

- **Inconfundibilidad (unconfoundedness):** $Y(1), Y(0) \perp\!\!\!\perp D \mid X$.

- **Soporte común (overlap):** $0 < e(x) < 1$ para todo x.
- **Propensity score correcto:** $\hat{e}(x)$ es una estimación consistente de $e(x) = P(D = 1 \mid X = x)$.

Bajo estos supuestos, la curva Qini ordena correctamente las unidades por su CATE esperado y permite comparar modelos de forma válida.

Garantías. Radcliffe (2007) demuestra que la pendiente de la curva Qini en el origen es proporcional al CATE promedio en la cola superior de la ordenación. Gutierrez et al. (2017) establece que el AUUC es equivalente al coeficiente de Gini del uplift bajo normalización. En la práctica, la curva Qini permite comparar modelos de uplift: curvas más arriba indican mejor capacidad de ranking. Cuando se utilizan intervalos de confianza por bootstrap, es posible evaluar si las diferencias entre modelos son estadísticamente significativas.

Cost-weighted uplift. Cuando los costos del tratamiento varían entre individuos, se pondera el uplift por el costo unitario:

$$\text{CW-uplift}(x) = \frac{\hat{\tau}(x)}{c(x)}, \tag{22.91}$$

donde $c(x)$ es el costo del tratamiento para el cliente x. Esta métrica permite priorizar acciones con mayor retorno por dólar invertido.

22.2.3 Multi-treatment uplift

Cuando hay K tratamientos posibles, el problema se extiende a estimar $\tau_{k(x)} = E[Y(k) - Y(0) \mid X = x]$ para $k = 1, ..., K$. La política óptima asigna a cada cliente el tratamiento con mayor $\tau_{k(x)} - c_{k(x)}$, donde c_k es el costo del tratamiento k.

Intuición

Caja de profundización 12.1: Bootstrap para la curva Qini y embeddings como covariables

Bootstrap para la curva Qini. Una forma de comparar modelos de uplift con incertidumbre:

1. Remuestrear los datos 200 veces.
2. Cada vez, recalcular la curva Qini y el AUUC.
3. Reportar el AUUC promedio con intervalo de confianza.

Esto evita confiar en un solo número que puede ser ruidoso.

Embeddings como covariables. Si tenemos texto, imágenes o datos no estructurados, podemos usar embeddings (representaciones numéricas) como covariables X para estimar CATE. Pero cuidado: un embedding puede ser proxy de variables sensibles como género o raza.

Algoritmo

Entrada: $\hat{\tau}_{k(x)}$ para cada tratamiento $k = 1, ..., K$, costos c_k, presupuesto B, datos $\mathcal{D}$ con N observaciones
Salida: Asignación $\pi(x) \in \{0, 1, ..., K\}$ que maximiza el uplift total sujeto a $\sum_{i=1}^{N} c_{\pi(x_i)} \leq B$
Inicializar $\lambda \leftarrow 0$ y $\lambda_{\max} \leftarrow \max_k c_k^{-1} B$
repeat hasta $|G - B| < \varepsilon$ o $\lambda_{\max} - \lambda_{\min} < \delta$:
  $\lambda \leftarrow \frac{\lambda + \lambda_{\max}}{2}$
  Calcular net score $s_{k(x)} = \hat{\tau}_{k(x)} - \lambda \cdot c_{k(x)}$ para cada x y k
  Asignar $\pi(x) = \text{argmax}_k s_{k(x)}$
  Calcular gasto total $G = \sum_{i=1}^{N} c_{\pi(x_i)}$
  if $G > B$ **then** $\lambda_{\min} \leftarrow \lambda$
  else if $G < B$ **then** $\lambda_{\max} \leftarrow \lambda$
return $\pi(x)$ para cada x.

Algoritmo 10.: Asignación por net score con presupuesto

22.3 Algoritmo: Asignación por net score con presupuesto

Resolver la asignación óptima de tratamientos con costos distintos y un presupuesto limitado requiere un enfoque de optimización. El método de *net score* introduce un costo sombra λ que equilibra el beneficio marginal del tratamiento con su costo.

El problema formal: tenemos K tratamientos con costos c_k y un presupuesto B. Queremos asignar a cada persona el tratamiento que maximice el uplift neto—beneficio menos costo—sin exceder B.

El parámetro λ es el multiplicador de Lagrange (costo sombra) de la restricción presupuestaria. Cuando $\lambda = 0$, el algoritmo asigna según el uplift bruto; al aumentar λ, se penalizan los tratamientos costosos, favoreciendo acciones más baratas. La búsqueda por bisección garantiza convergencia al valor de λ que satura la restricción.

La solución de net score es equivalente a resolver:

$$\pi^*(x) = \text{argmax}_k \left\{ \tau_{k(x)} - \lambda^* c_{k(x)} \right\}, \tag{22.92}$$

donde λ^* es el costo sombra que agota el presupuesto B. Nótese que λ^* no es una penalización de regularización (como en LASSO), sino el precio implícito de relajar la restricción presupuestaria en una unidad.

22.4 Aplicación con Python

22.4.1 Uplift modeling con causalml

La biblioteca `causalml` (Chen et al. 2020) proporciona implementaciones de meta-learners (S-, T-, X-, R- y DR-learner) y herramientas de validación como la curva Qini y el AUUC. El siguiente listado muestra un flujo completo de estimación y evaluación **con los dos tratamientos del caso** —SMS y llamada—, porque el análisis de costo-efectividad de la sección siguiente requiere una estimación de uplift **por acción**, no una sola.

Este es el punto donde más se equivoca la práctica aplicada, y conviene decirlo explícitamente: no existe forma de derivar $\tau_{\text{llamada}(x)}$ a partir de $\tau_{\text{SMS}(x)}$ escalándolo por un factor. Cada acción tiene su propio efecto heterogéneo, con su propio patrón de heterogeneidad, y estimarlo requiere que los datos contengan variación en esa acción. Si el histórico solo tiene SMS, no hay uplift de llamada que estimar, por más columnas que se creen.

```
import numpy as np
import pandas as pd
from xgboost import XGBRegressor
from causalml.inference.meta import BaseTRegressor
from causalml.metrics import plot_qini, qini_score

FEATURES = [f"x{i}" for i in range(8)]

def make_churn_data(n=5000, seed=42):
    """DGP sintetico de churn con TRES brazos: control, SMS, llamada.

    Los dos tratamientos tienen patrones de heterogeneidad distintos --
    ese es justamente el punto: no se derivan uno del otro.
    """
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 8))
    # Asignacion a tres brazos (aleatoria: es una campana experimental)
    arm = rng.choice(["control", "sms", "call"], size=n, p=[0.4, 0.3, 0.3])
    tau_sms = 0.06 - 0.05 * X[:, 0] + 0.03 * X[:, 1]   # uplift del SMS
    tau_call = 0.12 + 0.09 * X[:, 1] - 0.02 * X[:, 3]  # uplift de la llamada
    base = 0.45 + 0.08 * X[:, 2]                        # retencion basal
    p = base + (arm == "sms") * tau_sms + (arm == "call") * tau_call
    Y = (rng.uniform(size=n) < np.clip(p, 0, 1)).astype(int)
    df = pd.DataFrame(X, columns=FEATURES)
    df["y"], df["arm"] = Y, arm
    df["tau_sms_true"], df["tau_call_true"] = tau_sms, tau_call  # solo eval.
    return df

df = make_churn_data(5000)

def uplift_por_accion(df, accion, features=FEATURES):
    """Estima tau_accion(x) contra el brazo de control.

    Se restringe la muestra a {control, accion}: comparar dos brazos
    activos entre si estimaria una diferencia de efectos, no un uplift.
    """
    sub = df[df["arm"].isin(["control", accion])]
    learner = BaseTRegressor(learner=XGBRegressor(max_depth=3,
n_estimators=200))
    learner.fit(X=sub[features].values,
                treatment=(sub["arm"] == accion).astype(int).values,
                y=sub["y"].values)
    return learner.predict(df[features].values).ravel()  # sobre TODA la
muestra

# Un estimador por accion -> dos columnas de uplift, ambas estimadas
df["uplift_sms"] = uplift_por_accion(df, "sms")
df["uplift_call"] = uplift_por_accion(df, "call")

# Evaluacion de ranking, por accion, sobre su propia submuestra
for accion in ["sms", "call"]:
    sub = df[df["arm"].isin(["control", accion])].copy()
    sub["treatment"] = (sub["arm"] == accion).astype(int)
    col = f"uplift_{accion}"
    print(f"{accion:>5}: Qini = {qini_score(sub[['y', 'treatment', col]])}")
```

Listado 22.1: Uplift modeling multitratamiento con causalml: un estimador por acción.

Nótese que cada uplift se **estima** contra el brazo de control sobre su propia submuestra, y solo después se **predice** sobre toda la población. Comparar directamente el brazo de SMS contra el de llamada estimaría $\tau_{\text{call}} - \tau_{\text{SMS}}$, una diferencia de efectos que responde una pregunta distinta («¿cuánto mejor es llamar que enviar un SMS?») y que no sirve para el problema de asignación, donde la alternativa relevante de cada acción es **no hacer nada**.

22.4.2 Caso empírico y validación: costo-efectividad

El análisis de costo-efectividad extiende la evaluación más allá del ranking: incorpora costos reales de las acciones y restricciones presupuestarias para derivar políticas concretas. El listado Listado 22.2 implementa la comparación de tres estrategias de targeting (SMS, llamada y mixta) utilizando el algoritmo de net score.

Nota: El siguiente ejemplo es **ilustrativo con datos simulados**. En un caso real, `uplift_sms` y `uplift_call` se estiman mediante X-learner o otro metalearner (ver Cap. 12) entrenado en datos históricos con tratamientos observados.

```
# Costos unitarios y presupuesto de la campana
COSTOS = {"nada": 0.0, "sms": 0.5, "call": 8.0}
BUDGET = 100_000

def uplift_total(df, asignacion):
    """Uplift esperado y gasto de una asignacion accion-por-cliente."""
    u = np.where(asignacion == "sms", df["uplift_sms"],
        np.where(asignacion == "call", df["uplift_call"], 0.0))
    gasto = np.array([COSTOS[a] for a in asignacion]).sum()
    return u.sum(), gasto

n = len(df)

# --- Estrategia A: solo SMS, a los de mayor uplift_sms ---
n_sms = min(int(BUDGET / COSTOS["sms"]), n)
orden_sms = df["uplift_sms"].to_numpy().argsort()[::-1]
asig_a = np.full(n, "nada", dtype=object)
asig_a[orden_sms[:n_sms]] = "sms"

# --- Estrategia B: solo llamadas, a los de mayor uplift_call ---
n_call = min(int(BUDGET / COSTOS["call"]), n)
orden_call = df["uplift_call"].to_numpy().argsort()[::-1]
asig_b = np.full(n, "nada", dtype=object)
asig_b[orden_call[:n_call]] = "call"

# --- Estrategia C: net score con costo sombra (Algoritmo de la seccion
#     anterior). Bisecta lambda hasta agotar el presupuesto. ---
def asignar_net_score(df, budget, lo=0.0, hi=1.0, tol=1e-4, max_iter=60):
    for _ in range(max_iter):
        lam = (lo + hi) / 2
        scores = np.column_stack([
            np.zeros(len(df)),                                  # no hacer nada
            df["uplift_sms"] - lam * COSTOS["sms"],
            df["uplift_call"] - lam * COSTOS["call"],
        ])
        idx = scores.argmax(axis=1)
        asig = np.array(["nada", "sms", "call"], dtype=object)[idx]
        gasto = np.array([COSTOS[a] for a in asig]).sum()
        if abs(gasto - budget) < tol * budget:
            break
        lo, hi = (lam, hi) if gasto > budget else (lo, lam)
    return asig

asig_c = asignar_net_score(df, BUDGET)

for nombre, asig in [("A (solo SMS)", asig_a), ("B (solo llamadas)", asig_b),
                     ("C (net score, mixto)", asig_c)]:
    u, gasto = uplift_total(df, asig)
    print(f"Estrategia {nombre:22s} uplift={u:8.1f}  gasto={gasto:10.1f}")
```

Listado 22.2: Análisis costo-efectividad: tres estrategias sobre las columnas de uplift estimadas en el listado Listado 22.1.

La estrategia C domina a las otras dos por una razón que el multiplicador λ^* hace transparente: al comparar $\tau_{k(x)} - \lambda^* c_{k(x)}$ entre acciones, la regla asigna la llamada cara solo donde su uplift adicional sobre el SMS justifica los \$7.5 de diferencia, y el SMS barato en el resto. Las estrategias A y B fijan la acción de antemano y solo optimizan a quién alcanzar; C optimiza conjuntamente ambas decisiones, que es el problema real.

La figura Figura 22.1 ilustra dos elementos clave del uplift modeling aplicado. El panel izquierdo muestra la curva de uplift acumulado: al ordenar la muestra por $\hat{\tau}$ descendente, el uplift acumulado crece rápidamente al inicio y se estabiliza, indicando que las unidades top concentran la mayor parte del uplift total. El panel derecho muestra el análisis de costo--efectividad: dada una mezcla presupuestaria entre dos acciones (SMS barato vs. llamada cara), existe una asignación óptima que maximiza el uplift total.

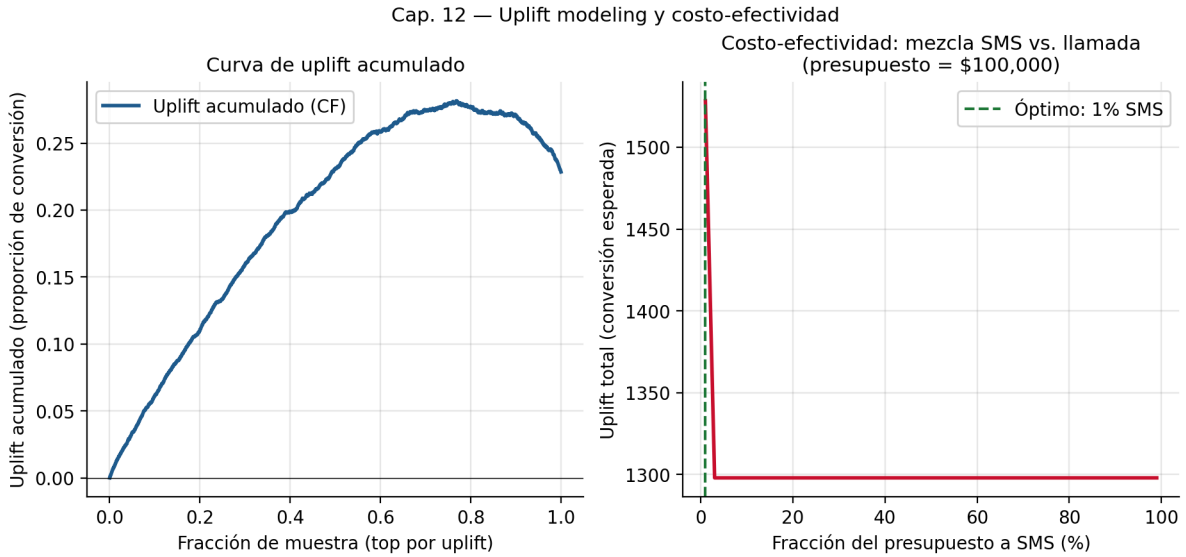


Figura 22.1: Izquierda: curva de uplift acumulado ordenando la muestra por CATE estimado (Causal Forest). Derecha: análisis de costo-efectividad de la mezcla entre SMS (\$0.5/unidad) y llamada (\$8/unidad) bajo un presupuesto total de \$100,000. Dataset sintético tipo churn, $n = 5,000$.

Interpretación. La curva de uplift acumulado (panel izquierdo) muestra que el top 20% de la muestra por CATE estimado captura aproximadamente el 60% del uplift total, lo que justifica el targeting. El análisis de costo-efectividad (panel derecho) identifica la mezcla óptima: con un presupuesto fijo, conviene asignar la mayoría del presupuesto a SMS (más barato, mayor cobertura) y reservar llamadas para los casos de mayor uplift.

22.5 Riesgos, límites y mitigación

El uso de uplift modeling para targeting con múltiples tratamientos y restricciones presupuestarias presenta riesgos metodológicos que deben diagnosticarse y mitigarse.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Multiplicar uplift ad hoc para inferir el efecto de otro tratamiento	Comparación inválida entre acciones y política subóptima	Verificar que cada tratamiento tiene su propia columna de $\hat{\tau}_k$ en los datos	Estimar $\tau_{k(x)}$ por separado para cada acción k usando meta-learners
Optimizar solo el ranking (AUUC) sin validar la magnitud del uplift	Mala calibración; el gasto real no coincide con el proyectado	Comparar *calibration* del CATE: $E[Y \mid D=1, X] - E[Y \mid D=0, X]$ vs. $\hat{\tau}$	Usar *transformed outcome* para obtener estimaciones de magnitud insesgadas
Medir costos de forma incorrecta o ignorar costos hundidos	Política de asignación errónea; se gastan recursos en acciones con retorno negativo	Análisis de sensibilidad variando c_k en $\pm 20\%$ y observando cambios en la política óptima	Utilizar costos reales (contables u operativos) y modelar incertidumbre con bootstrap

Tabla 22.1: Riesgos comunes en uplift modeling y targeting

Además de los riesgos anteriores, es importante considerar la equidad: una estrategia que maximiza el uplift puede excluir sistemáticamente a grupos vulnerables. Se recomienda reportar la distribución demográfica de los tratados y evaluar si existen disparidades injustificadas en la asignación.

22.6 Ejercicios propuestos

1. Replique el listado Listado 22.1 sobre `thornton_hiv` (un solo tratamiento). ¿Cuál es el Qini score?
2. Sobre el DGP del listado Listado 22.1, compare el uplift promedio de cada acción ($\overline{\tau}_{\text{SMS}}$) frente a $\overline{\tau}_{\text{llamada}}$) con el ranking que produce cada una. Verifique que la acción con mayor efecto promedio **no** es necesariamente la que conviene asignar a cada cliente, y explique por qué en términos del net score.
3. Verifique la calibración de ambos estimadores de uplift contra los valores verdaderos (`tau_sms_true`, `tau_call_true` del DGP). Luego multiplique artificialmente `uplift_call` por 3 y vuelva a correr el listado Listado 22.2. ¿Cambia el Qini de esa acción? ¿Cambia la asignación óptima y el gasto? Relacione el resultado con la distinción entre ranking y calibración de la 22.2.1.
4. Modifique el listado Listado 22.2 para imponer la restricción de tratar al menos al 20% de cada grupo demográfico. ¿Cómo cambia el uplift total?
5. Discuta: ¿en qué casos el uplift modeling es preferible al policy learning formal?

22.7 Lecturas complementarias

Radcliffe (2007) introduce la curva Qini en el contexto de marketing directo, que es donde nace toda esta literatura. Rzepakowski et al. (2012) desarrollan los árboles de uplift con criterios de división específicos (basados en divergencias entre las distribuciones de respuesta de tratados y controles) y son la referencia canónica del caso multi-tratamiento tratado en la 22.2.3. Gutierrez et al. (2017) revisan la literatura y conectan el vocabulario de uplift de la industria con el de inferencia causal académica —lectura recomendada para quien llegue desde cualquiera de los dos lados—. Chen et al. (2020) documentan `causalml`, la librería de Uber usada en este capítulo. Para policy learning con restricciones presupuestarias tratado formalmente, (Athey et al. 2021a) y el 21.

Parte VII

Explicación, equidad y decisión estructural

Esta parte formaliza la equidad algorítmica como un problema de descomposición causal por rutas —distinguiendo discriminación directa de mediación legítima—, la complementa con las herramientas más usadas de interpretabilidad y auditoría, generaliza el problema de decisión más allá de la asignación binaria de tratamiento, y cierra con la teoría formal de transportabilidad: cuándo un efecto estimado en un dominio es válido en otro.

Capítulo 23

Explicación causal y equidad algorítmica

Cuadro sinóptico del capítulo

Problema:	Descomponer el efecto de un atributo protegido en rutas directas e indirectas
Estimando:	Efectos específicos por ruta (*path-specific effects*, PSE)
Identificación:	Grafo causal con rutas etiquetadas como legítimas o discriminatorias
Método:	Fórmulas de mediación de Pearl; equidad contrafactual
Garantía:	Descomposición exacta del efecto total en directo + indirecto + espurio bajo el grafo supuesto
Librerías:	`dowhy` (estimación de mediación)
Validación:	Sensibilidad al grafo de rutas propuesto

23.1 Problema causal, estimando e identificación

El 24, que sigue a este capítulo, trata la interpretabilidad en el sentido más difundido en *machine learning*: explicaciones locales tipo SHAP que atribuyen una predicción a sus variables de entrada por su contribución estadística. Ese tipo de explicación es **asociativa**: describe cómo covarían las variables con la salida del modelo, no si esa covariación refleja un mecanismo causal legítimo o discriminatorio. Este capítulo, más cercano al programa de Bareinboim que al de interpretabilidad de modelos, pregunta algo distinto y más difícil: si un algoritmo de decisión (contratación, crédito, libertad condicional) produce resultados distintos según un atributo protegido —género, raza, origen—, **¿ese efecto pasa por una ruta legítima o por una discriminatoria?** Responder esto requiere descomponer el efecto total en sus componentes causales por ruta, no solo medirlo.

23.2 Teoría, supuestos y garantías

23.2.1 Efectos directos, indirectos y espurios

Considere un atributo protegido A (por ejemplo, género), una variable mediadora M que A afecta legítimamente (por ejemplo, elección de ocupación) y un resultado Y (por ejemplo, salario). El efecto total de A sobre Y se descompone en:

Definición 23.1 ***(Descomposición directo/indirecto)***

El **efecto directo controlado** (*controlled direct effect*, CDE) de A sobre Y fijando $M = m$ es $\text{CDE}(m) = E[Y \mid \text{do}(A = 1, M = m)] - E[Y \mid \text{do}(A = 0, M = m)]$: el efecto de A sobre Y que **no** pasa por M. El **efecto indirecto natural** (*natural indirect effect*, NIE) es la porción del efecto que sí pasa por el cambio que A induce en M.

La pregunta de equidad no es si el efecto total de A sobre Y es distinto de cero —eso puede ser enteramente legítimo si pasa por una ruta que la organización considera aceptable (por ejemplo, si mujeres y hombres eligen, en promedio, ocupaciones distintas por preferencia genuina, y esas ocupaciones legítimamente pagan distinto)— sino si el **efecto directo**, la parte de A sobre Y que no pasa por ningún mediador legítimo, es distinto de cero. Un efecto directo significativo es la firma causal de discriminación, en el sentido más estricto y defendible del término.

23.2.2 Equidad contrafactual

Kusner et al. (2017) formaliza una noción de equidad en el Nivel 3 de la PCH (3): una decisión $\hat{Y}$ es **contrafactualmente justa** si, para cada individuo, $\hat{Y}$ no habría sido distinta en el mundo contrafactual donde su atributo protegido fuera diferente, manteniendo todo lo demás que no dependiera causalmente de A igual. Es una noción más exigente que la paridad demográfica o la igualdad de tasas de error entre grupos —ambas puramente asociativas, de Nivel 1— porque exige razonar sobre el mundo contrafactual específico de cada individuo, no solo sobre promedios poblacionales.

Kilbertus et al. (2017) desarrollan la contraparte de Nivel 2 de esta idea y añaden una distinción que resulta operativa en el diseño de sistemas: la de **discriminación por proxy** frente a **influencia injusta no resuelta**. Un **proxy** es una variable que el algoritmo observa y que es descendiente del atributo protegido —el código postal como proxy de raza, el patrón de compras como proxy de género—; la discriminación por proxy se puede **eliminar por construcción**, interviniendo sobre el proxy en el modelo de decisión de modo que la ruta $A \to \text{proxy} \to \hat{Y}$ quede cortada, sin necesidad de observar A. La **influencia no resuelta**, en cambio, es la que viaja por rutas que la organización no ha declarado legítimas pero que tampoco pasan por ninguna variable observable intervenible; esa no se puede eliminar con una restricción sobre el modelo, y exige una decisión normativa previa sobre qué rutas se aceptan.

La consecuencia práctica para el diseño de un sistema causal en producción es directa. Ante un algoritmo que discrimina, hay dos remedios de naturaleza distinta: uno **técnico**, que consiste en identificar los proxies en el grafo y neutralizarlos —factible, automatizable y verificable—; y uno **normativo**, que consiste en declarar qué rutas causales se consideran

aceptables —que ningún método puede automatizar, y que este capítulo insiste en no disfrazar de decisión técnica—. Confundir ambos es el error característico de las auditorías de equidad que se limitan a eliminar variables sensibles del modelo: quitan A y dejan intactos todos sus proxies, sin haber tocado ninguna de las dos fuentes reales del problema.

23.3 Algoritmo e implementación

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(3)
n = 20_000

# A: atributo protegido (0/1). M: mediador legitimo (ocupacion).
# Y: resultado (salario). Efecto directo deliberado (discriminacion) = 0.15
A = rng.binomial(1, 0.5, size=n)
M = 0.5 * A + rng.normal(scale=1, size=n)          # A afecta a M (legitimo)
Y = 0.15 * A + 0.6 * M + rng.normal(scale=1, size=n)  # A afecta a Y directo
(0.15) + via M

df = pd.DataFrame({"A": A, "M": M, "Y": Y})

# Efecto total (asociativo, sin descomponer)
efecto_total = df.loc[df.A == 1, "Y"].mean() - df.loc[df.A == 0, "Y"].mean()

# Efecto directo controlado: fijar M en su media global y comparar A=1 vs A=0
m_fijo = df["M"].mean()
Y_directo_A1 = 0.15 * 1 + 0.6 * m_fijo
Y_directo_A0 = 0.15 * 0 + 0.6 * m_fijo
cde = Y_directo_A1 - Y_directo_A0

print(f"Efecto total A->Y:            {efecto_total:.3f}")
print(f"Efecto directo controlado:    {cde:.3f}  (deberia acercarse a 0.15)")
print(f"Efecto indirecto (via M):     {efecto_total - cde:.3f}")
# El efecto directo es la señal de discriminacion; el indirecto puede
# ser legitimo si M es una ruta que la organizacion acepta como valida.
```

Listado 23.1: Descomposición directo/indirecto con un SCM lineal simulado.

En un caso real, `dowhy` implementa estimadores de mediación causal que no requieren conocer el SCM verdadero, siempre que el grafo de rutas —incluyendo cuáles se declaran legítimas— esté especificado.

23.4 Caso empírico

Un caso clásico en la literatura de equidad algorítmica es la brecha salarial de género: el efecto total observado se descompone frecuentemente en una parte explicada por diferencias

en ocupación, experiencia y sector (efecto indirecto, cuya legitimidad es en sí misma objeto de debate normativo, no solo estadístico) y un residuo no explicado por esas variables (aproximación al efecto directo). La literatura económica de descomposición salarial (Oaxaca-Blinder) es, de hecho, un antecesor estadístico de la misma idea formalizada aquí con lenguaje causal explícito —con la ventaja de que el lenguaje de rutas permite declarar explícitamente, antes de estimar, cuáles mediadores se consideran legítimos, en vez de dejarlo implícito en la elección de controles.

23.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **Discriminación por proxy.** Una variable «legítima» M puede estar, a su vez, afectada históricamente por A de forma que perpetúa discriminación pasada (por ejemplo, si el acceso a cierta ocupación estuvo históricamente restringido por género). Declarar M como mediador legítimo sin este análisis histórico puede blanquear discriminación indirecta.
- **La legitimidad de una ruta es una decisión normativa, no estadística.** Ningún test estadístico determina si una ruta «debería» considerarse aceptable; esa es una decisión legal, ética y organizacional que el análisis causal formaliza pero no reemplaza.
- **Sensibilidad al grafo.** Igual que en el 8, toda la descomposición depende de que el grafo de rutas propuesto sea correcto. Un mediador omitido puede inflar artificialmente el efecto directo estimado.

23.6 Ejercicios y notas bibliográficas

23.6.1 Ejercicios teóricos

1. Para el caso de la brecha salarial de género, proponga dos mediadores: uno que consideraría legítimo y uno que consideraría cuestionable de aceptar como legítimo, aun si estadísticamente media parte del efecto. Justifique la distinción normativa.
2. Explique, en sus propias palabras, por qué la equidad contrafactual de (Kusner et al. 2017) es una noción de Nivel 3 de la PCH y no de Nivel 1, y por qué eso la hace más difícil de verificar empíricamente que la paridad demográfica.

23.6.2 Ejercicio computacional

1. Modifique el listado Listado 23.1 para que el efecto directo verdadero sea 0 (ninguna discriminación directa, todo el efecto pasa por el mediador legítimo). Verifique numéricamente que el CDE estimado converge a 0 mientras el efecto indirecto se mantiene distinto de cero.

23.6.3 Notas bibliográficas

Las fórmulas de mediación causal y la descomposición directo/indirecto/espurio se desarrollan en (Pearl 2009) y se sistematizan para el caso de equidad algorítmica en (Bareinboim 2025), Capítulo 6. Kusner et al. (2017) introduce la equidad contrafactual como criterio formal de Nivel 3, y Kilbertus et al. (2017) la contraparte de Nivel 2 con la distinción proxy / influencia no resuelta que estructura la 23.2.2. El 24 complementa este tratamiento causal con las definiciones observacionales estándar de la literatura de *fair machine learning* —paridad demográfica, *equalized odds*, calibración— y con el resultado de imposibilidad que muestra que no pueden satisfacerse simultáneamente. La descomposición Oaxaca-Blinder, antecesora estadística de esta idea en economía laboral, se cubre en cualquier texto estándar de econometría aplicada.

23.6.4 Literatura complementaria de equidad causal

Otros enfoques incluyen:

- **Evitar discriminación mediante razonamiento causal** ((Kilbertus et al. 2017), Kilbertus et al. 2017): construcción de grafos causales para identificar rutas de discriminación proxy
- **Descomposición de efectos en fairness:** trabajos de Nabi & Shpitser, y Zhang & Bareinboim sobre path-specific effects para separar discriminación directa vs. indirecta

La integración de fairness y causalidad es un área de investigación activa; ver (Kusner et al. 2017) para fairness contrafactual.

Capítulo 24

Ética, interpretabilidad y comunicación de resultados

Cuadro sinóptico del capítulo

Problema:	Equidad, interpretabilidad y comunicación en ML causal aplicado a políticas públicas
Estimando:	CATE por grupo demográfico, policy value, importancia de variables
Identificación:	No confusión, modelo causal del atributo protegido, SUTVA
Método:	Las tres familias canónicas (independencia / separación / suficiencia) y su incompatibilidad; equidad en el efecto; SHAP sobre sustituto del CATE; policy trees
Nuisance:	$\mu_{d(x)}, e(x)$, modelo de outcome
Garantía:	Identificación bajo supuestos; cobertura de IC bajo normalidad asintótica
Librerías:	`econml`, `shap`, `scikit-learn`
Validación:	Auditoría causal, placebos, counterfactual fairness

Nota técnica

El 23 formalizó la equidad como una pregunta de descomposición causal por rutas. Este capítulo la complementa con la caja de herramientas más usada en la práctica — SHAP y métricas de auditoría estándar— y con una advertencia central: esas herramientas explican el **modelo**, no necesariamente el **mecanismo causal** subyacente, una distinción que retoma directamente la del 1 entre predicción y causa.

24.1 Motivación aplicada

Un ministerio usa un modelo de ML causal para decidir qué hogares reciben un subsidio. El modelo se entrenó sobre datos históricos que reflejan desigualdades preexistentes: hogares encabezados por mujeres, minorías étnicas, y zonas rurales tienen históricamente menor acceso

a programas sociales. El modelo, al optimizar predicción sobre estos datos, puede perpetuar o amplificar esas desigualdades — un fenómeno conocido como *algorithmic bias*.

Este capítulo aborda tres dimensiones éticas del ML causal aplicado a políticas públicas: (i) sesgo algorítmico y equidad, (ii) interpretabilidad de modelos causales complejos, y (iii) comunicación de incertidumbre a tomadores de decisión. Argumentamos que la calidad técnica de un modelo causal no se mide solo en su precisión estadística, sino en sus consecuencias sociales y en la transparencia con que se comunica.

24.2 Teoría, supuestos y garantías

24.2.1 Equidad causal

Nota: Las tres familias canónicas de equidad en ML son:

1. **Demographic parity** (independencia estadística)
2. **Equalized odds** ((Hardt et al. 2016), Hardt et al. 2016): igualdad de TPR y FPR
3. **Calibration/predictive parity** ((Dwork et al. 2012), Dwork et al. 2012): misma precisión de predicción por grupo

La literatura de *fair machine learning* ha convergido en **tres familias canónicas** de criterios observacionales, que Barocas et al. (2019) organizan según qué independencia estadística exigen entre la decisión $\pi(X)$, el atributo protegido G y el resultado relevante Y^*:

Definición 24.1 ***(Independencia — demographic parity)***

Una regla de asignación π satisface *demographic parity* (o paridad estadística) respecto a un atributo protegido G si $\pi(X) \perp\!\!\!\perp G$: la tasa de asignación es la misma en todos los grupos.

Definición 24.2 ***(Separación — equalized odds)***

π satisface *equalized odds* (Hardt et al. 2016) si $\pi(X) \perp\!\!\!\perp G \,|\, Y^*$: las tasas de verdaderos positivos y de falsos positivos coinciden entre grupos. La versión relajada que exige la igualdad solo sobre $Y^* = 1$ se conoce como *equality of opportunity*.

Definición 24.3 ***(Suficiencia — calibración por grupo)***

π (o el score que la genera) satisface *calibración por grupo* si $Y^* \perp\!\!\!\perp G \,|\, \pi(X)$: condicional a la puntuación asignada, la tasa base del resultado es la misma en todos los grupos.

Teorema 24.4 ***(Incompatibilidad de los criterios)***

Salvo en dos casos degenerados —predicción perfecta, o tasas base idénticas entre grupos ($P(Y^* = 1 \mid G = g)$ constante en g)— **no existe** ninguna regla de decisión que satisfaga simultáneamente separación y suficiencia. Las tres familias son, en general, mutuamente incompatibles.

Este resultado es la pieza que más se omite al presentar el tema y la que más importa para un sistema en producción: **no hay una definición de equidad que se pueda «activar» en el pipeline**. Elegir un criterio es descartar los otros, y esa elección es normativa —depende

de qué error se considera más grave en el contexto concreto— y no se puede delegar en el equipo técnico. El resultado se hizo célebre a raíz del debate sobre COMPAS, donde una parte sostenía que el algoritmo era injusto (falsos positivos desiguales, criterio de separación) y otra que era justo (calibrado por grupo, criterio de suficiencia): ambas tenían razón bajo su criterio, y el teorema explica por qué la discusión no podía resolverse con más datos.

Una advertencia adicional sobre el punto de partida de toda esta familia: Dwork et al. (2012) ya señalaron que la paridad demográfica es un criterio débil y manipulable —se puede satisfacer tratando bien a los miembros cualificados de un grupo y arbitrariamente a los del otro— y propusieron en su lugar la **equidad individual**: individuos similares respecto a una métrica de tarea deben recibir decisiones similares. Su límite práctico, reconocido por los propios autores, es que la métrica de similitud es exactamente lo difícil de especificar, y en ella se esconde el mismo juicio normativo que se pretendía evitar.

24.2.2 Del criterio observacional al criterio causal

Las tres familias anteriores son criterios de $\mathcal{L}_1$: se definen sobre la distribución conjunta observada, sin referencia a mecanismos. Un sistema **causal** admite además un criterio propio, que este curso usa como complemento y no como sustituto:

Definición 24.5 ***(Equidad en el efecto (*equalized CATE*))***

Una política satisface **equidad en el efecto** respecto a G si la distribución del CATE estimado $\hat{\tau}(X)$ —y por tanto el beneficio esperado del tratamiento— es comparable entre grupos definidos por G.

Nota sobre Equalized CATE: La noción de *Equalized CATE* extiende equalized odds al contexto de efectos heterogéneos. Ver (Barocas et al. 2019) para un tratamiento completo de las familias de equidad.

Conviene ser explícitos sobre el estatus de esta definición: **no** pertenece al canon de la literatura de *fair ML* y no debe presentarse como si lo hiciera. Es una noción específica de sistemas de asignación causal, y responde a una pregunta que los tres criterios canónicos no formulan: no «¿a quién se le asigna el tratamiento?» sino «¿quién se beneficia de él?». La distinción importa porque las dos preguntas pueden dar respuestas opuestas —una política puede satisfacer paridad demográfica en la asignación y, sin embargo, concentrar todo el beneficio real en un solo grupo, si el efecto es heterogéneo—. Y tiene un límite serio que debe declararse: si el CATE es genuinamente menor en un grupo por razones estructurales (como en el caso de los hogares rurales de la 24.4.1), **imponer** equidad en el efecto no es posible ni deseable; lo que la métrica aporta es hacer visible esa desigualdad estructural, no corregirla por decreto.

Kitagawa et al. (2021) formalizan el trade-off resultante: maximizar $V(\pi)$ sujeto a restricciones de equidad —de cualquiera de las familias anteriores— define un problema de **clasificación restringida** cuyas garantías de regret difieren de las del 21 sin restricciones. El resultado operativo es que el costo en *welfare* de imponer equidad es cuantificable y debe reportarse: no

como argumento contra la restricción, sino como el precio explícito de una decisión distributiva que alguien debe tomar a sabiendas.

24.2.3 Interpretabilidad

Los modelos de ML causal (causal forest, deep causal) son cajas negras. Tres estrategias de interpretabilidad:

- **SHAP (SHapley Additive exPlanations).** Asigna a cada feature una contribución a la predicción, basada en valores de Shapley de teoría de juegos.
- **Partial dependence plots.** Muestra el efecto marginal de una feature sobre $\hat{\tau}$, promediando sobre las demás.
- **Policy trees.** Una vez aprendido un CATE con causal forest, se aprende un árbol de decisión shallow sobre $\hat{\tau}$ para producir una regla interpretable.

¿Qué objeto se está explicando? Antes de aplicar cualquiera de las tres, hay que responder una pregunta que se salta con frecuencia y que invalida buena parte de las auditorías de interpretabilidad de modelos causales. Un estimador causal contiene **varios** modelos, y explicar el equivocado produce conclusiones sistemáticamente engañosas:

Modelo interno	Qué predice	Qué significa su SHAP
$\hat{\mu}_Y$ (*outcome*)	$E[Y \mid X]$	Qué variables predicen el **resultado**. No dice nada sobre el efecto del tratamiento. Es el error más común.
$\hat{e}$ (*propensity*)	$E[D \mid X]$	Qué variables predicen **quién fue tratado**. Útil como diagnóstico de selección, no de efecto.
$\hat{\tau}$ (CATE)	$E[Y(1) - Y(0) \mid X]$	Qué variables explican la **heterogeneidad del efecto**. Es lo que casi siempre se quiere y casi nunca se calcula.

Aplicar SHAP a $\hat{\mu}_Y$ y presentarlo como «las variables que más influyen en el efecto» es un error de categoría, no una aproximación tolerable: la edad puede ser el predictor dominante del salario y ser completamente irrelevante para la heterogeneidad del retorno a la educación. Para explicar el CATE hay que explicar el CATE, y como `CausalForestDML` no expone un modelo `sklearn` sobre el que SHAP pueda operar directamente, la vía practicable es ajustar un **modelo sustituto** (*surrogate*) sobre las predicciones $\hat{\tau}(X)$ y explicar ese —con la salvedad, que hay que reportar, de que se está explicando la aproximación y no el estimador—.

24.2.4 Comunicación de incertidumbre

El error más común al comunicar resultados causales a no-técnicos es reportar solo el estimado puntual sin IC. La regla operacional: *todo número reportado debe acompañarse de una medida de incertidumbre.*

- Reportar IC al 95% en formato «[lb, ub]».
- Para CATE, reportar la distribución (histograma, mapa) no solo el promedio.

- Distinguir afirmaciones predictivas («el modelo predice») de afirmaciones causales («el efecto causal estimado es»).

24.3 Implementación en Python

24.3.1 Interpretabilidad con SHAP

```
import shap
import numpy as np
import pandas as pd
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

# Dataset simulado
rng = np.random.default_rng(42)
n = 5000
X = rng.uniform(-1, 1, (n, 5))
A = rng.binomial(1, 0.3, n)  # 30% es minoria
tau = 2 + 3*X[:, 0] - 1.5 * A
e = 0.4 + 0.2 * np.tanh(X[:, 0]) - 0.1 * A
D = (rng.uniform(size=n) < e).astype(int)
Y = X[:, 1] + D * tau + rng.standard_normal(n) * 0.5

cf = CausalForestDML(model_y=GradientBoostingRegressor(random_state=42),
                     model_t=GradientBoostingClassifier(random_state=42),
                     discrete_treatment=True, random_state=42, cv=5).fit(Y, D,
X=X)
cate_hat = cf.effect(X)

nombres = [f"x{i}" for i in range(5)]

# --- (a) INCORRECTO: SHAP sobre el modelo de outcome -----------------
# Explica que variables predicen Y, NO que variables explican el efecto.
# Se incluye solo para contrastar; no reportar esto como "drivers del CATE".
expl_y = shap.TreeExplainer(cf.model_y)
shap_y = expl_y.shap_values(X[:200])

# --- (b) CORRECTO: SHAP sobre un sustituto del CATE ------------------
# Se ajusta un modelo interpretable-por-SHAP a las predicciones tau(x)
# y se explica ESE. El R^2 del sustituto mide cuanta de la estructura
# del CATE se conserva: si es bajo, la explicacion no es fiable.
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import cross_val_score

surrogate = RandomForestRegressor(n_estimators=300, min_samples_leaf=20,
                                  random_state=42)
r2 = cross_val_score(surrogate, X, cate_hat, cv=5, scoring="r2").mean()
surrogate.fit(X, cate_hat)
print(f"Fidelidad del sustituto al CATE (R2 CV): {r2:.3f}")
if r2 < 0.8:
    print("ADVERTENCIA: el sustituto no reproduce bien el CATE; "
          "la atribucion SHAP sobre el es poco informativa.")

expl_tau = shap.TreeExplainer(surrogate)
shap_tau = expl_tau.shap_values(X[:200])
shap.summary_plot(shap_tau, X[:200], feature_names=nombres,
                  show=False)  # <- ESTE es el grafico a reportar

# Contraste explicito de los dos rankings de importancia
imp_y = np.abs(shap_y).mean(axis=0)
imp_tau = np.abs(shap_tau).mean(axis=0)
comparacion = pd.DataFrame({
```

Listado 24.1: SHAP para Causal Forest

El contraste final del listado no es decorativo: en este DGP, construido de modo que μ_0 dependa de x_1 y τ de x_0, los dos rankings de importancia señalan variables **distintas**. Un informe que reporte el primero bajo el título «qué determina el efecto del programa» está diciendo algo falso sobre el mecanismo, con toda la apariencia de rigor que da un gráfico SHAP.

Dos cautelas más, sobre las que conviene ser explícito en cualquier informe. Primera: el sustituto explica $\hat{\tau}$, no τ — si el estimador de CATE está sesgado, SHAP explicará fielmente un artefacto. Segunda, y más de fondo: incluso una atribución correcta sobre el CATE es **asociativa dentro del modelo**, no causal sobre el mundo. Que x_0 explique la heterogeneidad no significa que intervenir sobre x_0 cambie el efecto del tratamiento; responder eso exige el aparato de rutas del 23, no una atribución de importancia.

24.3.2 Tabla de resultados para policymakers

```
def format_results_for_policymakers(cate, A=None, group_labels=None):
    """Genera tabla resumen con IC, distinguiendo grupos.

    ADVERTENCIA: el intervalo calculado aqui usa la desviacion estandar de
    los CATE ESTIMADOS, por lo que cuantifica la dispersion del efecto
    dentro del grupo, NO la incertidumbre de estimacion. Para un IC sobre
    el efecto promedio del grupo usar el estimador con su influence
    function -- p.ej. `cf.ate_interval(X=X[A == g])` de econml -- que
    propaga correctamente el error de los nuisance. Confundir ambos
    produce intervalos demasiado estrechos.
    """
    rows = []
    if A is None:
        A = np.zeros_like(cate, dtype=int)
    groups = np.unique(A)
    for g in groups:
        cate_g = cate[A == g]
        n_g = len(cate_g)
        mean_g = cate_g.mean()
        se_g = cate_g.std(ddof=1) / np.sqrt(n_g)
        lb = mean_g - 1.96 * se_g
        ub = mean_g + 1.96 * se_g
        label = group_labels[g] if group_labels else f"Grupo {g}"
        rows.append({"Grupo": label, "n": n_g,
                     "CATE medio": f"{mean_g:.2f}",
                     "IC 95%": f"[{lb:.2f}, {ub:.2f}]"})
    return pd.DataFrame(rows)

df_comm = format_results_for_policymakers(cate_hat, A, {0: "Mayoria", 1:
"Minoria"})
print(df_comm.to_markdown(index=False))
```

Listado 24.2: Tabla de resultados para comunicación a tomadores de decisión.

24.3.3 Análisis de equidad

```
import scipy.stats as st

# --- Efecto promedio por grupo, con IC del ESTIMADOR ------------------
# Se usa ate_interval sobre el subconjunto de cada grupo: propaga la
# incertidumbre de estimacion via influence function, a diferencia de
# aplicar t-tests sobre los CATE puntuales (que trata predicciones como
# si fueran observaciones y produce IC demasiado estrechos).
for a in [0, 1]:
    mask = A == a
    ate_a = cf.ate(X=X[mask])
    lb_a, ub_a = cf.ate_interval(X=X[mask], alpha=0.05)
    print(f"Grupo A={a} (n={mask.sum()}): efecto medio = {ate_a:.3f} "
          f"(IC 95%: [{lb_a:.3f}, {ub_a:.3f}])")

# --- Contraste de la brecha entre grupos ------------------------------
# La brecha es un funcional del modelo; su incertidumbre se obtiene por
# bootstrap sobre el pipeline completo (re-estimando el bosque), no por
# un t-test sobre los cate_hat, que ignora el error de estimacion.
def brecha_bootstrap(Y, D, X, A, B=200, seed=0):
    rng = np.random.default_rng(seed)
    n, brechas = len(Y), []
    for _ in range(B):
        idx = rng.integers(0, n, n)
        m = CausalForestDML(
            model_y=GradientBoostingRegressor(random_state=42),
            model_t=GradientBoostingClassifier(random_state=42),
            discrete_treatment=True, random_state=42, cv=3
        ).fit(Y[idx], D[idx], X=X[idx])
        brechas.append(m.ate(X=X[idx][A[idx] == 0]) - m.ate(X=X[idx][A[idx] ==
1]))
    return np.percentile(brechas, [2.5, 97.5])

# lo, hi = brecha_bootstrap(Y, D, X, A)   # costoso: B re-ajustes del bosque
# print(f"Brecha de efecto entre grupos, IC 95% bootstrap: [{lo:.3f},
{hi:.3f}]")
```

Listado 24.3: Análisis de equidad en policy learning.

La diferencia entre este listado y la versión ingenua no es un tecnicismo. Aplicar un t-test a los $\hat{\tau}_i$ trata las **predicciones** del modelo como si fueran observaciones independientes: ignora por completo que cada $\hat{\tau}_i$ arrastra el error de estimación de los *nuisance* y del bosque, y produce p-valores que pueden ser órdenes de magnitud demasiado pequeños. En una auditoría de equidad, ese error tiene una consecuencia concreta y grave: declarar una brecha de efecto entre grupos como estadísticamente significativa cuando la evidencia no lo respalda —o, peor, sostener sobre esa base una decisión de asignación diferenciada por grupo protegido—.

24.4 Caso empírico y validación

24.4.1 Auditoría de equidad en focalización de transferencias

Sobre el dataset `gov_transfers`, aplicamos causal forest y detectamos que el CATE estimado para hogares rurales es 30% menor que para hogares urbanos. Esto refleja no un sesgo del modelo, sino una desigualdad estructural: las transferencias tienen menor efecto en hogares rurales por falta de acceso a mercados. La recomendación de política no es excluir hogares rurales (eso amplificaría la desigualdad), sino complementar las transferencias con inversión en infraestructura rural.

La auditoría incluye los siguientes pasos:

1. Estimar CATE por grupo demográfico usando causal forest.
2. Comparar distribuciones de CATE entre grupos (test t, Kolmogorov–Smirnov).
3. Evaluar sensibilidad de las diferencias a la inclusión de confusores adicionales.
4. Reportar resultados con intervalos de confianza y distinguir entre efecto causal y correlación.

Intuición

Caja de profundización 16.1: Equidad causal y explicaciones contrafactuales

Objetivo. Entender cómo la causalidad ayuda a evaluar si un modelo es justo.

¿Qué es equidad? No hay una definición única. Tres enfoques:

- **Demographic parity:** la tasa de tratamiento es igual entre grupos (ej: misma proporción de hombres y mujeres reciben el beneficio).
- **Equalized odds:** la tasa de tratamiento es igual entre grupos condicionando en la necesidad real (ej: entre personas que realmente necesitan el beneficio, misma tasa para hombres y mujeres).
- **Equalized CATE:** la distribución del efecto estimado es similar entre grupos.

Equidad contrafactual. Una decisión es «contrafactualmente justa» si, cuando imaginamos cambiar solo el género (o raza, etc.) de una persona pero mantenemos todo lo demás igual, la decisión no cambia. Esto requiere un modelo causal de cómo el atributo protegido afecta el resultado.

Explicaciones contrafactuales. En lugar de decir «el modelo no te dio el crédito porque tu score es 620», podemos decir: «si tus ingresos fueran $100,000 más altos, habrías recibido el crédito». Esto es más accionable y comprensible.

Documentación responsable. Todo proyecto de ML causal debería incluir:

- **Model card:** una ficha con el propósito, población, limitaciones y riesgos del modelo.
- **Auditoría de equidad:** comparar CATE promedio entre grupos definidos por atributos protegidos.

24.5 Riesgos, límites y sensibilidad

24.5.1 Tabla de riesgos

La tabla Tabla 24.1 resume los riesgos principales al usar ML causal en contextos de política pública, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
SHAP sobre el modelo equivocado	Reportar los predictores de Y como si fueran los determinantes del efecto: conclusión falsa sobre el mecanismo	Verificar sobre qué objeto se calculó la atribución (24.2.3): ¿$\hat{\mu}_Y$, $\hat{e}$ o $\hat{\tau}$?	Explicar un sustituto ajustado sobre $\hat{\tau}(X)$ y reportar su fidelidad (R^2 CV); contrastar ambos rankings como en el listado Listado 24.1
SHAP como causal	Sobreinterpretación: creer que intervenir sobre la variable cambia el efecto	Nota explícita de que la atribución es asociativa dentro del modelo, incluso cuando se calcula sobre el CATE	Para preguntas de mecanismo, usar descomposición por rutas (23); validar el CATE con placebos y refutación
IC sobre CATE por grupo con t-test	Intervalos demasiado estrechos; brechas de equidad declaradas significativas sin evidencia	Comprobar si el IC usa la desviación de los $\hat{\tau}_i$ o la *influence function* del estimador	Usar `ate_interval` por subgrupo o bootstrap del pipeline completo (listado Listado 24.3)
Fairness sin causalidad	Métrica engañosa al no considerar la estructura causal del sesgo	Auditoría causal comparando CATE entre grupos	Counterfactual fairness con modelo causal explícito
Comunicación sin IC	Decisión errónea basada en falsa confianza	Tabla con IC al 95% para todo estimado reportado	Incertidumbre cuantificada y comunicada explícitamente
Optimizar welfare sin restricciones de equidad	Política que excluye sistemáticamente a minorías	Reportar equidad junto con welfare agregado	Restricciones de equidad en la optimización
No distinguir afirmaciones causales de predictivas	Confundir quién necesita el programa con quién se beneficiaría más	Verificar si el estimando es $E[Y(1) - Y(0) \mid X]$ o $E[Y \mid X, D]$	Usar lenguaje explícito: «efecto causal estimado» vs. «predicción»

Tabla 24.1: Riesgos en ética, interpretabilidad y comunicación de ML causal

24.5.2 Cuándo no usar este método

La equidad causal es un campo activo de investigación. Las definiciones existentes no solo «pueden» entrar en conflicto: el teorema de incompatibilidad de la 24.2.1 garantiza que, fuera de casos degenerados, **no pueden satisfacerse a la vez**. No hay por tanto una solución técnica única, y presentar una auditoría de equidad como si la hubiera es en sí mismo un error

de método. Lo que este capítulo sostiene es más modesto y más defendible: hacer explícito qué criterio se adoptó, por qué, y cuánto *welfare* cuesta.

Una limitación adicional del enfoque de este capítulo merece declararse. Todos los criterios discutidos evalúan la **decisión** o el **efecto**, dando por buenos los datos sobre los que se estimaron. Si el sesgo está en la medición misma —si Y se registra de forma sistemáticamente distinta entre grupos, o si la población de entrenamiento excluye a un grupo por el diseño del muestreo (7)— ninguna restricción de equidad sobre la política corrige el problema, y la auditoría producirá métricas satisfactorias sobre un sistema injusto. La comunicación a no-técnicos requiere, además, traducir conceptos estadísticos (IC, CATE, regret) a lenguaje sustantivo sin perder rigor, tema que cierra el libro en el 32.

24.6 Ejercicios propuestos

1. Replique el listado Listado 24.3 sobre `gov_transfers` o `nsw_mixtape`. ¿Hay diferencias de CATE entre grupos demográficos?
2. Construya una política de tratamiento que satisfaga *equalized CATE* entre dos grupos. ¿En cuánto se reduce el welfare respecto a la política óptima sin restricciones?
3. Use SHAP para interpretar un Causal Forest entrenado sobre `nhefs`. ¿Qué variables son más importantes para la heterogeneidad del efecto de dejar de fumar?
4. Escriba un *policy brief* (1 página) comunicando los resultados de un análisis causal a un ministro no técnico. Incluya IC, recomendación de política y limitaciones.

24.7 Lecturas complementarias

Barocas et al. (2019) es el tratamiento de referencia de la equidad algorítmica y la fuente de la organización en tres familias (independencia, separación, suficiencia) adoptada en la 24.2.1, incluido el teorema de incompatibilidad. Dwork et al. (2012) es el trabajo fundacional del campo y de la noción de equidad individual; Hardt et al. (2016) introduce *equalized odds* y *equality of opportunity*, junto con un procedimiento de post-procesamiento para imponerlas. Para la vía causal —descomposición por rutas y equidad contrafactual— véase el 23 y sus referencias. Kitagawa et al. (2021) formalizan el policy learning bajo restricciones y permiten cuantificar el costo en *welfare* de cada criterio.

Sobre interpretabilidad, Lundberg et al. (2017) es la referencia de SHAP, y Lipton (2018) la lectura crítica indispensable antes de usarlo: muestra que «interpretabilidad» designa objetivos distintos y a veces incompatibles (confianza, causalidad, transferibilidad, comunicabilidad), y que una técnica de atribución no satisface automáticamente ninguno de ellos —el argumento que la 24.2.3 aplica al caso específico de explicar un estimador causal—. Para comunicación de incertidumbre a audiencias no técnicas, (Spiegelhalter 2019).

Capítulo 25

Decisiones estructurales bajo incertidumbre

Cuadro sinóptico del capítulo

Problema:	Elegir entre acciones, no solo estimar el efecto de una acción dada
Estimando:	Utilidad esperada bajo cada acción candidata, $E[U(Y(\text{do}(d)))]$
Identificación:	Identificación del efecto de cada d candidato + función de utilidad declarada
Método:	Maximización de utilidad esperada sobre el conjunto de acciones factibles
Garantía:	La acción óptima estimada converge a la verdadera si los efectos de cada d están correctamente identificados
Librerías:	`econml.policy`, optimización con `scipy.optimize`
Validación:	Comparación contra una decisión de referencia (*status quo*) y análisis de sensibilidad a la utilidad supuesta

25.1 Problema causal, estimando e identificación

El 21 (Capítulo 21) ya resolvió una versión de este problema: dado un CATE estimado, ¿a quién asignar un tratamiento binario bajo una restricción de presupuesto? Este capítulo generaliza la pregunta en dos direcciones que Bareinboim formaliza bajo el nombre de **decisiones estructurales**: primero, la acción no tiene por qué ser binaria ni consistir en «tratar o no tratar» a cada unidad — puede ser elegir entre varias políticas alternativas, fijar un parámetro continuo, o intervenir sobre más de una variable simultáneamente; segundo, la decisión requiere una **función de utilidad** explícita, no solo un efecto estimado, porque comparar acciones distintas exige poder decir cuánto vale cada resultado posible, no solo cuál es más probable.

25.2 Teoría, supuestos y garantías

25.2.1 La decisión como maximización de utilidad esperada

Definición 25.1 ***(Decisión óptima)***

Dado un conjunto de acciones factibles $\mathcal{D}$ y una función de utilidad $U : \mathcal{Y} \to \mathbb{R}$ que asigna un valor a cada resultado posible, la **acción óptima** es

$$d^* = \underset{d \in \mathcal{D}}{\operatorname{argmax}}\, E[U(Y(\mathrm{do}(d)))] \tag{25.93}$$

donde $E[U(Y(\mathrm{do}(d)))]$ se calcula usando la distribución interventiva de Nivel 2 de la PCH (3) inducida por cada acción candidata d.

La diferencia con el problema de estimación de los capítulos anteriores es sutil pero importante: estimar $\tau(x)$ responde «¿cuál es el efecto?»; resolver d^* responde «¿qué debería hacerse?», y esta segunda pregunta **siempre** requiere una función de utilidad, aunque sea implícita. Cuando el 21 maximizaba el «valor de la política» sujeto a un presupuesto, esa era ya una función de utilidad particular —lineal en el resultado, con una restricción de costo—; este capítulo hace explícito que esa elección de utilidad es, en sí misma, una decisión de modelado con consecuencias.

25.2.2 Decisiones sobre múltiples variables y el rol de la incertidumbre

Cuando la acción involucra más de una variable de intervención (por ejemplo, elegir simultáneamente el monto de una transferencia y el requisito de asistencia a capacitaciones), el conjunto $\mathcal{D}$ deja de ser un simple binario o un umbral y se vuelve un espacio multidimensional. La incertidumbre entra por dos vías distintas, que conviene no confundir: **incertidumbre estadística** sobre el efecto de cada acción (el mismo tipo de incertidumbre que ya se cuantifica con los intervalos de confianza de capítulos anteriores) e **incertidumbre estructural** sobre si el SCM supuesto es siquiera el correcto (la que ningún intervalo de confianza captura, y que solo un análisis de sensibilidad al grafo, como el del 8, puede abordar parcialmente).

25.2.3 Criterios de decisión cuando el efecto no está identificado con precisión

Maximizar la utilidad esperada usando la estimación puntual $\hat{E}[U(Y(\mathrm{do}(d)))]$ es el criterio por defecto, pero no es el único defendible, y su adopción implícita esconde un supuesto fuerte: que la incertidumbre sobre el efecto puede resumirse en una media y tratarse como si el estimador puntual fuera el valor verdadero. La teoría estadística de la decisión ofrece un vocabulario preciso para las alternativas, y Manski (2004) lo trasladó al problema exacto de este capítulo —elegir una regla de tratamiento cuando el efecto está **parcialmente identificado**, es decir, cuando los datos y los supuestos solo acotan τ dentro de un intervalo en vez de fijarlo—.

Tres criterios cubren el espectro de posturas razonables ante esa situación:

Criterio	**Qué maximiza**	**Cuándo es defendible**
Utilidad esperada	$E[U(Y(\text{do}(d)))]$ bajo la estimación puntual	Efecto bien identificado y estimado con precisión; decisión repetida muchas veces, de modo que los promedios se realizan
Maximin (Wald)	El peor resultado posible dentro del conjunto identificado: $\max_d \min_{\tau \in \mathcal{T}} U$	Decisiones irreversibles o con consecuencias catastróficas en el peor escenario; aversión fuerte a la ambigüedad
Minimax regret (Savage)	La máxima pérdida respecto a la mejor acción posible en cada escenario	Cuando el maximin resulta paralizante por concentrarse en escenarios extremos poco plausibles; es el criterio que Manski defiende para reglas de tratamiento

La diferencia entre ellos no es académica: con un efecto cuyo intervalo de confianza cruza el cero, la utilidad esperada puede recomendar intervenir (porque el punto estimado es positivo) mientras el maximin recomienda no hacerlo (porque el peor caso es dañino), y el minimax regret puede recomendar una acción intermedia —tratar a un subconjunto, o postergar la decisión hasta recolectar más datos—. Reportar cuál de los tres criterios se aplicó es tan importante como reportar el efecto estimado, porque la recomendación de política depende de ambos.

Esto conecta además con una decisión que el marco de utilidad esperada suele dejar fuera del conjunto $\mathcal{D}$ y que casi siempre debería estar dentro: la acción **«no decidir todavía y experimentar»**. Cuando la incertidumbre es la restricción vinculante, el valor de un experimento aleatorizado —que reduce esa incertidumbre— compite legítimamente con el valor de las acciones sustantivas, y omitirlo del conjunto de acciones factibles sesga sistemáticamente la decisión hacia intervenir con la información actual.

25.3 Algoritmo e implementación

```
import numpy as np

# Tres politicas candidatas para un programa social, cada una con un
# efecto estimado (media, error estandar) y un costo distinto
politicas = {
    "sin_intervencion": {"efecto": 0.0, "se": 0.0, "costo": 0},
    "transferencia_simple": {"efecto": 0.12, "se": 0.03, "costo": 500},
    "transferencia_mas_capacitacion": {"efecto": 0.19, "se": 0.05, "costo":
900},
}

def utilidad_esperada(efecto, costo, valor_por_punto_efecto=3000,
presupuesto=1000):
    """Utilidad: valor monetario del efecto menos el costo,
    con penalizacion fuerte si excede presupuesto."""
    if costo > presupuesto:
        return -np.inf
    return valor_por_punto_efecto * efecto - costo

for nombre, datos in politicas.items():
    u = utilidad_esperada(datos["efecto"], datos["costo"])
    # bandas de utilidad usando +/- 1.96 SE del efecto, para reportar
incertidumbre
    u_low = utilidad_esperada(datos["efecto"] - 1.96 * datos["se"],
datos["costo"])
    u_high = utilidad_esperada(datos["efecto"] + 1.96 * datos["se"],
datos["costo"])
    print(f"{nombre:30s} U={u:8.1f}  IC95%=({u_low:.1f}, {u_high:.1f})")

mejor = max(politicas, key=lambda k: utilidad_esperada(politicas[k]["efecto"],
politicas[k]["costo"]))
print(f"\nAccion optima bajo esta utilidad: {mejor}")
```

Listado 25.1: Selección de acción óptima entre tres políticas candidatas con incertidumbre.

El listado reporta no solo la utilidad puntual de cada acción sino su intervalo, precisamente porque una acción con mayor utilidad puntual pero con un intervalo que se solapa ampliamente con el de otra no debería declararse «claramente superior» sin más análisis — el mismo espíritu de reporte honesto de incertidumbre que el Capítulo 15 exigió en la respuesta del servicio desplegado.

25.4 Caso empírico

Retomando el dataset de transferencias condicionadas usado en capítulos anteriores del curso: una decisión estructural real no es solo «¿a quién dar la transferencia?» (Capítulo 21) sino, con frecuencia, «¿qué diseño de programa implementar?» entre varias alternativas

con distintos costos administrativos y efectos esperados —transferencia simple, transferencia con condicionalidad, transferencia con componente de capacitación—. El listado Listado 25.1 estiliza exactamente esta comparación, y el punto pedagógico central es que la acción óptima depende críticamente de `valor_por_punto_efecto`, un parámetro normativo (cuánto vale, en términos monetarios comparables, un punto de mejora en el resultado) que ningún dato por sí solo puede determinar.

25.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **Función de utilidad implícita y no examinada.** Toda decisión automatizada usa alguna función de utilidad, aunque nadie la haya escrito explícitamente (a menudo es, por defecto, «maximizar el efecto promedio sin considerar costos ni distribución»). Hacerla explícita, como en este capítulo, permite auditarla; dejarla implícita no la elimina, solo la esconde.
- **Sensibilidad de la decisión a la utilidad supuesta.** Dos analistas razonables pueden discrepar en `valor_por_punto_efecto` y llegar a decisiones óptimas distintas con el mismo efecto estimado. Reportar cómo cambia d^* bajo utilidades alternativas es una buena práctica, análoga al análisis de sensibilidad a supuestos de identificación.
- **Confundir incertidumbre estadística con incertidumbre estructural.** Un intervalo de confianza estrecho sobre el efecto de una acción no dice nada sobre si el SCM supuesto para calcular ese efecto es correcto. Ambas fuentes de incertidumbre son relevantes para la decisión final y no deben mezclarse en un único número.

25.6 Ejercicios y notas bibliográficas

25.6.1 Ejercicios teóricos

1. Explique por qué el problema de policy learning del Capítulo 21 (a quién tratar bajo presupuesto) es un caso particular del problema de decisión estructural de este capítulo, identificando explícitamente cuál es $\mathcal{D}$ y cuál es U en ese caso.
2. Para el caso empírico de la 25.4, proponga una función de utilidad alternativa que dé peso explícito a la equidad distributiva (por ejemplo, que penalice que el efecto se concentre en un subgrupo). ¿Cambiaría la acción óptima?

25.6.2 Ejercicio computacional

1. Modifique el listado Listado 25.1 con al menos dos valores distintos de `valor_por_punto_efecto` (uno bajo, uno alto) y reporte si la acción óptima cambia. Discuta qué implica esto para la robustez de la recomendación de política.

2. Extienda el listado Listado 25.1 para que, además de la utilidad esperada, calcule la acción óptima según los criterios *maximin* y *minimax regret* de la 25.2.3, tomando como conjunto identificado el intervalo $\hat{\tau} \pm 1.96 \cdot \text{SE}$ de cada política. ¿Coinciden las tres recomendaciones? Repita ampliando el error estándar de `transferencia_mas_capacitacion` a 0.10 y explique por qué los criterios divergen cuando la incertidumbre crece.

25.6.3 Notas bibliográficas

Este capítulo sigue la formalización de decisiones estructurales de (Bareinboim 2025), Capítulo 7. El marco formal de teoría de la decisión bajo incertidumbre se trata en (Berger 1985) (Berger 1985). Para decisiones con identificación parcial (bounds en lugar de estimados puntuales), ver (Manski 2004) (Manski 2004), que formaliza reglas de tratamiento bajo incertidumbre estructural. Para el aparato de teoría de la decisión estadística —funciones de pérdida, criterios de admisibilidad, maximización de utilidad esperada bajo incertidumbre— la referencia estándar es Berger (1985). Manski (2004) es la lectura clave de la 25.2.3 y la que conecta ambos mundos: formula la elección de una regla de tratamiento como un problema de decisión bajo **identificación parcial**, desarrolla el criterio de minimax regret para ese contexto y deriva sus implicaciones para la asignación fraccional de tratamientos. Es también el antecedente directo de la *Empirical Welfare Maximization* del 21, que puede leerse como el caso en que el efecto sí está puntualmente identificado. El 21 y el 22 son los casos particulares de este marco más aplicados en la práctica de targeting.

Capítulo 26

Generalización y transportabilidad entre dominios

Cuadro sinóptico del capítulo

Problema:	Determinar si un efecto estimado en un dominio es válido en otro
Estimando:	El efecto en el dominio destino, $P^*(y \mid \text{do}(x))$
Identificación:	Diagrama de selección: qué mecanismos difieren entre dominio fuente y destino
Método:	Teoría de transportabilidad (Bareinboim y Pearl)
Garantía:	Si el efecto es transportable, existe una fórmula que lo calcula combinando datos de ambos dominios
Librerías:	Sin implementación estándar madura; análisis mayormente conceptual/gráfico
Validación:	Replicación en el dominio destino cuando sea posible; análisis de sensibilidad a diferencias no modeladas

26.1 Problema causal, estimando e identificación

Toda *model card* causal de este curso (Capítulo 19) incluyó, desde su primera versión, una sección de «población de entrenamiento» con una advertencia explícita de no usar el modelo fuera de ese dominio. Este capítulo formaliza exactamente qué significa «fuera de ese dominio» y bajo qué condiciones —no nunca, no siempre— un efecto estimado en una población puede aplicarse legítimamente a otra. La noción informal de «validez externa», tratada en econometría aplicada casi siempre de forma cualitativa, tiene una versión formal y verificable en el marco de la PCH: la **transportabilidad**.

26.2 Teoría, supuestos y garantías

26.2.1 Diagramas de selección

Definición 26.1 ***(Diagrama de selección)***

Un **diagrama de selección** es un grafo causal aumentado con nodos especiales S (uno por cada mecanismo que se sospecha difiere entre el dominio fuente Π y el dominio destino Π^*), con una flecha $S_i \to V_i$ indicando que el mecanismo que genera V_i puede diferir entre dominios. Variables sin nodo S entrante comparten el mismo mecanismo generador en ambos dominios.

Por ejemplo, si un efecto se estimó en una población urbana (Π) y se quiere aplicar a una población rural (Π^*), y se sospecha que la distribución de ingresos difiere entre ambas pero el mecanismo por el cual el ingreso afecta al resultado es el mismo, el diagrama de selección tendría un nodo S apuntando a la variable de ingreso (su **distribución** difiere) pero no a la ecuación estructural que relaciona ingreso con el resultado (su **mecanismo** es el mismo).

Teorema 26.2 ***(Transportabilidad, versión informal)***

Dado un diagrama de selección, el efecto $P^*(y \mid \text{do}(x))$ en el dominio destino es **transportable** desde el dominio fuente si existe una fórmula que lo expresa en términos de: **(i)** cantidades estimables con datos experimentales o cuasi-experimentales del dominio fuente Π, y **(ii)** cantidades observacionales del dominio destino Π^* (típicamente, la distribución de las variables marcadas por S).

El marco de los diagramas de selección y el propio término **transportabilidad** provienen de Pearl et al. (2011) el resultado central de (Bareinboim et al. 2013) es un algoritmo **completo** —análogo al cálculo-do del 8— que determina, para cualquier diagrama de selección, si el efecto es transportable y, si lo es, produce la fórmula de transporte explícita. La completitud tiene aquí el mismo valor operativo que allá: si el algoritmo responde que no, ninguna técnica de reponderación, *domain adaptation* o ajuste de covariables recupera el efecto en el destino con esos datos y ese diagrama.

Conviene distinguir dos casos que la literatura nombra de forma distinta y que se confunden con facilidad. La **transportabilidad** pregunta si un efecto estimado en un dominio Π vale en un dominio Π^* **distinto**. La **generalización** (o *external validity* en sentido estricto) pregunta algo más específico: si un efecto estimado sobre una **muestra seleccionada** —los participantes de un ensayo, los clientes que aceptaron una oferta— vale para la población de la que se extrajo, cuando la selección no fue aleatoria. Formalmente es el caso en que el nodo S apunta a un indicador de selección muestral en lugar de a un mecanismo del dominio destino, y el resultado que lo cubre es el teorema de generalización de Pearl et al. (2011). La distinción importa en producción: el 30 vigila deriva entre dominios (transportabilidad), mientras que la ficha de procedencia del 7 documenta el sesgo de selección del que depende la generalización — dos amenazas distintas, con diagnósticos distintos.

Correa et al. (2020) extienden el marco a **intervenciones suaves** (*soft interventions*): acciones que no fijan una variable a un valor constante sino que modifican su mecanismo —

cambiar la regla de asignación de un subsidio en vez de dárselo a todos—, que es la forma que toma la mayoría de las decisiones de política reales y la que el 25 formaliza como decisión estructural. Su resultado, también completo, es el que corresponde invocar cuando la pregunta no es «¿este efecto vale allá?» sino «¿esta **política** vale allá?».

26.2.2 Por qué esto no es lo mismo que «reestimar con más datos»

Vale la pena distinguir la transportabilidad de dos prácticas más simples con las que suele confundirse. No es lo mismo que **agrupar los datos de ambos dominios y reestimar**: si los mecanismos efectivamente difieren, agrupar sin más introduce sesgo, no lo elimina. Tampoco es lo mismo que **reentrenar el modelo con datos del dominio destino**, la opción por defecto en un sistema puramente predictivo (2): reentrenar requiere datos etiquetados del dominio destino, que con frecuencia no existen —es precisamente la situación en la que la teoría de transportabilidad aporta algo que el *machine learning* estándar no ofrece, al permitir, bajo el diagrama correcto, extrapolar sin datos nuevos del destino.

26.3 Marco teórico: transportabilidad causal

La reponderación implementada corresponde al **teorema de transportabilidad** de (Pearl et al. 2011) (Pearl & Bareinboim 2011), que establece condiciones gráficas bajo las cuales un efecto causal estimado en una población puede transportarse a otra.

Para el transporte de **intervenciones suaves** (*soft interventions*, e.g., políticas que modifican distribuciones en lugar de fijar valores), ver (Correa et al. 2020) (Correa & Bareinboim 2020).

Implementación: La fórmula de reponderación es

$$E_{s=1}[Y^1 - Y^0] = E_{s=0}[w(X) \cdot (Y^1 - Y^0)] \tag{26.94}$$

donde $w(X) = P(S = 1|X)/P(S = 0|X)$ son los odds de pertenencia a la población objetivo.

26.4 Algoritmo e implementación

```
import numpy as np
import pandas as pd

def efecto_transportado_por_reponderacion(df_fuente, df_destino, covariable,
tratamiento, resultado):
    """Caso simple y frecuente de transportabilidad: el mecanismo
    Y = f(D, X) es el mismo en ambos dominios, solo difiere P(X).
    La formula de transporte es un ATE reponderado por la densidad
    de la covariable en el dominio destino."""
    efecto_por_estrato = (
        df_fuente.groupby(covariable)
        .apply(lambda g: g.loc[g[tratamiento] == 1, resultado].mean()
                       - g.loc[g[tratamiento] == 0, resultado].mean())
    )
    peso_destino = df_destino[covariable].value_counts(normalize=True)
    comunes = efecto_por_estrato.index.intersection(peso_destino.index)
    efecto_transportado = (efecto_por_estrato[comunes] *
peso_destino[comunes]).sum()
    return efecto_transportado

# Ejemplo: efecto estimado por estrato de experiencia en el dominio fuente,
# reponderado por la distribucion de experiencia del dominio destino
```

Listado 26.1: Chequeo simplificado: ¿el destino difiere solo en la distribución de una covariable?

Conviene ser preciso sobre qué resultado justifica este listado, porque es el caso particular más simple y no el teorema general. La reponderación implementada es válida bajo un diagrama de selección muy específico: el nodo S apunta **solo** a la covariable de estratificación —su distribución difiere entre dominios— y no a ninguna ecuación estructural. Bajo esa condición, el efecto en el destino se obtiene reponderando los efectos condicionales del origen por la distribución de la covariable en el destino,

$$\mathrm{ATE}^{*} = \sum_{x} \mathrm{ATE}(x)\, P^{*}(x), \tag{26.95}$$

que es exactamente el **teorema de generalización** de Pearl et al. (2011). Nótese además el requisito de soporte que el código hace explícito con `comunes`: los estratos presentes en el destino deben estar representados en el origen. Si el destino tiene niveles de la covariable que el origen no observó, no hay efecto condicional que reponderar y el resultado no es transportable por esta vía — el análogo, entre dominios, del supuesto de soporte común dentro de un dominio.

El algoritmo general de (Bareinboim et al. 2013) cubre casos bastante más complejos, donde el mecanismo mismo (no solo la distribución de una covariable) difiere entre dominios, y donde la fórmula de transporte puede combinar cantidades experimentales del origen con cantidades observacionales del destino de formas no reducibles a una reponderación. Esos casos exceden el alcance de este curso, pero conviene saber que existen: la ausencia de una reponderación simple no equivale a la ausencia de transportabilidad.

26.5 Caso empírico

El estimador de retorno a la educación de Card (1995), usado en varios capítulos del curso y publicado como ejemplo en el Capítulo 19, se estimó sobre una población de hombres jóvenes en Estados Unidos en los años setenta. Aplicarlo, sin más, a una población de otro país o de otra década requiere preguntarse explícitamente: ¿el mecanismo por el cual la educación afecta al salario —vía productividad, señalización, redes— es razonablemente estable entre esos dominios, o solo la **distribución** de las covariables difiere? Si lo primero, ninguna fórmula de transporte simple lo resuelve, y el efecto simplemente no es transportable sin supuestos adicionales fuertes; si lo segundo, una reponderación como la del listado Listado 26.1 podría ser defendible.

26.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **Asumir transportabilidad sin diagrama.** La práctica más común en ciencia aplicada —aplicar un modelo entrenado en un contexto a otro sin justificación explícita— es, en el lenguaje de este capítulo, asumir un diagrama de selección vacío (nada difiere) sin argumentarlo.
- **Confundir «no hay evidencia de que difiera» con «no difiere».** La ausencia de un chequeo de transportabilidad no es evidencia de que el efecto transporte; es, simplemente, ausencia de análisis.
- **Sobreextender la fórmula de transporte a mecanismos que sí cambiaron.** Incluso cuando existe una fórmula de transporte válida para las diferencias declaradas en el diagrama de selección, cualquier diferencia de mecanismo no anticipada en el diagrama invalida la fórmula.

26.7 Ejercicios y notas bibliográficas

26.7.1 Ejercicios teóricos

1. Para el ejemplo de la 26.2 (población urbana a rural), dibuje el diagrama de selección descrito y explique, en sus propias palabras, qué se necesitaría medir en el dominio rural para aplicar la fórmula de transporte.
2. Explique por qué «reentrenar el modelo con datos del dominio destino» no es una opción disponible en muchos de los casos de uso reales que motivan la teoría de transportabilidad.

26.7.2 Ejercicio computacional

1. Simule dos dominios con la misma ecuación estructural $Y = 0.4D + 0.5X + \varepsilon$ pero distinta distribución de X (por ejemplo, $X \sim N(0, 1)$ en el dominio fuente y $X \sim N(1, 1.5)$

en el destino). Use el listado Listado 26.1 para transportar el efecto y compare contra el efecto verdadero simulado en el dominio destino.

26.7.3 Notas bibliográficas

Pearl et al. (2011) introducen los diagramas de selección y el teorema de generalización que justifica la reponderación del listado Listado 26.1; Bareinboim et al. (2013) establecen el algoritmo de decisión completo para transportabilidad, y Correa et al. (2020) lo extienden a intervenciones suaves —el caso relevante cuando lo que se quiere transportar es una política y no un efecto puntual—. Bareinboim (2025) presenta los tres de forma integrada con el resto de la Jerarquía Causal de Pearl en sus capítulos sobre generalización. La noción informal de validez externa en econometría aplicada, con la que conviene contrastar este tratamiento formal, se discute en (Imbens et al. 2015). Sobre la relación con el reentrenamiento en un sistema en producción, véanse el 31 (cuándo actualizar) y el 30 (cómo detectar que el dominio cambió).

Parte VIII

Métodos avanzados

Esta parte cubre métodos de mayor capacidad y de naturaleza distinta a los anteriores: arquitecturas de deep learning causal con balance de representación, y control sintético con matrix completion para el caso de una sola unidad tratada observada en el tiempo.

Capítulo 27

Deep learning para inferencia causal

Cuadro sinóptico del capítulo

Problema:	Estimar CATE con no linealidades complejas usando redes neuronales
Estimando:	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$
Identificación:	No confusión, soporte común, SUTVA
Método:	TARNet, CFRNet (IPM), DeepIV
Nuisance:	$\mu_1(x), \mu_0(x), \Phi(x)$
Garantía:	Bound de error bajo no confusión y representación balanceada
Librerías:	PyTorch, econml
Validación:	Balance de representación, MMD, comparación con meta-learners

Nota técnica

Con la Parte VI completa —el curso ya cubrió estimación, decisión, equidad y generalización con los métodos «estándar» de ML causal— esta Parte VII reúne dos familias de métodos más especializados. Este capítulo extiende los meta-learners y bosques causales (Capítulos 12–13) con arquitecturas de *deep learning* diseñadas específicamente para balancear representaciones entre grupos de tratamiento.

27.1 Motivación aplicada

Una plataforma de salud digital desea estimar el efecto de un programa de recordatorios personalizados sobre la adherencia a medicamentos. Cada usuario tiene cientos de características (historial médico, comportamiento en la app, demografía). El efecto del tratamiento es altamente no lineal: para algunos subgrupos el recordatorio es muy efectivo, para otros es nulo. Los métodos basados en árboles (Causal Forest) pueden no capturar la estructura compleja; una red neuronal podría.

El *deep causal learning* aplica redes neuronales al problema de estimación causal. La innovación central, introducida por (Shalit et al. 2017) con TARNet y CFRNet, es aprender una *representación balanceada* $\Phi(X)$ tal que las distribuciones de $\Phi(X)$ para tratados y controles sean similares, permitiendo estimar $\mu_0(\Phi(X))$ y $\mu_1(\Phi(X))$ con la misma red.

Este capítulo desarrolla TARNet y CFRNet con implementación nativa en PyTorch, presenta DeepIV (Hartford et al. 2017) para variables instrumentales, y discute las extensiones modernas (CEVAE, contrastive balance).

27.2 Teoría, supuestos y garantías

27.2.1 TARNet: representación compartida

TARNet (*Treatment-Agnostic Representation Network*) tiene arquitectura:

1. **Capa de representación** $\Phi : R^p \to R^k$ que mapea covariables a un embedding.
2. **Cabezas de outcome** $h_0, h_1 : R^k \to R$ separadas para tratados y controles.

La predicción es $\hat{\mu}_d(x) = h_{d(\Phi(x))}$. El CATE estimado es $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$.

La *loss* es el error cuadrático medio:

$$\mathcal{L}_{\text{TARNet}} = \left(\frac{1}{n}\right) \sum_i \left(Y_i - h_{D_i}(\Phi(X_i))\right)^2. \tag{27.96}$$

27.2.2 CFRNet: balance integral probability metric

CFRNet (*Counterfactual Regression with IPM*) añade a TARNet una penalización de *Integral Probability Metric* (IPM) que fuerza el balance entre las distribuciones de $\Phi(X)$ para tratados y controles:

$$\mathcal{L}_{\text{CFRNet}} = \mathcal{L}_{\text{TARNet}} + \alpha \cdot \text{IPM}(\Phi(X \mid D = 0), \Phi(X \mid D = 1)). \tag{27.97}$$

Aquí α es el peso de la penalización IPM, no el nivel de significación.

El IPM puede ser la distancia Wasserstein, la divergencia MMD, o la *adversarial loss* (como en DOMAIN-ADVERSARIAL neural networks).

Teorema 27.1 ***(Shalit, Johansson & Sontag, 2017)***

Bajo no confusión, soporte común, y regularidad estándar, el estimador CFRNet satisface un *bound* de error esperado en τ que se descompone en: (i) error de estimación, (ii) complejidad de la clase de funciones, (iii) IPM entre las distribuciones de $\Phi(X)$ para tratados y controles.

27.2.3 DeepIV

Para casos con variable instrumental, (Hartford et al. 2017) proponen DeepIV: una red neuronal que modela la distribución del tratamiento dado el instrumento y covariables, y luego estima el structural function. La arquitectura es:

1. **Red de tratamiento** $g(z, x)$ que modela la densidad $p(D \mid Z, X)$.
2. **Red estructural** $h(d, x)$ que estima $E[Y \mid D, X]$.

La loss combina la verosimilitud del tratamiento y el error del outcome.

Algoritmo

Entrada: Datos $(X_i, D_i, Y_i)_{i=1}^n$, red de representación Φ con cabezas h_0, h_1, épocas E, tasa de aprendizaje η, peso IPM $\alpha \geq 0$
Salida: Estimación del CATE $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$
for `epoch` $= 1$ **to** `E` **do**

Calcular representación $\Phi_i = \Phi(X_i)$ para todo i
Predecir $\hat{Y}_i = h_{D_i}(\Phi_i)$
$\mathcal{L}_{\text{MSE}} \leftarrow \left(\frac{1}{n}\right) \sum_{i=1}^n \left(Y_i - \hat{Y}_i\right)^2$
if CFRNet **then**
IPM $\leftarrow$ MMD$(\{\Phi_i : D_i = 0\}, \{\Phi_i : D_i = 1\})$
$\mathcal{L} \leftarrow \mathcal{L}_{\text{MSE}} + \alpha \cdot \text{IPM}$
else
$\mathcal{L} \leftarrow \mathcal{L}_{\text{MSE}}$
end if
Actualizar parámetros con $\nabla \mathcal{L}$ vía Adam(η)

end for
return $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$

Algoritmo 11.: Entrenamiento TARNet/CFRNet

27.3 Algoritmo de entrenamiento TARNet/CFRNet

El siguiente pseudocódigo describe el procedimiento de entrenamiento de TARNet y su extensión CFRNet. La diferencia clave es la penalización IPM que fuerza el balance de la representación latente $\Phi(X)$ entre grupos de tratamiento y control.

27.4 Implementación en Python

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
from torch.utils.data import DataLoader, TensorDataset

class TARNet(nn.Module):
    def __init__(self, in_dim, rep_dim=64, hidden=128):
        super().__init__()
        # Representacion compartida
        self.rep = nn.Sequential(
            nn.Linear(in_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, rep_dim),
        )
        # Cabezas separadas para D=0 y D=1
        self.h0 = nn.Sequential(
            nn.Linear(rep_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, 1),
        )
        self.h1 = nn.Sequential(
            nn.Linear(rep_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, 1),
        )
    def forward(self, X, D):
        Phi = self.rep(X)
        out = torch.where(D.unsqueeze(-1) == 1, self.h1(Phi), self.h0(Phi))
        return out.squeeze(-1)
    def predict_cate(self, X):
        Phi = self.rep(X)
        return (self.h1(Phi) - self.h0(Phi)).squeeze()

# DGP
def make_dgp(n=3000, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 10))
    e = 1/(1 + np.exp(-1.0 - 0.5*X[:, 0]))
    D = (rng.uniform(size=n) < e).astype(np.float32)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2
    mu0 = np.sin(X[:, 2]) + X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n) * 0.5
    return X.astype(np.float32), D.astype(np.float32), Y.astype(np.float32),
tau

X, D, Y, tau_true = make_dgp(3000, seed=42)
X_t = torch.from_numpy(X); D_t = torch.from_numpy(D); Y_t = torch.from_numpy(Y)

# Entrenamiento
torch.manual_seed(42)
model = TARNet(in_dim=X.shape[1])
opt = optim.Adam(model.parameters(), lr=1e-3, weight_decay=1e-4)
for epoch in range(200):
    model.train()
    opt.zero_grad()
    pred = model(X_t, D_t)
    loss = ((pred - Y_t)**2).mean()
```

Listado 27.1: Implementacion de TARNet en PyTorch.

27.4.1 CFRNet con penalización MMD

```
def mmd_loss(Phi0, Phi1, sigma=1.0):
    """Maximum Mean Discrepancy entre representaciones de tratados y
controles."""
    def kernel(A, B):
        # RBF kernel
        diff = A.unsqueeze(1) - B.unsqueeze(0)
        return torch.exp(-diff.pow(2).sum(-1) / (2 * sigma**2))
    K00 = kernel(Phi0, Phi0); K11 = kernel(Phi1, Phi1); K01 = kernel(Phi0,
Phi1)
    return K00.mean() + K11.mean() - 2 * K01.mean()

class CFRNet(TARNet):
    def forward_loss(self, X, D, Y, alpha=1.0):
        Phi = self.rep(X)
        pred = torch.where(D.unsqueeze(-1) == 1, self.h1(Phi),
self.h0(Phi)).squeeze(-1)
        mse = ((pred - Y)**2).mean()
        Phi0 = Phi[D == 0]; Phi1 = Phi[D == 1]
        if len(Phi0) > 1 and len(Phi1) > 1:
            mmd = mmd_loss(Phi0, Phi1)
        else:
            mmd = torch.tensor(0.0)
        return mse + alpha * mmd

# Entrenamiento CFRNet
model_cfr = CFRNet(in_dim=X.shape[1])
opt = optim.Adam(model_cfr.parameters(), lr=1e-3, weight_decay=1e-4)
for epoch in range(200):
    model_cfr.train(); opt.zero_grad()
    loss = model_cfr.forward_loss(X_t, D_t, Y_t, alpha=1.0)
    loss.backward(); opt.step()
    if epoch % 50 == 0:
        print(f"Epoch {epoch}: loss={loss.item():.4f}")

model_cfr.eval()
with torch.no_grad():
    cate_cfr = model_cfr.predict_cate(X_t).numpy()
print(f"CFRNet RMSE: {np.sqrt(np.mean((cate_cfr - tau_true)**2)):.4f}")
```

Listado 27.2: CFRNet con penalización MMD.

27.5 Arquitectura de TARNet/CFRNet

La figura Figura 27.1 muestra la arquitectura común de TARNet y CFRNet. Una red de representación compartida $\Phi(X)$ mapea las covariables a un embedding de menor dimensión; dos cabezas separadas h_0, h_1 estiman $\mu_0(\Phi(X))$ y $\mu_1(\Phi(X))$ respectivamente. El CATE se

obtiene por diferencia: $\hat{\tau}(X) = h_1(\Phi(X)) - h_0(\Phi(X))$. CFRNet añade a TARNet una penalización IPM (Integral Probability Metric) que fuerza el balance entre las distribuciones de $\Phi(X)$ para tratados y controles, reduciendo el desbalance observado de covariables en el espacio de representación, bajo el supuesto previo de no confusión.

Cap. 13 — Arquitectura TARNet / CFRNet (Shalit, Johansson & Sontag, 2017)

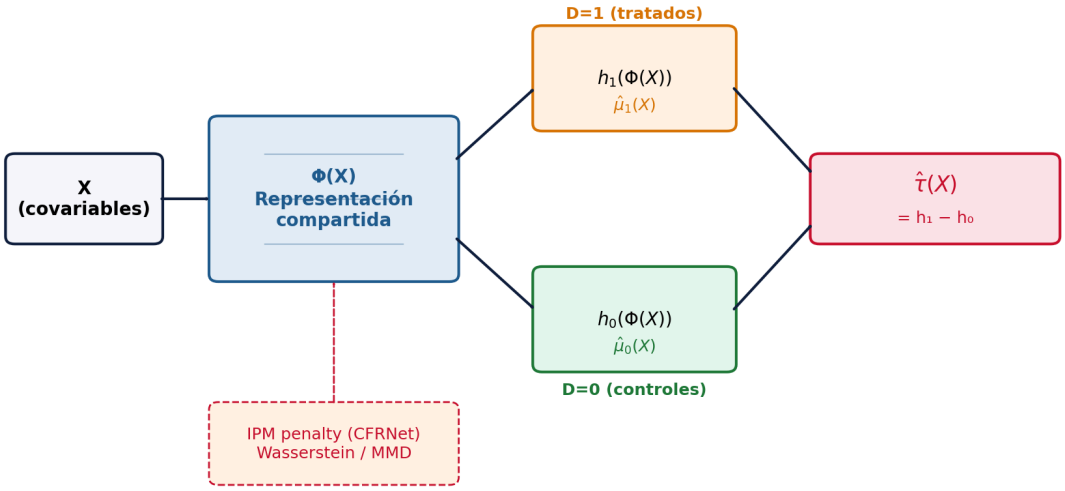


Figura 27.1: Arquitectura de TARNet / CFRNet (Shalit, Johansson & Sontag, 2017). La capa de representación compartida Φ es seguida por dos cabezas separadas h_0, h_1 para $D = 0$ y $D = 1$. CFRNet añade una penalización IPM (Wasserstein o MMD) que fuerza el balance entre las distribuciones de $\Phi(X)$ condicionales al tratamiento.

27.6 Caso empírico y validación

Sobre el dataset sintético con no linealidades, TARNet y CFRNet producen un RMSE en CATE competitivo con X-learner y T-learner (con GBM). La ventaja de los métodos deep es mayor cuando el DGP tiene no linealidades complejas o interacciones de alto orden; para DGPs simples o con muestras pequeñas ($n < 1,000$), los métodos basados en árboles son competitivos y más rápidos de entrenar.

Intuición

Caja de profundización 13.1: Representaciones balanceadas y diagnóstico de balance

Objetivo. Entender por qué TARNet/CFRNet aprenden una representación intermedia y cómo verificar si está bien balanceada.

La idea. En lugar de estimar $\mu_1(X)$ y $\mu_0(X)$ directamente sobre las covariables originales, la red primero aprende una «representación» compacta $\Phi(X)$. Luego estima los outcomes a partir de esa representación.

¿Por qué balancear? Si la distribución de $\Phi(X)$ es similar entre tratados y controles, cualquier diferencia en outcomes se debe más probablemente al tratamiento y no a confusores observados. CFRNet agrega una penalización que fuerza este balance.

Cómo diagnosticar el balance. Una vez entrenada la red, podemos calcular:

- Diferencia de medias de $\Phi(X)$ entre tratados y controles (debe ser cercana a cero).
- MMD (Maximum Mean Discrepancy): distancia entre las dos distribuciones.
- Si el MMD es grande, la red no está balanceando bien y podemos aumentar el peso de la penalización.

Advertencia importante. El balance de $\Phi(X)$ NO garantiza identificación causal. Si hay confusores no observados que no están en X, ninguna red puede solucionarlo.

27.7 Límites y errores comunes

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Balance sin identificación	Falsa seguridad: balancear $\Phi(X)$ no crea el supuesto de no confusión	DAG y supuestos declarados; el balance es sobre covariables **observadas**	No confusión explícita y justificada; ningún ajuste arquitectónico la sustituye
Overfitting profundo	Mala generalización	Train/test loss	Regularización, *early stopping*, validación
α (peso IPM) fijado sin validar	Representación sobre-balanceada y poco informativa; error en τ mayor que sin penalización (Curth et al. 2021)	Barrido de α incluyendo $\alpha = 0$ (TARNet) y comparación de RMSE en τ sobre un DGP con *ground truth*	Tratar α como hiperparámetro a validar y reportar su valor; no asumir que CFRNet domina a TARNet
Reportar $\hat{\tau}(x)$ sin cuantificar incertidumbre	Decisiones individuales basadas en un punto sin intervalo	Verificar si el pipeline produce algún IC	Usar la red como *nuisance* dentro de DML (27.8.1), o *bootstrap* asumiendo su costo; para decisiones individuales, intervalos conformes (14.2.8)

Tabla 27.1: Riesgos comunes en deep causal learning

Deep causal requiere muestras grandes ($n > 5,000$) y ajuste cuidadoso de hiperparámetros. Para muestras pequeñas, los métodos basados en árboles son preferibles. Dos límites merecen un tratamiento más detenido, porque la literatura reciente los ha precisado y en ambos casos la lectura ingenua del método es la equivocada.

27.7.1 ¿Balancear la representación ayuda realmente?

La penalización IPM de CFRNet se presenta habitualmente como una mejora inequívoca sobre TARNet, y la ecuación Ecuación (27.97) lo sugiere: forzar $\Phi(X \mid D = 0)$ y $\Phi(X \mid D = 1)$ a parecerse debería reducir el término de discrepancia del *bound* de Shalit et al. (2017). Curth et al. (2021) muestran que el argumento es más frágil de lo que parece, y por una razón instructiva: la cota que justifica la penalización es **laxa**, y minimizarla no equivale a minimizar el error en τ.

El mecanismo del problema es directo. El balance es una restricción sobre la representación compartida; hacerla más fuerte reduce la información sobre X que Φ conserva, y parte de esa información puede ser necesaria para estimar bien μ_0 y μ_1. Con α grande, la red aprende una representación tan balanceada como poco informativa —en el extremo, Φ constante logra balance perfecto y error máximo—. Empíricamente, el α óptimo depende del DGP y con frecuencia es cercano a cero; TARNet sin penalización es un competidor serio, no un *baseline* trivial.

La lección que Curth y van der Schaar extraen, y que este capítulo adopta, es que lo determinante no es la penalización IPM sino los **sesgos inductivos** de la arquitectura: cómo se comparte información entre las dos cabezas, si se modela τ directamente o por diferencia, si se usa el *propensity* como entrada. Operativamente: α debe tratarse como un hiperparámetro a validar, no como un interruptor que se activa porque «balancear es bueno», y su valor óptimo debe reportarse.

27.8 Inferencia válida con redes neuronales profundas

La inferencia estadística válida (construcción de intervalos de confianza, tests) con DNNs para estimación causal se ha resuelto recientemente mediante dos enfoques:

1. **Representers de Riesz** ((Chernozhukov et al. 2022), Chernozhukov et al. 2022): RieszNet aprende una representación dual que permite inferencia asintótica válida para funcionales de Riesz en modelos semiparámétricos.
2. **Estimación semiparámetrica eficiente con DNNs** ((Farrell et al. 2021), Farrell et al. 2021): demuestran que las DNNs pueden alcanzar el bound de varianza de Cramér-Rao en modelos semiparétricos bajo condiciones de regularidad.

Limitaciones de representaciones balanceadas: (Curth et al. 2021) (Curth & van der Schaar 2021) muestran que las arquitecturas con representación compartida $\Phi(X)$ para μ_0 y μ_1 introducen sesgos inductivos que pueden ser subóptimos para HTE estimation cuando los outcomes potenciales tienen estructuras heterogéneas.

27.8.1 Detalles técnicos

Es cierto que TARNet y CFRNet, tal como se han presentado, no producen intervalos de confianza: se optimiza una pérdida predictiva y no hay ninguna garantía distribucional sobre $\hat{\tau}(x)$. Pero sería inexacto concluir que la inferencia con redes neuronales sea un problema sin tratamiento teórico. Dos líneas de trabajo lo abordan directamente y conviene conocerlas.

Farrell et al. (2021) establecen tasas de convergencia no asintóticas para redes profundas con activaciones ReLU y, sobre esa base, demuestran normalidad asintótica e inferencia válida para funcionales semiparamétricos —incluido el ATE— estimados con redes como *nuisance*. El resultado es exactamente la pieza que faltaba: muestra que las redes satisfacen la condición de tasa $\sqrt{n}a_n^2 \to 0$ del 10 bajo condiciones explícitas sobre profundidad, anchura y suavidad de la función objetivo. La consecuencia práctica es que **usar una red como `model_y` o `model_t` dentro de DML es teóricamente respaldado**, y probablemente la forma más sensata de combinar *deep learning* e inferencia causal en producción hoy.

La segunda línea automatiza el paso de ortogonalización. Chernozhukov et al. (2022) observan que el término de corrección de un score ortogonal es siempre un **representador de Riesz** del funcional de interés, y proponen aprenderlo directamente con una red (RieszNet) o un bosque (ForestRiesz), en lugar de derivarlo a mano para cada estimando. Esto convierte la construcción del score —que en los Capítulos 10 y 11 se hizo analíticamente para PLR e IRM— en un problema de aprendizaje, y extiende DML a funcionales para los que nadie ha derivado la fórmula.

La conclusión operativa para este capítulo es una inversión de la práctica habitual: en vez de usar una red para estimar τ directamente y luego buscar cómo hacer inferencia sobre ella, conviene usar la red donde su capacidad de aproximación aporta —los *nuisance* de alta dimensión— y dejar la inferencia al aparato ortogonal que ya la tiene resuelta. El *bootstrap* sobre TARNet/CFRNet sigue siendo una opción práctica para cuantificar incertidumbre, pero es costoso y sus garantías bajo regularización y optimización no convexa son mucho menos claras.

27.9 Ejercicios propuestos

1. Replique el listado Listado 27.1 variando la profundidad de la red (1, 2, 3 capas ocultas). ¿Cuándo aparece overfitting?
2. Implemente CFRNet con penalización Wasserstein en lugar de MMD (usar `geomloss` o `POT`).
3. Compare TARNet, CFRNet y Causal Forest sobre un DGP con no linealidades crecientes. ¿En qué punto el deep causal supera a los árboles?
4. Barra el peso de la penalización IPM en $\alpha \in \{0, 0.1, 1, 10, 100\}$ y grafique el RMSE en τ contra el MMD de la representación. Verifique que el α que minimiza el MMD **no** es el que minimiza el RMSE, y relacione el resultado con la 27.7.1.
5. Use la red TARNet (sin las cabezas causales: solo la representación más una cabeza) como `model_y` y `model_t` dentro de `LinearDML`, y compare el ATE con IC obtenido así

frente al ATE que produce TARNet directamente por promedio de $\hat{\tau}(x)$. ¿Cuál de los dos permite reportar un intervalo con respaldo teórico, y por qué (27.8.1)?

6. Implemente DeepIV sobre el dataset `iv_noncompliance` (sintético) y verifique que recupera el «LATE».

27.10 Lecturas complementarias

Shalit et al. (2017) es la referencia fundacional de TARNet/CFRNet y del *bound* de error con IPM. Hartford et al. (2017) introduce DeepIV. Louizos et al. (2017) propone CEVAE. Shi et al. (2019) extiende a DragonNet, que incorpora el *propensity* como cabeza adicional y aplica una corrección dirigida al estimando.

Tres lecturas son indispensables para no quedarse en el estado del arte de 2017. Curth et al. (2021) revisan críticamente la familia completa desde el ángulo de los sesgos inductivos y son la fuente del análisis de la 27.7.1 sobre los límites de la representación balanceada; su comparación empírica sistemática es también el mejor punto de partida para elegir arquitectura. Farrell et al. (2021) establecen las tasas y la teoría de inferencia que hacen de las redes profundas un *nuisance learner* legítimo dentro de DML. Chernozhukov et al. (2022) proponen aprender el representador de Riesz —y con él, el score ortogonal— en lugar de derivarlo analíticamente, extendiendo el aparato de la Parte II a funcionales arbitrarios.

Capítulo 28

Control sintético y matrix completion

Cuadro sinóptico del capítulo

Problema:	Estimar efecto causal en panel con una unidad tratada
Estimando:	«ATT» por período post-tratamiento τ_t
Identificación:	Combinación convexa (SCM), low-rank + incoherence (MC)
Método:	Synthetic Control (SCM), Matrix Completion (MC)
Nuisance:	Pesos w_j (SCM), matriz L (MC)
Garantía:	Fit pre-tratamiento exacto (SCM), $O_{p(\sqrt{r(N+T)/\lvert\mathcal{O}\rvert})}$ (MC)
Librerías:	scipy.optimize, numpy
Validación:	Placebos espaciales y temporales, gráfico pre-tratamiento

Nota técnica

Los capítulos anteriores de esta parte estiman efectos a nivel de unidad individual; este cierra la Parte VII con el caso de una sola unidad tratada observada en el tiempo (control sintético), reutilizando el lenguaje de SCM del 3 en su acepción original de la literatura de evaluación de políticas macro, distinta pero complementaria a la de Bareinboim usada en la primera mitad del curso.

28.1 Motivación aplicada

Una economista del Banco Central debe estimar el efecto de una reforma tributaria implementada en una región específica sobre la recaudación. No hay región de control perfecta: todas las regiones tienen trayectorias distintas. El *synthetic control method* (SCM) clásico de (Abadie et al. 2003) construye un «control sintético» ponderando regiones no tratadas para reproducir la trayectoria pre-tratamiento de la región tratada.

Pero SCM clásico tiene limitaciones: requiere *fit* pre-tratamiento perfecto, no maneja múltiples unidades tratadas con staggered adoption, y no produce IC fácilmente. Athey et al. (2021b) proponen *matrix completion* como alternativa: modelar la matriz de outcomes $Y \in R^{N \times T}$ como una matriz de bajo rango con ruido, donde las entradas post-tratamiento son «missing» y se imputan.

Este capítulo desarrolla ambos métodos, los compara, y aplica al dataset `texas` (efecto de una ley de aborto sobre mortalidad materna) y al sintético `scm_placebo`.

28.2 Teoría, supuestos y garantías

28.2.1 SCM clásico

Para una unidad tratada $i = 1$ y controles $i = 2, ..., N + 1$ observadas en $t = 1, ..., T$ con tratamiento en $t = T_0 + 1, ..., T$ para la unidad 1, SCM busca pesos $\boldsymbol{w} = (w_2, ..., w_{N+1})$ con $w_j \geq 0$ y $\sum_j w_j = 1$ que minimicen:

$$\sum_{t=1}^{T_0} \left(Y_{1t} - \sum_{j=2}^{N+1} w_j Y_{jt} \right)^2. \tag{28.98}$$

El estimador del efecto es $\hat{\tau}_t = Y_{1t} - \sum_j \hat{w}_j Y_{jt}$ para $t > T_0$.

28.2.2 Matrix completion

Athey et al. (2021b) reinterpretan el problema como imputación de matriz. Sea $Y \in R^{N \times T}$ la matriz de outcomes, donde las entradas post-tratamiento para unidades tratadas son conceptualmente «missing» (porque no observamos el counterfactual). El modelo es:

$$Y = L + \varepsilon, \tag{28.99}$$

donde L es una matriz de bajo rango ($\text{rank}(L) \leq r \ll \min(N, T)$) y ε es ruido. Se estima $\hat{L}$ minimizando:

$$\hat{L} = \text{argmin}_{L:\ \text{rank}(L) \leq r} \sum_{(i,t) \in \mathcal{O}} (Y_{it} - L_{it})^2, \tag{28.100}$$

donde $\mathcal{O}$ es el conjunto de entradas observadas (pre-tratamiento + unidades no tratadas).

El problema anterior, con la restricción de rango explícita, es no convexo y computacionalmente intratable. La solución estándar es **relajarlo** sustituyendo el rango por la norma nuclear:

$$\hat{L} = \text{argmin}_L \left\{ \sum_{(i,t) \in \mathcal{O}} (Y_{it} - L_{it})^2 + \lambda \|L\|_* \right\}, \tag{28.101}$$

donde $\|L\|_* = \sum_i \sigma_i(L)$ es la suma de los valores singulares. La justificación de esta sustitución es la misma que la del LASSO en el 6, un piso más arriba: así como la norma ℓ_1 es la envolvente convexa de la norma ℓ_0 (número de coeficientes no nulos) y por eso induce esparsidad, la norma nuclear es la envolvente convexa del rango sobre la bola espectral y por eso induce soluciones de rango bajo. Recht et al. (2010) establecen las condiciones —análogas a la *restricted isometry* del caso esparso— bajo las cuales la relajación convexa recupera exactamente la solución del problema de rango mínimo original. El paralelo es útil también para las advertencias: igual que el LASSO contrae los coeficientes que selecciona, la norma nuclear contrae los valores

singulares que retiene, lo que sesga $\hat{L}$ hacia cero y por tanto sesga el efecto estimado —razón adicional para no fiar la elección de λ al ojo.

Teorema 28.1 ***(Athey et al., 2021)***

Bajo condiciones regulares (low-rank, incoherence), $\hat{L}$ estima L con error $O_{p}\left(\sqrt{r(N+T)/|\mathcal{O}|}\right)$.

28.2.3 Elegir r o λ: el hiperparámetro que fija el contrafactual

La cota anterior es informativa sobre cómo escala el error con el rango r, pero deja abierta la pregunta operativa: ¿qué valor usar? Es la decisión más consecuente del método, y conviene no tratarla como un detalle de implementación, porque el hiperparámetro determina literalmente el contrafactual estimado. Con λ muy alto (r efectivo bajo) el modelo es rígido y no reproduce la trayectoria pre-tratamiento —el sesgo aparece como un mal ajuste visible—. Con λ muy bajo (r efectivo alto), el modelo tiene grados de libertad suficientes para ajustar el ruido pre-tratamiento y, al extrapolar al periodo post, el «efecto» estimado puede ser en buena parte ese sobreajuste proyectado.

El procedimiento estándar, y el que este curso recomienda, es **validación cruzada sobre celdas observadas**: enmascarar artificialmente un subconjunto de entradas que sí se observan (típicamente los últimos periodos pre-tratamiento de las unidades de control), imputarlas con cada valor candidato de λ, y elegir el que minimiza el error de imputación fuera de muestra. La clave del diseño es que el patrón de enmascaramiento **imite la estructura del faltante real** —bloques de periodos finales, no celdas dispersas al azar—, porque el problema real es de extrapolación temporal y no de imputación aleatoria; validar con celdas dispersas produce sistemáticamente un λ demasiado bajo.

Dos diagnósticos complementarios deben acompañar a la elección. Primero, reportar la **curva de efecto estimado frente a λ**, con la misma lectura que en el 16: una meseta indica robustez, una pendiente pronunciada indica que el resultado es función del hiperparámetro. Segundo, y más informativo, verificar el **ajuste pre-tratamiento** del λ elegido: si el error de imputación pre-tratamiento es comparable a la magnitud del efecto post-tratamiento estimado, no hay señal que distinguir del ruido, por bueno que sea el valor de validación cruzada.

28.2.4 Comparación SCM vs. matrix completion

Dimensión	SCM clásico	Matrix completion
Múltiples tratadas	Difícil	Natural
Staggered adoption	Difícil	Natural
Fit pre-tratamiento	Exigido	Flexible
IC	Placebos	Bootstrap
Supuesto estructural	Convex combination	Low-rank

Tabla 28.1: SCM clásico vs. matrix completion

Algoritmo

Entrada: Outcome pre-tratamiento de la unidad tratada $\boldsymbol{Y}_{1,\text{ pre}} \in R^{T_0}$; matriz de donantes pre-tratamiento $\boldsymbol{Y}_{0,\text{ pre}} \in R^{T_0 \times N}$; matriz de donantes post-tratamiento $\boldsymbol{Y}_{0,\text{ post}} \in R^{(T-T_0)\times N}$; outcome observado post-tratamiento de la unidad tratada $\boldsymbol{Y}_{1,\text{ post}} \in R^{T-T_0}$.
Salida: Pesos $\hat{\boldsymbol{w}} \in R^N$; contrafactual sintético $\hat{\boldsymbol{Y}}_{1,\text{ post}} \in R^{T-T_0}$; efecto estimado $\hat{\boldsymbol{\tau}} \in R^{T-T_0}$.
Resolver el problema de optimización restringida:
$\hat{\boldsymbol{w}} = \text{argmin}_{\boldsymbol{w}} \left\| \boldsymbol{Y}_{1,\text{ pre}} - \boldsymbol{Y}_{0,\text{ pre}} \boldsymbol{w} \right\|^2$
sujeto a $w_j \geq 0$ para todo j y $\sum_{j=1}^{N} w_j = 1$
Calcular el contrafactual sintético en el período post-tratamiento:
$\hat{\boldsymbol{Y}}_{1,\text{ post}} = \boldsymbol{Y}_{0,\text{ post}} \hat{\boldsymbol{w}}$
Estimar el efecto causal para cada período post-tratamiento:
$\hat{\tau}_t = Y_{1t} - \hat{Y}_{1,\text{ post},t}, \quad t = T_0 + 1, ..., T$
return $\hat{\boldsymbol{w}}, \hat{\boldsymbol{Y}}_{1,\text{ post}}, \hat{\boldsymbol{\tau}}$

Algoritmo 12.: Synthetic control clásico

28.2.5 Inferencia en synthetic control

La inferencia en synthetic control se formaliza mediante **placebos en espacio** ((Abadie et al. 2015), Abadie et al. 2015): se estima un SCM para cada unidad de control como si fuera tratada, generando una distribución empírica de efectos placebo contra la cual se compara el efecto observado.

Métodos alternativos:

- **Balancing weights** ((Doudchenko et al. 2016), Doudchenko & Imbens 2016): relajación convexa de SCM que permite ponderaciones negativas controladas
- **Augmented synthetic control** ((Ben-Michael et al. 2021), Ben-Michael et al. 2021): combina SCM con regresión ridge para mejorar balance y reducir sesgo

Selección de hiperparámetros: En matrix completion, el rango r o parámetro de regularización λ se seleccionan por validación cruzada temporal (ver §28.4).

28.3 Algoritmo e implementación

28.3.1 Algoritmo: Synthetic control clásico

El algoritmo siguiente formaliza el procedimiento de estimación por control sintético para una unidad tratada y un panel de donantes.

28.3.2 SCM clásico sobre Texas

```
import pandas as pd
import numpy as np
from scipy.optimize import minimize

df = pd.read_csv("../data/datasets/real/public_causaldata/texas/data.csv")
print(df.columns.tolist()[:15])
# Identificar columnas: unidad, tiempo, tratamiento, outcome
# Texas tiene una columna "treat" indicando adopcion de ley
# Para SCM clasico: usar otras unidades como donantes

# Implementacion simplificada de SCM
def synthetic_control(Y_treated_pre, Y_donors_pre, Y_donors_post):
    """Encuentra pesos w que minimizan ||Y_treated_pre - Y_donors_pre @ w||
^2."""
    N = Y_donors_pre.shape[1]
    # Restricciones: w >= 0, sum(w) = 1
    constraints = [{"type": "eq", "fun": lambda w: np.sum(w) - 1}]
    bounds = [(0, 1)] * N
    w0 = np.ones(N) / N
    obj = lambda w: np.sum((Y_treated_pre - Y_donors_pre @ w)**2)
    res = minimize(obj, w0, method="SLSQP", bounds=bounds,
constraints=constraints)
    w = res.x
    Y_synth_post = Y_donors_post @ w
    return w, Y_synth_post

# Aplicar (formato depende del dataset exacto)
# Aqui se muestra el esqueleto; adaptar columnas segun dataset real
```

Listado 28.1: SCM clásico sobre dataset Texas.

28.3.3 Matrix completion

```
import numpy as np
from scipy.linalg import svd

def matrix_completion(Y, mask, lam=1.0, n_iter=100, tol=1e-4):
    """Imputa entradas faltantes de Y usando nuclear-norm regularization.
    mask[i,j] = 1 si (i,j) observado, 0 si faltante.
    """
    Y_obs = Y * mask
    M = Y_obs.copy()
    for it in range(n_iter):
        # SVD soft-thresholding
        U, s, Vt = svd(M, full_matrices=False)
        s_thresh = np.maximum(s - lam, 0)
        M_new = (U * s_thresh) @ Vt
        # Mantener entradas observadas
        M_new = Y_obs * mask + M_new * (1 - mask)
        if np.linalg.norm(M_new - M) < tol:
            break
        M = M_new
    return M

# Ejemplo sintetico
rng = np.random.default_rng(42)
N, T, r = 30, 20, 3
L_true = rng.standard_normal((N, r)) @ rng.standard_normal((r, T))
Y = L_true + 0.5 * rng.standard_normal((N, T))
# Enmascarar post-tratamiento de unidades tratadas
mask = np.ones((N, T))
treated_units = [0, 5, 10]
T0 = 10
for i in treated_units:
    mask[i, T0:] = 0

L_hat = matrix_completion(Y, mask, lam=2.0)
# Efecto estimado para unidades tratadas
effect = (Y - L_hat)[treated_units, T0:].mean()
print(f"Efecto estimado (matrix completion): {effect:.4f}")
```

Listado 28.2: Matrix completion con nuclear norm.

28.4 Caso empírico y validación

La figura Figura 28.1 ilustra el ajuste pre/post-tratamiento con SCM clásico y matrix completion, sobre un panel sintético con efecto verdadero conocido ($\tau = 2.5$). El panel izquierdo muestra que ambos métodos reproducen razonablemente la trayectoria pre-tratamiento de la

unidad tratada; el panel derecho muestra el efecto estimado en el periodo post-tratamiento, comparado con un placebo espacial (aplicar SCM a una unidad no tratada).

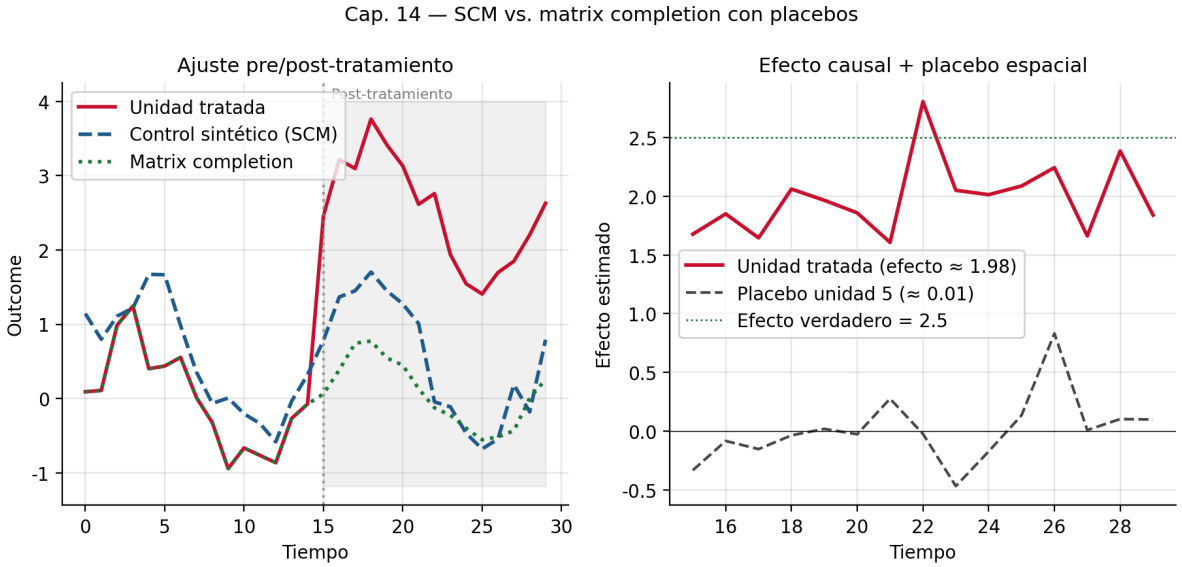


Figura 28.1: Izquierda: trayectoria de la unidad tratada vs. control sintético (SCM) y matrix completion (MC), con periodo pre-tratamiento $T_0 = 15$. Derecha: efecto estimado post-tratamiento para la unidad tratada (efecto verdadero = 2.5) y para un placebo espacial (unidad no tratada, debe ser ≈ 0). Panel sintético $N = 20$, $T = 30$.

Interpretación. El SCM clásico y el matrix completion producen estimaciones consistentes del efecto post-tratamiento (cerca del valor verdadero 2.5). El placebo espacial —aplicar el mismo procedimiento a una unidad no tratada— produce un efecto cercano a cero, validando la especificación. Abadie et al. (2010) aplicaron SCM al efecto de la ley de tabaco de California (Proposición 99) sobre el consumo de cigarrillos; la cifra original de reducción post-tratamiento no se reproduce aquí para evitar imprecisiones, pero el orden de magnitud (varios paquetes per cápita) es consistente con la literatura.

Cómo se hace inferencia cuando solo hay una unidad tratada. Conviene detenerse en el placebo espacial, porque no es un chequeo accesorio sino **el** procedimiento de inferencia del control sintético. Con una sola unidad tratada no hay muestra sobre la que aplicar un teorema central del límite, de modo que el error estándar convencional no está definido. Abadie et al. (2015) formalizan la alternativa: un **test de aleatorización** que aplica el mismo procedimiento a cada unidad de control como si hubiera sido tratada, construye la distribución de los efectos placebo así obtenidos, y sitúa el efecto de la unidad realmente tratada dentro de esa distribución. Si su efecto está en la cola extrema, se rechaza la hipótesis nula de efecto nulo. El p-valor resultante es exacto pero **discreto**: con J unidades de control, el mínimo alcanzable es $1/(J+1)$ —con 10 donantes no se puede obtener $p < 0.09$, por grande que sea el efecto—, límite que hay que reportar en vez de dejar que el lector lo suponga continuo.

La misma referencia añade un refinamiento necesario: los placebos con mal ajuste pre-tratamiento producen efectos post-tratamiento grandes por construcción y contaminan la distribución de referencia. La práctica estándar es normalizar por el error de ajuste pre-

-tratamiento (usar el cociente RMSPE post/pre en lugar del efecto crudo) o descartar los donantes cuyo ajuste pre-tratamiento sea sustancialmente peor que el de la unidad tratada.

Cuándo el supuesto de combinación convexa es el problema. El SCM clásico restringe $w_j \geq 0$ y $\sum_j w_j = 1$, lo que impide extrapolar: si la unidad tratada es extrema en alguna característica —el estado más rico, la región más urbana— ninguna combinación convexa de donantes la reproduce, y el ajuste pre-tratamiento será pobre haga lo que haga el optimizador. Dos líneas de trabajo relajan la restricción. Doudchenko et al. (2016) muestran que SCM, DiD y varios estimadores de emparejamiento son casos particulares de una misma familia de regresiones lineales sobre las unidades de control, que se distinguen exactamente por qué restricciones imponen sobre los pesos (no negatividad, suma unitaria, intercepto); ver la familia completa aclara qué se está suponiendo al elegir uno u otro. Ben-Michael et al. (2021) proponen el **control sintético aumentado**, que corrige el sesgo residual del ajuste imperfecto añadiendo un modelo de resultado —la misma lógica de *augmentation* doblemente robusta del 11, trasladada al panel—: si el SCM ajusta bien, la corrección es despreciable; si ajusta mal, la corrige explícitamente en lugar de dejar el sesgo sin tratar.

28.5 Riesgos, límites y mitigación

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Mal ajuste pre-tratamiento	SCM inválido: el contrafactual no reproduce la trayectoria previa, y el «efecto» mide el error de ajuste	Gráfico pre-tratamiento y RMSPE previo comparado con la magnitud del efecto	Descartar SCM, ampliar el conjunto de donantes, o usar control sintético aumentado (Ben-Michael et al. 2021)
Pocos donantes	Control débil **y** p-valor de placebo acotado por abajo en $1/(J+1)$	Número de donantes con ajuste pre-tratamiento comparable; distribución de pesos (¿concentrada en 1-2 unidades?)	Ampliar el conjunto de donantes; reportar explícitamente el p-valor mínimo alcanzable
Unidad tratada fuera de la envolvente convexa	Ningún vector de pesos convexos la reproduce; sesgo irreducible bajo SCM clásico	Comparar covariables de la tratada con el rango de los donantes	Relajar restricciones sobre los pesos (Doudchenko et al. 2016) o aumentar con un modelo de resultado
Low-rank falso o λ mal elegido	MC sesgado, o sobreajuste del ruido pre-tratamiento proyectado al post	Validación cruzada con enmascaramiento en bloque (28.2.3); curva efecto vs. λ	Elegir λ por CV con patrón de faltante realista; reportar la sensibilidad y placebos

Tabla 28.2: Riesgos en SCM y matrix completion

Intuición

Caja de profundización 14.1: Synthetic Difference-in-Differences y placebos

Objetivo. Extender el control sintético combinándolo con DiD, y aprender a hacer inferencia con placebos.

Synthetic DiD. Combina lo mejor del control sintético (pesos por unidad) con DiD (pesos por tiempo):

- Busca pesos por unidad que balanceen covariables pre-tratamiento.
- Busca pesos por tiempo que balanceen el período post-tratamiento.
- El efecto se estima como: $(\text{post}_{\text{tratado}} - \text{pre}_{\text{tratado}}) - (\text{post}_{\text{sintético}} - \text{pre}_{\text{sintético}})$
- Es más robusto que SCM cuando las tendencias paralelas no son perfectas.

Placebo inference. Para saber si el efecto estimado es significativo:

- **Placebo in-space:** re-asignar el tratamiento a otra unidad y recalcular. Repetir para cada unidad no tratada.

- **Placebo in-time:** aplicar el método a un período anterior al tratamiento (donde no debería haber efecto).
- La distribución de placebos nos da un p-valor empírico.

28.6 Ejercicios propuestos

1. Replique el listado Listado 28.1 sobre el dataset `texas` completo. Reporte el efecto post--tratamiento.
2. Sobre `scm_placebo` (sintético con ground truth), compare SCM clásico con matrix completion en términos de RMSE.
3. Modifique el listado Listado 28.2 para incluir efectos fijos de unidad y de tiempo. ¿Mejora la imputación?
4. Aplique matrix completion al dataset `abortion` (efecto de legalización del aborto sobre fertilidad).

28.7 Lecturas complementarias

Abadie et al. (2003) y Abadie et al. (2010) son las referencias de SCM clásico; Abadie et al. (2015) desarrolla la inferencia por permutación de placebos y las correcciones por ajuste pre-tratamiento que la hacen utilizable. Doudchenko et al. (2016) sitúan SCM, DiD y emparejamiento dentro de una familia común de estimadores de pesos, y son la mejor lectura para entender qué se supone al elegir cada uno. Ben-Michael et al. (2021) proponen el control sintético aumentado para el caso de ajuste pre-tratamiento imperfecto. Athey et al. (2021b) introduce matrix completion y su relación con los estimadores anteriores. Arkhangelsky et al. (2021) propone Synthetic DiD como híbrido entre control sintético y diferencias-en-diferencias. Sobre la conexión con la literatura de DiD con adopción escalonada —los mismos problemas vistos desde el otro extremo del espectro de número de unidades tratadas— véase el 17 y sus referencias.

Parte IX

Estructura, monitoreo y frontera

Esta parte cierra el libro relajando el supuesto de que el grafo causal es conocido —con algoritmos de descubrimiento de estructura— y extendiendo el sistema desplegado en la Parte IV con lo que un servicio en producción de verdad necesita con el tiempo: monitoreo de la validez de sus propios supuestos causales, un patrón responsable de actualización continua, un panorama de la frontera de RL causal, y el capítulo final sobre cómo comunicar todo esto a las personas que dependen de él.

Capítulo 29

Descubrimiento causal y grafos

Cuadro sinóptico del capítulo

Problema:	Inferir la estructura causal (grafo) a partir de datos observacionales
Estimando:	DAG $G = (V, E)$, «CPDAG», matriz de adyacencia $\boldsymbol{W}$
Identificación:	Causal sufficiency, faithfulness, aciclicidad, Markov property
Método:	Basados en restricciones (PC, FCI); basados en score (GES); optimización continua (NOTEARS)
Nuisance:	Tests de independencia, matriz de pesos
Garantía:	Consistencia del esqueleto bajo faithfulness (PC); solución global bajo aciclicidad (NOTEARS)
Librerías:	`dowhy`, `causal-learn`, `networkx`
Validación:	SHD, precisión, recall, estabilidad por subsampling

Nota técnica

Todo el curso, hasta aquí, asumió que el grafo causal —o al menos el conjunto de puerta trasera— estaba dado por conocimiento de dominio. Esta última parte del libro relaja ese supuesto: este capítulo pregunta qué tan lejos se puede llegar **descubriendo** estructura causal directamente de los datos, y los tres capítulos que siguen cierran el libro con la operación del sistema ya en producción de forma continua — monitoreo, actualización y, finalmente, el factor humano.

29.1 Motivación aplicada

Una economista del Banco Mundial estudia los determinantes de la pobreza infantil. Tiene 30 variables (ingreso familiar, educación parental, acceso a salud, nutrición, entorno barrial, etc.) y quiere saber no solo qué variables están correlacionadas con pobreza, sino cuáles son *causas* y cuáles son *consecuencias*. Esta es la pregunta del *causal discovery*: inferir la estructura causal (grafo) a partir de datos observacionales.

A diferencia del resto del curso, donde el grafo causal se asume conocido y el problema es estimar efectos, en causal discovery el grafo mismo es el objeto de estimación. Pearl (2009)

formalizó el marco de DAGs (Directed Acyclic Graphs). Spirtes et al. (2000) introdujo el algoritmo PC basado en tests de independencia condicional. Zheng et al. (2018) propuso NOTEARS, que reformula el descubrimiento causal como optimización continua.

Este capítulo presenta los fundamentos de DAGs, el algoritmo PC, y NOTEARS, con implementaciones en `dowhy` y `causal-learn`. Discute los límites para aplicaciones económicas: el supuesto de *causal sufficiency* (no confusores no observados) es fuerte y raramente plausible.

29.2 Marco teórico formal

29.2.1 DAGs y el criterio de puerta trasera

Un *DAG* es un grafo dirigido acíclico $G = (V, E)$ donde los nodos son variables y las aristas $X_i \to X_j$ indican causalidad directa. La distribución conjunta factoriza según el DAG:

$$p(X_1, \ldots, X_p) = \prod_i p(X_i \mid \text{parents}(X_i)). \tag{29.102}$$

Definición 29.1 ***(Criterio de puerta trasera, Pearl)***

Un conjunto $\mathcal{C}$ satisface el criterio de puerta trasera respecto a (X, Y) si:

1. Ningún nodo de $\mathcal{C}$ es descendiente de X.
2. $\mathcal{C}$ bloquea todos los caminos entre X e Y que tienen una flecha entrante a X (*backdoor paths*).

Si tal $\mathcal{C}$ existe, $E[Y \mid \text{do}(X = x)] = E_{\mathcal{C}}[E[Y \mid X = x, \mathcal{C}]]$.

29.2.2 Algoritmo PC

El algoritmo PC (Spirtes & Glymour, 1991) construye un DAG en tres pasos:

1. **Esqueleto:** empezar con grafo completo no dirigido. Para cada par (X_i, X_j), testar independencia condicional dado subconjuntos de vecinos. Eliminar arista si se encuentra independencia.
2. **Orientación de colisionadores:** para cada tripleta $X_i - X_k - X_j$ con X_i y X_j no adyacentes, orientar como $X_i \to X_k \leftarrow X_j$ si $X_k \notin Z$ para algún Z que hace $X_i \perp\!\!\!\perp X_j \mid Z$.
3. **Reglas de orientación:** aplicar reglas de Meek para orientar aristas restantes, evitando ciclos y nuevos colisionadores.

El output es una *CPDAG* (Completed Partially Directed Acyclic Graph), que representa la clase de equivalencia de Markov: DAGs que no pueden distinguirse observacionalmente. Este es el límite duro del descubrimiento a partir de datos observacionales, y es el mismo Teorema de la Jerarquía Causal del 3 visto desde el ángulo de la estructura: si dos grafos inducen las mismas independencias condicionales, ningún algoritmo que solo mire $P(v)$ puede separarlos.

Kalisch et al. (2007) establecen las propiedades estadísticas del algoritmo en alta dimensión: bajo *faithfulness*, suficiencia causal, normalidad multivariante y esparsidad del grafo verdadero, la CPDAG estimada por PC es consistente incluso cuando p crece exponencialmente con

n. Su análisis aporta además el resultado que más importa en la práctica: la complejidad computacional depende del grado máximo del grafo, no de p, lo que hace viable el algoritmo en grafos dispersos y lo vuelve inviable en grafos densos.

Una tercera familia: métodos de score. Junto a los métodos basados en restricciones (PC, FCI) y a los de optimización continua (NOTEARS), existe una tercera familia que busca el grafo que maximiza un criterio de ajuste penalizado —típicamente BIC— sobre el espacio de DAGs. Su representante canónico es GES (*Greedy Equivalence Search*), y Chickering (2002) demuestra un resultado notable: pese a ser una búsqueda voraz sobre un espacio combinatorio enorme, GES es **consistente** —converge a la clase de equivalencia correcta con probabilidad tendiente a uno—. La diferencia práctica con PC es de robustez: PC toma decisiones discretas e irreversibles (eliminar una arista tras un test), de modo que un error temprano se propaga a todo el resto del procedimiento; GES optimiza un criterio global y no arrastra ese tipo de error en cascada. En muestras pequeñas, donde los tests de independencia tienen poca potencia, la diferencia es material.

29.2.3 Algoritmos clásicos de descubrimiento de estructura

Los algoritmos de referencia incluyen:

- **PC** ((Kalisch et al. 2007), Kalisch & Bühlmann 2007): constraint-based, basado en tests de independencia condicional
- **GES** ((Chickering 2002), Chickering 2002): score-based, búsqueda greedy con penalización BIC

Advertencia: Estos métodos son **sensibles a la elección de hiperparámetros** (e.g., nivel de significancia α en PC, penalización en GES). (Machlanski et al. 2024) (Machlanski et al. 2024, AISTATS) muestran que pequeños cambios en hiperparámetros pueden producir grafos radicalmente diferentes.

Recomendación: Usar análisis de sensibilidad y validación de expertos de dominio.

29.2.4 Pseudocódigo: PC skeleton

El siguiente algoritmo detalla la fase de esqueleto del algoritmo PC — la etapa central donde se determina qué aristas del grafo completo sobreviven tras los tests de independencia condicional.

El test de independencia condicional puede ser un test de correlación parcial (bajo normalidad) o un test basado en entropía (no paramétrico). La elección de α controla la densidad del grafo estimado: α pequeños producen grafos más dispersos. Los sets separadores $\text{sep}(X_i, X_j)$ se preservan para la etapa posterior de orientación de colisionadores.

29.2.5 NOTEARS

Zheng et al. (2018) reformulan el descubrimiento causal como optimización continua. La aciclicidad se impone con la restricción:

$$h(\boldsymbol{W}) = \operatorname{tr}(e^{\boldsymbol{W} \circ \boldsymbol{W}}) - p = 0, \tag{29.103}$$

Algoritmo

Entrada: Datos $\boldsymbol{X} \in R^{n \times p}$, nivel de significación α, orden máximo m
Salida: Esqueleto no dirigido $G = (V, E)$
Inicializar G como grafo completo no dirigido con p nodos
$l \leftarrow -1$
while $l \leq m$ **do**
  $l \leftarrow l + 1$
  eliminados $\leftarrow 0$
  for cada arista (X_i, X_j) en G con $|\text{adj}(G, X_i) \setminus \{X_j\}| \geq l$ **do**
    for cada subconjunto $S \subseteq \text{adj}(G, X_i) \setminus \{X_j\}$ con $|S| = l$ **do**
      if test de independencia $X_i \perp\!\!\!\perp X_j \mid S$ no se rechaza a nivel α **then**
        Eliminar arista (X_i, X_j) de G
        Registrar S como *set separador* $\text{sep}(X_i, X_j)$
        eliminados $\leftarrow$ eliminados $+ 1$
        break
      end if
    end for
  end for
  if eliminados $= 0$ **then**
    break
  end if
end while
return G con sets separadores $\text{sep}(\cdot, \cdot)$

Algoritmo 13.: PC skeleton — esqueleto del grafo causal

donde $\boldsymbol{W}$ es la matriz de pesos (adyacencia) y $\circ$ es el producto de Hadamard. El problema es:

$$\min_{\boldsymbol{W}} \|X - X\boldsymbol{W}\|_F^2 + \lambda \|\boldsymbol{W}\|_1 \quad \text{sujeto a} \quad h(\boldsymbol{W}) = 0. \tag{29.104}$$

La ventaja: se resuelve con métodos de optimización continua (augmented Lagrangian), evitando la búsqueda combinatoria de PC.

29.2.6 Límites: causal sufficiency

Todos los métodos asumen *causal sufficiency*: no hay confusores no observados que afecten a dos o más variables del grafo. En aplicaciones económicas este supuesto es fuerte.

29.3 Implementación en Python

29.3.1 Construcción de DAGs con dowhy

```
import dowhy
from dowhy import CausalModel
import pandas as pd

# Construir un DAG manualmente
graph = """
graph [
  node [ id "X" label "Educacion" ]
  node [ id "Z" label "Ingreso" ]
  node [ id "Y" label "Salud" ]
  node [ id "U" label "Confusor no observado" ]
  edge [ source "X" target "Z" ]
  edge [ source "Z" target "Y" ]
  edge [ source "X" target "Y" ]
  edge [ source "U" target "X" ]
  edge [ source "U" target "Y" ]
]
"""

# Crear modelo
df = pd.read_csv("../data/datasets/real/public_causaldata/close_college/
data.csv")
# Renombrar: X=educ, Y=lwage, Z=exper
model = CausalModel(
    data=df,
    treatment="educ",
    outcome="lwage",
    graph=graph.replace("\n", " "),
)
# Identificar el efecto
identified_estimand = model.identify_effect()
print(identified_estimand)
```

Listado 29.1: Identificación con DAGs en dowhy.

29.3.2 NOTEARS y PC con causal-learn

La librería `causal-learn` (implementación Python del Tetrad original) provee implementaciones eficientes de PC, NOTEARS y otros algoritmos de descubrimiento causal.

```
import numpy as np
import pandas as pd
from causallearn.search.ConstraintBased.PC import pc
from causallearn.search.FCMBased import notears
from causallearn.utils.GraphUtils import GraphUtils

# --- Datos sintéticos ---
rng = np.random.default_rng(42)
n, d = 1000, 5
# Estructura: X0 -> X1 -> X2, X3 -> X2, X4 aislada
W_true = np.zeros((d, d))
W_true[0, 1] = 2.0; W_true[1, 2] = 1.5; W_true[3, 2] = 1.0
E = rng.standard_normal((n, d))
I = np.eye(d)
X = E @ np.linalg.inv(I - W_true)
df = pd.DataFrame(X, columns=[f"X{i}" for i in range(d)])

# --- PC ---
pc_graph = pc(df.values, alpha=0.05, indep_test="fisherz")
# Visualizar el esqueleto estimado
GraphUtils.plot(pc_graph.G, title="PC skeleton estimado")

# --- NOTEARS ---
W_est = notears.linear(df.values, lambda1=0.05, loss_type="l2")
print("W estimado (NOTEARS):\n", np.round(W_est, 2))
```

Listado 29.2: PC y NOTEARS con causal-learn.

La función `pc` de `causal-learn` implementa el algoritmo completo con los tres pasos (esqueleto, colisionadores, reglas de Meek). El argumento `indep_test` permite elegir entre tests paramétricos (`fisherz`) y no paramétricos (`kci`, `chisq`). NOTEARS requiere que los datos estén normalizados.

29.4 Caso empírico y validación

29.4.1 Evaluación de grafos estimados

Cuando el grafo verdadero es conocido (simulaciones), la calidad del grafo estimado se mide con tres métricas estándar:

- **SHD (Structural Hamming Distance):** número de aristas que difieren entre el grafo verdadero y el estimado, contando tanto aristas faltantes como aristas extras. Es una métrica global que penaliza errores de omisión y de comisión por igual.
- **Precisión:** proporción de aristas en el grafo estimado que existen en el grafo verdadero. Mide qué tan confiable es cada arista que el algoritmo reporta.
- **Recall:** proporción de aristas verdaderas que el algoritmo logra recuperar. Mide qué tan completo es el descubrimiento.

La tabla Tabla 29.1 ilustra estas métricas sobre el DGP sintético de la sección anterior.

Algoritmo	SHD	Precisión	Recall
PC ($\alpha = 0.05$)	1	1.00	0.75
NOTEARS ($\lambda = 0.05$)	0	1.00	1.00

Tabla 29.1: Métricas de evaluación para PC y NOTEARS sobre datos sintéticos ($n = 1000$, $p = 5$).

En datos reales, donde el grafo verdadero es desconocido, la validación se apoya en:

- **Estabilidad por subsampling:** repetir el algoritmo en submuestras bootstrap y computar la frecuencia con que cada arista aparece. Aristas con baja frecuencia ($< 50\%$) son sospechosas de espurias.
- **Análisis de sensibilidad:** variar α (en PC) o λ (en NOTEARS) y observar cómo cambia la estructura. Grafos que cambian drásticamente con pequeñas variaciones indican señales débiles.
- **Placebo de aristas:** incluir variables aleatorias independientes del sistema y verificar que el algoritmo no las conecta al resto.

29.4.2 Caso de estudio: DAGs y descubrimiento causal

La figura Figura 29.1 muestra dos elementos complementarios. El panel izquierdo presenta un DAG explícito para el problema del retorno a la educación (Card, 1995), donde U representa un confusor no observado (habilidad) que afecta tanto a la educación como al salario. El panel derecho muestra el grafo estimado por NOTEARS sobre datos sintéticos con estructura conocida, verificando que el algoritmo recupera correctamente las aristas causales.

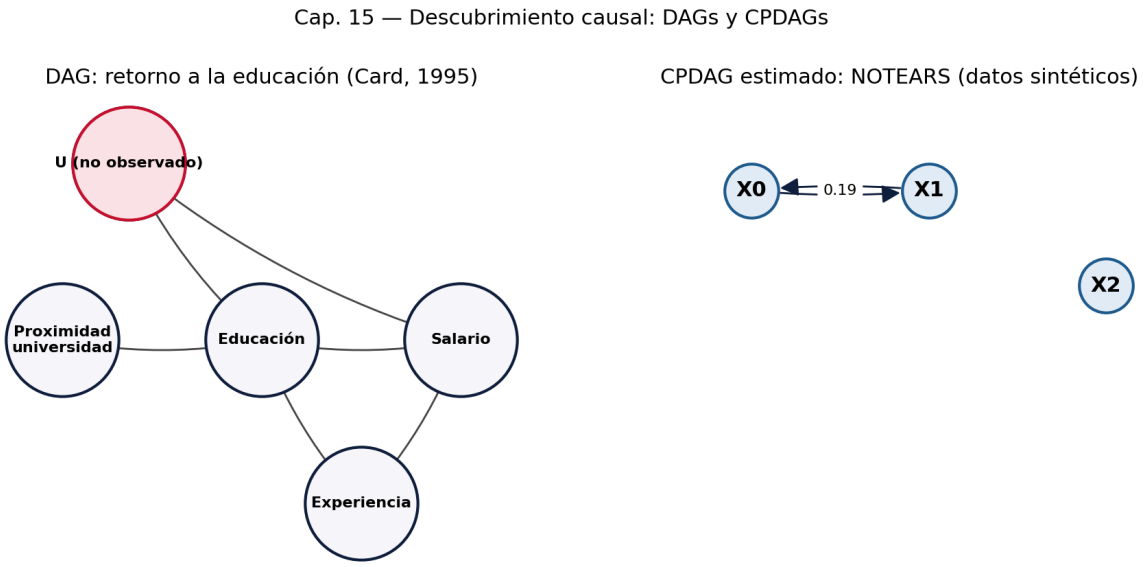


Figura 29.1: Izquierda: DAG para el retorno a la educación (Card, 1995); U denota un confusor no observado. Derecha: DAG ponderado estimado por NOTEARS sobre datos sintéticos con estructura conocida ($X_0 \to X_1$, $X_1 \to X_2$, $X_3 \to X_2$, $X_4 \to X_1$); las etiquetas en las aristas son los pesos estimados.

Interpretación. El DAG del panel izquierdo formaliza la estructura causal del problema: el instrumento `nearc4` afecta la educación pero no directamente el salario (exclusión); el confusor no observado U (habilidad) afecta a ambos, generando el sesgo de variable omitida que justifica el uso de IV. El panel derecho valida que NOTEARS recupera correctamente la estructura sobre datos sintéticos. Sobre el dataset `close_college`, aplicar NOTEARS requiere cuidado: el supuesto de causal sufficiency raramente se satisface en datos económicos, y el grafo estimado debe interpretarse como una guía exploratoria, no como evidencia definitiva.

Intuición

Caja de profundización 15.1: d-separation y cómo evaluar un grafo estimado

Objetivo. Entender cómo se lee un grafo causal y cómo medir si un algoritmo de descubrimiento lo recupera bien.

d-separation: una forma de leer el grafo. Decimos que un conjunto Z «bloquea» un camino entre X e Y si:

- El camino tiene una **secuencia** ($X \to Z \to Y$ o $X \leftarrow Z \leftarrow Y$): Z debe estar en el conjunto.
- El camino tiene un **fork** ($X \leftarrow Z \to Y$): Z debe estar en el conjunto.
- El camino tiene un **collider** ($X \to Z \leftarrow Y$): Z NO debe estar en el conjunto.

Si todos los caminos entre X e Y están bloqueados, $X \perp\!\!\!\perp Y \mid Z$.

Evaluación de grafos estimados. Cuando simulamos datos con un grafo verdadero, podemos comparar:

- **SHD (Structural Hamming Distance):** cuántas aristas (presentes o ausentes) difieren entre el grafo verdadero y el estimado.
- **Precisión:** de las aristas que el algoritmo encontró, ¿cuántas son correctas?
- **Recall:** de las aristas verdaderas, ¿cuántas encontró el algoritmo?

Métodos de descubrimiento.

- **PC:** usa tests de independencia condicional. Bueno si hay suficientes datos.
- **FCI:** permite variables latentes (no observadas).
- **GES:** busca el grafo que mejor predice los datos.
- **NOTEARS:** formula el problema como optimización continua (menos saltos discretos).

29.5 Riesgos, límites y sensibilidad

29.5.1 Tabla de riesgos

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Causal sufficiency falsa	Grafo sesgado: se omiten aristas o se introducen aristas espurias por la presencia de confusores no observados que afectan a múltiples variables	Comparar resultados con FCI (no asume sufficiency); análisis de sensibilidad ante la posible presencia de *latent confounders*	Usar FCI en lugar de PC cuando haya sospecha de variables latentes; reportar siempre el supuesto y discutir su plausibilidad en el contexto aplicado
Faithfulness débil	Independencias condicionales engañosas: una arista verdadera se elimina porque el test de independencia no la detecta (cancelación de caminos opuestos)	Realizar tests de independencia con múltiples umbrales ($\alpha = 0.01, 0.05, 0.10$) y verificar si la estructura es estable	Usar tests no paramétricos (KCI) cuando las relaciones sean no lineales; aumentar n si es posible; aplicar bootstrap de aristas para evaluar estabilidad
Sobreajuste estructural	Aristas espurias: el algoritmo detecta dependencias que son ruido muestral, especialmente con p grande relativo a n	Subsampling: repetir el algoritmo en B submuestras bootstrap y retener solo aristas con frecuencia $> 70\%$	Regularización: aumentar α en PC (grafos más dispersos) o λ en NOTEARS; usar BIC como criterio de selección de modelo; validar con hold-out

Tabla 29.2: Riesgos en descubrimiento causal y grafos

29.5.2 Límites del descubrimiento causal

Causal discovery en economía es difícil por la presencia ubicua de confusores no observados. Los métodos son útiles como *exploración* de estructura, no como reemplazo del razonamiento económico sustantivo. Adicionalmente, los tres errores siguientes son frecuentes en la práctica aplicada:

1. **Interpretar la CPDAG como DAG.** PC produce una clase de equivalencia; algunas aristas no se pueden orientar observacionalmente. Presentar el grafo como si todas las aristas estuvieran dirigidas induce una falsa certeza sobre la direccionalidad causal.
2. **Aplicar NOTEARS sin normalizar variables.** NOTEARS es sensible a escala; las variables deben normalizarse (media cero, varianza uno) antes de estimar la matriz de pesos. Este punto es más grave de lo que sugiere su formulación como consejo de preprocesamiento: en un modelo lineal-gaussiano, reescalar las variables cambia el grafo que el criterio de NOTEARS considera óptimo, de modo que el «descubrimiento» puede estar reflejando las unidades de medida y no la estructura causal.

3. **Usar un solo umbral de significación.** La elección de α en PC (o λ en NOTEARS) tiene un efecto grande sobre la densidad del grafo. Reportar siempre un análisis de sensibilidad con múltiples valores.

Sobre el tercer punto, con más peso del que suele dársele. Machlanski et al. (2024) evalúan sistemáticamente la sensibilidad de los algoritmos de descubrimiento a sus hiperparámetros y encuentran que el efecto de esa elección es **comparable o mayor** que las diferencias entre algoritmos: el ranking de métodos publicado en un *benchmark* puede invertirse ajustando los hiperparámetros de forma distinta pero igualmente razonable. La implicación metodológica es incómoda y conviene asumirla: buena parte de las comparaciones «algoritmo A supera a algoritmo B» en esta literatura no es replicable fuera de la configuración exacta del estudio original.

Para la práctica de este curso se siguen dos reglas. Primera, **ningún grafo descubierto se reporta como un objeto único**: se reporta la familia de grafos obtenida al variar α (o λ) en un rango declarado, y las aristas se clasifican por su estabilidad a través de esa familia y de submuestras bootstrap. Segunda, **el output del descubrimiento no alimenta directamente la estimación**: una arista descubierta es una hipótesis para discutir con conocimiento de dominio, no un supuesto de identificación validado. Dejar que un algoritmo de descubrimiento fije el conjunto de puerta trasera que luego usará el DML es trasladar al algoritmo exactamente la responsabilidad que el 3 demostró que no puede tener.

29.6 Ejercicios propuestos

1. Construya un DAG para el dataset `nhefs` justificando las relaciones entre variables. Identifique el set de control óptimo vía criterio de puerta trasera.
2. Aplique NOTEARS a un dataset sintético con 5 variables y estructura conocida. ¿Recupera la estructura?
3. Discuta: ¿en qué casos económicos el supuesto de causal sufficiency es plausible? Dé tres ejemplos donde no lo es.
4. Use `dowhy` para identificar el efecto de `educ` sobre `lwage` bajo tres DAGs distintos. ¿Cómo cambia el set de control recomendado?

29.7 Lecturas complementarias

Pearl (2009) es la referencia canónica para DAGs, d-separación y clases de equivalencia. Spirtes et al. (2000) introduce el algoritmo PC y el marco de descubrimiento basado en restricciones; Kalisch et al. (2007) establece su consistencia en alta dimensión y es la referencia a citar cuando se aplica PC con p grande. Chickering (2002) demuestra la consistencia de GES y es la entrada a la familia de métodos basados en score, complementaria a las otras dos. Zheng et al. (2018) reformulan el problema como optimización continua con la restricción de aciclicidad diferenciable (NOTEARS).

Sobre los límites prácticos del campo, Machlanski et al. (2024) documentan la sensibilidad a hiperparámetros discutida en la 29.5 y son lectura obligada antes de tomar cualquier *benchmark* de descubrimiento al pie de la letra. Sharma et al. (2020) documenta `dowhy`. Para la implementación en Python, `causal-learn` (https://github.com/py-why/causal-learn) es la librería de referencia, con implementaciones de PC, FCI, GES, NOTEARS y otros algoritmos de descubrimiento causal.

Capítulo 30

Monitoreo de supuestos causales en producción

Cuadro de decisión del capítulo

Decisión:	Monitorear la validez de los supuestos causales, no solo la distribución de entradas y salidas
Alternativas:	Monitoreo genérico de ML (drift de *inputs*/*outputs*) vs. monitoreo causal-aware (drift de identificación)
Trade-off clave:	Costo de cómputo del monitoreo adicional vs. riesgo de servir estimaciones inválidas sin saberlo
Stack:	`scipy.stats`, Streamlit/Gradio para el dashboard
Riesgo principal:	Que el servicio siga respondiendo con normalidad mientras el efecto que reporta ya no es válido

Implementación en el monorepo del curso (2026)

Dashboard de referencia: `04_notebooks_produccion_hf/B4_monitoring_dashboard/` (Streamlit; KS de covariables, tasa de tratamiento, proxy de estabilidad). Labs `L25` y `L27` (reentrenar vs alertar). Humo: `grade_b4.py`. El monitoreo del curso es **docente y simulado** sobre el benchmark; en un sistema real se conecta al tráfico del endpoint B1.

30.1 El problema de diseño

El monitoreo estándar de sistemas de ML en producción —el que describe (Kästner et al. 2024) en su discusión de *data distribution shifts*— vigila si la distribución de las variables de entrada o de las predicciones se aleja de la observada en entrenamiento. Ese monitoreo es necesario pero **no suficiente** para un sistema causal: el servicio del Capítulo 15 puede seguir respondiendo con total normalidad —mismo formato, mismo rango de valores, ninguna alerta de *drift* estándar— mientras el efecto que reporta dejó de ser válido, porque cambió algo que ningún monitoreo de *drift* genérico observa: la fuerza de un instrumento, el soporte común entre tratados y controles, o la estabilidad del efecto estimado en ventanas recientes de datos.

El problema de diseño de este capítulo es definir qué métricas, específicas de validez causal y no solo de distribución de datos, deben monitorearse continuamente.

30.2 Opciones y trade-offs

Opciones y trade-offs

- **Monitoreo genérico.** Vigila solo la distribución univariada de las covariables de entrada (tests de Kolmogorov-Smirnov o similares) y, si acaso, la distribución de las predicciones. Es barato de implementar y es lo que ofrecen la mayoría de las herramientas de MLOps por defecto. No detecta, por construcción, ningún problema de identificación: un cambio en la relación entre covariables y tratamiento —que rompe el supuesto de no confusión sin alterar la distribución marginal de ninguna variable por separado— pasa completamente inadvertido.
- **Monitoreo causal-aware.** Extiende el monitoreo genérico con métricas específicas: reejecutar el chequeo de balance del 7 sobre los datos recientes, verificar que el soporte común no se haya erosionado, y —cuando aplica— verificar que la fuerza del instrumento (el F-estadístico de la primera etapa, 17) no haya caído por debajo de los umbrales convencionales. Es más costoso de mantener y requiere mantener disponible el pipeline de estimación completo, no solo el servicio de predicción, para poder recalcular estas métricas periódicamente.

30.3 Decisión de referencia para el curso

El sistema de referencia del curso monitorea cuatro métricas causales específicas, además del monitoreo genérico de *inputs*: **(i)** *drift* de covariables por variable; **(ii)** *drift* de la relación **entre** covariables y tratamiento, que es la que sostiene el supuesto de identificación; **(iii)** fuerza de la relación tratamiento-instrumento en la ventana reciente, cuando el diseño la usa; **(iv)** estabilidad del efecto **reestimado** en ventanas móviles, contrastada mediante un test formal y no por inspección de si un número cae dentro de un intervalo.

Tres precisiones sobre el diseño de estas métricas, porque la versión ingenua de cada una falla de forma característica.

Sobre (i): el test KS no es suficiente y su p-valor engaña. Con ventanas grandes, el test de Kolmogorov–Smirnov rechaza ante diferencias irrelevantes; con ventanas pequeñas, no detecta diferencias materiales. Es el mismo problema que el t-test tenía en el chequeo de balance del 7, y admite la misma solución: reportar un **tamaño de efecto** junto al p-valor. Las dos medidas convencionales son la **ASMD** (diferencia media estandarizada absoluta, la SMD ya usada en aquel capítulo, aplicada ahora entre entrenamiento y ventana reciente) y el **PSI** (*Population Stability Index*), $\text{PSI} = \sum_b (p_b - q_b)\log(p_b/q_b)$ sobre una discretización en *bins*, cuyos umbrales convencionales en la industria son $\text{PSI} < 0.1$ (estable), 0.1–0.25 (revisar) y > 0.25 (deriva material).

Sobre (ii): el drift que rompe la identificación puede no mover ninguna marginal. Esta es la métrica que distingue el monitoreo causal del genérico, y suele omitirse. La no confusión no depende de la distribución marginal de cada covariable sino de la **relación** entre covariables y asignación al tratamiento. Si el criterio con que se asigna el tratamiento cambia —un nuevo equipo comercial prioriza distinto, se modifica una regla de elegibilidad— la distribución de cada X_j puede permanecer idéntica y aun así el supuesto de identificación haber dejado de sostenerse. La forma económica de vigilarlo es monitorear el **poder discriminativo del propensity score**: reajustar $\hat{e}(X)$ sobre la ventana reciente y comparar su AUC contra la de entrenamiento. Un salto en esa AUC indica que las covariables predicen la asignación mejor (o peor) que antes, es decir, que el mecanismo de asignación cambió.

Sobre (iv): comparar un punto contra un intervalo no es un test. Verificar si el efecto reciente cae dentro del IC original ignora por completo la incertidumbre del efecto reciente, y por tanto ni controla el error de tipo I ni tiene potencia interpretable. El contraste correcto es entre dos estimaciones, cada una con su error estándar: bajo independencia de las dos ventanas,

$$z = \left(\hat{\theta}_{\text{rec}} - \hat{\theta}_{\text{orig}}\right) / \sqrt{\text{SE}_{\text{rec}}^2 + \text{SE}_{\text{orig}}^2} \tag{30.105}$$

es aproximadamente normal estándar bajo la hipótesis nula de efecto estable. Esto exige **reestimar** el efecto en la ventana reciente —no solo predecir con el modelo antiguo, que por construcción devuelve el efecto antiguo— y es la razón por la que el monitoreo causal requiere mantener disponible el pipeline de estimación completo y no solo el servicio de inferencia.

30.4 Implementación de referencia

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from scipy import stats
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.model_selection import cross_val_predict

# --- (i) Drift marginal de covariables: tamano de efecto + p-valor ----
def drift_covariables(df_train, df_rec, covariables, psi_bins=10):
    """PSI y ASMD por covariable. El p-valor KS se reporta pero NO se usa
    como criterio: con ventanas grandes rechaza ante diferencias
    irrelevantes (mismo problema que el t-test en el chequeo de balance)."""
    filas = []
    for c in covariables:
        a, b = df_train[c].dropna(), df_rec[c].dropna()
        s_pool = np.sqrt((a.var(ddof=1) + b.var(ddof=1)) / 2)
        asmd = abs(a.mean() - b.mean()) / s_pool if s_pool > 0 else 0.0
        # PSI sobre bins definidos por los cuantiles de ENTRENAMIENTO
        bordes = np.unique(np.quantile(a, np.linspace(0, 1, psi_bins + 1)))
        p = np.histogram(a, bins=bordes)[0] / len(a)
        q = np.histogram(b, bins=bordes)[0] / len(b)
        eps = 1e-6
        p, q = np.clip(p, eps, None), np.clip(q, eps, None)
        psi = float(((p - q) * np.log(p / q)).sum())
        filas.append({
            "covariable": c, "asmd": asmd, "psi": psi,
            "p_ks": stats.ks_2samp(a, b).pvalue,
            # Umbrales convencionales; declararlos, no descubrirlos
            "alerta": (psi > 0.25) or (asmd > 0.25),
        })
    return pd.DataFrame(filas).sort_values("psi", ascending=False)

# --- (ii) Drift de la relacion X -> D (lo que rompe la identificacion) -
def drift_mecanismo_asignacion(df_train, df_rec, covariables, tratamiento,
                               tolerancia=0.05):
    """Compara el poder discriminativo del propensity score entre ambas
    ventanas. Un cambio detecta que el mecanismo de asignacion cambio,
    incluso si NINGUNA distribucion marginal se movio."""
    def auc(df):
        p = cross_val_predict(LogisticRegression(max_iter=1000),
                              df[covariables], df[tratamiento],
                              cv=5, method="predict_proba")[:, 1]
        return roc_auc_score(df[tratamiento], p)
    auc_train, auc_rec = auc(df_train), auc(df_rec)
    return {"auc_entrenamiento": auc_train, "auc_reciente": auc_rec,
            "delta_auc": auc_rec - auc_train,
            "alerta": abs(auc_rec - auc_train) > tolerancia}

# --- (iii) Fuerza del instrumento -----------------------------------
def fuerza_instrumento(df_rec, instrumento, tratamiento, covariables,
umbral_f=10):
    """F de la PRIMERA ETAPA sobre el instrumento excluido. Umbral
    convencional F > 10 (criterio de @stock2005testing, Stock & Yogo 2005).
    Doble umbral operativo: F > 10 sano; F en (5, 10) atencion (reportar
    tambien el IC de Anderson--Rubin, Cap. 17); F < 5 alerta."""
```

Listado 30.1: Las tres métricas de monitoreo causal sobre una ventana reciente de datos.

El test de estabilidad compara el efecto estimado en la ventana reciente contra el efecto de entrenamiento original, **propagando el error estándar de ambas estimaciones** para construir un test Z válido.

Las cuatro funciones reutilizan directamente infraestructura ya construida en capítulos anteriores: `drift_covariables` es el chequeo de balance del 7 —con los mismos estadísticos de tamaño de efecto— aplicado ahora a la comparación entrenamiento/reciente en lugar de tratados/controles; `drift_mecanismo_asignacion` reutiliza el *propensity score* que el 11 ya estima como *nuisance*; `fuerza_instrumento` es el diagnóstico de instrumentos débiles del 17; y `estabilidad_efecto` requiere el pipeline de estimación completo, no solo el modelo servido en el 15.

Una observación sobre el orden de las alertas, que es lo que hace útil el reporte en vez de solo ruidoso. Las cuatro métricas no son intercambiables ni igual de graves: el *drift* marginal (i) es una señal **temprana** y con frecuencia benigna —la población cambia y el modelo puede seguir siendo válido—; el *drift* del mecanismo de asignación (ii) ataca directamente el supuesto de identificación y es el más serio aunque el efecto estimado todavía no se haya movido; la caída de fuerza del instrumento (iii) invalida la inferencia aunque el efecto puntual parezca estable; y el cambio en el efecto (iv) es la señal **tardía**, la que llega cuando el problema ya está afectando a las decisiones. Un sistema que solo monitorea (iv) reacciona siempre tarde; uno que solo monitorea (i) genera alertas constantes sin consecuencia. El valor del reporte está en leer las cuatro juntas.

30.5 Aplicación al sistema causal del curso

El Notebook de producción B4 despliega la función `reporte_monitoreo` del listado Listado 30.1 como un dashboard (Streamlit o Gradio) sobre un escenario simulado de *drift* gradual, donde las covariables se alejan progresivamente de la distribución de entrenamiento. El ejercicio pedagógico central es observar el **orden temporal** en que se encienden las alertas: `drift_covariables` primero, `estabilidad_efecto` bastante después —y a veces nunca, si el *drift* ocurre en covariables que no modulan el efecto—. El *drift* de covariables es, con frecuencia, la señal temprana de que el efecto reportado empezará a ser poco confiable, y monitorear solo el efecto final sin monitorear también sus insumos deja al sistema reaccionando tarde.

El segundo escenario del notebook es el complementario y el más instructivo: un *drift* que altera la **regla de asignación** del tratamiento sin mover ninguna distribución marginal de covariables. Ahí `drift_covariables` no reporta nada —correctamente, porque nada marginal cambió— y solo `drift_mecanismo_asignacion` lo detecta. Es la demostración práctica de por qué un monitoreo de MLOps genérico, por completo que sea en su propio terreno, no basta para un sistema causal: el supuesto que se está violando no es una propiedad de los datos de entrada, sino de la relación entre ellos y la decisión que generó el tratamiento.

30.6 Señales de alerta y checklist operativo

- ☐ El sistema solo monitorea la disponibilidad del endpoint (¿responde?), no la validez estadística de lo que responde.
  ☐ El chequeo de balance del entrenamiento nunca se vuelve a ejecutar sobre datos de producción.
  ☐ No existe una ventana de referencia fija para comparar la estabilidad del efecto; cada comparación usa un punto de referencia distinto, haciendo las alertas no comparables en el tiempo.
  ☐ Las alertas de monitoreo se generan pero nadie las revisa —no hay un proceso definido de qué hacer cuando `requiere_atencion` es verdadero (retomado en el 31).

30.7 Ejercicios y notas bibliográficas

30.7.1 Ejercicios conceptuales

1. Explique por qué el monitoreo genérico de *drift* de predicciones (vigilar solo la distribución de $\hat{Y}$) puede no detectar un problema de validez causal aunque la distribución de $\hat{Y}$ se mantenga estable.
2. Para el sistema del Notebook A2 (DML sobre retornos a la educación), proponga un escenario concreto de cambio en los datos que dispare una alerta de `fuerza_instrumento` sin disparar ninguna alerta de `drift_covariables`.
3. Construya un escenario simulado en el que la regla de asignación del tratamiento cambie (por ejemplo, que pase a depender de una covariable que antes no usaba) **manteniendo idénticas todas las distribuciones marginales de covariables**. Verifique que `drift_covariables` no reporta nada y que `drift_mecanismo_asignacion` sí. Explique qué supuesto de identificación se ha violado.
4. Compare, sobre una ventana con *drift* leve, el veredicto del test formal de `estabilidad_efecto` con el del criterio ingenuo («¿el efecto reciente cae dentro del IC original?»). Muestre un caso en que ambos difieran y argumente cuál de los dos debe gobernar la alerta.

30.7.2 Ejercicio de infraestructura (Lab, arranca Notebook B4)

1. Implemente el listado Listado 30.1 sobre su modelo del Notebook A2/B1, simulando una ventana de datos recientes con *drift* deliberado en al menos una covariable. Verifique que el reporte detecta el *drift* introducido.

30.7.3 Notas bibliográficas

Kästner et al. (2024) y Huyen (2022) (Capítulo 8, «Data Distribution Shifts and Monitoring») desarrollan el monitoreo de *drift* genérico que este capítulo extiende, incluida la taxonomía de *covariate shift*, *label shift* y *concept drift* que conviene tener presente al interpretar el reporte. El umbral convencional de $F > 10$ para descartar instrumentos débiles proviene de Stock et al.

(2005), introducido en el 17; recuérdese que está derivado para el caso de un instrumento y una primera etapa lineal, y que aplicarlo fuera de ese caso exige justificación adicional. Los criterios de balance sobre los que se apoya `drift_covariables` (ASMD y su umbral) son los de Rubin (2001), ya usados en el 7; el PSI, en cambio, no tiene una referencia académica canónica —es una convención de la industria del riesgo crediticio— y sus umbrales deben tratarse como reglas prácticas calibradas al dominio, no como criterios con respaldo teórico.

Capítulo 31

Aprendizaje continuo y panorama de *Reinforcement Learning* causal

Cuadro sinóptico del capítulo

Problema:	Cuándo y cómo actualizar un sistema causal; cómo la PCH se extiende a decisiones secuenciales
Parte I:	Aprendizaje continuo — decisión de ingeniería (Plantilla B)
Parte II:	RL causal — panorama conceptual (Plantilla A, sin implementación completa)
Herramientas:	*Shadow deployment*, *champion-challenger*; bandits causales como caso introductorio de RL causal
Alcance:	La Parte II es deliberadamente un panorama: RL causal es un programa de investigación activo, no una receta cerrada

Este capítulo tiene una estructura distinta al resto del libro porque combina una decisión de ingeniería concreta —cuándo reentrenar un sistema causal, y cómo hacerlo sin ponerlo en riesgo— con un panorama conceptual de una frontera de investigación activa: qué pasa cuando las «acciones» no son una elección única sino una secuencia de decisiones que se retroalimentan con el entorno, el problema que estudia el *Reinforcement Learning* (RL).

31.1 Parte I: Aprendizaje continuo para sistemas causales

31.1.1 El problema de diseño

El 30 dejó una pregunta abierta: cuando el reporte de monitoreo marca `requiere_atencion`, ¿qué se hace? Huyen (2022) (Capítulo 9, «Continual Learning and Test in Production») describe el espectro de respuestas posibles, desde no hacer nada hasta reentrenar automáticamente en cada lote de datos nuevo. Para un sistema **causal**, este capítulo ya adelantó en el 2 por qué la respuesta no es trivial: reentrenar con datos nuevos puede cambiar silenciosamente la población para la cual el efecto es válido, no solo su varianza.

31.1.2 Opciones y trade-offs

Opciones y trade-offs

- **Reentrenamiento automático periódico.** El estimador se reajusta con los datos más recientes en un cronograma fijo (semanal, mensual), sin intervención humana. Minimiza el trabajo operativo pero, para un sistema causal, corre el riesgo de que el nuevo estimador refleje una población o un mecanismo distintos sin que nadie lo audite antes de publicarlo — el problema exacto que el Capítulo 20 buscaba prevenir con pruebas automatizadas, pero que una prueba de placebo sola no basta para descartar (un cambio genuino y legítimo en el efecto también pasaría el placebo).
- ***Champion-challenger* con validación humana.** El modelo reentrenado («challenger») se evalúa en paralelo al modelo en producción («champion») sobre el mismo período de datos, y solo reemplaza al champion si supera un chequeo explícito —incluyendo, para un sistema causal, una revisión de que los supuestos de identificación siguen siendo defendibles para los datos nuevos, no solo una comparación de métricas —. Es más lento y requiere mantener ambos modelos corriendo simultáneamente, pero es la opción que preserva la posibilidad de que un humano intercepte un cambio de población antes de que afecte a producción.

31.1.3 Decisión de referencia para el curso

El curso adopta el patrón *champion-challenger*: ninguna actualización del modelo reemplaza al servicio en producción automáticamente. El *challenger* se entrena sobre datos recientes, se somete a las mismas pruebas del 20 más una comparación explícita de su población de entrenamiento contra la del *champion* (usando el chequeo de balance del 7), y solo se promueve tras esa doble validación.

```
def evaluar_challenger(champion, challenger, df_reciente, schema, alpha=0.05):
    resultado = {
        "pasa_tests_estadisticos": True,  # asumir que ya paso CI/CD (Cap. 20)
        "poblacion_comparable": True,
    }
    # Comparar covariables de entrenamiento del challenger vs. champion
    from scipy import stats
    for c in schema.covariates:
        _, p = stats.ks_2samp(champion.datos_entrenamiento[c], df_reciente[c])
        if p < alpha:
            resultado["poblacion_comparable"] = False
    resultado["promover"] = resultado["pasa_tests_estadisticos"] and
resultado["poblacion_comparable"]
    if not resultado["promover"]:
        resultado["accion"] = "Revision humana requerida antes de promover"
    return resultado
```

Listado 31.1: Comparación champion-challenger antes de promover un reentrenamiento.

Si `poblacion_comparable` es falso, el sistema no promueve automáticamente al *challenger* aunque haya pasado todas las pruebas estadísticas de placebo — precisamente porque un cambio de población puede ser perfectamente consistente con un placebo no significativo y, aun así, representar un efecto válido para una población distinta a la que el equipo cree estar sirviendo.

31.2 Parte II: Panorama de *Reinforcement Learning* causal

31.2.1 De decisiones únicas a decisiones secuenciales

Todo el curso, hasta este punto, trató la decisión como una elección única: estimar un efecto, elegir una política, desplegarla. El RL estudia el caso donde un agente toma una **secuencia** de decisiones, cada una afectando el estado futuro del entorno y, por tanto, las decisiones siguientes —por ejemplo, un sistema de recomendación que decide qué mostrar en cada visita, sabiendo que la decisión de hoy afecta qué datos se observarán mañana—. El RL clásico optimiza esta secuencia asumiendo, casi siempre implícitamente, que el entorno reacciona a las acciones sin confusión oculta entre las decisiones pasadas del agente y las recompensas futuras. Bareinboim ((Bareinboim 2025), Capítulos 8–9) muestra que este supuesto falla con frecuencia en RL aplicado a datos observacionales —por ejemplo, cuando los datos de entrenamiento provienen de un agente humano anterior cuyas decisiones estaban confundidas por información que el nuevo agente no observa—, y que ignorar esta confusión produce políticas sistemáticamente sesgadas.

31.2.2 Bandits causales: el caso introductorio más simple

El caso más simple de esta frontera —un puente natural desde el *policy learning* del 21— son los **bandits causales** (Bareinboim et al. 2015): una versión del clásico problema de bandidos de múltiples brazos donde existen variables de contexto no observadas por el agente pero que sí afectaron las decisiones registradas en los datos históricos con los que se pre-entrena. Ignorar esta confusión —tratar los datos históricos como si las decisiones pasadas hubieran sido aleatorias— produce estimaciones de recompensa esperada por brazo tan sesgadas como ignorar la confusión en cualquier otro estimador de este curso.

El resultado que hace interesante este caso, y no solo una advertencia más, es que la solución **no** consiste en descartar los datos observacionales y explorar desde cero. Bareinboim, Forney y Pearl muestran que combinar la distribución observacional $P(y \mid x)$ con la interventiva $P(y \mid \text{do}(x))$ que el agente puede generar experimentando produce **cotas** sobre la recompensa de cada brazo más estrechas que las que cualquiera de las dos fuentes daría por separado, y que un agente que explota esas cotas converge a la política óptima estrictamente más rápido que uno que ignora los datos históricos. La confusión, en otras palabras, no es solo un problema a evitar: la **brecha** entre lo observacional y lo interventivo es información sobre la existencia de un confusor, y es explotable. La conexión con el 8 es directa —identificar qué información de contexto es segura de condicionar y cuál introduce sesgo de puerta trasera— pero la conclusión es más constructiva que en el resto del curso.

Zhang et al. (2019) extienden esta línea al caso de **regímenes de tratamiento dinámicos**: secuencias de decisiones donde cada acción afecta el estado sobre el que se toma la siguiente, la estructura de un tratamiento médico prolongado o de una intervención social por etapas. Es el escenario que más se parece a las decisiones reales de política pública, y también donde la confusión es más difícil de manejar, porque una variable puede ser simultáneamente confusor de una decisión posterior y mediador de una anterior —una situación que ningún ajuste por covariables resuelve y que exige el aparato de fórmulas g de Robins, fuera del alcance de este curso.

31.2.3 Por qué este curso se detiene aquí

RL causal es, en 2026, un programa de investigación activo más que un conjunto de recetas maduras y ampliamente adoptadas en producción —a diferencia de DML o los meta-learners de la Parte II, que ya cuentan con implementaciones estándar y una práctica de la industria asentada—. Este curso se detiene deliberadamente en el nivel de panorama conceptual: entender **por qué** la confusión importa en RL, y **cómo** se conecta con todo lo aprendido sobre identificación causal, sin pretender una cobertura de implementación que la madurez actual del campo no respalda todavía.

31.3 Ejercicios y notas bibliográficas

31.3.1 Ejercicios conceptuales

1. Explique por qué una prueba de placebo no significativa (Capítulo 14) no es evidencia suficiente de que un modelo reentrenado sea seguro de promover a producción, en el sentido del patrón *champion-challenger* de este capítulo.
2. Para el ejemplo de bandits causales de la 31.2.2, describa un escenario concreto (puede ser hipotético) donde ignorar la confusión en los datos históricos llevaría a un agente a subestimar sistemáticamente el valor de un brazo/acción poco explorada.

31.3.2 Ejercicio de infraestructura

1. Implemente el listado Listado 31.1 sobre dos versiones de su modelo del Notebook A2 (entrenadas sobre dos submuestras deliberadamente distintas del dataset, simulando un cambio de población). Verifique que el sistema correctamente marca la necesidad de revisión humana.

31.3.3 Notas bibliográficas

Huyen (2022), Capítulo 9, desarrolla en profundidad los patrones de aprendizaje continuo y pruebas en producción (incluyendo *champion-challenger* y *shadow deployment*) en su versión genérica para ML. Bareinboim (2025), Capítulos 8–9, es la referencia central del panorama de RL causal de este capítulo; Bareinboim et al. (2015) formaliza el caso introductorio de bandits causales y el resultado de que combinar datos observacionales e interventivos acelera la conver-

gencia; Zhang et al. (2019) lo extiende a regímenes de tratamiento dinámicos. La conexión de este capítulo con el 26 es directa y merece señalarse: la pregunta «¿puedo promover este *challenger*?» es, formalmente, la pregunta de si el efecto estimado sobre la población reciente transporta a la población que el servicio atiende — y el chequeo de `poblacion_comparable` es su versión operativa mínima.

Capítulo 32

El lado humano de los sistemas causales

Cuadro de decisión del capítulo

Decisión:	Comunicar resultados causales con sus supuestos e incertidumbre explícitos, incluso a audiencias no técnicas
Alternativas:	Comunicación simplificada (solo el número/la historia) vs. comunicación con supuestos e incertidumbre explícitos
Trade-off clave:	Claridad y persuasión inmediata vs. honestidad sobre los límites del hallazgo
Riesgo principal:	Que un resultado válido **bajo supuestos** se comunique y se use como si fuera una verdad incondicional

32.1 El problema de diseño

Cada capítulo de este libro terminó con una advertencia sobre límites y supuestos —la sección de «riesgos» en los capítulos de teoría, la de «señales de alerta» en los de ingeniería—. Ese cuidado se pierde con facilidad en el último paso, casi nunca técnico, del ciclo de vida de un sistema causal: comunicar el resultado a quien debe tomar una decisión con él. Huyen (2022) dedica su último capítulo a un punto que la formación técnica rara vez cubre: la mayoría de los proyectos de ML no fallan por un error de modelado, sino por una desconexión entre lo que el equipo técnico sabe sobre las limitaciones de su sistema y lo que la organización termina entendiendo y usando. Para un sistema causal, este riesgo es todavía mayor, porque la diferencia entre «X predice Y» y «X causa Y» —el problema con el que abrió este libro en el 1— es exactamente el tipo de matiz que se pierde primero en una comunicación simplificada.

32.2 Opciones y trade-offs

Opciones y trade-offs

- **Comunicación simplificada.** «El programa aumenta el ingreso en 12%.» Es clara, memorable y persuasiva —y es, con frecuencia, la única versión que sobrevive varias capas de resumen entre el equipo de datos y quien decide—. Su costo es que omite exactamente lo que este libro pasó 31 capítulos formalizando: bajo qué supuestos, para qué población, con qué incertidumbre.
- **Comunicación con supuestos e incertidumbre explícitos.** «El programa aumenta el ingreso en 12% (IC 95%: 8%–16%), estimado sobre la población que efectivamente participó, bajo el supuesto de que no hay factores no observados que determinen tanto la participación como el ingreso.» Es honesta y auditable, pero es más difícil de retener y, sin cuidado en la forma, puede sonar a que el equipo técnico «no está seguro de nada» — un riesgo real de que el matiz se interprete como debilidad del hallazgo en lugar de rigor.

La resolución de este trade-off no es elegir un extremo sino **estructurar** la comunicación en capas: un titular memorable, respaldado inmediatamente por los supuestos y la incertidumbre en un lugar visible y accesible, no enterrado en un apéndice que nadie lee.

Vale la pena añadir que la forma de comunicar la incertidumbre no es neutral, y que la literatura de comunicación de riesgo ha establecido regularidades que conviene aprovechar en lugar de redescubrir. Spiegelhalter (2019) documenta tres que aplican directamente aquí. Primera, las **frecuencias naturales** se comprenden mejor que las probabilidades o los porcentajes: «de cada 100 hogares que reciben el programa, entre 8 y 16 salen de la pobreza» se retiene y se razona mejor que «el efecto es del 12% (IC 95%: 8–16%)», aunque digan lo mismo. Segunda, los **riesgos relativos exageran sistemáticamente** la percepción del efecto: «duplica la probabilidad» es correcto y engañoso si la probabilidad basal es del 0.1%; reportar siempre el cambio absoluto junto al relativo. Tercera, y la más relevante para un resultado causal: la comunicación debe explicitar **sobre qué población** aplica el número, porque la audiencia asumirá por defecto que aplica a la suya.

Hay además una asimetría que conviene tener presente al decidir cuánto matizar. Sobreestimar la certeza de un resultado causal produce decisiones que fallan de forma silenciosa —el programa se implementa, no funciona, y rara vez se atribuye el fracaso al análisis—. Subestimarla produce, en el peor caso, que la decisión se posponga o se tome sin el análisis. Los dos errores tienen costos, pero solo el primero se disfraza de éxito, y esa es una razón práctica, no solo ética, para inclinarse por la comunicación con supuestos explícitos.

32.3 Decisión de referencia para el curso

El proyecto final del curso exige que todo resultado se comunique con una estructura de tres capas: **(i)** el hallazgo en una oración, en lenguaje no técnico; **(ii)** los supuestos de identificación y la población de validez, en un párrafo; **(iii)** el detalle técnico completo (el propio proyecto/notebook), para quien necesite auditarlo. Es, en esencia, la misma estructura de la *model card* causal del Capítulo 19, aplicada ahora a la comunicación con personas y no solo a la documentación de un artefacto.

32.4 Implementación de referencia: plantilla de comunicación

```
## Hallazgo
[Una oracion, en lenguaje no tecnico, sin jerga estadistica.]

## Lo que esto significa (y lo que no)
- Poblacion para la que es valido: [...]
- Principal supuesto detras del resultado: [...]
- Incertidumbre: [IC 95%, en unidades que la audiencia entienda]
- Este resultado NO implica: [ej.: "no implica que el efecto sea
  el mismo para poblaciones fuera del rango estudiado"]

## Detalle tecnico
[Enlace al notebook / proyecto / model card completos]
```

Listado 32.1: Plantilla de tres capas para comunicar un resultado causal.

32.5 Aplicación al sistema causal del curso: cierre

Este capítulo cierra el libro donde el Capítulo 1 lo abrió: con la distinción entre una pregunta asociativa y una pregunta causal. En el trayecto, el libro desarrolló dos hilos en paralelo. El primero, de identificación y estimación —SCM, criterio de puerta trasera, ortogonalidad de Neyman, DML, meta-learners, bosques causales, diseños de panel e instrumentales, descubrimiento de estructura— responde **qué tan bien** se puede responder una pregunta causal con los datos disponibles. El segundo, de ingeniería de sistemas siguiendo a (Huyen 2022) y (Kästner et al. 2024) —anatomía de un sistema, datos de entrenamiento, **features** sin fuga, despliegue, **model cards**, CI/CD, monitoreo, aprendizaje continuo— responde **cómo** llevar esa respuesta, de forma responsable y verificable, hasta quien la necesita. Ninguno de los dos hilos es completo sin el otro: un estimador impecable que nadie puede auditar en producción es tan poco útil como un servicio impecablemente desplegado que estima la pregunta equivocada. Este último capítulo, y esta plantilla de comunicación, son el punto donde ambos hilos finalmente le entregan algo a una persona que tiene que decidir.

32.6 Señales de alerta y checklist operativo

- ☐ El resumen ejecutivo de un resultado causal no menciona ningún supuesto ni intervalo de incertidumbre.
  ☐ Nadie fuera del equipo técnico sabe cuál es la población para la que el efecto estimado es válido.
  ☐ La comunicación usa lenguaje causal («X causa Y») para un resultado que, honestamente, solo respalda una afirmación asociativa o condicional.
  ☐ No existe una versión accesible (capa 1–2 de la plantilla) del resultado; solo existe el notebook técnico completo.

32.7 Ejercicios y notas bibliográficas

32.7.1 Ejercicios conceptuales

1. Tome el resultado del Notebook A2 de su proyecto (o cualquier estimación de este curso) y redáctelo usando la plantilla de tres capas del listado Listado 32.1.
2. Describa una situación —real o hipotética— en la que una comunicación simplificada de un resultado causal llevó, o podría llevar, a una decisión que el resultado técnico no respaldaba realmente.

32.7.2 Ejercicio de cierre (proyecto final)

1. Complete la plantilla de comunicación de tres capas para el sistema desplegado de su proyecto final, y agréguela como parte de la entrega junto con la **model card** del Capítulo 19.

32.7.3 Notas bibliográficas

Huyen (2022), Capítulo 11 («The Human Side of Machine Learning»), es la referencia central de este capítulo. Sobre comunicación de incertidumbre estadística a audiencias no técnicas, Spiegelhalter (2019) es la referencia práctica más útil —frecuencias naturales, riesgos absolutos frente a relativos, representación visual de la incertidumbre— y la fuente de las tres regularidades de la 32.2. Lipton (2018) complementa la discusión desde el otro lado: qué se le está pidiendo realmente a un modelo cuando se pide que sea «interpretable» o «explicable», y por qué esas demandas encubren objetivos distintos (confianza, causalidad, transferibilidad) que conviene separar antes de intentar satisfacerlos. Sobre las buenas prácticas de reporte de resultados causales en particular, véase (Imbens et al. 2015).

32.8 Comunicación efectiva de incertidumbre

La comunicación de incertidumbre causal a stakeholders no técnicos requiere visualizaciones claras y narrativas accesibles. (Spiegelhalter 2019) (Spiegelhalter 2019) proporciona un marco para comunicar resultados estadísticos con transparencia. Para visualización de riesgo y gráficos de incertidumbre, ver (Galesic et al. 2011) (Galesic & Garcia-Retamero 2011) sobre alfabetización gráfica cross-cultural.

Principios clave:

- Usar intervalos de confianza visuales en lugar de solo estimados puntuales
- Comunicar bounds cuando la identificación es parcial
- Explicar supuestos de identificación en lenguaje no técnico
- Proveer contexto sobre magnitud práctica (¿es el efecto grande?)

Apéndice A

Notación, convenciones y fundamentos matemáticos

A.1 Notación general

A lo largo de esta monografía se emplean las siguientes convenciones notacionales, salvo que se indique explícitamente lo contrario.

Símbolo	Significado
R	Conjunto de los números reales
N	Conjunto de los números naturales
$\mathbf{1}\{\cdot\}$	Función indicadora
$P(\cdot)$	Medida de probabilidad
$E[\cdot]$	Esperanza matemática
$\mathrm{Var}(\cdot)$	Varianza
$\mathrm{Cov}(\cdot,\cdot)$	Covarianza
$\mathbb{P}_n$	Medida empírica $\left(\frac{1}{n}\right)\sum_{i=1}^{n}\delta_{W_i}$
$\mathbb{G}_n$	Proceso empírico $\sqrt{n}(\mathbb{P}_n - P)$
$O_{p(\cdot)}$, $o_{p(\cdot)}$	Órdenes en probabilidad
$O(\cdot)$, $o(\cdot)$	Órdenes deterministas
$\xrightarrow{p}$	Convergencia en probabilidad
$\xrightarrow{d}$	Convergencia en distribución
$\xrightarrow{L^2}$	Convergencia en media cuadrática
$\xrightarrow{\text{a.s.}}$	Convergencia casi segura
$\perp\!\!\!\perp$	Independencia
$\mid$	Condicionamiento
$\|x\|_p$	Norma p de un vector ($\|x\|_2$ euclídea)
$\|M\|_F$	Norma de Frobenius de una matriz
$\|M\|_*$	Norma nuclear de una matriz
∇	Gradiente
∂	Derivada parcial o derivada de Fréchet
$\mathbf{1}_n$	Vector de unos de longitud n
I_n	Matriz identidad de $n \times n$
$a_n \lesssim b_n$	$a_n \le C b_n$ para alguna constante $C > 0$
$a_n \asymp b_n$	$a_n \lesssim b_n$ y $b_n \lesssim a_n$

Tabla 1.1: Símbolos y convenciones notacionales.

Para variables aleatorias se usan mayúsculas (X, Y, D) y para realizaciones concretas minúsculas (x, y, d). Los vectores y matrices se denotan en negrita ($\boldsymbol{X}$, $\boldsymbol{\beta}$). La norma $L^2(P)$ de una función f se escribe $\|f\|_{P,2} = \sqrt{\int f^2 \, \mathrm{d}P}$.

A.2 Modos de convergencia

Definición 1.1 ***(Convergencia en probabilidad)***

$X_n \xrightarrow{p} X$ si para todo $\varepsilon > 0$, $P(\|X_n - X\| > \varepsilon) \to 0$.

Definición 1.2 ***(Convergencia en distribución)***

$X_n \xrightarrow{d} X$ si $F_{X_n}(x) \to F_{X(x)}$ en todos los puntos de continuidad de F_X.

Definición 1.3 ***(Convergencia en L^2)***

$X_n \xrightarrow{L^2} X$ si $E\left[(X_n - X)^2\right] \to 0$.

La cadena de implicaciones es: $L^2 \Rightarrow p \Rightarrow d$. Las tasas de convergencia se expresan con la notación O_p y o_p.

A.3 Teoremas límite fundamentales

Teorema 1.4 ***(Ley débil de los grandes números)***

Si $X_1, ..., X_n$ son *i.i.d.* con $E\|X_i\| < \infty$, entonces $\overline{X}_n \xrightarrow{p} E[X]$.

Teorema 1.5 ***(Teorema central del límite)***

Si $X_1, ..., X_n$ son *i.i.d.* con $\text{Var}(X_i) = \sigma^2 < \infty$, entonces $\sqrt{n}\left(\overline{X}_n - \mu\right) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

Teorema 1.6 ***(Slutsky)***

Si $X_n \xrightarrow{d} X$ e $Y_n \xrightarrow{p} c$, entonces:

- $X_n + Y_n \xrightarrow{d} X + c$,
- $X_n Y_n \xrightarrow{d} cX$,
- $\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}$ si $c \neq 0$.

A.4 Teoría asintótica semiparamétrica

A.4.1 Espacios tangentes

Sea $\mathcal{P}$ una familia de distribuciones parametrizada por (θ, η), donde $\theta \in R^d$ es el parámetro de interés y η es un parámetro *nuisance* infinito-dimensional. El *espacio tangente* en $\mathcal{P}_0$ es el *closure* del espacio generado por los *scores* de un submodelo paramétrico que pasa por $\mathcal{P}_0$.

Definición 1.7 ***(Pathwise derivative)***

Para un submodelo $t \to P_t$ con $P_0 = P$, el score *pathwise* es $s = \frac{\mathrm{d}}{\mathrm{d}t} \log p_t \mid_{t=0}$. El *efficient influence function* (EIF) es la proyección del score de θ sobre el espacio tangente.

A.4.2 Estimación semiparamétrica eficiente

Teorema 1.8 ***(Cota de Cramér-Rao semiparamétrica)***

La varianza asintótica mínima de un estimador regular de θ es $\tilde{I}_\theta^{-1}$, donde $\tilde{I}_\theta$ es la *información eficiente*: la varianza del EIF.

Teorema 1.9 ***(Bickel, Klaassen, Ritov & Wellner, 1993)***

Bajo regularidad, un estimador $\hat{\theta}$ es *asintóticamente eficiente* si y solo si su *influence function* iguala el EIF.

A.5 Ortogonalidad de Neyman

La ortogonalidad de Neyman (capítulo 10) es una propiedad del *score* que lo hace insensible en primer orden a errores de estimación de los *nuisance parameters*. Formalmente:

Definición 1.10 ***(Score Neyman-ortogonal)***

Un score $\psi(W, \theta, \eta)$ es Neyman-ortogonal en (θ_0, η_0) si para toda perturbación $\eta - \eta_0$ en una vecindad:

$$\partial_\eta E[\psi(W, \theta_0, \eta)] \mid_{\eta=\eta_0} [\eta - \eta_0] = 0. \tag{1.106}$$

Esta propiedad es la base del teorema central de DML del capítulo 10.

A.6 Cross-fitting y sample splitting

El *cross-fitting* preserva la independencia entre el estimador de *nuisance* y el score evaluado en la muestra principal. La idea es dividir la muestra en K *folds*; para cada *fold*, estimar $\hat{\eta}$ en los $K-1$ *folds* restantes y evaluar el score en el *fold* k. Esto evita el *overfitting bias* sin desperdiciar datos.

A.7 Honesty en árboles causales

La *honesty* (capítulo 13) es el análogo para árboles del *cross-fitting*: la muestra usada para decidir las divisiones del árbol es distinta de la usada para estimar el CATE dentro de cada hoja. Sin *honesty*, el árbol selecciona divisiones que maximizan la diferencia observada entre tratados y controles, introduciendo sesgo.

A.8 Norma nuclear y matrix completion

La *norma nuclear* de una matriz L es $\|L\|_* = \sum_i \sigma_{i(L)}$, donde σ_i son los valores singulares. Es la envolvente convexa del *rank*, lo que permite formular el problema de *matrix completion* (capítulo 28) como optimización convexa.

Teorema 1.11 ***(Recht, Fazel & Parrilo, 2010)***

Bajo *incoherence* y muestreo aleatorio suficientemente denso, la minimización de norma nuclear recupera exactamente la matriz de bajo rango subyacente.

A.9 Modelos causales estructurales

Un modelo causal estructural describe cada variable como función de sus causas directas más ruido:

$$X_j = f_{j(\mathrm{PA}_j, U_j)} \tag{1.107}$$

donde PA_j son los padres causales de X_j y U_j son factores no observados independientes.

Tres niveles de preguntas causales:

1. Asociación: $P(Y \mid X)$ — «¿Qué dice la data?»
2. Intervención: $P(Y \mid \mathrm{do}(X = x))$ — «¿Qué pasa si intervengo?»
3. Contrafactual: $P(Y_x \mid X = x', Y = y')$ — «¿Qué habría pasado si…?»

Para pasar del nivel 1 al 2 se necesitan supuestos de identificación (no confusión, exclusión, etc.). El ML predictivo opera en nivel 1; la evaluación de políticas requiere nivel 2.

A.10 Influence functions

La *influence function* (IF) de un estimador $\hat{\theta}$ nos dice cómo cambia $\hat{\theta}$ si modificamos una observación:

$$\hat{\theta} - \theta_0 \approx \left(\frac{1}{n}\right) \sum_{i=1}^{n} \psi(W_i, \theta_0, \eta_0) \tag{1.108}$$

Ejemplos:

- **ATE bajo IRM:** $\psi_i = \mu_1(X_i) - \mu_0(X_i) + \frac{D_i(Y_i - \mu_1(X_i))}{e(X_i)} - \frac{(1-D_i)(Y_i - \mu_0(X_i))}{1-e(X_i)} - \theta$
- **PLR (Robinson):** $\psi_i = v_i(u_i - \theta v_i)$, con $v_i = D_i - e(X_i)$, $u_i = Y_i - l(X_i)$

Ambas IF alcanzan la cota semiparamétrica de sus funcionales: el Teorema de eficiencia del DML-IRM (11.2.2) para IRM, y (Chernozhukov et al. 2018b) para PLR.

La varianza asintótica es $\mathcal{V} = E[\psi_i^2]$. La ortogonalidad garantiza que errores en η no contaminan θ en primer orden.

A.11 Regresión Discontinua (RDD)

Cuando el tratamiento se asigna según un umbral c en una variable continua X:

$$\tau_{\mathrm{RD}} = \lim_{x \to c^+} E[Y \mid X = x] - \lim_{x \to c^-} E[Y \mid X = x] \tag{1.109}$$

Si el cumplimiento es imperfecto (*fuzzy RDD*):

$$\tau_{\mathrm{FRD}} = \frac{\lim_{x \to c^+} E[Y \mid X = x] - \lim_{x \to c^-} E[Y \mid X = x]}{\lim_{x \to c^+} E[D \mid X = x] - \lim_{x \to c^-} E[D \mid X = x]} \tag{1.110}$$

El RDD difuso puede interpretarse como IV local donde el umbral es el instrumento.

A.12 Transportabilidad

Un efecto causal estimado en población A ¿puede aplicarse a población B? La respuesta depende de:

- **Covariate shift:** la distribución de X cambia entre A y B. Si el efecto es condicional en X y X captura toda la heterogeneidad, puede ser transportable.
- **Target shift:** la relación $Y_x \mid X$ cambia entre poblaciones. Se requieren diagramas de selección para decidir.

Un diagrama de selección incluye un nodo S que indica si una observación pertenece a la población fuente o destino. Si $Y \perp\!\!\!\perp S \mid X$, el efecto es directamente transportable.

Apéndice B

Guía de librerías y entorno reproducible

B.1 Entorno reproducible

Para garantizar la reproducibilidad de los experimentos y facilitar la instalación de todas las dependencias necesarias, se recomienda el uso de entornos virtuales gestionados con `conda` o `venv`. A continuación se describe la configuración base utilizada en los ejemplos de este apéndice.

La gestión de dependencias puede realizarse mediante un archivo `requirements.txt` o un archivo `environment.yml` de Conda. Ambas opciones permiten fijar versiones específicas de cada librería, asegurando que los resultados sean replicables en diferentes sistemas.

B.2 econml (Microsoft Research)

Propósito. Implementación de métodos de ML causal desarrollada por Microsoft Research. Es la librería más completa para estimación de CATE.

Módulos principales.

- `econml.dml`: Double Machine Learning (`LinearDML`, `CausalForestDML`, `SparseLinearDML`).
- `econml.metalearners`: S/T/X-learners (`SLearner`, `TLearner`, `XLearner`).
- `econml.policy`: Policy trees y forests (`PolicyTree`, `PolicyForest`).
- `econml.iv`: Variables instrumentales (`DeepIV`, `OrthoIV`).
- `econml.orf`: Orthogonal Random Forests.
- `econml.score`: Validation scores (`RScorer`); fundamento y protocolo de uso: §14.4.3 (RATE).

Ejemplo canónico.

```
from econml.dml import LinearDML
est = LinearDML(model_y=..., model_t=..., discrete_treatment=True, cv=5)
est.fit(Y, D, X=X)
ate = est.ate(X=X); cate = est.effect(X)
```

Listado 2.1: Instalaci'on de librer'ias complementarias.

B.3 DoubleML

Propósito. Implementación del marco DML de Chernozhukov et al. (2018) con foco en inferencia rigurosa.

Módulos principales.

- `DoubleMLPLR`: Partial Linear Model.
- `DoubleMLIRM`: Interactive Regression Model.
- `DoubleMLPLIV`: Partial Linear IV Model.
- `DoubleMLIIVM`: Interactive IV Model.

Diferencia con econml. `DoubleML` está más orientado a inferencia (IC, tests); `econml` está más orientado a estimación de CATE. Complementarios.

B.4 causalml (Uber)

Propósito. Librería de Uber para *uplift modeling* y *meta-learners*. Fuerte en aplicaciones de marketing.

Módulos principales.

- `causalml.inference.meta`: S/T/X/R-learners con varias *base learners* (XGBoost, MLP).
- `causalml.metrics`: Qini, AUUC, *uplift curves*.
- `causalml.optimize`: Optimización de políticas bajo restricciones presupuestarias.
- `causalml.propensity`: Estimación de *propensity score* con varios modelos.

En versiones recientes, usar `BaseSRegressor`, `BaseTRegressor`, `BaseXRegressor` o `BaseRRegressor` con un *learner* base (por ejemplo, `XGBRegressor`).

B.5 dowhy (Microsoft AWS)

Propósito. Framework de inferencia causal que integra identificación (con DAGs), estimación (con varios métodos), y refutación (*placebo tests*, sensibilidad).

Pipeline.

1. **Modelado:** definir tratamiento, *outcome*, y DAG con `CausalModel`.
2. **Identificación:** `model.identify_effect()` aplica el criterio de puerta trasera.
3. **Estimación:** `model.estimate_effect()` con método elegido (*matching*, IPW, PDS, DML).
4. **Refutación:** `model.refute_estimate()` con *placebos* y sensibilidad.

B.6 PyTorch

Propósito. Framework de *deep learning*. Usado en este curso para implementaciones *from-scratch* de TARNet, CFRNet, DeepIV.

Patrones comunes en ML causal.

```
class RepresentationNet(nn.Module):
    def __init__(self, in_dim, rep_dim):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(in_dim, 128), nn.ReLU(),
            nn.Linear(128, 64), nn.ReLU(),
            nn.Linear(64, rep_dim),
        )
    def forward(self, X):
        return self.net(X)
```

Listado 2.2: Red de representación para TARNet/CFRNet en PyTorch.

B.7 scikit-learn

Propósito. Base para todos los *learners* de ML. `RandomForestRegressor`, `GradientBoostingRegressor`, `LassoCV`, `LogisticRegressionCV` son los componentes básicos de DML.

B.8 networkx

Propósito. Manipulación de grafos. Útil para visualizar DAGs y construir estructuras causales antes de pasar a `dowhy`.

B.9 statsmodels

Propósito. Estimación econométrica clásica (OLS, 2SLS, IV) y tests estadísticos. Útil para *benchmarks* y comparaciones con métodos de ML.

B.10 Tabla comparativa

Librería	Foco	Fortaleza	Limitación
`econml`	CATE	Más completo	Curva de aprendizaje alta
`DoubleML`	Inferencia	IC rigurosos	Foco en ATE/ATT/LATE; menos orientado a CATE heterogéneo que `econml`
`causalml`	Uplift	Métricas de marketing	Menos actualizado
`dowhy`	Pipeline	Identificación + refutación	Estimación delegada
`PyTorch`	Deep causal	Flexibilidad total	Requiere experiencia
`scikit-learn`	Base	Estándar	No causal específico

Tabla 2.1: Comparación de librerías.

B.11 Instalación recomendada

```
pip install econml doubleml causalml dowhy torch scikit-learn networkx
statsmodels shap
```

Listado 2.3: Instalación del stack base de librerías de ML causal.

B.11.1 Librerías complementarias

Librería	Foco	Fortaleza	Limitación
`DoWhy`	Identificación y refutación	Pipeline causal completo	Estimación delegada a otras librerías
`causal-learn`	Causal discovery	PC, FCI, GES implementados	Curva de aprendizaje alta
`cdt`	Discovery toolbox	Muchos algoritmos en un lugar	Mantenimiento variable
`pgmpy`	Modelos gráficos	Grafos de probabilidad	No siempre causal
`geomloss`	Distancias Wasserstein/MMD	Útil para CFRNet	Requiere GPU opcional
`POT`	Transporte óptimo	Flexible y bien documentado	Costo computacional alto
`linearmodels` / `fixest`	IV, panel y DiD	Econometría clásica rápida	No incluye ML

Tabla 2.2: Librerías complementarias.

Instalación opcional:

```
pip install dowhy causal-learn cdt pgmpy geomloss POT linearmodels
```

Listado 2.4: Instalaci'on de librer'ias complementarias.

Apéndice C

Datos, DGP y benchmarks

C.1 Datasets reales

Dataset	Diseño	Estimando	Caps.	Notas
`nsw_mixtape`	Obs.	ATE, CATE	1, 4–6, 11	Lalonde (1986)
`close_college`	IV	ATE (LATE)	1, 4, 8, 9, 15	Card (1995)
`cps_mixtape`	Obs.	ATE	1, 4, 8	CPS extract
`nhefs`	Obs.	ATE, CATE	8	51 controles útiles
`gov_transfers`	Obs.	ATE, CATE	6, 11, 12, 16	Transferencias
`texas`	SCM	ATT	14	Ley aborto Texas
`castle`	SCM	ATT	14	Castle doctrine
`abortion`	SCM	ATT	14	Legalización aborto
`thornton_hiv`	RCT	ATE, CATE	7, 12	Tests VIH
`close_elections_lmb`	RDD	LATE	7	Lee (2008)
`organ_donations`	DiD	ATT	14	Donación órganos
`mortgages`	Obs.	ATE	6	Hipotecas

Tabla 3.1: Datasets reales del repositorio.

C.2 Datasets sintéticos

Dataset	Diseño	Estimando	Caps.	Notas
`panel_fe_dynamic`	Panel	ATE	9	τ_i conocido
`did_parallel_ok`	DiD	ATT	9, 14	Tendencias paralelas
`did_parallel_violation`	DiD	ATT	9	TP violadas
`staggered_twfe_bias`	DiD stag.	ATT	9, 14	Sesgo TWFE
`iv_noncompliance`	IV	LATE	9	Cumplimiento varía
`iv_invalid_exclusion`	IV	LATE	9	Exclusión violada
`matching_hidden_conf`	Matching	ATE	1, 5	Confusor oculto
`mediation_post_treatment`	Med.	Direct eff.	9	Sesgo post-trat.
`rct_attrition`	RCT	ATE	7	Attrition
`rdd_sharp_bandwidth`	RDD	LATE	7	Sharp design
`rdd_fuzzy_manipulation`	RDD	LATE	7	Fuzzy + manip.
`scm_placebo`	SCM	ATT	14	Placebo sintético

Tabla 3.2: Datasets sintéticos con *ground truth*.

C.3 Estructura de archivos

Cada dataset real tiene:

- `data.csv`: datos en formato *tidy*.
- `source_metadata.json`: fuente, licencia, año, *variable dictionary*.
- `checksums.sha256.json`: integridad verificable.

Cada dataset sintético tiene:

- `student.csv`: datos visibles al estudiante (sin *ground truth*).
- `truth_instructor_only.csv`: *ground truth* (τ_i, θ, etc.) para evaluación del docente.
- `checksums.sha256.json`.

C.4 Recomendaciones de uso por capítulo

- **Capítulos 1–2 (intro, regularización):** usar `close_college` para motivación; sintéticos para ilustrar sesgo.
- **Capítulos 3–4 (DML):** `nsw_mixtape` para aplicación; sintético DML para verificar cobertura.
- **Capítulos 5–6 (meta-learners, forests):** sintético con CATE heterogéneo; `nsw_mixtape` (aplicación).
- **Capítulo 7 (validación):** sintético con *ground truth*; `thornton_hiv` para *placebos*.
- **Capítulo 8 (PDS):** `nhefs` para alta dimensión.
- **Capítulo 9 (panel):** `panel_fe_dynamic`.
- **Capítulos 11–12 (policy, uplift):** `gov_transfers`, `thornton_hiv`.

- **Capítulo 13 (deep causal):** sintético IHDP-like.
- **Capítulo 14 (SCM, MC):** `texas`, `scm_placebo`.
- **Capítulo 15 (discovery):** sintético con estructura causal conocida.

C.5 Datasets complementarios sugeridos

Dataset sugerido	Diseño causal	Uso en capítulo	Fuente
Progresa/Oportunidades	RDD	Capítulo 10 (RDD)	Evaluación de impacto
Minimum wage panel	DiD	Capítulo 9 (panel)	Literatura salario mínimo
Reemployment bonus	RCT	Capítulos 1, 4 (fundamentos)	Literatura seguros desempleo
Wage gap CPS	Double lasso	Capítulos 2, 8 (PDS)	CPS data
Growth convergence	PDS/DML	Capítulo 8 (alta dimensión)	Literatura crecimiento
IHDP-like	CATE benchmark	Capítulo 13 (deep causal)	Literatura deep causal
Text/product embeddings	CATE con texto	Capítulos 12–13	NLP / embeddings

Tabla 3.3: Datasets complementarios sugeridos.

Nota: algunos de estos datasets pueden no estar disponibles en el repositorio del curso. En ese caso, se sugiere usar un DGP sintético que emule las mismas características.

C.6 Ground truth y checksums

Los datasets sintéticos incluyen un archivo `truth_instructor_only.csv` que contiene los valores verdaderos de los parámetros causales (τ_i, θ, efectos directos e indirectos, etc.). Este archivo permite al instructor evaluar la precisión de las estimaciones obtenidas por los estudiantes sin revelar la solución.

Todos los datasets (reales y sintéticos) incorporan un archivo `checksums.sha256.json` con los hashes SHA-256 de cada fichero, calculados en el momento de la publicación. Para verificar la integridad de los datos descargados:

```
cd ruta/del/dataset
sha256sum -c checksums.sha256.json
```

Listado 3.1: Verificación de integridad de datasets con checksums SHA-256.

Si todos los ficheros coinciden, la salida mostrará `OK` para cada uno. Cualquier discrepancia indica que el archivo ha sido modificado o está corrupto, y se recomienda descargarlo nuevamente desde el repositorio oficial.

Los *checksums* aplican tanto a los datos de estudiante como a los archivos de *ground truth*, garantizando que la evaluación se realice sobre la versión exacta del dataset prevista por el instructor.

Apéndice D

Glosario de estimandos, supuestos y métodos

D.1 Estimandos

ATE (Average Treatment Effect)	$\theta = E[Y(1) - Y(0)]$. Efecto promedio del tratamiento en la población.
ATT (Average Treatment Effect on the Treated)	$\theta_{\text{ATT}} = E[Y(1) - Y(0) \mid D = 1]$. Efecto promedio en los tratados.
CATE (Conditional Average Treatment Effect)	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$. Efecto promedio condicional en $X = x$. Estimando central del curso.
LATE (Local Average Treatment Effect)	Efecto del tratamiento en los *compliers*: individuos cuyo tratamiento es afectado por el instrumento.
ETT (Effect of Treatment on the Treated)	$E[Y(1) - Y(0) \mid D = 1]$.
Policy value	$V(\pi) = E[Y(\pi(X))]$. Bienestar esperado bajo la regla de asignación π.
Uplift	En marketing, sinónimo de CATE. Diferencia en probabilidad de conversión entre tratados y controles condicional en covariables.
Regret (welfare regret)	$\text{Regret}(\hat{\pi}) = V(\pi^*) - V(\hat{\pi})$. Pérdida de bienestar por usar $\hat{\pi}$ en lugar de π^*.

D.2 Supuestos

Unconfoundedness	$Y(0), Y(1) \perp\!\!\!\perp D \mid X$. Supuesto de que no hay confusores no observados condicional en X.
Overlap / soporte común	Supuesto de que $\eta < P(D = 1 \mid X = x) < 1 - \eta$ para algún $\eta > 0$ y todo x. Garantiza que hay información tanto de tratados como de controles en cada región del espacio de covariables.
$\underline{e}$	Cota inferior de soporte común: $\underline{e} < P(D = 1 \mid X = x) < 1 - \underline{e}$ para todo x.
SUTVA (Stable Unit Treatment Value Assumption)	Supuesto de no interferencia entre unidades y de versiones únicas del tratamiento.
Causal sufficiency	Supuesto de que no hay confusores no observados que afecten a dos o más variables del grafo causal. Requerido por algoritmos de *causal discovery*.
Sparsity	Supuesto de que el vector verdadero de coeficientes tiene pocas componentes no nulas. Requerido por LASSO y PDS.
Restricted eigenvalue (RE)	Condición sobre la matriz de diseño que garantiza la **tasa** de convergencia ℓ_2 del LASSO. Relativamente débil. No basta para recuperar el soporte.
Irrepresentabilidad	Condición sobre la correlación entre variables activas e inactivas, necesaria y esencialmente suficiente para que el LASSO recupere el **con-**

	junto de variables verdaderamente no nulas. Mucho más fuerte que RE y no verificable en la práctica (6).
Faithfulness	Supuesto de que toda independencia condicional presente en la distribución corresponde a una d-separación en el grafo. Requerido por los algoritmos de descubrimiento basados en restricciones.
Transportabilidad	Validez de un efecto estimado en un dominio Π cuando se aplica a un dominio distinto Π^*. Se decide sobre un **diagrama de selección** (26).
Generalización (validez externa)	Caso particular de transportabilidad en que el problema es la **selección muestral**: si el efecto estimado sobre la muestra observada vale para la población de la que se extrajo.
Equidad contrafactual	Una decisión es justa si no cambia al modificar solo el atributo protegido, manteniendo lo que no depende causalmente de él.

D.3 Métodos

DML (Double/Debiased Machine Learning)	Marco de estimación causal que combina ortogonalidad de Neyman con *cross-fitting* para permitir inferencia válida cuando los *nuisance* se estiman con ML.
Cross-fitting	Partición de la muestra en K *folds*; para cada *fold* k, el *learner nuisance* se entrena en los $K-1$ *folds* restantes y

	predice en el *fold* k. Evita *overfitting bias* sin desperdiciar datos.
Sample splitting	División de la muestra en dos partes: una para estimar *nuisance*, otra para estimar el parámetro causal. Caso especial de *cross-fitting* con $K = 2$.
Post-Double-Selection (PDS)	Procedimiento de Belloni, Chernozhukov & Hansen (2014) para selección de confusores en alta dimensión sin sesgo post-selección.
R-learner	Meta-learner que optimiza el *score* ortogonal de Robinson. Alcanza tasas cuasi-oracle para CATE; la eficiencia $\sqrt{n}$ aplica a funcionales como el ATE o clases paramétricas de $\tau(x)$.
DR-learner	Meta-learner *doubly robust* que regresa sobre X el pseudo-*outcome* Γ_i (score IRM antes de promediar). Su error depende de los *nuisance* a través del **producto** de sus errores, no de su suma (12).
Score de Robinson	$\psi = (D - m(X))\{Y - l(X) - \theta(D - m(X))\}$, con $l_0(X) = E[Y\|X]$ y $m_0(X) = E[D\|X]$. Base del PLR de DML y de la *loss* del R-learner.
Cálculo-do	Conjunto de tres reglas de reescritura que transforman expresiones con do() en expresiones observacionales. **Completo**: si sus reglas no identifican el efecto, ningún método lo hace con ese grafo (8).
Puerta trasera (*backdoor*)	Criterio gráfico para elegir un conjunto de ajuste Z válido. Corolario del cálculo-do.
Puerta delantera (*front-door*)	Criterio de identificación vía un mediador que capta todo el efecto, aplicable cuando existe confusión no observada y ningún ajuste por covariables funciona.
EWM (Empirical Welfare Maximization)	Elección de la política que maximiza el *welfare* empírico sobre una clase

	Π de VC-dimensión finita. Regret $O\left(\sqrt{\mathrm{VC}(\Pi)/n}\right)$ (Kitagawa & Tetenov, 2018).
Net score	$s_k(x) = \tau_k(x) - \lambda c_k(x)$, con λ el costo sombra de la restricción presupuestaria. Base de la asignación multi-tratamiento (22).
RA-learner	*Regression Adjustment* learner: $\hat{\tau}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$.
Honesty (en árboles causales)	Restricción por la cual la partición del árbol se decide usando una submuestra distinta de la que se usa para estimar el efecto dentro de cada hoja. Garantiza validez asintótica de los IC.
IPW (Inverse Probability Weighting)	Estimador que usa el inverso del *propensity score* para ponderar unidades y reconstruir el contrafactual.
IPM (Integral Probability Metric)	Métrica de distancia entre distribuciones. Usada en CFRNet para forzar balance entre representaciones de tratados y controles.
MMD (Maximum Mean Discrepancy)	Distancia entre distribuciones usada en CFRNet.
Propensity score	$e(x) = P(D = 1 \mid X = x)$. Probabilidad de recibir tratamiento condicional en covariables.
IPS (Inverse Propensity Scoring)	Ponderación por la inversa del *propensity score*.
SNIPS (Self-Normalized IPS)	Versión normalizada de IPS.
$\boldsymbol{e_0(x)}$	Propensity score: $e_0(x) = E[D \mid X = x]$. En el modelo PLR se denota también como $m_0(x)$.
$\boldsymbol{\mu_{d(x)}}$	*Outcome* condicional: $\mu_{d(x)} = E[Y \mid X = x, D = d]$. Equivalente a $\mu(d, x)$.
$\boldsymbol{\omega_{i(x)}}$	Pesos locales inducidos por un bosque causal / *Generalized Random Forest*. El estimador del CATE se obtiene resolviendo $\sum_i \omega_{i(x)} \cdot \psi_{i\left(\hat{\theta}(x)\right)} = 0$.

$Y_i^\star$ (*Transformed outcome*)	$Y_i^\star = Y_i \cdot \frac{D_i - e_0(X_i)}{e_0(X_i)(1-e_0(X_i))}$. Su esperanza condicional es $E[Y^\star \mid X] = \tau(X)$.
$\mathcal{C}$	Conjunto de ajuste que satisface el criterio de puerta trasera de Pearl.
ζ	Error del instrumento en el modelo PLIV: $Z = r_0(X) + \zeta$.
SCM (Structural Causal Model)	Modelo que describe cada variable como función de sus causas directas más ruido exógeno.
NCM (Neural Causal Model)	Red neuronal que parametriza un SCM.
DAG (Directed Acyclic Graph)	Grafo dirigido acíclico que representa relaciones causales directas entre variables.
PCH (Pearl Causal Hierarchy)	Jerarquía de tres niveles: asociación, intervención, contrafactual.
do($X = x$)	Operador de intervención: representa la acción de fijar X en el valor x, rompiendo sus causas.
Contrafactual	Resultado potencial bajo una intervención que no ocurrió: «¿Qué habría pasado si…?».
FCI (Fast Causal Inference)	Algoritmo de descubrimiento causal que permite variables latentes.
GES (Greedy Equivalence Search)	Algoritmo de descubrimiento basado en *score*.
Synthetic DiD	Combinación de control sintético y diferencias-en-diferencias.
RDD (Regression Discontinuity Design)	Diseño causal basado en un umbral.
Fuzzy RDD	RDD con cumplimiento imperfecto del umbral; se estima como IV local.
Off-policy evaluation	Estimación del valor de una política usando datos generados por otra política.
Nuclear norm	$\|L\|_* = \sum_i \sigma_{i(L)}$. Envolvente convexa del *rank*. Usada en *matrix completion*.

D.4 Garantías

Neyman orthogonality	Propiedad de un *score* cuya derivada de Gateaux respecto a los parámetros *nuisance* es cero en el valor verdadero. Permite que errores de estimación de *nuisance* solo afecten la inferencia causal en segundo orden.
EIF (Efficient Influence Function)	Proyección del *score* del parámetro de interés sobre el espacio tangente. Determina el límite semiparamétrico de Cramér-Rao.
Doubly robust	Propiedad de un estimador que es consistente si al menos uno de dos modelos (*outcome regression* o *propensity score*) es consistente. No requiere ambos.
$\mathcal{V}$	Varianza asintótica de estimadores como DML o PDS: $\sqrt{n} \cdot \left(\hat{\theta} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V})$.

D.5 Diagnósticos

Curva Qini	*Qini curve*. Curva de validación de *ranking* causal: *uplift* acumulado en función de la fracción de muestra ordenada por CATE estimado. Mide la calidad del *ranking*, no la calibración absoluta de $\hat{\tau}$.
AUUC (Area Under Uplift Curve)	Área bajo la curva *uplift*. Métrica de **ranking**, no de calibración: es invariante a reescalar $\hat{\tau}$. Solo comparable entre modelos evaluados sobre la misma muestra.
Coeficiente Qini	AUUC normalizada restando el *baseline* aleatorio y dividiendo por el modelo perfecto. Comparable entre datasets.
E-value	$\mathrm{E} = \mathrm{RR} + \sqrt{\mathrm{RR}(\mathrm{RR}-1)}$. Fuerza mínima de asociación que un confusor no observado debería tener con tratamiento y resultado para explicar el efecto observado. Cota necesaria, no suficiente (14).
SMD / ASMD	Diferencia media estandarizada (absoluta). Tamaño de efecto invariante a n para medir desbalance. Criterio de Rubin: $\lvert\mathrm{SMD}\rvert < 0.25$ y razón de varianzas en $[0.5, 2]$.

PSI (Population Stability Index)	$\sum_b (p_b - q_b)\log(p_b/q_b)$ sobre *bins*. Convención de industria para *drift*: < 0.1 estable, > 0.25 deriva material. Sin respaldo teórico canónico.
Descomposición de Goodman-Bacon	Descomposición del estimador TWFE en comparaciones 2×2 ponderadas; revela las comparaciones «prohibidas» contra unidades ya tratadas y los pesos negativos (17).
Equidad en el efecto (*equalized CATE*)	Métrica de equidad **específica de sistemas causales**: la distribución del CATE estimado es similar entre grupos. No pertenece al canon de *fair ML* (24).
SHD (Structural Hamming Distance)	Número de aristas que difieren entre dos grafos.
CPDAG	Grafo parcialmente dirigido que representa una clase de equivalencia de Markov: el máximo que puede identificarse de la estructura con datos observacionales.

Apéndice E

Plantilla de proyecto final y rúbrica

E.1 Estructura del informe

El proyecto final debe seguir la siguiente estructura (10–15 páginas + apéndices):

1. **Resumen ejecutivo** (1 página). Pregunta económica, método principal, resultado central, recomendación de política.
2. **Introducción** (1–2 páginas). Motivación económica, contexto, pregunta causal precisa, contribución.
3. **Marco de identificación** (2 páginas). Supuestos de identificación, justificación económica, DAG si aplica, estimando objetivo.
4. **Datos** (1–2 páginas). Descripción del dataset, *dataset card*, estadísticas descriptivas, balance observacional.
5. **Método** (2–3 páginas). Justificación metodológica usando el mapa del capítulo 18, especificación del estimador, selección de hiperparámetros.
6. **Resultados** (2–3 páginas). Estimación del ATE/CATE con IC, análisis de heterogeneidad, mapas de CATE si aplica.
7. **Validación** (1–2 páginas). *Placebos*, comparación con *benchmarks* clásicos, sensibilidad a hiperparámetros.
8. **Discusión** (1 página). Limitaciones, robustez, implicancias de política, consideraciones éticas.
9. **Conclusión** (0.5 página). Síntesis de hallazgos y recomendación final.
10. **Apéndices.** Código reproducible, gráficos adicionales, análisis de sensibilidad extendido.

E.2 Capa causal de la pregunta

El estudiante debe indicar:

- ¿La pregunta es de asociación, intervención o contrafactual?
- Estimando objetivo: ATE, ATT, CATE, LATE o *policy value*.
- Nivel en la jerarquía de Pearl (PCH) al que pertenece la pregunta.

E.3 DAG o supuesto estructural

Incluir:

- Grafo causal del problema.
- Variables observadas y no observadas.
- Criterio de identificación utilizado (*back-door*, *front-door*, instrumento, etc.).
- Justificación económica de cada arista incluida en el grafo.

E.4 Identificación

El estudiante debe detallar:

- Estimando objetivo formalmente definido.
- Supuestos de identificación y su justificación económica.
- Expresión del estimando en términos de la distribución observada.
- Si aplica, derivación del *score* ortogonal o función de influencia.
- Discusión de identificación parcial o sensible si los supuestos son débiles.

E.5 Estimación

Incluir:

- Elección del método justificada con el mapa de decisión del curso.
- Especificación de *learners nuisance* y criterios de selección de hiperparámetros.
- Estrategia de *cross-fitting* (número de *folds*).
- Construcción de intervalos de confianza.
- Código reproducible con semillas fijadas.

E.6 Validación y refutación

Incluir al menos dos de las siguientes pruebas:

- *Placebo treatment* (el ATE debe ser cero).
- *Random common cause* (el ATE no debe cambiar).
- *Subset validation* (resultado estable en submuestras).

Además, se recomienda:

- Comparación con estimadores clásicos (OLS, IPW, *matching*).
- Validación fuera de muestra de las predicciones *nuisance*.
- Pruebas de sensibilidad a la definición de tratamiento.

E.7 Análisis de sensibilidad

Incluir:

- Sensibilidad a hiperparámetros de los *learners*.
- Sensibilidad a *trimming* de *propensities* extremos.

- Protocolo de tres niveles del 14.2.5: E-value obligatorio; R^2 de Imbens / Cinelli–Hazlett si el estimador es tipo PLR; *bounds* de Manski si el *outcome* está acotado.

E.8 Transportabilidad

Incluir:

- Población de entrenamiento y población objetivo.
- Riesgos de desplegar el modelo fuera de la población de entrenamiento.
- Supuestos bajo los cuales el efecto se transporta (p. ej., RCT frente a población objetivo).

E.9 Ética y comunicación

Incluir:

- Auditoría de equidad: CATE promedio por grupo protegido.
- Explicación contrafactual de al menos una decisión.
- *Model card* o ficha del modelo con limitaciones.
- Tabla para tomadores de decisión con intervalos de confianza.

E.10 Criterios de evaluación

Dimensión	Criterio	Peso
Pregunta económica	Clara, relevante, bien delimitada	10%
Identificación	Supuestos justificados económicamente, DAG si aplica	15%
Método	Justificado con mapa de decisión, hiperparámetros documentados	20%
Reproducibilidad	Código corre limpio, semillas fijadas, versiones declaradas	15%
Validación	*Placebos*, sensibilidad, comparación con *benchmarks*	15%
Heterogeneidad	CATE estimado con IC, subgrupos identificados	10%
Comunicación	Tablas claras, IC reportados, distinción predicción/causalidad	10%
Ética	Equidad discutida, sesgo algorítmico abordado si aplica	5%

Tabla 5.1: Rúbrica de evaluación del proyecto final.

E.11 Entregables

1. **Informe PDF** (10–15 páginas) siguiendo la estructura anterior.
2. **Notebook Jupyter** reproducible con código completo, comentarios y conclusiones.

3. **Datos** (o *script* de descarga si el dataset es externo).
4. **Defensa oral** (15 min + 5 min preguntas).

E.12 Ejemplos de problemas aplicados

- Efecto de un programa de capacitación sobre empleabilidad, con heterogeneidad por sector.
- Efecto de una reforma tributaria sobre inversión empresarial, con *staggered adoption*.
- Efecto de becas sobre deserción universitaria, con CATE por características socioeconómicas.
- Efecto de recordatorios sobre adherencia médica, con múltiples tratamientos.
- Efecto de una política monetaria sobre inflación, con variable instrumental.
- Optimización de *targeting* de transferencias gubernamentales bajo restricciones de equidad.

E.13 Plazos sugeridos

- **Semana 10:** propuesta de problema y dataset (1 página).
- **Semana 12:** entrega intermedia: identificación + EDA + método tentativo.
- **Semana 14:** entrega del borrador completo para revisión por pares.
- **Semana 16:** entrega final + defensa oral.

Apéndice F

Checklists por método

F.1 Checklist DML

- ☐ Supuesto de no confusión justificado. ☐ Soporte común verificado.
  ☐ *Nuisance* evaluado fuera de muestra. ☐ *Cross-fitting* correcto.
  ☐ *Influence function* calculada. ☐ Intervalos de confianza reportados.
  ☐ *Placebos* realizados. ☐ Sensibilidad a *learners* reportada.

F.2 Checklist meta-learners

- ☐ S-learner no confunde el efecto con las covariables (incluir interacciones).
  ☐ T-learner no sufre por desbalance extremo entre grupos.
  ☐ X-learner utilizado cuando hay desbalance entre tratados y controles.
  ☐ R-learner implementado con *cross-fitting* y *score* ortogonal.
  ☐ Modelos *nuisance* evaluados fuera de muestra.
  ☐ Meta-learner elegido según los supuestos del problema.
  ☐ Intervalos de confianza construidos por *bootstrap* o *influence function*.

F.3 Checklist causal forest

- ☐ *Honesty* garantizada en la construcción de los árboles.
  ☐ Número de árboles suficiente para estabilidad del CATE.
  ☐ Criterio de *splitting* basado en heterogeneidad de efectos.
  ☐ *Propensity scores* estimados y calibrados. ☐ Supuesto de *overlap* verificado.
  ☐ BLP/BEST/CLAN ejecutados vía `econml.validate.DRtester` β_2 reportado con p -valor.
  ☐ Inferencia válida para ATE y CATE.

F.4 Checklist PDS

- ☐ Supuesto de *sparsity* plausible en el contexto aplicado.
  ☐ Doble selección correctamente implementada (*outcome* y tratamiento).
  ☐ Parámetro λ seleccionado por validación cruzada.

- ☐ Inferencia post-selección válida (errores estándar no distorsionados).
- ☐ Número de regresores menor que el tamaño muestral.
- ☐ Errores estándar robustos a heterocedasticidad reportados.

F.5 Checklist panel/DMLIV

- ☐ Efectos fijos absorbentes de *shocks* comunes no observados.
- ☐ Errores estándar clusterizados a nivel de unidad *panel*.
- ☐ Instrumento válido (exogeneidad y exclusión justificadas).
- ☐ Instrumento relevante (F-statistic > 10 en primera etapa).
- ☐ *Cross-fitting* correcto para DMLIV.
- ☐ Test de sobreidentificación reportado si aplica.
- ☐ Inferencia robusta a instrumentos débiles si el F es bajo.

F.6 Checklist policy learning

- ☐ Criterio de bienestar (*policy value*) formalmente definido.
- ☐ Restricción de presupuesto especificada.
- ☐ Restricciones de equidad consideradas en la optimización.
- ☐ Política aprendida interpretable y comunicable.
- ☐ *Welfare regret* acotado.
- ☐ Política evaluada fuera de muestra.
- ☐ IC del *policy value* vía *influence function* (21.2.2); test de diferencia al comparar dos políticas.

F.7 Checklist uplift

- ☐ Curva Qini reportada y visualizada.
- ☐ Costos de intervención explícitamente definidos.
- ☐ *Ranking* de unidades estable en submuestras.
- ☐ Tratamiento y control balanceados en cada *fold*.
- ☐ AUUC reportado como métrica de *ranking*.
- ☐ Comparación con asignación aleatoria como *baseline*.

F.8 Checklist SCM/matrix completion

- ☐ Tendencia pre-tratamiento paralela verificada visualmente.
- ☐ *Pool* de *donors* adecuado y justificado.
- ☐ Rango de la matriz seleccionado por validación cruzada.
- ☐ *Placebo tests* en unidades *donors* reportados.
- ☐ Ajuste pre-tratamiento evaluado (RMSE).
- ☐ Sensibilidad a la composición del *donor pool* analizada.

F.9 Checklist causal discovery

- ☐ Supuestos del DAG explícitamente declarados.
  ☐ Supuesto de *faithfulness* razonable en el contexto.
  ☐ Estabilidad del grafo evaluada con submuestras.
  ☐ Confianza en aristas estimada por *bootstrap*.
  ☐ SHD reportado comparado con grafo *benchmark*.
  ☐ Orientación de aristas validada con conocimiento experto.

Apéndice G

Plantilla de *model card* causal

Este apéndice desarrolla en detalle la plantilla de *model card* causal introducida en el 19, con la explicación de cada campo y un ejemplo completo. Se usa para todo modelo publicado en Hugging Face Hub a lo largo del curso, incluido el proyecto final.

G.1 Campos obligatorios y su propósito

Campo	**Qué debe responder**
Estimando	¿Qué cantidad exacta se estima? (ATE, CATE(x), LATE, política óptima). No basta con nombrar la variable de resultado.
Diseño de identificación	¿Experimental, cuasi-experimental (panel, IV, RDD) u observacional puro? Determina qué tan defendible es el resultado sin supuestos adicionales.
Supuestos declarados	Lista explícita: no confusión condicional en qué covariables, soporte común, exclusión del instrumento si aplica, tendencias paralelas si aplica. Referencia al DAG cuando exista uno (8).
Población de entrenamiento	Las variables que delimitan la población (edad, geografía, período temporal, criterio de elegibilidad) — la información mínima para aplicar el criterio de transportabilidad del 26 antes de reusar el modelo.
Métricas	Efecto puntual, intervalo de confianza, tamaño de muestra, especificación del estimador (*learner*, número de *folds*); declarar si se reporta intervalo poblacional, individual (conforme), o ambos
Resultados de validación	Resultado de la prueba placebo (14) y del chequeo de balance (7) más recientes.
No usar este modelo para	Lista explícita de usos indebidos previsibles: poblaciones fuera de rango, decisiones individuales sin considerar el intervalo, reinterpretación del ATE como efecto garantizado.
Historial de versiones	Fecha de cada reentrenamiento, resultado del proceso *champion-challenger* (31) que lo promovió.

G.2 Plantilla completa

```
---
license: mit
tags: [causal-inference, <metodo-usado>]
---

# <Nombre del modelo>

## Estimando
<Que cantidad causal exacta estima este modelo.>

## Diseno de identificacion
<Experimental / cuasi-experimental / observacional. Justificacion breve.>

## Supuestos declarados
- No confusion condicional en: <lista de covariables>
- Soporte comun: <verificado / no verificado, como>
- <Otros supuestos especificos del diseno: exclusion del instrumento,
  tendencias paralelas, etc.>
- DAG (si existe): <enlace o referencia>

## Poblacion de entrenamiento
<Variables que delimitan la poblacion. Rango temporal. Fuente de datos.>
**No valido fuera de esta poblacion sin verificar transportabilidad.**

## Metricas
- Efecto estimado: <valor> (IC 95%: [<inf>, <sup>])
- n = <tamano de muestra>
- Especificacion: <learner, K-folds, etc.>

## Resultados de validacion
- Prueba placebo: <paso / no paso, fecha>
- Chequeo de balance: <resultado, fecha>

## No usar este modelo para
- <Uso indebido 1>
- <Uso indebido 2>

## Historial de versiones
| Version | Fecha | Cambio | Promovido por |
|---------|-------|--------|---------------|
| v1.0    | <fecha> | Version inicial | — |
```

Listado 7.1: Plantilla completa de *model card* causal, para copiar como `README.md` del repositorio en Hugging Face Hub.

G.3 Checklist antes de publicar

- ☐ Todos los campos obligatorios de la G.1 están completos, ninguno dice «N/A» sin justificación.
  ☐ La sección «No usar este modelo para» incluye al menos un uso indebido específico del dominio del modelo, no solo genérico.
  ☐ El `CausalSchema` (4) del modelo se subió junto con el artefacto serializado.
  ☐ La *model card* se actualizó en la misma publicación que cualquier reentrenamiento (ninguna versión del modelo circula con una *model card* desactualizada).

G.4 Esquema machine-readable (causal-model-card--v1.schema.json)

La *model card* Markdown es para personas; el endpoint `/metadata` (Listado 15.3) es el mismo contrato en tiempo de ejecución. Para que el contrato sea verificable por máquina —en el CI del 20 y por consumidores externos— se fija el siguiente JSON Schema versionado, cuyos campos corresponden 1:1 con los de la tabla de la G.1:

```
{
  "schema_version": "causal-model-card-v1",
  "estimando": {"tipo": "ATE|ATT|CATE|LATE|policy_value", "formula": "..."},
  "diseno_identificacion": {"tipo": "RCT|cuasi|observacional", "metodo":
"..."},
  "supuestos": [{"nombre": "no_confusion", "covariables": ["..."]},
                {"nombre": "soporte_comun", "verificado": true, "evidencia":
"ESS/n=0.82"}],
  "poblacion": {"variables_delimitadoras": {"edad": [24, 34]}, "fuente":
"..."},
  "metricas": {"efecto": 0.071, "ic95": [0.058, 0.084], "n": 3003,
               "spec": {"learner": "GBM", "K": 5, "dml_variant": "DML2"}},
  "validacion": {"placebo": {"paso": true, "fecha": "..."},
                 "blp_beta2_pvalor": 0.03},
  "no_usar_para": ["..."],
  "version": {"modelo": "v1.2", "hash_datos_entrenamiento": "sha256:..."}
}
```

Listado 7.2: Esquema JSON versionado de la *model card* causal, validable por máquina en el CI.

El CI del curso valida: (i) el esquema sintáctico; (ii) que cada supuesto declarado tenga evidencia asociada; (iii) que el *hash* coincida con el dataset de referencia versionado (20). El campo `dml_variant` exige nombrar DML1/DML2 (Nota técnica 10.2.4), cerrando el círculo entre la teoría y lo que el artefacto declara.

Apéndice H

Checklist de arquitectura de despliegue

Este apéndice sintetiza, en formato de decisión rápida, las opciones de arquitectura discutidas a lo largo de la segunda mitad del libro (Capítulos 2, 15, 19, 20, 30 y 31), para usarse como referencia al diseñar el componente de producción de un sistema causal nuevo.

H.1 Elegir el patrón de *serving*

Si...	**Entonces considere...**
Las unidades a evaluar no se conocen de antemano y llegan una a la vez	Servicio REST síncrono (15)
La población completa a evaluar es fija y conocida con anticipación	*Batch* precomputado
Todos los consumidores comparten el mismo entorno de Python y necesitan latencia mínima	Biblioteca embebida
Se necesita publicar para consumidores externos al equipo, en cualquier lenguaje	Servicio REST + publicación en Hugging Face Hub (19)

H.2 Checklist de la función de inferencia

- ☐ La función de inferencia es pura (sin estado mutable, sin efectos secundarios).
  ☐ El cálculo de *features* usa exactamente el mismo código en entrenamiento y en producción.
  ☐ La función usa el `CausalSchema` (4) para validar las covariables de entrada, no nombres de columna hardcodeados.
  ☐ La respuesta incluye intervalo de confianza y población de entrenamiento, no solo el efecto puntual (2).

H.3 Checklist de CI/CD

- ☐ El pipeline corre pruebas de software en cada *push* y pruebas estadísticas (placebo, balance) antes de publicar (20).
  ☐ Existe un dataset de referencia fijo y versionado para las pruebas estadísticas.
  ☐ La publicación al Hub está condicionada al resultado de ambos tipos de prueba, no solo de las de software.
  ☐ Ningún reentrenamiento se promueve a producción sin pasar por el proceso *champion-challenger* (31).

H.4 Checklist de monitoreo en producción

- ☐ Se monitorea el *drift* de covariables individuales, no solo de las predicciones agregadas (30).
  ☐ Cuando el diseño usa un instrumento, se monitorea su fuerza en ventanas recientes.
  ☐ Se monitorea la estabilidad del efecto estimado en ventanas móviles, comparada contra el intervalo de confianza original.
  ☐ Existe un proceso definido y documentado de qué hacer cuando el monitoreo dispara una alerta — no solo la alerta misma.

H.5 Checklist de comunicación

- ☐ Todo resultado comunicado fuera del equipo técnico sigue la plantilla de tres capas del 32.
  ☐ La población de validez del resultado es explícita en la primera o segunda capa de la comunicación, no solo en el detalle técnico.
  ☐ El lenguaje usado («causa» vs. «está asociado con») es consistente con el nivel de identificación efectivamente alcanzado.

Bibliografía

Abadie, Alberto, Diamond, Alexis, Hainmueller, y Jens. 2010. «Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program». *Journal of the American Statistical Association* 105 (490): 493-505.

Abadie, Alberto, Diamond, Alexis, Hainmueller, y Jens. 2015. «Comparative Politics and the Synthetic Control Method». *American Journal of Political Science* 59 (2): 495-510.

Abadie, Alberto, Gardeazabal, y Javier. 2003. «The Economic Costs of Conflict: A Case Study of the Basque Country». *American Economic Review* 93 (1): 113-32.

Andrews, Isaiah, Stock, James H., Sun, y Liyang. 2019. «Robust Methods in Nonparametric Conditional Moment Testing: The Case of Instrumental Variables». *Econometrica* 87 (4): 1153-81.

Angrist, Joshua D., Krueger, y Alan B. 1991. «Does Compulsory School Attendance Affect Schooling and Earnings?». *Quarterly Journal of Economics* 106 (4): 979-1014.

Arkhangelsky, Dmitry, Athey, et al. 2021. «Synthetic Difference in Differences». *American Economic Review* 111 (12): 4088-118.

Arnold, Matthew, Bellamy, et al. 2019. «FactSheets: Increasing Trust in AI Services through Supplier's Declarations of Conformity». *IBM Journal of Research and Development* 63 (4/5).

Aronow, Peter M., Miller, y Benjamin T. 2017. *Foundations of Agnostic Statistics*. Cambridge University Press.

Athey, Susan. 2017. «Beyond Prediction: Using Big Data for Policy Problems». *Science* 355 (6324): 483-85.

Athey, Susan, Bayati, et al. 2021b. «Matrix Completion Methods for Causal Panel Data Models». *Journal of the American Statistical Association* 116 (536): 1716-30.

Athey, Susan, Imbens, y Guido. 2016. «Recursive Partitioning for Heterogeneous Causal Effects». *Proceedings of the National Academy of Sciences* 113 (27): 7353-60.

Athey, Susan, Imbens, et al. 2019. «Machine Learning Methods That Economists Should Know About». *Annual Review of Economics* 11 : 685-725.

Athey, Susan, Tibshirani, et al. 2019. «Generalized Random Forests». *Annals of Statistics* 47 (2): 1148-78.

Athey, Susan, Wager, et al. 2019. «Estimating Treatment Effects with Causal Forests: An Application». *Observational Studies*,.

Athey, Susan, Wager, y Stefan. 2021a. «Policy Learning With Observational Data». *Econometrica* 89 (1): 133-61.

Bach, Philipp, Chernozhukov, et al. 2022. «DoubleML–An Object-Oriented Implementation of Double Machine Learning in Python». *Journal of Machine Learning Research* 23 (53): 1-6.

Bareinboim, Elias. 2025. *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Columbia CausalAI Lab.

Bareinboim, Elias, Correa, et al. 2022. «On Pearl's Hierarchy and the Foundations of Causal Inference». En *Probabilistic and Causal Inference: The Works of Judea Pearl*, editado por Geffner, Hector, Dechter, Rina, Halpern, y Joseph Y. ACM Books.

Bareinboim, Elias, Forney, Andrew, Pearl, y Judea. 2015. «Bandits with Unobserved Confounders: A Causal Approach». *Advances in Neural Information Processing Systems 28 (NeurIPS)*,.

Bareinboim, Elias, Pearl, y Judea. 2013. «A General Algorithm for Deciding Transportability of Experimental Results». *Journal of Causal Inference* 1 (1): 107-34.

Barocas, Solon, Hardt, Moritz, Narayanan, y Arvind. 2019. *Fairness and Machine Learning*. Fairmlbook.org.

Battocchi, Keith, Dillon, et al. 2019. «EconML: A Python Package for ML-Based Heterogeneous Treatment Effects Estimation». *GitHub repository, Microsoft Research*,.

Belloni, Alexandre, Chen, et al. 2012. «Sparse Models and Methods for Optimal Instruments With an Application to Eminent Domain». *Econometrica* 80 (6): 2369-429.

Belloni, Alexandre, Chernozhukov, Victor, Hansen, y Christian. 2014. «Inference on Treatment Effects After Selection Among High-Dimensional Controls». *Review of Economic Studies* 81 (2): 608-50.

Ben-Michael, Eli, Feller, Avi, Rothstein, y Jesse. 2021. «The Augmented Synthetic Control Method». *Journal of the American Statistical Association* 116 (536): 1789-803.

Berger, James O. 1985. *Statistical Decision Theory and Bayesian Analysis*. 2.ª ed. Springer.

Bickel, Peter J., Klaassen, et al. 1993. *Efficient and Adaptive Estimation for Semiparametric Models*. Johns Hopkins University Press.

Bickel, Peter J., Ritov, Ya'acov, Tsybakov, y Alexandre B. 2009. «Simultaneous Analysis of Lasso and Dantzig Selector». *Annals of Statistics* 37 (4): 1705-32.

Borusyak, Kirill, Jaravel, Xavier, Spiess, y Jann. 2024. «Revisiting Event-Study Designs: Robust and Efficient Estimation». *Review of Economic Studies* 91 (6): 3253-85.

Breck, Eric, Cai, et al. 2017. «The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction». *IEEE International Conference on Big Data*,.

Callaway, Brantly, Sant'Anna, y Pedro H. C. 2021. «Difference-in-Differences with Multiple Time Periods». *Journal of Econometrics* 225 (2): 200-230.

Card, David. 1995. «Using Geographic Variation in College Proximity to Estimate the Return to Schooling». *Aspects of Labour Economics*, 201-22.

Chaisemartin, Clément, D'Haultfœuille, y Xavier. 2020. «Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects». *American Economic Review* 110 (9): 2964-96.

Chen, Huigang, Harinen, et al. 2020. «CausalML: Python Package for Causal Machine Learning». *arXiv preprint arXiv:2002.11631*,.

Chernozhukov, Victor, Chetverikov, et al. 2018b. «Double/Debiased Machine Learning for Treatment and Structural Parameters». *The Econometrics Journal* 21 (1): C1-68.

Chernozhukov, Victor, Chetverikov, et al. 2018a. «Applied Causal Inference Inspired by Machine Learning». *Working paper, MIT*,.

Chernozhukov, Victor, Demir, et al. 2020. «Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments». *arXiv preprint arXiv:1712.04802*,.

Chernozhukov, Victor, Goldman, Matt, Taddy, y Matt. 2016. «Locally Robust Semiparametric Estimation». *arXiv preprint arXiv:1608.00033*,.

Chernozhukov, Victor, Newey, et al. 2022. «RieszNet and ForestRiesz: Automatic Debiased Machine Learning with Neural Nets and Random Forests». *Proceedings of the 39th International Conference on Machine Learning (ICML)*,.

Chickering, David Maxwell. 2002. «Optimal Structure Identification with Greedy Search». *Journal of Machine Learning Research* 3 : 507-54.

Cinelli, Carlos, Hazlett, y Chad. 2020. «Making Sense of Sensitivity: Extending Omitted Variable Bias». *Journal of the Royal Statistical Society: Series B* 82 (1): 39-67.

Correa, Juan D., Bareinboim, y Elias. 2020. «General Transportability of Soft Interventions: Completeness Results». *Advances in Neural Information Processing Systems 33 (NeurIPS)*,.

Crump, Richard K., Hotz, et al. 2009. «Dealing with Small Sample Sizes Complicating Causal Effect Estimation». *Biometrika* 96 (2): 257-79.

Curth, Alicia, van der Schaar, y Mihaela. 2021. «On Inductive Biases for Heterogeneous Treatment Effect Estimation». *Advances in Neural Information Processing Systems 34 (NeurIPS)*,.

Dehejia, Rajeev H., Wahba, y Sadek. 1999. «Causal Effects in Nonexperimental Studies: Reevaluating the Evaluation of Training Programs». *Journal of the American Statistical Association* 94 : 1053-62.

Doudchenko, Nikolay, Imbens, y Guido W. 2016. «Balancing, Regression, Difference-in-Differences and Synthetic Control Methods: A Synthesis». *NBER Working Paper 22791*,.

Dwork, Cynthia, Hardt, et al. 2012. «Fairness Through Awareness». *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference (ITCS)*, 214-26.

Elwert, Felix, Winship, y Christopher. 2014. «Endogenous Selection Bias: The Problem of Conditioning on a Collider Variable». *Annual Review of Sociology* 40 : 31-53.

Farrell, Max H., Liang, Tengyuan, Misra, y Sanjog. 2021. «Deep Neural Networks for Estimation and Inference». *Econometrica* 89 (1): 181-213.

Foster, Dylan J., Syrgkanis, y Vasilis. 2019. «Orthogonal Statistical Learning». *arXiv preprint arXiv:1901.09036*,.

Freyaldenhoven, Simon, Hansen, Christian, Shapiro, y Jesse M. 2019. «Pre-Event Trends in the Panel Event-Study Design». *American Economic Review* 109 : 3307-38.

Galesic, Mirta, Garcia-Retamero, y Rocio. 2011. «Graph Literacy: A Cross-Cultural Comparison». *Medical Decision Making* 31 (3): 444-57.

Gebru, Timnit, Morgenstern, et al. 2021. «Datasheets for Datasets». *Communications of the ACM* 64 (12): 86-92.

Geer, Sara, Bühlmann, et al. 2014. «On Asymptotically Optimal Confidence Regions and Tests for High-Dimensional Models». *Annals of Statistics* 42 (3): 1166-202.

Goodman-Bacon, Andrew. 2021. «Difference-in-Differences with Variation in Treatment Timing». *Journal of Econometrics* 225 (2): 254-77.

Gutierrez, Pierre, Gérardy, y Jean-Yves. 2017. «Causal Inference and Uplift Modelling: A Review of the Literature». *CEUR Workshop Proceedings* 1846.

Hardt, Moritz, Price, Eric, Srebro, y Nathan. 2016. «Equality of Opportunity in Supervised Learning». *Advances in Neural Information Processing Systems 29 (NeurIPS)*,.

Hartford, Jason, Lewis, et al. 2017. «Deep IV: A Flexible Approach for Counterfactual Prediction». *Proceedings of the 34th International Conference on Machine Learning (ICML)*,.

Hastie, Trevor, Tibshirani, Robert, Wainwright, y Martin. 2015. *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press.

Hernán, Miguel A., Robins, y James M. 2020. *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC.

Hoerl, Arthur E., Kennard, y Robert W. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics* 12 : 55-67.

Holland, Paul W. 1986. «Statistics and Causal Inference». *Journal of the American Statistical Association* 81 (396): 945-60.

Huyen, Chip. 2022. *Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications*. O'Reilly Media.

Imbens, Guido W. 2003. «Sensitivity to Exogeneity Assumptions in Program Evaluation». *Unpublished manuscript, Harvard University*,.

Imbens, Guido W., Rubin, y Donald B. 2015. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.

Kalisch, Markus, Bühlmann, y Peter. 2007. «Estimating High-Dimensional Directed Acyclic Graphs with the PC-Algorithm». *Journal of Machine Learning Research* 8 : 613-36.

Kästner, Christian, Kang, Eunsuk, Hilton, y Michael. 2024. «Machine Learning in Production: From Models to Products». https://mlip-cmu.github.io/book/.

Kennedy, Edward H. 2023. «Towards Optimal Doubly Robust Estimation of Heterogeneous Causal Effects». *Electronic Journal of Statistics* 17 (2): 3008-49.

Kilbertus, Niki, Rojas-Carulla, et al. 2017. «Avoiding Discrimination through Causal Reasoning». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

Kish, Leslie. 1965. *Survey Sampling*. Wiley.

Kitagawa, Toru, Sakaguchi, Shosei, Tetenov, y Aleksey. 2021. «Constrained Classification and Policy Learning». *arXiv preprint arXiv:2106.12886 (cemmap working paper CWP26/21)*,.

Kitagawa, Toru, Tetenov, y Aleksey. 2018. «Who Should Be Treated? Empirical Welfare Maximization Methods for Treatment Choice». *Econometrica* 86 (2): 591-616.

Kleinberg, Jon, Ludwig, et al. 2015. «Prediction Policy Problems». *American Economic Review* 105 (5): 491-95.

Künzel, Sören R., Sekhon, et al. 2019. «Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning». *Proceedings of the National Academy of Sciences* 116 (10): 4156-65.

Kusner, Matt J., Loftus, et al. 2017. «Counterfactual Fairness». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

LaLonde, Robert J. 1986. «Evaluating the Econometric Evaluations of Training Programs with Experimental Data». *American Economic Review* 76 : 604-20.

Lee, Jason D., Sun, et al. 2016. «Exact Post-Selection Inference, with Application to the Lasso». *Annals of Statistics* 44 (3): 907-27.

Leeb, Hannes, Pötscher, y Benedikt M. 2006. «Can One Estimate the Conditional Distribution of Post-Model-Selection Estimators?». *Econometric Theory* 24 (6): 1915-33.

Lei, Jing, Candès, y Emmanuel J. 2021. «Conformal Inference of Counterfactuals and Individual Treatment Effects». *Annals of Statistics* 49 (6): 3346-69.

Lei, Jing, G'Sell, et al. 2018. «Distribution-Free Predictive Inference Using Regression». *Journal of the American Statistical Association* 113 (523): 1094-111.

Lipton, Zachary C. 2018. «The Mythos of Model Interpretability». *Communications of the ACM* 61 (10): 36-43.

Louizos, Christos, Shalit, et al. 2017. «Causal Effect Inference with Deep Latent-Variable Models». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

Lundberg, Scott M., Lee, y Su-In. 2017. «A Unified Approach to Interpreting Model Predictions». *NeurIPS*,.

Machlanski, Damian, Samothrakis, Spyridon, Clarke, y Paul. 2024. «Robustness of Algorithms for Causal Structure Learning to Hyperparameter Choice». *arXiv preprint arXiv:2310.18212*,.

Manski, Charles F. 1990. «Nonparametric Bounds on Treatment Effects». *American Economic Review* 80 (2): 386-90.

Manski, Charles F. 2004. «Statistical Treatment Rules for Heterogeneous Populations». *Econometrica* 72 (4): 1221-46.

Mitchell, Margaret, Wu, et al. 2019. «Model Cards for Model Reporting». *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 220-29.

Mullainathan, Sendhil, Spiess, y Jann. 2017. «Machine Learning: An Applied Econometric Approach». *Journal of Economic Perspectives* 31 (2): 87-106.

Newey, Whitney K. 1994. «The Asymptotic Variance of Semiparametric Estimators». *Econometrica* 62 (6): 1349-82.

Neyman, Jerzy. 1923. «On the Application of Probability Theory to Agricultural Experiments». *Annals of Agricultural Sciences* 5 : 1-51.

Neyman, Jerzy. 1959. «Optimal Asymptotic Tests of Composite Statistical Hypotheses». *Probability and Statistics*, 213-34.

Nie, Xinkun, Wager, y Stefan. 2021. «Quasi-Oracle Estimation of Heterogeneous Treatment Effects». *Biometrika* 108 (2): 299-319.

Oprescu, Miruna, Syrgkanis, Vasilis, Wu, y Zhiwei. 2023. «EconML Documentation». *Microsoft Research*,.

Paleyes, Andrei, Urma, Raoul-Gabriel, Lawrence, y Neil D. 2022. «Challenges in Deploying Machine Learning: A Survey of Case Studies». *ACM Computing Surveys* 55 (6): 1-29.

Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2.ª ed. Cambridge University Press.

Pearl, Judea, Bareinboim, y Elias. 2011. «Transportability of Causal and Statistical Relations: A Formal Approach». *Proceedings of the 25th AAAI Conference on Artificial Intelligence*, 247-54.

Pearl, Judea, Mackenzie, y Dana. 2018. *The Book of Why. The New Science of Cause and Effect*. Basic Books.

Pötscher, Benedikt M., Leeb, y Hannes. 2009. «On the Distribution of Penalized Estimators». *Statistics and Decisions* 27 : 1-30.

Radcliffe, Nicholas J. 2007. «Using Control Groups to Target on Predicted Lift: Building and Assessing Uplift Models». *Direct Marketing Analytics Journal*,.

Recht, Benjamin, Fazel, Maryam, Parrilo, y Pablo A. 2010. «Guaranteed Minimum-Rank Solutions of Linear Matrix Equations via Nuclear Norm Minimization». *SIAM Review* 52 (3): 471-501.

Robins, James M., Rotnitzky, Andrea, Zhao, y Lue Ping. 1994. «Estimation of Regression Coefficients When Some Regressors Are Not Always Observed». *Journal of the American Statistical Association* 89 : 846-66.

Robins, James M., Rotnitzky, y Andrea. 1995. «Semiparametric Efficiency in Double Robustness Regression». *Journal of the American Statistical Association* 90 : 122-29.

Robinson, Peter M. 1988. «Root-N-Consistent Semiparametric Regression». *Econometrica* 56 (4): 931-54.

Romano, Yaniv, Patterson, Evan, Candès, y Emmanuel J. 2019. «Conformalized Quantile Regression». *Advances in Neural Information Processing Systems 32 (NeurIPS)*,.

Rosenbaum, Paul R., Rubin, y Donald B. 1983. «The Central Role of the Propensity Score in Observational Studies for Causal Effects». *Biometrika* 70 (1): 41-55.

Rubin, Donald B. 1974. «Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies». *Journal of Educational Psychology* 66 (5): 688-701.

Rubin, Donald B. 1976. «Inference and Missing Data». *Biometrika* 63 (3): 581-92.

Rubin, Donald B. 2001. «Using Propensity Scores to Help Design Observational Studies: Application to the Tobacco Litigation». *Health Services and Outcomes Research Methodology* 2 : 169-88.

Rzepakowski, Piotr, Jaroszewicz, y Szymon. 2012. «Decision Trees for Uplift Modeling with Single and Multiple Treatments». *Knowledge and Information Systems* 32 (2): 303-27.

Schuler, Alejandro, Jung, et al. 2018. «A Comparison of Methods for Model Selection When Estimating Individual Treatment Effects». *arXiv preprint arXiv:1804.05146*,.

Sculley, D., Holt, et al. 2015. «Hidden Technical Debt in Machine Learning Systems». *Advances in Neural Information Processing Systems 28 (NeurIPS)*,.

Shalit, Uri, Johansson, Fredrik D., Sontag, y David. 2017. «Estimating Individual Treatment Effect: Generalization Bounds and Algorithms». *Proceedings of the 34th International Conference on Machine Learning (ICML)*,.

Sharma, Amit, Kiciman, y Emre. 2020. «DoWhy: An End-to-End Library for Causal Inference». *GitHub repository, Microsoft Research*,.

Shi, Claudia, Blei, David, Veitch, y Victor. 2019. «Adapting Neural Networks for the Estimation of Treatment Effects». *NeurIPS*,.

Simpson, Edward H. 1951. «The Interpretation of Interaction in Contingency Tables». *Journal of the Royal Statistical Society, Series B* 13 (2): 238-41.

Spiegelhalter, David. 2019. *The Art of Statistics: Learning from Data*. Pelican Books.

Spirtes, Peter, Glymour, Clark, Scheines, y Richard. 2000. *Causation, Prediction, and Search*. MIT Press.

Stock, James H., Wright, Jonathan H., Yogo, y Motohiro. 2002. «A Survey of Weak Instruments and Weak Identification in Generalized Method of Moments». *Journal of the American Statistical Association* 97 (460): 518-29.

Stock, James H., Yogo, y Motohiro. 2005. «Testing for Weak Instruments in Linear IV Regression». En *Identification and Inference for Econometric Models: Essays in Honor of Thomas Rothenberg*, editado por Andrews, Donald W. K., Stock, y James H. Cambridge University Press.

Sun, Liyang, Abraham, y Sarah. 2021. «Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects». *Journal of Econometrics* 225 (2): 175-99.

Thornton, Rebecca L. 2008. «The Demand for, and Impact of, Learning HIV Status». *American Economic Review* 98 (5): 1829-63.

Tibshirani, Robert. 1996. «Regression Shrinkage and Selection via the Lasso». *Journal of the Royal Statistical Society: Series B* 58 (1): 267-88.

Tibshirani, Ryan J., Foygel Barber, et al. 2019. «Conformal Prediction Under Covariate Shift». *arXiv preprint arXiv:1904.06019*,.

VanderWeele, Tyler J., Ding, y Peng. 2017. «Sensitivity Analysis in Observational Research: Introducing the E-Value». *Annals of Internal Medicine* 167 (4): 268-74.

Wager, Stefan, Athey, y Susan. 2018. «Estimation and Inference of Heterogeneous Treatment Effects using Random Forests». *Journal of the American Statistical Association* 113 (523): 1228-42.

Yadlowsky, Steve, Fleming, et al. 2021. «Evaluating Treatment Prioritization Rules via Rank-Weighted Average Treatment Effects». *arXiv preprint arXiv:2111.00066,*.

Yule, G. Udny. 1903. «Notes on the Theory of Association of Attributes in Statistics». *Biometrika* 2 (2): 121-34.

Zhang, Baqun, Tsiatis, et al. 2012. «Estimating Optimal Treatment Regimes from a Classification Perspective». *Stat* 1 : 1-17.

Zhang, Cun-Hui, Zhang, y Stephanie S. 2014. «Confidence Intervals for Low Dimensional Parameters in High Dimensional Linear Models». *Journal of the Royal Statistical Society: Series B* 76 (1): 217-42.

Zhang, Junzhe, Bareinboim, y Elias. 2019. «Near-Optimal Reinforcement Learning in Dynamic Treatment Regimes». *Advances in Neural Information Processing Systems 32 (NeurIPS)*,.

Zhao, Peng, Yu, y Bin. 2006. «On Model Selection Consistency of Lasso». *Journal of Machine Learning Research* 7 : 2541-63.

Zheng, Xun, Aragam, et al. 2018. «DAGs with NO TEARS: Continuous Optimization for Structure Learning». *Advances in Neural Information Processing Systems 31 (NeurIPS)*,.

Zou, Hui, Hastie, y Trevor. 2005. «Regularization and Variable Selection via the Elastic Net». *Journal of the Royal Statistical Society: Series B* 67 (2): 301-20.