Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

previos · actual · próximos · ◇ profundización electiva (no bloquea el camino ⋆)

1

CAPÍTULO 1

★ Camino crítico

Causalidad elemental y el problema fundamental de la inferencia causal

Parte 0 · Sesión S1

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Distinguir una pregunta asociativa de una pregunta causal en un caso aplicado.
2. Enunciar el problema fundamental de la inferencia causal (Holland, 1986) y su consecuencia sobre el efecto individual.
3. Ubicar una pregunta en el nivel correcto de la escalera de Pearl (asociación / intervención / contrafactual).

⋆ Antes de clase
Lectura: Cap. 1 — Causalidad elemental (@cap-causalidad-elemental)
Lab: L01
Entrega/hito: —

Agenda

01 · Dos preguntas que parecen la misma pregunta

02 · Tres escenas clásicas: cigüeñas, tamaño del pie, Simpson

03 · El problema fundamental de la inferencia causal

04 · Un adelanto de la escalera de la causalidad

05 · Por qué el ML no es causal por defecto

Problema causal, estimando e identificación

Problema

Un modelo predictivo entrenado sobre (beca, calificación) puede tener excelente precisión respondiendo "¿quién tiene mejor nota?" y, sin embargo, dar una respuesta equivocada si se usa para decidir a quién becar.

Gancho aplicado

¿Los estudiantes becados tienen mejores calificaciones? vs. ¿dar una beca a un estudiante mejora sus calificaciones? — misma tabla de datos, preguntas radicalmente distintas.

Caso del curso · Programa de becas universitarias: asociación observada vs. efecto de otorgar la beca.

Definiciones clave

Cigüeñas y nacimientos	Correlación regional sin vínculo causal: ambas responden a la ruralidad de la región — ejemplo clásico de correlación espuria.
Tamaño del pie y lectura	Confusor: la edad afecta ambas variables. Un modelo de ML «aprendería» la relación con alta confianza sin que sea causal.
Paradoja de Simpson	El tratamiento A gana en conjunto pero B gana en cada subgrupo — la gravedad del caso es el confusor. (Simpson, 1951; el fenómeno ya descrito por Yule, 1903)

El problema fundamental de la inferencia causal

Para cualquier unidad i, solo se observa uno de los dos resultados potenciales — nunca ambos. Si i recibió el tratamiento, observamos Y_i(1) pero Y_i(0) permanece contrafactual, y viceversa. (Marco de resultados potenciales: Neyman, 1923; Rubin, 1974. Formalización del problema: Holland, 1986.)

$$Y_i(1) - Y_i(0) \quad \text{nunca calculable directamente}$$

Resultado: por qué la comparación de grupos no es automática

$\Delta = E[Y|D{=}1] - E[Y|D{=}0] = ATT +$ sesgo de selección, con $ATT = E[Y(1){-}Y(0)|D{=}1]$ y sesgo $= E[Y(0)|D{=}1] - E[Y(0)|D{=}0]$: el segundo término compara el resultado potencial no observado de los tratados contra el observado de los controles. Los experimentos aleatorizados lo anulan por diseño; el resto del curso trata de aproximarlo cuando no hubo aleatorización.

Demostración: idea principal

Paso 1. Aplicar la restricción de consistencia $Y = D \cdot Y(1) + (1-D) \cdot Y(0)$ a la diferencia de medias observada.

↓

Paso 2. Aislar el término $E[Y(0)|D=1] - E[Y(0)|D=0]$: compara el resultado potencial no observado de los tratados contra el observado de los controles.

↓

Paso 3. Mostrar que la aleatorización hace ambos términos iguales en expectativa — comparabilidad **por diseño**, no por volumen de datos.

★

Punto de quiebre · Conceptual

Clasifique tres preguntas en Nivel 1 (asociación), Nivel 2 (intervención) o Nivel 3 (contrafactual): (a) ¿más médicos per cápita, menor mortalidad infantil? (b) ¿contratar más médicos reduciría la mortalidad? (c) ¿habría sobrevivido este paciente con un médico más? (Ejercicio 1 del capítulo.)

⏱ 2-4 min · Votación mano alzada o Mentimeter

Recordatorio del caso

Ministerio de Desarrollo Social: 100 variables por hogar, presupuesto para 30% de la población. Pregunta correcta: ¿quién experimentaría el mayor incremento de ingresos si recibiera el programa? — no ¿quién tendrá mayor ingreso futuro?

Resultado numérico

Sin cifra numérica — capítulo conceptual (gancho de apertura del curso). La distinción se retoma con datos reales en el Cap. 5 (predicción vs. causalidad) y el Cap. 11 (DML).

Lectura de política · La pregunta predictiva y la causal pueden dar respuestas opuestas sobre a quién priorizar.

Nivel PCH	Estimando / métrica principal
L1 (asociación) vs. L2 (intervención) — adelanto, formalizado en el Cap. 3	Δ (diferencia de medias) vs. $\tau = E[Y(1)-Y(0)]$

Pregunta activa (1 min)

Si solo predijéramos quién tendrá mejor resultado, ¿a quién trataríamos? Con el efecto causal, ¿cambia la decisión?

Escalera PCH: L1 (asociación) $\subseteq$ L2 (intervención) $\subseteq$ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Confundir «el modelo predice bien» con «el modelo estima el efecto causal» — es el error más común y más costoso del curso.

Creer que más datos resuelven la falta de aleatorización: el sesgo de selección no se reduce con n, se elimina con diseño.

Conexiones conceptuales

La escalera de Pearl (adelanto aquí) se formaliza con SCM en el Cap. 3 y con el criterio de puerta trasera en el Cap. 8.

Discusión y ejercicio

Pregunta de discusión

¿Por qué el problema fundamental de la inferencia causal implica que ningún algoritmo, por sofisticado que sea, puede calcular Y_i(1)−Y_i(0) para una unidad específica a partir de solo datos observacionales de esa unidad?

Ejercicio (5-10 min)

Un equipo entrena gradient boosting para predecir ventas a partir de si hubo promoción, con R^2=0.95, y concluye "la promoción explica el 95% de las ventas". ¿Qué está mal en términos de los niveles de la escalera de causalidad? (Ejercicio 4 del capítulo.)

Cierre del capítulo

Resumen

- Asociación $\neq$ causa; ningún volumen de datos por sí solo convierte una en otra.
- El problema fundamental: nunca se observan ambos resultados potenciales de una misma unidad.
- La escalera de Pearl organiza toda pregunta causal en tres niveles anidados.

Referencias clave

(1) Holland (1986), «Statistics and Causal Inference»

(2) Neyman (1923) / Rubin (1974), marco de resultados potenciales

(3) Pearl & Mackenzie (2018), **The Book of Why**

Próximo episodio · Cap. 2 — Anatomía de un sistema de ML en producción

Gancho: La pregunta causal está clara; ahora, ¿dónde vive en un sistema que hay que operar?