Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

3

CAPÍTULO 3

★ Camino crítico

Modelos Causales Estructurales y la Jerarquía Causal de Pearl

Parte I · Sesión S3

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Escribir la definición formal de un SCM.
2. Distinguir los tres niveles de la PCH y qué información mínima requiere cada uno.
3. Enunciar el Teorema de la Jerarquía Causal y explicar por qué es la razón formal — no solo intuitiva — de la tesis del Cap. 1.

⋆ Antes de clase
Lectura: Cap. 3 — SCM y PCH (@cap-scm-pch)
Lab: L03
Entrega/hito: —

Agenda

01 · Formalizar «causa» matemáticamente

02 · Definición de SCM

03 · Los tres niveles de la PCH

04 · Teorema de la Jerarquía Causal

05 · Verificación de consistencia del grafo

Problema

¿Qué objeto matemático representa completamente un sistema causal, y qué tres tipos de pregunta —y solo tres— se le pueden hacer?

Gancho aplicado

Los resultados potenciales del Cap. 1 son naturales para un tratamiento y un resultado; los SCM son naturales para sistemas con muchas variables relacionadas — el tipo de sistema que aparece en un pipeline de producción.

Caso del curso · SCM simulado de becas y calificaciones con motivación no observada U.

Definiciones clave

SCM	Tupla ⟨U, V, F, P(u)⟩: exógenas, endógenas, funciones estructurales, distribución de fondo.
L1 — Asociación	P(v): la distribución observacional, sin modificar M.
L2 — Intervención	P(y | do(x)): distribución tras reemplazar la ecuación de X por la constante x.
L3 — Contrafactual	P(y_x | e): abducción → acción → predicción.

SCM (Modelo Causal Estructural)

M = ⟨U, V, F, P(u)⟩. Cada V_i = f_i(pa_i, U_i). El grafo inducido no es una descripción estadística: cada ecuación representa un mecanismo real, no una relación ajustada a los datos.

$$M = (U, V, F, P(u))$$

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
L1 — Asociación	Se calcula con los datos observados, sin modificar M	Filtrar df[df.D==1] ≠ intervenir
L2 — Intervención	Requiere el SCM «quirúrgicamente modificado»	do(D=1): se borra f_D y se fija D=1
L3 — Contrafactual	Requiere abducción-acción-predicción	Condiciona en evidencia observada de una unidad específica

Teorema de la Jerarquía Causal (Causal Hierarchy Theorem)

El conjunto de SCM para los cuales las distribuciones de nivel L_(k+1) quedan determinadas por las de nivel L_k tiene medida cero, para k=1,2. Salvo un conjunto excepcional, dos SCM distintos pueden inducir la misma P(v) y distintas P(y|do(x)). Bareinboim, Correa, Ibeling & Icard (2022).

Ver: sección @thm-cht del capítulo fuente en la monografía.

Demostración: idea principal

Paso 1. Definir una medida de probabilidad natural sobre el espacio Ω de SCM (funciones estructurales + distribuciones exógenas).

↓

Paso 2. Mostrar que el subconjunto de SCM «colapsables» (donde un nivel determina al siguiente) tiene medida cero en Ω.

↓

Paso 3. Consecuencia operativa: todo método de estimación causal debe importar información extra-datos — un supuesto de identificación — porque la información simplemente no está en $P(v)$.

Punto de quiebre · Conceptual

★ ¿Es "df[df.D==1]" una observación o una intervención? ¿Cuándo coinciden P(y|X=x) y P(y|do(x))?

⏱ 2-4 min · Votación mano alzada o Mentimeter

SCM simulado: asociación vs. intervención — parte 1

```python
import numpy as np
rng = np.random.default_rng(7)
n = 50_000

# U: motivación no observada (confusor de D y de Y)
U = rng.normal(size=n)
# D (beca): depende de U -- estudiantes mas motivados piden mas becas
D_obs = (U + rng.normal(size=n) > 0.3).astype(int)
# Y (calificacion): depende de D (efecto causal verdadero = 0.4) y de U
Y_obs = 0.4 * D_obs + 0.9 * U + rng.normal(scale=0.5, size=n)

# Nivel 1 (asociacion): P(Y | D=1) observacional
assoc = Y_obs[D_obs == 1].mean() - Y_obs[D_obs == 0].mean()

# Nivel 2 (intervencion): do(D=1) para TODA la poblacion -- se reemplaza
# la ecuacion estructural de D por la constante 1
Y_do1 = 0.4 * 1 + 0.9 * U + rng.normal(scale=0.5, size=n)
Y_do0 = 0.4 * 0 + 0.9 * U + rng.normal(scale=0.5, size=n)
intervencion = Y_do1.mean() - Y_do0.mean()

print(f"Asociacion P(Y|D=1)-P(Y|D=0):  {assoc:.3f}")
print(f"Intervencion P(Y|do(D=1)):     {intervencion:.3f}")
```

Chequeo de sanidad

```python
# assert abs(intervencion - 0.4) < 0.05  # recupera el efecto verdadero
```

Caso aplicado · Consistencia del grafo con close_college (Card, 1995)

Recordatorio del caso

Un grafo que supone que nearc4 afecta educ pero no directamente wage, controlando por educ, implica una independencia condicional testeable.

Resultado numérico

nearc4 $\perp$ wage | educ + controles — verificable con dowhy/causal-learn (test de independencia condicional). Necesario, no suficiente: varios grafos pueden ser observacionalmente equivalentes (CPDAG, Cap. 29).

Lectura de política · Un test estadístico puede refutar un grafo, nunca confirmarlo como "el verdadero".

Mapeo PCH del capítulo · pregunta activa

Nivel PCH	**Estimando / métrica principal**
L1, L2 y L3 — los tres formalizados por primera vez en este capítulo	P(v), P(y | do(x)), P(y_x | evidencia)

Pregunta activa (1 min)

¿Por qué ningún test de independencia condicional puede confirmar que un grafo es "el verdadero", solo refutarlo?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Confundir P(y|X=x) con P(y|do(x)) — el error más frecuente al empezar en inferencia causal.

Asumir que el grafo es «el verdadero»: un SCM formaliza supuestos, no los verifica.

Tratar L3 como si fuera L2: una pregunta contrafactual individual no se responde con el procedimiento de una pregunta interventiva poblacional.

Conexiones conceptuales

El criterio de puerta trasera (Cap. 8) es la versión operacional de 'qué controlar' para llegar de L1 a L2 en la práctica.

Discusión y ejercicio

Pregunta de discusión

Dé un ejemplo de dos SCM distintos que induzcan la misma P(v) pero distinta P(y|do(x)).

Ejercicio (5-10 min)

Modifique el listado de simulación para que el efecto causal verdadero sea 0 (sin efecto), manteniendo la confusión vía U. Verifique que la diferencia asociativa sigue siendo distinta de cero mientras el efecto interventivo converge a 0.

Cierre del capítulo

Resumen

- Un SCM es una tupla ⟨U,V,F,P(u)⟩; equivalente formalmente a resultados potenciales.
- Los tres niveles de la PCH requieren información estrictamente creciente.
- El Teorema de la Jerarquía Causal es la razón formal de que los datos observacionales solos no respondan preguntas causales.

Referencias clave

(1) Bareinboim, Correa, Ibeling & Icard (2022), «On Pearl's Hierarchy…»

(2) Pearl (2009), **Causality**, 2.ª ed.

(3) Imbens & Rubin (2015), equivalencia SCM ↔ resultados potenciales

Próximo episodio · Cap. 4 — Ingeniería de datos para sistemas causales

Gancho: El SCM formaliza qué es una variable causal; falta formalizar qué rol juega cada columna de un dataset real.