Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

4

CAPÍTULO 4

★ Camino crítico

Ingeniería de datos para sistemas causales

Parte I · Sesión S4

Plantilla B (ingeniería y producción)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Declarar un CausalSchema con roles tratamiento/resultado/covariables/ instrumentos.
2. Explicar por qué un rol causal es una afirmación sobre identificación, no sobre tipo de dato.
3. Completar el arranque del Notebook A1.

⋆ Antes de clase

Lectura: Cap. 4 — Ingeniería de datos (@cap-ingenieria-datos-causales)
Lab: L04
Entrega/hito: A1 arranca

Agenda

01 · ¿Qué rol estructural juega cada columna?

02 · Tabla ancha vs. esquema con roles etiquetados

03 · Decisión: CausalSchema obligatorio

04 · Implementación de referencia

05 · Aplicación: A1 y B1 comparten el mismo esquema

El problema de diseño

Decisión	Adoptar un esquema explícito de roles causales sobre los datos, no solo un esquema de tipos.
Alternativas	Tabla ancha sin metadatos vs. esquema con roles etiquetados (tratamiento/resultado/covariable/instrumento).
Trade-off clave	Velocidad de prototipado vs. prevención sistemática de errores de identificación.
Stack	pandas, Parquet o CSV+metadata.json, pandera (validación de esquema).
Riesgo principal	Que el tratamiento se filtre como covariable, o que una variable post-tratamiento contamine X.

Opciones y trade-offs

Tabla ancha sin metadatos

Nombres de columna hardcodeados por notebook. Rápida para un análisis único; dos notebooks pueden definir X de forma sutilmente distinta sin que nadie lo note.

Esquema con roles etiquetados

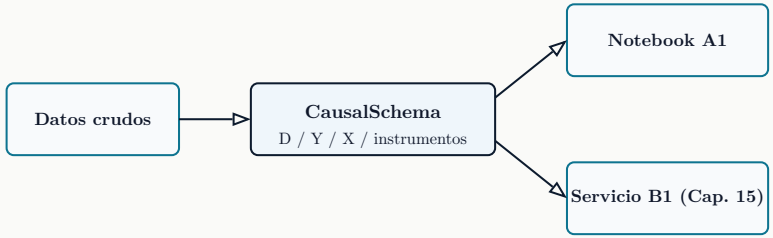
Se declara en un único lugar qué es D, Y, X e instrumentos. Fricción inicial a cambio de hacer sintácticamente imposible pasar el tratamiento como covariable por accidente.

Decisión adoptada

CausalSchema con 4 listas (treatment/outcome/covariates/instruments).
Formato preferido: Parquet con metadatos embebidos; CSV + metadata.json versionado es aceptable si el esquema viaja siempre junto a los datos.

Lo que la decisión fija es que el esquema exista y sea la única fuente de verdad sobre los roles — no el formato de serialización. Etiquetar una columna como covariates es una afirmación causal (satisface puerta trasera), no de tipo de dato.

El CausalSchema como contrato entre A1 y B1



el mismo esquema define el entrenamiento (A1) y el contrato del servicio (B1) — una sola fuente de verdad sobre los roles

CausalSchema — parte 1

```python
from dataclasses import dataclass, field
import pandas as pd

@dataclass
class CausalSchema:
    treatment: str
    outcome: str
    covariates: list[str]
    instruments: list[str] = field(default_factory=list)

    def validate(self, df: pd.DataFrame) -> None:
        declared = {self.treatment, self.outcome, *self.covariates, *self.instruments}
        missing = declared - set(df.columns)
        if missing:
            raise ValueError(f"Columnas declaradas ausentes: {missing}")
        overlap = set(self.covariates) & {self.treatment, self.outcome}
        if overlap:
            raise ValueError(f"D/Y no pueden ser covariables: {overlap}")

    def X(self, df): return df[self.covariates]
    def D(self, df): return df[self.treatment]
    def Y(self, df): return df[self.outcome]

# Ejemplo: retornos a la educación (Card, 1995)
schema = CausalSchema(
    treatment="educ", outcome="wage",
    covariates=["exper", "black", "south", "married"],
    instruments=["nearc4"])
df = pd.read_parquet("data/close_college.parquet")
schema.validate(df)
```

Chequeo de sanidad

```python
# schema.validate(df)  # lanza ValueError si D/Y quedan también en X
```

02_monografia → 03_notebooks_caso_estudio / 04_notebooks_produccion_hf / 05_labs_sesion

data_benchmark_causal/.../datasets/ como CSV + metadata.json (no Parquet obligatorio). Roles resueltos con lib.data_io.load_scenario y lib.schema.CausalSchema.from_scenario("real/jobs"). Labs: L04-L06. Entrega: Notebook A1 (Jobs). Stack: 03_notebooks_caso_estudio/lib/.

Recordatorio del caso

El Notebook A1 exige construir el CausalSchema antes de correr cualquier estimación, forzando la pregunta de identificación a un paso de ingeniería verificable.

Resultado numérico

El mismo esquema reaparece sin cambios en el Notebook B1 (Cap. 15): la función de inferencia en producción usa schema.covariates para saber exactamente qué columnas esperar del cliente.

Lectura de política · Cierra el círculo entre el notebook de entrenamiento y el servicio desplegado — el esquema es el contrato entre ambos.

Nivel PCH	**Estimando / métrica principal**
Transversal (precondición para cualquier estimación de L2)	CausalSchema válido: D, Y, X e instrumentos sin solapamiento

Pregunta activa (1 min)

¿Puede el mismo dataset producir dos estimaciones distintas del ATE en dos notebooks solo porque cada uno definió X de forma distinta?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Señales de alerta y checklist operativo

- El nombre de la columna de tratamiento aparece hardcodeado en más de un notebook.
- Ninguna función de carga valida que D e Y no estén también en covariates.
- No hay forma de saber, sin leer el código, si una covariable fue medida después del tratamiento.
- El esquema de roles no viaja junto con los datos (ni en el archivo ni en un metadata.json versionado a su lado).

Si dos o más señales están presentes, el sistema no está listo según los criterios de este curso.

Punto de quiebre · Aplicado

★ Para el dataset de becas del Cap. 1, proponga tres covariables legítimas y una variable post-tratamiento que sería incorrecto incluir. Justifique.

⏱️ 2-4 min · Votación mano alzada o Mentimeter

Discusión y ejercicio

Pregunta de discusión

¿Por qué un esquema de roles causales explícito importa más en un sistema con varios notebooks y colaboradores que en un análisis individual de una sola vez?

Ejercicio (5-10 min)

Extienda CausalSchema con un método summary() que imprima, para cada rol, el número de valores faltantes y el tipo de dato. Aplíquelo al dataset del Notebook A1.

Cierre del capítulo

Resumen

- Un rol causal (D/Y/X/instrumento) es una afirmación sobre identificación, no sobre tipo de dato.
- CausalSchema hace sintácticamente imposible pasar D como covariable por accidente.
- El mismo esquema conecta A1 (entrenamiento) con B1 (servicio, Cap. 15).

Referencias clave

(1) Huyen (2022), **Designing Machine Learning Systems**, Cap. 3

(2) Sculley et al. (2015), deuda técnica en sistemas de ML

Próximo episodio · Cap. 6 — Regularización, selección de variables y sesgo post-selección (S5; el Cap. 5 es lectura de refuerzo, sin sesión propia)

Gancho: El esquema dice qué es cada columna; falta decidir cuáles de las covariables entran al modelo sin sesgar la inferencia.