Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8
9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

9

CAPÍTULO 9

★ Camino crítico

Ingeniería de features sin fuga causal

Parte I · Sesión S8

Plantilla B (ingeniería y producción)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Auditar una feature candidata por su rol causal, no solo por su poder predictivo.
2. Construir las dos especificaciones X_base / X_ampliada para variables de rol ambiguo.
3. Detectar fuga temporal con marca de tiempo.

⋆ Antes de clase
Lectura: Cap. 9 — Features sin fuga (@cap-features-sin-fuga)
Lab: L08
Entrega/hito: A2 arranca

Agenda

01 · Una feature puede mejorar la predicción y sesgar el efecto

02 · Selección por importancia predictiva vs. por rol causal

03 · Auditoría obligatoria: X_base y X_ampliada

04 · Aplicación: Notebook A2 y ortogonalidad de Neyman

El problema de diseño

Decisión	Auditar cada feature candidata contra el grafo causal antes de incluirla, no solo contra su poder predictivo.
Alternativas	Selección de features por importancia predictiva vs. selección por rol causal.
Trade-off clave	Una feature que mejora el ajuste predictivo puede empeorar la estimación causal.
Stack	pandas, el CausalSchema del Cap. 4.
Riesgo principal	Fuga (leakage) de información post-tratamiento disfrazada de covariable.

Opciones y trade-offs

Importancia predictiva
Agregar features mientras mejoren CV (RMSE/AUC). Un modelo puede predecir excelente y estimar el efecto con sesgo severo.

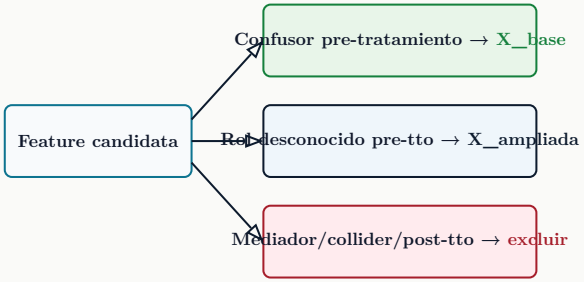
Rol causal, informado por el grafo
Clasificar primero cada candidata (confusor/mediador/collider/post-tratamiento, Cap. 8) y solo después evaluar su aporte predictivo dentro de la categoría legítima.

Decisión adoptada

Etapa de auditoría de features obligatoria antes de construir X. Cada columna se anota con su rol supuesto y produce DOS especificaciones: X_base (solo confusores pre-tratamiento) y X_ampliada (+ rol desconocido pre-tratamiento, para análisis de sensibilidad).

Las dos decisiones posibles sobre una variable de rol desconocido tienen riesgos opuestos y no comparables (excluir arriesga confusión omitida, incluir arriesga mal control). Reportar ambas estimaciones convierte la duda en información.

Auditoría de una feature candidata por rol causal



auditar_features — dos especificaciones

```python
import pandas as pd

# Roles que NUNCA entran en X: su inclusion sesga la estimacion
ROLES_PROHIBIDOS = {"mediador", "collider", "post_tratamiento"}

def auditar_features(df, treatment_time_col, feature_time_cols, roles):
    filas = []
    for feature, t_col in feature_time_cols.items():
        posterior = (df[t_col] > df[treatment_time_col]).mean()
        rol = roles.get(feature, "desconocido")
        pre = posterior == 0.0  # medida antes del tratamiento
        conf = rol == "confusor"
        # "desconocido" NO se excluye: entra en X_ampliada (sensibilidad)
        filas.append({"feature": feature, "rol": rol,
                      "riesgo_temporal": not pre,
                      "incluir_en_X_base": conf and pre,
                      "incluir_en_X_ampliada": (conf or rol == "desconocido")
                                               and pre and rol not in ROLES_PROHIBIDOS})
    return pd.DataFrame(filas)

def columnas_X(resultado, especificacion="base"):
    col = f"incluir_en_X_{especificacion}"
    return resultado.loc[resultado[col], "feature"].tolist()
```

Chequeo de sanidad

```python
# assert set(columnas_X(r,'base')) <= set(columnas_X(r,'ampliada'))
```

02_monografia → 03_notebooks_caso_estudio / 04_notebooks_produccion_hf / 05_labs_sesion

Lab L08 planta fugas deliberadas (outcome, tratamiento, interacciones) y las detecta antes de estimar. La Serie A2 (DML) y el escenario ihdp_medium asumen covariables solo pre-tratamiento. No usar columnas de ground truth (y0, y1, tau) fuera de celdas de evaluación. Rutas: 05_labs_sesion/L08_leakage_ihdp/ y notebook A2 en 03_notebooks_caso_estudio/notebooks/.

Recordatorio del caso

El Notebook A2 (DML) exige ejecutar la auditoría sobre la matriz de covariables antes de estimar el modelo PLR/IRM (Cap. 11).

Resultado numérico

Conecta directamente con un punto que el Cap. 10 asume resuelto: la validez de la ortogonalidad de Neyman depende de que X contenga controles legítimos, no mediadores ni colliders disfrazados.

Lectura de política · La auditoría de features es la precondición silenciosa de todo el aparato de la Parte II.

Mapeo PCH del capítulo · pregunta activa

Nivel PCH	**Estimando / métrica principal**
Transversal (precondición para L2, conecta con Cap. 8)	X_base vs. X_ampliada; % de features con riesgo temporal

Pregunta activa (1 min)

Si los IC de X_base y X_ampliada no se solapan, ¿qué capítulo hay que reabrir antes de reportar cualquiera de las dos estimaciones?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Señales de alerta y checklist operativo

- ☐ Una feature mejora sustancialmente el ajuste predictivo sin razón causal clara para incluirla.
- ☐ Ninguna columna tiene marca de tiempo para verificar si fue medida antes o después del tratamiento.
- ☐ Se agregó una feature «porque funcionaba mejor en las pruebas» sin revisar el DAG.
- ☐ Existen features derivadas cuya fórmula usa, aunque indirectamente, el propio resultado Y.

Si dos o más señales están presentes, el sistema no está listo según los criterios de este curso.

Punto de quiebre · Conceptual

★ ¿Por qué un "promedio móvil del resultado en las últimas 4 semanas" es casi siempre fuga en un sistema causal, aunque en uno predictivo sea razonable?

⏱ 2-4 min · Votación mano alzada o Mentimeter

Discusión y ejercicio

Pregunta de discusión

Estime el efecto con X_base y con X_ampliada. Si los IC no se solapan, ¿por qué ninguna de las dos estimaciones es defendible sin resolver antes la pregunta de identificación?

Ejercicio (5-10 min)

Aplique la auditoría al dataset del Notebook A1, declarando roles causales para al menos 6 covariables, con al menos una "desconocido". Reporte X_base vs. X_ampliada.

Cierre del capítulo

Resumen

- Auditar por rol causal, no solo por poder predictivo.
- Rol desconocido $\Rightarrow$ dos especificaciones, no una exclusión de facto.
- La fuga temporal se detecta con marca de tiempo, de forma mecánica y verificable.

Referencias clave

(1) Huyen (2022), **Designing Machine Learning Systems**, Cap. 5

(2) Bareinboim (2025) / Pearl (2009), clasificación de controles

Próximo episodio · Cap. 10 — Ortogonalidad de Neyman, cross-fitting e influence functions (Parte II)

Gancho: Con datos, controles y features auditados, llega la pregunta puramente estadística que estructura toda la Parte II: ¿cómo usar ML flexible sin que su propio sesgo contamine la inferencia?