Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

10

CAPÍTULO 10

★ Camino crítico

Ortogonalidad de Neyman, cross-fitting e influence functions

Parte II · Sesión S9

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Explicar el «doble sesgo» de los enfoques naïve al enchufar ML en una fórmula causal.
2. Enunciar la ortogonalidad de Neyman y por qué reduce el error de los nuisance a segundo orden.
3. Describir qué hace el cross-fitting que la ortogonalidad sola no hace.

⋆ Antes de clase
Lectura: Cap. 10 — Ortogonalidad (@cap-ortogonalidad)
Lab: L09
Entrega/hito: A2

Agenda

01 · El problema del doble sesgo

02 · Ortogonalidad de Neyman: definición y score de Robinson

03 · Teorema central de DML

04 · El rol del cross-fitting

05 · DML manual con Monte Carlo

Problema causal, estimando e identificación

Problema

5000 firmas, 200 covariables, asignación no aleatoria de una reforma tributaria. "Enchufar" estimadores de ML en una fórmula causal estándar no da inferencia válida: los errores de $hat(mu)_d$ y $hat(e)$ contaminan la estimación en primer orden.

Gancho aplicado

Bosques aleatorios tienen tasa a_n = n^(-2/5) — mucho más lenta que la n^(-1/2) que la inferencia clásica necesita.

Caso del curso · Consultora evaluando efecto de reforma tributaria sobre inversión empresarial.

Definiciones clave

g0(X), m0(X)	outcome regression y propensity function en el modelo PLR.
Score ortogonal	Derivada de Gateaux respecto a los nuisance = 0 en el valor verdadero.
Cross-fitting	Estimar los nuisance en folds distintos de donde se evalúa el score.

Score ortogonal de Neyman

Un score ψ(W,θ,η) es ortogonal de Neyman respecto a η en (θ0,η0) si la derivada de Gateaux respecto a η se anula para toda perturbación r.

$$\partial_\eta E[\psi(W, \theta_0, \eta)]|_{\eta=\eta_0} [r] = 0$$

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
$\mathbf{E[\varepsilon \mid D, X] = 0}$	g0 correctamente especificado	Residuo del outcome ortogonal a D,X
$\mathbf{E[v \mid X] = 0}$	m0 correctamente especificado	Residuo del tratamiento ortogonal a X
$\mathbf{\sqrt{n} \cdot a_n^2 \to 0}$	El sesgo de 2.º orden desaparece	Verificar tasa del learner elegido

Teorema central de DML (Chernozhukov et al., 2018)

Si $\hat{\eta}0$ se estima con $\|\hat{\eta}0-\eta0\|=O_p(a_n)$, $\sqrt{n}\cdot a_n^2\to0$, y $\hat{\theta}$ resuelve la ecuación de momento ortogonal con cross-fitting, entonces $\sqrt{n}(\hat{\theta}-\theta0)\to\hat{}d\ N(0,\sigma^2)$. La magia: NO se necesita estimar η a tasa $\sqrt{n}$ — basta una tasa más lenta con $a_n^2=o(n\hat{}(-1/2))$.

El score ortogonal canónico

Seis estimandos que el curso presenta como «distintos» son, en realidad, instancias de un único $\psi(W, \theta, \eta)$ con $E[\psi(W, \theta_0, \eta_0)] = 0$ y ortogonalidad respecto a η. Lo que cambia entre capítulos es ψ y el estimando — no el aparato de inferencia (cross-fitting, tasa $\sqrt{n}a_n^2 \to 0$, error estándar vía influence function).

Estimando	$\psi(W, \theta, \eta)$	η
PLR / ATE (Cap. 11)	$(D - m(X))(Y - l(X) - \theta(D - m(X)))$	(l, m)
ATE bajo IRM (Cap. 11)	$\mu(1, X) - \mu(0, X) + \frac{D(Y-\mu(1,X))}{e(X)} - \frac{(1-D)(Y-\mu(0,X))}{1-e(X)} - \theta$	(μ, e)
CATE, DR-learner (Cap. 12)	Γ_i = score IRM antes de promediar	(μ, e)
CATE, R-learner (Cap. 12)	$[(Y - m_Y(X)) - \tau(X)(D - e(X))]^2$	(m_Y, e)
PLIV (Cap. 17)	$(Z - r(X))(Y - g(X) - \theta D)$	(g, r, m)
Policy value (Cap. 21)	$\mu_{\pi(X)}(X) + \frac{\mathbf{1}\{D=\pi(X)\}}{e_{\pi(X)}(X)}\big(Y - \mu_{\pi(X)}(X)\big) - V(\pi)$	(μ, e)

Ver Cap. 10, tabla del score canónico — se cita de nuevo en los Caps. 11, 12, 17 y 21 en vez de repetirla.

Demostración: idea principal

Paso 1. Descomponer √n(θ̂−θ0) en: (a) término i.i.d. de varianza — sobrevive y fija σ²; (b) proceso empírico — neutralizado por cross-fitting, O_p(a_n); (c) sesgo de 2.º orden — neutralizado por ortogonalidad, O_p(√n · a_n²).

↓

Paso 2. (b): como $\hat{\eta}$ se estima fuera del fold de evaluación, el sumando es i.i.d. condicional a la muestra auxiliar — sin esto, se necesitarían condiciones de entropía que el ML moderno no satisface.

↓

Paso 3. (c): Taylor de 2.º orden en η alrededor de η0 — el término de 1.er orden se anula exactamente por ortogonalidad.

↓

Paso 4. Condiciones completas (Chernozhukov et al. 2018, Teorema 3.1): (C1) ortogonalidad; (C2) identificabilidad local $|E[\partial_\theta \psi]| \geq c > 0$; (C3) tasa de nuisance $\sqrt{n} a_n^2 \to 0$; (C4) momentos acotados. Dos variantes de agregación por fold: **DML1** (mediana de $\hat{\theta}_k$) vs. **DML2** (promedio ponderado, recomendada, con **repeated cross-fitting** $R = 5$–10 para reducir la varianza de partición).

Punto de quiebre · Conceptual

★ Si se estimó l0(X)=E[Y\|X], ¿por qué el score correcto es (D−m)(Y−l−θ(D−m)) y no (D−m)(Y−g−θD)? — la distinción Robinson vs. forma estructural.

⏱ 2-4 min · Votación mano alzada o Mentimeter

DML manual para PLR — parte 1

```python
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import KFold

# DML para PLR: cross-fitting K-fold con score de Robinson
def dml_plr_manual(Y, D, X, n_folds=5, learner=None):
    if learner is None:
        learner = lambda: RandomForestRegressor(n_estimators=100, min_samples_leaf=20, random_state=42)
    n = len(Y)
    l_hat, m_hat = np.zeros(n), np.zeros(n)  # E[Y|X], E[D|X]
    kf = KFold(n_splits=n_folds, shuffle=True, random_state=42)
    for tr, te in kf.split(X):
        l_hat[te] = learner().fit(X[tr], Y[tr]).predict(X[te])
        m_hat[te] = learner().fit(X[tr], D[tr]).predict(X[te])
    v_hat = D - m_hat          # residuos Robinson del tratamiento
    u_hat = Y - l_hat          # residuos del outcome
    den = np.mean(v_hat * v_hat)
    theta_hat = np.mean(v_hat * u_hat) / den
    psi = v_hat * (u_hat - theta_hat * v_hat) / den  # influence function
    se = np.sqrt(np.mean(psi ** 2) / n)
    return theta_hat, se
```

```python
# DGP sintético con confusores de alta dimensión
def make_dgp(n=2000, p=50, theta=2.0, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.standard_normal((n, p))
    g0 = X[:, 0] + 0.5 * X[:, 1]**2 - X[:, 2] * X[:, 3]
    m0 = 0.5 + 0.3 * np.tanh(X[:, 0] + X[:, 4])
    D = m0 + rng.standard_normal(n) * 0.5
    Y = theta * D + g0 + rng.standard_normal(n)
    return Y, D, X

# Monte Carlo: 200 réplicas
ests, ses = [], []
for b in range(200):
    Y, D, X = make_dgp(n=2000, p=50, theta=2.0, seed=b)
    th, se = dml_plr_manual(Y, D, X)
    ests.append(th); ses.append(se)
ests = np.array(ests); ses = np.array(ses)
print(f"Sesgo: {ests.mean() - 2.0:.4f}")
print(f"Cobertura 95%: {np.mean(np.abs(ests - 2.0) < 1.96*ses):.3f}")
```

Chequeo de sanidad

```python
# assert 0.90 <= cobertura <= 0.98
```

Salida

```
theta verdadero = 2.0
Sesgo: ~0.00
Cobertura 95%: 0.94-0.96
```

Recordatorio del caso

Efecto del programa de capacitación sobre ingresos 1978 (re78).

Resultado numérico

ATE ≈ \$1,600, IC 95% [\$800, \$2,400].

Lectura de política · Consistente con la estimación clásica de Dehejia & Wahba por matching.

Nivel PCH	**Estimando / métrica principal**
L2 (intervención) — ATE identificado bajo no confusión condicional	θ_0 con $\sqrt{n}(\hat{\theta}-\theta_0)\to N(0,\sigma^2)$ — ver tabla de score canónico (6 instancias)

Pregunta activa (1 min)

¿Por qué un bosque aleatorio con tasa $n^{(-2/5)}$ puede seguir dando inferencia válida sobre θ_0 pese a NO tener tasa $\sqrt{n}$ para η_0?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

- Omitir cross-fitting: evaluar el score en la misma muestra donde se estimaron los nuisance produce overfitting bias y IC demasiado estrechos.
- Usar K=1 (single sample splitting): desperdicia información, estimación ineficiente.
- Mezclar la forma estructural g0 con la condicional l0 — rompe la ortogonalidad respecto de m(X).

Conexiones conceptuales

El Cap. 11 aplica exactamente este aparato a PLR e IRM con librerías reales (DoubleML, econml).

Discusión y ejercicio

Pregunta de discusión

Compare DML con y sin cross-fitting sobre el mismo Monte Carlo. ¿En cuánto se degrada la cobertura sin cross-fitting?

Ejercicio (5-10 min)

Construya un DGP donde $\hat{g}$ tenga tasa $a_n = n^{-1/4}$ (más lento que $n^{-2/5}$). Verifique empíricamente que la cobertura de DML se degrada al no satisfacerse $\sqrt{n} \cdot a_n^2 \to 0$.

Cierre del capítulo

Resumen

- Enchufar ML sin ortogonalizar contamina la inferencia en 1.er orden — el «doble sesgo».
- Ortogonalidad + cross-fitting neutralizan, respectivamente, el sesgo de 2.º orden y el sesgo de sobreajuste.
- El score de Robinson es la pieza que reaparece en meta-learners (Cap. 12) y paneles (Cap. 17).

Referencias clave

(1) Chernozhukov et al. (2018), «Double/Debiased ML»

(2) Robinson (1988), score de residuo-contra-residuo

(3) Neyman (1959), test C(α) y ortogonalidad

Próximo episodio · Cap. 11 — Double/Debiased Machine Learning

Gancho: El score ortogonal y el cross-fitting son el motor; ahora se monta en los dos modelos que se usan en la práctica —PLR e IRM— con librerías reales.