Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 **11** 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

11

CAPÍTULO 11

★ Camino crítico

Double/Debiased Machine Learning

Parte II · Sesión S10

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Implementar DML-PLR y DML-IRM con DoubleML/econml.
2. Elegir un learner de nuisance verificando la condición de tasa.
3. Distinguir qué estima cada uno de OLS/IV/DML-PLIV sobre el mismo dataset — no son el mismo estimando.

⋆ Antes de clase

Lectura: Cap. 11 — DML (@cap-dml)
Lab: L10
Entrega/hito: A2 · Validar con grade_a2.py

Agenda

01 · PLR e IRM: score y garantías

02 · Learners de nuisance y sus tasas

03 · DoubleML y econml: dos implementaciones

04 · Verificación de leakage

05 · Card (1995): OLS, IV, DML-PLIV no son comparables sin más

Problema causal, estimando e identificación

Problema

Ministerio de Educación: efecto de una beca sobre rendimiento, 60 covariables, asignación priorizó bajo rendimiento previo pero también variables familiares y de contexto.

Gancho aplicado

El Cap. 10 mostró que el score ortogonal funciona; este capítulo lo implementa con librerías reales y cubre PLR e IRM.

Caso del curso · Beca sobre rendimiento académico, panel con 60 covariables.

Score IRM (modelo interactivo)

Permite heterogeneidad en D; combina la forma doubly-robust clásica de Robins et al. (1994) ajustada para ortogonalidad de Neyman. Es la fila 'ATE bajo IRM' de la tabla del score canónico del Cap. 10 — la misma versión sin promediar reaparece como Γ_i del DR-learner (Cap. 12) y como EIF del policy value (Cap. 21).

$$\psi_{\text{IRM}} = \mu(1,X) - \mu(0,X) + \frac{D(Y-\mu(1,X))}{e(X)} - \frac{(1-D)(Y-\mu(0,X))}{1-e(X)} - \theta$$

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
No confusión condicional	$Y(0), Y(1) \perp\!\!\!\perp D \mid X$	Ficha de procedencia, Cap. 7
Soporte común	$0 < P(D = 1\|X) < 1$ c.s.	Histograma de ê(X)
Consistencia	Y=Y(D)	—

Doble robustez + ortogonalidad (score IRM)

El score IRM es ortogonal de Neyman respecto a η=(μ,e). Además es doubly robust: si $\hat{\mu}$ O $\hat{e}$ es consistente (no necesariamente ambos), $\hat{\theta}$ es consistente.

Eficiencia semiparamétrica del estimador DML-IRM

Bajo no confusión, soporte común y Y acotado, la efficient influence function (EIF) del funcional $\theta 0 = E[\mu(1,X) - \mu(0,X)]$ en el modelo IRM es EXACTAMENTE el integrando del score IRM. Por la cota de Cramér-Rao semiparamétrica (Ap. A), el estimador DML-IRM es asintóticamente eficiente: ningún estimador regular tiene varianza asintótica menor que $V_eff = E[(\tau(X) - \theta 0)^2 + \sigma^2_1(X)/e(X) + \sigma^2_0(X)/(1 - e(X))]$. La doble robustez del teorema anterior protege contra mala especificación de un nuisance; la eficiencia certifica que, cuando ambos nuisance convergen, no se puede hacer mejor — son propiedades complementarias, no una versión más fuerte de la otra.

Diagnósticos cuantitativos de soporte común: ESS y trimming

La alerta "ê cerca de 0 o 1" se vuelve operativa con dos cantidades medibles. ESS de Kish para la componente IPW: $ESS=(\Sigma w_i)^2/\Sigma w_i^2$, con $w_i=D_i/\hat{e}(X_i)$ — $ESS/n \ll 1$ señala que pocas unidades con ê extremo dominan la estimación, aunque el histograma de ê "se vea bien" (Kish, 1965). Trimming óptimo (Crump et al., 2009): recortar observaciones con $\hat{e}(X) \notin [\alpha, 1-\alpha]$ minimiza la varianza asintótica del ATE; el α óptimo resuelve una condición de punto fijo sin forma cerrada simple, y como regla práctica —validada en un amplio rango de distribuciones del propensity score— los autores proponen $\alpha \approx 0.1$. Regla operativa del curso: reportar ESS/n y el rango de ê en todo resultado DML. Atención al estimando: tras el trimming, el efecto identificado es el ATE sobre la población con overlap, no el ATE poblacional — declararlo en la model card (Cap. 19) es obligatorio.

Punto de quiebre · Aplicado

★ Un learner único sin análisis de sensibilidad — ¿qué riesgo concreto corre el resultado? (Divergencias grandes entre learners señalan problemas de especificación.)

⏱ 2-4 min · Votación mano alzada o Mentimeter

DML-PLR con DoubleML — parte 1

```
import doubleml as dml
from sklearn.ensemble import RandomForestRegressor
import pandas as pd

df = pd.read_csv('../data/datasets/real/public_causaldata/nsw_mixtape/data.csv')
Y = df['re78'].values
D = df['treat'].values
X = df[['age','educ','black','hisp','marr','nodegree','re74','re75']].values

obj_dml = dml.DoubleMLPLR(
    dml.DoubleMLData.from_arrays(X, Y, D),
    ml_l=RandomForestRegressor(n_estimators=200, min_samples_leaf=20, random_state=42),
    ml_m=RandomForestRegressor(n_estimators=200, min_samples_leaf=20, random_state=42),
    n_folds=5,
)
obj_dml.fit()
print(obj_dml.summary)
```

💡 Chequeo de sanidad: el ATE estimado debe estar en el rango de la réplica del libro y llevar IC reportado, no solo el coeficiente. Comparar con OLS con controles.

Verificación de leakage — parte 2

```python
from sklearn.model_selection import KFold
from sklearn.ensemble import RandomForestRegressor

def verify_no_leakage(Y, D, X, n_folds=5, seed=42):
    """Predicciones nuisance SOLO fuera de fold."""
    kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
    n = len(Y)
    l_hat = np.zeros(n)
    m_hat = np.zeros(n)
    fold_assigned = np.zeros(n, dtype=int)

    for k, (train, test) in enumerate(kf.split(X)):
        fold_assigned[test] = k
        m_l = RandomForestRegressor(n_estimators=50, random_state=seed).fit(X[train], Y[train])
        l_hat[test] = m_l.predict(X[test])
        m_m = RandomForestRegressor(n_estimators=50, random_state=seed).fit(X[train], D[train])
        m_hat[test] = m_m.predict(X[test])

    print(f"Folds asignados correctamente: {(fold_assigned != -1).all()}")
    return l_hat, m_hat

verify_no_leakage(Y, D, X)
```

Chequeo de sanidad

```python
# assert (fold_assigned != -1).all()
```

💡 Si D es binario, usar un clasificador con predict_proba; para verificar leakage basta estimar E[D|X]. No dejar m_hat en ceros: una celda sin predecir es un bug de folds.

Caso aplicado · Card (1995): OLS, IV, DML-PLIV — estimandos distintos

Recordatorio del caso

close_college, n=3003. OLS con controles (no confusión implausible), IV con nearc4 (LATE de compliers), DML-PLIV (mismo LATE, nuisance flexibles).

Resultado numérico

OLS 0.071, IV 2SLS 0.124, DML-PLIV 0.145 — IC de IV casi 10× más ancho que el de OLS.

Lectura de política · IV no es "OLS corregido": estima el efecto sobre los compliers, un subgrupo distinto de la población general. El intervalo ancho es el precio de identificar con variación limitada, no un defecto del método.

Nivel PCH	**Estimando / métrica principal**
L2 (intervención) — ATE (PLR) o heterogéneo en D (IRM)	θ0 con IC vía influence function; ESS/n y trimming (α≈0.1) para el diagnóstico de soporte común

Pregunta activa (1 min)

Si OLS, IV y DML-PLIV dan tres números distintos sobre el mismo dataset, ¿cuál está "mal"? (Ninguno — estiman objetos distintos.)

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

- Asumir que DML «resuelve» la confusión no observada: DML requiere no confusión condicional, igual que OLS.
- Soporte común ignorado: $\hat{e}(X)$ cerca de 0 o 1 hace explotar las ponderaciones IPW.
- $\hat{e}$ extremo sin reportar ESS/trimming: la varianza se infla sin que el histograma de $\hat{e}$ lo delate.
- Learner único sin comparar al menos uno lineal y uno no lineal.

Conexiones conceptuales

El Cap. 14 (Validación) es el siguiente paso obligatorio antes de servir cualquiera de estos números.

Discusión y ejercicio

Pregunta de discusión

Verifique empíricamente la doble robustez: reemplace $\hat{\mu}$ por una constante (mal especificado) y observe que el ATE sigue siendo consistente si $\hat{e}$ es consistente.

Ejercicio (5-10 min)

Sobre nhefs, estime el efecto de dejar de fumar con (a) OLS manual, (b) DML-PLR con GBM, (c) DML-IRM con GBM. Compare.

Cierre del capítulo

Resumen

- PLR asume efecto constante; IRM permite heterogeneidad en D.
- El score IRM es doblemente robusto además de ortogonal.
- OLS/IV/DML-PLIV sobre el mismo dataset son estimandos distintos, no una escalera de corrección de sesgo.

Referencias clave

(1) Chernozhukov et al. (2018), paper fundacional de DML

(2) Bach et al. (2022), DoubleML

(3) Battocchi et al. (2019), econml

(4) Crump et al. (2009), trimming óptimo y $\alpha \approx 0.1$

Próximo episodio · Cap. 14 — Validación, refutación y sensibilidad (S11; el orden de enseñanza salta a Validación antes de Meta-learners)

Gancho: Con un ATE estimado y una librería que lo produce en segundos, la pregunta que sigue no es metodológica sino de confianza: ¿cómo sé que este número es razonable antes de servirlo?