Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 **12** 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

12

CAPÍTULO 12

★ Camino crítico

Meta-learners para efectos de tratamiento heterogéneos

Parte II · Sesión S13

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Implementar S/T/X/R/DR-learner.
2. Explicar por qué R- y DR-learner dependen de los nuisance a 2.º orden y S/T/X a 1.er orden.
3. Elegir un meta-learner según soporte común y muestra disponible.

⋆ Antes de clase

Lectura: Cap. 12 — Meta-learners (@cap-meta-learners)
Lab: L13
Entrega/hito: A3 arranca

Agenda

01 · S-learner, T-learner, X-learner

02 · R-learner: score de Robinson aplicado a $\tau(x)$

03 · DR-learner: pseudo-resultado y tasa oracle

04 · Comparación de propiedades

05 · Caso NSW: CATE por subgrupo

Problema causal, estimando e identificación

Problema

ONG decide entre dos variantes de microcrédito por cliente — no "¿cuál es el efecto promedio?" sino "¿a qué clientes conviene asignar A y a cuáles B?".

Gancho aplicado

Ningún meta-learner domina uniformemente: S sufre sesgo de regularización, T sufre varianza en grupo pequeño, X mitiga ambos, R es eficiente pero complejo.

Caso del curso · Microcrédito grupal (A) vs. individual (B), efecto heterogéneo sobre repago.

Definiciones clave

S-learner Un solo modelo con D como covariable — riesgo: D puede ser ignorado bajo regularización.
T-learner Dos modelos separados — riesgo: varianza alta si un grupo es pequeño.
X-learner Imputa efectos cruzados y pondera por $\hat{e}(x)$.

R-learner (score de Robinson aplicado a $\tau(x)$)

Optimiza directamente una loss que aísla el CATE usando el score ortogonal de Robinson (1988), con τ como función en vez de escalar.

$$\hat{\tau}_R = \text{argmin}_\tau \left\{ \frac{1}{n} \sum_i \left[(Y_i - \hat{m}_Y(X_i)) - \tau(X_i)(D_i - \hat{e}(X_i)) \right]^2 + \Lambda(\tau) \right\}$$

DR-learner: tasa oracle (Kennedy, 2023)

El pseudo-resultado Γ_i es el score IRM antes de promediar — la fila 'CATE, DR-learner' de la tabla de score canónico del Cap. 10: el mismo objeto, sin promediar. El error del DR-learner se acota por el error de un oracle que observara los Γ_i verdaderos, más un término de 2.º orden proporcional al PRODUCTO de los errores de μ̂_d y ê — no a su suma, como en S/T/X. Por eso tolera nuisance mediocres si no fallan los dos a la vez.

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
S/T/X-learner	Dependencia de 1.er orden en los nuisance	Tasa a_n heredada directamente
R/DR-learner	Dependencia de 2.º orden (producto de errores)	Cuasi-oracle / tasa oracle bajo condición de producto

Punto de quiebre · Conceptual

★ El S-learner con regularización fuerte colapsa el CATE a cero — ¿por qué eso no es un problema del algoritmo sino del diseño del método?

⏱ 2-4 min · Votación mano alzada o Mentimeter

Comparación de 4 meta-learners — RMSE vs. CATE verdadero

```python
import numpy as np
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.linear_model import LogisticRegressionCV
from econml.metalearners import SLearner, TLearner, XLearner
from econml.dml import CausalForestDML

def make_dgp(n=2000, p=10, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, p))
    e = 1 / (1 + np.exp(-1.0 - 0.5*X[:, 0]))
    D = (rng.uniform(size=n) < e).astype(int)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2  # CATE verdadero
    Y = X[:, 2] + 0.5*X[:, 3] + D*tau + rng.standard_normal(n)*0.5
    return Y, D, X, tau

Y, D, X, tau_true = make_dgp(n=2000, seed=42)
ml = lambda: GradientBoostingRegressor(n_estimators=200, max_depth=4, random_state=42)
e_model = LogisticRegressionCV(cv=5)
tau_s = SLearner(overall_model=ml()).fit(Y, D, X).effect(X)
tau_t = TLearner(models=ml()).fit(Y, D, X).effect(X)
tau_x = XLearner(models=ml(), propensity_model=e_model).fit(Y, D, X).effect(X)
tau_r = CausalForestDML(model_y=ml(), model_t=e_model, discrete_treatment=True,
                        n_estimators=200, random_state=42).fit(Y, D, X=X).effect(X)

for name, tau_hat in [("S", tau_s), ("T", tau_t), ("X", tau_x), ("R", tau_r)]:
    rmse = np.sqrt(np.mean((tau_hat - tau_true)**2))
    print(f"{name}-learner: RMSE={rmse:.4f}  Bias={np.mean(tau_hat - tau_true):.4f}")
```

Salida

```
S-learner: RMSE=... Bias=...
T-learner: RMSE=...
X-learner: RMSE=...
R-learner: RMSE=...
```

Caso aplicado · NSW: CausalForestDML por subgrupo educativo

Recordatorio del caso

n=445, 185 tratados. CATE medio \$2,226, IC 95% [\$14, \$4,438].

Resultado numérico

CATE por educación: \$1,174 (educ=7) → \$3,515 (educ=14). Consistente con que individuos con más educación previa aprovechan mejor la capacitación.

Lectura de política · La regla naïve "tratar a los más pobres" no es óptima — conviene incorporar la educación como criterio adicional.

Nivel PCH	**Estimando / métrica principal**
L2 heterogéneo — $\tau(x) = E[Y(1)-Y(0)\|X=x]$	RMSE($\hat{\tau}$, τ) sobre DGP sintético; CATE medio por subgrupo en NSW

Pregunta activa (1 min)

Si solo predijéramos quién tiene mayor Y esperado, ¿coincidiría con a quién conviene asignar el microcrédito grupal? ¿Por qué no necesariamente?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes y conexiones

Errores comunes

S-learner regularizado: CATE colapsa a cero — verificar la fracción de CATE estimados en exactamente cero.

Propensity extremo: varianza alta en X/R/DR-learner sin trimming — mismo diagnóstico ESS/α^* del Cap. 11, heredado por los denominadores $\hat{e}(X)$ y $1-\hat{e}(X)$ en Γ_i.

Subgrupos sin IC: bootstrap o forest, nunca reportar CATE por subgrupo sin incertidumbre.

Conexiones conceptuales

Guía de elección: DR/R primero si hay soporte común y muestra; T-learner como baseline obligatorio; S-learner solo con learners poco regularizados.

Discusión y ejercicio

Pregunta de discusión

¿Por qué el R- y el DR-learner tienen garantías más fuertes con nuisance mediocres que el T-learner, pese a usar el mismo tipo de learners internamente?

Ejercicio (5-10 min)

Implemente el R-learner "a mano" con cross-fitting (K=5) para $\hat{m}_Y$ y $\hat{e}$, y un RandomForestRegressor para $\hat{\tau}$. Compare con la implementación de econml.

Cierre del capítulo

Resumen

- Cuatro estrategias reutilizan learners genéricos para estimar $\tau(x)$: S, T, X, R, y el DR--learner las extiende con tasa oracle.
- La distinción de fondo es la dependencia de 1.er vs. 2.º orden en los nuisance.
- Ningún meta-learner domina siempre — la elección depende de soporte común y muestra.

Referencias clave

(1) Künzel et al. (2019), S/T/X-learners

(2) Nie & Wager (2021), R-learner

(3) Kennedy (2023), DR-learner y tasa oracle

Próximo episodio · Cap. 13 — Árboles y bosques causales

Gancho: Los meta-learners reutilizan learners genéricos; el siguiente capítulo presenta una familia diseñada específicamente para CATE, con mejores garantías de inferencia.