Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 **13** 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

13

CAPÍTULO 13

★ Camino crítico

Árboles y bosques causales

Parte II · Sesión S14

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Explicar la honesty y por qué evita el sesgo de selección estructural.
2. Describir el bosque causal como generador de pesos locales, no como promedio de árboles.
3. Usar CausalForestDML con mapas de heterogeneidad.

⋆ Antes de clase

Lectura: Cap. 13 — Bosques causales (@cap-causal-forests)
Lab: L14
Entrega/hito: B1 entrega

Agenda

01 · Identificar subgrupos con efecto heterogéneo

02 · Honesty: splitting subsample vs. estimation subsample

03 · El bosque como pesos de vecindad — no promedio de árboles

04 · Normalidad asintótica local

05 · Caso NSW: mapas de heterogeneidad

Problema causal, estimando e identificación

Problema

El CATE promedio de un programa de transferencias puede ser modesto (3pp) mientras la heterogeneidad es grande: nulo en algunos subgrupos, >10pp en otros.

Gancho aplicado

La honesty evita el overfitting estructural de los árboles estándar y permite IC asintóticamente válidos.

Caso del curso · Transferencias condicionadas y asistencia escolar por subgrupo.

Honesty

Un árbol causal es honest si las decisiones de partición son independientes (en muestra) de las estimaciones de $\hat{\tau}$ dentro de cada hoja: S = S_split ∪ S_est, el árbol se construye con S_split y los efectos se estiman con S_est.

$$\hat{\tau}(\mathcal{L}_m) = \frac{1}{n_{1,m}} \sum_{D_i=1} Y_i - \frac{1}{n_{0,m}} \sum_{D_i=0} Y_i$$

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
Honesty	Evita sesgo de selección: sin ella, $\hat{\tau}$ en hojas seleccionadas tiende a ser mayor en valor absoluto que el verdadero	Comparar con/sin honesty sobre la misma muestra
No confusión + soporte común	Igual que el resto de la Parte II	$\hat{e}(x)$ sin valores cerca de 0 o 1

Normalidad asintótica local (Wager & Athey, 2018)

Bajo honesty, submuestreo, soporte común y suavidad local, existe una varianza estimada $\hat{V}(x)$ tal que $(\hat{\tau}_CF(x) - \tau(x))/\sqrt{\hat{V}(x)} \to^{d} N(0,1)$. La tasa es LOCAL y depende de la probabilidad de caer en hojas cercanas a x — no una normalización $\sqrt{n}$ universal.

Demostración: idea principal

Paso 1. Un bosque aleatorio predictivo promedia predicciones de árboles.

↓

Paso 2. Un bosque CAUSAL, en su formulación canónica (GRF), NO promedia $\hat{\tau}_b(x)$: induce pesos de vecindad $\omega_i(x)$ — cuán a menudo i cae en la misma hoja que x.

↓

Paso 3. Con esos pesos, se resuelve una ecuación de momento LOCAL: $\sum_i \omega_i(x)\psi_i\big(\hat{\theta}(x)\big) = 0$. El árbol elige qué vecinos son relevantes; el score causal hace la estimación.

Punto de quiebre · Aplicado

★ Policy trees son interpretables — ¿por qué su interpretabilidad es también la fuente de su garantía estadística (VC finita, Athey & Wager 2021) y no solo una concesión de comunicación?

⏱️ 2-4 min · Votación mano alzada o Mentimeter

CausalForestDML con mapas de heterogeneidad

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor, GradientBoostingClassifier

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/data.csv")
Y, D = df["re78"].values, df["treat"].values
X = df[["age", "educ", "black", "hisp", "marr", "nodegree", "re74", "re75"]].values

cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, max_depth=4, random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, max_depth=4, random_state=42),
    discrete_treatment=True, n_estimators=400, min_samples_leaf=20, cv=5)
cf.fit(Y, D, X=X)

ate = cf.ate(X=X); lb, ub = cf.ate_interval(X=X, alpha=0.05)
print(f"ATE: {ate:.2f}  IC 95%: [{lb:.2f}, {ub:.2f}]")

cate = cf.effect(X)
cate_lb, cate_ub = cf.effect_interval(X, alpha=0.05)

# Mapas de heterogeneidad: CATE por edad y educacion
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
for ax, var in zip(axes, ["age", "educ"]):
    ax.scatter(df[var], cate, c=cate, cmap="viridis", alpha=0.6)
    ax.set_xlabel(var); ax.set_ylabel("CATE estimado")
plt.tight_layout(); plt.show()
```

Caso aplicado · NSW: heterogeneidad por educación e ingreso previo

Recordatorio del caso

n=445 (185 tratados). ATE \$2,226, IC [\$14, \$4,438].

Resultado numérico

feature_importances_: age (0.43), educ (0.24), re75 (0.22), re74 (0.08).
CATE por educación: \$1,174 (educ=7) → \$3,515 (educ=14).

Lectura de política · Heterogeneidad estructurada consistente con la teoría económica de la capacitación.

Nivel PCH	**Estimando / métrica principal**
L2 heterogéneo — inferencia asintótica local	$\hat{\tau}$_CF(x) con $\hat{V}$(x) local

Pregunta activa (1 min)

¿Por qué un bosque aleatorio predictivo (para Y) no puede convertirse en un bosque causal solo cambiando la etiqueta que predice?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes y conexiones

Errores comunes

Árbol sin honesty: sesgo de selección — comparar con/sin honesty sobre la misma muestra.

Data dredging de subgrupos: pre-registrar subgrupos de interés, ajustar por Bonferroni/FDR si se comparan varios.

CATE fuera del soporte común: no extrapolar a regiones sin solapamiento.

Conexiones conceptuales

Policy trees (Athey & Wager 2021) conectan directamente con el policy learning formal del Cap. 21.

Discusión y ejercicio

Pregunta de discusión

Compare causal forest con R-learner sobre el mismo dataset. ¿Qué método identifica más heterogeneidad y por qué podría diferir la respuesta según el tamaño muestral?

Ejercicio (5-10 min)

Implemente un árbol causal honesto "a mano" dividiendo la muestra en S_split y S_est. Compare con la implementación de econml.

Cierre del capítulo

Resumen

- Honesty separa partición de estimación — evita el sesgo de selección estructural de los árboles estándar.
- El bosque causal genera pesos de vecindad; el score causal hace la estimación local.
- Policy trees heredan la garantía de VC finita del Cap. 21.

Referencias clave

(1) Athey & Imbens (2016), causal trees

(2) Wager & Athey (2018), normalidad asintótica

(3) Athey, Tibshirani & Wager (2019), Generalized Random Forests

Próximo episodio · Cap. 15 — Despliegue de un estimador causal como servicio (S12 en el orden de enseñanza real, ya cubierto antes — este capítulo cierra la Parte II en el libro)

Gancho: El estimador ya es robusto y validado; falta ponerlo donde alguien pueda consultarlo sin reabrir el notebook.