Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 **14** 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

14

CAPÍTULO 14

★ Camino crítico

Validación, refutación y sensibilidad

Parte II · Sesión S11

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Explicar por qué la validación cruzada estándar no aplica al CATE.
2. Construir curvas Qini/AUUC y distinguir ranking de calibración.
3. Calcular e interpretar un E-value.

⋆ Antes de clase

Lectura: Cap. 14 — Validación (@cap-validacion)
Lab: L11
Entrega/hito: A2 entrega · Validar con grade_a2.py

Agenda

01 · El problema fundamental: $\tau(x)$ nunca se observa

02 · Curva Qini, AUUC y coeficiente Qini

03 · Placebo tests y transformed outcome

04 · E-value: sensibilidad a confusión no observada

05 · Baselines obligatorios y versionado del proceso

Problema

Un banco entrenó un modelo de uplift para crédito pre-aprobado. No se observa el CATE verdadero para ningún cliente — cada cliente recibe solo un tratamiento.

Gancho aplicado

La validación cruzada estándar de ML supervisado es inválida para el CATE: no hay "y verdadero" contra qué comparar.

Caso del curso · Modelo de uplift para líneas de crédito pre-aprobadas.

Imposibilidad de validación directa

Para cualquier estimador $\hat{\tau}$ y cualquier dataset real (Y,D,X), no existe función de los datos que permita estimar el error $\|\hat{\tau}-\tau\|$ sin supuestos adicionales. La solución: proxy metrics y placebo tests que detectan fallos gruesos sin medir el error directamente.

Definiciones clave

AUUC	Área bajo la curva uplift. Métrica de RANKING, invariante a reescalar $\hat{\tau}$ — no de calibración.
Coeficiente Qini	AUUC normalizada — comparable entre datasets.
Transformed outcome	$Y^\star$ con $E[Y^\star \mid X] = \tau(X)$ si $\hat{e}$ es consistente — permite RMSE supervisado sobre $\hat{\tau}$.

Sensibilidad, Nivel 1 — E-value (VanderWeele & Ding, 2017)

$E = RR + \sqrt{(RR(RR-1))}$. Un confusor no observado tendría que estar asociado a tratamiento Y resultado por un factor de riesgo ≥ E para explicar completamente la asociación observada. Condición NECESARIA, no suficiente: describe el confusor único más débil que explicaría el resultado — varios confusores moderados pueden combinarse.

Sensibilidad, Niveles 2 y 3 — R^2 parcial y bounds de Manski

Nivel 2 (Cinelli & Hazlett, 2020; Imbens, 2003): para estimaciones tipo PLR, ¿qué R^2 parcial con D y con Y tendría que tener un confusor no observado U para anular el efecto? Se reporta contra el benchmark del confusor observado más fuerte, en la escala del propio modelo — sin cambiar a razones de riesgo como el E-value. Nivel 3 (Manski, 1990): con $Y \in [0,1]$ y sin ningún supuesto de no confusión, $\theta = E[Y(1) - Y(0)]$ queda acotado en un intervalo de ancho ≤ 1, que puede estrecharse combinando el bound con el E-value del Nivel 1. Protocolo del curso: todo resultado observacional reporta Nivel 1 siempre + Nivel 2 si el estimador es tipo PLR + Nivel 3 si el outcome está acotado y el resultado es próximo a cero. Un resultado que no sobrevive el Nivel 1 se reporta como "no robusto" y no se despliega.

Punto de quiebre · Conceptual

★ Un modelo puede predecir Y con R^2=0.99 y producir CATE completamente sesgado. ¿Cómo es posible? (El R^2 predictivo no correlaciona con la calidad de la estimación causal.)

⏱️ 2-4 min · Votación mano alzada o Mentimeter

Curva Qini sobre DGP con ground truth

```python
import numpy as np, pandas as pd, matplotlib.pyplot as plt
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor, GradientBoostingClassifier

rng = np.random.default_rng(42)  # DGP con CATE conocido (ground truth)
X = rng.uniform(-1, 1, (3000, 5))
D = (rng.uniform(size=3000) < 1/(1 + np.exp(-0.5 - 0.3*X[:, 0]))).astype(int)
Y = X[:, 2] + X[:, 3] + D*(2 + 3*X[:, 0] - X[:, 1]**2) + rng.standard_normal(3000)*0.5

cf = CausalForestDML(model_y=GradientBoostingRegressor(n_estimators=200, random_state=42),
                     model_t=GradientBoostingClassifier(n_estimators=200, random_state=42),
                     discrete_treatment=True, n_estimators=400, cv=5).fit(Y, D, X=X)
tau_hat = cf.effect(X)

def qini_curve(Y, D, tau_hat):  # Qini acumulada, ranking por tau_hat
    df = pd.DataFrame({'Y': Y, 'D': D, 'tau_hat': tau_hat}).sort_values('tau_hat', ascending=False)
    cum_D, cum_n_C = df['D'].cumsum(), (np.arange(1, len(df)+1) - df['D'].cumsum()).clip(lower=1)
    qini = (df['Y']*df['D']).cumsum() - (df['Y']*(1-df['D'])).cumsum() * (cum_D/cum_n_C)
    return np.arange(1, len(df)+1)/len(df), qini

frac, qini = qini_curve(Y, D, tau_hat)
frac_r, qini_r = qini_curve(Y, D, np.random.permutation(tau_hat))  # baseline aleatorio
plt.plot(frac, qini, label='Causal Forest', lw=2)
plt.plot(frac_r, qini_r, label='Random', lw=2, ls='--', color='gray'); plt.legend()
```

Tests formales de heterogeneidad: BLP, BEST y CLAN (Chernozhukov et al., 2020)

La curva Qini evalúa ranking; no responde si la heterogeneidad detectada es estadísticamente distinguible de cero. BLP (Best Linear Predictor): sobre una muestra de evaluación separada (sample-splitting), $Y^* = \beta 1 \cdot \hat{T} + \beta 2 \cdot (\hat{T} - \bar{T}) \cdot \hat{T} + \varepsilon$; H0:$\beta 2 = 0$ testea 'no hay heterogeneidad linealmente detectable por $\hat{T}$'. BEST: partición por la mediana de $\hat{T}$, test de diferencia de efectos medios entre los dos grupos. CLAN: efectos medios por cuantiles de $\hat{T}$ con IC simultáneos, para perfilar la forma de la heterogeneidad sin compromiso paramétrico. Los tres están en econml.validate.DRtester. Regla operativa: ningún informe de heterogeneidad se publica sin el BLP; si $\beta 2$ no es significativo, la heterogeneidad se declara exploratoria.

Intervalos conformes para efectos individuales

El teorema de cobertura del CATE cubre $\tau(x)$, no el efecto individual $Y_i(1)-Y_i(0)$: su varianza incluye el ruido ε_i, que la varianza del estimador no captura — y las decisiones individuales del servicio (Cap. 15) requieren justamente eso. Split conformal sobre el transformed outcome: (1) particionar en entrenamiento y calibración; (2) entrenar $\hat{\tau}$ en el primero; (3) calcular residuos no conformes $R_i=|Y^*_i-\hat{\tau}(X_i)|$ en el segundo; (4) $\hat{C}(x)=[\hat{\tau}(x)-\hat{q},\ \hat{\tau}(x)+\hat{q}]$ con $\hat{q}$ el cuantil adecuado de $\{R_i\}$. Si las observaciones son intercambiables, la cobertura marginal es $\geq 1-\alpha$ sin supuestos distribucionales sobre (Y,D,X). Dos advertencias: la cobertura es del transformed outcome, no de $Y_i(1)-Y_i(0)$ literal; y con propensity estimado se requiere conformal ponderado, no la versión sin ponderar.

RATE: selección formal de estimadores de CATE

```
# RATE: Rank-Weighted Average Treatment Effect (Yadlowsky et al., 2021)
# WET(alpha) = efecto promedio sobre el top-alpha bajo el ranking de tau_hat
# RATE(alpha) = integral_0^alpha WET(u) du
# Pondera las regiones del ranking donde los errores de priorizacion
# cuestan mas; admite inferencia via influence function: la diferencia
# de RATE entre dos estimadores tiene IC valido, analogo al test de
# diferencia de AUC entre clasificadores.
from econml.score import RScorer  # implementa esta comparacion (Ap. B)
```

💡 Regla operativa: la elección entre meta-learners y causal forest en datos reales se documenta con la diferencia de RATE y su IC, no con la inspección visual de Qini. Qini sigue siendo la métrica de reporte para audiencias de negocio (Cap. 22); RATE es la métrica de decisión interna.

```
}
```

Caso aplicado · thornton_hiv (experimento aleatorizado)

Recordatorio del caso

Incentivos monetarios sobre demanda de resultados de test de VIH,
Malaui. Tratamiento ALEATORIZADO — identificación no está en discusión.

Resultado numérico

Ranking top-20% muestra uplift sustancialmente mayor que el promedio.

Lectura de política · Sirve como banco de pruebas de control: toda desviación en la suite de refutación es atribuible al estimador, no al diseño — a diferencia de datos observacionales donde ambas fuentes de error se confunden.

Nivel PCH	Estimando / métrica principal
L2 (evaluación de la estimación, no un nivel nuevo)	Qini/AUUC (ranking) + BLP/BEST/CLAN (heterogeneidad formal) + RATE (selección de estimador) + conformal (IC individual) + sensibilidad en 3 niveles (E-value/R^2/Manski)

Pregunta activa (1 min)

Un AUUC excelente y un E-value bajo — ¿qué le dice cada uno que el otro no puede decirle?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes y conexiones

Errores comunes

Validar con R^2 de Y: el R^2 predictivo no correlaciona con la calidad causal — un modelo puede predecir Y perfectamente y dar CATE sesgado.

Omitir placebo tests en datos reales: sin ground truth, son la única validación de especificación.

Sobreinterpretar Qini creciente como CATE insesgado: indica buen ranking, no ausencia de sesgo en la magnitud.

Conexiones conceptuales

Baselines obligatorios (efecto constante, aleatorio, riesgo sin causalidad) versionados junto al modelo — precondición del Cap. 15.

Discusión y ejercicio

Pregunta de discusión

¿Por qué reportar un AUUC sin banda de confianza por bootstrap invita a declarar ganador a un modelo que no lo es?

Ejercicio (5-10 min)

Implemente el transformed outcome Y^* y calcule la correlación con $\hat{\tau}$. ¿Es alta? ¿Qué dice esto sobre la calidad del estimador?

Cierre del capítulo

Resumen

- $\tau(x)$ nunca se observa — la validación es siempre indirecta.
- Qini/AUUC miden ranking; BLP/BEST/CLAN dan un test formal de heterogeneidad; RATE decide entre estimadores; conformal da IC individual.
- La sensibilidad ya no es solo E-value: es un protocolo de tres niveles (E-value, R^2, bounds de Manski), y baselines + versionado hacen el proceso comparable en el tiempo.

Referencias clave

(1) VanderWeele & Ding (2017), E-value

(2) Cinelli & Hazlett (2020), sensibilidad en escala R^2

(3) Radcliffe (2007), curva Qini

(4) Chernozhukov et al. (2020), BLP/BEST/CLAN

(5) Yadlowsky et al. (2021), RATE

(6) Huyen (2022), Cap. 6, evaluación offline versionada

Próximo episodio · Cap. 15 — Despliegue de un estimador causal como servicio

Gancho: Con el proceso de evaluación versionado y reproducible, la pregunta natural es cómo llevar el estimador que pasó esa evaluación a un servicio que otros puedan consultar.