16

CAPÍTULO 16

◇ Profundización electiva

Post-Double-Selection LASSO

Parte III · Sesión ampliación de S5

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Aplicar PDS: doble selección LASSO + OLS final.
2. Elegir entre λ por validación cruzada y λ teóricamente justificado — y por qué reportar ambos.
3. Comparar PDS con DML y saber cuándo cada uno es preferible.

⋆ Antes de clase

Lectura: Cap. 16 — Post-Double-Selection (@cap-pds) — profundización, no bloquea el camino ⋆
Lab: —
Entrega/hito: —

Agenda

01 · NHEFS: 51 covariables, ¿cuáles son confusoras?

02 · Post-Double-Selection: tres pasos

03 · Teorema (Belloni, Chernozhukov & Hansen, 2014)

04 · λ_CV vs. λ_BCH: la elección no es un detalle

05 · Caso: efecto de dejar de fumar sobre el peso

Problema

NHEFS: 51 covariables tras excluir post-tratamiento. No todas son confusoras; algunas no afectan ni a D ni a Y, otras solo a Y. ¿Cómo seleccionar automáticamente las relevantes sin el sesgo post-selección del Cap. 6?

Gancho aplicado

Las confusoras son las variables que predicen TANTO al tratamiento COMO al resultado — seleccionar por separado y tomar la unión diluye el sesgo de selección individual.

Caso del curso · Efecto de dejar de fumar sobre el cambio de peso (NHEFS).

Post-Double-Selection (Belloni, Chernozhukov & Hansen, 2014)

Bajo sparsity aproximada de γ0 y β0, restricted eigenvalue, y regularidad estándar: √n($\hat{\theta}$_PDS − θ0) →ˆd N(0,V). La inferencia t-Student estándar es válida. Tres pasos: (1) LASSO de Y sobre X → S_Y; (2) LASSO de D sobre X → S_D; (3) OLS de Y sobre D y S_Y∪S_D.

Demostración: idea principal

Paso 1. λ_{CV} minimiza error de PREDICCIÓN — tiende a ser más pequeño que el teóricamente justificado, seleccionando de más.

↓

Paso 2. $\lambda_{\text{BCH}} = \frac{c \cdot \sigma}{\sqrt{n}} \cdot \Phi^{-1}\left(1 - \frac{\gamma}{2p}\right)$ — calibrado para dominar el «ruido máximo» entre las p variables candidatas (ajuste tipo Bonferroni).

↓

Paso 3. Recomendación operativa: reportar AMBAS estimaciones. Si coinciden, la elección era inmaterial; si difieren, la discrepancia es información sobre cuántos controles se admiten.

Recordatorio del caso

n=1566, 51 controles potenciales.

Resultado numérico

OLS sin controles 2.54 kg; manual (5 controles) 3.20 kg; PDS 3.22 kg (18 variables); DML-GBM 3.13 kg.

Lectura de política · Consistentes entre métodos con controles (3.13-3.22 kg) — valida la robustez del efecto pese a las distintas estrategias de selección.

Nivel PCH	**Estimando / métrica principal**
L2 (no confusión condicional, bajo esparsidad y linealidad)	$\hat{\theta}$_PDS con IC t-Student

Pregunta activa (1 min)

PDS no usa cross-fitting como DML — ¿por qué la teoría de BCH no lo necesita, y qué le cuesta esa decisión cuando la linealidad falla?

Escalera PCH: L1 (asociación) $\subseteq$ L2 (intervención) $\subseteq$ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Discusión y ejercicio

Pregunta de discusión

¿Cuándo preferir PDS sobre DML, y viceversa?

Ejercicio (5-10 min)

Implemente la penalización teórica de BCH y compare, sobre nhefs, el λ_BCH resultante con el λ_CV. ¿Cambia el efecto estimado o solo el tamaño del conjunto seleccionado?

Cierre del capítulo

Resumen

- PDS selecciona confusoras dos veces (Y y D) y toma la unión — diluye el sesgo de selección individual del Cap. 6.
- λ por CV y λ teórico (BCH) responden preguntas distintas; reportar ambos.
- PDS falla bajo confusión densa; ahí DML (Cap. 11) es preferible.

Próximo episodio · Cap. 17 — Machine learning causal en datos de panel

Gancho: PDS resuelve alta dimensión bajo linealidad y esparsidad; cuando los datos son un panel o hay endogeneidad, se necesita otra estructura.

Referencias clave

(1) Belloni, Chernozhukov & Hansen (2014), Post-Double-Selection