# Progreso del curso · 32 capítulos, 9 partes

## Parte 0
Introducción

1 2

## Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

## Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

## Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

## Parte IV
Publicación y operación en producción

19 20

## Parte V
Heterogeneidad, políticas y targeting

**21** 22

## Parte VI
Explicación, equidad y decisión

23 24 25 26

## Parte VII
Métodos avanzados

27◇ 28◇

## Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

21

CAPÍTULO 21

★ Camino crítico

# Aprendizaje de políticas óptimas

Parte V · Sesión S22

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

# Roadmap del capítulo

## Objetivos de aprendizaje

1. Formalizar policy value y welfare regret.
2. Atribuir correctamente EWM (Kitagawa-Tetenov) vs. su extensión con nuisance de ML (Athey-Wager).
3. Construir un policy tree con restricción presupuestaria.

**⋆ Antes de clase**

**Lectura:** Cap. 21 — Policy learning (@cap-policy-learning)
**Lab:** L22
**Entrega/hito:** A4 arranca

## Agenda

**01** · Presupuesto para 30% de la población, ¿a quién tratar?

**02** · Policy value y política óptima $\pi^*(x) = \mathbf{1}\{\tau(x) > 0\}$

**03** · EWM: regret sobre VC-dimensión finita

**04** · Extensión con nuisance de ML (Athey & Wager)

**05** · DGP sintético: targeting vs. aleatorio vs. tratar a todos

# Problema causal, estimando e identificación

**Problema**

Programa de capacitación laboral, \$1000/hogar, cubre solo 30% de la población. El CATE varía ampliamente: \$2500 en algunos hogares, ~0 en otros.

## Gancho aplicado

¿Qué regla de asignación, dada una restricción presupuestaria, maximiza el bienestar agregado?

**Caso del curso** · gov_transfers — DGP SINTÉTICO (advertencia del capítulo: covariables reales, tratamiento y resultado simulados para poder medir el regret).

**Policy value y regret**

$V(\pi)=E[Y(\pi(X))]=E[\mu 0(X)+\pi(X)\tau(X)]$. Política óptima $\pi^*(x)=1\{\tau(x)>0\}$.
Regret$(\hat{\pi})=V(\pi^*)-V(\hat{\pi})=E[(\pi^*(X)-\hat{\pi}(X))\tau(X)]$.

**EWM (Kitagawa & Tetenov, 2018) vs. su extensión (Athey & Wager, 2021)**

EWM: sobre una clase $\Pi$ de VC-dimensión finita, el regret contra la MEJOR política de la clase (no la óptima sin restricciones) es $O(\sqrt{(VC(\Pi)/n)})$ — óptimo minimax, y NO requiere estimar bien el CATE. Athey & Wager EXTIENDEN esto al caso con nuisance estimados por ML: si el policy value se construye con el score doblemente robusto y cross-fitting, la tasa se conserva porque el error de los nuisance entra solo a segundo orden.

# Demostración: idea principal

**Paso 1.** El regret de EWM se mide contra $\max_{\pi \in \Pi} V(\pi)$, no contra $\pi^*$ sin restricciones — el error de aproximación de la clase no desaparece con más datos.

↓

**Paso 2.** Athey & Wager aplican la misma estructura de DML (ortogonalidad + cross-fitting) al problema de OPTIMIZACIÓN sobre una clase de políticas, no solo a la estimación de un escalar.

↓

**Paso 3.** Consecuencia práctica: un CATE con RMSE alto puede seguir dando una política casi óptima — «el CATE es malo» y «la política es buena» no son afirmaciones contradictorias.

**Inferencia sobre el policy value (EIF)**

La efficient influence function de $V(\pi)$ bajo no confusión y soporte común es $\psi\pi(W) = \mu\pi(X)(X) + 1\{D{=}\pi(X)\}/e\pi(X)(X) \cdot (Y{-}\mu\pi(X)(X)) - V(\pi)$ — caso particular de la forma canónica del Cap. 10 (fila 'Policy value'). Por tanto $\sqrt{n}(\hat{V}(\pi){-}V(\pi)){\to}N(0,E[\psi\pi^2])$, y la comparación de dos políticas candidatas $\hat{\pi}A$, $\hat{\pi}B$ sobre el mismo hold-out usa el test $z{=}(\hat{V}(\hat{\pi}A){-}\hat{V}(\hat{\pi}B))/\sqrt{(SE^2A{+}SE^2B{-}2 \cdot Cov)}$, con varianzas estimadas por la influence function de cada una sobre las mismas observaciones. No basta con reportar cada welfare puntual con su propio IC — este es el test que falta para decidir si una política domina a otra.

**Punto de quiebre · Conceptual**

★ Si la curva de targeting NO se separa de la aleatoria, ¿cuál es la política óptima? (Tratar a todos o a nadie según el signo del ATE — no hay heterogeneidad accionable.)

⏱️ 2-4 min · Votación mano alzada o Mentimeter

# Policy tree con restricción presupuestaria — parte 1

```python
import numpy as np
import pandas as pd
from econml.dml import CausalForestDML
from econml.policy import PolicyTree
from sklearn.ensemble import GradientBoostingRegressor, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split

# DGP SINTETICO: X reales (gov_transfers); D/tau/Y simulados para medir regret
df = pd.read_csv('../data/datasets/real/public_causaldata/gov_transfers/data.csv')
rng = np.random.default_rng(42)
X = df.select_dtypes(include=[np.number]).dropna(axis=1).values[:len(df)][:, :10]
D = rng.binomial(1, 0.5, len(df))         # asignacion aleatoria SIMULADA
tau_true = 2 * X[:, 0] + X[:, 1]          # CATE verdadero SIMULADO
Y = X[:, 2] + D * tau_true + rng.standard_normal(len(df))
X_tr, X_te, Y_tr, Y_te, D_tr, D_te, tau_te = train_test_split(
    X, Y, D, tau_true, test_size=0.3, random_state=42)

# CATE y policy tree se aprenden SOLO en train
cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, random_state=42),
    discrete_treatment=True, n_estimators=400, min_samples_leaf=20,
    cv=5, random_state=42).fit(Y_tr, D_tr, X=X_tr)
policy = PolicyTree(max_depth=3, min_samples_leaf=50, random_state=42)
policy.fit(X_tr, cf.effect(X_tr))

# Evaluacion en hold-out con ground truth sintetico
pi_te = policy.predict(X_te).astype(int)
welfare = tau_te[pi_te == 1].mean() * pi_te.mean()
print(f"Welfare hold-out: {welfare:.4f} | Fraccion tratada: {pi_te.mean():.3f}")

# IC del policy value via EIF
e_hat = LogisticRegression(max_iter=1000).fit(X_tr, D_tr).predict_proba(X_te)[:, 1]
mu_pi = np.where(pi_te == 1, cf.effect(X_te), 0.0)
psi = mu_pi + pi_te * (Y_te - mu_pi) / np.clip(e_hat, 0.01, 0.99) - welfare
print(f"IC 95% policy value: {welfare:.4f} +/- {1.96 * psi.std(ddof=1) / np.sqrt(len(Y_te)):.4f}")
```

# Restricción presupuestaria — parte 2

```
# Restriccion: tratar maximo al 30% con mayor CATE
cate = cf.effect(X)                  # CATE estimado sobre toda la muestra
threshold = np.quantile(cate, 0.70)  # cuantil 70% = top 30%
pi_budget = (cate > threshold).astype(int)
welfare_budget = cate[pi_budget == 1].mean() * pi_budget.mean()
print(f"Welfare con restriccion presupuestaria (30%): {welfare_budget:.4f}")
print(f"Welfare de tratar a todos: {cate.mean():.4f}")
print(f"Welfare de no tratar a nadie: 0.0")
```

# Caso aplicado · Targeting vs. aleatorio vs. tratar a todos

### Recordatorio del caso

gov_transfers (covariables reales, D/Y/$\tau$ simulados). Presupuesto: 30% de la población.

### Resultado numérico

Targeting por CATE obtiene welfare ~3× mayor que aleatorio al mismo presupuesto.

**Lectura de política** · Que la curva domine en todo el rango es mecánico si $\hat{\tau}$ ordena mejor que el azar — lo informativo sería lo contrario: si NO se separa, no hay heterogeneidad accionable.

| **Nivel PCH** | **Estimando / métrica principal** |
|---|---|
| L2 (decisión basada en efecto, no en riesgo) | V(π), regret sobre clase Π; IC vía EIF para comparar dos políticas |

**Pregunta activa (1 min)**

Si solo predijéramos quién tiene mayor Y esperado sin tratamiento,
¿la asignación coincidiría con $\pi^*(x)=1\{\tau(x)>0\}$? ¿Por qué no en general?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

## Errores comunes

Evaluar el policy value in-sample: welfare optimista por overfitting — usar siempre hold-out.

Ignorar equidad: auditar la distribución demográfica de los tratados.

CATE mal calibrado produce un umbral de tratamiento incorrecto.

### Conexiones conceptuales

El @cap-decisiones-estructurales generaliza este marco a acciones no binarias y a criterios de decisión bajo identificación parcial.

# Discusión y ejercicio

**Pregunta de discusión**

El Cap. 21 es un caso particular del marco de decisiones estructurales del Cap. 25 — identifique explícitamente cuál es el conjunto de acciones $cal(D)$ y cuál la utilidad $U$ en este capítulo.

**Ejercicio (5-10 min)**

Compare tres políticas: tratar a todos, aleatorio 30%, top 30% por CATE estimado. ¿En cuánto mejora el welfare?

# Cierre del capítulo

## Resumen

- Policy value y regret formalizan «a quién tratar» bajo presupuesto.
- EWM (Kitagawa-Tetenov) da la cota de regret; Athey-Wager la extienden con nuisance de ML.
- Un CATE mediocre puede seguir dando una política casi óptima — son preguntas distintas.

## Referencias clave


(1) Kitagawa & Tetenov (2018), Empirical Welfare Maximization

(2) Athey & Wager (2021), policy learning con nuisance de ML


**Próximo episodio** · Cap. 22 — Uplift modeling y targeting económico

*Gancho: Policy learning decide a quién; en marketing y programas sociales la pregunta se vuelve con qué acción, entre varias con costos distintos.*