Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 **22**

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

22

CAPÍTULO 22

★ Camino crítico

Uplift modeling y targeting económico

Parte V · Sesión S23

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Distinguir cuándo basta el ranking de cuándo se necesita magnitud calibrada.
2. Implementar net score con presupuesto y múltiples tratamientos.
3. Publicar la política en un Space de Hugging Face.

★ Antes de clase

Lectura: Cap. 22 — Uplift (@cap-uplift-targeting)
Lab: L23
Entrega/hito: A4 + B3 · Validar con grade_a4.py / grade_b3.py

Agenda

01 · Telco: SMS vs. llamada, presupuesto $100,000

02 · Uplift = CATE, pero el foco es ranking + cost-effectiveness

03 · Qini/AUUC/coeficiente Qini

04 · Net score con costo sombra λ

05 · Un estimador de uplift POR ACCIÓN, no uno escalado

Problema

Telco: no hacer nada / SMS (\$0.5) / llamada (\$8). ¿A qué clientes aplicar cada acción, con presupuesto \$100,000?

Gancho aplicado

Ranking basta si la decisión es "a quién tratar con presupuesto fijo"; magnitud calibrada es necesaria si la decisión es "cuánto presupuesto" o "qué acción entre varias con costos distintos".

Caso del curso · Reducción de churn: SMS vs. llamada personalizada.

Definiciones clave

Uplift	Matemáticamente igual al CATE — el foco cambia a ranking y cost-effectiveness.
AUUC	Área bajo la curva uplift — depende de n y escala de Y.
Coeficiente Qini	AUUC normalizada — comparable entre datasets.

Net score con costo sombra

$\pi^*(x)=\text{argmax_k}\ \{\tau_k(x)-\lambda^*\cdot c_k(x)\}$, donde λ^* es el multiplicador de Lagrange (costo sombra) que agota el presupuesto B. Bisección sobre λ garantiza convergencia.

Demostración: idea principal

Paso 1. Cada acción tiene su propio patrón de heterogeneidad — no existe forma de derivar $\tau_{\text{llamada}}(x)$ a partir de $\tau_{\text{SMS}}(x)$ escalándolo por un factor.

↓

Paso 2. Se necesita UN estimador por acción, cada uno contra el brazo de control sobre su propia submuestra — comparar SMS contra llamada directamente estimaría $\tau_{\text{llamada}} - \tau_{\text{SMS}}$, una pregunta distinta.

↓

Paso 3. El net score compara $\tau_k(x) - \lambda c_k(x)$ entre acciones: la llamada cara se asigna solo donde su uplift adicional justifica la diferencia de costo.

Punto de quiebre · Aplicado

★ Multiplicar uplift_call × 3 para simular otro tratamiento — ¿cambia el Qini de esa acción? ¿Cambia la asignación óptima? (Ranking invariante a escala; asignación NO.)

⏱ 2-4 min · Votación mano alzada o Mentimeter

Uplift multi-tratamiento — un estimador por acción

```python
import numpy as np
import pandas as pd
from xgboost import XGBRegressor
from causalml.inference.meta import BaseTRegressor
from causalml.metrics import qini_score

FEATURES = [f"x{i}" for i in range(8)]

def make_churn_data(n=5000, seed=42):
    """DGP sintetico de churn con TRES brazos: control, SMS, llamada."""
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 8))
    arm = rng.choice(["control", "sms", "call"], size=n, p=[0.4, 0.3, 0.3])
    tau_sms = 0.06 - 0.05*X[:, 0] + 0.03*X[:, 1]   # uplift del SMS
    tau_call = 0.12 + 0.09*X[:, 1] - 0.02*X[:, 3]  # uplift de la llamada
    p = 0.45 + 0.08*X[:, 2] + (arm == "sms")*tau_sms + (arm == "call")*tau_call
    Y = (rng.uniform(size=n) < np.clip(p, 0, 1)).astype(int)
    df = pd.DataFrame(X, columns=FEATURES)
    df["y"], df["arm"] = Y, arm
    return df

df = make_churn_data(5000)

def uplift_por_accion(df, accion, features=FEATURES):
    """Estima tau_accion(x) contra el brazo de control, no entre activos."""
    sub = df[df["arm"].isin(["control", accion])]
    m = BaseTRegressor(learner=XGBRegressor(max_depth=3, n_estimators=200))
    m.fit(sub[features].values, (sub["arm"] == accion).astype(int).values, sub["y"].values)
    return m.predict(df[features].values).ravel()   # sobre TODA la muestra

# Un estimador POR ACCION -> dos columnas de uplift, ambas estimadas
df["uplift_sms"] = uplift_por_accion(df, "sms")
df["uplift_call"] = uplift_por_accion(df, "call")

# Ranking por accion sobre su propia submuestra {control, accion}
for accion in ["sms", "call"]:
    sub = df[df["arm"].isin(["control", accion])].copy()
    sub["treatment"] = (sub["arm"] == accion).astype(int)
    print(f"{accion}: Qini = {qini_score(sub[['y', 'treatment', f'uplift_{accion}']])}")
```

Net score con bisección de λ

```python
# Costos unitarios y presupuesto de la campana
COSTOS = {"nada": 0.0, "sms": 0.5, "call": 8.0}
BUDGET = 100_000
n = len(df)

# Estrategias A y B: una sola accion, a los de mayor uplift
asig_a = np.full(n, "nada", dtype=object)
asig_a[df["uplift_sms"].to_numpy().argsort()[::-1][:int(BUDGET / COSTOS["sms"])]] = "sms"
asig_b = np.full(n, "nada", dtype=object)
asig_b[df["uplift_call"].to_numpy().argsort()[::-1][:int(BUDGET / COSTOS["call"])]] = "call"

# Estrategia C: net score con costo sombra — biseccion de lambda
def asignar_net_score(df, budget, lo=0.0, hi=1.0, tol=1e-4, max_iter=60):
    for _ in range(max_iter):
        lam = (lo + hi) / 2
        scores = np.column_stack([np.zeros(len(df)),                # no hacer nada
                                  df["uplift_sms"] - lam*COSTOS["sms"],
                                  df["uplift_call"] - lam*COSTOS["call"]])
        asig = np.array(["nada", "sms", "call"], dtype=object)[scores.argmax(axis=1)]
        gasto = np.array([COSTOS[a] for a in asig]).sum()
        if abs(gasto - budget) < tol * budget:
            break
        lo, hi = (lam, hi) if gasto > budget else (lo, lam)
    return asig

asig_c = asignar_net_score(df, BUDGET)

def uplift_total(df, asig):
    u = np.where(asig == "sms", df["uplift_sms"],
                 np.where(asig == "call", df["uplift_call"], 0.0))
    return u.sum(), np.array([COSTOS[a] for a in asig]).sum()

for nombre, asig in [("A (solo SMS)", asig_a), ("B (solo llamadas)", asig_b),
                     ("C (net score, mixto)", asig_c)]:
    u, g = uplift_total(df, asig)
    print(f"{nombre:20s} uplift={u:8.1f} gasto={g:10.1f}")
```

Recordatorio del caso

Presupuesto \$100,000. Costo SMS \$0.5, llamada \$8.

Resultado numérico

La estrategia C (net score, mixta) domina a A y B por separado.

Lectura de política · C optimiza conjuntamente A QUIÉN y CON QUÉ ACCIÓN; A y B fijan la acción de antemano y solo optimizan a quién alcanzar.

Nivel PCH	**Estimando / métrica principal**
L2 heterogéneo, multi-tratamiento	$\tau_k(x)$ por acción; Qini/AUUC; net score con λ^*

Pregunta activa (1 min)

Si solo predijéramos qué clientes tienen mayor probabilidad de irse (riesgo), ¿coincidiría con a quién conviene enviar la llamada cara?

Escalera PCH: L1 (asociación) $\subseteq$ L2 (intervención) $\subseteq$ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Multiplicar uplift ad hoc para inferir el efecto de otro tratamiento — cada acción necesita su propio estimador.

Optimizar solo AUUC sin validar calibración: transformed outcome (Cap. 14) para magnitudes insesgadas.

Medir costos incorrectamente o ignorar costos hundidos.

Conexiones conceptuales

Las mismas curvas Qini del Cap. 14 reaparecen aquí como criterio de evaluación de la POLÍTICA, no solo del estimador.

Discusión y ejercicio

Pregunta de discusión

¿En qué casos el uplift modeling es preferible al policy learning formal (Cap. 21)?

Ejercicio (5-10 min)

Sobre el DGP de tres brazos, compare el uplift promedio de cada acción con el ranking que produce. Verifique que la acción con mayor efecto promedio no es necesariamente la que conviene asignar a cada cliente.

Cierre del capítulo

Resumen

- Ranking basta para «a quién»; magnitud calibrada es necesaria para «cuánto» o «qué acción».
- Cada tratamiento necesita su propio estimador de uplift — no se deriva escalando.
- Net score con costo sombra optimiza conjuntamente a quién y con qué acción tratar.

Referencias clave

(1) Radcliffe (2007), curva Qini

(2) Rzepakowski & Jaroszewicz (2012), árboles de uplift multi-tratamiento

(3) Chen et al. (2020), causalml

Próximo episodio · Cap. 23 — Explicación causal y equidad algorítmica (S19 en el orden real de enseñanza, ya cubierto antes en el libro)

Gancho: Con el CATE ya usado para decidir a quién y con qué acción tratar, falta preguntar si esa decisión se puede explicar del mismo modo que se calculó.