Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

23

CAPÍTULO 23

★ Camino crítico

Explicación causal y equidad algorítmica

Parte VI · Sesión S19

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Descomponer un efecto en directo/indirecto/espurio.
2. Aplicar equidad contrafactual (Kusner et al., 2017).
3. Distinguir discriminación por proxy de influencia no resuelta (Kilbertus et al., 2017).

⋆ Antes de clase

Lectura: Cap. 23 — Explicación y equidad (@cap-explicacion-equidad)
Lab: L19
Entrega/hito: —

Agenda

01 · ¿El efecto de un atributo protegido pasa por una ruta legítima?

02 · CDE / NIE: descomposición directo/indirecto

03 · Equidad contrafactual

04 · Proxy vs. influencia no resuelta — dos remedios distintos

05 · Caso: brecha salarial y Oaxaca-Blinder

Problema causal, estimando e identificación

Problema

Un algoritmo de decisión (contratación, crédito, libertad condicional) produce resultados distintos según un atributo protegido — ¿ese efecto pasa por una ruta legítima o por una discriminatoria?

Gancho aplicado

Distinto del Cap. 24: SHAP es asociativo (atribuye contribución estadística); este capítulo pregunta si esa covariación refleja un mecanismo legítimo.

Caso del curso · Brecha salarial de género, ocupación como mediador.

Descomposición directo/indirecto/espurio

CDE(m)=E[Y|do(A=1,M=m)]−E[Y|do(A=0,M=m)]: efecto de A sobre Y que NO pasa por M. NIE: la porción que sí pasa por el cambio que A induce en M. La pregunta de equidad no es si el efecto total es distinto de cero, sino si el efecto DIRECTO lo es.

Proxy vs. influencia no resuelta (Kilbertus et al., 2017)

Un PROXY es una variable observada, descendiente del atributo protegido (código postal ≈ raza) — la discriminación por proxy se elimina por CONSTRUCCIÓN, cortando la ruta A→proxy→$\hat{Y}$, sin observar A. La INFLUENCIA NO RESUELTA viaja por rutas no declaradas legítimas que no pasan por ninguna variable observable intervenible — exige una decisión NORMATIVA, no técnica. Confundir ambas es el error típico de auditorías que solo quitan la variable sensible del modelo.

Demostración: idea principal

Paso 1. Identificar los proxies del atributo protegido en el grafo (variables observadas, descendientes de A).

↓

Paso 2. Neutralizar técnicamente los proxies: cortar su ruta hacia $\hat{Y}$ en el modelo de decisión.

↓

Paso 3. Para la influencia no resuelta: declarar explícitamente qué rutas se consideran legítimas — una decisión normativa que ningún algoritmo puede automatizar.

Punto de quiebre · Conceptual

★ Declarar M (ocupación) como mediador legítimo sin análisis histórico — ¿qué se puede estar blanqueando si el acceso a esa ocupación estuvo históricamente restringido por género?

⏱️ 2-4 min · Votación mano alzada o Mentimeter

Descomposición directo/indirecto — SCM simulado

```python
import numpy as np
import pandas as pd

rng = np.random.default_rng(3)
n = 20_000

# A: atributo protegido (0/1); M: mediador legitimo (ocupacion);
# Y: salario. Efecto directo deliberado (discriminacion) = 0.15
A = rng.binomial(1, 0.5, size=n)
M = 0.5 * A + rng.normal(scale=1, size=n)  # A -> M (legitimo)
Y = 0.15 * A + 0.6 * M + rng.normal(scale=1, size=n)  # directo 0.15 + via M

df = pd.DataFrame({"A": A, "M": M, "Y": Y})

# Efecto total (asociativo, sin descomponer)
efecto_total = df.loc[df.A == 1, "Y"].mean() - df.loc[df.A == 0, "Y"].mean()

# CDE: fijar M en su media global y comparar A=1 vs A=0
m_fijo = df["M"].mean()
cde = (0.15 * 1 + 0.6 * m_fijo) - (0.15 * 0 + 0.6 * m_fijo)

print(f"Efecto total A->Y:          {efecto_total:.3f}")
print(f"Efecto directo controlado:  {cde:.3f}  (deberia acercarse a 0.15)")
print(f"Efecto indirecto (via M):   {efecto_total - cde:.3f}")
```

Chequeo de sanidad

```python
# assert abs(cde - 0.15) < 0.02
```

Recordatorio del caso

Efecto total observado se descompone en: parte explicada por ocupación/experiencia/sector (indirecto) y un residuo no explicado (aprox. al directo).

Resultado numérico

Oaxaca-Blinder es un antecesor estadístico de esta idea en economía laboral.

Lectura de política · El lenguaje de rutas permite declarar EXPLÍCITAMENTE, antes de estimar, qué mediadores se consideran legítimos — en vez de dejarlo implícito en la elección de controles.

Nivel PCH	**Estimando / métrica principal**
L2/L3 (rutas interventivas; equidad contrafactual es L3)	CDE, NIE; equidad contrafactual (Kusner et al.)

Pregunta activa (1 min)

¿Por qué la equidad contrafactual de Kusner et al. es de Nivel 3 de la PCH y no de Nivel 1, y por qué eso la hace más difícil de verificar empíricamente que la paridad demográfica?

Escalera PCH: L1 (asociación) $\subseteq$ L2 (intervención) $\subseteq$ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Declarar un mediador legítimo sin análisis histórico de si esa ruta perpetúa discriminación pasada.

La legitimidad de una ruta es una decisión normativa, no estadística — ningún test la determina.

Sensibilidad al grafo: un mediador omitido infla artificialmente el efecto directo estimado.

Conexiones conceptuales

El Cap. 24 complementa esto con la caja de herramientas de uso más frecuente en la práctica: SHAP y las tres familias observacionales de fair ML.

Discusión y ejercicio

Pregunta de discusión

Proponga dos mediadores para la brecha salarial: uno que consideraría legítimo y uno cuestionable de aceptar, aun si estadísticamente media parte del efecto. Justifique la distinción normativa.

Ejercicio (5-10 min)

Modifique el listado para que el efecto directo verdadero sea 0. Verifique que el CDE estimado converge a 0 mientras el efecto indirecto se mantiene distinto de cero.

Cierre del capítulo

Resumen

- El efecto total se descompone en directo (potencial discriminación) e indirecto (potencialmente legítimo).
- Proxy y influencia no resuelta requieren remedios de naturaleza distinta: técnico vs. normativo.
- La legitimidad de una ruta es siempre una decisión normativa que el análisis causal formaliza pero no reemplaza.

Referencias clave

(1) Pearl (2009), fórmulas de mediación causal

(2) Kusner et al. (2017), equidad contrafactual

(3) Kilbertus et al. (2017), proxy vs. influencia no resuelta

Próximo episodio · Cap. 24 — Ética, interpretabilidad y comunicación de resultados

Gancho: La descomposición por rutas es el aparato causal de equidad; el capítulo siguiente lo complementa con la caja de herramientas que de verdad se usa en la práctica.