Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 **24** 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

24

CAPÍTULO 24

★ Camino crítico

Ética, interpretabilidad y comunicación de resultados

Parte VI · Sesión S20

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Ubicar un criterio de equidad en su familia correcta (independencia/ separación/ suficiencia) y explicar por qué no pueden satisfacerse a la vez.
2. Explicar SHAP sobre un sustituto del CATE, no sobre el modelo de outcome.
3. Reportar resultados con IC correcto por subgrupo.

⋆ Antes de clase

Lectura: Cap. 24 — Ética e interpretabilidad (@cap-etica-interpretabilidad)
Lab: L20
Entrega/hito: —

Agenda

01 · Un ministerio usa ML causal para focalizar un subsidio

02 · Tres familias: independencia, separación, suficiencia

03 · Teorema de incompatibilidad — el caso COMPAS

04 · SHAP: ¿sobre qué modelo interno?

05 · IC por subgrupo: t-test vs. influence function

Problema causal, estimando e identificación

Problema

Un modelo de ML causal decide qué hogares reciben subsidio, entrenado sobre datos que reflejan desigualdades preexistentes. Puede perpetuar o amplificar esas desigualdades.

Gancho aplicado

La calidad técnica de un modelo causal no se mide solo en precisión estadística sino en sus consecuencias sociales.

Caso del curso · gov_transfers: CATE rural 30% menor que urbano.

Tres familias canónicas de equidad

Independencia (demographic parity): $\pi(X) \perp G$. Separación (equalized odds): $\pi(X) \perp G | Y^*$. Suficiencia (calibración por grupo): $Y^* \perp G | \pi(X)$. Barocas, Hardt & Narayanan organizan toda la literatura de fair ML en estas tres.

Teorema de incompatibilidad

Salvo predicción perfecta o tasas base idénticas entre grupos, NO existe ninguna regla de decisión que satisfaga simultáneamente separación y suficiencia a la vez. El debate COMPAS (falsos positivos desiguales = injusto, bajo separación; calibrado por grupo = justo, bajo suficiencia) no se resuelve con más datos: ambas partes tenían razón bajo su propio criterio.

Demostración: idea principal

Paso 1. No hay una definición de equidad que se «active» en el pipeline — elegir un criterio es descartar los otros.

↓

Paso 2. Equidad EN EL EFECTO (equalized CATE) es una noción propia de este curso, no canónica: responde «¿quién se beneficia?», no «¿a quién se asigna?».

↓

Paso 3. Si el CATE es genuinamente menor en un grupo por razones estructurales, imponer equidad en el efecto no es posible ni deseable — la métrica hace visible la desigualdad, no la corrige por decreto.

Punto de quiebre · Conceptual

★ ¿Por qué un t-test sobre los $\hat{\tau}_i$ subestima la incertidumbre de la brecha de efecto entre grupos?

⏱️ 2-4 min · Votación mano alzada o Mentimeter

SHAP sobre el modelo equivocado (incorrecto) — parte 1

```python
import shap
import numpy as np
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor, GradientBoostingClassifier

# Dataset simulado: mu0 depende de x1; tau = 2 + 3*x0 - 1.5*A
rng = np.random.default_rng(42)
X = rng.uniform(-1, 1, (5000, 5))
A = rng.binomial(1, 0.3, 5000)              # 30% es minoria
tau = 2 + 3*X[:, 0] - 1.5*A
e = 0.4 + 0.2*np.tanh(X[:, 0]) - 0.1*A
D = (rng.uniform(size=5000) < e).astype(int)
Y = X[:, 1] + D*tau + rng.standard_normal(5000)*0.5

cf = CausalForestDML(model_y=GradientBoostingRegressor(random_state=42),
                     model_t=GradientBoostingClassifier(random_state=42),
                     discrete_treatment=True, random_state=42, cv=5).fit(Y, D, X=X)
cate_hat = cf.effect(X)

# (a) INCORRECTO: SHAP sobre cf.model_y — explica que predice Y, NO el efecto
expl_y = shap.TreeExplainer(cf.model_y)
shap_y = expl_y.shap_values(X[:200])
# Solo para contrastar; no reportar esto como "drivers del CATE".
```

💡 $\hat{\mu}_Y$, $\hat{e}$ y $\hat{\tau}$ son tres modelos internos distintos — explicar el equivocado produce conclusiones sistemáticamente engañosas.

SHAP sobre un sustituto del CATE (correcto) — parte 2

```python
import shap
import numpy as np
import pandas as pd
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import cross_val_score

# (b) CORRECTO: SHAP sobre un sustituto del CATE (usa X, cate_hat, shap_y de la parte 1)
surrogate = RandomForestRegressor(n_estimators=300, min_samples_leaf=20, random_state=42)
r2 = cross_val_score(surrogate, X, cate_hat, cv=5, scoring="r2").mean()
surrogate.fit(X, cate_hat)
print(f"Fidelidad del sustituto al CATE (R2 CV): {r2:.3f}")
if r2 < 0.8:
    print("ADVERTENCIA: el sustituto no reproduce bien el CATE")

expl_tau = shap.TreeExplainer(surrogate)
shap_tau = expl_tau.shap_values(X[:200])
shap.summary_plot(shap_tau, X[:200], feature_names=[f"x{i}" for i in range(5)], show=False)

# Contraste explicito de los dos rankings de importancia
imp_y = np.abs(shap_y).mean(axis=0)
imp_tau = np.abs(shap_tau).mean(axis=0)
pd.DataFrame({"feature": [f"x{i}" for i in range(5)],
              "importancia_para_Y": imp_y / imp_y.sum(),
              "importancia_para_CATE": imp_tau / imp_tau.sum()}
             ).sort_values("importancia_para_CATE", ascending=False)
```

Chequeo de sanidad

```
# if r2 < 0.8: print('ADVERTENCIA: sustituto no reproduce el CATE')
```

Caso aplicado · gov_transfers: CATE rural 30% menor

Recordatorio del caso

CausalForestDML, comparación urbano/rural.

Resultado numérico

No es sesgo del modelo — es desigualdad estructural (falta de acceso a mercados).

Lectura de política · La recomendación NO es excluir hogares rurales (amplificaría la desigualdad) sino complementar con inversión en infraestructura.

Mapeo PCH del capítulo · pregunta activa

Nivel PCH	**Estimando / métrica principal**
L1 (SHAP es asociativo) vs. L2 (el CATE que se está explicando)	R^2 de fidelidad del sustituto; IC por subgrupo vía influence function

Pregunta activa (1 min)

Si SHAP sobre el modelo de outcome y SHAP sobre el sustituto del CATE dan rankings de importancia DISTINTOS, ¿cuál responde "qué determina el efecto"?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

SHAP sobre el modelo equivocado: reportar los predictores de Y como si fueran los determinantes del efecto — error de categoría, no aproximación.

IC por subgrupo con t-test sobre los $\hat{\tau}_i$: ignora el error de estimación, produce intervalos demasiado estrechos.

SHAP como causal incluso sobre el CATE correcto: sigue siendo asociativo dentro del modelo, no autoriza afirmaciones de mecanismo.

Conexiones conceptuales

Para preguntas de mecanismo, usar la descomposición por rutas del Cap. 23, no una atribución de importancia.

Discusión y ejercicio

Pregunta de discusión

La equidad causal es un campo activo — las tres familias pueden entrar en conflicto. ¿Qué significa entonces "hacer una auditoría de equidad responsable" si no hay solución técnica única?

Ejercicio (5-10 min)

Use SHAP sobre un sustituto de un Causal Forest entrenado en nhefs. ¿Qué variables son más importantes para la heterogeneidad del efecto de dejar de fumar?

Cierre del capítulo

Resumen

- Independencia, separación y suficiencia son mutuamente incompatibles salvo casos degenerados.
- SHAP debe aplicarse a un sustituto del CATE, nunca al modelo de outcome, si se quiere explicar el EFECTO.
- El IC por subgrupo requiere la influence function del estimador, no un t-test sobre predicciones.

Referencias clave

(1) Barocas, Hardt & Narayanan (2019), **Fairness and Machine Learning**

(2) Hardt et al. (2016), equalized odds

(3) Lundberg & Lee (2017), SHAP

Próximo episodio · Cap. 25 — Decisiones estructurales bajo incertidumbre

Gancho: Explicar y auditar el efecto asume que ya se decidió qué hacer con él; el capítulo siguiente formaliza esa decisión misma, más allá de "tratar o no tratar".