Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 **25** 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

25

CAPÍTULO 25

★ Camino crítico

Decisiones estructurales bajo incertidumbre

Parte VI · Sesión S21

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Formalizar una decisión como maximización de utilidad esperada sobre un conjunto de acciones.
2. Aplicar maximin y minimax regret cuando el efecto solo está parcialmente identificado.
3. Distinguir incertidumbre estadística de incertidumbre estructural.

⋆ Antes de clase

Lectura: Cap. 25 — Decisiones estructurales (@cap-decisiones-estructurales)
Lab: L21
Entrega/hito: —

Agenda

01 · Elegir entre acciones, no solo estimar el efecto de una dada

02 · Decisión óptima: $d^* = \text{argmax}_d \, E[U(Y(\text{do}(d)))]$

03 · Tres criterios bajo identificación parcial

04 · Caso: tres políticas de transferencia

Problema

El Cap. 21 resolvió "tratar o no tratar" bajo presupuesto. Este capítulo generaliza: la acción no tiene por qué ser binaria, y comparar acciones exige una función de utilidad explícita, no solo un efecto estimado.

Gancho aplicado

Cuando el Cap. 21 maximizaba welfare sujeto a presupuesto, ya usaba una función de utilidad particular — lineal en el resultado con restricción de costo.

Caso del curso · Transferencia simple vs. con capacitación, tres políticas candidatas.

Decisión óptima

d* = argmax_d E[U(Y(do(d)))] sobre un conjunto de acciones factibles D y una función de utilidad U. Distinta de estimar τ(x): esta pregunta siempre requiere U, aunque sea implícita.

Tres criterios bajo identificación parcial (Manski, 2004)

Utilidad esperada: maximiza E[U] bajo la estimación puntual — defendible si el efecto está bien identificado y la decisión se repite muchas veces. Maximin (Wald): maximiza el peor resultado dentro del conjunto identificado — decisiones irreversibles o catastróficas en el peor caso. Minimax regret (Savage): minimiza la máxima pérdida respecto a la mejor acción en cada escenario — el que Manski defiende para reglas de tratamiento cuando el maximin resulta paralizante.

Demostración: idea principal

Paso 1. Con un efecto cuyo IC cruza el cero, la utilidad esperada puede recomendar intervenir (punto positivo) mientras el maximin recomienda no hacerlo (peor caso dañino).

↓

Paso 2. El minimax regret puede recomendar una acción intermedia — tratar a un subconjunto, o postergar y experimentar.

↓

Paso 3. «No decidir todavía y experimentar» debería estar en el conjunto de acciones factibles: el valor de un experimento que reduce la incertidumbre compite legítimamente con las acciones sustantivas.

Punto de quiebre · Conceptual

★ El policy learning del Cap. 21 (a quién tratar bajo presupuesto) es un caso particular de este marco — identifique explícitamente cuál es D y cuál es U en ese capítulo.

⏱ 2-4 min · Votación mano alzada o Mentimeter

Selección de acción óptima con incertidumbre

```python
politicas = {
    "sin_intervencion": {"efecto": 0.0, "se": 0.0, "costo": 0},
    "transferencia_simple": {"efecto": 0.12, "se": 0.03, "costo": 500},
    "transferencia_mas_capacitacion": {"efecto": 0.19, "se": 0.05, "costo": 900},
}

def utilidad_esperada(efecto, costo, valor_por_punto_efecto=3000, presupuesto=1000):
    """Utilidad: valor monetario del efecto menos el costo."""
    if costo > presupuesto:
        return -np.inf
    return valor_por_punto_efecto * efecto - costo

for nombre, datos in politicas.items():
    u = utilidad_esperada(datos["efecto"], datos["costo"])
    # bandas de utilidad con +/- 1.96 SE del efecto
    u_low = utilidad_esperada(datos["efecto"] - 1.96*datos["se"], datos["costo"])
    u_high = utilidad_esperada(datos["efecto"] + 1.96*datos["se"], datos["costo"])
    print(f"{nombre:30s} U={u:8.1f}  IC95%=({u_low:.1f}, {u_high:.1f})")

mejor = max(politicas, key=lambda k: utilidad_esperada(politicas[k]["efecto"], politicas[k]["costo"]))
print(f"Accion optima bajo esta utilidad: {mejor}")
```

💡 Reportar el intervalo de utilidad, no solo el punto: una accion con mayor U puntual pero IC muy solapado con otra no es "claramente superior". La accion optima depende de valor_por_punto_efecto — parametro NORMATIVO que ningun dato determina.

Recordatorio del caso

Transferencia simple / con condicionalidad / con capacitación — costos administrativos y efectos esperados distintos.

Resultado numérico

La acción óptima depende críticamente de valor_por_punto_efecto — un parámetro NORMATIVO que ningún dato por sí solo puede determinar.

Lectura de política · Dos analistas razonables pueden discrepar en ese parámetro y llegar a decisiones óptimas distintas con el MISMO efecto estimado.

Nivel PCH	**Estimando / métrica principal**
L2 (utilidad esperada sobre distribución interventiva)	$d^* = \text{argmax } E[U(Y(do(d)))]$; regret bajo cada criterio

Pregunta activa (1 min)

¿Cambia la acción óptima si se usa maximin en vez de utilidad esperada, y qué le dice ese cambio sobre cuánto pesa la incertidumbre en la decisión?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Función de utilidad implícita y no examinada: toda decisión automatizada usa alguna, aunque nadie la haya escrito — hacerla explícita permite auditarla.

Sensibilidad de la decisión a la utilidad supuesta: reportar cómo cambia d^* bajo utilidades alternativas.

Confundir incertidumbre estadística con estructural: un IC estrecho no dice nada sobre si el SCM supuesto es correcto.

Conexiones conceptuales

Conecta con la teoría de la decisión estadística clásica (Berger, 1985) y con el marco de identificación parcial (Manski, 2004).

Discusión y ejercicio

Pregunta de discusión

Proponga una función de utilidad alternativa que dé peso explícito a la equidad distributiva (penalice que el efecto se concentre en un subgrupo). ¿Cambia la acción óptima?

Ejercicio (5-10 min)

Extienda el listado con maximin y minimax regret, tomando como conjunto identificado $\hat{\tau} \pm 1.96 \cdot \mathrm{SE}$ de cada política. ¿Coinciden las tres recomendaciones? Amplíe el SE de la política más costosa y observe cuándo divergen.

Cierre del capítulo

Resumen

- Toda decisión requiere una función de utilidad, aunque sea implícita.
- Bajo identificación parcial, utilidad esperada / maximin / minimax regret pueden recomendar acciones distintas.
- Experimentar es una acción más del conjunto factible cuando la incertidumbre es la restricción vinculante.

Referencias clave

(1) Manski (2004), reglas de tratamiento bajo identificación parcial

(2) Berger (1985), teoría de la decisión estadística

Próximo episodio · Cap. 26 — Generalización y transportabilidad entre dominios

Gancho: Toda decisión estructural asume que el efecto vale para la población sobre la que se decide — ¿y si la política se aplica en otro mercado?