27

CAPÍTULO 27

◇ Profundización electiva

Deep learning para inferencia causal

Parte VII · Sesión electivo avanzado

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Describir TARNet/CFRNet y el rol de la representación balanceada.
2. Explicar por qué balancear no siempre ayuda — α como hiperparámetro a validar.
3. Explicar por qué la inferencia válida con redes NO es un problema abierto.

⋆ Antes de clase

Lectura: Cap. 27 — Deep causal (@cap-deep-causal) — electivo avanzado, no bloquea el camino ⋆
Lab: —
Entrega/hito: —

Agenda

01 · Adherencia a medicamentos, recordatorios personalizados

02 · TARNet/CFRNet: representación compartida + balance IPM

03 · ¿Balancear ayuda siempre? (Curth & van der Schaar, 2021)

04 · Inferencia válida: redes como nuisance dentro de DML

Problema causal, estimando e identificación

Problema

Plataforma de salud digital: efecto de recordatorios personalizados sobre adherencia a medicamentos. Efecto altamente no lineal — Causal Forest puede no capturar la estructura compleja.

Gancho aplicado

TARNet aprende una representación compartida Phi(X); CFRNet añade una penalización que fuerza a que Phi(X) se parezca entre tratados y controles.

Caso del curso · DGP sintético con no linealidades e interacciones de alto orden.

Dos correcciones al estado del arte de 2017

(1) Balancear no siempre ayuda (Curth & van der Schaar, 2021): la cota de Shalit et al. es LAXA — minimizarla no equivale a minimizar el error en tau. Alpha debe validarse, no activarse como interruptor; TARNet sin penalización es competidor serio. (2) La inferencia válida NO es un problema abierto: Farrell, Liang & Misra (2021) dan tasas para redes como nuisance dentro de DML; RieszNet (Chernozhukov et al., 2022) aprende el representador de Riesz en vez de derivarlo a mano.

Demostración: idea principal

Paso 1. Con alpha grande, la representación se vuelve tan balanceada como poco informativa — en el extremo, Phi constante logra balance perfecto y error máximo.

↓

Paso 2. Usar la red donde su capacidad de aproximación aporta: los nuisance de alta dimensión dentro de DML — y dejar la inferencia al aparato ortogonal del Cap. 10, que ya la tiene resuelta.

↓

Paso 3. RieszNet automatiza la construcción del score ortogonal para funcionales sin fórmula analítica derivada a mano.

Punto de quiebre · Conceptual

★ ¿Por qué TARNet sin penalización de balance puede ser un competidor serio frente a CFRNet, si toda la motivación de CFRNet es forzar el balance?

⏱ 2-4 min · Votación mano alzada o Mentimeter

TARNet en PyTorch

```python
class TARNet(nn.Module):
    def __init__(self, in_dim, rep_dim=64, hidden=128):
        super().__init__()
        self.rep = nn.Sequential(          # representacion compartida
            nn.Linear(in_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, rep_dim),
        )
        self.h0 = nn.Sequential(nn.Linear(rep_dim, hidden), nn.ReLU(), nn.Linear(hidden, 1))
        self.h1 = nn.Sequential(nn.Linear(rep_dim, hidden), nn.ReLU(), nn.Linear(hidden, 1))

    def forward(self, X, D):               # solo la cabeza de su grupo
        Phi = self.rep(X)
        return torch.where(D.unsqueeze(-1) == 1, self.h1(Phi), self.h0(Phi)).squeeze(-1)

    def predict_cate(self, X):
        Phi = self.rep(X)
        return (self.h1(Phi) - self.h0(Phi)).squeeze()   # tau_hat(x)

# CFRNet: loss = MSE + alpha * MMD(Phi|D=0, Phi|D=1)  -- alpha a validar
```

💡 CFRNet anade la penalizacion MMD entre Phi(X|D=0) y Phi(X|D=1) a la loss MSE. Alpha es hiperparametro a validar, no un interruptor "balancear es bueno" (Curth & van der Schaar, 2021).

Recordatorio del caso

En vez de estimar tau directamente con una red y buscar cómo hacer inferencia después.

Resultado numérico

Usar la red como model_y/model_t dentro de LinearDML — teóricamente respaldado por Farrell, Liang & Misra (2021).

Lectura de política · Probablemente la forma más sensata de combinar deep learning e inferencia causal en producción hoy.

Nivel PCH	**Estimando / métrica principal**
L2 heterogéneo, vía representación aprendida	RMSE(tau_hat, tau); R2 de fidelidad si se usa como nuisance

Pregunta activa (1 min)

¿Cuándo el deep causal supera a los árboles, y cuándo el costo de ajustar hiperparámetros no se justifica frente a un Causal Forest?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Tratar alpha como interruptor «balancear es bueno» en vez de hiperparámetro a validar.

Reportar el punto de tau_hat(x) sin ningún intervalo de confianza — mitigación: red como nuisance dentro de DML, bootstrap, o intervalos conformes para decisiones individuales (Cap. 14).

Conexiones conceptuales

Conecta con el Cap. 10 (ortogonalidad) por la vía de usar redes como nuisance en vez de estimador final.

Discusión y ejercicio

Pregunta de discusión

¿En qué punto el deep causal supera a los árboles a medida que crecen las no linealidades del DGP?

Ejercicio (5-10 min)

Barra alpha en {0, 0.1, 1, 10, 100} y grafique RMSE en tau contra el MMD de la representación. Verifique que el alpha que minimiza el MMD no es el que minimiza el RMSE.

Cierre del capítulo

Resumen

- TARNet/CFRNet aprenden una representación compartida con balance opcional.
- Balancear más no siempre reduce el error — es un hiperparámetro, no un principio.
- La inferencia válida con redes tiene solución conocida: usarlas como nuisance dentro de DML.

Referencias clave

(1) Shalit, Johansson & Sontag (2017), TARNet/CFRNet

(2) Curth & van der Schaar (2021), sesgos inductivos

(3) Farrell, Liang & Misra (2021), inferencia con redes profundas

Próximo episodio · Cap. 28 — Control sintético y matrix completion

Gancho: TARNet/CFRNet estiman a nivel de unidad; el capítulo electivo que sigue trata el caso de una sola unidad tratada observada en el tiempo.