Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

29

CAPÍTULO 29

★ Camino crítico

Descubrimiento causal y grafos

Parte VIII · Sesión S26

Plantilla A (teoría e identificación)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Ejecutar PC y NOTEARS y leer una CPDAG correctamente.
2. Explicar la sensibilidad a hiperparámetros y por qué invalida comparaciones ingenuas entre algoritmos.
3. Situar el descubrimiento como exploración, no reemplazo del razonamiento causal sustantivo.

⋆ Antes de clase

Lectura: Cap. 29 — Descubrimiento de grafos (@cap-descubrimiento-grafos)
Lab: L26
Entrega/hito: B3 cierre

Agenda

01 · Determinantes de la pobreza infantil: ¿qué es causa y qué consecuencia?

02 · PC: esqueleto + orientación de colisionadores

03 · NOTEARS: optimización continua con restricción de aciclicidad

04 · CPDAG = misma clase de equivalencia del Cap. 3, vista desde la estructura

05 · Sensibilidad a hiperparámetros (Machlanski et al., 2024)

Problema causal, estimando e identificación

Problema

30 variables sobre pobreza infantil. A diferencia de todo el curso hasta aquí, donde el grafo se asume conocido, ahora el grafo mismo es el objeto de estimación.

Gancho aplicado

El supuesto de causal sufficiency (sin confusores no observados) es fuerte y raramente plausible en economía — el descubrimiento es exploración, no reemplazo del razonamiento sustantivo.

Caso del curso · DAG sintético con estructura conocida para validar PC/NOTEARS.

CPDAG

Output del algoritmo PC: grafo parcialmente dirigido que representa la clase de equivalencia de Markov — DAGs que no pueden distinguirse observacionalmente. Mismo fenómeno del Teorema de la Jerarquía Causal (Cap. 3) visto desde la estructura: si dos grafos inducen las mismas independencias condicionales, ningún algoritmo que solo mire P(v) puede separarlos.

Marco teórico II: supuestos de identificación

Supuesto	Implicación	Chequeo en el caso
Faithfulness	Toda independencia condicional corresponde a d-separación	Requerido por métodos basados en restricciones
Causal sufficiency	Sin confusores no observados afectando 2+ variables	Raramente plausible en datos económicos

GES: tercera familia (basada en score) y sensibilidad a hiperparámetros

GES (Chickering, 2002) maximiza un criterio de ajuste penalizado (BIC) de forma voraz sobre el espacio de DAGs, y es CONSISTENTE pese a ser voraz — más robusta que PC en muestras pequeñas porque no arrastra errores en cascada de decisiones discretas irreversibles. Machlanski et al. (2024): el efecto de los hiperparámetros (alpha en PC, lambda en NOTEARS) puede ser COMPARABLE O MAYOR que las diferencias entre algoritmos — buena parte de las comparaciones publicadas no son replicables fuera de la configuración exacta del estudio.

Punto de quiebre · Conceptual

★ Si un benchmark publicado dice "NOTEARS supera a PC", ¿qué pregunta hay que hacer antes de aceptar esa conclusión?

⏱ 2-4 min · Votación mano alzada o Mentimeter

PC y NOTEARS con causal-learn

```python
from causallearn.search.ConstraintBased.PC import pc
from causallearn.search.FCMBased import notears

# Datos sinteticos con estructura conocida: X0->X1->X2, X3->X2
rng = np.random.default_rng(42)
n, d = 1000, 5
W_true = np.zeros((d, d))
W_true[0, 1] = 2.0; W_true[1, 2] = 1.5; W_true[3, 2] = 1.0
X = rng.standard_normal((n, d)) @ np.linalg.inv(np.eye(d) - W_true)

# PC: esqueleto + orientacion de colisionadores -> CPDAG
pc_graph = pc(X, alpha=0.05, indep_test="fisherz")

# NOTEARS: optimizacion continua; normalizar ANTES (sensible a escala)
W_est = notears.linear(X, lambda1=0.05, loss_type="l2")
print("W estimado (NOTEARS):", np.round(W_est, 2))
```

💡 Normalizar las variables ANTES de NOTEARS: el grafo optimo cambia con las unidades de medida. `indep_test` permite fisherz/kci/chisq; reportar sensibilidad con varios alpha/lambda (Machlanski et al., 2024).

Caso aplicado · DAG de Card (1995) con confusor no observado

Recordatorio del caso

Panel izquierdo: DAG explícito con U (habilidad) afectando educ y wage.

Resultado numérico

Panel derecho: NOTEARS recupera correctamente la estructura sobre datos sintéticos con estructura conocida.

Lectura de política · Sobre datos reales, el grafo estimado es una guía exploratoria, no evidencia definitiva — causal sufficiency raramente se satisface.

Nivel PCH	**Estimando / métrica principal**
Estructural (precede a L1→L2; determina qué conjuntos de ajuste existen)	CPDAG, SHD, precisión/recall frente a grafo verdadero

Pregunta activa (1 min)

Dos algoritmos con SHD similar pero configuraciones de hiperparámetros distintas — ¿es una comparación válida?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Errores comunes

Interpretar la CPDAG como DAG: algunas aristas no se pueden orientar observacionalmente — presentarlas como dirigidas induce falsa certeza.

Aplicar NOTEARS sin normalizar: cambia el grafo óptimo según las unidades de medida.

Un solo umbral de significación: reportar siempre sensibilidad con múltiples valores de alpha/lambda.

Conexiones conceptuales

El output del descubrimiento NO debe alimentar directamente la estimación — es una hipótesis para discutir con conocimiento de dominio, no un supuesto de identificación validado.

Discusión y ejercicio

Pregunta de discusión

¿En qué casos económicos el supuesto de causal sufficiency es plausible?
Dé tres ejemplos donde no lo es.

Ejercicio (5-10 min)

Construya un DAG para nhefs justificando las relaciones. Identifique el set de control óptimo vía el criterio de puerta trasera del Cap. 8.

Cierre del capítulo

Resumen

- PC (restricciones), NOTEARS (optimización continua) y GES (score) son tres familias con supuestos y garantías distintas.
- La CPDAG es el límite estructural de lo identificable — mismo fenómeno del Cap. 3.
- La sensibilidad a hiperparámetros exige reportar la familia de grafos, no un grafo único.

Referencias clave

(1) Spirtes, Glymour & Scheines (2000), algoritmo PC

(2) Zheng et al. (2018), NOTEARS

(3) Machlanski et al. (2024), sensibilidad a hiperparámetros

Próximo episodio · Cap. 30 — Monitoreo de supuestos causales en producción

Gancho: Con o sin grafo descubierto, el sistema ya está en producción. La pregunta cambia de identificación puntual a identificación continua: ¿sigue siendo válida mañana?