Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 **30** 31 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

30

CAPÍTULO 30

★ Camino crítico

Monitoreo de supuestos causales en producción

Parte VIII · Sesión S25

Plantilla B (ingeniería y producción)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Distinguir monitoreo genérico de drift de monitoreo causal-aware.
2. Implementar las 4 métricas del capítulo, en particular el drift del mecanismo de asignación.
3. Interpretar el reporte en el orden correcto: temprano a tardío.

⋆ Antes de clase

Lectura: Cap. 30 — Monitoreo (@cap-monitoreo-causal)
Lab: L25
Entrega/hito: B4 arranca · Validar con grade_b4.py

Agenda

01 · Un servicio puede responder normal con un efecto ya inválido

02 · Monitoreo genérico vs. causal-aware

03 · Las 4 métricas: PSI/ASMD, drift del mecanismo, F de instrumento, estabilidad

04 · Escenario clave: drift sin mover ninguna marginal

El problema de diseño

Decisión	Monitorear la validez de los supuestos causales, no solo la distribución de entradas y salidas.
Alternativas	Monitoreo genérico de ML (drift de inputs/outputs) vs. causal-aware (drift de identificación).
Trade-off clave	Costo de cómputo del monitoreo adicional vs. riesgo de servir estimaciones inválidas sin saberlo.
Stack	scipy.stats, sklearn (LogisticRegression para propensity), Streamlit para el dashboard.
Riesgo principal	Que el servicio siga respondiendo con normalidad mientras el efecto que reporta ya no es válido.

Opciones y trade-offs

Monitoreo genérico

KS univariado en covariables y/o predicciones. Barato, pero no detecta un cambio en la RELACIÓN entre covariables y tratamiento aunque ninguna marginal se mueva.

Monitoreo causal-aware

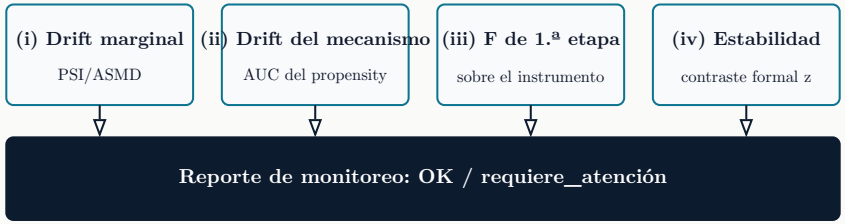
Reejecuta el chequeo de balance del Cap. 7, verifica soporte común, fuerza del instrumento. Más costoso, requiere el pipeline de estimación completo, no solo el servicio de predicción.

Decisión adoptada

Cuatro métricas: (i) drift marginal con PSI/ASMD, no solo KS; (ii) drift del MECANISMO DE ASIGNACIÓN vía AUC del propensity reestimado — detecta ruptura de identificación aunque NINGUNA marginal se mueva; (iii) F de primera etapa correcto (f_test sobre el instrumento, no el F global); (iv) estabilidad del efecto REESTIMADO vía contraste formal, no "¿cae dentro del IC?".

La no confusión no depende de la distribución marginal de cada covariable sino de la relación entre covariables y asignación — si esa relación cambia, el supuesto de identificación puede romperse sin ninguna señal marginal.

Las 4 métricas del monitoreo causal-aware



(ii) detecta ruptura de identificación aunque ninguna marginal se mueva — la más informativa y la más tardía en aparecer

drift_covariables y drift_mecanismo_asignacion

```python
import numpy as np, pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.model_selection import cross_val_predict

# --- (i) Drift marginal de covariables: PSI + ASMD ---
def drift_covariables(df_train, df_rec, covariables, psi_bins=10):
    filas = []
    for c in covariables:
        a, b = df_train[c].dropna(), df_rec[c].dropna()
        s_pool = np.sqrt((a.var(ddof=1) + b.var(ddof=1)) / 2)
        asmd = abs(a.mean() - b.mean()) / s_pool if s_pool > 0 else 0.0
        # PSI sobre bins definidos por los cuantiles de ENTRENAMIENTO
        bordes = np.unique(np.quantile(a, np.linspace(0, 1, psi_bins + 1)))
        p = np.histogram(a, bins=bordes)[0] / len(a)
        q = np.histogram(b, bins=bordes)[0] / len(b)
        p, q = np.clip(p, 1e-6, None), np.clip(q, 1e-6, None)
        psi = float(((p - q) * np.log(p / q)).sum())
        filas.append({'covariable': c, 'asmd': asmd, 'psi': psi,
                      'alerta': (psi > 0.25) or (asmd > 0.25)})
    return pd.DataFrame(filas).sort_values('psi', ascending=False)

# --- (ii) Drift de la relacion X -> D (lo que rompe la identificacion) ---
def drift_mecanismo_asignacion(df_train, df_rec, covariables, tratamiento, tolerancia=0.05):
    def auc(df):
        p = cross_val_predict(LogisticRegression(max_iter=1000), df[covariables],
                              df[tratamiento], cv=5, method='predict_proba')[:, 1]
        return roc_auc_score(df[tratamiento], p)
    auc_train, auc_rec = auc(df_train), auc(df_rec)
    return {'auc_entrenamiento': auc_train, 'auc_reciente': auc_rec,
            'delta_auc': auc_rec - auc_train,
            'alerta': abs(auc_rec - auc_train) > tolerancia}
```

fuerza_instrumento y estabilidad_efecto

```python
import numpy as np
import statsmodels.api as sm
from scipy import stats

# --- (iii) Fuerza del instrumento: F de PRIMERA ETAPA ---
def fuerza_instrumento(df_rec, instrumento, tratamiento, covariables, umbral_f=10):
    # Doble umbral (Etapa 2): F > 10 sano; F en (5, 10) atencion, reportar
    # tambien el IC de Anderson-Rubin (Cap. 17) junto al de Wald; F < 5 alerta
    X = sm.add_constant(df_rec[[instrumento] + covariables])
    modelo = sm.OLS(df_rec[tratamiento], X).fit()
    restriccion = np.zeros((1, X.shape[1]))
    restriccion[0, list(X.columns).index(instrumento)] = 1
    f_stat = float(modelo.f_test(restriccion).fvalue)  # sobre el instrumento, NO el F global
    return {'f_primera_etapa': f_stat, 'alerta_debil': f_stat < umbral_f}

# --- (iv) Estabilidad del efecto: contraste formal entre ventanas ---
def estabilidad_efecto(reestimar, df_rec, theta_orig, se_orig, alpha=0.05):
    theta_rec, se_rec = reestimar(df_rec)  # pipeline completo del Cap. 11
    z_estabilidad = abs(theta_rec - theta_orig) / np.sqrt(se_orig**2 + se_rec**2)
    p_estabilidad = 2 * (1 - stats.norm.cdf(z_estabilidad))
    print(f'Z: {z_estabilidad:.2f}  P-valor: {p_estabilidad:.4f}')
    return {'theta_original': theta_orig, 'theta_reciente': theta_rec,
            'z': z_estabilidad, 'p_valor': p_estabilidad,
            'alerta': p_estabilidad < alpha}
```

02_monografia → 03_notebooks_caso_estudio / 04_notebooks_produccion_hf / 05_labs_sesion

04_notebooks_produccion_hf/B4_monitoring_dashboard/
(Streamlit; KS de covariables, tasa de tratamiento, proxy de estabilidad). Labs L25 y L27 (reentrenar vs alertar). Humo: grade_b4.py. El monitoreo del curso es docente y simulado sobre el benchmark; en un sistema real se conecta al tráfico del endpoint B1.

Recordatorio del caso

Dos escenarios del Notebook B4: (1) drift gradual de covariables — alerta temprana en (i); (2) drift del mecanismo de asignación con marginales IDÉNTICAS.

Resultado numérico

En el escenario (2), drift_covariables no reporta nada — correctamente, porque nada marginal cambió— y solo drift_mecanismo_asignacion lo detecta.

Lectura de política · Es la demostración práctica de por qué un monitoreo de MLOps genérico, por completo que sea en su terreno, no basta para un sistema causal.

Mapeo PCH del capítulo · pregunta activa

Nivel PCH	**Estimando / métrica principal**
L2 continuo (monitoreo, no una estimación nueva)	PSI/ASMD, AUC del propensity, F de primera etapa, contraste z de estabilidad

Pregunta activa (1 min)

Si drift_covariables no reporta alertas, ¿es seguro asumir que el supuesto de no confusión sigue vigente?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Señales de alerta y checklist operativo

- ☐ El sistema solo monitorea si el endpoint responde, no la validez de lo que responde.
- ☐ El chequeo de balance del entrenamiento nunca se vuelve a ejecutar sobre datos de producción.
- ☐ No existe una ventana de referencia fija — cada comparación usa un punto de referencia distinto.
- ☐ Las alertas se generan pero nadie las revisa — no hay proceso definido para el estado «requiere atención».

Si dos o más señales están presentes, el sistema no está listo según los criterios de este curso.

Punto de quiebre · Aplicado

★ Ordene las 4 métricas de más temprana a más tardía como señal de alerta. ¿Qué pasa si un sistema solo monitorea la más tardía?

⏱️ 2-4 min · Votación mano alzada o Mentimeter

Discusión y ejercicio

Pregunta de discusión

Proponga un escenario donde la regla de asignación cambie sin mover ninguna distribución marginal de covariables. ¿Qué supuesto de identificación se viola?

Ejercicio (5-10 min)

Compare, sobre una ventana con drift leve, el veredicto del test formal de estabilidad del efecto con el criterio ingenuo (¿cae dentro del IC original?). Muestre un caso en que difieran.

Cierre del capítulo

Resumen

- Monitoreo genérico vigila datos; monitoreo causal-aware vigila el mecanismo de identificación.
- PSI/ASMD reemplazan al KS solo; el drift del propensity detecta lo que ninguna marginal revela.
- El contraste formal z, no la inspección visual del IC, decide si el efecto cambió.

Referencias clave

(1) Kästner et al. (2024) / Huyen (2022), Cap. 8, drift genérico

(2) Stock & Yogo (2005), umbral F>10

(3) Rubin (2001), criterios de balance (ASMD)

Próximo episodio · Cap. 31 — Aprendizaje continuo y panorama de Reinforcement Learning causal

Gancho: El reporte de monitoreo puede marcar requiere_atencion — ¿qué se hace entonces?