Progreso del curso · 32 capítulos, 9 partes

Parte 0
Introducción

1 2

Parte I
Fundamentos estructurales y de datos

3 4 5◇ 6 7 8 9

Parte II
Estimación flexible y primer despliegue

10 11 12 13 14 15

Parte III
Diseños de identificación con ML

16◇ 17◇ 18◇

Parte IV
Publicación y operación en producción

19 20

Parte V
Heterogeneidad, políticas y targeting

21 22

Parte VI
Explicación, equidad y decisión

23 24 25 26

Parte VII
Métodos avanzados

27◇ 28◇

Parte VIII
Estructura, monitoreo y frontera

29 30 **31** 32

■ previos · ■ actual · □ próximos · ◇ profundización electiva (no bloquea el camino ⋆)

31

CAPÍTULO 31

★ Camino crítico

Aprendizaje continuo y panorama de Reinforcement Learning causal

Parte VIII · Sesión S27

Plantilla B (ingeniería y producción)

IA Causal en Producción

Curso ECO-490 / ECON-540 · Edición 2026

Roadmap del capítulo

Objetivos de aprendizaje

1. Implementar el patrón champion-challenger con doble validación.
2. Explicar por qué un placebo no significativo no basta para promover un reentrenamiento.
3. Describir por qué combinar datos observacionales e interventivos acelera la convergencia en bandits causales.

⋆ Antes de clase

Lectura: Cap. 31 — Aprendizaje continuo (@cap-aprendizaje-continuo)
Lab: L27
Entrega/hito: B4

Agenda

01 · Parte I: cuándo y cómo reentrenar sin poner en riesgo el sistema

02 · Reentrenamiento automático vs. champion-challenger

03 · Doble validación: placebo + comparación de poblaciones

04 · Parte II: de decisiones únicas a secuenciales — panorama RL causal

05 · Bandits causales: combinar observacional + interventivo acelera la convergencia

El problema de diseño

Decisión	Cuándo y cómo actualizar un sistema causal sin ponerlo en riesgo.
Alternativas	Reentrenamiento automático periódico vs. champion-challenger con validación humana.
Trade-off clave	Reentrenar sin auditoría (rápido, arriesgado) vs. champion-challenger (más lento, preserva intercepción humana).
Stack	scipy.stats (KS para comparar poblaciones), el pipeline de CI del Cap. 20.
Riesgo principal	Que el nuevo estimador refleje una población o mecanismo distintos sin que nadie lo audite antes de publicarlo.

Opciones y trade-offs

Reentrenamiento automático

Minimiza trabajo operativo. Riesgo: un cambio genuino y legítimo en el efecto también pasaría un placebo — la prueba de humo sola no basta para descartar un cambio de población.

Champion-challenger

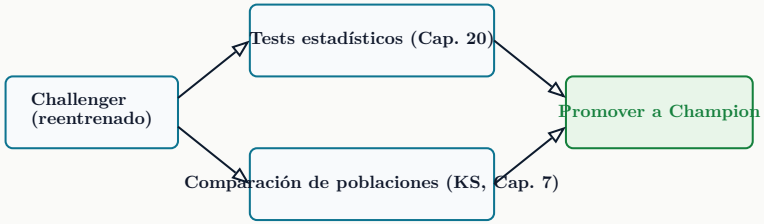
El challenger se evalúa en paralelo; solo reemplaza al champion tras revisar que los supuestos de identificación siguen siendo defendibles, no solo comparar métricas.

Decisión adoptada

Champion-challenger: ninguna actualización reemplaza al servicio automáticamente. El challenger pasa las pruebas del Cap. 20 MÁS una comparación explícita de su población de entrenamiento contra la del champion (chequeo de balance del Cap. 7).

Un cambio de población puede ser perfectamente consistente con un placebo no significativo y, aun así, representar un efecto válido para una población distinta a la que el equipo cree estar sirviendo.

Champion-challenger: doble validación antes de promover



si cualquiera de los dos falla → revisión humana, no auto-promoción

evaluar_challenger()

```python
def evaluar_challenger(champion, challenger, df_reciente, schema, alpha=0.05):
    resultado = {
        "pasa_tests_estadisticos": True,  # ya paso CI/CD (Cap. 20)
        "poblacion_comparable": True,
    }
    from scipy import stats
    for c in schema.covariates:
        _, p = stats.ks_2samp(champion.datos_entrenamiento[c], df_reciente[c])
        if p < alpha:
            resultado["poblacion_comparable"] = False
    resultado["promover"] = (resultado["pasa_tests_estadisticos"]
                             and resultado["poblacion_comparable"])
    if not resultado["promover"]:
        resultado["accion"] = "Revision humana requerida antes de promover"
    return resultado
```

💡 Doble validacion: las pruebas estadisticas del Cap. 20 (placebo) MAS la comparacion KS por covariable contra la poblacion de entrenamiento del champion. Un cambio de poblacion puede ser consistente con un placebo no significativo.

Punto de quiebre · Conceptual

★ ¿Por qué un placebo no significativo no es evidencia suficiente de que un modelo reentrenado sea seguro de promover a producción?

⏱ 2-4 min · Votación mano alzada o Mentimeter

Problema

Todo el curso trató la decisión como elección única: estimar, elegir política, desplegar. RL estudia decisiones SECUENCIALES, donde cada acción afecta el estado futuro y, por tanto, las decisiones siguientes.

Gancho aplicado

El RL clásico asume, casi siempre implícitamente, que el entorno reacciona sin confusión oculta entre decisiones pasadas y recompensas futuras — un supuesto que falla con frecuencia en datos observacionales.

Caso del curso · Bandits causales: puente natural desde el policy learning del Cap. 21.

Bandits causales: por qué combinar datos ayuda, no solo evita sesgo

Bareinboim, Forney & Pearl muestran que combinar la distribución observacional P(y|x) con la interventiva P(y|do(x)) que el agente genera experimentando produce COTAS más estrechas sobre la recompensa de cada brazo que cualquiera de las dos fuentes por separado — y un agente que explota esas cotas converge más rápido que uno que ignora los datos históricos. La brecha entre lo observacional y lo interventivo es información explotable sobre la existencia de un confusor.

Recordatorio del caso

RL causal es, en 2026, un programa de investigación activo — a diferencia de DML o meta-learners, que ya cuentan con implementaciones estándar y práctica de industria asentada.

Resultado numérico

Regímenes de tratamiento dinámicos (Zhang & Bareinboim, 2019): una variable puede ser simultáneamente confusor de una decisión posterior y mediador de una anterior.

Lectura de política · Entender POR QUÉ la confusión importa en RL, sin pretender una cobertura de implementación que la madurez del campo no respalda todavía.

Nivel PCH	**Estimando / métrica principal**
L2 secuencial (champion-challenger); L2/L3 con confusión (bandits/RL)	poblacion_comparable + pasa_tests_estadisticos; regret del bandit causal

Pregunta activa (1 min)

¿Por qué la pregunta "¿puedo promover este challenger?" es, formalmente, la misma pregunta de transportabilidad del Cap. 26?

Escalera PCH: L1 (asociación) ⊆ L2 (intervención) ⊆ L3 (contrafactual) — cada nivel exige supuestos estrictamente más fuertes que el anterior. Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Discusión y ejercicio

Pregunta de discusión

Describa un escenario donde ignorar la confusión en los datos históricos de un bandit lleve a subestimar sistemáticamente el valor de un brazo poco explorado.

Ejercicio (5-10 min)

Implemente evaluar_challenger() sobre dos versiones del modelo del Notebook A2 (entrenadas sobre submuestras deliberadamente distintas). Verifique que el sistema marca correctamente la necesidad de revisión humana.

Cierre del capítulo

Resumen

- Champion-challenger preserva intercepción humana; un placebo solo no basta.
- La comparación de poblaciones (Cap. 7) es la segunda validación obligatoria antes de promover.
- Bandits causales: combinar datos observacionales e interventivos acelera la convergencia, no solo evita sesgo.

Referencias clave

(1) Huyen (2022), Cap. 9, continual learning

(2) Bareinboim, Forney & Pearl (2015), bandits causales

(3) Zhang & Bareinboim (2019), regímenes de tratamiento dinámicos

Próximo episodio · Cap. 32 — El lado humano de los sistemas causales

Gancho: El sistema ya sabe cuándo y cómo actualizarse. Falta el último paso, casi nunca técnico: comunicar el resultado a quien debe decidir con él.